

TED 8750 - PRICE

PRIVACIDADE NOS CENSOS EDUCACIONAIS

Termo de Execução Descentralizada entre
o Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira
e a Universidade Federal de Minas Gerais

PRODUTO 01

Relatório sobre o panorama internacional e o contexto do Inep a
respeito dos métodos de tratamento de controle de privacidade na
divulgação estatística



Mário S. ALVIM
Ramon G. GONZE

Jeroen van de GRAAF
Gabriel H. NUNES

03 de julho de 2020

Resumo

O presente documento consiste em um *Relatório sobre o panorama internacional e o contexto do Inep a respeito dos métodos de tratamento de controle de privacidade na divulgação estatística*, previsto como Produto 01 no plano de trabalho do Termo de Execução Descentralizada (TED) 8750. Este TED foi firmado entre o Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira (Inep) e a Universidade Federal de Minas Gerais (UFMG), e encontra-se em execução pelo Laboratório Inscript (*Laboratory of Information Security, Cryptography, Privacy, and Transparency*) do Departamento de Ciência da Computação (DCC) da Universidade.

Neste relatório apresentam-se, através de vários estudos de caso, um panorama internacional e um nacional de como institutos produtores de estatísticas oficiais equilibram requisitos de transparência e de proteção à privacidade em seus métodos de divulgação de informação. Cada estudo de caso consiste em: (i) um sumário da regulamentação geral mais relevante sobre privacidade no país ou região onde o caso se insere; (ii) um sumário da regulamentação específica identificada como pertinente ao instituto em questão; (iii) a identificação dos tipos de dados divulgados pelo instituto, distinguindo-se entre micro-dados e dados agregados; e (iv) uma descrição das medidas empregadas para mitigação de possíveis violações de privacidade decorrentes da divulgação.

A cobertura do panorama internacional inicia-se com um sumário das principais diretivas e regulamentações gerais sobre privacidade estabelecidas pela Organização das Nações Unidas (ONU) e outros organismos internacionais relevantes. Em seguida, apresentam-se os seguintes estudos de caso no contexto dos Estados Unidos: (1) o caso das práticas de limitação de divulgação das agências federais norte-americanas; (2) o caso da divulgação de dados estatísticos pelo Centro Nacional de Estatísticas da Educação (*National Center for Education Statistics* - NCES); e (3) o caso da divulgação de dados estatísticos pelo Escritório do Censo (*Census Bureau* - USCB); no contexto da União Europeia: (4) o caso da divulgação de dados educacionais por escolas e pelo Ministério da Educação da Holanda; e no contexto da Austrália: (5) o caso da divulgação de dados estatísticos pelo Escritório Australiano de Estatística (*Australian Bureau of Statistics* - ABS).

A cobertura do panorama nacional inicia-se com um sumário das principais diretivas e regulamentações gerais brasileiras sobre transparência e privacidade, com foco na Lei 12.527/2011, conhecida como *Lei de Acesso à Informação* (LAI), e na Lei 13.709/2018,

conhecida como *Lei Geral de Proteção de Dados Pessoais* (LGPD ou LGPD). Em seguida, apresentam-se seguintes estudos de caso nacionais: (1) o caso da divulgação de dados pelo Instituto Brasileiro de Geografia e Estatística (IBGE); e (2) o caso da divulgação de dados pelo Portal da Transparência do Governo Federal.

Na sequência, procede-se ao cerne deste documento: uma avaliação comparativa da atual forma de divulgação dos Censos Educacionais pelo Inep frente a práticas correntes nos panoramas internacional e nacional, com foco em potenciais riscos à privacidade. Primeiramente, apresenta-se uma contextualização da atual situação do Instituto, incluindo sumários da principal regulamentação específica a ele aplicável, da sua atual forma de divulgação dos Censos Educacionais, e das metodologias de mitigação de danos à privacidade por ele empregadas atualmente. Em seguida, provê-se uma análise comparativa da situação do Inep com aquela dos outros estudos de caso internacionais e nacionais descritos neste documento. A partir desta análise, ressaltam-se as seguintes conclusões:

- (i) Frente a todos os casos internacionais estudados, o Inep publica em seus Censos Educacionais a maior quantidade de microdados individuais e em maior nível de detalhes.
- (ii) Em todos os casos internacionais estudados, os órgãos produtores de estatísticas oficiais adotam medidas mais rígidas do que as do Inep na mitigação de danos à privacidade causados por publicação de microdados. Tais medidas incluem, e.g., a não publicação de microdados individuais de estudantes sob nenhuma forma, a publicação de microdados apenas por amostras da população, ou a permissão de acesso a todo o conjunto de microdados apenas sob autorização prévia, de acordo com os objetivos do pesquisador ou indivíduo interessado, e em salas seguras.
- (iii) As atuais técnicas de proteção de privacidade utilizadas pelo Inep nos microdados divulgados, consistindo apenas em *desidentificação* –em que se removem possíveis identificadores individuais óbvios dos registros, como nome, CPF e RG– e em *pseudonimização* –em que tais identificadores individuais óbvios são substituídos por um código único de identificação artificialmente criado–, estão sujeitas a vários riscos de privacidade já identificados na literatura.

Em seguida, discutem-se riscos decorrentes da atual forma de divulgação adotada pelo Instituto de acordo com a literatura técnica sobre proteção de privacidade.

Por fim, o corpo principal do documento encerra-se com algumas considerações finais.

Como anexos, proveem-se: uma seleção dos trechos da Constituição da República Federativa do Brasil, da Lei de Acesso à Informação (LAI) e da Lei Geral de Proteção de Dados Pessoais (LGPD) identificados como mais relevantes no escopo deste projeto; uma comparação das principais diferenças entre a LGPD brasileira e o Regulamento Geral de Proteção de Dados - RGPD (ou *General Data Protection Regulation* - GDPR) europeu, de acordo com o trabalho de Richie Koch; e um panorama da percepção da questão de privacidade pela sociedade brasileira, formado por uma seleção de reportagens e artigos recentes relevantes produzidos sobre o assunto.

Sumário

1	Introdução e motivação	1
1.1	Objetivo deste documento	1
1.2	Contextualização e definição de “privacidade”	2
1.3	A preocupação com privacidade relativa à divulgação pelo Inep dos Censos Educacionais	4
1.4	Organização deste documento	6
2	Estudos de caso do panorama internacional	9
2.1	Contexto da Organização das Nações Unidas e de outros organismos internacionais	9
2.2	Contexto dos Estados Unidos da América	11
2.2.1	Regulamentação geral	11
2.2.2	Estudo de caso internacional 1: Práticas de limitação de divulgação das agências federais	11
2.2.3	Estudo de caso internacional 2: Divulgação de dados estatísticos pelo Centro Nacional de Estatísticas da Educação	16
2.2.4	Estudo de caso internacional 3: Divulgação de dados estatísticos pelo Escritório do Censo	17
2.2.4.1	Técnicas utilizadas nos Censos de 1960 a 2010 para a publicação de microdados na forma de arquivos PUMS	18
2.2.4.2	Técnicas utilizadas no Censo de 2020	20
2.3	Contexto da União Europeia	21
2.3.1	Regulamentação geral	21
2.3.2	Estudo de caso internacional 4: Divulgação de dados educacionais por escolas e pelo Ministério da Educação da Holanda	23

2.4	Contexto da Austrália	27
2.4.1	Regulamentação geral	27
2.4.2	Estudo de caso internacional 5: Divulgação de dados estatísticos pelo Escritório Australiano de Estatística	28
3	Estudos de caso do panorama nacional	31
3.1	Regulamentação geral	31
3.2	Estudo de caso nacional 1: Divulgação de dados estatísticos pelo IBGE . .	37
3.2.1	Regulamentação específica	37
3.2.2	Dados divulgados	37
3.3	Estudo de caso nacional 2: Divulgação de dados pelo Portal da Transparência do Governo Federal	39
4	Análise da atual situação do Inep frente aos panoramas internacional e nacional e à literatura técnica em privacidade	40
4.1	Descrição da atual forma de divulgação dos Censos Educacionais pelo Inep	40
4.1.1	Regulamentação específica aplicável	41
4.1.2	Atual forma de divulgação dos Censos Educacionais	41
4.1.3	Métodos de proteção de privacidade atualmente empregados	43
4.2	Sumários comparativos da atual situação do Inep com os estudos de caso internacionais e nacionais	43
4.3	Destaques da comparação de estudos de caso identificados como relevantes à atual situação do Inep	44
4.4	Possíveis riscos à privacidade que a literatura técnica aponta na atual situação do Inep	47
5	Considerações finais	53
	Referências Bibliográficas	55
	Anexos	65
A	Constituição da República Federativa do Brasil: Principais trechos relacionados ao escopo deste projeto	66
B	LAI: Principais trechos relacionados ao escopo deste projeto	68

C LGPD: Principais trechos relacionados ao escopo deste projeto	73
D Principais diferenças entre a LGPD brasileira e a GDPR europeia	79
E Um panorama da percepção da questão de privacidade pela sociedade brasileira	82
Lista de Siglas	84
Glossário	87

Lista de Tabelas

2.2.1 Práticas de proteção à privacidade adotadas pelas agências federais norte-americanas em 2005	15
2.2.2 Práticas de proteção à privacidade adotadas pelo USCB nos Censos de 1960 a 2010 para a publicação de Amostras de Microdados de Uso Público (PUMS)	19
4.2.1 Sumário comparativo dos estudos de caso internacionais efetuados no contexto dos EUA	50
4.2.2 Sumário comparativo dos estudos de caso internacionais efetuados no contexto da União Europeia e Austrália	51
4.2.3 Sumário comparativo dos estudos de caso efetuados no contexto nacional, incluindo o do Inep em sua divulgação dos Censos Educacionais	52

1 Introdução e motivação

Este documento consiste no Produto 01, intitulado *Relatório sobre o panorama internacional e o contexto do Inep a respeito dos métodos de tratamento de controle de privacidade na divulgação estatística*, do plano de trabalho do Termo de Execução Descentralizada (TED) 8750, firmado entre o Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira (Inep) e a Universidade Federal de Minas Gerais (UFMG), e em execução pelo Laboratório Inscript (*Laboratory of Information Security, Cryptography, Privacy, and Transparency*) do Departamento de Ciência da Computação (DCC) da Universidade.

1.1 Objetivo deste documento

De acordo com o plano de trabalho do TED 8750, o Produto 01 que este documento implementa consiste em um:

Relatório com o panorama internacional sobre o tratamento de dados com vistas a garantir a transparência das pesquisas e privacidade dos dados pessoais na divulgação estatística de outros institutos produtores de estatísticas oficiais, incluindo a contextualização da situação do Inep.

Mais especificamente, visa-se a atender ao Objetivo Específico 01 do plano de trabalho:

[L]evantar o panorama internacional dos procedimentos de garantia da privacidade em bases de dados de pesquisas estatísticas, em especial nos produtos de disseminação dos microdados. O contexto desta pesquisa bibliográfica deve abranger os normativos técnicos e as políticas de tratamento de dados pessoais de outros institutos relevantes de pesquisas estatísticas, no cenário internacional, relacionando-os ao contexto do Inep. O objetivo desta pesquisa é estabelecer a percepção da situação atual do Inep frente a institutos similares em outros países, além de reconhecer os desafios inerentes e as melhores práticas aplicáveis. Neste sentido, a pesquisa será fundamental para a definição das melhorias desejadas na atual política de disseminação de microdados do Inep, uma vez que trará evidências sobre o tratamento técnico realizado por outros institutos e o embasamento necessário à tomada de decisão.

1.2 Contextualização e definição de “privacidade”

Uma primeira aproximação, intuitiva e concisa, da definição do termo “privacidade” pode ser encontrada na Wikipédia [3], que afirma que “privacidade” pode ser entendida como “o direito à reserva de informações pessoais e da própria vida pessoal: o direito de ser deixado em paz”. O termo pode ser também entendido como a vontade de controlar a exposição e a disponibilidade de informações acerca de si mesmo, ou seja, a quantidade de controle que um indivíduo exerce sobre a entrada e a saída de declarações de si mesmo e a quantidade de contato que se tem com outras pessoas.

Já uma abordagem mais formal é oferecida pela Dra. Helen Nissenbaum, professora de ciência da informação na Universidade *Cornell Tech* e expoente internacional na área de pesquisa em privacidade. Nissenbaum defende que qualquer interpretação pragmática do termo *privacidade* está atrelada ao fluxo de informações pessoais [78]. Sua tese é de que o que realmente causa a sensação de “violação de privacidade” nas pessoas não é o *ato em si de compartilhamento de informação* –já que a maioria das pessoas entende que isto é essencial para a vida social– mas o *uso inapropriado da informação compartilhada*. Entretanto, os limites e o conteúdo do que é considerado privado diferem entre culturas e indivíduos, e depende também do contexto em que a informação é compartilhada.

A preocupação com a privacidade tem aumentando nas últimas décadas. O Regulamento Geral sobre a Proteção de Dados (RGPD) da União Europeia [29], de 2016, aponta que:

A rápida evolução tecnológica e a globalização criaram novos desafios em matéria de proteção de dados pessoais. A recolha e a partilha de dados pessoais registaram um aumento significativo. As novas tecnologias permitem às empresas privadas e às entidades públicas a utilização de dados pessoais numa escala sem precedentes no exercício das suas atividades. As pessoas singulares disponibilizam cada vez mais as suas informações pessoais de uma forma pública e global. As novas tecnologias transformaram a economia e a vida social e deverão contribuir para facilitar a livre circulação de dados pessoais na União e a sua transferência para países terceiros e organizações internacionais, assegurando simultaneamente um elevado nível de proteção dos dados pessoais.

No contexto tecnológico, tal preocupação já existe há pelo menos algumas dezenas de anos. Por exemplo, já no ano 2000 Simson e Garfinkel descreviam em seu livro *Database Nation* [56] diversos cenários de possíveis violações de privacidade decorrentes do uso de novas tecnologias disponíveis na época. Os exemplos citados incluíam casos em que dados de um consumidor poderiam ser cruzados (e.g., dados do cartão de crédito com a conta do supermercado), ou em que *cookies* em navegadores poderiam ser usados para rastreamento do comportamento do usuário na Internet.

Como um exemplo de como o uso de novas tecnologias pode causar a sensação de violação de privacidade de maneiras inéditas –e que desafiam nossa capacidade de classificar precisamente onde teria ocorrido a efetiva “violação”–, considere o seguinte cenário. Imagine o

centro de uma cidade onde em toda esquina haja câmeras que gravem a imagem dos transeuntes e os identifiquem por reconhecimento facial ou pelo seu “modo de andar” (*gait*, no termo original em inglês). Considere ainda que todas as câmeras estejam conectadas a um grande banco de dados, possibilitando o cruzamento de informações e permitindo, assim, o acompanhamento em tempo real dos trajetos realizados por qualquer indivíduo pela cidade. A contemplação de tal cenário provoca em um grande número de pessoas um desconforto associado a uma percepção de *violação de privacidade*. Repare, entretanto, que *toda a informação coletada neste caso consiste, em princípio, em informação pública*, afinal, o trajeto de pessoas em vias públicas é observável por qualquer um que esteja nestas vias. Porém, sem aparatos tecnológicos, seria impraticável para agentes do Estado parar cada pessoa em cada esquina e registrar seus movimentos, e seria ainda mais infactível processar e cruzar as informações obtidas em tempo real.

O exemplo anterior ilustra um ponto crucial da realidade em que vivemos, o qual é central para o presente projeto: *o uso de tecnologia possibilita que informações a princípio consideradas públicas se tornem uma ameaça à privacidade de indivíduos*. Consequentemente, a crescente capacidade de coleta, armazenamento e processamento de informação provida por avanços tecnológicos força a sociedade a continuamente rever sua percepção de riscos de violação de privacidade. Do ponto de vista prático, no ano de 2020 o cenário esboçado no exemplo acima nem pode mais ser considerado puramente futurista: a cidade de Londres, na Inglaterra, já analisa as imagens de milhares de câmeras para proteger seu centro contra ataques terroristas [49], enquanto o governo da China usa essa mesma tecnologia para monitorar sua população [55]. Em ambos os casos, há forte reação de setores da sociedade preocupados com a proteção da privacidade dos cidadãos.

No Brasil, a preocupação com privacidade permaneceu relativamente diminuta até recentemente. De fato, frequentemente vinham-se adotando novas tecnologias sem um cuidadoso senso crítico quanto aos potenciais riscos à privacidade delas decorrentes. Esse cenário, entretanto, vem felizmente evoluindo. Pode-se argumentar que um catalisador relevante para essa maior conscientização sobre os riscos das novas tecnologias digitais em relação à privacidade foram as revelações de Edward Snowden em 2013. Snowden demonstrou que o governo dos EUA colecionava dados de cidadãos estrangeiros numa escala gigantesca e sem precedentes, desenvolvendo plataformas e tecnologias específicas para cruzar e minerar esses dados [16]. No caso particular do Brasil, chamou a atenção a revelação de que os celulares da então presidente da República, Dilma Rousseff, e de seus assessores foram *hackeados*, vazando dados dos círculos mais restritos do governo.

A conscientização fomentada por estes e outros acontecimentos eventualmente provocou respostas do Poder Legislativo brasileiro. A Lei 13.709/2018, conhecida como *Lei Geral de Proteção de Dados Pessoais* (LGPD ou LGPD) [41], sancionada em 14 de agosto de 2018 e publicada no Diário Oficial da União no dia seguinte, alterou significativamente a maneira como organismos públicos e privados devem lidar com informações pessoais, visando à preservação da privacidade.¹

¹A princípio, o início da vigência da LGPD ocorreria em fevereiro de 2020. No entanto, em dezembro de 2018, o presidente Michel Temer editou a Medida Provisória 869/2018 [61], prevendo a criação da

Por outro lado, a Lei 12.527/2011, conhecida como *Lei de Acesso à Informação* (LAI) [47], determina ao poder público o dever de garantir o amplo acesso à informação, particularmente àquela considerada de interesse coletivo ou geral, a qual deve ser disponibilizada via Internet independentemente de requerimento. Determina, também, o direito de acesso às demais informações não imediatamente disponibilizadas via Internet, e garante o acesso à informação primária, íntegra, autêntica, e atualizada em ambos os casos.² A própria LAI aponta, entretanto, que a informação pessoal deve ser protegida, reconhecendo que o cuidado com a privacidade dos indivíduos é uma questão central mesmo na regulamentação sobre acesso a dados.

Neste contexto, impõe-se aos órgãos públicos que coletam, mantêm e divulgam dados o desafio de conciliar os requisitos de transparência com os requisitos de proteção de privacidade impostos pela atual legislação brasileira. Na próxima seção, introduzimos tal desafio no contexto particular do Inep relativo à divulgação de seus Censos Educacionais.

1.3 A preocupação com privacidade relativa à divulgação pelo Inep dos Censos Educacionais

O Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira (Inep)³, autarquia federal vinculada ao Ministério da Educação (MEC),⁴ tem entre suas atribuições a responsabilidade pela execução de levantamentos estatísticos sobre a educação nacional nos níveis básico e superior, incluindo o tratamento de dados, o controle de qualidade, e a produção e divulgação das estatísticas anuais específicas e dos indicadores educacionais.

Nesta seção, fundamentamos a relevância do presente TED 8750, que tem como objetivo uma cuidadosa avaliação da atual forma como o Inep lida com o compromisso entre transparência na divulgação de dados de interesse público e a proteção à privacidade dos titulares dos dados. O contexto do Inep é discutido em detalhes na Seção 4, mas para os objetivos da presente seção é suficiente notar os seguintes pontos:

1. O Inep produz e divulga várias Pesquisas de grande relevância nacional, incluindo o *Censo da Educação Básica*, o *Censo da Educação Superior*, o *Exame Nacional do Ensino Médio* (ENEM), o *Sistema de Avaliação da Educação Básica* (SAEB), o *Exame Nacional de Certificação de Competências de Jovens e Adultos* (ENCCEJA) e o *Exame Nacional de Desempenho dos Estudantes* (ENADE).

Autoridade Nacional de Proteção de Dados (ANPD) para fiscalizar o cumprimento da LGPD e alterando o início da vigência da lei para 14 de agosto de 2020. Em abril de 2020, o presidente Jair Bolsonaro editou a Medida Provisória 959/2020 [63], adiando novamente a entrada em vigor da LGPD para maio de 2021. Finalmente, em junho de 2020 foi sancionada a Lei 14.010/2020, que determina que as sanções da LGPD só devem ser aplicadas a partir de agosto de 2021 [42]. A LGPD é abordada em mais detalhes na Seção 3.1.

²A LAI também é abordada em mais detalhes na Seção 3.1.

³<http://www.inep.gov.br/>

⁴<https://www.gov.br/mec/>

2. O formato atual de publicação destes Censos consiste em *microdados*, ou seja, dados na menor unidade de agregação possível, que incluem informações em nível individual sobre alunos, professores e escolas.
3. As técnicas de proteção de privacidade atualmente aplicadas aos microdados divulgados pelo Inep consistem em:
 - *desidentificação*, pela qual são removidos possíveis identificadores individuais óbvios dos registros (como nome, CPF, RG, ou endereços em níveis mais detalhados que as cidades); e
 - *pseudonimização*, em que o Instituto atribui a cada registro um código único de identificação artificialmente criado, substituindo identificadores individuais naturais (como nome, CPF ou RG).

Neste contexto, a harmonização dos requisitos legais da Lei de Acesso à Informação (LAI) e da Lei Geral de Proteção de Dados Pessoais (LGPD) se apresentam como desafios para o Inep, em particular, na divulgação dos dados de suas Pesquisas.

De fato, os pesquisadores brasileiros Queiroz e Motta já apontaram, em estudo de 2015, fragilidades quanto à proteção de privacidade decorrentes da atual forma de divulgação de dados dos Censos Educacionais pelo Inep [102]. Utilizando o arquivo referente aos docentes do Censo da Educação Superior do ano de 2013, os pesquisadores puderam reidentificar unicamente um dos autores do estudo dentre todos os 383.683 registros de docentes presentes na base, utilizando apenas sua data de nascimento, gênero, e nome da Instituição de Ensino Superior à qual estava vinculado.

O Produto 02 do presente TED 8750 tem como objetivo principal produzir uma análise quantitativa deste e de outros riscos de violação de privacidade no contexto do Inep. Além disso, a Seção 4.4 do presente documento apresenta uma análise preliminar dos potenciais riscos à privacidade previstos pela literatura técnica na área, além de uma contextualização da atual situação do Inep frente a outros institutos de estatísticas oficiais inseridos nos panoramas internacional e nacional. Na presente seção, portanto, limitamo-nos a produzir mais um exemplo de risco à privacidade que julgamos ilustrativo.

O filho de um dos autores do presente documento tem hoje 14 anos e, portanto, consta nas divulgações dos microdados dos Censos do Ensino Básico pelo Inep em vários anos distintos. Apesar do nome, RG e CPF do adolescente não constarem nos microdados publicados, pudemos reidentificá-lo de forma relativamente fácil da seguinte maneira. Primeiramente, a partir do nome da escola onde o adolescente estuda, encontramos o identificador único correspondente a esta escola na própria base do Inep. Em um segundo momento, entre os alunos desta escola selecionamos na base aqueles com a mesma data de nascimento do adolescente em quem estávamos interessados. Como havia apenas um estudante nesta escola com a data de nascimento em questão, e sabendo que o adolescente alvo estava na base, pudemos reidentificá-lo e recuperar seus dados sensíveis, como, por exemplo, se ele é ou não portador de necessidades especiais.

Neste caso, a reidentificação foi possível porque não havia nenhum outro aluno naquela mesma escola com a mesma data de nascimento do aluno alvo. Caso houvesse, a inspeção dos microdados retornaria o registro de todos estes alunos, e seria necessária alguma informação auxiliar (como a série do aluno) para reidentificá-lo. Porém, nesse ponto, seria possível que alguma informação sensível sobre o adolescente já tivesse sido revelada. Por exemplo, caso todos os alunos que compartilhem de sua data de nascimento em sua escola fossem (ou não fossem) portadores de necessidades especiais, ficaria evidenciado se o aluno em questão também seria (ou não seria) portador de tais necessidades. Este exemplo demonstra que *mesmo que o aluno não tivesse sido unicamente reidentificado na base do Inep, uma violação de privacidade já poderia ter ocorrido*.

No exemplo acima, a reidentificação desse aluno em particular demandou menos de 20 minutos de trabalho de um membro da equipe do Inscript que já está familiarizado com as bases de microdados do Censo da Educação Básica. Entretanto, seria perfeitamente possível implementar-se uma página na Internet onde o usuário escolheria o nome da escola, digitaria a data de nascimento de um aluno, e visualizaria imediatamente todos os dados do aluno presentes no Censo. O esforço para desenvolver tal página não seria proibitivo: talvez um dia de trabalho de um profissional de tecnologia da informação.

A discussão acima demonstra que há uma possibilidade concreta de violações de privacidade decorrentes da atual forma de divulgação dos Censos Educacionais por parte do Inep. É imperativo, portanto, estudar cuidadosamente o contexto de tais Censos, identificando suas peculiaridades e encontrando técnicas que permitam o melhor compromisso entre a transparência da informação divulgada e a proteção da privacidade dos indivíduos. Este é exatamente o objetivo geral do presente TED 8750.

1.4 Organização deste documento

O presente documento se foca em estudos de caso de como outras instituições produtoras de estatísticas, em nível internacional e nacional, atuam na mitigação de possíveis danos à privacidade, e na comparação destes estudos de caso com a atual situação do Inep.

O restante deste documento está organizado da seguinte forma.

- **Estudos de caso do panorama internacional** (Seção 2): Nesta seção provemos um panorama internacional de como institutos produtores de estatísticas oficiais equilibram requisitos de transparência e de proteção à privacidade em seus métodos de divulgação de informação. Iniciamos a seção com um sumário das principais diretrizes e regulamentações gerais sobre privacidade estabelecidas pela Organização das Nações Unidas (ONU) e outros organismos internacionais relevantes (Seção 2.1). Em seguida, apresentamos a seguinte coleção de estudos de caso internacionais.

- I. **No contexto dos Estados Unidos da América** (Seção 2.2): Após um sumário dos aspectos mais relevantes da regulamentação geral norte-americana sobre privacidade (Seção 2.2.1), apresentamos:

- **Estudo de caso internacional 1** (Seção 2.2.2): *Práticas de limitação de divulgação das agências federais norte-americanas.*
- **Estudo de caso internacional 2** (Seção 2.2.3): *Divulgação de dados estatísticos pelo Centro Nacional de Estatísticas da Educação* (National Center for Education Statistics - NCES).
- **Estudo de caso internacional 3** (Seção 2.2.4): *Divulgação de dados estatísticos pelo Escritório do Censo* (Census Bureau - USCB).
- II. **No contexto da União Europeia** (Seção 2.3): Após um sumário dos aspectos mais relevantes da regulamentação geral da União Europeia sobre privacidade (Seção 2.3.1), apresentamos:
 - **Estudo de caso internacional 4** (Seção 2.3.2): *Divulgação de dados educacionais por escolas e pelo Ministério da Educação da Holanda.*
- III. **No contexto da Austrália** (Seção 2.4): Após um sumário dos aspectos mais relevantes da regulamentação geral australiana sobre privacidade (Seção 2.4.1), apresentamos:
 - **Estudo de caso internacional 5** (Seção 2.4.2): *Divulgação de dados estatísticos pelo Escritório Australiano de Estatística* (Australian Bureau of Statistics - ABS).
- **Estudos de caso do panorama nacional** (Seção 3): Nesta seção provemos um panorama nacional de como institutos produtores de estatísticas oficiais equilibram requisitos de transparência e de proteção de privacidade em seus métodos de divulgação de informação. Iniciamos a seção com um sumário das principais diretivas e regulamentações gerais brasileiras sobre transparência e privacidade (Seção 3.1), com especial foco na Lei de Acesso à Informação (LAI) e na Lei Geral de Proteção de Dados Pessoais (LGPD), além do Marco Civil da Internet (MCI). Em seguida, apresentamos a seguinte coleção de estudos de caso nacionais.
 - **Estudo de caso nacional 1** (Seção 3.2): *Divulgação de dados pelo Instituto Brasileiro de Geografia e Estatística (IBGE).*
 - **Estudo de caso nacional 2** (Seção 3.3): *Divulgação de dados pelo Portal da Transparência do Governo Federal.*
- **Análise da atual situação do Inep frente aos panoramas internacional e nacional e à literatura técnica em privacidade** (Seção 4): Nesta seção apresentamos uma análise da atual forma de divulgação dos Censos Educacionais por parte do Inep, com especial foco nos possíveis riscos à privacidade dela decorrentes. Iniciamos a seção com uma contextualização da atual situação do Instituto (Seção 4.1), que inclui um sumário dos principais pontos da regulamentação específica aplicável ao mesmo (Seção 4.1.1), uma breve descrição da atual forma de divulgação dos Censos Educacionais realizados pelo Inep (Seção 4.1.2) e a identificação das atuais metodologias de mitigação de danos à privacidade aplicadas pelo Instituto (Seção 4.1.3). Em seguida, apresentamos um sumário comparativo do contexto do

Inep com o dos outros casos de estudo internacionais e nacionais já apresentados neste documento (Seção 4.2) e destacamos os pontos identificados como os mais relevantes à atual situação do Inep (Seção 4.3). Por fim, realizamos uma avaliação preliminar dos possíveis riscos decorrentes da forma de divulgação adotada pelo Instituto de acordo com o conhecimento acumulado na literatura técnica sobre proteção de privacidade (Seção 4.4).

- **Considerações finais** (Seção 5): Nesta seção apresentamos as considerações finais deste documento.
- **Anexos:** Apresentamos aqui o seguinte material suplementar.
 - **Constituição da República Federativa do Brasil: Principais trechos relacionados ao escopo deste projeto** (Anexo A): Neste anexo apresentamos uma seleção dos trechos da Constituição da República Federativa do Brasil identificados como os mais relevantes no escopo do presente projeto.
 - **Lei 12.527/2011 (LAI): Principais trechos relacionados ao escopo deste projeto** (Anexo B): Neste anexo apresentamos uma seleção dos trechos da Lei de Acesso à Informação (LAI) identificados como os mais relevantes no escopo do presente projeto.
 - **Lei 13.709/2018 (LGPD): Principais trechos relacionados ao escopo deste projeto** (Anexo C): Neste anexo apresentamos uma seleção dos trechos da Lei Geral de Proteção de Dados Pessoais (LGPD) identificados como os mais relevantes no escopo do presente projeto.
 - **Principais diferenças entre a LGPD brasileira e a GDPR europeia** (Anexo D): Neste anexo apresentamos uma seleção das principais diferenças entre a Lei Geral de Proteção de Dados Pessoais (LGPD) brasileira e o Regulamento Geral de Proteção de Dados - RGPD (*General Data Protection Regulation* - GDPR) europeu, de acordo com o trabalho de Richie Koch.
 - **Um panorama da percepção da questão de privacidade pela sociedade brasileira** (Anexo E): Neste anexo apresentamos uma coleção de notícias e artigos relevantes recentes que ilustram a percepção da sociedade brasileira quanto a questões de privacidade.
- **Lista de siglas e Glossário** encerram o documento. Recomendamos ao leitor a consulta ao Glossário para encontrar a definição de termos utilizados recorrentemente neste documento, como, por exemplo, *anonimização*, *pseudonimização*, *desidentificação*, *reidentificação*, dentre outros.

2 Estudos de caso do panorama internacional

Nesta seção provemos um panorama internacional dos diferentes métodos pelos quais institutos produtores de estatísticas oficiais divulgam informação de forma a garantir transparência e, ao mesmo tempo, privacidade de dados pessoais. Iniciamos a seção com um sumário das principais diretivas e regulamentações gerais sobre privacidade estabelecidas pela Organização das Nações Unidas (ONU) e outros organismos internacionais relevantes. Em seguida, apresentamos uma coleção de estudos de caso no contexto dos Estados Unidos, União Europeia e Austrália.

2.1 Contexto da Organização das Nações Unidas e de outros organismos internacionais

Em 29 de janeiro de 2014, a Assembleia Geral da Organização das Nações Unidas (ONU) adotou a Resolução 68/261, que estabelece um conjunto de princípios fundamentais para estatísticas oficiais [30]. Os princípios definidos nessa Resolução advêm de um trabalho desenvolvido pela Conferência dos Estatísticos Europeus em 1992 e adotado pela primeira vez pela Comissão de Estatística das Nações Unidas em abril de 1994 [32].

Dentre as motivações da Assembleia Geral da ONU para a adoção desses princípios está a necessidade de que o público confie nos sistemas estatísticos oficiais, o que, de acordo com o preâmbulo da Resolução, decorre do respeito aos valores e princípios fundamentais que nela constam. Por sua vez, dentre os princípios estabelecidos, destaca-se:

Princípio 6. Os dados individuais coletados pelos órgãos estatísticos para a elaboração de estatísticas, sejam eles referentes a pessoas físicas ou jurídicas, devem ser estritamente confidenciais e utilizados exclusivamente para fins estatísticos.

Anteriormente à adoção dos princípios pela Assembleia Geral da ONU, ainda quando eles haviam sido adotados apenas pela Comissão de Estatística da entidade, os mesmos

serviram de base para que o Serviço de Estatística da União Europeia (EUROSTAT) elaborasse a *Código de Conduta para as Estatísticas Europeias* em 2001, revisado em 2017 [53]. Posteriormente, a declaração foi utilizada para o desenvolvimento do *Código de Boas Práticas das Estatísticas Europeias*, adaptado à realidade regional, adotado em 2005, e revisado em 2019 [54, 33].

Similarmente, a Conferência Estatística das Américas (CEA) da Comissão Econômica para a América Latina e o Caribe (CEPAL) desenvolveu, entre os anos de 2009 e 2011, o *Código Regional de Boas Práticas das Estatísticas para a América Latina e o Caribe*, aprovado em Novembro de 2011 durante a Sexta Reunião da CEA [27]. O desenvolvimento do Código Regional contou com a colaboração do EUROSTAT e de 14 países membros da CEA-CEPAL, dentre eles Argentina, Brasil, Paraguai, Uruguai, e Chile.¹ Entretanto, essas Resoluções, Declarações, ou Códigos apenas estabelecem princípios e boas práticas nos quais órgãos estatísticos governamentais deveriam se basear, sem que, na prática, tenham força de Lei.

Já no contexto comercial, é sabido que o Brasil aspira a associar-se à Organização para a Cooperação e o Desenvolvimento Econômico (OCDE). Segundo o Itamaraty [75]:

A Organização para a Cooperação e o Desenvolvimento Econômico (OCDE) constitui foro composto por 35 países, dedicado à promoção de padrões convergentes em vários temas, como questões econômicas, financeiras, comerciais, sociais e ambientais. Suas reuniões e debates permitem troca de experiências e coordenação de políticas em áreas diversas da atuação governamental.

[...]

Em junho de 2015, o Brasil e a OCDE assinaram um acordo de cooperação, que permitirá aprofundar e sistematizar o relacionamento bilateral. O acordo institucionaliza a participação brasileira em diversos foros da OCDE e estabelece mecanismos para a definição de linhas de trabalho futuras.

Para possibilitar o fluxo livre de informações entre países, considerado essencial na nova economia digital, a OCDE zela para que a legislação relativa à privacidade seja o mais uniforme possível em seus países membros. Para tanto, a Organização criou, em 2013, um documento descrevendo seu arcabouço de privacidade [96]. Esse documento serviu como base para a legislação brasileira que veio posteriormente. Além disso, a OCDE mantém vários documentos tratando especificamente dos riscos enfrentados por crianças no ambiente *on-line* [97, 104].

¹Posteriormente, esse Código Regional serviu como base para que o Instituto Brasileiro de Geografia e Estatística (IBGE) elaborasse o *Código de Boas Práticas das Estatísticas do IBGE*, publicado em 2013 [33], e discutido na Seção 3.2. Por sua vez, tanto o Código Regional quanto o do IBGE serviram de orientação para a Portaria 91/2017 do Inep [64], que versa sobre o mesmo tema no contexto do Instituto, e para a Portaria 492/2018 [65], que institui a *Política de Divulgação de Estatísticas, Exames e Avaliações, Estudos e Pesquisas do Inep*. O contexto do Inep é discutido em mais detalhes na Seção 4.

2.2 Contexto dos Estados Unidos da América

Nesta seção, após um sumário dos aspectos mais relevantes da regulamentação geral norte-americana sobre privacidade, apresentamos três estudos de caso no contexto dos Estados Unidos da América (EUA).

2.2.1 Regulamentação geral

Os Estados Unidos da América criaram sua primeira *Lei de Privacidade* em 1974, em uma emenda ao Código dos Estados Unidos que acrescentou a Seção 552a ao seu Título 5 [89]. De acordo com a nova seção, agências federais que coletam, mantêm, usam, ou disseminam qualquer registro de informações pessoais identificáveis devem certificar-se de que essas ações ocorram de forma legal, e que sejam fornecidas salvaguardas adequadas para evitar seu uso indevido. Particularmente no uso desses registros para pesquisas estatísticas, a transferência das informações deve dar-se de tal forma a garantir que os registros não sejam individualmente identificáveis, conforme a seção 552a(b)(5) [95].

Em 2002, a *Lei de Proteção à Informação Confidencial e Eficiência Estatística* [92] foi aprovada e trouxe em seu texto novas salvaguardas às informações individualmente identificáveis fornecidas a agências federais para fins estatísticos sob promessa de confidencialidade. A partir de então, qualquer divulgação intencional de tais informações para fins não estatísticos, sem o consentimento do titular, tornou-se crime federal.

Diversas agências federais dos Estados Unidos coletam e divulgam informações pessoais para fins estatísticos, dentre elas o Centro Nacional de Estatísticas da Educação (*National Center for Education Statistics* - NCES) e o Escritório do Censo (*United States Census Bureau* - USCB). Vale destacar que cada agência está subordinada a um Departamento específico do governo federal e sujeita às normas estabelecidas por ele, além de que, em alguns casos, há também legislação específica que rege o mandato de certas agências.

2.2.2 Estudo de caso internacional 1: Práticas de limitação de divulgação das agências federais

Originalmente publicado em 1994, o *Documento de Trabalho sobre Política Estatística 22 - Relatório sobre a Metodologia de Limitação de Divulgação Estatística* foi revisado em 2005 [93] e traz não apenas definições de diversos métodos de limitação de divulgação estatística, como também as práticas adotadas à época pelas seguintes 14 agências federais dos Estados Unidos.

- *Economic Research Service* (ERS), responsável por divulgar dados sobre agricultura e economia.
- *National Agricultural Statistics Service* (NASS), responsável por divulgar dados sobre produção agrícola, economia, demografia, e meio ambiente.

- *Bureau of Economic Analysis* (BEA), responsável por divulgar dados sobre macroeconomia e indústria, incluindo o produto interno bruto nacional e regional.
- *United States Census Bureau* (USCB), responsável por divulgar dados sobre população e economia.
- *National Center for Education Statistics* (NCES), responsável por divulgar dados sobre educação e informações sobre finanças de distritos escolares.
- *Energy Information Administration* (EIA), responsável por divulgar dados sobre energia, incluindo dados sobre carvão, petróleo, gás natural, energia elétrica, renovável, e energia nuclear.
- *National Center for Health Statistics* (NCHS), responsável por divulgar dados sobre saúde pública.
- *Agency for Healthcare Research & Quality* (AHRQ), responsável por divulgar dados sobre qualidade, adequação e eficácia dos serviços de saúde, assim como o acesso aos mesmos.
- *Social Security Administration* (SSA), responsável por divulgar dados sobre renda e uma lista anual com os nomes mais comumente dados a bebês recém-nascidos nos Estados Unidos no ano anterior.
- *Bureau of Justice Statistics* (BJS), responsável por divulgar dados sobre criminalidade.
- *Bureau of Labor Statistics* (BLS), responsável por divulgar dados sobre economia e trabalho.
- *Internal Revenue Service, Statistics of Income Division* (IRS), responsável por divulgar dados sobre declarações de imposto de renda e informações relacionadas.
- *Bureau of Transportation Statistics* (BTS), responsável por divulgar dados sobre transporte.
- *National Science Foundation* (NSF), responsável por divulgar dados sobre educação e pesquisa básica em todos os campos não médicos da ciência e engenharia.

O Documento 22 descreve que as agências federais acima adotavam em 2005 como formas de divulgação de informação:

- *Microdados*: tipo de dados em nível de registros individuais.
- *Dados agregados*, incluindo:
 - *Dados de frequência*: tipo de dados relacionado a contagens, e.g., quantos estabelecimentos estão operando em um determinado estado.

- *Dados de magnitude*: tipo de dados relacionado a grandezas como lucro, e.g., contagem de estabelecimentos juntamente com a receita bruta agregada.

No que se refere à publicação de microdados, o Documento 22 reconhece a dificuldade inerente de proteger-se esse tipo de registro contra violações de privacidade, uma vez que há sempre a possibilidade de que informações externas aos microdados sejam utilizadas para a reidentificação de indivíduos. Ainda assim, algumas agências dos Estados Unidos publicavam microdados à época da elaboração do Documento 22, sendo que todas elas utilizavam os seguintes métodos de proteção:

- (i) inclusão de registros de apenas uma amostra da população;
- (ii) não inclusão de identificadores óbvios, como nome, endereço e números de identificação;
- (iii) limitação do detalhamento geográfico, i.e., agregar registros em regiões mais amplas; e
- (iv) limitação da quantidade e do detalhamento de categorias dentro das variáveis.

Particularmente para variáveis consideradas de elevado risco, como renda, etnia e idade, os seguintes métodos também eram utilizados:

- (v) *top- e bottom-coding*, i.e., truncamento de códigos extremos para certas variáveis, não revelando valores exatos acima ou abaixo de um limite;
- (vi) recodificação em intervalos ou arredondamentos;
- (vii) adição ou multiplicação por números aleatórios (ruído), e.g., a partir de uma distribuição normal;
- (viii) permutação, i.e., selecionar uma amostra, encontrar uma correspondência dentre os registros restantes dado um conjunto de variáveis, e permutar as demais variáveis entre os grupos;
- (ix) troca de classificação, o que permite a seleção de pares para permutação em variáveis contínuas, uma vez que os registros estejam próximos na classificação;
- (x) apagamento e imputação, i.e., seleção de registros aleatoriamente, apagando variáveis selecionadas e atribuindo novos valores a elas com base em um modelo;
- (xi) *blurring*, i.e., agregamento em pequenos grupos, substituindo o valor relatado de um registro pela média; e
- (xii) supressão direcionada, i.e., remoção de um registro por completo ou de valores sensíveis para certas variáveis no registro caso não seja possível protegê-lo de outra forma.

Vale ressaltar que os microdados submetidos à permutação, ao método de apagamento e imputação, ou ao *blurring* não são marcados de qualquer forma nos arquivos divulgados, de modo a garantir a segurança desses registros. Entretanto, isso adiciona um elevado grau de incerteza aos dados, uma vez que o usuário se torna incapaz de determinar se um registro isolado contém dados reais, permutados, imputados, ou ofuscados.

Além disso, tanto a divulgação de microdados quanto a atualização de dados divulgados e a inclusão de dados adicionais devem ser previamente determinadas pelos seguintes órgãos:

- *Disclosure Review Board (DRB)*: este Conselho de Revisão de Divulgação funciona como um curador que determina a liberação ou não de novos conjuntos de microdados, tendo em vista fatores como a disponibilidade de arquivos externos com dados comparáveis, esforço computacional estimado para reidentificação, sensibilidade de itens individuais, quantidade de registros únicos no conjunto de dados, proporção da população incluída na amostra, erros esperados nos dados, e idade do conjunto de dados.
- *CENSUS*: o Escritório do Censo (USCB) é autorizado a conduzir pesquisas para outras agências governamentais, conforme os Títulos 13 e 15 do Código dos Estados Unidos [88, 90]. Quaisquer dados colhidos dessa forma estão sob a jurisdição especial dada ao USCB, e os procedimentos de limitação de divulgação estatística utilizados são então determinados pelo Escritório do Censo, e não pela agência responsável pela publicação.

Já no que se refere à publicação de dados agregados, o Documento 22 reconhece que a simples agregação não garante necessariamente a proteção dos mesmos, e diversas técnicas aplicáveis a microdados já eram aplicadas à época também a dados agregados de magnitude e de frequência.

Por fim, o Escritório do Censo (USCB) disponibilizou também um sistema de consultas (ou *queries*) avançado (*Advanced Query System*) *on-line* para acesso aos dados do Censo do ano 2000. Nesse sistema, o usuário podia definir consultas próprias que então eram analisadas por um primeiro filtro (*Query Filter*), o qual identificava se a consulta enviada revelaria ou não mais informações do que o permitido, e.g., por extrapolar limites geográficos. Caso a consulta fosse aprovada pelo primeiro filtro, a tabela gerada por ela era então submetida a um segundo filtro, agora de resultados estatísticos (*Statistical Results Filter*), responsável por verificar condições de limitação de divulgação de dados nas células da tabela. Finalmente, a tabela resultante era fornecida ao usuário apenas caso as condições fossem satisfeitas.

A Tabela 2.2.1 apresenta um resumo das práticas de proteção de privacidade adotadas pelas agências federais dos Estados Unidos em 2005 [93], a todos os tipos de dados (microdados e dados agregados de frequência e magnitude), onde os seguintes termos adicionais são usados:

Agência	Tipo de Dados			Autorização Individual	Acesso Restrito
	Magnitude	Frequência	Microdados		
ERS	❶ ❸	❺ ❸	✗	✓	✓
NASS	❶ ❷	✗	✗	✓	✓
BEA	❷	✗	✗	✗	✓
USCB	❷ ❸	❺ ❻ ❸	✓ (DRB)	✓	✓
NCES	❸ ❺ ❻ ❷	❸ ❺ ❻ ❷	✓ (DRB)	✗	✓
EIA	❶	❺	✓ (DRB)	✓	✗
NCHS	❶	❹ ❺	✓ (DRB)	✗	✓
AHRQ	✗	❹ ❺	✓ (DRB)	✓	✓
SSA	❸ ❺	❸ ❺	✓ (DRB)	✗	✗
BJS	✗	❺ ❿	✓ (DRB)	✗	✗
BLS	❶ ❷	variável	✓ (CENSUS)	✓	✓
IRS	❸ ❺	❸ ❺	✓ (DRB)	✗	✗
BTS	variável	❸ ❺	✓ (DRB)	✗	✗
NSF	❶	variável	✓ (DRB)	✓	✓

Tabela 2.2.1: Práticas de proteção à privacidade adotadas pelas agências federais norte-americanas em 2005: ❶ (n, k) -rule, ❷ p -percent rule, ❸ 3+, ❹ 4+, ❺ truncamento, ❻ permutação, ❼ recodificação, ❽ ruído, ❾ sistema avançado de consultas, ❿ 10+.

- Níveis de acesso a dados possíveis:
 - *Autorização individual*: permissão por escrito obtida diretamente dos entrevistados que autoriza a publicação de células sensíveis como uma forma de evitar a supressão de dados.
 - *Acesso restrito*: sala de análise segura pertencente à agência federal para pesquisadores visitantes ou licenciamento externo.
- Critérios de determinação de se uma célula é sensível:
 - (n, k) -rule: independentemente da quantidade de registros em uma célula da tabela, se uma pequena quantidade (n ou menor que n) contribui em uma grande porcentagem (k por cento ou mais) para o valor total da célula, então a célula é considerada sensível.
 - p -percent rule: uma célula é considerada sensível se for possível estimar o valor de algum dos indivíduos que a compõem dentro de uma margem determinada por um valor p em torno do valor real.
 - *Threshold rule* ($N+$): uma célula é considerada sensível se a quantidade de indivíduos reportados por ela for inferior a um tamanho mínimo N determinado (e.g., para 3+, 4+, ou 10+, cada célula representa ao menos 3, 4, ou 10 indivíduos, respectivamente).

2.2.3 Estudo de caso internacional 2: Divulgação de dados estatísticos pelo Centro Nacional de Estatísticas da Educação

Na seção anterior, cobrimos o panorama geral das agências federais dos EUA; aqui dedicamos especial atenção a uma agência com particular relevância no contexto do presente projeto: O Centro Nacional de Estatísticas da Educação (*National Center for Education Statistics* - NCES).² Como uma agência estatística do Departamento de Educação dos Estados Unidos (*United States Department of Education* - ED),³ o NCES é o principal responsável pela coleta, análise e divulgação de dados educacionais no país. Dentre os dados coletados, estão aqueles referentes às instituições de ensino e respectivos corpos docentes, administrativos, e discentes, sendo as publicações realizadas por meio de dados agregados, como em tabelas de frequência ou magnitude, e por meio de microdados.

Regulamentação específica Assim como as demais agências federais, o NCES é regido pela *Lei de Privacidade* de 1974 e a *Lei de Proteção à Informação Confidencial e Eficiência Estatística* de 2002. Entretanto, certa regulamentação específica também se aplica ao mandato do NCES.

A *Lei de Reforma das Ciências da Educação* de 2002 [87], dentre outras providências, trata especificamente sobre os trabalhos do NCES. A respeito das informações individualmente identificáveis sobre estudantes, suas famílias, e escolas, a Lei determina que todas devem permanecer confidenciais.

Entretanto, o *USA PATRIOT Act* [91], lei antiterrorismo aprovada em 2001, autoriza o Procurador Geral dos Estados Unidos a solicitar judicialmente o acesso às informações individualmente identificáveis coletadas pelo Centro caso sejam relevantes a investigações relacionadas ao terrorismo nacional ou internacional. Como consequência, tornou-se necessário informar aos indivíduos entrevistados sobre a possibilidade de que as informações fornecidas possam ser utilizadas em formato identificável caso exigido por lei.

Ainda assim, práticas para a limitação da divulgação de dados estatísticos constam nos *Padrões Estatísticos do Centro Nacional de Estatísticas da Educação*, revisados em 2012 [94].

Dados publicados Conforme o Padrão 7-1 do Padrões Estatísticos do Centro Nacional de Estatísticas da Educação [94], citado acima, o NCES disponibiliza microdados de acesso restrito para agentes autorizados e publica microdados de uso público produzidos a partir dos primeiros. Além disso, o Escritório disponibiliza ferramentas de análise *on-line*, nas quais os microdados são agregados para a produção de estimativas tabulares ou, em alguns casos, para análises de regressão.

De acordo com o Padrão 4-2-7, que trata especificamente das ferramentas de análise *on-line*, caso os microdados acessados por essas ferramentas sejam de uso público, os

²<https://nces.ed.gov/>

³<https://www.ed.gov/>

mesmos devem ser submetidos a técnicas de perturbação para limitação de divulgação. Além disso, caso os microdados acessados por essas ferramentas sejam de acesso restrito, os mesmos devem cumprir as seguintes condições:

- o tamanho exato da amostra não pode ser divulgado;
- as edições de confidencialidade devem ter sido aprovadas pelo DRB responsável; e
- a ferramenta *on-line* deve divulgar apenas contagens ponderadas.

Finalmente, o Padrão 4-2-8 define que todos os microdados de uso público devem ser tratados pelo NCES de modo a limitar a possibilidade de que indivíduos venham a ser reidentificados (i.e., tornar-se *outliers* ou únicos) com o auxílio de informações externas à publicação. Dessa forma, os microdados de uso público devem passar por uma análise de risco de divulgação em preparação para a liberação, o que pode incluir técnicas de perturbação ou a redução da precisão dos dados divulgados.

2.2.4 Estudo de caso internacional 3: Divulgação de dados estatísticos pelo Escritório do Censo

Na Seção 2.2.2, cobrimos o panorama geral das agências federais dos EUA; nesta seção, dedicamos especial atenção a outra destas agências de particular interesse no escopo deste projeto: o Escritório do Censo (*United States Census Bureau* - USCB).⁴ Como uma agência estatística do Departamento de Comércio dos Estados Unidos (*United States Department of Commerce*),⁵ o USCB é a maior agência estatística do governo federal. Dentre suas responsabilidades, está a condução dos Censos Decenais, requisitados pela Constituição dos EUA, e cujos resultados servem de base para a repartição dos assentos na Câmara dos Deputados entre os estados, além da distribuição de mais de US\$ 675 bilhões em fundos federais para estados e organizações locais.

Além disso, o USCB é autorizado a conduzir pesquisas para outras agências federais, como regulamentado pelos Títulos 13 e 15 do Código dos Estados Unidos. Entretanto, as informações coletadas sob o mandato do Título 13, como aquelas referentes aos Censos Decenais, são protegidas por garantias de confidencialidade mais restritivas.

Regulamentação específica O Título 13 do Código dos Estados Unidos [88], em sua seção 9, determina que toda informação obtida com base nesse Título deve ser utilizada exclusivamente para os propósitos estatísticos para os quais foi coletada, sendo que nenhum indivíduo ou estabelecimento em particular pode ter sua identidade revelada a partir das informações prestadas.

⁴<https://www.census.gov>

⁵<https://www.commerce.gov/>

Para tanto, o Escritório determina práticas para a limitação da divulgação de dados estatísticos em seus *Padrões de Qualidade Estatística*, revisados em 2013 [22]. De acordo com o Requerimento S1-2, técnicas de prevenção devem ser utilizadas para impedir a liberação de informações protegidas, particularmente aquelas referentes à identificação de pessoas ou estabelecimentos, sendo que as técnicas citadas são semelhantes às aquelas apresentadas pelo *Documento de Trabalho sobre Política Estatística 22* [93], detalhadas anteriormente.

Dados publicados Conforme o Requerimento A1-2 dos *Padrões de Qualidade Estatística* do USCB [22] e o Documento 22 [93], o USCB publica tanto dados agregados na forma de tabelas de frequência ou de magnitude, quanto microdados. Especificamente para os microdados, a divulgação pode ocorrer na forma de [25]:

- *Arquivos de Uso Público (Public Use Files - PUFs)*, os quais contêm todos os registros de todos os entrevistados. Este tipo de arquivo não é publicado para os dois principais e mais abrangentes estudos realizados pelo USCB: os Censos Decenais e as Pesquisas de Comunidades Americanas (*American Community Surveys - ACS*).
- *Amostras de Microdados de Uso Público (Public Use Microdata Samples - PUMS)*, os quais contêm os registros para apenas uma amostra da população. Este tipo de arquivo é usado, em particular, para os Censos Decenais.
- *Acesso restrito via salas seguras (Research Data Centers - RDCs)*: paralelamente à aplicação de técnicas de limitação de divulgação aos dados publicados, permite-se o acesso controlado e limitado aos microdados originais por pesquisadores e funcionários previamente autorizados. Estas salas estão distribuídas pelo país, e todas as análises devem ser realizadas dentro do ambiente regulado, o que permite ao USCB garantir a segurança dos registros e a aplicação de métodos de limitação de divulgação aos resultados obtidos antes de sua liberação para o público.

No estudo de caso do USCB, focaremos nas publicações referentes aos Censos Decenais, devido a sua importância legal, à abrangência de indivíduos entrevistados, e aos desenvolvimentos recentes nas técnicas de proteção à privacidade adotadas pelo USCB com o objetivo de garantir o direito à privacidade definido no Título 13 do Código dos Estados Unidos [88].

2.2.4.1 Técnicas utilizadas nos Censos de 1960 a 2010 para a publicação de microdados na forma de arquivos PUMS

De 1960 a 2010, diferentes técnicas de limitação de divulgação foram utilizadas nos Censos Decenais, muitas vezes motivadas por alterações nos questionários utilizados pelo Escritório do Censo [24]. A Tabela 2.2.2, apresenta um resumo das práticas adotadas pelo USCB nesse período. Estas práticas são descritas em mais detalhes a seguir.

Ano do Censo	Práticas adotadas
1960	X
1970	X
1980	1
1990	1 2
2000	1 3 4 5
2010	
... Residências	1 3 4 5
... Quartos de grupos	1 4 6

Tabela 2.2.2: Práticas de proteção à privacidade adotadas pelo USCB nos Censos de 1960 a 2010 para a publicação de Amostras de Microdados de Uso Público (PUMS), conforme [24]: **1** truncamento e recodificação, **2** apagamento e imputação, **3** permutação, **4** truncamento de variáveis categóricas, **5** adição de ruído, **6** dado parcialmente sintético.

Nos primeiros dois Censos Decenais relatados, em 1960 e 1970, foi realizada apenas a remoção de identificadores diretos e a limitação do detalhamento geográfico a populações de 250.000 pessoas, técnicas que continuaram em uso até o Censo de 2010. Já no Censo de 1980, o detalhamento geográfico aumentou com a alteração da limitação a populações de 100.000 pessoas, mas também foram introduzidos agrupamentos de renda e truncamento superior para as variáveis renda e idade.

Para o Censo Decenal de 1990, mais variáveis foram submetidas à recodificação e ao truncamento superior, dentre elas: locais de residência e de trabalho, tipo de dormitório coletivo (como hospitais, prisões, e dormitórios universitários e militares), renda, e idade. Além disso, com o objetivo de proteger tabelas publicadas para pequenas populações, a técnica de apagamento e imputação também foi aplicada aos PUMS.

Para o Censo do ano 2000, a técnica de apagamento e imputação deixou de ser utilizada, mas a recodificação e o truncamento superior de variáveis foram mantidos, agora acrescentado o truncamento inferior. Uma vez que truncamentos superiores deveriam ter ao menos três valores, a maioria das variáveis econômicas foram truncadas superiormente a nível nacional. Além disso, utilizou-se pela primeira vez da permutação de registros para pequenas regiões geográficas, do truncamento de variáveis categóricas, e da adição de ruído para residências grandes.

Finalmente, para o Censo de 2010, técnicas diferentes foram utilizadas para residências e quartos de grupos, uma vez que permutações ou adição de ruído não geram resultados aceitáveis para quartos de grupos devido à homogeneidade normalmente detectada nessas populações. Dessa forma, optou-se pela adição de dados sintéticos como técnica de limitação de divulgação para quartos de grupos, enquanto as técnicas aplicadas no Censo do ano 2000 foram mantidas para o caso das residências [21].

2.2.4.2 Técnicas utilizadas no Censo de 2020

O USCB está atualmente executando o Censo de 2020, no qual ocorrerá a maior alteração já realizada pela agência no que diz respeito às suas práticas de limitação de divulgação de dados. As mudanças são devidas ao reconhecimento de que os métodos utilizados até o Censo Decenal de 2010, conhecidos como métodos sintáticos,⁶ são inerentemente inseguros e sujeitam os registros individuais à possibilidade de reidentificação [25]. Mais precisamente:

- Para o caso de microdados, a reidentificação pode ser realizada, e.g., determinando-se combinações únicas de variáveis (quaseidentificadores) e combinando-as com informações disponíveis externamente, como em outras publicações de dados estatísticos ou mesmo na Internet.
- Para o caso de dados tabulares,⁷ a reidentificação pode ser realizada, e.g., ao vincularem-se tabelas publicadas pelo mesmo estudo estatístico em busca de células que possam ser ligadas de modo a recriar os microdados originais [25]. Outro risco é o *ataque de reconstrução de bases de dados*, descoberto por Nissim em 2003 [36]. Seu famoso *Teorema da Reconstrução de Bases de Dados* demonstrou que mesmo uma pequena quantidade de consultas a uma base de microdados (ou divulgação de dados tabulares) seria suficiente para revelar informações de registros únicos. Desde então, o USCB já realizou estudos de reidentificação em seus microdados e encontrou combinações de variáveis que poderiam ser utilizadas em ataques de reidentificação. Entretanto, esses estudos não podem ser publicados devido à regulamentação que rege a confidencialidade dos dados obtidos pelo Escritório [57].

Dessa forma, os métodos sintáticos não serão utilizados no Censo Decenal de 2020, dando lugar aos métodos semânticos,⁸ mais especificamente à privacidade diferencial (*differential privacy*, no original em inglês), inicialmente proposta por Dwork et al. em 2006 [51]. A privacidade diferencial garante formalmente que apenas uma quantidade negligível de informação sobre um dado indivíduo pode ser obtida a partir dos dados publicados, independentemente da participação ou não do indivíduo na pesquisa [50].

Entretanto, a implementação da privacidade diferencial pelo USCB enfrentou e enfrenta diversas dificuldades, tanto técnicas [58] quanto de comunicação com o restante da comunidade de estatística [73]. Apesar disso, o Escritório do Censo continua a preparação para o uso da privacidade diferencial, inclusive com a publicação de produtos de demonstração derivados dos microdados do Censo de 2010 [23].

⁶Métodos sintáticos são aqueles que formulam condições puramente sintáticas para a divulgação de informação. Exemplos incluem as técnicas de desidentificação, de *k-anonymity* e de *l-diversity*.

⁷É importante ressaltar que no presente contexto das agências federais dos EUA, o termo *dados tabulares* é utilizado como sinônimo de *dados agregados*, e não se confunde com *microdados* [93].

⁸Métodos semânticos são aqueles que formulam condições semânticas para a divulgação de informação, incorporando em si mesmos a formalização de privacidade almejada.

Devido às alterações nos métodos utilizados pelo USCB para o controle da divulgação de dados estatísticos, mudanças também são esperadas no que diz respeito aos produtos que serão disponibilizados pelo Escritório a partir dos dados coletados pelo Censo de 2020.⁹ Até a última atualização divulgada pelo USCB, em 08 de novembro de 2019, por volta de um terço das publicações agregadas tabulares planejadas já são suportadas pelo novo sistema baseado em privacidade diferencial, ou estão em fase de implementação. Entretanto, os outros dois terços das publicações agregadas tabulares ainda estão em fase de pesquisa para adaptação, ou por serem dependentes de operações complexas, ou por serem muito específicas no que se refere à população abordada, ou ainda por dependerem de publicações ainda não suportadas. Finalmente, ainda não há, também, uma definição quanto à publicação ou não de arquivos PUMS referentes ao Censo de 2020 [26].

2.3 Contexto da União Europeia

Nesta seção, após um sumário dos aspectos mais relevantes da regulamentação geral da União Europeia sobre privacidade, apresentamos um estudo de caso relativo à divulgação de dados educacionais por escolas e pelo Ministério da Educação da Holanda.

2.3.1 Regulamentação geral

Em 1995, o Parlamento e o Conselho Europeu acataram a Diretiva 95/46/CE, relativa à proteção dos indivíduos no que diz respeito ao tratamento de dados pessoais e à livre circulação desses dados [28].

Em 25 de maio de 2018, entrou em vigor o Regulamento UE 2016/679 [29], conhecido como *Regulamento Geral de Proteção de Dados* - RGPD em Portugal, e no Brasil por seu nome e sigla em inglês, *General Data Protection Regulation* - GDPR. O regulamento trata sobre privacidade e proteção de dados pessoais de todos os indivíduos na União Europeia (UE) e no Espaço Econômico Europeu (EEE) –incluindo entidades que realizam comércio com a UE, independentemente de seu país de origem–, assim como da exportação de dados pessoais para fora dessas regiões. O regulamento tem como objetivo prover aos cidadãos e residentes formas de controlar seus dados pessoais, além de unificar o quadro regulamentar europeu, baseando-se nos seguintes princípios:

⁹De acordo com [58], os dados coletados pelo USCB para o Censo de 2020 proveem da Internet, de chamadas telefônicas e de formulários entregues por funcionários da agência na residência de cada cidadão. Todos esses dados confidenciais são coletados e processados para formar a primeira base de dados não editada, chamada de Arquivo Não Editado do Censo (*Census Unedited File* - CUF). Especialistas de diversas áreas realizam, então, correções de problemas de diferentes naturezas no CUF utilizando como auxílio outras fontes de dados, e a partir disso é gerada a primeira base editada, chamada de Arquivo Editado do Censo (*Census Edited File* - CEF). Em seguida, algumas modificações são realizadas no CEF pelo Sistema de Prevenção de Divulgação (*Disclosure Avoidance System* - DAS), e o resultado destas modificações compõe a base chamada de Arquivo Detalhado de Microdados (*Microdata Detailed File* - MDF). Todos os dados disponibilizados publicamente são obtidos utilizando a MDF.

- **transparência:** o titular dos dados processados deve estar ciente disso, ter dado sua permissão para isso, e conhecer seus direitos;
- **limitação de finalidade:** os dados pessoais são coletados para uma finalidade legítima específica e não podem ser usados para outras finalidades;
- **limitação de dados:** somente os dados necessários para a finalidade pretendida podem ser coletados;
- **precisão:** os dados pessoais devem estar e permanecer corretos;
- **limite de retenção:** os dados pessoais não podem ser mantidos por mais tempo que o necessário para a finalidade pretendida;
- **integridade e confidencialidade:** os dados pessoais devem ser protegidos contra acesso, perda ou destruição não autorizada; e
- **responsabilidade:** o responsável pelo tratamento deve demonstrar conformidade com essas regras.

Os principais direitos que a GDPR garante aos cidadãos europeus são sumarizados por Filipe Pontes como a seguir [99].

1. **Direito de informação:** direito de receber informações sobre os termos do tratamento de dados pessoais quando da sua recolha;
2. **Direito de acesso:** direito de obter confirmação de que os dados pessoais são ou não objeto de tratamento e, se for o caso, ter acesso aos seus dados pessoais;
3. **Direito de retificação:** o titular tem o direito de obter, sem demora injustificada, a retificação ou atualização dos dados pessoais inexatos;
4. **Direito de apagamento dos dados:** o titular tem o direito de obter o apagamento dos seus dados pessoais, sem demora injustificada, dentro dos limites legalmente previstos;
5. **Direito à limitação de tratamento:** o titular dos dados tem o direito de obter a limitação do tratamento;
6. **Direito de Portabilidade:** o titular dos dados tem o direito de receber os dados pessoais que lhe digam respeito e que tenha fornecido num formato de uso corrente e de leitura automática;
7. **Direito de não ficar sujeito a decisões individuais automatizadas:** o titular dos dados tem o direito de não ficar sujeito a nenhuma decisão tomada exclusivamente com base no tratamento automatizado dos seus dados pessoais, incluindo a definição de perfis, que produza efeitos na sua esfera jurídica ou que o afete significativamente de forma similar;

8. **Direito de oposição:** o titular dos dados tem o direito de se opor, a qualquer momento, por motivos relacionados com a sua situação particular, ao tratamento dos dados pessoais que lhe digam respeito, nomeadamente quando os seus dados sejam tratados para efeitos de comercialização direta.

2.3.2 Estudo de caso internacional 4: Divulgação de dados educacionais por escolas e pelo Ministério da Educação da Holanda

A variedade de países constituintes da União Europeia permite uma vasta gama de opções para a escolha do estudo de caso europeu apresentado no presente documento. Os seguintes três motivos nos levaram a optar por um caso da Holanda.

Como primeiro motivo, um dos autores deste documento é de nacionalidade holandesa e, como pesquisador experiente na área de segurança, tem conhecimento profundo sobre as questões de privacidade de seu país.

Como segundo motivo, a sociedade holandesa, por razões históricas, sempre demonstrou um nível de preocupação de vanguarda com questões relativas à privacidade de seus cidadãos. Podemos citar os seguintes exemplos que ilustram este notório histórico.

- Durante a ocupação pela Alemanha na Segunda Guerra Mundial, os nazistas usaram cadastros dos cidadãos (na Holanda o papel dos cartórios é obrigação dos municípios) para perseguir os judeus, e a Resistência Holandesa destruiu o cadastro da cidade Amsterdam para sabotar essa política [1].
- A Holanda realiza um censo (*volkstelling*) estatístico populacional desde 1795. No entanto, o censo de 1981 foi cancelado quando ficou evidente que 26% da população se recusaria a colaborar por motivos de privacidade. Em 1991, o censo foi oficialmente abolido e substituído por técnicas por amostragem [5].
- Durante a atual pandemia de COVID-19, o governo holandês tem tentado empregar um aplicativo rastreador (*tracing app*, em inglês) para identificar indivíduos com quem uma pessoa possivelmente infectada teve contato, facilitando assim o rastreamento do espalhamento da doença. No entanto, há em curso um grande debate na Holanda sobre como essa medida poderia ser implementada, com o objetivo de mitigar a séria erosão de privacidade que ela poderia causar. De fato, a equivalente holandesa à nossa Autoridade Nacional de Proteção de Dados já demonstrou independência ao contrariar várias vezes o governo [108].

Como terceiro motivo para a opção por um caso holandês, notamos que a tecnologia se integrou ao sistema educacional do país precocemente, e sistemas computacionais passaram a fazer parte da administração das escolas há pelo menos três décadas. Cada escola na Holanda tem um sistema de administração que armazena dados pessoais de alunos

e professores, e existe também um sistema de acompanhamento escolar (*leerlingvolgsysteem*), para acompanhar o progresso acadêmico do aluno. Além disso, com o advento da Internet, o computador está cada vez mais entremeado nas salas de aula: por um lado as editoras de livros didáticos oferecem cada vez mais material *on-line*, enquanto várias empresas oferecem ferramentas de ensino *on-line*.

Desta forma, formou-se na Holanda um ambiente bastante complexo com diversas partes interessadas em dados educacionais: as escolas, as empresas que desenvolvem sistemas computacionais para as escolas, as empresas que oferecem os serviços de TI, as editoras de material didático, o Ministério da Educação, entre outros. Além disso, há vários tipos de usuários de informação, incluindo professores, alunos, diretores, coordenadores, e administradores. Por causa deste contexto, a Holanda teve que desenvolver de forma pioneira suas próprias políticas sobre quem pode ter acesso a que tipo de informação, e sobre as garantias de proteção da privacidade de dados pessoais das partes envolvidas.

Como um exemplo desta forte atuação holandesa nessa questão, podemos citar um relevante caso ocorrido em 2018. Naquele ano, a Autoridade de Privacidade - AP (*Autoriteit Persoonsgegevens*), equivalente à Autoridade Nacional de Proteção de Dados (ANPD) brasileira, conduziu uma investigação sobre privacidade educacional envolvendo a ASKO (*Amsterdamse Stichting voor Katholiek, Protestants-Christelijk en Interconfessioneel Onderwijs*), um conselho que administra 32 escolas na Holanda, e que empregava um sistema computacional cujo nome foi omitido para proteger o fornecedor, sendo chamado apenas de “Sistema de Rastreamento de Estudantes X”. Os resultados desta investigação foram publicados em um relatório intitulado *Pesquisa sobre os direitos de acesso dos funcionários das instituições de ensino da ASKO a dados pessoais de estudantes no Sistema de Rastreamento de Estudantes X* [15]. A motivação dada a esse esforço foi a seguinte:

As instituições de ensino processam muitos dados pessoais dos alunos, como detalhes de contato, número de previdência social (BSN), dados de ausência às aulas, resultados de estudos e dados sobre saúde e bem-estar. Elas precisam dessas informações para fornecer educação aos alunos. Tendo em vista a natureza e o escopo desses dados pessoais, incluindo dados pessoais especiais, e o fato de as crianças poderem ser classificadas como pessoas vulneráveis, é de grande importância que as instituições educacionais manejem com cuidado os dados pessoais e os princípios da Lei de Proteção de Dados Pessoais e observem os princípios do Regulamento Geral de Proteção de Dados (GDPR) a partir de 25 de maio de 2018. A Autoridade Holandesa de Proteção de Dados (AP), portanto, anunciou em sua agenda de 2016 que será dada especial atenção à privacidade das crianças na educação.

O relatório final da investigação chegou a definir recomendações, diretrizes e boas práticas a serem adotadas no tratamento de dados educacionais. Entretanto, nenhuma multa foi aplicada à época uma vez que o relatório foi publicado em janeiro de 2018, antes do GDPR entrar em vigor. Como reação a esse relatório, e para agir de acordo com

a GDPR, foi criado um consórcio que combinou com todas as partes que atuam no ambiente educacional um acordo de privacidade educacional [101]. Discutimos abaixo as ações deste consórcio no contexto da regulamentação específica sobre privacidade nos dados educacionais da Holanda.

Regulamentação específica Já em 1989 foi aprovada na Holanda a *Lei Registro de Pessoas* (*Wet persoonsregistraties*) [7], determinando que um indivíduo precisaria conceder permissão a uma empresa ou instância no compartilhamento de seus dados para uso diferente do objetivo original. A lei também criou uma Câmara de Privacidade para cadastrar esses registros e para se certificar do cumprimento dos regulamentos.

Em setembro de 2001, entrou em vigor a *Lei de Proteção a Dados Pessoais* (*Wet bescherming persoonsgegevens*) [6] para proteger a privacidade dos cidadãos, substituindo a lei anterior. Essa lei foi em grande parte baseada na Diretiva 95/46 da Comunidade Europeia relativa à proteção de dados pessoais [28]. A lei concedia aos cidadãos certos direitos, como o direito de saber o que está acontecendo com seus dados pessoais.

Em maio de 2018, essa lei foi substituída pela GDPR europeia e, portanto, a partir de então a Holanda passou a seguir o regulamento europeu discutido na seção anterior. A lei holandesa que implementa a GDPR é conhecida como *Algemene Verordening Gegevensbescherming* (AVG) [4]. A Câmara de Privacidade passou a chamar-se *Autoridade de Privacidade* - AP (*Autoriteit Persoonsgegevens*),¹⁰ o equivalente holandês da Autoridade Nacional de Proteção de Dados prevista pela LGPD brasileira.

No contexto de tratamento de dados educacionais, a AP holandesa provê instruções especialmente cuidadosas, mesmo por que os indivíduos a quem os dados se referem são muitas vezes crianças, que têm direito a proteção e tratamento especiais pela GDPR. A AP esclarece precisamente várias questões relativas à privacidade na educação [14], incluindo pontos como os seguintes:

- **Responsabilização:** as escolas devem ser capazes de demonstrar quais as medidas técnicas e organizacionais tomadas para proteger os dados pessoais dos alunos.
- **Necessidade de aprovação:** caso uma escola deseje estabelecer ou alterar um regulamento para o uso de dados pessoais, ela deve primeiro pedir aprovação ao conselho de participação.
- **Câmeras nas escolas:** entre outros, oferece “Vigilância por câmera na escola”, um pacote gratuito de lições sobre privacidade adaptado para alunos de 11-12 anos.

Além disso, a AP também estabelece claramente obrigações das partes envolvidas no tratamento de dados escolares. Alguns exemplos de questões detalhadas pela AP incluem:

- **Obrigações das escolas em relação ao GDPR:**

¹⁰<https://autoriteitpersoonsgegevens.nl>

- Quando cada escola deve realizar uma avaliação de impacto de proteção de dados (*Data Protection Impact Assessment* - DPIA).
 - Quais regras se aplicam ao usar um sistema de rastreamento de alunos.
 - Quais regras se aplicam em relação ao programa de saúde do município para os alunos.
- **Obrigações das escolas sobre informações e permissões:**
 - Quando cada escola deve informar alunos e pais sobre os dados pessoais por ela processados.
 - Quais informações cada escola deve fornecer aos alunos e/ou pais sobre os dados pessoais que processa.
 - Quais cuidados tomar ao informar pais e alunos sobre os dados processados.
 - Como e se cada escola pode publicar imagens de alunos.
 - **Obrigações das escolas sobre programas de ação em que dados pessoais são utilizados:**
 - Quem é responsável pelo processamento de dados ao usar um programa anti-*bullying*.
 - Como e se cada escola pode incluir informações sobre a raça, religião ou orientação sexual de uma pessoa em um programa anti-*bullying*.
 - Se e quando cada escola precisa de uma base legal para processar os dados pessoais de alunos.
 - Por quanto tempo cada escola pode manter os dados dos alunos.
 - Como cada escola deve gerenciar a segurança ao usar um programa anti-*bullying*.
 - Quem pode acessar os dados dos alunos.

Como mencionado anteriormente, há em vigência na Holanda um acordo de privacidade educacional criado por um consórcio formado por todas as partes que atuam no ambiente das escolas [101]. Um dos pontos principais desse acordo é a definição de um código único para cada aluno de ensino básico e secundário, que serve como pseudônimo (o que consiste em uma técnica de *pseudonimização*). O consórcio também é responsável pela definição técnica dessa proposta. Foi estabelecido um padrão que define protocolos de Internet [52], de como as partes devem trocar as informações entre si [69], e inclui uma implementação de referência [68].

Dados divulgados por escolas A partir da inspeção da vasta documentação disponível, concluímos que as escolas holandesas nunca publicam microdados dos alunos. Além disso, uma pessoa só tem acesso aos dados realmente necessários para uma dada

tarefa que esteja executando (*need-to-know principle*, em inglês). Como um exemplo, normalmente até funcionários das escolas não têm acesso aos dados pessoais do aluno, e quando um aluno precisa de assistência imediata emergencial, um funcionário entra num procedimento específico que lhe concede acesso aos dados do aluno durante 24 horas. Esse acesso fica registrado, e o funcionário precisa justificá-lo.

Dados divulgados pelo Ministério da Educação Na Holanda, a Divisão de Implantação Ensino (*Dienst Uitvoering Onderwijs*) do Ministério da Educação é responsável por gerir as escolas e universidades do país. A informação divulgada por esta divisão está disponível para visualização *on-line* [35]. Nunca são divulgados microdados de alunos, sob nenhuma forma. São divulgados apenas dados de escolas ou regiões, e dados de alunos apenas em forma agregada. Exemplos de informações disponibilizadas incluem:

- endereços das instituições de ensino;
- dados financeiros das instituições de ensino;
- quantidade de alunos e funcionários por instituição de ensino;
- indicadores de qualidade por instituição de ensino;
- distância média entre a casa do aluno e sua escola;
- dados sobre a porcentagem de alunos que abandonaram um curso de uma escola antecipadamente, sem se formar;
- resultados médios das escolas para exames nacionais; e
- previsão de quantidade de alunos por tipo de ensino e por região.

2.4 Contexto da Austrália

Nesta seção, após um sumário dos aspectos mais relevantes da regulamentação geral australiana sobre privacidade, apresentamos um estudo de caso no contexto da Austrália.

2.4.1 Regulamentação geral

A *Lei de Privacidade* de 1988 [81], revisada em novembro de 2015, estabelece a regulação nacional para privacidade e tratamento de informações pessoais, particularmente com a definição dos *Princípios Australianos de Privacidade*.

Dentre os princípios estabelecidos, destacam-se a garantia do uso de *anonimização*, i.e., a desassociação dos indivíduos de seus respectivos registros, ou de *pseudonimização*, i.e., a atribuição de um código individual a cada registro de uma base de dados, além da transparência por parte das entidades governamentais na coleta e no tratamento de informações pessoais, assim como de regras para o uso e a divulgação de dados pessoais.

2.4.2 Estudo de caso internacional 5: Divulgação de dados estatísticos pelo Escritório Australiano de Estatística

O Escritório Australiano de Estatística (*Australian Bureau of Statistics* - ABS) foi criado por Lei em 1975 [79] e tem seu mandato de coleta de dados estatísticos estabelecido pela Lei do Censo e Estatísticas de 1905 [80], o que inclui a realização do Censo Nacional. A Lei de 1905 requer que o ABS publique as informações estatísticas ao mesmo tempo em que garanta a confidencialidade das informações coletadas.

Regulamentação específica As informações pessoais coletadas para o Censo são regidas pela *Política de Privacidade* do ABS [82, 86]. De acordo com a Legislação vigente e a *Política de Privacidade*, o Escritório nunca publicou, nem publicará, informações identificáveis sobre indivíduos, residências, ou estabelecimentos comerciais.

Assim como a Nova Zelândia e o Canadá [86], o Escritório armazena nomes e endereços dos entrevistados, mas de forma desassociada entre si e das demais informações coletadas, sendo utilizadas apenas para a reconstrução da base de dados quando necessário.

Dados divulgados Até o Censo de 2016, o ABS disponibilizou microdados apenas por amostras da população e sob restrições de acesso [84]. Além do controle de acesso aos arquivos de amostras, o Escritório também cobra pelo serviço de acordo com o acesso requisitado [85].

Paralelamente, é mantido o *Australian Census Longitudinal Dataset* (ACLD) [83], um Censo Longitudinal criado a partir de amostras aleatórias com correspondência, a saber:

- 2006-2011 ACLD: amostra de 5% de registros aleatórios, o equivalente a aproximadamente um milhão de registros, do Censo de 2006 com os registros correspondentes do Censo de 2011.
- 2011-2016 ACLD: aproximadamente 1,2 milhão de registros do Censo de 2011 com os registros correspondentes do Censo de 2016.

O Censo Longitudinal é acessível para usuários registrados no serviço de geração de tabelas e na forma de microdados para usuários aprovados que estejam conduzindo projetos consentidos. Assim como ocorre para os microdados em Censos individuais, o Escritório também cobra pelos serviços do Censo Longitudinal.

Finalmente, vale destacar que nenhuma informação sobre a aplicação de métodos de anonimização foi encontrada para as divulgações estatísticas do Escritório Australiano de Estatística. As únicas medidas de controle de divulgação relatadas foram a remoção de identificadores óbvios e a publicação de amostras.

Controvérsia sobre armazenamento de dados pessoais do Censo de 2016 Alterando as práticas até então empregadas, o Escritório Australiano de Estatística decidiu manter nomes e endereços coletados para o Censo de População e Habitação de 2016. Em comunicado oficial [11], o ABS justificou que a medida permitiria uma imagem estatística mais rica e dinâmica da Austrália por meio da combinação de dados do Censo com outros dados administrativos e de pesquisa. Mais especificamente, o Escritório declarou que:

Embora o Censo sempre tenha sido valioso por si só, quando usado em combinação com outros dados, ele pode fornecer uma visão ainda maior. Alguns exemplos incluem:

- A combinação de dados do Censo com dados educacionais pode fornecer informações sobre os resultados de emprego a partir dos vários caminhos educacionais disponíveis para os australianos; e
- A combinação de dados do Censo com dados de saúde pode ajudar a melhorar a compreensão e o apoio da Austrália de pessoas que necessitem de serviços de saúde mental e ajudar no projeto de melhores programas de apoio e prevenção.

O Escritório alegou ainda que a retenção de endereços permitiria operações de pesquisa mais eficientes, reduzindo o custo para os contribuintes e o ônus para as famílias australianas.

No mesmo comunicado oficial, o ABS afirmou comprometimento com a proteção da privacidade e confidencialidade dos respondentes ao Censo. Declarou ainda que a medida se baseou em uma cuidadosa Avaliação de Impacto de Privacidade realizada em 2015 [10], e que os riscos à privacidade identificados seriam considerados pequenos dadas as medidas de proteção que o Escritório já adotava. De acordo com o Escritório, tais riscos seriam ainda atenuados pelo armazenamento de nomes e endereços separadamente de outros dados do Censo, bem como separadamente um do outro. Entretanto, houve reação contundente por vários setores da sociedade australiana contra medida.

Em particular, houve forte resistência por parte da Fundação Australiana de Privacidade (*Australian Privacy Foundation*), ¹¹ uma organização não governamental formada com o objetivo de proteger os direitos de privacidade dos australianos. O vice-diretor da entidade, que tem como uma de suas missões defender o direito dos indivíduos de controlar o acesso às informações pessoais e de evitar invasões excessiva, declarou à época que [12]:

As mudanças na tecnologia aumentaram o risco [à privacidade], de modo que a decisão do ABS de armazenar nossos nomes e endereços por anos é ainda mais preocupante. [Esta decisão] cria um atrativo irresistível para hackers e

¹¹<https://privacy.org.au/>

cibercriminosos em uma época em que nenhuma segurança de tecnologia da informação pode impedir “intrusos motivados”. As violações graves de dados são agora um perigo real e crescente. O armazenamento de nomes e endereços também atrairá dezenas de agências [governamentais] reclamando direito de acesso aos dados. O cruzamento de dados está mais fácil, mais barato e mais intrusivo do que nunca. Pode ser necessária apenas “uma canetada” ou uma emenda a um regulamento para que o Governo use os dados para outros fins, caso decida fazê-lo.

À época a imprensa australiana engrossou o coro às críticas à posição do ABS, notando que o movimento do Escritório contrariava as práticas adotadas até então e abalava a credibilidade do Escritório frente à população [98].

A sensação de desconforto de parte da sociedade australiana foi reforçada pela ocorrência de ataques aos servidores do ABS em 2016. Apesar de os ataques não terem causado vazamento ou comprometimento de dados dos Censos, eles reforçaram as dúvidas de parte da imprensa e da sociedade australiana sobre os riscos de vazamento dos dados pessoais armazenados pelo Escritório [17, 103]. De fato, todo o ocorrido tem exigido um grande esforço por parte do ABS para a recuperação de sua credibilidade junto à sociedade australiana.

3 Estudos de caso do panorama nacional

Nesta seção provemos um panorama nacional dos diferentes métodos pelos quais institutos produtores de estatísticas oficiais divulgam informação de forma a garantir transparência e, ao mesmo tempo, privacidade de dados pessoais. Iniciamos a seção com um sumário das principais diretivas e regulamentações gerais brasileiras sobre transparência e privacidade, com especial foco na Lei de Acesso à Informação (LAI) e na Lei Geral de Proteção de Dados Pessoais (LGPD), além do Marco Civil da Internet (MCI). Em seguida, apresentamos estudos de caso referentes à divulgação de informação pelo Instituto Brasileiro de Geografia e Estatística (IBGE) e pelo Portal da Transparência do Governo Federal. ¹

3.1 Regulamentação geral

Nesta seção apresentamos um sumário da regulamentação brasileira sobre privacidade e transparência, com foco nas previsões da Constituição da República, na Lei de Acesso à Informação e na Lei de Proteção de Dados Pessoais. ²

A Constituição da República Federativa do Brasil A Constituição Brasileira de 1988 [37], em seu Artigo 5º, garante a todos os brasileiros e estrangeiros residentes no país que:

X são invioláveis a intimidade, a vida privada, a honra e a imagem das pessoas, assegurado o direito a indenização pelo dano material ou moral decorrente de sua violação;

¹ Um panorama da percepção da questão de privacidade pela sociedade brasileira, formado por uma seleção de reportagens e artigos relevantes recentes produzidos sobre o assunto, pode ser encontrado no Anexo E.

² Aqui nos focamos em uma análise dos pontos mais relevantes dessas diretrizes; uma seleção textual dos pontos da Constituição Federal, da LAI e da LGPD mais relevantes ao Projeto PRICE encontram-se nos Anexos A, B e C, respectivamente.

XXXIII todos têm direito a receber dos órgãos públicos informações de seu interesse particular, ou de interesse coletivo ou geral, que serão prestadas no prazo da lei, sob pena de responsabilidade, ressalvadas aquelas cujo sigilo seja imprescindível à segurança da sociedade e do Estado;

Dessa forma, tem-se que o inciso X do Artigo 5º fundamenta o direito constitucional à privacidade do indivíduo, enquanto que o inciso XXXIII do mesmo Artigo fundamenta o direito constitucional, individual e coletivo, à transparência por parte do Estado. Entretanto, não há qualquer definição referente a como equilibrar esses dois princípios ou sobre quais seriam os limites legais de cada um deles, particularmente frente aos avanços tecnológicos das últimas décadas, os quais propiciaram a coleta e o tratamento em larga escala de dados pessoais.

Portanto, devido à necessidade de regulamentação dos direitos à privacidade e à transparência determinados nas Cláusulas Pétreas da Constituição de 1988, a Lei 12.527 de 2011 foi sancionada para regulamentar o acesso à informação e a Lei 13.709 de 2018 foi sancionada para regulamentar a proteção de dados pessoais.

Lei 12.527/2011 - Lei de Acesso à Informação (LAI) A Lei 12.527 de 2011 [47], conhecida como Lei de Acesso à Informação (LAI), regulamenta o inciso XXXIII do Artigo 5º da Constituição Federal. Em seu Artigo 4º, essa Lei define o significado de alguns termos técnicos, dentre eles:

- I **informação**: dados, processados ou não, que podem ser utilizados para produção e transmissão de conhecimento, contidos em qualquer meio, suporte ou formato;
- II **documento**: unidade de registro de informações, qualquer que seja o suporte ou formato;
- III **informação sigilosa**: aquela submetida temporariamente à restrição de acesso público em razão de sua imprescindibilidade para a segurança da sociedade e do Estado;
- IV **informação pessoal**: aquela relacionada à pessoa natural identificada ou identificável;
- V **tratamento da informação**: conjunto de ações referentes à produção, recepção, classificação, utilização, acesso, reprodução, transporte, transmissão, distribuição, arquivamento, armazenamento, eliminação, avaliação, destinação ou controle da informação;
- VI **autenticidade**: qualidade da informação que tenha sido produzida, expedida, recebida ou modificada por determinado indivíduo, equipamento ou sistema;
- VII **integridade**: qualidade da informação não modificada, inclusive quanto à origem, trânsito e destino;

VIII **primariedade**: qualidade da informação coletada na fonte, com o máximo de detalhamento possível, sem modificações.

Os Artigos 6º e 8º da LAI determinam ao poder público o dever de garantir o amplo acesso à informação, particularmente àquela considerada de interesse coletivo ou geral, a qual deve ser disponibilizada via Internet independentemente de requerimento. Além disso, o Artigo 7º garante o direito de acesso às demais informações não imediatamente disponibilizadas via Internet. Ademais, os Artigos 7º e 8º garantem o acesso à informação primária, íntegra, autêntica, e atualizada em ambos os casos, conforme as definições dadas no Artigo 4º.

Entretanto, ainda de acordo com o Artigo 7º e de acordo com o Artigo 22º, o acesso à informação pode ser negado total ou parcialmente no caso de a informação ser considerada sigilosa, incluindo os casos de segredo de justiça ou industrial.

Particularmente para o caso do tratamento de informações pessoais, o Artigo 31º estabelece que as mesmas devem ser tratadas de forma transparente e com respeito às liberdades e garantias individuais, conforme o inciso X do Artigo 5º da Constituição Federal, determinando restrições ao seu acesso. Mas o parágrafo 3º do mesmo Artigo determina casos específicos nos quais não é exigido o consentimento individual para o uso de informações pessoais, incluindo quando as informações forem necessárias:

II à realização de estatísticas e pesquisas científicas de evidente interesse público ou geral, previstos em lei, sendo vedada a identificação da pessoa a que as informações se referirem;

V à proteção do interesse público e geral preponderante.

Entretanto, ainda de acordo com o Artigo 31º da LAI, em seu parágrafo 5º, fica em aberto à regulamentação posterior disposições sobre o tratamento de informações pessoais.

Lei 12.965/2014 - Marco Civil da Internet (MCI) Como já mencionado antes, o Marco Civil da Internet [59] surgiu no contexto da reação brasileira à invasão aos sistemas de comunicação da Presidência pelo governo dos EUA. Apesar de ter como foco primordial os direitos dos usuários de Internet, a Lei também trata de privacidade. Em particular, o Artigo 7º estabelece que o acesso à Internet é essencial ao exercício da cidadania, e assegura aos cidadãos os seguintes direitos:

VII não fornecimento a terceiros de seus dados pessoais, inclusive registros de conexão, e de acesso a aplicações de internet, salvo mediante consentimento livre, expresso e informado ou nas hipóteses previstas em lei;

VIII informações claras e completas sobre coleta, uso, armazenamento, tratamento e proteção de seus dados pessoais, que somente poderão ser utilizados para finalidades que:

- a) justifiquem sua coleta;
 - b) não sejam vedadas pela legislação; e
 - c) estejam especificadas nos contratos de prestação de serviços ou em termos de uso de aplicações de internet;
- IX consentimento expresso sobre coleta, uso, armazenamento e tratamento de dados pessoais, que deverá ocorrer de forma destacada das demais cláusulas contratuais;
- X exclusão definitiva dos dados pessoais que tiver fornecido a determinada aplicação de internet, a seu requerimento, ao término da relação entre as partes, ressalvadas as hipóteses de guarda obrigatória de registros previstas nesta Lei;

No contexto do presente projeto, entretanto, fica evidente que o MCI é menos relevante que outras regulamentações nacionais.

Lei 13.709/2018 - Lei de Proteção de Dados Pessoais (LGPD ou LGPD) A regulamentação sobre o tratamento de informações pessoais ausente na LAI veio com a Lei 13.709/2018 [41], conhecida como Lei Geral de Proteção de Dados Pessoais (LGPD ou LGPD), a qual tem por objetivo a proteção dos direitos fundamentais de liberdade e de privacidade, conforme o seu Artigo 1º. Em seu Artigo 5º, essa Lei define o significado de alguns termos técnicos, dentre eles:

- I **dado pessoal**: informação relacionada a pessoa natural identificada ou identificável;
- II **dado pessoal sensível**: dado pessoal sobre origem racial ou étnica, convicção religiosa, opinião política, filiação a sindicato ou a organização de caráter religioso, filosófico ou político, dado referente à saúde ou à vida sexual, dado genético ou biométrico, quando vinculado a uma pessoa natural;
- III **dado anonimizado**: dado relativo a titular que não possa ser identificado, considerando a utilização de meios técnicos razoáveis e disponíveis na ocasião de seu tratamento;
- V **titular**: pessoa natural a quem se referem os dados pessoais que são objeto de tratamento;
- VI **controlador**: pessoa natural ou jurídica, de direito público ou privado, a quem competem as decisões referentes ao tratamento de dados pessoais;
- VII **operador**: pessoa natural ou jurídica, de direito público ou privado, que realiza o tratamento de dados pessoais em nome do controlador;
- IX **agentes de tratamento**: o controlador e o operador;

- X **tratamento**: toda operação realizada com dados pessoais, como as que se referem a coleta, produção, recepção, classificação, utilização, acesso, reprodução, transmissão, distribuição, processamento, arquivamento, armazenamento, eliminação, avaliação ou controle da informação, modificação, comunicação, transferência, difusão ou extração;
- XI **anonimização**: utilização de meios técnicos razoáveis e disponíveis no momento do tratamento, por meio dos quais um dado perde a possibilidade de associação, direta ou indireta, a um indivíduo;
- XVIII **órgão de pesquisa**: órgão ou entidade da administração pública direta ou indireta ou pessoa jurídica de direito privado sem fins lucrativos legalmente constituída sob as leis brasileiras, com sede e foro no País, que inclua em sua missão institucional ou em seu objetivo social ou estatutário a pesquisa básica ou aplicada de caráter histórico, científico, tecnológico ou estatístico;

O Artigo 7º dispõe sobre as hipóteses nas quais o tratamento de dados pessoais é permitido, sendo que o Artigo 11º aplica-se especificamente aos dados pessoais sensíveis, conforme definido no Artigo 5º, inciso II. Em ambos os casos, o tratamento é permitido mediante o consentimento do titular ou do responsável legal no caso de dados sensíveis. Entretanto, o consentimento não é exigido nas hipóteses em que o tratamento de dados seja indispensável para, conforme o inciso II do Artigo 11º:

- a) cumprimento de obrigação legal ou regulatória pelo controlador;
- b) tratamento compartilhado de dados necessários à execução, pela administração pública, de políticas públicas previstas em leis ou regulamentos;
- c) realização de estudos por órgão de pesquisa, garantida, sempre que possível, a anonimização dos dados pessoais sensíveis;

Além disso, de acordo com o Artigo 12º da LGPD, dados anonimizados não são considerados dados pessoais, exceto quando a anonimização puder ser revertida com esforços razoáveis. Para tanto, deve-se considerar fatores objetivos como o custo e o tempo necessários para reverter o processo de anonimização dadas as tecnologias disponíveis e desconsiderando-se o uso de meios de terceiros.

Particularmente no contexto de estudos em saúde pública, faz-se o uso do termo pseudonimização, não definido no Artigo 5º, mas apenas no Artigo 13º, parágrafo 4º:

- § 4º Para os efeitos deste artigo, a **pseudonimização** é o tratamento por meio do qual um dado perde a possibilidade de associação, direta ou indireta, a um indivíduo, senão pelo uso de informação adicional mantida separadamente pelo controlador em ambiente controlado e seguro. [Ênfase nossa.]

Tecnicamente, *pseudonimização* é a atribuição de um código individual a cada registro de uma base de dados, acompanhada da transferência de identificadores diretos, como nome e números de identificação, para outra base de dados. Dessa forma, o controlador é capaz de mapear identificadores diretos em uma base de dados a registros específicos na outra base através do uso dos códigos individuais. Entretanto, diferentemente do que é afirmado pelo parágrafo 4º do Artigo 13º, pseudonimização, do ponto de vista técnico, não garante proteção contra a reidentificação de indivíduos a partir da base de dados sem identificadores diretos.

Finalmente, o Artigo 16º da LGPD determina a eliminação dos dados pessoais uma vez finalizado o tratamento para o qual seu uso foi autorizado, salvo as hipóteses específicas nas quais é permitida a sua conservação.

Nota sobre o princípio de autodeterminação informativa Um fundamento em comum na regulamentação apresentada acima é o *princípio de autodeterminação informativa*, descrito da seguinte forma por Luíza Brandão, fundadora e diretora do Instituto de Referência em Internet e Sociedade (IRIS) ³ [20]:

Esse conceito [o princípio de autodeterminação informativa], que ganha notoriedade nas discussões europeias sobre proteção de dados, leva em conta que a lógica da economia baseada em dados gira em torno de informações construídas sobre e a partir de pessoas. Em tal cenário, a autodeterminação seria uma forma de proteção frente aos interesses de outros atores da “economia da vigilância” pela qual as pessoas podem determinar, escolher e controlar as informações (extraídas a partir de seus dados) sobre elas, seus modos de utilização e, inclusive, seu apagamento ou correção. A escolha legislativa do Marco Civil que reflete esse conceito, como em outras regulações pelo mundo, se expressa na ideia de consentimento. Conforme descreve Bruno Bioni [18], o consentimento *[n]ada mais é do que a liberdade que todo cidadão tem de reger a sua vida, criando, modificando e extinguindo as suas relações em meio à sociedade. Essa mesma autonomia é captada e transportada para a proteção dos dados pessoais, na medida em que é o próprio cidadão quem deve governar seus dados pessoais.*

Nota sobre regulamentação específica referente a crianças No que se refere ao tratamento de dados de crianças e adolescentes, o Artigo 14º da LGPD estabelece que o mesmo deverá ser realizado com o consentimento específico e em destaque dado por pelo menos um dos pais ou pelo responsável legal. Além disso, os controladores responsáveis pelos dados devem publicar os tipos de dados coletados, como esses dados são utilizados, e quais são os meios para que os direitos garantidos ao titular dos dados, de acordo com a LGPD, sejam exercidos, incluindo o acesso aos dados, a correção dos mesmos, ou

³<http://irisbh.com.br>

a revogação do consentimento e eliminação dos dados. Ademais, todas as informações a respeito do tratamento de dados de crianças e adolescentes devem ser fornecidas de maneira simples, clara e acessível, de modo que seja adequada ao entendimento não apenas dos pais ou do responsável legal, mas também da criança ou do adolescente.

3.2 Estudo de caso nacional 1: Divulgação de dados estatísticos pelo IBGE

A Fundação Instituto Brasileiro de Geografia e Estatística (IBGE), ⁴ vinculada ao Ministério da Economia, ⁵ é o principal órgão estatístico do país e responsável pela produção e análise dos Censos Demográficos Decenais e de diversos outros produtos estatísticos nos âmbitos social, demográfico, agropecuário, e econômico.

3.2.1 Regulamentação específica

A Lei 5.534, de novembro de 1968 [43], junto à sua regulamentação pelo Decreto 73.177, de novembro de 1973 [40], define o mandato do IBGE para coleta de dados sob a jurisdição brasileira. De acordo com a Lei, em seu Artigo 1º, toda pessoa natural ou jurídica, de direito público ou privado, é obrigada a prestar as informações solicitadas pelo IBGE. Entretanto, essas informações são protegidas por sigilo e podem ser usadas, exclusivamente, para fins estatísticos [34].

Tendo em vista o mandato legal do IBGE e o *Código Regional de Boas Práticas das Estatísticas para a América Latina e o Caribe* [27], baseado nos *Princípios Fundamentais das Estatísticas Oficiais da ONU* [30], o IBGE publicou em 2013 o *Código de Boas Práticas das Estatísticas do IBGE* [33]. De acordo com a Seção 1 do Código, Princípio 4, o IBGE considera como indicadores de boas práticas relativas à confidencialidade estatística, que:

- 4.6 O acesso aos microdados não desidentificados deve estar sujeito a protocolos de confidencialidade, estabelecidos para usuários externos que têm acesso com a finalidade de análise e pesquisa estatística.
- 4.7 O arquivamento das informações pelo Instituto deve ser feito de acordo com os protocolos de segurança e confidencialidade estabelecidos e com as normas vigentes.

3.2.2 Dados divulgados

O IBGE divulgou em 2018 o documento *Confidencialidade no IBGE - procedimentos adotados na preservação do sigilo das informações individuais nas divulgações de resultados das operações estatísticas* [34]. Dentre os procedimentos abordados, destacam-se

⁴<https://www.ibge.gov.br/>

⁵<https://www.gov.br/economia/pt-br>

aqueles referentes às Pesquisas Domiciliares por Amostragem Probabilística e aos Censos Demográficos Decenais.

Pesquisas Domiciliares por Amostragem Probabilística No que se refere às Pesquisas Domiciliares por Amostragem Probabilística, o IBGE divulga tanto informações agregadas em forma de tabelas quanto microdados. Para os dados agregados, o Instituto afirma não aplicar procedimentos de desidentificação nas células das tabelas, sob o argumento de que a reidentificação de informantes não é possível dada a natureza da investigação e da divulgação [34]: ⁶

Isso porque a natureza da investigação e da divulgação não permite a identificação dos informantes desses dados, uma vez que os dados tabulados correspondem a estimativas obtidas a partir da agregação de unidades investigadas na amostra ponderadas pelos fatores de expansão (ou pesos), inerentes ao plano amostral da pesquisa.

Já para a divulgação de microdados, o IBGE disponibiliza arquivos com microdados desidentificados, i.e., sem variáveis que propiciem a identificação imediata do informante, como seu nome ou endereço. O Instituto argumenta outra vez que, dada a natureza da investigação, a simples desidentificação dos registros já seria o suficiente para garantir a impossibilidade de reidentificação [34]: ⁷

O procedimento de amostragem, por si só, já se configura numa técnica de tratamento estatístico para o controle do risco de revelação de dados individuais.

Censos Demográficos Decenais No que se refere aos Censos Demográficos Decenais, o IBGE divulga microdados apenas sobre a parcela de investigação por amostragem. Já para os dados censitários dos Censos, o IBGE não publica microdados, mas apenas dados agregados, uma vez que seria possível a reidentificação dos informantes indiretamente, com ou sem o auxílio de informações externas. Para os dados agregados, o IBGE afirma não aplicar procedimentos de desidentificação às células das tabelas. Entretanto, para o Censo Demográfico de 2010, setores com menos do que cinco domicílios particulares permanentes tiveram os valores omitidos para a maioria das variáveis.

⁶Os autores do presente documento acreditam que as afirmações do IBGE quanto ao baixo risco à privacidade acarretado pela divulgação de dados agregados merecem escrutínio cuidadoso. A literatura técnica é rica em exemplos de violações de privacidade decorrentes da divulgação de dados agregados, e esse fato é reconhecido no próprio *Documento de Trabalho sobre Política Estatística 22 - Relatório sobre a Metodologia de Limitação de Divulgação Estatística* das agências federais americanas [93], assim como no relatório sobre o Censo de 2020 nos EUA [57], ambos já tratados no presente documento.

⁷ Os autores do presente documento acreditam que também as afirmações do IBGE quanto ao baixo risco à privacidade acarretado pela divulgação de dados amostrais merecem escrutínio cuidadoso, uma vez que a literatura técnica contém exemplos de violações de ocorridas em divulgações desse tipo [76].

Finalmente, o IBGE conta com uma Sala de Acesso a Dados Restritos (SAR), na qual o público externo tem acesso aos microdados de forma controlada, de acordo com o perfil do usuário que acessa o serviço.

3.3 Estudo de caso nacional 2: Divulgação de dados pelo Portal da Transparência do Governo Federal

De acordo com o próprio Governo Federal [48], o Portal da Transparência por ele mantido ⁸ é um canal pelo qual o cidadão pode acompanhar a utilização dos recursos federais arrecadados com impostos no fornecimento de serviços públicos à população, além de informar-se sobre outros assuntos relacionados à Administração Pública Federal. O site, lançado em 2004 e remodelado em junho de 2018, é mantido pela Controladoria Geral da União (CGU) e tem o objetivo de garantir e ampliar a transparência da gestão pública e fortalecer a participação social na fiscalização dos gastos e investimentos do Poder Executivo Federal.

Regulamentação específica Aplicam-se ao Portal da Transparência do Governo Federal a Lei de Acesso à Informação (LAI) e a Lei Complementar 131/2009, também conhecida como Lei Capiberibe [46], que permite o acesso a informações referentes ao Poder Executivo Federal. Em particular, a Lei Capiberibe estabelece que devem publicizar-se todos os atos praticados pelas unidades gestoras no decorrer da execução de despesa, no momento de sua realização, com a disponibilização mínima dos dados referentes ao número do correspondente processo, ao bem fornecido ou ao serviço prestado, à pessoa física ou jurídica beneficiária do pagamento e, quando for o caso, ao procedimento licitatório realizado.

Dados divulgados Dentre os dados disponibilizados, encontram-se microdados referentes a fichas de remuneração de servidores públicos e recursos disponibilizados e sacados por beneficiários de programas sociais, como o Bolsa Família, o Benefício de Prestação Continuada, e o Auxílio Emergencial devido à pandemia de COVID-19, implementado em abril de 2020. Em ambos os casos, é possível encontrar para um mesmo indivíduo dados como nome completo, CPF parcial, estado e cidade de residência, além dos valores recebidos. Exceto pela omissão parcial do CPF, nenhuma outra técnica de controle de divulgação foi aplicada aos microdados, sendo possível a reidentificação direta dos indivíduos presentes nos registros.

⁸<http://www.portaltransparencia.gov.br/>

4 Análise da atual situação do Inep frente aos panoramas internacional e nacional e à literatura técnica em privacidade

Nesta seção apresentamos uma análise da atual forma de divulgação dos Censos Educacionais por parte do Inep, com especial foco nos possíveis riscos à privacidade dela decorrentes. Iniciamos a seção com uma contextualização da atual situação do Instituto, que inclui um sumário dos principais pontos da regulamentação específica aplicável ao mesmo, uma breve descrição da atual forma de divulgação das Pesquisas Educacionais realizadas pelo Inep e a identificação das atuais metodologias de mitigação de danos à privacidade aplicadas pelo Instituto. Em seguida, apresentamos um sumário comparativo do contexto do Inep com o dos outros casos de estudo internacionais e nacionais já apresentados neste documento e destacamos os pontos identificados como os mais relevantes à atual situação do Inep. Por fim, realizamos uma avaliação preliminar dos possíveis riscos decorrentes da forma de divulgação adotada pelo Instituto de acordo com o conhecimento acumulado na literatura técnica sobre proteção de privacidade.

4.1 Descrição da atual forma de divulgação dos Censos Educacionais pelo Inep

A harmonização dos requisitos legais da LAI e da LGPD são desafios para o Inep, em particular, na divulgação dos dados de seus Censos Educacionais.¹

É relevante observar que existem regulamentos institucionais que visam a dar transparência à forma como o Inep produz e divulga os resultados das pesquisas que desenvolve.

¹A Seção 3.1 apresenta uma visão geral destas leis, enquanto os Anexos B e C deste documento complementam esta exposição com uma seleção de trechos, respectivamente, da LAI e da LGPD identificados como sendo de impacto mais relevante para a divulgação dos Censos Educacionais por parte Inep.

Mais precisamente, a Portaria 91/2018 [64] apresenta um conjunto de princípios fundamentais e de boas práticas que orientam a produção e divulgação das estatísticas educacionais oficiais produzidas pelo Instituto. Já a Portaria 492/2018 [65] institui a *Política de Divulgação de Estatísticas, Exames e Avaliações, Estudos e Pesquisas Educacionais do Inep*. Em particular, em seu Artigo 6º, a Portaria define que “os dados pessoais coletados pelo Inep para fins de pesquisa e produção de estatísticas serão empregados apenas para os fins a que se destinam, tratados com o devido sigilo estatístico, nos termos da legislação aplicável”. Na prática, entretanto, as Portarias acima servem principalmente como guias de políticas institucionais que deveriam se desdobrar em protocolos e procedimentos, mas que ainda não tiveram essas regulamentações definidas.

4.1.1 Regulamentação específica aplicável

A Lei 9.448/1997 [45], assim como o Decreto 6.317/2007 [38], definem como finalidades do Inep, dentre outras, o desenvolvimento e a manutenção de sistemas de estatísticas educacionais e de projetos de avaliação educacional, assim como a disseminação dessas informações e de demais produtos relacionados. Entretanto, diferentemente do mandato do Instituto Brasileiro de Geografia e Estatística (IBGE) para coleta de dados, baseado em Lei e regulamentado por Decreto específicos (ver Seção 3.2 para mais detalhes sobre o caso do IBGE), o Inep dispõe apenas do Decreto 6.425/2008 [39], o qual regulamenta o Censo Anual da Educação.

De acordo com o Decreto 6.425/2008, tanto os estabelecimentos de Educação Básica quanto os estabelecimentos de Ensino Superior, sejam eles públicos ou privados, são obrigados a fornecer as informações solicitadas pelo Inep. Além disso, o Decreto assegura o sigilo dos dados pessoais coletados e veda a utilização dos mesmos para outros fins. Entretanto, o Decreto apenas regulamenta a Lei 9.394/1996 [44], a qual estabelece um mandato à União, e não ao Inep, para a coleta, análise, e disseminação de informações sobre a educação, assim como o acesso a todos os dados e informações necessários de todos os estabelecimentos e órgãos educacionais.

4.1.2 Atual forma de divulgação dos Censos Educacionais

Tendo em vista tanto as finalidades conferidas ao Inep quanto os requisitos da LAI, o Instituto publicou em julho de 2016 a Portaria 370, que institui a *Política de Dados Abertos* [31]. De acordo com o Plano Institucional de Dados Abertos estabelecido, dada a Matriz de Responsabilidade para divulgação de produtos na forma de bases de dados, o Inep produz e publica os seguintes produtos formados por microdados, ou seja, dados na menor unidade de agregação possível:

- **Censo da Educação Básica:** com frequência anual, é a principal pesquisa estatística educacional do país, a qual abrange a Educação Básica e Profissional. Inclui a Educação Infantil, os Ensinos Fundamental e Médio, a Educação Especial,

a Educação de Jovens e Adultos, e os Cursos Técnicos e Cursos de Formação Inicial Continuada ou Qualificação Profissional.

- **Censo da Educação Superior:** com frequência anual, é a mais completa pesquisa estatística sobre as Instituições de Ensino Superior (IES's) do país, as quais ofertam Cursos de Graduação e Sequências de Formação Específica. Inclui informações sobre as IES, além de seus alunos e docentes.
- **Exame Nacional do Ensino Médio (ENEM):** com frequência anual, é responsável por avaliar o desempenho escolar ao final da Educação Básica. Seus resultados colaboram para o acesso à Educação Superior, incluindo a oferta de financiamento e apoio estudantil.
- **Sistema de Avaliação da Educação Básica (SAEB):** com frequência bienal, consiste em um conjunto de testes e questionários aplicados na rede pública e em uma amostra da rede privada. Auxilia o Inep na realização de um diagnóstico da Educação Básica e de possíveis fatores que interfiram no desempenho do estudante.
- **Exame Nacional de Certificação de Competências de Jovens e Adultos (ENCCEJA):** com frequência eventual, afere competências, habilidades, e saberes de jovens e adultos que não tenham concluído o Ensino Fundamental ou o Ensino Médio na idade adequada.
- **Exame Nacional de Desempenho dos Estudantes (ENADE):** com frequência anual, avalia o rendimento dos concluintes dos Cursos de Graduação tanto em relação aos conteúdos programáticos previstos nas diretrizes curriculares dos cursos, quanto no que diz respeito às habilidades desenvolvidas e à atualização do aluno em relação ao Brasil e ao mundo.

Os microdados das Pesquisas acima são divulgados pelo Inep para *download* no domínio do Instituto,² com links também disponibilizados a partir do Portal Brasileiro de Dados Abertos³ e em mecanismos de pesquisa como o Google Dataset Search.⁴

Para o Censo da Educação Básica, o Inep disponibiliza dados de 1995 até 2019, assim como para o Censo da Educação Superior, exceto pela base de dados referente a 2019, ainda não publicada. A partir de 2007, o Instituto passou a divulgar microdados relativos ao Censo da Educação Básica com informações individuais sobre alunos e professores, além de escolas e turmas. O mesmo ocorreu a partir de 2009 para o Censo da Educação Superior, com a divulgação de microdados sobre alunos e professores, além de instituições e cursos.

No caso dos exames, o Inep disponibiliza microdados com informações individuais sobre os participantes do ENEM desde 1998 até 2018, e do ENADE desde 2004 até 2018.

²<http://inep.gov.br/microdados>

³<http://dados.gov.br/>

⁴<https://datasetsearch.research.google.com/>

Vale destacar que as respostas dadas por cada um dos participantes ao Questionário Socioeconômico também constam dos microdados, assim como as alternativas por eles selecionadas para cada uma das questões do exame.

Especificamente para o ENEM, vale ainda destacar que o Inep passou a divulgar o Código da Escola de cada participante a partir de 2001, com o cuidado de utilizar uma máscara de proteção e não o Código da Escola conforme publicado no Censo da Educação Básica. Essa medida vigorou até a publicação dos microdados para o ENEM de 2006, sendo que a partir de 2007, o Código da Escola passou a apresentar o valor real conforme o Censo da Educação Básica. Além disso, o Inep publicou uma segunda edição para várias das bases de microdados do ENEM em 2019, sendo a remoção da data de nascimento e a inclusão da idade dos inscritos a alteração mais relevante.

4.1.3 Métodos de proteção de privacidade atualmente empregados

A partir das análises iniciais realizadas sobre os arquivos de microdados dos Censos Educacionais disponibilizados publicamente, identificamos que o Inep aplica as seguintes técnicas de proteção de privacidade aos microdados divulgados:

- *desidentificação*, pela qual são removidos possíveis identificadores individuais óbvios dos registros (como nome, CPF, RG, ou endereços em níveis mais detalhados que as cidades); e
- *pseudonimização*, em que o Instituto atribui a cada registro um código único de identificação artificialmente criado, substituindo identificadores individuais naturais (como nome, CPF ou RG).

Nenhuma outra medida para o controle de divulgações estatísticas foi identificada.

4.2 Sumários comparativos da atual situação do Inep com os estudos de caso internacionais e nacionais

Em seções anteriores deste documento apresentamos uma coleção de estudos de caso relativos a como institutos produtores de estatísticas oficiais equilibram requisitos de transparência e de proteção de privacidade em seus métodos de divulgação de informação.

Em particular, apresentamos tanto casos internacionais, no contexto dos Estados Unidos da América, da União Europeia, e da Austrália (Seção 2), quanto casos nacionais, com foco na divulgação de dados por parte do IBGE e do Portal da Transparência do Governo Federal (Seção 3). Na presente seção provemos sumários comparativos entre a atual situação do Inep em relação à divulgação das informações de seus Censos Educacionais e estes estudos de caso, organizados da seguinte forma:

- a Tabela 4.2.1 apresenta um quadro-sumário dos estudos de caso internacionais no contexto dos EUA;
- a Tabela 4.2.2 apresenta um quadro-sumário dos estudos de caso internacionais no contexto da União Europeia e Austrália; e
- a Tabela 4.2.3 apresenta um quadro-sumário dos estudos de caso nacionais, incluindo a atual situação do Inep em relação à divulgação de seus Censos Educacionais.

4.3 Destaques da comparação de estudos de caso identificados como relevantes à atual situação do Inep

A partir dos quatro critérios utilizados na análise da seção anterior, identificamos os seguintes destaques em relação à atual forma de divulgação dos Censos Educacionais pelo Inep frente àquela adotada nos panoramas internacional e nacional levantados.

Principais pontos da regulamentação geral relevante Todos os países e regiões internacionais pesquisados (EUA, União Europeia e Austrália) possuem alguma forma de regulamentação geral que define parâmetros mínimos de cuidado na divulgação de dados pessoais e estabelece um conjunto de direitos a indivíduos, incluindo aqueles sobre coleta, manutenção e tratamento dos dados, com especial foco na preservação de privacidade de dados pessoais.

Destaque identificado relevante à atual situação do Inep: A LGPD brasileira foi fortemente inspirada pelo seu equivalente europeu, o GDPR, com o qual compartilha filosofia e abrangência similares. De fato, pode-se constatar que a legislação brasileira relativa à privacidade se aproxima mais da europeia, que por sua vez é muito diferente da legislação dos EUA. Entretanto, há significativas diferenças entre a LGPD e a GDPR, e o Anexo D apresenta um paralelo mais detalhado dos dois regulamentos.

Principais pontos da regulamentação específica relevante aplicável à agência ou órgão Todos os casos internacionais pesquisados exigem a utilização dos dados para o propósito original para que foram coletados, com raras exceções em caso de segurança nacional (como no caso de uso de dados para combate ao terrorismo nacional ou internacional, permitido pelo *USA PATRIOT Act* dos EUA). Além disso, a maioria dos casos internacionais pesquisados prevê a obrigatoriedade do uso de pelo menos técnicas simples de preservação de privacidade de dados individuais, como alguma forma de ocultação de identificadores óbvios via *desidentificação*, ou substituição de identificadores naturais por códigos artificialmente gerados via *pseudonimização*.

Destaque identificado relevante à atual situação do Inep: Não foi identificada regulamentação específica que obrigue o Inep a manter a divulgação de todos os microdados de seus Censos Educacionais da forma como atualmente é feita. A manutenção da acurácia dos dados colhidos pelo Inep depende da confiança que as fontes dos mesmos depositam nos processos empregados pelo Instituto. É crucial, portanto, zelar pela percepção dos titulares dos dados –incluindo escolas professores, estudantes e seus familiares– quanto à apropriada proteção de sua privacidade.

Formas de divulgação de dados No caso das escolas e do Ministério da Educação da Holanda, não foi identificada a divulgação de microdados sobre indivíduos. No contexto da Austrália ocorreu, até o último Censo realizado, em 2016, a publicação de microdados apenas de forma controlada. No contexto dos EUA, em geral, agências federais devem dar preferência a dados agregados, mas até recentemente microdados ainda eram publicados após submetidos a medidas de proteção como: (i) divulgação de dados de apenas uma amostra da população; (ii) aplicação de técnicas de proteção como introdução de ruído e permutação; ou (iii) autorização de acesso completo apenas através de salas seguras.

No contexto nacional, o IBGE publica tanto microdados quanto dados agregados para as Pesquisas Domiciliares por Amostragem Probabilística, enquanto que para os Censos Demográficos Decenais são divulgados microdados apenas sobre a parcela de investigação por amostragem, sendo os dados censitários divulgados apenas de forma agregada. Já o Portal da Transparência do Governo Federal, por seu próprio objetivo expresso, publica microdados de forma explícita, incluindo dados pessoais. É relevante ressaltar que essa divulgação por parte do Portal da Transparência pode ser utilizada como informação auxiliar em ataques de reidentificação a outras bases de dados tratadas com as técnicas de desidentificação e, em especial, de pseudonimização. (Na Seção 4.4 exemplificamos casos de ataques que se valem do cruzamento de informação entre bases distintas.) É, portanto, de particular importância que as entidades que divulgam microdados de pesquisas, incluindo o Inep, considerem esse risco. No contexto do Inep a preocupação é reforçada pela grande abrangência da população brasileira cujos dados estão contidos no Portal da Transparência (e.g., sabe-se que parte considerável dos alunos das escolas públicas brasileiras –algo entre 40% e 50%– consiste em beneficiários do Bolsa Família e, portanto, seus dados estão disponíveis no Portal da Transparência).

Destaque identificado relevante à atual situação do Inep: Frente a todos os casos internacionais estudados, o Inep publica em seus Censos Educacionais a maior quantidade de microdados individuais e em maior nível de detalhes.

Medidas de proteção de privacidade empregadas No caso das publicações dos institutos educacionais e do Ministério da Educação da Holanda, não foi identificada a

presença de microdados, sob nenhuma forma, o que indica a forte preocupação destes órgãos com os riscos de violação de privacidade inerentes a esse tipo de dado. O Escritório Australiano de Estatística (ABS) protege a publicação de microdados com divulgação de apenas amostras da população, acesso restrito aos microdados baseado em pré-aprovação, e cobrança monetária por este acesso.

Nos EUA, as agências federais produtoras de estatísticas oficiais reconhecem explicitamente, pelo menos desde 2005, a dificuldade inerente de se protegerem microdados contra violações de privacidade, uma vez que há sempre a possibilidade de que informações externas aos microdados sejam utilizadas para a reidentificação de indivíduos. Por esta razão, a divulgação de microdados ocorria de forma controlada por medidas que têm como potencial efeito colateral uma significativa diminuição da precisão dos dados divulgados. (Por exemplo, os registros submetidos a permutação, a apagamento e imputação, ou a *blurring* não são marcados de qualquer forma nos arquivos divulgados, de modo a garantir a segurança desses registros; com isso, um elevado grau de incerteza é adicionado aos dados, uma vez que o usuário se torna incapaz de determinar se um registro isolado contém dados reais, permutados, imputados, ou ofuscados.) Em particular, o Escritório do Censo dos EUA (USCB) reconheceu recentemente que mesmo as medidas adotadas até o último Censo Decenal, em 2010, para proteção de privacidade não são suficientes. O USCB está no momento alterando drasticamente a forma de divulgação de dados de seu Censo de 2020 para dados tabulares protegidos por privacidade diferencial. Além disso, usam-se nos EUA salas seguras (*Research Data Centers* - RDCs) espalhadas pelo país para acesso controlado a microdados por indivíduos previamente autorizados.

No contexto nacional, o IBGE reconhece os riscos inerentes à divulgação de microdados, publicando aqueles relativos às Pesquisas Domiciliares por Amostragem Probabilística apenas após desidentificação. Entretanto, o IBGE é mais permissivo na publicação de dados agregados, afirmando não aplicar medidas extras de proteção neste caso sob o argumento de que a reidentificação de informantes não seria possível dada a natureza da investigação e da divulgação agregada.⁵ Já o Portal da Transparência do Governo Federal, por seu próprio objetivo expresso, publica microdados de forma explícita, sem aparente preocupação com a consequente reidentificação de indivíduos possível.

Destaque identificado relevante à atual situação do Inep: Em todos os casos internacionais estudados, os órgãos produtores de estatísticas oficiais adotam medidas mais rígidas que o Inep no controle de divulgação de microdados, com destaque para: (i) não publicação de microdados individuais de estudantes sob nenhuma forma (caso

⁵Como já mencionado na Seção 3.2, os autores do presente documento acreditam que as afirmações do IBGE quanto ao baixo risco à privacidade acarretado pela divulgação de dados agregados merecem escrutínio cuidadoso. A literatura técnica é rica em exemplos de violações de privacidade decorrentes da divulgação de dados agregados, e esse fato é reconhecido no próprio *Documento de Trabalho sobre Política Estatística 22 - Relatório sobre a Metodologia de Limitação de Divulgação Estatística* das agências federais americanas [93], assim como no relatório sobre o Censo de 2020 nos EUA [57], ambos já tratados no presente documento.

das escolas e do Ministério da Educação na Holanda); (ii) publicação de microdados apenas por amostras da população (caso do Escritório do Censo dos EUA - USCB e do Escritório Australiano de Estatística - ABS); ou (iii) acesso a todo o conjunto de microdados permitido apenas sob autorização prévia e em salas seguras (também caso do Escritório do Censo dos EUA - USCB). Dado o compromisso não trivial que existe entre transparência em divulgação de dados e proteção de privacidade, as medidas adotadas pelos institutos internacionais estudados em geral diminuem –e, em alguns casos, consideravelmente– a acessibilidade e a qualidade das informações prestadas de forma aberta à sociedade. No caso do Inep, identificamos que a extensa base de microdados dos Censos Educacionais é divulgada em sua totalidade, sendo que os microdados são tratados apenas com as técnicas de *desidentificação*, em que se removem possíveis identificadores individuais óbvios dos registros (como nome, CPF, RG) e de *pseudonimização*, em que tais identificadores individuais óbvios são substituídos por um código único de identificação artificialmente criado. A atual forma de divulgação de microdados pelo Inep está sujeita a vários riscos já identificados na literatura técnica na área de privacidade (que são melhor discutidos na Seção 4.4).

4.4 Possíveis riscos à privacidade que a literatura técnica aponta na atual situação do Inep

O plano de trabalho do presente TED 8750 prevê produtos cujo objeto são análises detalhadas sobre os riscos à privacidade decorrentes da atual forma de divulgação dos dados dos Censos Educacionais pelo Inep (Produto 02), assim como possíveis formas de mitigação dos mesmos (Produtos 03). Nesta seção procedemos a uma análise preliminar da atual situação do Inep baseada em uma revisão dos riscos já documentados na literatura.

A literatura técnica na área de proteção de privacidade apresenta fartos exemplos de que métodos de mitigação de riscos à privacidade como aqueles atualmente empregados pelo Inep –mais especificamente, o método de *desidentificação* (i.e., remoção de identificadores individuais óbvios, como CPF, nome completo, ou identidade) e o método de *pseudonimização* (i.e., substituição dos identificadores usuais por identificadores artificiais, como números únicos produzidos para cada indivíduo)– são, em isolamento, insuficientes para proteger a privacidade dos titulares dos dados. Podemos destacar os seguintes trabalhos como alguns dos mais influentes sobre o assunto nas últimas décadas:

- (I) Em 1998, Samarati e Sweeney observaram que, mesmo quando os titulares de dados removem ou criptografam identificadores explícitos (como nomes, endereços e números de telefone) de indivíduos aos quais microdados divulgados se referem, outros dados distintos, que elas denominaram *quaseidentificadores* (*quasi-identifiers*, no original em inglês), geralmente se combinam de maneira inadequada e podem ser vinculados a informações publicamente disponíveis para reidentificar os indivíduos

[105]. Como exemplo de quaseidentificadores poderosos, Sweeney demonstrou em 2000 que 87% da população dos EUA poderia ser unicamente identificada usando-se apenas o *zip-code* (o equivalente americano ao CEP brasileiro), o gênero e data de nascimento do indivíduo [109]. Portanto, qualquer divulgação de microdados que contivesse pelo menos estes três campos (e.g., algum censo ou base de dados médicos) permitiria a reidentificação de até 87% da população americana, levando a uma consequente exposição generalizada de atributos sensíveis individuais.

- (II) Em 2008, Narayanan e Shmatikov apresentaram uma nova técnica de reidentificação estatística de microdados de alta dimensão (e.g., aqueles que contêm preferências individuais, recomendações, ou registros de transações) e a aplicaram ao conjunto de microdados do *Prêmio Netflix* [77], que continha as notas atribuídas aos filmes assistidos (*movie ratings*, do original em inglês) por 500.000 assinantes da Netflix, então o maior serviço de aluguel de filmes *on-line* do mundo [76]. Os pesquisadores demonstraram que alguém que conhecesse apenas poucos dados sobre um assinante individual poderia facilmente reidentificar o registro desse assinante no conjunto de microdados. Usando o *Internet Movie Database* (IMDB)⁶ como fonte de informação auxiliar, os pesquisadores foram capazes de reidentificar com sucesso nos registros da Netflix usuários famosos, descobrindo suas aparentes preferências políticas e outras informações potencialmente sensíveis.

Como exemplo concreto dos riscos apresentados pelos trabalhos acadêmicos acima, destacamos o caso de reidentificação da AOL [2]. Esse caso ocorreu em um contexto bastante similar ao do Inep no momento, e serve como ilustração dos riscos à privacidade decorrentes do uso de apenas métodos de desidentificação e pseudonimização. Em 4 de agosto de 2006, a *AOL Research* disponibilizou um arquivo de texto compactado em um de seus sites contendo cerca de 20 milhões de palavras-chave usadas por 650.000 usuários em seu motor de busca, em um período de três meses, destinado a fins de pesquisa. O arquivo foi desidentificado e pseudonimizado de forma que identificadores pessoais óbvios foram removidos e nomes foram substituídos por números como pseudônimos, mas as palavras-chave das consultas realizadas por cada indivíduo permaneceram no arquivo. Como exemplo, os dados divulgados mostravam que o indivíduo #4.417.749 havia realizado pesquisas no motor de busca por expressões como “*dedos dormentes*”, “*homens solteiros com mais de 60 anos*”, “*cão que urina em tudo*”, e “*paisagistas em Lilburn, GA*”. Cruzando os dados dessas pesquisas com informações de listas telefônicas, o jornal *The New York Times* foi capaz de identificar unicamente o indivíduo #4.417.749 como Thelma Arnold, uma viúva de 62 anos de Lilburn, estado da Georgia, EUA [106]. Apesar de, no caso específico de Arnold, o jornal ter divulgado sua identidade com sua permissão, o risco potencial às outras centenas de milhares de usuários da base estava escancarado. Essa violação foi amplamente divulgada na imprensa, e levou à renúncia da então CTO da organização, Maureen Govern, em 21 de agosto de 2006. A AOL reconheceu que a liberação dos dados, mesmo desidentificados e pseudonimizados, foi um erro e os removeu

⁶<https://www.imdb.com/>

de sua página; no entanto, a remoção foi tardia demais. Os dados foram redistribuídos por outras pessoas e ainda podem ser baixados de páginas-espelho.

É importante observar que a atual forma de divulgação de microdados dos Censos Educacionais por parte do Inep é muito similar àquela adotada pela AOL no exemplo acima, o que suscita a razoável preocupação sobre em qual extensão os dados do Inep estariam sujeitos a violações de privacidade semelhantes.

De fato, como mencionamos na introdução do presente documento, os pesquisadores brasileiros Queiroz e Motta já observaram a vulnerabilidade da atual situação do Inep em um estudo de 2015 [102]. Utilizando o arquivo referente aos docentes do Censo da Educação Superior do ano de 2013, eles conseguiram reidentificar unicamente um dos autores do estudo dentre todos os 383.683 registros de docentes na base utilizando apenas sua data de nascimento, gênero, e nome da Instituição de Ensino Superior à qual estava vinculado. Como possível solução, Queiroz e Motta sugeriram a aplicação de dois métodos mais sofisticados aos Censos Educacionais do Inep: os métodos sintáticos conhecidos como *k-anonymity* [105] e *l-diversity* [71], o que foi feito com o auxílio da ferramenta ARX [100]. Os resultados preliminares apresentados pelos autores poderiam parecer, à primeira vista, promissores: utilizando a ferramenta ARX, eles computaram que o número de indivíduos com alto risco de reidentificação caiu de 100% no conjunto de microdados original para 50% no conjunto de microdados tratado com as novas técnicas. Entretanto, métodos sintáticos como *k-anonymity* e *l-diversity* são demonstradamente vulneráveis a um tipo de ataque conhecido como *ataque composicional*, ao qual o Inep estaria sujeito por publicar os Censos Educacionais com frequência regular. A fragilidade destes métodos já foi demonstrada pelo próprio ataque de Narayanan e Shmatikov citado no Exemplo II acima, relativo ao Prêmio Netflix (que foi realizado sobre uma base *k*-anonimizada), e confirmada pela avaliação da equipe responsável pelo novo método de publicação do Censo 2020 dos EUA [57]. Portanto, mesmo os métodos sugeridos por Queiroz e Motta em seu trabalho de 2015, isoladamente, não resolveriam de forma definitiva o problema de proteção de privacidade no caso do Inep.

Ademais, conforme mencionado na Seção 4.3, os microdados pessoais divulgados pelo Portal da Transparência poderiam ser usados como informação auxiliar em tentativas de reidentificação de indivíduos nos Censos Educacionais divulgados pelo Inep. Mais precisamente, os dados do Portal poderiam ser cruzados com os Censos de forma análoga a como os dados do IMDB foram cruzados com os dos usuários da Netflix no caso descrito acima. No contexto do Inep a preocupação é reforçada pela grande abrangência da população brasileira cujos dados estão contidos no Portal da Transparência (e.g., parte considerável dos alunos das escolas públicas brasileiras consiste em beneficiários do Bolsa Família e, portanto, seus dados estão disponíveis no Portal da Transparência).

A discussão da presente seção demonstra não apenas que há uma possibilidade concreta de violações de privacidade decorrentes da atual forma de divulgação de dados dos Censos Educacionais por parte do Inep, como também o fato de que a escolha das técnicas de mitigação de danos à privacidade devem ser adotadas com critérios cuidadosos.

Estudos de caso internacionais: Estados Unidos da América			
	Caso 1: Agências Federais (2005) - Seção 2.2.2	Caso 2: Centro Nacional de Estatísticas da Educação (NCES) - Seção 2.2.3	Caso 3: Escritório do Censo (USCB) - Seção 2.2.4
Principais pontos da regulamentação geral relevante	Lei de Privacidade de 1974, Tít. 5 Cód. EUA [89]: agências federais que lidam com registros de informações pessoais identificáveis devem protegê-los contra uso indevido, e seu uso para pesquisas estatísticas deve garantir que os mesmos não sejam individualmente identificáveis. Lei de Proteção à Informação Confidencial e Eficiência Estatística de 2002 [92]: torna-se crime federal a divulgação intencional, sem consentimento, de dados individualmente identificáveis obtidos para fins estatísticos sob promessa de confidencialidade.		
Principais pontos da regulamentação específica relevante aplicável à agência ou órgão	Documento de Trabalho sobre Política Estatística 22 - Relatório sobre a Metodologia de Limitação de Divulgação Estatística de 1994, revisado em 2005 [93]: define diversos métodos de limitação de divulgação estatística, como também as práticas adotadas por 14 agências federais dos EUA à época. Além disso, reconhece a dificuldade inerente à proteção de microdados contra divulgação indevida, uma vez que há sempre a possibilidade de que informações externas a tais dados sejam utilizadas para a reidentificação de indivíduos.	Documento 22 [93]: aplica-se ao NCES como agência federal. Lei de Reforma das Ciências da Educação de 2002 [87]: informações individualmente identificáveis sobre estudantes, suas famílias e escolas, devem permanecer confidenciais. USA PATRIOT Act de 2001 [91]: o Procurador Geral pode ter acesso judicial a informações individualmente identificáveis caso relacionadas a terrorismo. Padrões Estatísticos do Centro Nacional de Estatísticas da Educação de 2012 [94]: todos os microdados de uso público devem ser tratados para limitar a possibilidade de reidentificação auxiliada por informações externas.	Documento 22 [93]: aplica-se ao USCB como agência federal. Código dos EUA, Título 13 [88]: toda informação deve ser utilizada exclusivamente para os propósitos estatísticos para os quais foi coletada, e nenhum indivíduo ou estabelecimento pode ter sua identidade revelada. Padrões de Qualidade Estatística de 2013 [22]: técnicas de prevenção devem ser utilizadas para impedir a liberação de informações protegidas, particularmente aquelas de pessoas ou estabelecimentos.
Formas de divulgação de dados	Microdados: em nível de registros individuais (mas devem ser evitados). Dados agregados de frequência: relacionados a contagens (e.g., número de lojas em uma região). Dados agregados de magnitude: relacionados a grandezas como lucro (e.g., número de lojas e a receita bruta agregada).	O NCES disponibiliza microdados de acesso restrito para agentes autorizados e publica microdados de uso público produzidos a partir dos primeiros, assim como ferramentas de análise <i>on-line</i>, nas quais os microdados são agregados para a produção de estimativas tabulares ou, em alguns casos, para análises de regressão.	Censos 1960–2010: dados agregados de magnitude e frequência, e microdados referentes a uma pequena amostra da população (<i>Public Use Microdata Samples - PUMS</i>), sob diferentes formas de proteção. Censo 2020: agregação tabular usando privacidade diferencial (<i>differential privacy</i>).
Medidas de proteção de privacidade empregadas	Aplicadas a microdados: (i) divulgação por amostras; (ii) remoção de identificadores óbvios; (iii) limitação do detalhamento geográfico; e (iv) limitação de quantidade/detalhamento de valores de variáveis. Medidas adicionais em variáveis de alto risco: (v) <i>top- e bottom-coding</i>; (vi) recodificação em intervalos ou arredondamentos; (vii) adição de ruído; (viii) permutação de valores; (ix) troca de classificação; (x) apagamento e imputação; (xi) <i>blurring</i>; (xii) supressão direcionada. Aplicadas a dados agregados de magnitude e frequência: (i) (n, k)-rule; (ii) <i>p</i>-percent rule; (iii) <i>threshold Rule</i> ($N+$); (iv) truncamento; (v) permutação; (vi) recodificação; (vii) adição de ruído; e (viii) controle de consultas.	Aplicadas a microdados de uso público acessados por ferramentas de análise <i>on-line</i> providas pelo NCES: perturbação via (i) <i>threshold rule</i> ($N+$); (ii) truncamento, (iii) permutação; e (iv) recodificação. Aplicadas a microdados de acesso restrito acessíveis pelas mesmas ferramentas: (v) o tamanho exato da amostra não pode ser divulgado; (vi) as edições de confidencialidade devem ter sido aprovadas pelo DRB (<i>Disclosure Review Board</i>) responsável; (vii) a ferramenta <i>on-line</i> deve divulgar apenas contagens ponderadas.	Aplicadas a microdados dos Censos 1960–2010: (i) truncamento e recodificação; (ii) apagamento e imputação; (iii) permutação; (iv) truncamento de variáveis categóricas; (v) adição de ruído; (vi) uso de dados parcialmente sintéticos. Aplicadas ao Censo 2020: substituição de métodos sintéticos por privacidade diferencial (<i>differential privacy</i>) [51], via o algoritmo <i>TopDown</i> de geração de tabelas [8]. (Entretanto, o novo método enfrenta dificuldades técnicas [58] e de comunicação com a comunidade de estatística [73].) Salas seguras (<i>Research Data Centers - RDC's</i>): salas espalhadas pelo país para acesso a microdados por indivíduos autorizados, de forma controlada.

Tabela 4.2.1: Sumário comparativo dos estudos de caso internacionais efetuados no contexto dos EUA

Estudos de caso internacionais: União Europeia e Austrália		
	Caso 4: Divulgação de dados educacionais por escolas e pelo Ministério da Educação da Holanda - Seção 2.3.2	Caso 5: Escritório Australiano de Estatística (ABS) - Seção 2.4.2
Principais pontos da regulamentação geral relevante	Regulamento UE 2016/679 (General Data Protection Regulation - GDPR) [29]: unifica o quadro regulamentar europeu e provê aos cidadãos e residentes da UE formas de controlar seus dados pessoais, conferindo-lhes os seguintes direitos básicos [99]: (i) de informação; (ii) de acesso; (iii) de retificação; (iv) de apagamento dos dados; (v) à limitação de tratamento; (vi) de portabilidade; (vii) a não ficar sujeito a decisões individuais automatizadas; e (viii) de oposição.	Princípios Australianos de Privacidade, Lei de Privacidade de 1988, revisada em 2015 [81]: garantia do uso de <i>anonimização</i> (i.e., a desassociação dos indivíduos de seus respectivos registros) ou de <i>pseudonimização</i> (i.e., a atribuição de um código individual a cada registro de uma base de dados), além da transparência por parte das entidades governamentais na coleta e no tratamento de informações pessoais, assim como de regras para o uso e a divulgação de dados pessoais.
Principais pontos da regulamentação específica relevante aplicável à agência ou órgão	Lei Algemene Verordening Gegevensbescherming (AVG) de 2018 [4]: implementa a GDPR europeia. Autoridade de Privacidade - AP (Autoriteit Persoonsgegevens) [13]: controla o uso e divulgação de informação escolar por institutos de ensino e pelo Ministério da Educação. Acordo sobre privacidade de 2018 [101]: define que um número único deve ser usado para cada aluno de ensino básico e secundário, servindo como pseudônimo (o que consiste em uma forma de <i>pseudonimização</i>). Além disso, estabelece um padrão de protocolos de Internet, [52] e de como as partes devem trocar as informações entre si [69], incluindo uma implementação de referência [68].	Política de Privacidade do Escritório de Estatística [82, 86]: a ABS nunca publicou, nem publicará, informações identificáveis sobre indivíduos, residências, ou estabelecimentos comerciais.
Formas de divulgação de dados	Dados divulgados por escolas: microdados dos alunos nunca são publicados, em nenhuma forma. Dados divulgados pelo Ministério da educação: microdados dos alunos nunca são publicados, em nenhuma forma; são divulgados, de forma <i>on-line</i> , apenas dados de escolas ou regiões, e dados de alunos apenas em forma agregada.	Dados relativos ao censo: Microdados de apenas amostras da população do censo estão disponíveis. Dados relativos ao censo longitudinal: Base com microdados do censo longitudinal (<i>Australian Census Longitudinal Dataset - ACLD</i>) é criada a partir de amostras aleatórias com correspondência e inclui: (i) 2006–2011 ACLD: amostra de 5% de registros aleatórios, o equivalente a aproximadamente um milhão de registros, do Censo de 2006 com os registros correspondentes do Censo de 2011; e (ii) 2011–2016 ACLD: aproximadamente 1,2 milhão de registros do Censo de 2011 com os registros correspondentes do Censo de 2016.
Medidas de proteção de privacidade empregadas	Microdados referentes a alunos nunca são publicados, em nenhuma forma , nem por escolas nem pelo Ministério da Educação. Medidas tomadas por instituições de ensino: mesmo agentes autorizados só têm acesso aos dados realmente necessários para uma dada tarefa, e mesmo assim de forma temporária, controlada e justificada. Medidas tomadas pelo Ministério da Educação: são divulgados, de forma <i>on-line</i> , apenas dados de escolas ou regiões, e dados de alunos apenas são divulgados em forma agregada (e.g., valores médios).	Até o Censo 2016, o ABS disponibilizou microdados apenas para amostras e sob restrições de acesso [84], incluindo cobrança monetária [85]. Dados do ACLD são acessíveis para usuários registrados no serviço de geração de tabelas e na forma de microdados para usuários aprovados que estejam conduzindo projetos consentidos, com cobrança monetária. As únicas medidas de proteção identificadas são a remoção de identificadores óbvios (desidentificação) e a publicação de dados por amostras .

Tabela 4.2.2: Sumário comparativo dos estudos de caso internacionais efetuados no contexto da União Europeia e Austrália

Estudos de caso nacionais			
	Caso 1: IBGE Seção 3.2	Caso 2: Portal da Transparência do Governo Federal Seção 3.3	Caso dos Censos Educacionais do Inep - Seção 4
Principais pontos da regulamentação geral relevante	Constituição Brasileira de 1988, Art. 5º [37]: direito à privacidade do indivíduo e direito individual e coletivo à transparência por parte do Estado (mas sem definição de como equilibrar tais princípios entre si). Lei 12.527/2011 - Lei de Acesso à Informação (LAI) [47]: o poder público deve garantir o amplo acesso à informação de interesse coletivo ou geral, a qual deve ser disponibilizada via Internet independentemente de requerimento; garante o direito de acesso às demais informações não imediatamente disponibilizadas via Internet; garante o acesso à informação primária, íntegra, autêntica, e atualizada. Lei 13.709/2018 - Lei Geral de Proteção de Dados Pessoais (LGPD) [41]: dados anonimizados não são considerados dados pessoais, exceto quando a anonimização puder ser revertida com esforços razoáveis (i.e., considerando fatores objetivos como o custo e o tempo necessários para reverter a anonimização dadas as tecnologias disponíveis e desconsiderando-se o uso de meios de terceiros).		
Principais pontos da regulamentação específica relevante aplicável à agência ou órgão	Lei 5.534/1968 [43] e Decreto 73.177/1973 [40]: toda pessoa natural ou jurídica, de direito público ou privado, é obrigada a prestar as informações solicitadas pelo IBGE, mas tais informações são protegidas por sigilo e só podem ser usadas para fins estatísticos [34]. Código de Boas Práticas das Estatísticas do IBGE de 2013 [33]: (i) o acesso aos microdados não desidentificados deve seguir protocolos de confidencialidade para usuários externos que têm acesso para análise e pesquisa estatística; (ii) o arquivamento das informações pelo Instituto deve seguir protocolos de segurança e confidencialidade estabelecidos.	Lei Complementar 131/2009 - Lei Capiberibe [46]: devem-se publicar todos os atos praticados pelas unidades gestoras no decorrer da execução de despesa, no momento de sua realização, com a disponibilização mínima dos dados referentes ao número do correspondente processo, ao bem fornecido ou ao serviço prestado, à pessoa física ou jurídica beneficiária do pagamento e, quando for o caso, ao procedimento licitatório realizado.	Lei 9.448/1997 [45] e Decreto 6.317/2007 [38]: estão entre as responsabilidades do Inep sistemas de estatísticas e projetos de avaliação educacionais, assim como a disseminação dessas informações e de demais produtos relacionados. Decreto 6.425/2008 [39]: regulamenta o Censo Anual da Educação; estabelecimentos públicos e privados de Educação Básica e Superior devem fornecer as informações solicitadas pelo Inep, sendo garantido o sigilo dos dados pessoais e vedada sua utilização para outros fins. (Entretanto, o Decreto regulamenta a Lei 9.394/1996 [44], que estabelece à União, e não ao Inep, um mandato para coleta, análise, e disseminação de informações sobre a educação.)
Formas de divulgação de dados	Guia de procedimentos de 2018 [34]: define os procedimentos adotados pelo IBGE. Em Pesquisas Domiciliares por Amostragem Probabilística: são divulgadas tanto informações agregadas em forma de tabelas quanto microdados. Nos Censos Demográficos Decenais: publicam-se dados censitários de forma agregada, além de microdados da parcela de investigação por amostragem.	Os dados disponibilizados incluem microdados (e.g., referentes a fichas de remuneração de servidores públicos e recursos disponibilizados e sacados por beneficiários de programas sociais, como o Bolsa Família, o Benefício de Prestação Continuada, e o Auxílio Emergencial devido à epidemia de COVID-19 implementado em Abril de 2020).	Divulgam-se microdados de Censos, incluindo o da Educação Básica (desde 2008, com dados individuais de alunos, professores, escolas e turmas), o da Educação Superior (desde 2009, com dados individuais de alunos, professores, instituições e cursos), e o ENEM (desde 1998, com dados individuais de participantes, incluindo suas respostas a cada questão do Exame e do Questionário Socioeconômico).
Medidas de proteção de privacidade empregadas	Aplicadas a Pesquisas Domiciliares: identificadores individuais óbvios são removidos de microdados; dados agregados são reportados sem medidas adicionais. Aplicadas aos Censos Demográficos Decenais: IBGE afirma não usar desidentificação, mas no Censo de 2010 setores com menos de cinco domicílios particulares tiveram valores omitidos para muitas variáveis. Sala de Acesso a Dados Restritos (SAR): local onde o público externo tem acesso aos microdados de forma controlada.	Exceto pela omissão parcial do CPF, nenhuma outra técnica de controle de divulgação foi identificada, sendo possível uma fácil e imediata reidentificação direta de todos os indivíduos cujos microdados estão presentes nos registros.	Os microdados são tratados com as técnicas de desidentificação, em que se removem possíveis identificadores individuais óbvios dos registros (como nome, CPF, RG) e de pseudonimização, em que tais identificadores individuais óbvios são substituídos por um código único de identificação artificialmente criado.

Tabela 4.2.3: Sumário comparativo dos estudos de caso efetuados no contexto nacional, incluindo o do Inep em sua divulgação dos Censos Educacionais

5 Considerações finais

Neste relatório apresentamos, através de uma coleção de estudos de caso, um panorama internacional e um nacional relativos a como institutos produtores de estatísticas oficiais equilibram requisitos de transparência e de proteção de privacidade em seus métodos de divulgação de informação. Procedemos, então, a uma contextualização da atual situação da divulgação dos Censos Educacionais por parte do Inep frente a esses casos.

Averiguamos que a extensa coleção de microdados dos Censos Educacionais é divulgada em sua totalidade, sendo a ela aplicadas apenas as técnicas de *desidentificação*, em que se removem possíveis identificadores individuais óbvios dos registros (como nome, CPF, RG) e de *pseudonimização*, em que tais identificadores individuais óbvios são substituídos por um código único de identificação artificialmente criado. A análise preliminar desta forma divulgação de microdados revelou que a mesma está sujeita a vários riscos já apontados na literatura técnica na área de privacidade. Dentre estes riscos, destacamos o de reidentificação de indivíduos via cruzamento com informações auxiliares, e a inferência de seus atributos sensíveis. Em nossa visão, tal situação poderia constituir em uma violação da Lei Geral de Proteção de Dados Pessoais.

Em comparação a todos os casos internacionais estudados, averiguamos que o Inep publica em seus Censos Educacionais a maior quantidade de microdados individuais e em maior nível de detalhes. Além disso, em todos os casos internacionais avaliados, os órgãos produtores de estatísticas oficiais adotam medidas mais rígidas do que as do Inep na mitigação de danos à privacidade causados por publicação de microdados. Dentre estas medidas, podemos destacar as seguintes:

- (i) não publicação de microdados individuais de estudantes sob nenhuma forma (no caso dos institutos de educação e Ministério da Educação na Holanda);
- (ii) publicação de microdados apenas por amostras da população (no caso do Escritório do Censo dos EUA e no do Escritório Australiano de Estatística); ou
- (iii) acesso a todo o conjunto de microdados permitido apenas sob autorização prévia, de acordo com os objetivos do pesquisador ou indivíduo interessado, e em salas seguras (também no caso do Escritório do Censo dos EUA).

É amplamente aceito na literatura técnica que existe um compromisso não trivial entre a transparência na divulgação de informação e a proteção de privacidade dos indivíduos envolvidos. Uma consequência desse compromisso, como reconhecido pelo próprio Escritório do Censo dos EUA, é que medidas de mitigação de danos em geral diminuem –e, por vezes, consideravelmente– a qualidade e a utilidade das informações prestadas de forma aberta à sociedade. Acertar esse equilíbrio é um processo árduo e contínuo.

A discussão apresentada neste documento evidencia que não apenas existem significativos riscos de violação de privacidade decorrentes da atual forma de divulgação dos Censos Educacionais pelo Inep, como também que a escolha dos métodos de controle desses riscos deve ser realizada com prudência. Mais precisamente, deve estudar-se sob a luz de critérios técnicos cuidadosos a situação dos Censos Educacionais do Inep em suas peculiaridades, a fim de selecionarem-se técnicas de mitigação de riscos que permitam um compromisso adequado entre a qualidade da informação divulgada e a proteção à privacidade dos indivíduos. Este é exatamente o objetivo geral do presente projeto.

Referências Bibliográficas

- [1] Aanslag op het Amsterdams bevolkingsregister. In *Wikipedia: de vrije encyclopedie*. Wikimedia, 2020. Disponível em: https://nl.wikipedia.org/wiki/Aanslag_op_het_Amsterdams_bevolkingsregister.
- [2] AOL search data leak. In *Wikipedia: the free encyclopedia*. Wikimedia, 2020. Disponível em: https://en.wikipedia.org/wiki/AOL_search_data_leak.
- [3] Privacidade. In *Wikipédia: a enciclopédia livre*. Wikimedia, 2020. Disponível em: <https://pt.wikipedia.org/wiki/Privacidade>.
- [4] Uitvoeringswet Algemene verordening gegevensbescherming. In *Wikipedia: de vrije encyclopedie*. Wikimedia, 2020. Disponível em: https://nl.wikipedia.org/wiki/Uitvoeringswet_Algemene_verordening_gegevensbescherming.
- [5] Volkstelling. In *Wikipedia: de vrije encyclopedie*. Wikimedia, 2020. Disponível em: <https://nl.wikipedia.org/wiki/Volkstelling>.
- [6] Wet bescherming persoonsgegevens (Nederland). In *Wikipedia: de vrije encyclopedie*. Wikimedia, 2020. Disponível em: [https://nl.wikipedia.org/wiki/Wet_bescherming_persoonsgegevens_\(Nederland\)](https://nl.wikipedia.org/wiki/Wet_bescherming_persoonsgegevens_(Nederland)).
- [7] Wet persoonsregistraties. In *Wikipedia: de vrije encyclopedie*. Wikimedia, 2020. Disponível em: https://nl.wikipedia.org/wiki/Wet_persoonsregistraties.
- [8] John Abowd, Daniel Kifer, Brett Moran, Robert Ashmead, Philip Leclerc, William Sexton, Simson Garfinkel, and Ashwin Machanavajjhala. Census TopDown: Differentially Private Data, Incrementalschemas, and Consistency with Public Knowledge, 2019. Disponível em: <https://columbia.github.io/private-systems-class/papers/Abowd2019Census.pdf>.
- [9] Agência Brasil. Supremo suspende MP do compartilhamento de dados com IBGE. *UOL*, 2020. Disponível em: <https://www.uol.com.br/tilt/noticias/redacao/2020/04/24/supremo-suspende-mp-do-compartilhamento-de-dados-com-ibge.htm>.

- [10] Australian Bureau of Statistics. Privacy Impact Assessment: Proposal to Retain Name and Address Information from Responses to the 2016 Census of Population and Housing, 2015. Disponível em: [https://www.abs.gov.au/websitedbs/D3310114.nsf/4a256353001af3ed4b2562bb00121564/170fd5a4b684aa3eca257f1e0021a392/\\$FILE/ABS%20Privacy%20Impact%20Assessment%202016%20Census.pdf](https://www.abs.gov.au/websitedbs/D3310114.nsf/4a256353001af3ed4b2562bb00121564/170fd5a4b684aa3eca257f1e0021a392/$FILE/ABS%20Privacy%20Impact%20Assessment%202016%20Census.pdf).
- [11] Australian Bureau of Statistics. Retention of names and addresses collected in the 2016 Census of Population and Housing, 2016. Disponível em: <https://www.abs.gov.au/websitedbs/D3310114.nsf/home/Retention+of+names+and+addresses+collected>.
- [12] Australian Privacy Foundation. ABS goes rogue: Orwellian plan to store Census Name and Address for years, 2016. Disponível em: https://privacy.org.au/Campaigns/Census2016/ABS_Census_MR_16.1.pdf.
- [13] Autoriteit Persoonsgegevens. Autoriteit Persoonsgegevens. Disponível em: <https://autoriteitpersoonsgegevens.nl>.
- [14] Autoriteit Persoonsgegevens. Gebruik van persoonsgegevens in het onderwijs. Disponível em: <https://autoriteitpersoonsgegevens.nl/nl/onderwerpen/onderwijs/gebruik-van-persoonsgegevens-het-onderwijs>.
- [15] Autoriteit Persoonsgegevens. Onderzoek naar de toegangsrechten van medewerkers van onderwijsinstellingen van ASKO tot persoonsgegevens van leerlingen in leerlingvolgsysteem X. 2018. Disponível em: https://autoriteitpersoonsgegevens.nl/sites/default/files/atoms/files/01_onderzoeksrapport_asko.pdf.
- [16] BBC. Edward Snowden: Leaks that exposed US spy programme. *BBC*, 2014. Disponível em: <https://www.bbc.com/news/world-us-canada-23123964>.
- [17] BBC. Australian census attacked by hackers. *BBC*, 2016. Disponível em: <https://www.bbc.com/news/world-australia-37008173>.
- [18] Bruno Ricardo Bioni. Xeque-mate: o tripé da proteção de dados pessoais no jogo de xadrez das iniciativas legislativas no brasil. *GPoPAI/USP*, 2016.
- [19] Rodolfo Borges. Do CPF na farmácia às redes: como nova lei protegerá seus dados pessoais. *El País*, 2018. Disponível em: https://brasil.elpais.com/brasil/2018/07/11/politica/1531325313_478217.html.
- [20] Luíza Couto Chaves Brandão. O Marco Civil da Internet e a Proteção de Dados: diálogos com a LGPD. In *Proteção de dados pessoais: privacidade versus avanço tecnológico*. *Cadernos Adenauer XX*, nº3. Fundação Konrad Adenauer, 2019. Disponível em: <https://www.kas.de/documents/265553/265602/Caderno+Adenauer+3+Schutz+von+pers%C3%B6nlichen+Daten.pdf/476709fc-b7dc-8430-12f1-ba21564cde06?version=1.0&t=1571685012573>.

- [21] United States Census Bureau. Disclosure Avoidance for Census 2010 and American Community Survey Five-year Tabular Data Products, 2009. Disponível em: <https://www.census.gov/library/working-papers/2009/adrm/rrs2009-10.html>.
- [22] United States Census Bureau. Statistical Quality Standards, 2013. https://www.census.gov/content/dam/Census/about/about-the-bureau/policies_and_notices/quality/statistical-quality-standards/Quality_Standards.pdf.
- [23] United States Census Bureau. 2010 Demonstration Data Products, 2019. Disponível em: <https://www.census.gov/programs-surveys/decennial-census/2020-census/planning-management/2020-census-data-products/2010-demonstration-data-products.html>.
- [24] United States Census Bureau. Disclosure Avoidance Techniques Used for the 1960 Through 2010 Decennial Censuses of Population and Housing Public Use Microdata Samples, 2019. Disponível em: <https://www.census.gov/library/working-papers/2019/adrm/six-decennial-censuses-da.html>.
- [25] United States Census Bureau. Legacy Techniques and Current Research in Disclosure Avoidance at the U.S. Census Bureau, 2019. Disponível em <https://www.census.gov/library/working-papers/2019/adrm/legacy-da-techniques.html>.
- [26] United States Census Bureau. Status Update on the 2020 Census Data Products Plan, 2019. Disponível em: <https://www2.census.gov/cac/nac/meetings/2019-11/devine-hollingsworth-status-update-2020-data-products-plan.pdf>.
- [27] CEPAL. Código Regional de Buenas Prácticas en Estadísticas para América Latina y el Caribe, 2011. Disponível em: <http://www.ine.gub.uy/buenas-practicas>.
- [28] Conselho da União Europeia. Diretiva 95/46/CE do Parlamento Europeu e do Conselho, de 24 de outubro de 1995, 1995. Disponível em: <https://eur-lex.europa.eu/legal-content/PT/TXT/HTML/?uri=CELEX:31995L0046&from=PT>.
- [29] Conselho da União Europeia. Regulamento (UE) 2016/679 do Parlamento Europeu e do Conselho de 27 de abril de 2016, 2016. Disponível em: <https://eur-lex.europa.eu/legal-content/PT/TXT/HTML/?uri=CELEX:32016R0679>.
- [30] Organização das Nações Unidas. Fundamental Principles of Official Statistics (A/RES/68/261 from 29 January 2014), 2014. Disponível em: <https://unstats.un.org/unsd/dnss/gp/fundprinciples.aspx>.
- [31] Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira. Portaria 370 - Plano de Dados Abertos, 2016. Disponível em: http://download.inep.gov.br/institucional/legislacao/2016/portaria_n370.pdf.

- [32] Instituto Brasileiro de Geografia e Estatística. Princípios Fundamentais das Estatísticas Oficiais. Disponível em https://www.ibge.gov.br/institucional/documentos-ibge.html?option=com_content&view=article&id=16148.
- [33] Instituto Brasileiro de Geografia e Estatística. Código de Boas Práticas das Estatísticas do IBGE, 2013. Disponível em ftp://ftp.ibge.gov.br/Informacoes_Gerais_e_Referencia/Codigo_de_Boas_Praticas_das_Estatisticas_do_IBGE.pdf.
- [34] Instituto Brasileiro de Geografia e Estatística. Confidencialidade no IBGE - procedimentos adotados na preservação do sigilo das informações individuais nas divulgações de resultados das operações estatísticas, 2018. Disponível em: <http://biblioteca.ibge.gov.br/index.php/biblioteca-catalogo?view=detalhes&id=2101636>.
- [35] Dienst Uitvoering Onderwijs. Open data van DUO. Disponível em: <https://duo.nl/open-onderwijsdata/>.
- [36] Irit Dinur and Kobbi Nissim. Revealing information while preserving privacy. In *Proceedings of the twenty-second ACM SIGMOD-SIGACT-SIGART symposium on Principles of database systems*, pages 202–210, 2003.
- [37] Governo do Brasil. Constituição Federal. Texto compilado até a Emenda Constitucional nº 105 de 12/12/2019. Disponível em: https://www.senado.leg.br/atividade/const/con1988/con1988_12.12.2019/ind.asp.
- [38] Governo do Brasil. Decreto 6.317, de 20 de dezembro de 2007. Disponível em: http://www.planalto.gov.br/ccivil_03/_Ato2007-2010/2007/Decreto/D6317.htm.
- [39] Governo do Brasil. Decreto 6.425, de abril de 2008. Disponível em: http://www.planalto.gov.br/ccivil_03/_Ato2007-2010/2008/Decreto/D6425.htm.
- [40] Governo do Brasil. Decreto 73.177, de 20 de novembro de 1973. Disponível em: http://www.planalto.gov.br/ccivil_03/decreto/Antigos/D73177.htm.
- [41] Governo do Brasil. Lei 13.709, de 14 de agosto de 2018, Lei Geral de Proteção de Dados Pessoais (LGPD). Disponível em: http://www.planalto.gov.br/ccivil_03/_ato2015-2018/2018/Lei/L13709.htm.
- [42] Governo do Brasil. Lei 14.010, de 10 de junho de 2020. Disponível em: http://www.planalto.gov.br/ccivil_03/_Ato2019-2022/2020/Lei/L14010.htm.
- [43] Governo do Brasil. Lei 5.534, de 14 de novembro de 1968. Disponível em: http://www.planalto.gov.br/ccivil_03/leis/L5534.htm.
- [44] Governo do Brasil. Lei 9.394, de dezembro de 1996. Disponível em: http://www.planalto.gov.br/ccivil_03/LEIS/L9394.htm.

- [45] Governo do Brasil. Lei 9.448, de 14 de março de 1997. Disponível em: http://www.planalto.gov.br/ccivil_03/LEIS/L9448.htm.
- [46] Governo do Brasil. Lei Complementar 131, de 27 de maio de 2009, Lei Capiberibe. Disponível em: http://www.planalto.gov.br/ccivil_03/LEIS/LCP/Lcp131.htm.
- [47] Governo do Brasil. Lei de Acesso à Informação (LAI). Disponível em: http://www.planalto.gov.br/ccivil_03/_Ato2011-2014/2011/Lei/L12527.htm.
- [48] Governo do Brasil. Portal da Transparência do Governo Federal, Controladoria-Geral da União. Disponível em: <https://www.gov.br/cgu/pt-br/assuntos/transparencia-publica/portal-da-transparencia>.
- [49] Vikram Dodd. Met police to begin using live facial recognition cameras in London. *The Guardian*, 2020. Disponível em: <https://www.theguardian.com/technology/2020/jan/24/met-police-begin-using-live-facial-recognition-cameras>.
- [50] Cynthia Dwork. A firm foundation for private data analysis. *Communications of the ACM*, 54(1):86–95, 2011.
- [51] Cynthia Dwork, Frank McSherry, Kobbi Nissim, and Adam Smith. Calibrating noise to sensitivity in private data analysis. In *Theory of cryptography conference*, pages 265–284. Springer, 2006.
- [52] ECK. Documentatie. Disponível em: <https://www.eck-id.nl/implementatie/documentatie>.
- [53] EUROSTAT. Código de Conduta para as Estatísticas Europeias, 2017. Disponível em: <https://ec.europa.eu/eurostat/documents/4031688/9332182/KS-02-18-142-PT-N.pdf/acea71f5-e1b1-4bcc-b4db-7cb98ea600dd>.
- [54] EUROSTAT. Quality Assurance Framework, 2019. Disponível em: <https://ec.europa.eu/eurostat/documents/64157/4392716/ESS-QAF-V1-2final.pdf/bbf5970c-1adf-46c8-afc3-58ce177a0646>.
- [55] Emily Feng. How China Is Using Facial Recognition Technology. *NPR*, 2019. Disponível em: <https://www.npr.org/2019/12/16/788597818/how-china-is-using-facial-recognition-technology>.
- [56] Simson Garfinkel. *Database Nation: The Death of Privacy in the 21st Century*. O'Reilly & Associates, Inc., USA, 2000.
- [57] Simson Garfinkel, John M Abowd, and Christian Martindale. Understanding database reconstruction attacks on public data. *Queue*, 16(5):28–53, 2018.

- [58] Simson L Garfinkel, John M Abowd, and Sarah Powazek. Issues encountered deploying differential privacy. In *Proceedings of the 2018 Workshop on Privacy in the Electronic Society*, pages 133–137, 2018.
- [59] Governo do Brasil. Lei 12.965, de 23 de abril de 2014, Marco Civil da Internet. Disponível em: http://www.planalto.gov.br/ccivil_03/_ato2011-2014/2014/lei/l12965.htm.
- [60] Governo do Brasil. Lei 9.507, de 12 de novembro de 1997. Disponível em http://www.planalto.gov.br/ccivil_03/LEIS/L9507.htm.
- [61] Governo do Brasil. Medida Provisória 869, de 2018. Proteção de dados pessoais. Disponível em <https://www.congressonacional.leg.br/materias/medidas-provisorias/-/mpv/135062>.
- [62] Governo do Brasil. Medida Provisória 954, de 17 de abril de 2020. Disponível em: http://www.planalto.gov.br/CCIVIL_03/_Ato2019-2022/2020/Mpv/mpv954.htm.
- [63] Governo do Brasil. Medida Provisória 959, de 2020. Regras para o auxílio emergencial e adiamento da vigência da LGPD. Disponível em <https://www.congressonacional.leg.br/materias/medidas-provisorias/-/mpv/141753>.
- [64] Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira. Portaria 91, de 2 de fevereiro de 2017, 2017. Disponível em: http://download.inep.gov.br/educacao_basica/censo_escolar/legislacao/2017/portaria_inep_91_02022017_principios_fundamentais_estatisticas_educacionais.pdf.
- [65] Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira. Portaria 492, de 7 de junho de 2018, 2018.
- [66] Gabriel Joppert. O que diz a lei atual quando o governo deixa vaziar nossos dados pessoais? *UOL*, 2019. Disponível em: <https://www.uol.com.br/tilt/noticias/redacao/2019/10/16/vazamentos-comprometem-dados-de-dezenas-de-milhoes-de-brasileiros.htm>.
- [67] Alexis Katefides, Joel Bates, Nikos Papageorgiou, Rumer Ramsey, Bart van der Geest, Alice Marini, and Pascale Arguinarena. Comparing privacy laws: GDPR v. LGPD, 2019. Disponível em: <https://baptistaluz.com.br/wp-content/uploads/2019/05/DataGuidance-GPDR-LGPD-For-Print.pdf>.
- [68] Kennisnet. Nummervoorziening - Java Client Reference Application, 2018. Disponível em: <https://github.com/kennisnet/Nummervoorziening-JavaReferenceImplementation>.

- [69] Kennisnet, Marc Fleischeuers, and Vincent Tedjakusuma. ECK iD Principes en processen, 2019. Disponível em: https://developers.wiki.kennisnet.nl/images/d/de/Principes_en_processen_ECK_ID.pdf.
- [70] Richie Koch. LGPD: a versão brasileira do regulamento europeu. *Serviço Federal de Processamento de Dados*, 2019. Disponível em: <https://www.serpro.gov.br/lgpd/noticias/lgpd-versao-brasileira-gdpr-dados-pessoais>.
- [71] Ashwin Machanavajjhala, Daniel Kifer, Johannes Gehrke, and Muthuramakrishnan Venkitasubramaniam. L-Diversity: Privacy beyond k-Anonymity. *ACM Transactions on Knowledge Discovery from Data*, 1(1):3–es, March 2007.
- [72] Angela Mari. Data privacy awareness grows in brazil. *ZD-Net*, 2020. Disponível em: <https://www.zdnet.com/article/data-privacy-awareness-grows-in-brazil/>.
- [73] Jeffrey Mervis. Can a set of equations keep U.S. census data private? *Science Magazine*, 2019. Disponível em: <https://www.sciencemag.org/news/2019/01/can-set-equations-keep-us-census-data-private>.
- [74] Eduardo Militão. Falha de cartórios expõe dados de ao menos 1 milhão de pais, mães e filhos. *UOL*, 2019. Disponível em: <https://noticias.uol.com.br/cotidiano/ultimas-noticias/2019/10/29/falha-de-cartorios-expoe-dados-de-ao-menos-1-milhao-de-pais-maes-e-filhos.htm>.
- [75] Ministério das Relações Exteriores do Brasil. O Brasil e a OCDE. Disponível em: <http://www.itamaraty.gov.br/pt-BR/politica-externa/diplomacia-economica-comercial-e-financeira/15584-o-brasil-e-a-ocde>.
- [76] Arvind Narayanan and Vitaly Shmatikov. Robust De-anonymization of Large Sparse Datasets. In *Proc. of S&P*, pages 111–125, 2008.
- [77] Netflix. Netflix Prize. Disponível em: <https://www.netflixprize.com/>.
- [78] Helen Nissenbaum. *Privacy in Context: Technology, Policy, and the Integrity of Social Life*. Stanford University Press, 2009.
- [79] Government of Australia. Australian Bureau of Statistics Act 1975. Disponível em: <https://www.legislation.gov.au/Details/C2017C00096>.
- [80] Government of Australia. Census and Statistics Act 1905. Disponível em: <https://www.legislation.gov.au/Details/C2016C01005>.
- [81] Government of Australia. Privacy Act 1988. Disponível em: <https://www.legislation.gov.au/Details/C2015C00598>.

- [82] Australian Bureau of Statistics. 2016 Census Privacy Policy. Disponível em: <https://www.abs.gov.au/websitedbs/censushome.nsf/home/privacypolicy?opendocument&navpos=110>.
- [83] Australian Bureau of Statistics. Australian Census Longitudinal Dataset. Disponível em: <https://www.abs.gov.au/ausstats/abs@.nsf/Lookup/by%20Subject/2011.0.55.001~2016~Main%20Features~Australian%20Census%20Longitudinal%20Dataset~12>.
- [84] Australian Bureau of Statistics. Census Microdata. Disponível em: <https://www.abs.gov.au/ausstats/abs@.nsf/Lookup/by%20Subject/2011.0.55.001~2016~Main%20Features~Census%20Microdata~13>.
- [85] Australian Bureau of Statistics. Microdata prices. Disponível em: <https://www.abs.gov.au/websitedbs/D3310114.nsf/home/Microdata+prices>.
- [86] Australian Bureau of Statistics. Privacy, Confidentiality & Security. Disponível em: <https://www.abs.gov.au/websitedbs/censushome.nsf/home/privacy?opendocument&navpos=130>.
- [87] Government of the United States of America. Statistical Standards Program - Confidentiality Laws. Disponível em: <https://nces.ed.gov/statprog/conflaws.asp>.
- [88] Government of the United States of America. U.S. Code, Title 13. Disponível em: <https://www.law.cornell.edu/uscode/text/13>.
- [89] Government of the United States of America. U.S. Code, Title 15, Section 552a. Disponível em: <https://www.law.cornell.edu/uscode/text/5/552a>.
- [90] Government of the United States of America. U.S. Code, Title 15, section 552a. Disponível em: <https://www.law.cornell.edu/uscode/text/15>.
- [91] Government of the United States of America. USA PATRIOT Act of 2001, 2001. Disponível em <https://www.fincen.gov/resources/statutes-regulations/usa-patriot-act>.
- [92] Government of the United States of America. Confidential Information Protection and Statistical Efficiency Act (CIPSEA), 2002. Disponível em: <https://www.eia.gov/cipsea/cipsea.pdf>.
- [93] Government of the United States of America. Statistical Policy Working Paper 22 - Report on Statistical Disclosure Limitation Methodology, 2005. Disponível em: <https://nces.ed.gov/FCSM/pdf/spwp22.pdf>.
- [94] Government of the United States of America. 2012 Revision of the National Center for Education Statistics Statistical Standards, 2012. Disponível em: <https://nces.ed.gov/statprog/2012/>.

- [95] Government of the United States of America. Overview of the Privacy Act of 1974, 2015. Disponível em: <https://www.justice.gov/opcl/overview-privacy-act-1974-2015-edition>.
- [96] Organização para a Cooperação e Desenvolvimento Econômico - OCDE. OECD privacy guidelines. Disponível em: <https://www.oecd.org/internet/ieconomy/privacy-guidelines.htm>.
- [97] Organização para a Cooperação e Desenvolvimento Econômico - OCDE. Growing Up Online: Addressing the Needs of Children in the Digital Environment, 2020. Disponível em: <https://www.oecd.org/going-digital/growing-up-online.pdf>.
- [98] Daniel Palmer. ABS to permanently store personal data from Australian census. *Delimiter*, 2016. Disponível em: <https://delimiter.com.au/2016/02/01/abs-permanently-store-personal-data-australian-census/>.
- [99] Filipe Pontes. RGPD e os seus direitos. *Visão*, 2018. Disponível em: <https://visao.sapo.pt/opiniao/ponto-de-vista/silencio-da-fraude/2018-05-30-rgpd-e-os-seus-direitos/>.
- [100] Fabian Prasser, Florian Kohlmayer, Ronald Lautenschlaeger, and Klaus A Kuhn. Arx-a comprehensive tool for anonymizing biomedical data. In *AMIA Annual Symposium Proceedings*, volume 2014, page 984. American Medical Informatics Association, 2014.
- [101] Privacyconvenant Onderwijs. Privacyconvenant Onderwijs. Disponível em: <https://www.privacyconvenant.nl/>.
- [102] MJ Queiroz and GHMB Motta. Privacidade e Transparência no Setor público: Um Estudo de Caso da Publicação de Microdados do INEP. In *XV Simposio Brasileiro em Seguranca da Informacao e de Sistemas Computacionais-SBSeg*, 2015.
- [103] Clarie Reilly. The census wasn't hacked, but australia still has a problem. *CNET*, 2016. Disponível em: <https://www.cnet.com/news/the-census-wasnt-hacked-but-the-abs-still-has-a-problem/>.
- [104] Elettra Ronchi and Lisa Robinson. Child protection online. In *Educating 21st Century Children: Emotional Well-being in the Digital Age*. Organização para a Cooperação e Desenvolvimento Econômico - OCDE, 2019. Disponível em: <https://www.oecd-ilibrary.org/sites/796ac574-en/index.html?itemId=/content/component/796ac574-en&mimeType=text/>.
- [105] Pierangela Samarati and Latanya Sweeney. Protecting privacy when disclosing information: k-anonymity and its enforcement through generalization and suppression, 1998.

- [106] Search-ID. AOL user #4417749: Thelma Arnold. Disponível em: http://explicit-id.com/user/4417749-thelma_arnold.
- [107] Paula Soprana. Governo vai usar dados de operadoras para monitorar aglomeração na pandemia. *Folha de S.Paulo*, 2020. Disponível em: <https://www1.folha.uol.com.br/mercado/2020/04/governo-vai-usar-dados-de-operadoras-para-monitorar-deslocamentos-na-pandemia.shtml>.
- [108] Alice Stollmeyer, Marietje Schaake, and Frank Dignum. The Dutch tracing app ‘soap opera’ - lessons for Europe. *EUobserver*, 2020. Disponível em: <https://euobserver.com/opinion/148265>.
- [109] Latanya Sweeney. Simple Demographics Often Identify People Uniquely, 2000. Disponível em: https://kylthub.cmu.edu/articles/Simple_Demographics_Often_Identify_People_Uniquely/6625769/1.

Anexos

A Constituição da República Federativa do Brasil: Principais trechos relacionados ao escopo deste projeto

A seguir apresentamos uma seleção dos trechos da Constituição da República Federativa do Brasil [37] identificados como os mais relevantes no escopo do presente TED 8750.

Art. 5º Todos são iguais perante a lei, sem distinção de qualquer natureza, garantindo-se aos brasileiros e aos estrangeiros residentes no País a inviolabilidade do direito à vida, à liberdade, à igualdade, à segurança e à propriedade, nos termos seguintes:

- X são invioláveis a intimidade, a vida privada, a honra e a imagem das pessoas, assegurado o direito a indenização pelo dano material ou moral decorrente de sua violação;
- XIV é assegurado a todos o acesso à informação e resguardado o sigilo da fonte, quando necessário ao exercício profissional;
- XXXIII todos têm direito a receber dos órgãos públicos informações de seu interesse particular, ou de interesse coletivo ou geral, que serão prestadas no prazo da lei, sob pena de responsabilidade, ressalvadas aquelas cujo sigilo seja imprescindível à segurança da sociedade e do Estado;
- LXXII conceder-se-á *habeas data*:
 - a) para assegurar o conhecimento de informações relativas à pessoa do impetrante, constantes de registros ou bancos de dados de entidades governamentais ou de caráter público;
 - b) para a retificação de dados, quando não se prefira fazê-lo por processo sigiloso, judicial ou administrativo;
- LXXVII são gratuitas as ações de *habeas corpus* e *habeas data*, e, na forma da lei, os atos necessários ao exercício da cidadania.

Art. 60. A Constituição poderá ser emendada mediante proposta:

§ 4º Não será objeto de deliberação a proposta de emenda tendente a abolir:

IV os direitos e garantias individuais.

B LAI: Principais trechos relacionados ao escopo deste projeto

A seguir apresentamos uma seleção dos trechos da Lei 12.527/2011, conhecida como *Lei de Acesso à Informação* (LAI) [47], identificados como os mais relevantes no escopo do presente TED 8750.

Art. 1º Esta Lei dispõe sobre os procedimentos a serem observados pela União, Estados, Distrito Federal e Municípios, com o fim de garantir o acesso a informações previsto no inciso XXXIII do art. 5º, no inciso II do § 3º do art. 37 § 2º do art. 216 da Constituição Federal [37].

Parágrafo único. Subordinam-se ao regime desta Lei:

- I os órgãos públicos integrantes da administração direta dos Poderes Executivo, Legislativo, incluindo as Cortes de Contas, e Judiciário e do Ministério Público;
- II as autarquias, as fundações públicas, as empresas públicas, as sociedades de economia mista e demais entidades controladas direta ou indiretamente pela União, Estados, Distrito Federal e Municípios.

Art. 3º Os procedimentos previstos nesta Lei destinam-se a assegurar o direito fundamental de acesso à informação e devem ser executados em conformidade com os princípios básicos da administração pública e com as seguintes diretrizes:

- I observância da publicidade como preceito geral e do sigilo como exceção;
- II divulgação de informações de interesse público, independentemente de solicitações;
- III utilização de meios de comunicação viabilizados pela tecnologia da informação;
- IV fomento ao desenvolvimento da cultura de transparência na administração pública;

V desenvolvimento do controle social da administração pública.

Art. 4º Para os efeitos desta Lei, considera-se:

- I informação: dados, processados ou não, que podem ser utilizados para produção e transmissão de conhecimento, contidos em qualquer meio, suporte ou formato;
- II documento: unidade de registro de informações, qualquer que seja o suporte ou formato;
- III informação sigilosa: aquela submetida temporariamente à restrição de acesso público em razão de sua imprescindibilidade para a segurança da sociedade e do Estado;
- IV informação pessoal: aquela relacionada à pessoa natural identificada ou identificável;
- V tratamento da informação: conjunto de ações referentes à produção, recepção, classificação, utilização, acesso, reprodução, transporte, transmissão, distribuição, arquivamento, armazenamento, eliminação, avaliação, destinação ou controle da informação;
- VI disponibilidade: qualidade da informação que pode ser conhecida e utilizada por indivíduos, equipamentos ou sistemas autorizados;
- VII autenticidade: qualidade da informação que tenha sido produzida, expedida, recebida ou modificada por determinado indivíduo, equipamento ou sistema;
- VIII integridade: qualidade da informação não modificada, inclusive quanto à origem, trânsito e destino;
- IX primariedade: qualidade da informação coletada na fonte, com o máximo de detalhamento possível, sem modificações.

Art. 6º Cabe aos órgãos e entidades do poder público, observadas as normas e procedimentos específicos aplicáveis, assegurar a:

- I gestão transparente da informação, propiciando amplo acesso a ela e sua divulgação;
- II proteção da informação, garantindo-se sua disponibilidade, autenticidade e integridade; e
- III proteção da informação sigilosa e da informação pessoal, observada a sua disponibilidade, autenticidade, integridade e eventual restrição de acesso.

Art. 7º O acesso à informação de que trata esta Lei compreende, entre outros, os direitos de obter:

- I orientação sobre os procedimentos para a consecução de acesso, bem como sobre o local onde poderá ser encontrada ou obtida a informação almejada;
- II informação contida em registros ou documentos, produzidos ou acumulados por seus órgãos ou entidades, recolhidos ou não a arquivos públicos;
- III informação produzida ou custodiada por pessoa física ou entidade privada decorrente de qualquer vínculo com seus órgãos ou entidades, mesmo que esse vínculo já tenha cessado;
- IV informação primária, íntegra, autêntica e atualizada;

§ 1º O acesso à informação previsto no caput não compreende as informações referentes a projetos de pesquisa e desenvolvimento científicos ou tecnológicos cujo sigilo seja imprescindível à segurança da sociedade e do Estado.

§ 2º Quando não for autorizado acesso integral à informação por ser ela parcialmente sigilosa, é assegurado o acesso à parte não sigilosa por meio de certidão, extrato ou cópia com ocultação da parte sob sigilo.

Art. 8º É dever dos órgãos e entidades públicas promover, independentemente de requerimentos, a divulgação em local de fácil acesso, no âmbito de suas competências, de informações de interesse coletivo ou geral por eles produzidas ou custodiadas.

§ 2º Para cumprimento do disposto no **caput**, os órgãos e entidades públicas deverão utilizar todos os meios e instrumentos legítimos de que dispuserem, sendo obrigatória a divulgação em sítios oficiais da rede mundial de computadores (Internet).

§ 3º Os sítios de que trata o § 2º deverão, na forma de regulamento, atender, entre outros, aos seguintes requisitos:

- I conter ferramenta de pesquisa de conteúdo que permita o acesso à informação de forma objetiva, transparente, clara e em linguagem de fácil compreensão;
- II possibilitar a gravação de relatórios em diversos formatos eletrônicos, inclusive abertos e não proprietários, tais como planilhas e texto, de modo a facilitar a análise das informações;
- III possibilitar o acesso automatizado por sistemas externos em formatos abertos, estruturados e legíveis por máquina;
- IV divulgar em detalhes os formatos utilizados para estruturação da informação;
- V garantir a autenticidade e a integridade das informações disponíveis para acesso;
- VI manter atualizadas as informações disponíveis para acesso;

Art. 22. O disposto nesta Lei não exclui as demais hipóteses legais de sigilo e de segredo de justiça nem as hipóteses de segredo industrial decorrentes da exploração direta de atividade econômica pelo Estado ou por pessoa física ou entidade privada que tenha qualquer vínculo com o poder público.

Art. 31. O tratamento das informações pessoais deve ser feito de forma transparente e com respeito à intimidade, vida privada, honra e imagem das pessoas, bem como às liberdades e garantias individuais.

§ 1º As informações pessoais, a que se refere este artigo, relativas à intimidade, vida privada, honra e imagem:

- I terão seu acesso restrito, independentemente de classificação de sigilo e pelo prazo máximo de 100 (cem) anos a contar da sua data de produção, a agentes públicos legalmente autorizados e à pessoa a que elas se referirem; e
- II poderão ter autorizada sua divulgação ou acesso por terceiros diante de previsão legal ou consentimento expresso da pessoa a que elas se referirem.

§ 2º Aquele que obtiver acesso às informações de que trata este artigo será responsabilizado por seu uso indevido.

§ 3º O consentimento referido no inciso II do § 1º não será exigido quando as informações forem necessárias:

- II à realização de estatísticas e pesquisas científicas de evidente interesse público ou geral, previstos em lei, sendo vedada a identificação da pessoa a que as informações se referirem;
- V à proteção do interesse público e geral preponderante.

§ 5º Regulamento disporá sobre os procedimentos para tratamento de informação pessoal.

Art. 32. Constituem condutas ilícitas que ensejam responsabilidade do agente público ou militar:

- I recusar-se a fornecer informação requerida nos termos desta Lei, retardar deliberadamente o seu fornecimento ou fornecê-la intencionalmente de forma incorreta, incompleta ou imprecisa;
- II utilizar indevidamente, bem como subtrair, destruir, inutilizar, desfigurar, alterar ou ocultar, total ou parcialmente, informação que se encontre sob sua guarda ou a que tenha acesso ou conhecimento em razão do exercício das atribuições de cargo, emprego ou função pública;
- IV divulgar ou permitir a divulgação ou acessar ou permitir acesso indevido à informação sigilosa ou informação pessoal;

Art. 38. Aplica-se, no que couber, a Lei nº 9.507, de 12 de novembro de 1997 [60], em relação à informação de pessoa, física ou jurídica, constante de registro ou banco de dados de entidades governamentais ou de caráter público.

C LGPD: Principais trechos relacionados ao escopo deste projeto

A seguir apresentamos uma seleção dos trechos da Lei 13.709/2018, conhecida como *Lei Geral de Proteção de Dados Pessoais* (LGPD ou LGPD) [41], identificados como os mais relevantes no escopo do presente TED 8750.

Art. 1º Esta Lei dispõe sobre o tratamento de dados pessoais, inclusive nos meios digitais, por pessoa natural ou por pessoa jurídica de direito público ou privado, com o objetivo de proteger os direitos fundamentais de liberdade e de privacidade e o livre desenvolvimento da personalidade da pessoa natural.

Parágrafo único. As normas gerais contidas nesta Lei são de interesse nacional e devem ser observadas pela União, Estados, Distrito Federal e Municípios.

Art. 2º A disciplina da proteção de dados pessoais tem como fundamentos:

- I o respeito à privacidade;
- II a autodeterminação informativa;
- III a liberdade de expressão, de informação, de comunicação e de opinião;
- IV a inviolabilidade da intimidade, da honra e da imagem;

Art. 3º Esta Lei aplica-se a qualquer operação de tratamento realizada por pessoa natural ou por pessoa jurídica de direito público ou privado, independentemente do meio, do país de sua sede ou do país onde estejam localizados os dados, desde que:

- I a operação de tratamento seja realizada no território nacional;
- II a atividade de tratamento tenha por objetivo a oferta ou o fornecimento de bens ou serviços ou o tratamento de dados de indivíduos localizados no território nacional; ou
- III os dados pessoais objeto do tratamento tenham sido coletados no território nacional.

§ 1º Consideram-se coletados no território nacional os dados pessoais cujo titular nele se encontre no momento da coleta.

Art. 5º Para os fins desta Lei, considera-se:

- I dado pessoal: informação relacionada a pessoa natural identificada ou identificável;
- II dado pessoal sensível: dado pessoal sobre origem racial ou étnica, convicção religiosa, opinião política, filiação a sindicato ou a organização de caráter religioso, filosófico ou político, dado referente à saúde ou à vida sexual, dado genético ou biométrico, quando vinculado a uma pessoa natural;
- III dado anonimizado: dado relativo a titular que não possa ser identificado, considerando a utilização de meios técnicos razoáveis e disponíveis na ocasião de seu tratamento;
- IV banco de dados: conjunto estruturado de dados pessoais, estabelecido em um ou em vários locais, em suporte eletrônico ou físico;
- V titular: pessoa natural a quem se referem os dados pessoais que são objeto de tratamento;
- VI controlador: pessoa natural ou jurídica, de direito público ou privado, a quem competem as decisões referentes ao tratamento de dados pessoais;
- VII operador: pessoa natural ou jurídica, de direito público ou privado, que realiza o tratamento de dados pessoais em nome do controlador;
- IX agentes de tratamento: o controlador e o operador;
- X tratamento: toda operação realizada com dados pessoais, como as que se referem a coleta, produção, recepção, classificação, utilização, acesso, reprodução, transmissão, distribuição, processamento, arquivamento, armazenamento, eliminação, avaliação ou controle da informação, modificação, comunicação, transferência, difusão ou extração;
- XI anonimização: utilização de meios técnicos razoáveis e disponíveis no momento do tratamento, por meio dos quais um dado perde a possibilidade de associação, direta ou indireta, a um indivíduo;
- XVII relatório de impacto à proteção de dados pessoais: documentação do controlador que contém a descrição dos processos de tratamento de dados pessoais que podem gerar riscos às liberdades civis e aos direitos fundamentais, bem como medidas, salvaguardas e mecanismos de mitigação de risco;
- XVIII órgão de pesquisa: órgão ou entidade da administração pública direta ou indireta ou pessoa jurídica de direito privado sem fins lucrativos legalmente constituída sob as leis brasileiras, com sede e foro no País, que inclua em sua missão institucional ou em seu objetivo social ou estatutário a pesquisa básica ou aplicada de caráter histórico, científico, tecnológico ou estatístico; e

XIX autoridade nacional: órgão da administração pública responsável por zelar, implementar e fiscalizar o cumprimento desta Lei em todo o território nacional.

Art. 6º As atividades de tratamento de dados pessoais deverão observar a boa-fé e os seguintes princípios:

- I finalidade: realização do tratamento para propósitos legítimos, específicos, explícitos e informados ao titular, sem possibilidade de tratamento posterior de forma incompatível com essas finalidades;
- II adequação: compatibilidade do tratamento com as finalidades informadas ao titular, de acordo com o contexto do tratamento;
- III necessidade: limitação do tratamento ao mínimo necessário para a realização de suas finalidades, com abrangência dos dados pertinentes, proporcionais e não excessivos em relação às finalidades do tratamento de dados;
- IV livre acesso: garantia, aos titulares, de consulta facilitada e gratuita sobre a forma e a duração do tratamento, bem como sobre a integralidade de seus dados pessoais;
- V qualidade dos dados: garantia, aos titulares, de exatidão, clareza, relevância e atualização dos dados, de acordo com a necessidade e para o cumprimento da finalidade de seu tratamento;
- VI transparência: garantia, aos titulares, de informações claras, precisas e facilmente acessíveis sobre a realização do tratamento e os respectivos agentes de tratamento, observados os segredos comercial e industrial;
- VII segurança: utilização de medidas técnicas e administrativas aptas a proteger os dados pessoais de acessos não autorizados e de situações acidentais ou ilícitas de destruição, perda, alteração, comunicação ou difusão;
- VIII prevenção: adoção de medidas para prevenir a ocorrência de danos em virtude do tratamento de dados pessoais;
- IX não discriminação: impossibilidade de realização do tratamento para fins discriminatórios ilícitos ou abusivos;
- X responsabilização e prestação de contas: demonstração, pelo agente, da adoção de medidas eficazes e capazes de comprovar a observância e o cumprimento das normas de proteção de dados pessoais e, inclusive, da eficácia dessas medidas.

Art. 7º O tratamento de dados pessoais somente poderá ser realizado nas seguintes hipóteses:

- I mediante o fornecimento de consentimento pelo titular;
- II para o cumprimento de obrigação legal ou regulatória pelo controlador;

- III pela administração pública, para o tratamento e uso compartilhado de dados necessários à execução de políticas públicas previstas em leis e regulamentos ou respaldadas em contratos, convênios ou instrumentos congêneres, observadas as disposições do Capítulo IV desta Lei;
- IV para a realização de estudos por órgão de pesquisa, garantida, sempre que possível, a anonimização dos dados pessoais;
- IX quando necessário para atender aos interesses legítimos do controlador ou de terceiro, exceto no caso de prevalecerem direitos e liberdades fundamentais do titular que exijam a proteção dos dados pessoais;

§ 3º O tratamento de dados pessoais cujo acesso é público deve considerar a finalidade, a boa-fé e o interesse público que justificaram sua disponibilização.

Art. 11. O tratamento de dados pessoais sensíveis somente poderá ocorrer nas seguintes hipóteses:

- I quando o titular ou seu responsável legal consentir, de forma específica e destacada, para finalidades específicas;
- II sem fornecimento de consentimento do titular, nas hipóteses em que for indispensável para:
 - a) cumprimento de obrigação legal ou regulatória pelo controlador;
 - b) tratamento compartilhado de dados necessários à execução, pela administração pública, de políticas públicas previstas em leis ou regulamentos;
 - c) realização de estudos por órgão de pesquisa, garantida, sempre que possível, a anonimização dos dados pessoais sensíveis;

§ 1º Aplica-se o disposto neste artigo a qualquer tratamento de dados pessoais que revele dados pessoais sensíveis e que possa causar dano ao titular, ressalvado o disposto em legislação específica.

§ 2º Nos casos de aplicação do disposto nas alíneas “a” e “b” do inciso II do caput deste artigo pelos órgãos e pelas entidades públicas, será dada publicidade à referida dispensa de consentimento, nos termos do inciso I do caput do art. 23 desta Lei.

Art. 12. Os dados anonimizados não serão considerados dados pessoais para os fins desta Lei, salvo quando o processo de anonimização ao qual foram submetidos for revertido, utilizando exclusivamente meios próprios, ou quando, com esforços razoáveis, puder ser revertido.

§ 1º A determinação do que seja razoável deve levar em consideração fatores objetivos, tais como custo e tempo necessários para reverter o processo de anonimização, de acordo com as tecnologias disponíveis, e a utilização exclusiva de meios próprios.

§ 2º Poderão ser igualmente considerados como dados pessoais, para os fins desta Lei, aqueles utilizados para formação do perfil comportamental de determinada pessoa natural, se identificada.

§ 3º A autoridade nacional poderá dispor sobre padrões e técnicas utilizados em processos de anonimização e realizar verificações acerca de sua segurança, ouvido o Conselho Nacional de Proteção de Dados Pessoais.

Art. 13. Na realização de estudos em saúde pública, os órgãos de pesquisa poderão ter acesso a bases de dados pessoais, que serão tratados exclusivamente dentro do órgão e estritamente para a finalidade de realização de estudos e pesquisas e mantidos em ambiente controlado e seguro, conforme práticas de segurança previstas em regulamento específico e que incluam, sempre que possível, a anonimização ou pseudonimização dos dados, bem como considerem os devidos padrões éticos relacionados a estudos e pesquisas.

§ 4º Para os efeitos deste artigo, a pseudonimização é o tratamento por meio do qual um dado perde a possibilidade de associação, direta ou indireta, a um indivíduo, senão pelo uso de informação adicional mantida separadamente pelo controlador em ambiente controlado e seguro.

Art. 14. O tratamento de dados pessoais de crianças e de adolescentes deverá ser realizado em seu melhor interesse, nos termos deste artigo e da legislação pertinente.

§ 1º O tratamento de dados pessoais de crianças deverá ser realizado com o consentimento específico e em destaque dado por pelo menos um dos pais ou pelo responsável legal.

§ 2º No tratamento de dados de que trata o § 1º deste artigo, os controladores deverão manter pública a informação sobre os tipos de dados coletados, a forma de sua utilização e os procedimentos para o exercício dos direitos a que se refere o art. 18 desta Lei.

§ 3º Poderão ser coletados dados pessoais de crianças sem o consentimento a que se refere o § 1º deste artigo quando a coleta for necessária para contatar os pais ou o responsável legal, utilizados uma única vez e sem armazenamento, ou para sua proteção, e em nenhum caso poderão ser repassados a terceiro sem o consentimento de que trata o § 1º deste artigo.

§ 4º Os controladores não deverão condicionar a participação dos titulares de que trata o § 1º deste artigo em jogos, aplicações de Internet ou outras atividades ao fornecimento de informações pessoais além das estritamente necessárias à atividade.

§ 5º O controlador deve realizar todos os esforços razoáveis para verificar que o consentimento a que se refere o § 1º deste artigo foi dado pelo responsável pela criança, consideradas as tecnologias disponíveis.

§ 6º As informações sobre o tratamento de dados referidas neste artigo deverão ser fornecidas de maneira simples, clara e acessível, consideradas as

características físico-motoras, perceptivas, sensoriais, intelectuais e mentais do usuário, com uso de recursos audiovisuais quando adequado, de forma a proporcionar a informação necessária aos pais ou ao responsável legal e adequada ao entendimento da criança.

Art. 16. Os dados pessoais serão eliminados após o término de seu tratamento, no âmbito e nos limites técnicos das atividades, autorizada a conservação para as seguintes finalidades:

- I cumprimento de obrigação legal ou regulatória pelo controlador;
- II estudo por órgão de pesquisa, garantida, sempre que possível, a anonimização dos dados pessoais;
- III transferência a terceiro, desde que respeitados os requisitos de tratamento de dados dispostos nesta Lei; ou
- IV uso exclusivo do controlador, vedado seu acesso por terceiro, e desde que anonimizados os dados.

Art. 17. Toda pessoa natural tem assegurada a titularidade de seus dados pessoais e garantidos os direitos fundamentais de liberdade, de intimidade e de privacidade, nos termos desta Lei.

D Principais diferenças entre a LGPD brasileira e a GDPR europeia

A Lei Geral de Proteção de Dados Pessoais (LGPD) brasileira (discutida na Seção 3.1) foi fortemente inspirada pelo seu equivalente europeu, o Regulamento Geral de Proteção de Dados (RGPD ou GDPR) (discutido na Seção 2.3.1), com o qual compartilha filosofia e abrangência similares. De fato, pode-se constatar que a legislação brasileira relativa à privacidade se aproxima mais da europeia, que por sua vez é muito diferente da legislação dos EUA (discutida na Seção 2.2.1). Entretanto, há significativas diferenças entre a LGPD e o GDPR.

Uma comparação rica em detalhes, possivelmente do interesse de profissionais da área jurídica, pode ser encontrada no relatório criado em conjunto pela equipe do *DataGuidance by OneTrust* e do escritório Baptista Luz Advogados [67].

A seguir citamos o paralelo abaixo oferecido por Richie Koch, editor-chefe do portal GDPR.EU, ¹ retirado de seu artigo sobre o assunto [70].

Diferenças entre a LGPD e o GDPR Apesar de seus objetivos similares e a aparente influência do GDPR sobre os legisladores brasileiros, existem algumas diferenças marcantes a serem notadas entre as duas legislações.

Encarregados de proteção de dados Ambos os textos legais demandam que os negócios e as organizações contratem um encarregado de proteção de dados. No entanto, enquanto a GDPR define quando um encarregado é necessário, o artigo 41 da LGPD diz, simplesmente: “O controlador deverá indicar encarregado pelo tratamento de dados pessoais”, o que sugere que qualquer organização que processa dados de pessoas no Brasil terá de contratar alguém para tal posto. Esta é outra área que provavelmente receberá maior clarificação, mas da forma como está escrito, é uma das áreas onde a LGPD é mais rígida que a GDPR.

¹<https://gdpr.eu/>

Base legal para processamento de dados Possivelmente a mais significativa diferença entre a LGPD e o GDPR recai sobre o que se qualifica como base legal para processar dados. O GDPR tem seis bases legais para o processamento, e um controlador de dados deve escolher uma delas como justificativa para utilizar a informação de um titular de dados. No entanto, no seu artigo 7º, a LGPD lista dez. São eles:

- Mediante o fornecimento de consentimento pelo titular;
- Para o cumprimento de obrigação legal ou regulatória pelo controlador;
- Pela administração pública, para o tratamento e uso compartilhado de dados necessários à execução de políticas públicas previstas em leis e regulamentos ou respaldadas em contratos, convênios ou instrumentos congêneres, observadas as disposições do capítulo IV da Lei;
- Para a realização de estudos por órgão de pesquisa, garantida, sempre que possível, a anonimização dos dados pessoais;
- Quando necessário para a execução de contrato ou de procedimentos preliminares relacionados a contrato do qual seja parte o titular, a pedido do titular dos dados;
- Para o exercício regular de direitos em processo judicial, administrativo ou arbitral, esse último nos termos da Lei nº 9.307, de 23 de setembro de 1996 (*Lei de Arbitragem*);
- Para a proteção da vida ou da incolumidade física do titular ou de terceiro;
- Para a tutela da saúde, exclusivamente, em procedimento realizado por profissionais de saúde, serviços de saúde ou autoridade sanitária;
- Quando necessário para atender aos interesses legítimos do controlador ou de terceiro, exceto no caso de prevalecerem direitos e liberdades fundamentais do titular que exijam a proteção dos dados pessoais;
- Para a proteção do crédito, inclusive quanto ao disposto na legislação pertinente.

Ter a proteção do crédito como base legal para o processamento de dados é de fato uma diferença substancial em relação ao GDPR.

Avisos sobre quebra de sigilo de dados Embora tanto o GDPR quanto a LGPD requeiram que as organizações avisem sobre quebra de sigilo de dados à autoridade nacional de proteção de dados, o nível de especificidade varia amplamente entre as duas leis. O GDPR é explícito: uma organização deve avisar sobre qualquer quebra de sigilo em até 72 horas a partir de sua descoberta (embora diferentes organizações já estejam testando este limite).

A LGPD não oferece nenhum limite definido: o artigo 48 simplesmente diz que “O controlador deverá comunicar à autoridade nacional e ao titular a ocorrência de incidente de segurança que possa acarretar risco ou dano relevante aos titulares [...] em prazo razoável, conforme definido pela autoridade nacional”. Uma vez que a agência nacional de proteção de dados não foi, até o momento, estabelecida, não há indicação sobre o que constitui “prazo razoável”.

Multas Uma lei é tão forte quanto seus “dentes”. É por isso que as multas máximas do GDPR são substanciais, obrigando organizações que cometem violações graves da legislação europeia a pagarem até 20 milhões de euros, ou 4% de sua receita global anual, o que for maior.

As multas da LGPD são muito menos severas. O artigo 52 define que a multa máxima para uma violação é “de até 2% (dois por cento) do faturamento da pessoa jurídica de direito privado, grupo ou conglomerado no Brasil no seu último exercício, excluídos os tributos, limitada, no total, a R\$ 50 milhões de reais por infração”, ou cerca de 11 milhões de euros. As multas da LGPD estão em linha com as multas da GDPR para infrações menores, mas 11 milhões de euros não vão preocupar os maiores processadores de dados do mundo.

E Um panorama da percepção da questão de privacidade pela sociedade brasileira

Desde a aprovação da Lei Geral de Proteção de Dados Pessoais (LGPD ou LGPD) pelo Senado Federal em 2018, a mídia brasileira vem cobrindo com atenção crescente temas relacionados à privacidade, especialmente quando se trata de dados coletados pelo Estado. Ainda em 2018, em comentário feito à edição brasileira do jornal El País [19], Flávia Lefèvre, conselheira da ONG Proteste, destacou o papel dos poderes públicos frente à proteção de dados pessoais. De acordo com Lefèvre, órgãos públicos são responsáveis pela coleta de muito mais dados do que empresas privadas, uma vez que processam, por exemplo, dados referentes a programas sociais, a declarações de imposto de renda, e a programas de saúde. Por esse motivo, a coleta e o tratamento de dados pelo Estado foram explicitamente incluídos na redação da LGPD.

Já em 2019, a questão da privacidade voltou a ser tratada pela imprensa com o vazamento de dados de aproximadamente 70 milhões de pessoas pelo Detran do Rio Grande do Norte, e com a descoberta de uma base de dados com informações sobre 92 milhões de brasileiros à venda na Internet. Dentre as análises jurídicas publicadas em reportagem do UOL [66], vale destacar aquela do advogado Diego Borba, consultor de segurança digital da Nielsen. De acordo com Borba, caso a LGPD já estivesse em vigor à época, a aplicação das penalizações previstas dependeria, por exemplo, dos métodos de prevenção adotados pelos órgãos, assim como das políticas e dos protocolos de segurança em caso de incidentes.

Outro incidente ocorrido em 2019 foi a exposição de informações de ao menos um milhão de brasileiros devido a uma falha de segurança que expôs milhares de arquivos de cartórios de São Paulo à Internet. Apesar de tratar-se de informações públicas, o acesso às mesmas deve ser controlado e regras e restrições aplicadas caso a caso, conforme declaração do tabelião e ex-delegado da Polícia Federal, Sandro Ferreira, ao UOL [74].

Já em 2020, com a chegada da pandemia de COVID-19 ao Brasil, foi anunciado pelo Ministério de Ciência e Tecnologia um acordo com grandes operadoras de telefonia móvel com o objetivo de monitorar aglomerações. Apesar de a LGPD ainda não estar em

vigor, as operadoras anunciaram que a plataforma criada para a colaboração respeita as normas da Lei, além daquelas estabelecidas pelo Marco Civil da Internet [59]. Para tanto, os dados fornecidos ao governo seriam organizados de forma agregada, estatística, e anônima. Entretanto, conforme apontado por Bruno Bioni, fundador do Data Privacy Brasil em comentário ao jornal Folha de São Paulo [107], é necessário que as medidas adotadas sejam divulgadas para que o cidadão e outros agentes possam proceder ao escrutínio público.

Outra iniciativa do governo federal frente à pandemia de COVID-19 foi estipulada pela Medida Provisória 954 [62], de abril de 2020, que permitiu o compartilhamento de informações cadastrais de usuários de linhas telefônicas com o IBGE. Entretanto, a Medida Provisória foi suspensa pelo Supremo Tribunal Federal por desrespeitar o direito à intimidade e ao sigilo da vida privada dos usuários [9], uma vez que os microdados seriam compartilhados sem qualquer tratamento prévio.

Finalmente, uma pesquisa realizada pela empresa de segurança Kaspersky e reportada pelo site de notícias ZDNet [72] aponta que 74% dos brasileiros entrevistados já tentaram remover informações pessoais de páginas na Internet ou redes sociais. Além disso, 58% tentam esconder informações pessoais ao navegarem pela Internet de modo a se protegerem de criminosos, enquanto 26% se dizem muito preocupados com as informações pessoais coletadas por aplicativos instalados em seus dispositivos.

Lista de Siglas

ABS *Australian Bureau of Statistics.*

ACLD *Australian Census Longitudinal Dataset.*

AHRQ *Agency for Healthcare Research & Quality.*

ANPD Autoridade Nacional de Proteção de Dados.

AP Autoriteit Persoonsgegevens (Autoridade de Privacidade holandesa).

ASKO *Amsterdamse Stichting voor Katholiek, Protestants-Christelijk en Interconfessioneel Onderwijs* (Fundação de Amsterdã para a Educação Católica, Cristã Protestante e Interconfessional).

AVG *Algemene Verordening Gegevensbescherming* (Lei holandesa que implementa a GDPR europeia).

BEA *Bureau of Economic Analysis.*

BJS *Bureau of Justice Statistics.*

BLS *Bureau of Labor Statistics.*

BTS *Bureau of Transportation Statistics.*

CEA Conferência Estatística das Américas.

CEPAL Comissão Econômica para a América Latina e o Caribe.

DCC Departamento de Ciência da Computação da UFMG.

DEED Diretoria de Estatísticas Educacionais do Inep.

DPIA *Data Protection Impact Assessment.*

DRB *Disclosure Review Board.*

ED *United States Department of Education.*

EEE Espaço Econômico Europeu.

EIA *Energy Information Administration.*

ENADE Exame Nacional de Desempenho dos Estudantes.

ENCCEJA Exame Nacional de Certificação de Competências de Jovens e Adultos.

ENEM Exame Nacional do Ensino Médio.

ERS *Economic Research Service.*

EUA Estados Unidos da América.

EUROSTAT Serviço de Estatística da União Europeia.

GDPR *General Data Protection Regulation.*

IBGE Instituto Brasileiro de Geografia e Estatística.

IES Instituição de Ensino Superior.

INEP Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira.

IRIS Instituto de Referência em Internet e Sociedade.

IRS *Internal Revenue Service, Statistics of Income Division.*

LAI Lei de Acesso à Informação.

LGPD Lei Geral de Proteção de Dados Pessoais.

LGPDP Lei Geral de Proteção de Dados Pessoais.

MCI Marco Civil da Internet.

MEC Ministério da Educação.

NASS *National Agricultural Statistics Service.*

NCES *National Center for Education Statistics.*

NCHS *National Center for Health Statistics.*

NSF *National Science Foundation.*

OCDE Organização para a Cooperação e Desenvolvimento Econômico.

ONU Organização das Nações Unidas.

PUF *Public Use Files.*

PUMS *Public Use Microdata Samples.*

RDC *Research Data Centers.*

RGPD Regulamento Geral de Proteção de Dados.

SAEB Sistema de Avaliação da Educação Básica.

SAR Sala de Acesso a Dados Restritos.

SSA *Social Security Administration.*

TED Termo de Execução Descentralizada.

UE União Europeia.

UFMG Universidade Federal de Minas Gerais.

USCB *United States Census Bureau.*

Glossário

Agency for Healthcare Research & Quality (AHRQ) Agência federal dos EUA responsável por divulgar dados sobre qualidade, adequação e eficácia dos serviços de saúde, assim como o acesso aos mesmos.

anonimização Utilização de meios técnicos razoáveis e disponíveis no momento do tratamento, por meio dos quais um dado perde a possibilidade de associação, direta ou indireta, a um indivíduo. Técnicas de anonimização incluem, mas não se limitam a, *desidentificação*, *k-anonymity*, *l-diversity* e *privacidade diferencial*, dentre outras. Diferentes técnicas têm diferentes graus de sucesso, e algumas são comprovadamente menos eficazes que outras.

ASKO *Amsterdamse Stichting voor Katholiek, Protestants-Christelijk en Interconfessioneel Onderwijs* (Fundação de Amsterdã para a Educação Católica, Cristã Protestante e Interconfessional), conselho que administra 32 escolas na Holanda.

ataque Método para tentar inferir informações sensíveis de indivíduos a partir de uma divulgação de dados.

ataque composicional Ataque que se utiliza do cruzamento de informações divulgadas por mais de uma fonte, ou por divulgações diferentes de uma mesma fonte (e.g., cruzamento de dados de um censo médico com registros públicos de eleitores).

ataque de reconstrução da base de dados Método para reconstruir parcialmente um conjunto de dados privado a partir de informações agregadas públicas.

ataque longitudinal Ataque que se utiliza de informações divulgadas ao longo do tempo (e.g., várias liberações de informação referentes a uma mesma pesquisa, ou pesquisas em anos consecutivos que se referem aos mesmos titulares).

Australian Bureau of Statistics (ABS) Escritório australiano com mandato de coleta de dados estatísticos, incluindo a realização do censo do país.

Australian Census Longitudinal Dataset (SCLD) Base de dados do censo longitudinal australiano, criada a partir de amostras aleatórias com correspondência.

Autoridade Nacional de Proteção de Dados (ANPD) Órgão da administração pública direta federal do Brasil que faz parte da Presidência da República e possui atribuições relacionadas à proteção de dados pessoais e da privacidade e, sobretudo, que deve fiscalizar o cumprimento da LGPD.

banco de dados O mesmo que *base de dados*.

base de dados Conjunto estruturado de dados pessoais, estabelecido em um ou em vários locais, em suporte eletrônico ou físico.

Bureau of Economic Analysis (BEA) Agência federal dos EUA responsável por divulgar dados sobre macroeconomia e indústria, incluindo o produto interno bruto nacional e regional.

Bureau of Justice Statistics (BJS) Agência federal dos EUA responsável por divulgar dados sobre criminalidade.

Bureau of Labor Statistics (BLS) Agência federal dos EUA responsável por divulgar dados sobre economia e trabalho.

Bureau of Transportation Statistics (BTS) Agência federal dos EUA responsável por divulgar dados sobre transporte.

Censo da Educação Básica Principal pesquisa estatística educacional do país, abrangendo a Educação Básica e Profissional.

Censo da Educação Superior Mais completa pesquisa estatística sobre as Instituições de Educação Superior do país.

consulta Uma recuperação de dados ou informações a partir de uma base de dados, normalmente efetuada em linguagem específica.

dado agregado Dado sumarizado correspondendo a uma agregação das informações dos microdados para unidades mais amplas, ou mesmo a uma função computada sobre essas informações (e.g., frequência, média ou outros tipos de análises).

dado anonimizado Dado relativo a titular que não possa ser identificado, considerando a utilização de meios técnicos razoáveis e disponíveis na ocasião de seu tratamento.

dado de frequência Tipo de dado agregado usado por agências federais dos EUA relacionado a contagens (e.g., quantos estabelecimentos estão operando em uma determinada região).

dado de magnitude Tipo de dado agregado usado por agências federais dos EUA relacionado a grandezas como lucro (e.g., contagem de estabelecimentos em uma determinada região juntamente com a receita bruta agregada).

dado pessoal Informação relacionada a pessoa natural identificada ou identificável.

dado pessoal sensível Dado pessoal sobre o qual a preocupação quanto à privacidade (e.g., sobre origem racial ou étnica, convicção religiosa, opinião política, filiação a sindicato ou a organização de caráter religioso, filosófico ou político, dado referente à saúde ou à vida sexual, dado genético ou biométrico), quando vinculado a uma pessoa natural.

dado tabular Termo técnico específico usado para se referir a um tipo de dado agregado usado por agências federais dos EUA em que sumários sobre microdados são organizados em tabelas.

desanonimização O mesmo que *reidentificação*.

desidentificação Técnica de tratamento de dados pela qual são removidos possíveis identificadores individuais óbvios dos registros (e.g., nome, CPF, RG, ou endereços em níveis mais detalhados que as cidades), na expectativa de dificultar-se uma eventual reidentificação do titular.

differential privacy O mesmo que *privacidade diferencial*.

Disclosure Review Board (DRB) Conselho dos EUA que funciona como um curador que determina a liberação ou não de novos conjuntos de microdados de agências federais do país.

Economic Research Service (ERS) Agência federal dos EUA responsável por divulgar dados sobre agricultura e economia.

Energy Information Administration (EIA) Agência federal dos EUA responsável por divulgar dados sobre energia, incluindo dados sobre carvão, petróleo, gás natural, energia elétrica, renovável e energia nuclear.

Ex. Nac. de Certificação de Competências de Jovens e Adultos (ENCCEJA)
Exame realizado pelo Inep que afere competências, habilidades, e saberes de jovens e adultos que não tenham concluído o Ensino Fundamental ou o Ensino Médio na idade adequada.

Exame Nacional de Desempenho dos Estudantes (ENADE) Avaliação do rendimento dos concluintes dos Cursos de Graduação tanto em relação aos conteúdos programáticos previstos nas diretrizes curriculares dos cursos, quanto no que diz respeito às habilidades desenvolvidas e à atualização do aluno em relação ao Brasil e ao mundo.

Exame Nacional do Ensino Médio (ENEM) Avaliação do desempenho escolar ao final da Educação Básica.

General Data Protection Regulation (GDPR) Regulamento do direito europeu de 2018 que trata da privacidade e proteção de dados pessoais, aplicável a todos os indivíduos na União Europeia e do Espaço Econômico Europeu.

informação auxiliar Em relação a uma divulgação de dados de interesse, informação auxiliar é qualquer informação que se possa obter a respeito de um indivíduo através de outros canais que não sejam a divulgação de dados de interesse em si mesma (e.g, via *web*, outros registros públicos, jornais ou revistas, conhecimento prévio).

informação lateral O mesmo que *informação auxiliar*.

Inscript *Laboratory of Information Security, Cryptography, Privacy, and Transparency*, laboratório de pesquisa do DCC/UFMG focado em segurança da informação, criptografia, privacidade e transparência.

Internal Revenue Service, Statistics of Income Division (IRS) Agência federal dos EUA responsável por divulgar dados sobre declarações de imposto de renda e informações relacionadas.

k-anonymity Método sintático de tratamento que garante que os dados de cada indivíduo pertencente a uma divulgação de dados não possam ser distinguidos dos dados de pelo menos outros $k-1$ indivíduos também pertencentes à mesma divulgação.

l-diversity Método sintático de tratamento que aperfeiçoa a técnica de *k-anonymity* ao garantir um nível mínimo de diversidade nos atributos sensíveis de cada conjunto de indivíduos agrupados.

Lei Capiberibe O mesmo que *Lei da Transparência*.

Lei da Transparência Lei brasileira 6.924/2009, que obriga a União, os estados e os municípios a divulgar seus gastos na Internet em tempo real.

Lei de Acesso à Informação (LAI) Lei brasileira 12.527/2011, que trata dos procedimentos a serem observados pelo Estado para garantir o acesso a informações previsto na Constituição Federal do Brasil de 1988.

Lei Geral de Proteção de Dados Pessoais (LGPD ou LGPDP) Lei brasileira 13.709/2018, que dispõe sobre o tratamento de dados pessoais, inclusive nos meios digitais, por pessoa natural ou por pessoa jurídica de direito público ou privado, com o objetivo de proteger os direitos fundamentais de liberdade e de privacidade e o livre desenvolvimento da personalidade da pessoa natural.

Marco Civil da Internet (MCI) Lei brasileira 12.965/2014, que regula o uso da Internet no Brasil por meio da previsão de princípios, garantias, direitos e deveres para quem usa a rede, bem como da determinação de diretrizes para a atuação do Estado.

método semântico Qualquer método de tratamento de dados que formule condições semânticas para a divulgação de informação, incorporando em si mesmo a formalização de privacidade almejada (e.g., privacidade diferencial).

método sintático Qualquer método de tratamento de dados que formule condições puramente sintáticas para a divulgação de informação (e.g., desidentificação, *k-anonymity* e *l-diversity*).

microdado A menor fração de um dado e pode estar relacionado a uma pesquisa ou avaliação; o dado em sua menor forma de agregação. Microdados geralmente carregam informação sobre entidades em nível individual (e.g., pessoas, escolas, institutos).

mitigação, técnica ou método de O mesmo que *tratamento de dados*.

National Agricultural Statistics Service (NASS) Agência federal dos EUA responsável por divulgar dados sobre produção agrícola, economia, demografia e meio ambiente.

National Center for Education Statistics (NCES) Agência federal dos EUA responsável por divulgar dados sobre educação e informações sobre finanças de distritos escolares.

National Center for Health Statistics (NCHS) Agência federal dos EUA responsável por divulgar dados sobre saúde pública.

National Science Foundation (NSF) Agência federal dos EUA responsável por divulgar dados sobre educação e pesquisa básica em todos os campos não médicos da ciência e engenharia.

privacidade diferencial Método semântico de tratamento de dados que garante formalmente que apenas uma quantidade negligível de informação sobre um dado indivíduo pode ser obtida a partir dos dados publicados, independentemente da participação ou não do indivíduo na pesquisa.

pseudonimização Técnica de tratamento de dados pela qual atribui-se um código individual artificialmente criado a cada registro de uma base de dados, acompanhada da transferência de identificadores diretos (como nome, CPF e RG) para outra base de dados. Dessa forma, o controlador é capaz de mapear identificadores diretos em uma base de dados a registros específicos na outra base através do uso dos códigos individuais, ao mesmo tempo em que se dificultam tentativas de reidentificação do titular por parte de agentes externos.

Public Use Files (PUF's) Tipo de arquivo utilizado pelo USCB (Escritório do Censo dos EUA) que contém todos os registros de todos os entrevistados em uma dada pesquisa.

Public Use Microdata Samples (PUMS) Tipo de arquivo utilizado pelo USCB (Escritório do Censo dos EUA) que contém os registros de apenas uma amostra da população em uma dada pesquisa.

quaseidentificador Informações que não são, em si mesmas, identificadores únicos, mas que estão suficientemente correlacionadas com uma entidade a ponto de poderem ser combinadas com outros quaseidentificadores para criar um identificador exclusivo.

query O mesmo que *consulta*.

registro Informação em uma base de dados correspondente a um indivíduo específico.

Regulamento Geral de Proteção de Dados (RGPD) O mesmo que *General Data Protection Regulation*.

reidentificação Prática de combinar dados anonimizados com informações publicamente disponíveis ou dados auxiliares, a fim de descobrir o indivíduo ao qual os dados pertencem.

Research Data Centers (RDC's) Tipo de sala segura utilizada pelo USCB (Escritório do Censo dos EUA) para acesso controlado e limitado a microdados de pesquisas.

Sistema de Avaliação da Educação Básica (SAEB) Conjunto de testes e questionários aplicados na rede pública e em uma amostra da rede privada que auxilia no diagnóstico da Educação Básica e de possíveis fatores que interfiram no desempenho do estudante.

Social Security Administration (SSA) Agência federal dos EUA responsável por divulgar dados sobre renda e uma lista anual com os nomes mais comumente dados a bebês recém-nascidos no país no ano anterior.

Teorema de Reconstrução da Base de Dados (*Dataset Reconstruction Theorem*) Resultado formal que mostra que, dado acesso a uma quantidade suficientemente grande de informações, alguém pode reconstruir bancos de dados subjacentes e, em teoria, reidentificar indivíduos.

titular Pessoa natural a quem se referem os dados pessoais que são objeto de tratamento.

tratamento (de dados) Toda operação realizada com dados pessoais, como as que se referem a coleta, produção, recepção, classificação, utilização, acesso, reprodução, transmissão, distribuição, processamento, arquivamento, armazenamento, eliminação, avaliação ou controle da informação, modificação, comunicação, transferência, difusão ou extração.

United States Census Bureau (USCB) Agência federal dos EUA responsável por divulgar dados sobre população e economia.

TED 8750 - PRICE

PRIVACIDADE NOS CENSOS EDUCACIONAIS

Termo de Execução Descentralizada entre o Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira - Inep e a Universidade Federal de Minas Gerais - UFMG

PRODUTO 02

Relatório sobre os riscos à privacidade decorrentes da atual forma de divulgação dos microdados dos Censos Educacionais do Inep



Mário S. ALVIM	Igor W. LEMES
Jeroen van de GRAAF	Ramon G. GONZE
	Gabriel H. NUNES

06 de setembro de 2020

Resumo

O presente documento consiste em um *Relatório sobre os riscos à privacidade decorrentes da atual forma de divulgação dos microdados dos Censos Educacionais do Inep*, previsto como Produto 02 no plano de trabalho do Termo de Execução Descentralizada (TED) 8750. Este TED foi firmado entre o Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira (Inep) e a Universidade Federal de Minas Gerais (UFMG), e encontra-se em execução pelo Laboratório Inscript (*Laboratory of Information Security, Cryptography, Privacy, and Transparency*) do Departamento de Ciência da Computação (DCC) da Universidade.

Neste relatório apresenta-se uma extensa análise quantitativa experimental dos riscos à privacidade de titulares de dados decorrentes da atual forma de divulgação dos microdados dos Censos Educacionais da Educação Básica e da Educação Superior por parte do Inep. Para fins de proteção de privacidade nestas divulgações, atualmente o Inep emprega apenas as técnicas de *desidentificação*, em que se removem possíveis identificadores individuais óbvios dos registros (como nome, CPF, RG) e de *pseudonimização*, em que tais identificadores individuais óbvios são substituídos por um código único de identificação artificialmente criado. Entretanto, é sabido na literatura técnica sobre privacidade que, mesmo quando se removem ou se criptografam identificadores explícitos (como nomes, endereços e números de telefone) dos titulares dos microdados em uma divulgação, outros dados distintos, chamados de *quaseidentificadores*, podem se combinar de maneira inadequada e ser, assim, ser vinculados a informações publicamente disponíveis para reidentificar os indivíduos. Neste contexto, este relatório analisa a degradação de privacidade de indivíduos presentes nas bases dos Censos Educacionais quando quaseidentificadores podem ser usados na inferência de informação sensível a seu respeito.

O documento provê uma formalização matemática precisa de modelos de *adversário* – i.e., a entidade contra quem se deseja proteger a informação sensível sobre indivíduos – e de *ataques* – i.e., uma ação ou conjunto de ações pelas quais o adversário pode obter informação sensível sobre titulares de dados. Em particular, provê-se uma classificação metódica de ataques organizada nas seguintes dimensões: (i) o tipo de informação procurada pelo adversário, distinguindo entre *ataques de reidentificação*, em que o objetivo do adversário é determinar uma correspondência entre registros presentes na base de dados e os titulares desses registros, vs. *ataques de inferência de atributo*, em que o objetivo do adversário é inferir o valor de um atributo considerado como sensível para

um conjunto de indivíduos, independentemente de se estes indivíduos tenham sido re-identificados com sucesso ou não; (ii) o foco do adversário, distinguindo entre *ataques focados em indivíduo* ou *individuais*, em que o adversário visa obter informação sensível a respeito de um indivíduo específico pré-determinado como alvo, vs. *ataques coletivos*, em que o adversário objetiva obter informação sensível sobre o maior número possível de indivíduos, independentemente de quem eles sejam; e (iii) as bases de dados acessíveis ao adversário, distinguindo entre *ataques em uma única base de dados*, em que o adversário tem acesso a uma única base de dados, referente a um ponto específico do tempo, vs. *ataques longitudinais*, em que o adversário tem acesso a várias versões da base de dados, cada uma referente a um ponto distinto do tempo. Consideram-se dois tipos de métricas da degradação de privacidade causada por um ataque: (i) *determinísticas*, em que a degradação é medida termos absolutos –i.e., um valor qualitativo dependendo de se a informação desejada foi recuperada com absoluta certeza ou não; e (ii) *probabilísticas*, em que a degradação é medida em termos estocásticos –i.e., um valor quantitativo representando o grau de certeza com o qual a informação desejada foi recuperada.

Dada a exposição acima, obtêm-se 8 combinações distintas de tipos de ataques e 2 medidas de degradação de privacidade, levando a um total de 16 cenários distintos. Para todos eles apresentam-se análises neste documento. Em particular, para cada tipo de ataque considerado –reidentificação vs. inferência de atributo, em uma única base vs. longitudinal–, apresentam-se resultados de ataques individuais e coletivos. Por focarem-se em um aluno específico pré-determinado como alvo, ataques individuais conseguem ilustrar concretamente os riscos a que um alvo selecionado pode estar sujeito. Entretanto, resultados quantitativos de ataques individuais são altamente dependentes das características específicas do alvo escolhido, e podem não ser representativos do risco esperado da coletividade de todos os indivíduos de interesse. Já as análises de ataques coletivos nos permitem quantificar o risco médio a que todos os indivíduos estão sujeitos. Portanto, apesar de mais abstratos, resultados quantitativos de ataques coletivos proveem uma visão mais acurada dos riscos médios esperados nas bases consideradas.

As análises demonstram que, usando apenas quaseidentificadores que sejam facilmente descobríveis sobre um indivíduo escolhido como alvo (e.g., sua data de nascimento ou escola em que está matriculado), ataques em uma única base de dados podem levar, em alguns casos, à reidentificação de mais de 78% dos indivíduos, e à inferência de um atributo sensível (e.g., se o indivíduo é ou não portador de necessidades especiais ou deficiente) de mais de 90% dos indivíduos. Usando informação auxiliar ainda mais trivial (e.g., apenas a instituição de ensino e curso vinculados a um aluno), um ataque longitudinal que combine várias bases liberadas ano a ano sobre um mesmo Censo podem levar o risco de reidentificação a mais de 15% dos indivíduos presentes nas bases, e à inferência de atributos sensíveis a mais de 58% dos indivíduos.

Os resultados obtidos demonstram de forma inequívoca que a atual forma de divulgação dos Censos Educacionais pelo Inep submete os titulares dos dados a consideráveis riscos de violação de privacidade, incluindo reidentificação e inferência de atributos sensíveis. Tal situação poderia constituir em violação da Lei Geral de Proteção de Dados Pessoais.

Sumário

1	Introdução e motivação	1
1.1	Objetivo deste documento	1
1.2	Contextualização	1
1.3	Contribuições deste documento	5
1.4	Organização deste documento	7
2	Fundamentação teórica	10
2.1	Conceitos fundamentais	10
2.2	Classificação de tipos de ataque	14
2.3	Modelos de bases de dados, registros e atributos	15
3	Modelo de ataques em uma única base de dados	19
3.1	Premissas sobre ataques em uma única base de dados	19
3.2	Ataque de reidentificação individual em uma única base de dados (RIU) .	22
3.3	Ataque de reidentificação coletiva em uma única base de dados (RCU) . .	24
3.4	Ataque de inferência de atributo individual em uma única base de dados (AIU)	26
3.5	Ataque de inferência de atributo coletiva em uma única base de dados (ACU)	29
4	Avaliação experimental de ataques em uma única base de dados nos Censos Educacionais	32
4.1	Configuração dos experimentos em uma única base	32
4.2	Resultados de ataques de reidentificação individual em uma única base de dados (RIU)	33

4.3	Resultados de ataques de reidentificação coletiva em uma única base de dados (RCU)	37
4.4	Resultados de ataques de inferência de atributo individual em uma única base de dados (AIU)	46
4.5	Resultados de ataques de inferência de atributo sensível coletiva em uma única base de dados (ACU)	48
5	Modelo de ataques longitudinais	63
5.1	Premissas sobre ataques longitudinais	63
5.2	Ataque de reidentificação individual longitudinal (RIL)	67
5.3	Ataque de reidentificação coletiva longitudinal (RCL)	70
5.4	Ataque de inferência de atributo individual longitudinal (AIL)	72
5.5	Ataque de inferência de atributo coletiva longitudinal (ACL)	75
6	Avaliação experimental de ataques longitudinais nos Censos Educacionais	79
6.1	Configuração dos experimentos longitudinais	79
6.2	Resultados de ataques de reidentificação individual longitudinal (RIL) . . .	81
6.3	Resultados de ataques de reidentificação coletiva longitudinal (RCL) . . .	83
6.4	Resultados de ataques de inferência de atributo individual longitudinal (AIL)	92
6.5	Resultados de ataques de inferência de atributo sensível coletiva longitudinal (ACL)	95
7	Considerações finais	109
	Referências Bibliográficas	114
	Anexos	116
A	Formalização matemática dos ataques	117
A.1	Formalização de ataques em uma única base de dados	117
A.2	Formalização de ataques longitudinais	130
B	A ferramenta ARX	140

Lista de Siglas	142
------------------------	------------

Glossário	144
------------------	------------

Lista de Tabelas

2.2.1	Tipos de ataques cobertos neste documento e seus acrônimos.	15
2.3.2	Base de dados D para o Exemplo 1.	18
4.1.1	Atributos usados como candidatos a quaseidentificadores nos experimen- tos de ataques em uma única base de dados.	34
4.1.2	Atributos sensíveis usados nos experimentos de ataques em uma única base de dados.	35
4.3.4	Experimento 8: Quaseidentificadores com maior degradação de privaci- dade em ataques de reidentificação coletiva (RCU) no Censo da Educação Superior de 2018.	40
4.3.7	Experimento 9: Quaseidentificadores com maior degradação de privaci- dade em ataques de reidentificação coletiva (RCU) no Censo da Educação Básica de 2019.	43
4.5.10	Experimento 11: Quaseidentificadores com maior degradação de privaci- dade em ataques de inferência de atributo coletiva (ACU) sobre atributo sensível <code>IN_DEFICIENCIA</code> no Censo da Educação Superior de 2018.	52
4.5.11	Experimento 11: Quaseidentificadores com maior degradação de privaci- dade em ataques de inferência de atributo coletiva (ACU) sobre atributo sensível <code>IN_FINANCIAMENTO_ESTUDANTIL</code> no Censo da Educação Superior de 2018.	53
4.5.15	Experimento 12: Quaseidentificadores com maior degradação de privaci- dade em ataques de inferência de atributo coletiva (ACU) sobre atributo sensível <code>IN_NECESIDADE_ESPECIAL</code> no Censo da Educação Básica de 2019.	59
4.5.16	Experimento 12: Quaseidentificadores com maior degradação de privaci- dade em ataques de inferência de atributo coletiva (ACU) sobre atributo sensível <code>IN_TRANSPORTE_PUBLICO</code> no Censo da Educação Básica de 2019.	60
5.1.2	Conjunto longitudinal $\mathcal{L}_{\mathcal{D}}=\{D_1, D_2\}$ e sua agregação para o Exemplo 13.	67

6.1.1	Atributos usados como candidatos a quaseidentificadores nos experimentos de ataques longitudinais.	80
6.1.2	Atributos sensíveis usados nos experimentos de ataques longitudinais. . .	80
6.3.3	Experimento 19: Degradação de privacidade em ataques de reidentificação coletiva longitudinal (RCL) no conjunto longitudinal dos Censos da Educação Superior de 2014 a 2017.	85
6.3.6	Experimento 20: Degradação de privacidade em ataques de reidentificação coletiva longitudinal (RCL) no conjunto longitudinal dos Censos da Educação Básica de 2014 a 2017.	89
6.5.9	Experimento 22: Degradação de privacidade em ataques de inferência de atributo coletiva longitudinal (ACL) no conjunto longitudinal dos Censos da Educação Superior de 2014 a 2017.	98
6.5.13	Experimento 23: Degradação de privacidade em ataques de inferência de atributo coletiva longitudinal (ACL) no conjunto longitudinal dos Censos da Educação Básica de 2014 a 2017.	105
B.1	Sucesso a posteriori do adversário em ataques de reidentificação coletiva em uma única base de dados (RCU) usando a ferramenta ARX.	141

Lista de Definições

24	Ataque de reidentificação individual em uma única base de dados (RIU)	117
25	Ataque de reidentificação coletiva em uma única base de dados (RCU)	120
26	Ataque de inferência de atributo individual em uma única base de dados (AIU)	123
27	Ataque de inferência de atributo coletiva em uma única base de dados (ACU)	126
28	Ataque de reidentificação individual longitudinal (RIL)	130
29	Ataque de reidentificação coletiva longitudinal (RCL)	132
30	Ataque de inferência de atributo individual longitudinal (AIL)	134
31	Ataque de inferência de atributo coletiva longitudinal (ACL)	137

Lista de Exemplos

1	Exemplo condutor para ataques em uma única base de dados	16
2	Distribuição de probabilidade marginal sobre um subconjunto de atributos	20
3	Execução de ataque de reidentificação individual em uma única base de dados (RIU)	22
4	Execução de ataque de reidentificação coletiva em uma única base de dados (RCU)	25
5	Execução de ataque de inferência de atributo individual em uma única base de dados (AIU)	27
6	Execução de ataque de inferência de atributo coletiva em uma única base de dados (ACU)	29
13	Exemplo condutor para ataques longitudinais	65
14	Execução de ataque de reidentificação individual longitudinal (RIL)	68
15	Execução de ataque de reidentificação coletiva longitudinal (RCL)	71
16	Execução de ataque de inferência de atributo individual longitudinal (AIL)	73
17	Execução de ataque de inferência de atributo coletiva longitudinal (ACL)	76

Lista de Experimentos

7	Ataques de reidentificação individual RIU sobre uma conhecida figura política nos Censos da Educação Superior de 2014 e 2018	33
8	Ataques de reidentificação coletiva RCU no Censo da Educação Superior de 2018	38
9	Ataques de reidentificação coletiva RCU no Censo da Educação Básica de 2019	42
10	Ataques de inferência de atributo individual AIU sobre atributo sensível IN_TRANSPORTE_PUBLICO de um parente de um dos autores do documento no Censo da Educação Básica de 2019	46
11	Ataques de inferência de atributo coletiva ACU sobre atributos sensíveis IN_DEFICIENCIA e IN_FINANCIAMENTO_ESTUDANTIL no Censo da Educação Superior de 2018	48
12	Ataques de inferência de atributo coletiva ACU sobre atributos sensíveis IN_NECESSIDADE_ESPECIAL e IN_TRANSPORTE_PUBLICO no Censo da Educação Básica de 2019	56
18	Ataques de reidentificação individual RIL nos Censos da Educação Superior	81
19	Ataques de reidentificação coletiva RCL nos Censos da Educação Superior de 2014 a 2017	83
20	Ataques de reidentificação coletiva RCL nos Censos da Educação Básica de 2014 a 2017	88
21	Ataques de inferência de atributo individual AIL sobre atributo sensível nos Censos da Educação Básica	92
22	Ataques de inferência de atributo coletiva ACL sobre atributos sensíveis IN_ALUNO_DEF_TGD_SUPER e IN_FINANC_ESTUDANTIL nos Censos da Educação Superior de 2014 a 2017	95
23	Ataques de inferência de atributo coletiva ACL sobre atributos sensíveis ID_POSSUI_NEC_ESPECIAL e ID_N_T_E_P nos Censos da Educação Básica de 2014 a 2017	102

1 Introdução e motivação

Este documento consiste no Produto 02, intitulado *Relatório técnico sobre os riscos de divulgação inapropriada no conjunto de microdados dos Censos da Educação e a definição do escopo do projeto piloto*, do plano de trabalho do Termo de Execução Descentralizada (TED) 8750, firmado entre o Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira (Inep) e a Universidade Federal de Minas Gerais (UFMG), e em execução pelo Laboratório Inscript (*Laboratory of Information Security, Cryptography, Privacy, and Transparency*) do Departamento de Ciência da Computação (DCC) da Universidade.

1.1 Objetivo deste documento

De acordo com o plano de trabalho do TED 8750, o Produto 02 que este documento implementa consiste em um:

Documento técnico apresentando os riscos de divulgação inapropriada no conjunto de microdados dos Censos da Educação e a definição do escopo do projeto piloto.

Mais especificamente, visa-se a atender ao Objetivo Específico 03 do plano de trabalho:

Avaliar o risco potencial de identificação das pessoas a quem os dados estatísticos se referem nos microdados do Censo Escolar da Educação Básica e do Censo da Educação Superior.

1.2 Contextualização

Nos últimos anos, entidades da sociedade civil têm se acostumado com um crescente acesso à informação de interesse público, em particular aquela provida por órgãos governamentais. Entretanto, esta nova realidade introduz a necessidade de um equilíbrio não trivial entre a transparência na divulgação de informação e a proteção da privacidade dos titulares dos dados.

No contexto brasileiro, a Lei 12.527/2011, conhecida como *Lei de Acesso à Informação* (LAI) [9]: (i) determina ao poder público o dever de garantir o amplo acesso à informação, particularmente àquela considerada de interesse coletivo ou geral, a qual deve ser disponibilizada via Internet independentemente de requerimento; (ii) garante ao cidadão o direito de acesso às demais informações não imediatamente disponibilizadas via Internet; e (iii) garante ao cidadão o acesso à informação primária, íntegra, autêntica, e atualizada em ambos os casos. Entretanto, a própria LAI aponta que a informação pessoal deve ser protegida, reconhecendo que o cuidado com a privacidade dos indivíduos é uma questão central mesmo na regulamentação sobre acesso a dados. Tal preocupação com a privacidade é reforçada pela Lei 13.709/2018, conhecida como *Lei Geral de Proteção de Dados Pessoais* (LGPD ou LGPD) [8], que altera significativamente a maneira como organismos públicos e privados devem lidar com informações pessoais, visando à preservação da privacidade. Neste contexto, impõe-se aos órgãos públicos que coletam, mantêm e divulgam dados a incumbência de conciliar os requisitos de transparência com os requisitos de proteção de privacidade impostos pela atual legislação brasileira.

No Produto 01 do presente TED 8750, provemos uma análise sobre a atual forma de divulgação dos Censos Educacionais pelo Inep, contextualizando-a em relação a práticas correntes de órgãos divulgadores de estatísticas oficiais internacionais e nacionais para proteção da privacidade dos titulares dos dados. Os resultados do Produto 01 serão referenciados no presente documento à medida em que se fizerem relevantes.

No presente Produto 02 damos prosseguimento ao plano de trabalho, provendo uma extensa análise quantitativa dos riscos à privacidade dos titulares dos dados decorrentes da atual forma de divulgação dos Censos Educacionais da Educação Básica e da Educação Superior pelo Inep, que consiste em microdados desidentificados e pseudonimizados.

A atual forma de divulgação dos Censos Educacionais por parte do Inep O Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira (Inep), ¹ autarquia federal vinculada ao Ministério da Educação (MEC), ² tem entre suas atribuições a responsabilidade pela execução de levantamentos estatísticos sobre a educação nacional nos níveis básico e superior, incluindo o tratamento de dados, o controle de qualidade, e a produção e divulgação das estatísticas anuais específicas e dos indicadores educacionais.

O Inep produz e divulga várias Pesquisas de grande relevância nacional, incluindo o *Censo da Educação Básica*, o *Censo da Educação Superior*, o *Exame Nacional do Ensino Médio* (ENEM), o *Sistema de Avaliação da Educação Básica* (SAEB), o *Exame Nacional de Certificação de Competências de Jovens e Adultos* (ENCCEJA) e o *Exame Nacional de Desempenho dos Estudantes* (ENADE). Os microdados dessas Pesquisas são divulgados pelo Inep para *download* no domínio do Instituto, ³ com links também disponibilizados a partir do Portal Brasileiro de Dados Abertos ⁴ e em mecanismos de pesquisa como o

¹<http://www.inep.gov.br/>

²<https://www.gov.br/mec/>

³<http://inep.gov.br/microdados>

⁴<http://dados.gov.br/>

Google Dataset Search.⁵

Neste documento nos focamos nas seguintes pesquisas divulgadas pelo Inep em forma de microdados, ou seja, dados na menor unidade de agregação possível:

- **Censo da Educação Básica:** com frequência anual, é a principal pesquisa estatística educacional do país, a qual abrange a Educação Básica e Profissional. Inclui a Educação Infantil, os Ensinos Fundamental e Médio, a Educação Especial, a Educação de Jovens e Adultos, e os Cursos Técnicos e Cursos de Formação Inicial Continuada ou Qualificação Profissional.
- **Censo da Educação Superior:** com frequência anual, é a mais completa pesquisa estatística sobre as Instituições de Educação Superior (IES's) do país, as quais ofertam Cursos de Graduação e Sequências de Formação Específica. Inclui informações sobre as IES, além de seus alunos e docentes.

Para o Censo da Educação Básica, o Inep disponibiliza dados de 1995 até 2019, assim como para o Censo da Educação Superior, exceto pela base de dados referente a 2019, ainda não publicada. A partir de 2007, o Instituto passou a divulgar microdados relativos ao Censo da Educação Básica com informações individuais sobre alunos e professores, além de escolas e turmas. O mesmo ocorreu a partir de 2009 para o Censo da Educação Superior, com a divulgação de microdados sobre alunos e professores, instituições e cursos.

A partir das análises realizadas sobre os arquivos de microdados dos Censos Educacionais disponibilizados publicamente, identificamos que o Inep aplica as seguintes técnicas de proteção de privacidade aos microdados divulgados:

- *desidentificação*, pela qual são removidos possíveis identificadores individuais óbvios dos registros (como nome, CPF, RG, ou endereços em níveis mais detalhados que as cidades); e
- *pseudonimização*, em que o Instituto atribui a cada registro um código único de identificação artificialmente criado, substituindo identificadores individuais naturais (como nome, CPF ou RG).

Como detalhado no Produto 01 do presente TED, há evidências baseadas casos objetivos pontuais dos riscos à privacidade de titulares de dados decorrentes da atual forma de divulgação dos Censos Educacionais por parte do Inep. Mais especificamente:

1. Os pesquisadores brasileiros Queiroz e Motta já observaram a vulnerabilidade da atual situação do Inep em um estudo de 2015 [17]. Utilizando o arquivo referente aos docentes do Censo da Educação Superior do ano de 2013, eles conseguiram reidentificar unicamente um dos autores do estudo dentre todos os 383 683 registros

⁵<https://datasetsearch.research.google.com/>

de docentes na base utilizando apenas sua data de nascimento, gênero, e nome da Instituição de Ensino Superior à qual estava vinculado. Como possível solução, Queiroz e Motta sugeriram a aplicação de dois métodos mais sofisticados aos Censos Educacionais do Inep: os métodos sintáticos conhecidos como *k-anonymity* [18] e *l-diversity* [14], o que foi feito com o auxílio da ferramenta ARX [16].

2. O filho de um dos autores do presente documento tem hoje 14 anos e, portanto, consta nas divulgações dos microdados dos Censos da Educação Básica pelo Inep em vários anos distintos. Apesar do nome, RG e CPF do adolescente não constarem nos microdados publicados, pudemos reidentificá-lo de forma relativamente fácil da seguinte maneira. Primeiramente, a partir do nome da escola onde o adolescente estuda, encontramos o identificador único correspondente a esta escola na própria base do Inep. Em um segundo momento, entre os alunos desta escola selecionamos na base aqueles com a mesma data de nascimento do adolescente em quem estávamos interessados. Como havia apenas um estudante nesta escola com a data de nascimento em questão, e sabendo que o adolescente alvo estava na base, pudemos reidentificá-lo e recuperar seus dados sensíveis, como, por exemplo, se ele é ou não portador de necessidades especiais.

Os exemplos acima ilustram riscos de *reidentificação*, ou seja, ligação de um ou mais registros na base de dados ao seu titular. Entretanto, reidentificação não é a única preocupação relevante sobre privacidade de titulares de dados.

Em algumas situações é possível inferir o valor de um atributo sensível de um indivíduo (e.g., se ele é ou não portador de necessidades especiais, ou qual sua renda familiar) mesmo sem tê-lo reidentificado na base de dados. Para ilustrar esse ponto, considere novamente o exemplo acima envolvendo o filho de um dos autores deste documento. Mesmo que o adolescente não fosse o único em sua escola com a mesma data de nascimento –o que inviabilizaria a sua reidentificação–, ainda seria possível que alguma informação sensível sobre o adolescente fosse revelada. Por exemplo, caso todos os alunos que compartilhassem de sua data de nascimento em sua escola fossem (ou não fossem) portadores de uma necessidade especial específica, ficaria evidenciado se o aluno em questão também seria (ou não seria) portador dessa necessidade. Esse exemplo demonstra que *mesmo que o aluno não tivesse sido unicamente reidentificado na base do Inep, uma violação de privacidade já poderia ter ocorrido*. Esse tipo de risco é conhecido como *inferência de atributo sensível*.

A discussão acima demonstra que há uma possibilidade concreta de violações de privacidade decorrentes da atual forma de divulgação dos Censos Educacionais pelo Inep. Entretanto, os exemplos citados consistem apenas em evidência baseada em casos objetivos pontuais. Neste documento provemos uma extensa análise quantitativa dos riscos à privacidade no cenário dos Censos Educacionais, contribuindo para um entendimento mais profundo de qual a extensão e intensidade destes riscos, a fim de que o Inep possa tomar decisões mais bem informadas sobre as formas de mitigá-los.

1.3 Contribuições deste documento

Para poder enunciar com clareza as contribuições deste documento, definimos informalmente abaixo alguns termos muito usados na teoria sobre privacidade. Tais conceitos serão formalizados precisamente na Seção 2.1.

- *Informação sensível*: informação considerada digna de proteção.
- *Adversário*: entidade contra quem se deseja proteger a informação sensível sobre indivíduos.
- *Ataque*: ação ou conjunto de ações pelas quais o adversário pode obter informação sensível sobre titulares de dados.
- *Quaseidentificadores*: atributos que não são, em si mesmos, identificadores únicos de um indivíduo (como nome, CPF ou RG), mas que estão suficientemente correlacionadas com o titular a ponto de poderem ser combinadas com outros quaseidentificadores para criar um identificador exclusivo. Por exemplo, Sweeney demonstrou em 2000 que o *zip-code* (o equivalente americano ao CEP brasileiro), o gênero e a data de nascimento de um indivíduo são quaseidentificadores poderosos, uma vez que 87% da população dos EUA poderia ser unicamente identificada usando-se apenas estes três atributos combinados [20].
- *Degradação de privacidade*: medida do quanto a execução de um ataque aumenta o sucesso do adversário em obter informação sensível a respeito de titulares de dados.

Neste contexto, podemos descrever as contribuições deste documento como a seguir.

Contribuição principal: *Uma extensa análise quantitativa experimental da degradação de privacidade causada por vários ataques executados sobre as bases dos Censos Educacionais do Inep em sua atual forma de divulgação (em que se aplicam apenas de-identificação e pseudonimização), levando em conta que o adversário pode usar quaseidentificadores para auxiliar a inferência de informação sensível contida nessas bases.*

Contribuições específicas:

1. Uma **formalização matemática precisa de modelos de adversário e classes de ataques**, considerando as seguintes dimensões:
 - (a) **Quanto ao tipo de informação procurada pelo adversário**: distinção entre *ataques de reidentificação*, em que o objetivo do adversário é determinar uma correspondência entre registros presentes na base de dados e os titulares desses registros, vs. *ataques de inferência de atributo*, em que o objetivo do

adversário é inferir o valor de um atributo considerado como sensível para um conjunto de indivíduos, independentemente de se estes indivíduos tenham sido reidentificados com sucesso ou não.

- (b) **Quanto ao foco do adversário:** distinção entre *ataques focados em indivíduo* ou *individuais*, em que o adversário visa obter informação sensível a respeito de um indivíduo específico pré-determinado como alvo, vs. *ataques coletivos*, em que o adversário objetiva obter informação sensível sobre o maior número possível de indivíduos, independentemente de quem eles sejam.
 - (c) **Quanto às bases de dados acessíveis ao adversário:** distinção entre *ataques em uma única base de dados*, em que o adversário tem acesso a uma única base de dados, referente a um ponto específico do tempo, vs. *ataques longitudinais*, em que o adversário tem acesso a várias versões da base de dados, cada uma referente a um ponto distinto do tempo. O estudo de ataques longitudinais é particularmente importante no contexto do Inep porque a divulgação das bases dos Censos Educacionais é feita anualmente, gerando um conjunto de dados longitudinal que cresce ano a ano. Dessa forma um adversário poderia cruzar a informação a respeito de um titular de dados ao longo das divulgações em vários anos e assim aumentar consideravelmente a chance de inferência de informação sensível.
2. Uma formalização precisa de **métricas da degradação de privacidade** causada por um ataque, incluindo métricas *determinísticas*, em que a degradação é medida termos absolutos –i.e., um valor qualitativo dependendo de se a informação desejada foi recuperada com absoluta certeza ou não– e métricas *probabilísticas*, em que a degradação é medida em termos estocásticos –i.e., um valor quantitativo representando o grau de certeza com o qual a informação desejada foi recuperada.
 3. Uma extensa **análise experimental quantitativa dos riscos à privacidade** nas bases dos Censos Educacionais da Educação Básica e da Educação Superior. Para cada tipo de ataque –reidentificação vs. inferência de atributo, em uma única base vs. longitudinal–, iniciamos nossas análises por ataques individuais, seguida por ataques coletivos. Por focarem-se em um aluno específico pré-determinado como alvo, ataques individuais conseguem ilustrar concretamente os riscos a que um alvo selecionado pode estar sujeito. Entretanto, resultados quantitativos de ataques individuais são altamente dependentes das características específicas do alvo escolhido, e podem não ser representativos do risco esperado da coletividade de todos os indivíduos de interesse. Já as análises de ataques coletivos nos permitem quantificar o risco médio a que todos os alunos estão sujeitos. Portanto, apesar de mais abstratos, resultados quantitativos de ataques coletivos proveem uma visão mais acurada dos riscos esperados de todos os indivíduos.

Dessa análise, destacam-se as seguintes conclusões:

- (a) Usando apenas informação auxiliar que seja de conhecimento de pessoas próximas a um indivíduo selecionado como alvo, ou que seja facilmente obtida

na Internet (como, e.g., sua data de nascimento ou escola em que está matriculado), ataques em uma única base de dados (e.g., a do Censo da Educação Superior de 2018 ou do Censo da Educação Básica de 2019) podem levar, em alguns casos, à reidentificação de mais de 78% dos indivíduos presentes nas bases, e à inferência de um atributo sensível (e.g., se o indivíduo é ou não portador de necessidades especiais ou deficiente) de mais de 90% dos indivíduos.

- (b) Usando informação auxiliar ainda mais trivial (e.g., apenas a instituição de ensino e curso vinculados a um aluno), um ataque longitudinal que combine várias bases liberadas ano a ano sobre um mesmo Censo (e.g., as bases de 2014 a 2017 do Censo da Educação Superior ou do Censo da Educação Básica) podem levar o risco de reidentificação a mais de 15% dos indivíduos presentes nas bases, e à inferência de atributos sensíveis a mais de 58% dos indivíduos.
- (c) Suportados pelas análises quantitativas dos experimentos, verificamos que as atuais técnicas empregadas pelo Inep, consistindo em desidentificação e pseudonimização, não são suficientes para mitigar satisfatoriamente os riscos de reidentificação e de inferência de atributos sensíveis dos titulares dos dados.

Não temos conhecimento de qualquer trabalho que tenha efetuado uma análise quantitativa experimental tão profunda a respeito dos riscos à privacidade decorrentes da atual forma de divulgação dos Censos Educacionais pelo Inep quanto a apresentada no presente documento.

1.4 Organização deste documento

O restante deste documento está organizado da seguinte forma.

- **Fundamentação teórica** (Seção 2): Nesta seção apresentamos a fundamentação teórica que serve de base para a formalização de ataques e para as análises de contidas deste documento. Iniciamos com a introdução de conceitos fundamentais utilizados neste documento, como “adversário”, “ataque”, “informação auxiliar”, e “degradação de privacidade” (Seção 2.1). Seguimos com a apresentação de uma classificação sistemática de ataques (Seção 2.2). Por fim, formalizamos o modelo de bases de dados utilizado nas seções seguintes (Seção 2.3).
- **Modelo de ataques em uma única base de dados** (Seção 3): Nesta seção especificamos os ataques em que o adversário está tentando obter informação sensível a partir de uma única base de dados. Iniciamos a Seção com uma exposição das premissas assumidas para este tipo de ataque (Seção 3.1), e então apresentamos os modelos de: (i) ataques de reidentificação individual em uma única base de dados (RIU, Seção 3.2); (ii) ataques de reidentificação coletiva em uma única base de dados (RCU, Seção 3.3); (iii) ataques de inferência de atributo individual em uma única base de dados (AIU, Seção 3.4); e (iv) ataques de inferência de atributo

coletiva em uma única base de dados (ACU, Seção 3.5). Cada ataque introduzido é seguido de um exemplo detalhado ilustrando como o adversário age passo a passo, e como seu sucesso é quantificado. Para propiciar uma leitura mais fluida do presente documento, os detalhes matemáticos da formalização dos ataques em uma única base de dados é reservada ao Anexo A.1.

- **Avaliação experimental de ataques em uma única base de dados nos Censos Educacionais** (Seção 4): Nesta seção apresentamos uma extensiva análise quantitativa experimental sobre riscos à privacidade decorrentes dos ataques em uma única base de dados introduzidos na Seção 3. Iniciamos a Seção com uma descrição da configuração dos experimentos (Seção 4.1), e então apresentamos os resultados dos experimentos referentes a: (i) ataques de reidentificação individual em uma única base de dados (RIU, Seção 4.2); (ii) ataques de reidentificação coletiva em uma única base de dados (RCU, Seção 4.3); (iii) ataques de inferência de atributo individual em uma única base de dados (AIU, Seção 4.4); e (iv) ataques de inferência de atributo coletiva em uma única base de dados (ACU, Seção 4.5).
- **Modelo de ataques longitudinais** (Seção 5): Nesta seção especificamos os ataques em que o adversário está tentando obter informação sensível a partir de um conjunto longitudinal de bases de dados. Nestes ataques o adversário pode se beneficiar de novas bases que são liberadas ao longo do tempo, usando-as como informação auxiliar para aumentar suas chances de sucesso. Iniciamos a Seção com uma exposição das premissas assumidas este tipo de ataque (Seção 5.1), e então apresentamos os modelos de: (i) ataques de reidentificação individual longitudinal (RIL, Seção 5.2); (ii) ataques de reidentificação coletiva longitudinal (RCL, Seção 5.3); (iii) ataques de inferência de atributo individual longitudinal (AIL, Seção 5.4); e (iv) ataques de inferência de atributo coletiva longitudinal (ACL, Seção 5.5). Cada ataque introduzido é seguido de um exemplo detalhado ilustrando como o adversário age passo a passo, e como seu sucesso é quantificado. Para propiciar uma leitura mais fluida do presente documento, os detalhes matemáticos da formalização dos ataques longitudinais é reservada ao Anexo A.2.
- **Avaliação experimental de ataques longitudinais nos Censos Educacionais** (Seção 6): Nesta seção apresentamos uma extensiva análise quantitativa experimental sobre riscos à privacidade decorrentes dos ataques em uma única base de dados introduzidos na Seção 5. Iniciamos a Seção com uma descrição da configuração dos experimentos (Seção 6.1), e então apresentamos os resultados dos experimentos referentes a: (i) ataques de reidentificação individual longitudinal (RIL, Seção 6.2); (ii) ataques de reidentificação coletiva longitudinal (RCL, Seção 6.3); (iii) ataques de inferência de atributo individual longitudinal (AIL, Seção 6.4); e (iv) ataques de inferência de atributo coletiva longitudinal (ACL, Seção 6.5).
- **Considerações finais** (Seção 7): Nesta seção apresentamos as considerações finais deste documento, incluindo uma seleção de destaques das lições aprendidas com as análises experimentais realizadas nos Censos Educacionais do Inep.

- **Anexos:** Apresentamos aqui o seguinte material suplementar.
 - **Formalização matemática dos ataques** (Anexo [A](#)): Neste anexo provemos a formalização matemática detalhada dos ataques tratados neste documento, incluindo os ataques em uma única base de dados (Anexo [A.1](#)) e os ataques longitudinais (Anexo [A.2](#)).
 - **A ferramenta ARX** (Anexo [B](#)): Neste anexo fazemos uma breve apresentação da ferramenta *ARX* [[15](#)], um software *open source* que tem o objetivo de fornecer métodos e algoritmos para quantificar, avaliar e promover a privacidade em bases de dados. Também apresentamos resultados experimentais realizados com a ferramenta ARX que corroboram independentemente os resultados de nossos experimentos sobre ataques de reidentificação coletiva em uma única base de dados.
- **Lista de siglas e Glossário** encerram o documento.

2 Fundamentação teórica

Nesta seção apresentamos a fundamentação teórica que serve de base para a formalização de ataques e para as análises de contidas deste documento. Iniciamos com a introdução de conceitos fundamentais sobre privacidade, como “adversário”, “ataque”, “informação auxiliar”, e “degradação de privacidade”. Seguimos a apresentação de uma classificação sistemática de ataques de acordo com: (i) o tipo de informação procurada pelo adversário, distinguindo entre “ataques de reidentificação” e “ataques de inferência de atributo sensível”; (ii) o foco do adversário, distinguindo entre “ataques focados em indivíduo” e “ataques coletivos”; e (iii) com quais são as bases acessíveis ao adversário, distinguindo entre “ataques em uma única bases de dados” e “ataques longitudinais”. Por fim, formalizamos o modelo de bases de dados que será utilizado nas seções seguintes.

2.1 Conceitos fundamentais

Iniciamos nossa formalização estabelecendo o significado técnico preciso de alguns termos da literatura sobre proteção à privacidade [2, 10, 19, 4, 5, 6, 13, 7, 12] que serão usados recorrentemente neste documento.

- **Informação sensível ou segredo:** informação considerada como digna de proteção. Exemplos típicos de informação sensível incluem dados pessoais de um indivíduo (e.g., número do cartão de crédito, senha bancária, ou condição médica), mas outros tipos de valores podem ser considerados sensíveis, como a própria identidade do indivíduo (e.g., caso o anonimato do remetente de uma mensagem seja importante, como em denúncias jornalísticas ou em países sujeitos a forte censura governamental), ou o território específico de circulação no qual pessoas em programas de proteção a testemunhas podem ser acessíveis. No contexto brasileiro, a LGPD [8], em seu Artigo 5º, inciso II, define como *dado pessoal sensível* todo aquele “dado pessoal sobre origem racial ou étnica, convicção religiosa, opinião política, filiação a sindicato ou a organização de caráter religioso, filosófico ou político, dado referente à saúde ou à vida sexual, dado genético ou biométrico, quando vinculado a uma pessoa natural”. Neste documento nos focamos nos seguintes tipos de segredos:

- a *ligação de um registro na base de dados a seu titular*, que é a informação sensível relevante em um ataque de reidentificação; e
 - o *valor de um atributo sensível de um indivíduo*, que é a informação sensível relevante em um ataque de inferência de atributo.
- **Adversário:** entidade contra quem se deseja proteger a informação sensível sobre indivíduos. O adversário pode ser uma pessoa física ou uma organização. É importante notar que não necessariamente se atribuem intenções deletérias ao adversário: é possível que um consumidor legítimo de uma divulgação estatística (e.g., um pesquisador acadêmico) atue inadvertidamente como adversário ao inferir informação sensível de indivíduos no decurso de suas ações idôneas.
 - **Quaseidentificadores:** atributos que não são, em si mesmos, identificadores únicos de um indivíduo (como nome, CPF ou RG), mas que estão suficientemente correlacionadas com o titular a ponto de poderem ser combinadas com outros quaseidentificadores para criar um identificador exclusivo. Por exemplo, Sweeney demonstrou em 2000 que o *zip-code* (o equivalente americano ao CEP brasileiro), o gênero e a data de nascimento de um indivíduo são quaseidentificadores poderosos, uma vez que 87% da população dos EUA poderia ser unicamente identificada usando-se apenas estes três atributos combinados [20].
 - **Informação auxiliar ou lateral:** em relação a uma divulgação de dados de interesse, informação auxiliar é qualquer informação que se possa obter a respeito de um indivíduo através de outros canais que não sejam a divulgação de dados de interesse em si mesma (e.g, via *web*, outros registros públicos, jornais ou revistas, conhecimento prévio). Um exemplo de obtenção de informação auxiliar por parte do adversário é quando ele consegue via outras fontes (e.g., um cartório) o valor de um quaseidentificador de um indivíduo (e.g., sua data de nascimento).
 - **Ataque:** ação ou conjunto de ações pelas quais o adversário pode obter informação sensível sobre indivíduos. É importante notar que também ao termo “ataque” não se atribui uma intenção necessariamente deletéria: uma utilização legítima dos dados (e.g., para pesquisa científica) pode resultar inadvertidamente em um ataque se porventura revelar informação sensível.
 - **Conhecimento a priori e sucesso a priori do adversário:** antes mesmo de o ataque ser realizado, presume-se que o adversário tenha algum *conhecimento a priori* sobre o segredo. Tal conhecimento pode advir de várias fontes: informação prévia sobre a distribuição de probabilidade a partir da qual o segredo foi amostrado (e.g., em caso de segredos aleatórios, como uma senha automaticamente gerada por um aplicativo); fontes auxiliares de informação (como jornais, revistas, mídia, ou conhecimento comum); ou mesmo de ataques anteriores. O *sucesso a priori do adversário* é, então, uma medida (determinística ou probabilística) do quanto de informação sensível o adversário já possui antes mesmo de executar um ataque, usando apenas seu conhecimento a priori.

Por exemplo, considere um cenário em que a informação sensível seja o dia da semana em que um indivíduo escolhido como alvo nasceu. Antes mesmo de executar o ataque, o adversário pode ter o conhecimento a priori (advindo, e.g., de jornais, revistas, censos demográficos, etc.) de que a distribuição de datas de nascimento na população em que o indivíduo alvo se insere é uniforme sobre os dias da semana. Usando apenas essa informação, o adversário poderia “adivinhar no escuro”¹ dia de nascimento do indivíduo-alvo e mesmo assim teria uma chance de 1 em 7 de inferir corretamente o valor do atributo sensível. Nesse caso, sua probabilidade de sucesso a priori na inferência do atributo sensível pode ser quantificada como $1/7 \approx 14\%$.

- **Conhecimento a posteriori e sucesso a posteriori do adversário:** ao longo da execução do ataque, o adversário combina suas observações dos resultados obtidos com seu conhecimento a priori e revisa sua informação sobre o segredo para chegar ao que se chama de *conhecimento a posteriori*. O *sucesso a posteriori do adversário* é, então, uma medida (determinística ou probabilística) do quanto de informação sensível o adversário detém após a execução do ataque.

Considere novamente o exemplo acima em que o segredo é o dia da semana em que um indivíduo nasceu. Suponha que o adversário execute um ataque sobre uma base de dados que contém informação sobre o indivíduo-alvo e averigue, assim, que esse indivíduo não nasceu nem em um sábado nem em um domingo. Neste caso o adversário revisa seu conhecimento a priori (de que qualquer dia da semana é igualmente provável como valor do atributo sensível) para um conhecimento a posteriori (de que qualquer dia entre segunda-feira e sexta-feira são igualmente prováveis como valor do atributo sensível, enquanto sábado e domingo estão descartados). Consequentemente, a probabilidade de sucesso a posteriori do adversário (i.e., a sua chance de inferir corretamente o valor do atributo sensível após a realização do ataque) neste caso é de $1/5 = 20\%$.

- **Degradação de privacidade:** um princípio fundamental da formalização de privacidade é que a degradação de privacidade de um ataque é uma comparação entre o sucesso a priori do adversário (i.e., informação a respeito do segredo antes mesmo da execução do ataque, contando apenas com seu conhecimento a priori) e seu sucesso a posteriori (i.e., informação a respeito do segredo após a executar o ataque, contando já com seu conhecimento a posteriori). Intuitivamente, quanto maior a degradação de privacidade de um ataque, maior êxito do adversário em obter informação sensível a respeito de seu alvo e maior o dano incorrido à privacidade *por*

¹Em vários momentos deste documento usamos a expressão “adivinhar no escuro” para descrever a melhor estratégia possível para se estimar o valor de uma variável desconhecida. Apesar do uso desta expressão informal, tal abordagem é solidamente baseada no *Princípio da máxima entropia*, que afirma que a distribuição de probabilidade que melhor representa um estado de conhecimento é aquela com a maior entropia possível, dadas as informações já conhecidas [11]. No nosso contexto, isso geralmente significa que, na ausência de mais informação, deve-se assumir que a distribuição de probabilidade sobre um conjunto é uniforme e, portanto, o melhor que o adversário tem a fazer é mesmo “adivinhar no escuro” o valor de uma variável desconhecida.

*causa direta do ataque.*²

Quando a comparação se faz pela razão entre o sucesso a posteriori e o sucesso a priori do adversário, temos uma *medida multiplicativa de degradação de privacidade* [3, 1]:

$$\text{degradação multiplicativa de privacidade} \stackrel{\text{def}}{=} \frac{\text{sucesso do adversário a posteriori}}{\text{sucesso do adversário a priori}}.$$

Já quando a comparação é feita tomando-se a diferença entre o sucesso a posteriori e o sucesso a priori do adversário, temos uma *medida aditiva de degradação de privacidade* [3, 1]:

$$\text{degradação aditiva de privacidade} \stackrel{\text{def}}{=} \text{sucesso do adversário a posteriori} - \text{sucesso do adversário a priori}.$$

Ainda considerando o mesmo exemplo de data de aniversário acima, a degradação multiplicativa de privacidade devida ao ataque seria de $(1/5)/(1/7) = 7/5 = 1.4$, indicando que a realização do ataque conferiria ao adversário um ganho relativo de 40% em sua chance de sucesso na inferência do atributo sensível. Por outro lado, a degradação aditiva de privacidade devida ao ataque seria dada pela diferença $1/5 - 1/7 = 2/35 \approx 0.06$, indicando que a realização do ataque conferiria ao adversário um ganho absoluto de aproximadamente 6% em sua chance de sucesso na inferência do atributo sensível.

²Como ilustração da razão pela qual a degradação de privacidade é definida como o *aumento na medida de sucesso do adversário devido a um ataque*, em vez de simplesmente como a medida de sucesso a posteriori (i.e., após a execução do ataque), apreciemos os seguintes exemplos. Considere novamente o cenário em que a informação sensível é o dia da semana em que um indivíduo-alvo nasceu. Suponha que o ataque consista em o adversário acessar uma base de dados em que o indivíduo está representado, juntamente com seu CPF e dia de nascimento, e usar o CPF do indivíduo como informação auxiliar para recuperar a informação sensível. Entretanto, dessa vez, suponha que um adversário *A* já tenha como conhecimento a priori (por exemplo, porque ele teve acesso à certidão do nascimento do indivíduo e cruzou essa informação com um calendário) de que o indivíduo nasceu em uma segunda-feira. Como o CPF é único, esse adversário terá sucesso em reidentificar o indivíduo na base e recuperar o seu dia de nascimento como uma segunda-feira. Note, entretanto, que *o ataque em si não alterou a informação que o adversário A já tinha sobre o segredo*. Intuitivamente, portanto, este ataque pode ser considerado inócuo, já que o sucesso a posteriori do adversário permanece o mesmo que seu sucesso a priori. Por outro lado, considere um adversário *B* cujo conhecimento a priori (e.g, vindo de informação auxiliar, ou de um ataque anterior) seja apenas de que é igualmente provável que o indivíduo alvo tenha nascido em qualquer dia entre segunda-feira e sexta-feira, mas não no final de semana. Claramente, assim como o adversário *A*, o adversário *B* também atinge certeza absoluta, após realizar o ataque, de que o indivíduo nasceu em uma segunda-feira. Entretanto, note que no caso do adversário *B* o ataque aumenta seu conhecimento sobre o segredo e pode, intuitivamente, ser considerado de alguma forma eficaz. Portanto, apesar do sucesso a posteriori de ambos os adversários *A* e *B* ser o mesmo (ambos sabem com certeza, a posteriori, o dia de nascimento do indivíduo alvo), a contribuição do ataque em si para o estabelecimento desse conhecimento é distinta em cada caso: para o adversário *A* o ataque não altera sua medida de sucesso, enquanto que para o adversário *B* o ataque aumenta significativamente sua medida de sucesso. Por essa razão, considera-se que a degradação de privacidade causada pelo ataque seja maior no caso do adversário *B* do que no caso do adversário *A*.

Na quantificação de degradação de privacidade, podemos distinguir entre os seguintes tipos principais de métricas de sucesso (sejam elas a priori ou a posteriori) do adversário.

- **Métricas determinísticas de sucesso:** mensuram o sucesso do adversário de forma absoluta –i.e., retornam um valor qualitativo dependendo de se a informação desejada foi ou não recuperada com absoluta certeza.

Exemplos típicos de métricas determinísticas incluem o número de indivíduos em uma base de dados que podem ser unicamente reidentificados, ou ter o valor de um atributo sensível inferido, com absoluta certeza.

- **Métricas probabilísticas de sucesso:** provêm um valor quantitativo representando o grau de certeza com o qual a informação desejada foi recuperada.

Exemplos típicos de métricas probabilísticas incluem a chance de que um indivíduo aleatoriamente selecionado como alvo seja reidentificado em uma base de dados, ou a probabilidade de que um indivíduo tenha o valor de seu atributo sensível corretamente inferido, mesmo que sem absoluta certeza.

2.2 Classificação de tipos de ataque

Neste documento consideramos ataques classificados de acordo com as três dimensões seguintes.

(I) Quanto ao tipo de informação procurada pelo adversário:

- **Ataques de reidentificação:** o objetivo do adversário é determinar uma correspondência entre registros presentes na base de dados e os titulares desses registros, i.e., os indivíduos do mundo real a quem os registros se referem.
- **Ataques de inferência de atributo sensível:** o objetivo do adversário é inferir o valor assumido por um atributo considerado como sensível para alguns indivíduos, independentemente de se estes indivíduos tenham sido reidentificados com sucesso ou não.

Note que ataques de reidentificação são, em geral, mais poderosos que ataques de inferência de atributo sensível, uma vez que o sucesso na reidentificação de um indivíduo implica o consequente sucesso na inferência de todos os seus atributos.³

(II) Quanto ao foco do adversário:

³Uma terceira classificação de ataques quanto ao tipo de informação procurada pelo adversário é a conhecida como *ataque de pertinência*. Nesse tipo de ataque, o objetivo do adversário é inferir se indivíduos estão ou não representados em uma base de dados, i.e., determinar se há ou não registros na base de quem o indivíduo seja titular. Neste documento não consideramos este tipo de ataque uma vez que em todos os cenários considerados assumimos que o adversário tem conhecimento de que todos os indivíduos de interesse estão representados na base de dados.

	Em uma única base (U)		Longitudinal (L)	
	Focado em indivíduo (I)	Coletivo (C)	Focado em indivíduo (I)	Coletivo (C)
Reidentificação (R)	RIU	RCU	RIL	RCL
Inferência de atributo (A)	AIU	ACU	AIL	ACL

Tabela 2.2.1: Tipos de ataques cobertos neste documento e seus acrônimos.

- **Ataques focados em indivíduo:** o objetivo do adversário é obter informação sensível a respeito de um indivíduo específico pré-determinado como alvo.
- **Ataques coletivos:** o objetivo do adversário é obter informação sensível a respeito do maior número possível de indivíduos, independentemente de quem sejam esses indivíduos.

(III) **Quanto às bases de dados acessíveis ao adversário:**

- **Ataques em uma única base de dados:** o adversário tem acesso a uma única base de dados, referente a um ponto específico do tempo.
- **Ataques longitudinais:** o adversário tem acesso a várias versões da base de dados, cada uma referente a um ponto distinto do tempo.

É importante ressaltar que ataques longitudinais são, em geral, mais poderosos que ataques em uma única base de dados, uma vez que o adversário pode cruzar a informação presente em várias bases (e.g., várias versões anuais de uma mesma pesquisa educacional) para aumentar sua medida de sucesso.

Levando em conta as variações de ataques nas três dimensões descritas acima, obtemos os 8 tipos distintos de ataques considerados neste documento, organizados por seus acrônimos na Tabela 2.2.1. Os ataques em uma única base de dados são especificados na Seção 3, enquanto os ataques longitudinais são cobertos na Seção 5. Antes, porém, na próxima seção formalizamos os modelos de bases de dados, registros e atributos.

2.3 Modelos de bases de dados, registros e atributos

Aqui formalizamos nosso modelo de “base de dados”, que é uma coleção de “registros” ou “linhas”, cada uma consistindo em uma tupla de valores correspondendo a “atributos” ou “colunas”. Os conceitos aqui introduzidos são ilustrados no Exemplo 1, e servirão de

base para as Seções 3 e 5 que apresentam, respectivamente, os ataques em única base de dados e longitudinais considerados neste documento.

Os elementos do modelo são os seguintes.

- Seja $\mathcal{A} = \{a_1, \dots, a_m\}$ um conjunto (finito) de *atributos* ou *colunas* em algum cenário de interesse. Para todo $1 \leq i \leq m$, denotamos por $\text{dom}(a_i)$ o domínio de todos os valores que o atributo a_i pode assumir.
- Um *registro* (ou *linha*) x é um mapeamento de atributos para valores, i.e., $x = \langle x[a_1], \dots, x[a_m] \rangle$, onde $x[a_i] \in \text{dom}(a_i)$ é o valor assumido pelo atributo a_i no registro x . O domínio de todos os registros possíveis sobre o conjunto de atributos $\mathcal{A}$ é denotado por $\text{registros}(\mathcal{A}) = \text{dom}(a_1) \times \dots \times \text{dom}(a_m)$.
- Uma *base de dados* sobre um conjunto de atributos $\mathcal{A}$ é um multiconjunto (finito) $D = \{\{x_1, x_2, \dots, x_n\}\}$ de registros, cada um pertencendo a $\text{registros}(\mathcal{A})$.⁴ Denotamos por $\text{mult}_D(x)$ a *multiplicidade* (i.e., o número de ocorrências distintas) do registro x na base de dados D , e por $|D| = \sum_{x \in \text{registros}(\mathcal{A})} \text{mult}_D(x)$ a *cardinalidade* (i.e., o número total de registros, incluindo repetições) de D .
- Dado um subconjunto $\mathcal{A}' \subseteq \mathcal{A}$ de atributos, denotamos por $x[\mathcal{A}']$ o *sub-registro* (ou a *sub-linha*) de x consistindo na projeção de x sobre $\mathcal{A}'$, i.e., a subtupla de x contendo apenas os valores correspondentes àqueles atributos em $\mathcal{A}'$. Os sub-registros correspondendo a atributos em $\mathcal{A}' = \{a_{i_1}, \dots, a_{i_k}\}$ têm como domínio o conjunto $\text{registros}(\mathcal{A}') = \text{dom}(a_{i_1}) \times \dots \times \text{dom}(a_{i_k})$.
- Denotamos por $D/\sim_{\mathcal{A}'}$ a partição sobre registros da base de dados D induzida pelos atributos $\mathcal{A}' \subseteq \mathcal{A}$.⁵ Intuitivamente, a partição quebra a base de dados D em vários blocos, sendo que cada bloco agrupa todos os registros que compartilhem os mesmos valores para os atributos em $\mathcal{A}'$. Denotamos por $\text{bloco}_{D/\sim_{\mathcal{A}'}}(a)$ o bloco da partição $D/\sim_{\mathcal{A}'}$ que contém os registros $x \in D$ que contém o valor a para os atributos $\mathcal{A}'$, ou seja,

$$\text{bloco}_{D/\sim_{\mathcal{A}'}}(a) \stackrel{\text{def}}{=} \{x \in D \mid x[\mathcal{A}'] = a\}.$$

A seguir apresentamos aquele que servirá como nosso exemplo condutor ao longo da formalização de ataques e suas métricas de sucesso nas seções seguintes.

Exemplo 1 (Exemplo condutor para ataques em uma única base de dados). Considere o cenário de interesse em que o conjunto de atributos seja $\mathcal{A} = \{id, idade, sexo, profissão, condição\}$, especificado como:

⁴Um *multiconjunto* é a generalização de um conjunto, de tal forma que se permite a repetição de elementos. Ao usar multiconjuntos para modelar bases de dados, estamos permitindo que um mesmo registro apareça múltiplas vezes em uma mesma base.

⁵Formalmente, uma *partição* P em um conjunto $\mathcal{X}$ é uma coleção $P = \{\mathcal{X}_1, \mathcal{X}_2, \dots, \mathcal{X}_k\}$ de *blocos* tais que: (i) $\mathcal{X}_i \subseteq \mathcal{X}$ para todo $1 \leq i \leq k$; (ii) $\mathcal{X}_i \cap \mathcal{X}_j = \emptyset$ para todo $1 \leq i, j \leq k$ e $i \neq j$; e (iii) $\bigcup_{i=1}^k \mathcal{X}_i = \mathcal{X}$.

- $dom(id) = \{1, 2, 3, \dots\}$, consistindo na identificação única de um indivíduo, formada por um número inteiro positivo;
- $dom(idade) = \{0, 1, 2, \dots, 120\}$, consistindo na idade de um indivíduo, em anos completos;
- $dom(sexo) = \{F, M\}$, indicando se um indivíduo é do sexo feminino (F) ou masculino (M);
- $dom(profissão) = \{1, 2, 3, 4, 5\}$, indicando a atividade profissional de um indivíduo de acordo uma categorização de interesse;
- $dom(condição) = \{asma, coração\}$, indicando se o indivíduo é portador de uma condição respiratória (*asma*) ou cardíaca (*coração*).

A Tabela 2.3.2 representa uma base de dados D formada por 10 registros (de modo que sua cardinalidade é $|D| = 10$), cada um deles uma tupla de valores proveniente do domínio $registros(\mathcal{A}) = dom(id) \times dom(idade) \times dom(sexo) \times dom(profissão) \times dom(condição)$ de todos os registros possíveis. Cada registro em D contém dados a respeito de um indivíduo de uma população de interesse (e.g., em um censo, pesquisa educacional, ou médica).

Considerando o subconjunto $\{sexo, condição\} \subseteq \mathcal{A}$ de atributos e tomando o indivíduo x como aquele representado pela tupla $\langle 1, 25, F, 1, coração \rangle$, o sub-registro correspondente a este indivíduo é dado por $x[\{sexo, condição\}] = \langle F, coração \rangle$. A partição $D/\sim_{\{sexo, condição\}}$ sobre D induzida por este subconjunto de atributos consiste em quatro blocos, um para cada combinação possível de sexo e condição, como a seguir:

- um bloco para todos os registros x tais que $x[\{sexo, condição\}] = \langle M, asma \rangle$, o que inclui o indivíduo de *id* 4;
- um bloco para todos os registros x tais que $x[\{sexo, condição\}] = \langle M, coração \rangle$, o que inclui os registros de *id*'s 5, 9 e 10;
- um bloco para todos os registros x tais que $x[\{sexo, condição\}] = \langle F, asma \rangle$, o que inclui os registros de *id*'s 2, 3, 6 e 7; e
- um bloco para todos os registros x tais que $x[\{sexo, condição\}] = \langle F, coração \rangle$, o que inclui os registros de *id*'s 1 e 8.

◁

<i>id</i>	<i>idade</i>	<i>sexo</i>	<i>profissão</i>	<i>condição</i>
1	25	F	1	coração
2	25	F	1	asma
3	25	F	3	asma
4	25	M	2	asma
5	25	M	2	coração
6	49	F	3	asma
7	49	F	3	asma
8	49	F	5	coração
9	49	M	4	coração
10	60	M	4	coração

Tabela 2.3.2: Base de dados D para o Exemplo 1.

3 Modelo de ataques em uma única base de dados

Nesta seção especificamos os ataques em que o adversário está tentando obter informação sensível a partir de uma única base de dados. Baseados na fundamentação teórica exposta na Seção 2, nosso modelo assume que o adversário tem acesso completo a uma única base dos Censos Educacionais divulgadas pelo Inep em sua forma atual, em que se empregam desidentificação e pseudonimização como métodos de proteção de privacidade. O modelo mede, então, a degradação de privacidade de cada ataque em termos do quanto a informação auxiliar a respeito de quaseidentificadores obtida por um adversário pode facilitar a reidentificação ou a inferência de atributos sensíveis de indivíduos na base. Cada ataque introduzido é seguido de um exemplo detalhado ilustrando como o adversário age passo a passo, e como seu sucesso é quantificado. Para propiciar uma leitura mais fluida do presente documento, os detalhes matemáticos da formalização dos ataques em uma única base de dados é reservada ao Anexo A.1. As análises experimentais quantitativas da aplicação do modelo às bases dos Censos Educacionais do Inep são apresentadas na Seção 4.

3.1 Premissas sobre ataques em uma única base de dados

Para todos os ataques em uma única base de dados apresentados a seguir, assumimos as seguintes premissas.

- PS0** Existe uma base de dados D de interesse definida sobre um conjunto de atributos $\mathcal{A}$.
- PS1** Cada indivíduo de interesse possui no máximo um registro na base de dados D .
- PS2** Existe um conjunto $\mathcal{Q}_{ID \in \mathcal{A}}$ de *quaseidentificadores* correspondendo a atributos cujos valores para alguns indivíduos podem ser conhecidos ou aprendidos pelo adversário.

PS3 A partir da base de dados D pode-se derivar uma *distribuição de probabilidade a priori* $\pi^D : \mathbb{D}(\text{registros}(\mathcal{A}))$ sobre registros da seguinte forma. Para cada registro $x \in \text{registros}(\mathcal{A})$, sua probabilidade π_x^D é sua frequência relativa na base D :

$$\pi_x^D \stackrel{\text{def}}{=} \frac{\text{mult}_D(x)}{|D|}. \quad (3.1)$$

A partir da distribuição π^D sobre registros, pode-se derivar a distribuição de probabilidade marginal $\pi^{\mathcal{A}'|D}$ sobre os valores de qualquer subconjunto $\mathcal{A}' \subseteq \mathcal{A}$ de atributos da forma usual. Mais precisamente, a probabilidade $\pi_a^{\mathcal{A}'|D}$ de cada valor $a \in \text{dom}(\mathcal{A}')$ é dada por:

$$\pi_a^{\mathcal{A}'|D} \stackrel{\text{def}}{=} \sum_{\substack{x \in D, \\ x[\mathcal{A}'] = a}} \pi_x^D = \sum_{\substack{x \in D, \\ x[\mathcal{A}'] = a}} \frac{\text{mult}_D(x)}{|D|} = \sum_{x \in D} \frac{|\{x \in D \mid x[\mathcal{A}'] = a\}|}{|D|}. \quad (3.2)$$

PS4 O conhecimento prévio do adversário inclui toda a base de dados D e o fato de que todos os indivíduos de interesse encontram-se na base.¹ O ataque consiste em o adversário obter como informação auxiliar (via outras fontes que não a base D) os valores dos quaseidentificadores em $\mathcal{Q}_{ID}$ para alguns indivíduos e usar esses valores para obter informação sensível a respeito destes indivíduos em D . A degradação de privacidade é, portanto, medida como a comparação do sucesso do adversário a posteriori –i.e., após usar a informação auxiliar sobre os valores dos quaseidentificadores– e seu sucesso a priori –i.e., antes de poder usar a informação sobre quaseidentificadores. Esses elementos são esquematizados na Figura 3.1.1.

O seguinte exemplo demonstra como o adversário pode usar seu conhecimento a priori sobre a base de dados para derivar distribuições de probabilidade sobre os valores de qualquer subconjunto dos atributos.

Exemplo 2 (Distribuição de probabilidade marginal sobre um subconjunto de atributos). Considere novamente a base de dados D sobre o conjunto $\mathcal{A}$ de atributos descrita no

¹O uso de bases amostrais quebraria a premissa de que o adversário já sabe a priori que todos os indivíduos estão na base. No geral, isto pode levar a uma significativa redução do risco médio dos indivíduos na base (tanto de reidentificação quanto de inferência de atributo), mas não provê garantias absolutas. Por exemplo, considere que um adversário tenha a informação auxiliar de que no Departamento de Ciência da Computação da UFMG (DCC) só haja um docente de origem holandesa. Caso seja criada uma base amostral em cima do conjunto de professores do DCC, e o docente holandês seja selecionado para fazer parte desta base (e a base contiver um atributo que indique seu país de origem), o adversário poderá facilmente reidentificar o alvo na base. Apesar da inclusão do docente holandês na base amostral ser um evento de probabilidade potencialmente pequena, isso não necessariamente traria conforto a ele uma vez que sua privacidade tenha sido violada. De qualquer forma, no presente documento adotamos a Premissa **PS4** porque ela reflete a atual forma de divulgação dos Censos Educacionais pelo Inep. Maneiras mais seguras de se eliminar esta premissa serão discutidas no Produto 03 do presente TED 8750, que trata de métodos de mitigação de degradação de privacidade que podem ser empregados pelo Inep na divulgação de seus Censos Educacionais.




Figura 3.1.1: Esquema de ataque em uma única base de dados. No tipo de ataque aqui considerado a degradação de privacidade é medida em termos do quanto a informação auxiliar a respeito de quaseidentificadores obtida por um adversário pode facilitar a reidentificação ou a inferência de atributos sensíveis de indivíduos nas bases dos Censos Educacionais divulgadas pelo Inep na forma atual.

Exemplo 1, e assuma a distribuição de probabilidade π^D sobre os registros de D definida na Equação 3.1. Se considerarmos o subconjunto de atributos $\{sexo, condição\} \subseteq \mathcal{A}$, podemos observar que seu domínio é

$$\text{dom}(\{sexo, condição\}) = \{\langle F, asma \rangle, \langle F, coração \rangle, \langle M, asma \rangle, \langle M, coração \rangle\}.$$

Podemos, então, computar a correspondente distribuição marginal $\pi^{\{sexo, condição\}|D}$ derivada a partir da frequência de registros em D . Mais precisamente,

$$\pi_{\langle F, asma \rangle}^{\{sexo, condição\}|D} = \sum_{\substack{x \in D, \\ x[\{sexo, condição\}] = \langle F, asma \rangle}} \pi_x^D = \sum_{\substack{x \in D, \\ x[\{sexo, condição\}] = \langle F, asma \rangle}} \frac{\text{mult}_D(x)}{|D|} = \frac{4}{10},$$

e, de forma análoga,

$$\pi_{\langle F, coração \rangle}^{\{sexo, condição\}|D} = 2/10, \quad \pi_{\langle M, asma \rangle}^{\{sexo, condição\}|D} = 1/10, \quad \text{e} \quad \pi_{\langle M, coração \rangle}^{\{sexo, condição\}|D} = 3/10.$$

◁

Estamos, então, prontos para definir a seguir os ataques em uma única base de dados de que tratamos neste documento.

3.2 Ataque de reidentificação individual em uma única base de dados (RIU)

Em um *ataque de reidentificação individual em uma única base de dados (RIU)*, o adversário tem acesso completo a uma única base de dados –conhecendo todos os seus registros– e é capaz de obter como informação auxiliar os valores de um conjunto de quase-identificadores de um indivíduo específico pré-determinado como alvo. O adversário tem como objetivo reidentificar o indivíduo-alvo, i.e., estabelecer qual registro na base de dados corresponde a esse indivíduo.

A degradação de privacidade do ataque é medida como uma comparação entre o sucesso a priori do adversário (i.e., conhecendo apenas a base de dados, mas não ainda os valores dos quase-identificadores) e seu sucesso a posteriori (i.e., após descobrir os valores dos quase-identificadores e cruzá-los com a base de dados). Mais precisamente, temos as seguintes condições para um ataque RIU:

- **Quantificação da degradação determinística de privacidade:** Ocorre degradação determinística de privacidade em um ataque RIU se, e somente se, o adversário não for capaz de reidentificar com absoluta certeza o indivíduo pré-determinado como alvo antes de efetuar o ataque, mas for capaz de fazê-lo após efetuar o ataque.
- **Quantificação da degradação probabilística de privacidade:** Na medição do sucesso probabilístico de um ataque RIU, não se exige que o adversário realize a reidentificação do indivíduo pré-determinado como alvo com absoluta certeza; em vez disso quantifica-se a probabilidade de que o adversário corretamente reidentifique tal indivíduo-alvo na base. Quanto maior essa probabilidade, mais exitoso é o adversário. A degradação probabilística de privacidade do ataque é definida, então, como a razão pela qual sua execução aumenta o sucesso probabilístico do adversário.

A Definição 24 no Anexo A.1 formaliza matematicamente o ataque RIU. A seguir ilustramos como o ataque é executado em nosso exemplo condutor.

Exemplo 3 (Execução de ataque de reidentificação individual em uma única base de dados (RIU)). Considere novamente a base de dados D sobre o conjunto de atributos $\mathcal{A}$ do Exemplo 1. Recorde que, de acordo com as hipóteses sobre ataques em uma única base, cada indivíduo de interesse possui no máximo um registro em D e que a distribuição de probabilidade a priori π^D é derivada de acordo com Equação 3.1.

Assuma que o adversário está interessado em reidentificar os registros de dois indivíduos pré-determinados como alvo: Alex e Bia. Adicionalmente, considere que o adversário consegue obter como informação auxiliar os valores dos seguintes quase-identificadores para cada um desses indivíduos:

- Alex é do sexo masculino e tem 60 anos, ou seja, os quaseidentificadores de Alex são $\mathcal{Q}'_{ID} = \{sexo, idade\}$; e
- Bia é do sexo feminino e sua profissão pertence ao grupo 1 –ou seja, os quaseidentificadores de Bia são $\mathcal{Q}''_{ID} = \{sexo, profissão\}$.

Vamos, então, computar a degradação determinística e probabilística de privacidade para ambos os indivíduos.

• Degradação determinística de privacidade

Note que, como a base de dados D possui mais que um registro, nem Alex nem Bia podem ser reidentificados com certeza absoluta na base sem uso de informação auxiliar de quaseidentificadores. Portanto, para nenhum dos alvos o adversário atinge sucesso determinístico a priori.

Entretanto, na realização de um ataque com o objetivo de reidentificar Alex, o adversário tem como informação auxiliar o sub-registro $x_{Alex}^*[\{sexo, idade\}] = \langle M, 60 \rangle$ correspondendo aos valores de seus quaseidentificadores. Note que existe exatamente um registro na base que apresenta os mesmos valores de quaseidentificadores de Alex: o registro com *id* 9. Dessa forma, o ataque de reidentificação determinística sobre Alex é exitoso (descobre-se que ele é o indivíduo com *id* 9), e atinge-se sucesso determinístico a posteriori em relação a este alvo. Como a realização do ataque usando sexo e idade como informação auxiliar permite ao adversário passar a ser capaz de reidentificar Alex com absoluta certeza na base de dados, há degradação determinística de privacidade em relação a Alex.

Por outro lado, ao realizar um ataque com o objetivo de reidentificar Bia, o adversário tem como informação auxiliar o sub-registro $x_{Bia}^*[\{sexo, profissão\}] = \langle F, 1 \rangle$ correspondendo aos valores de seus quaseidentificadores. Nesse caso, a tentativa de reidentificação determinística a posteriori de Bia não é exitosa, uma vez que existem dois registros na base com os mesmos valores de quaseidentificadores: os registros de *id*'s 1 e 2. Portanto, o ataque usando sexo e grupo profissional como informação auxiliar não passa a permitir ao adversário reidentificar Bia com absoluta certeza na base, e não há degradação determinística de privacidade em relação a ela.

• Degradação probabilística de privacidade

Note que o ataque determinístico, apesar de exitoso contra Alex, não permitiu a reidentificação com absoluta certeza de Bia. Entretanto, ainda é possível para o adversário ter algum sucesso probabilístico no caso de Bia.

Em primeiro lugar, note que o sucesso probabilístico a priori do adversário em relação a Bia é de 10%, uma vez que sem acesso a quaseidentificadores a chance de o adversário “adivinhar no escuro” qual registro em D corresponde a Bia é de 1 em 10 (pois a base tem 10 registros).

Entretanto, ao realizar o ataque, o adversário usa a informação auxiliar de que os valores dos quaseidentificadores de Bia são $x_{Bia}^*[\{sexo, profissão\}] = \langle F, 1 \rangle$ para reduzir a quantidade de registros em D passíveis de serem atribuídos a Bia a apenas dois: os registros com *id*'s 1 e 2. Como agora o adversário só precisa “adivinhar no escuro” entre duas possibilidades, seu sucesso probabilístico a posteriori em relação a Bia passa a ser de 50%.

A correspondente degradação probabilística de privacidade de Bia é, portanto, a razão $50\%/10\% = 5$, o que reflete que o ataque usando sexo e profissão como informação auxiliar aumenta a probabilidade de o adversário reidentificar Bia em 5 vezes.

◁

3.3 Ataque de reidentificação coletiva em uma única base de dados (RCU)

Em um *ataque de reidentificação coletiva em uma única base de dados (RCU)*, o adversário tem acesso completo a uma única base de dados –conhecendo todos os seus registros– e é capaz de obter como informação auxiliar os valores de um conjunto de quaseidentificadores para todos os indivíduos cujos registros estão na base. O adversário tem como objetivo reidentificar o maior número possível de indivíduos, independentemente de quem sejam esses indivíduos.

A degradação de privacidade do ataque é medida como uma comparação entre o sucesso a priori do adversário (i.e., conhecendo apenas a base de dados, mas não ainda os valores dos quaseidentificadores) e seu sucesso a posteriori (i.e., após descobrir os valores dos quaseidentificadores e cruzá-los com a base de dados). Mais precisamente, temos as seguintes condições para um ataque RCU:

- **Quantificação da degradação determinística de privacidade:** A medição do sucesso determinístico de um ataque coletivo RCU leva em conta que adversário tem como alvo todos os indivíduos da base; portanto, define-se tal sucesso como a fração de indivíduos na base que pode ser reidentificada com absoluta certeza. A degradação determinística de privacidade do ataque é definida, então, como a diferença pela qual sua execução aumenta o sucesso determinístico do adversário.
- **Quantificação da degradação probabilística de privacidade:** Na medição do sucesso probabilístico de um ataque coletivo RCU, não se exige que o adversário realize a reidentificação de todos os indivíduos com absoluta certeza; em vez disso quantifica-se a probabilidade de um indivíduo aleatoriamente escolhido como alvo ser reidentificado com sucesso. Quanto maior essa probabilidade, mais exitoso é o adversário, e maior é o risco esperado de cada indivíduo presente na base ser

reidentificado. A degradação probabilística de privacidade do ataque é definida, então, como a razão pela qual sua execução aumenta o sucesso probabilístico do adversário.

A Definição 25 no Anexo A.1 formaliza matematicamente o ataque RCU. A seguir ilustramos como o ataque é executado em nosso exemplo condutor.

Exemplo 4 (Execução de ataque de reidentificação coletiva em uma única base de dados (RCU)). Considere novamente a base de dados D sobre o conjunto de atributos $\mathcal{A}$ do Exemplo 1. Recorde que, de acordo com as hipóteses sobre ataques em uma única base, cada indivíduo de interesse possui no máximo um registro em D e que a distribuição de probabilidade a priori π^D é derivada de acordo com Equação 3.1. Também assuma que o adversário está interessado em reidentificar os registros de todos os indivíduos presentes em D .

Considere que o adversário tem como informação auxiliar os valores do quaseidentificador $\mathcal{Q}'_D = \{\text{idade}\}$ para todos os indivíduos na base de dados. Vamos computar tanto a degradação determinística de privacidade quanto a probabilística para este adversário.

- **Degradação determinística de privacidade**

Como a base de dados D possui mais do que um registro, nenhum indivíduo na base pode ser reidentificado com certeza sem informação auxiliar. Dessa forma, o sucesso determinístico a priori do adversário é de 0%, pois esta é a fração de indivíduos reidentificáveis com absoluta certeza na base.

Ao realizar o ataque, entretanto, o adversário pode utilizar a idade dos indivíduos como informação auxiliar. Note, porém, que em D apenas um registro possui idade única (o registro de *id* 10, cuja idade é 60), significando que apenas um registro na base pode ser reidentificado com absoluta certeza apenas pelo valor da idade. Como o tamanho da base é $|D| = 10$, o sucesso determinístico a posteriori do adversário é de 10%, significando que usando apenas idade como informação auxiliar o adversário pode reidentificar 10% dos registros na base.

A correspondente degradação determinística de privacidade é, então de $10\% - 0\% = 10\%$, significando que o uso de idade como informação auxiliar produz um aumento absoluto de 10% na quantidade de registros que passam a ser reidentificáveis com absoluta certeza na base de dados.

- **Degradação probabilística de privacidade**

Note que sem informação auxiliar, o melhor que o adversário pode fazer para reidentificar um indivíduo aleatoriamente selecionado na base é “adivinhar no escuro” qual registro, dentre todos os presentes na base D , corresponde ao indivíduo em questão. Como na base há 10 registros, o sucesso probabilístico a priori do adversário é de 10%.

Entretanto, ao realizar o ataque o adversário pode utilizar os valores das idade de todos os indivíduos como informação auxiliar. Note que, neste caso, o adversário

pode particionar a base D em 3 blocos, cada um contendo todos os registros que compartilham o mesmo valor para o atributo *idade*: um bloco contendo os 5 registros cuja idade é 25, um bloco contendo os 4 registros cuja idade é 49, e um bloco contendo o único registro cuja idade é 60. Note que no bloco com idade de 25 anos o adversário tem 20% de probabilidade de reidentificar um indivíduo corretamente (pois o bloco tem 5 registros), enquanto no bloco com idade de 49 anos a probabilidade de reidentificação é de 25% (pois o bloco tem 4 registros), e no bloco de idade de 60 anos a probabilidade de sucesso é de 100% (pois o bloco só tem 1 registro). Ponderando pelo fato que um indivíduo aleatoriamente selecionado tem 50% de chance de pertencer ao bloco de idade de 25 anos (pois 5 dos 10 registros têm essa idade), 40% de chance de pertencer ao bloco de indivíduos cuja idade é 49 anos (4 registros em 10), e 10% de chance de pertencer ao bloco de 60 anos (1 registro em 10), o sucesso probabilístico a posteriori do adversário pode ser computado como $50\% \cdot 20\% + 40\% \cdot 25\% + 10\% \cdot 100\% = 30\%$, o que significa que, ao usar idade como informação auxiliar, espera-se que um indivíduo aleatoriamente selecionado como alvo na base possa ser reidentificado com probabilidade de 30%.

Portanto, a correspondente degradação probabilística de privacidade é de $30\%/10\% = 3$ o que reflete que o sucesso probabilístico do adversário, ao utilizar idade como informação auxiliar, aumenta por um fator de 3.

<

3.4 Ataque de inferência de atributo individual em uma única base de dados (AIU)

Em um *ataque de inferência de atributo individual em uma única base de dados (AIU)*, o adversário tem acesso completo a uma única base de dados –conhecendo todos os seus registros– e é capaz de obter como informação auxiliar os valores de um conjunto de quaseidentificadores de um indivíduo específico pré-determinado como alvo. O adversário tem como objetivo inferir os valores de um atributo considerado como sensível para o indivíduo-alvo, independentemente de se esse indivíduo tenha sido reidentificado com sucesso ou não.

A degradação de privacidade do ataque é medida como uma comparação entre o sucesso a priori do adversário (i.e., conhecendo apenas a base de dados, mas não ainda os valores dos quaseidentificadores) e seu sucesso a posteriori (i.e., após descobrir os valores dos quaseidentificadores e cruzá-los com a base de dados). Mais precisamente, temos as seguintes condições para um ataque AIU:

- **Quantificação da degradação determinística de privacidade:** A degradação determinística de privacidade em um ataque AIU ocorre se, e somente se, o adversário não for capaz de inferir com absoluta certeza o valor sensível do indivíduo-alvo antes de efetuar o ataque, mas for capaz de fazê-lo após efetuar o ataque.

- **Quantificação da degradação probabilística de privacidade:** Na medição do sucesso probabilístico de um ataque individual AIU, não se exige que o adversário infira o valor do atributo sensível do indivíduo pré-determinado como alvo com absoluta certeza; em vez disso quantifica-se a probabilidade de que o adversário corretamente infira tal valor. Quanto maior essa probabilidade, mais exitoso é o adversário. A degradação probabilística de privacidade em um ataque AIU é definida, então, como a razão pela qual a execução do ataque aumenta o sucesso probabilístico do adversário.

A Definição 26 no Anexo A.1 formaliza matematicamente o ataque AIU. A seguir ilustramos como o ataque é executado em nosso exemplo condutor.

Exemplo 5 (Execução de ataque de inferência de atributo individual em uma única base de dados (AIU)). Considere novamente a base de dados D sobre o conjunto de atributos $\mathcal{A}$ do Exemplo 1. Recorde que, de acordo com as hipóteses sobre ataques em uma única base, cada indivíduo de interesse possui no máximo um registro em D e que a distribuição de probabilidade a priori π^D é derivada de acordo com Equação 3.1.

Assuma que o adversário está interessado em inferir os valores do atributo sensível *condição* de dois indivíduos pré-determinados como alvo: Caio e Dora. Adicionalmente, considere que o adversário obteve como informação auxiliar os valores dos seguintes quaseidentificadores para cada um desses indivíduos:

- Caio é do sexo masculino e seu grupo profissional é o 4, ou seja, os quaseidentificadores de Caio são $\mathcal{Q}'_{ID} = \{sexo, profissão\}$; e
- Dora é do sexo feminino e tem 49 anos de idade, ou seja, os quaseidentificadores de Dora são $\mathcal{Q}''_{ID} = \{sexo, idade\}$.

Vamos, então, computar a degradação determinística e probabilística de privacidade para ambos os indivíduos.

- **Degradação determinística de privacidade**

De imediato, note que o atributo *condição* apresenta mais de um valor possível dentre os registros da base de dados D : 5 registros apresentam valor *asma*, e 5 registros apresentam valor *coração*. Portanto, na ausência de informação auxiliar o adversário não pode determinar com absoluta certeza o valor do atributo sensível nem para Caio, nem para Dora. Portanto, o adversário não obtém sucesso determinístico a priori para nenhum dos dois alvos.

Entretanto, na realização de um ataque com o objetivo de inferir o valor do atributo sensível de Caio, o adversário tem como informação auxiliar os valores $x^*_{Caio}[\{sexo, profissão\}] = \langle M, 4 \rangle$ de seus quaseidentificadores. Note que, apesar de haver 2 registros na base de dados com os mesmos valores de sexo e profissão que Caio (os registros de *id*'s 9 e 10), mesmo assim a inferência do atributo sensível de

Caio pode ser feita com absoluta certeza, uma vez que ambos os registros apresentam o mesmo valor para o campo *condição*: **coração**. Portanto, o adversário atinge sucesso determinístico a posteriori em relação a Caio, e há degradação determinística de privacidade com o uso de idade e profissão como informação auxiliar. Note que neste caso o adversário é capaz de inferir o atributo sensível de Caio mesmo sem ter ocorrido sua reidentificação com absoluta certeza.

Por outro lado, ao realizar um ataque com o objetivo de inferir o valor do atributo sensível de Dora, o adversário tem acesso à informação auxiliar com os valores $x_{Dora}^*[\{sexo, idade\}] = \langle F, 49 \rangle$ de seus quaseidentificadores. Mesmo assim, neste caso a tentativa de inferência de atributo determinística de Dora falha, uma vez que existem três registros em D com os mesmos valores de sexo e idade que Dora (os registros de *id*'s 6, 7 e 8), e nem todos eles possuem o mesmo valor para o atributo sensível *condição* (os registros de *id*'s 6 e 7 apresentam o valor **asma**, enquanto o registro de *id*' 8 apresenta o valor **coração**). Portanto, não há sucesso determinístico a posteriori em relação a Dora, e nem degradação determinística de privacidade. De fato, a informação auxiliar sobre o sexo e idade de Dora não torna possível a inferência com absoluta certeza de sua condição de saúde a partir da base de dados.

- **Degradação probabilística de privacidade**

Note que o ataque determinístico, apesar de exitoso contra Caio, não permitiu a inferência do atributo sensível de Dora com absoluta certeza. Entretanto, ainda é possível para o adversário ter algum sucesso probabilístico no caso de Dora.

De imediato, note que em D o atributo *condição* apresenta o valor **asma** em 50% dos registros e o valor **coração** também em 50% dos registros. Dessa forma, sem nenhuma informação auxiliar, o adversário pode “adivinhar no escuro” qual o valor sensível de um indivíduo-alvo (tanto **asma** quanto **coração**) e mesmo assim ter 50% de probabilidade de sucesso na inferência. Logo o sucesso probabilístico a priori do adversário tanto para Caio quanto para Dora é de 50%.

Entretanto, ao realizar o ataque, o adversário tem como informação auxiliar os valores $x_{Dora}^*[\{sexo, idade\}] = \langle F, 49 \rangle$ dos quaseidentificadores de Dora, e pode usá-los para reduzir a quantidade de registros em D passíveis de serem atribuídos a ela a apenas 3 (os registros de *id*'s 6, 7 e 8). Como 2 entre esses 3 registros têm o valor **asma** para o atributo sensível, ao “adivinhar no escuro” esse valor o adversário ainda teria uma probabilidade de $2/3 = 0.67$ de acertar o valor correto do atributo *condição*. Dessa forma, o sucesso probabilístico a posteriori do adversário em relação a Dora é 67%.

A correspondente degradação probabilística de privacidade de Dora é, portanto, de $67\%/50\% = 1.34$, significando que o uso de sexo e idade como informação auxiliar permite ao adversário aumentar em aproximadamente 34% a sua probabilidade de inferência da condição de Dora.

◁

3.5 Ataque de inferência de atributo coletiva em uma única base de dados (ACU)

Em um *ataque de inferência de atributo coletiva em uma única base de dados (ACU)*, o adversário tem acesso completo a uma única base de dados –conhecendo todos os seus registros– e é capaz de obter como informação auxiliar os valores de um conjunto de quaseidentificadores para todos os indivíduos cujos registros estão na base. O adversário tem como objetivo inferir o valor de um atributo considerado como sensível para o maior número possível de indivíduos, independentemente de se esses indivíduos tenham sido reidentificados com sucesso ou não.

A degradação de privacidade do ataque é medida como uma comparação entre o sucesso a priori do adversário (i.e., conhecendo apenas a base de dados, mas não ainda os valores dos quaseidentificadores) e seu sucesso a posteriori (i.e., após descobrir os valores dos quaseidentificadores e cruzá-los com a base de dados). Mais precisamente, temos as seguintes condições para um ataque ACU:

- **Quantificação da degradação determinística de privacidade:** Na medição do sucesso determinístico de um ataque coletivo ACU, leva-se em conta que adversário tem como alvo todos os indivíduos da base; portanto, define-se tal sucesso como a fração desses indivíduos cujo valor do atributo sensível pode ser inferido com absoluta certeza. A degradação determinística de privacidade do ataque é definida, então, como a diferença pela qual sua execução aumenta o sucesso determinístico do adversário.
- **Quantificação da degradação probabilística de privacidade:** Na medição do sucesso probabilístico de um ataque coletivo ACU, não se exige que o adversário infira valor do atributo sensível de todos os indivíduos com absoluta certeza; em vez disso quantifica-se a probabilidade de um indivíduo aleatoriamente escolhido como alvo ter o valor de seu atributo sensível inferido com sucesso. Quanto maior essa probabilidade, mais exitoso é o adversário, e maior é o risco esperado de cada indivíduo presente na base ter seu atributo sensível inferido. A degradação probabilística de privacidade do ataque é definida, então, como a razão pela qual sua execução aumenta o sucesso probabilístico do adversário.

A Definição 27 no Anexo A.1 formaliza matematicamente o ataque ACU. A seguir ilustramos como o ataque é executado em nosso exemplo condutor.

Exemplo 6 (Execução de ataque de inferência de atributo coletiva em uma única base de dados (ACU)). Considere novamente a base de dados D sobre o conjunto de atributos $\mathcal{A}$ do Exemplo 1. Recorde que, de acordo com as hipóteses sobre ataques em uma única base, cada indivíduo de interesse possui no máximo um registro em D e que a distribuição de probabilidade a priori π^D é derivada de acordo com Equação 3.1.

Considere que o adversário está interessado em inferir o valor do atributo sensível *condição* para o maior número possível de indivíduos, e tem como informação auxiliar os valores do quaseidentificador $\mathcal{Q}'_{ID} = \{idade\}$ para todos os indivíduos na base de dados. Vamos computar tanto a degradação determinística de privacidade quanto a probabilística para este adversário.

- **Degradação determinística de privacidade**

Como a base de dados D possui mais do que um valor para o atributo sensível *condição* (5 registros possuem o valor **asma** e 5 registros possuem o valor **coração**), nenhum indivíduo na base pode ter o valor de seu atributo sensível inferido com absoluta certeza sem informação auxiliar. Portanto, o sucesso determinístico a priori é de 0%, pois esta é a fração de indivíduos na base cujo valor do atributo sensível pode ser inferido com absoluta certeza.

Entretanto, ao realizar o ataque, o adversário pode utilizar a idade dos indivíduos como informação auxiliar. Note que, neste caso, o adversário pode particionar a base D em 3 blocos, cada um contendo todos os registros que compartilham o mesmo valor para o atributo idade: um bloco contendo os 5 registros cuja idade é 25, um bloco contendo os 4 registros cuja idade é 49, e um bloco contendo o único registro cuja idade é 60. Entretanto, note que apenas em um desses blocos todos os registros têm o mesmo valor para o atributo sensível: o bloco que contém o indivíduo de *id* 9, que tem 60 anos de idade e condição **coração**. Logo, em apenas 1 dos 10 registros da base o atributo sensível pode ser inferido com absoluta certeza usando-se apenas idade como informação auxiliar. Nesse caso, o sucesso determinístico a posteriori do adversário é dado por $1/10 = 10\%$, significando que apenas 1 em 10 indivíduos podem ter o atributo sensível inferido após o ataque.

A correspondente degradação determinística de privacidade é, então, de $10\% - 0\% = 10\%$, significando que o uso de idade como informação auxiliar produz um aumento absoluto de 10% na quantidade de registros que passam a ter o atributo sensível *condição* inferível com absoluta certeza na base.

- **Degradação probabilística de privacidade**

De imediato, note que em D o atributo *condição* apresenta o valor **asma** em 50% dos casos e o valor **coração** também em 50% dos casos. Dessa forma, sem nenhuma informação auxiliar, o adversário pode “adivinhar no escuro” qual o valor sensível de qualquer indivíduo (tanto **asma** quanto **coração**) e mesmo assim ter 50% de probabilidade de inferi-lo com sucesso. Logo, o sucesso probabilístico a priori do adversário de inferir corretamente o atributo sensível de um indivíduo aleatoriamente selecionado como alvo é de 50%.

Entretanto, ao realizar o ataque, o adversário pode utilizar os valores das idades de todos os indivíduos como informação auxiliar. Note que, neste caso, o adversário pode particionar a base D em 3 blocos, cada um contendo registros com uma mesma idade: um bloco contendo os 5 registros cuja idade é 25, um bloco contendo

os 4 registros cuja idade é 49, e um bloco contendo o único registro cuja idade é 60. Note que no bloco com idade de 25 anos o adversário tem 60% de chance de inferir o atributo sensível corretamente (pois 3 dos 5 registros têm o mesmo valor), no bloco com idade de 49 anos a chance de acerto é de 50% (pois 2 dos 4 registros têm o mesmo valor), e no bloco de idade de 60 anos o adversário tem 100% de chance de acerto (pois só há 1 registro). Ponderando pelo fato que um indivíduo aleatoriamente selecionado tem 50% de chance de pertencer ao bloco de idade de 25 anos (pois 5 dos 10 registros têm essa idade), 40% de chance de pertencer ao bloco de indivíduos cuja idade é 49 anos (4 registros em 10), e 10% de chance de pertencer ao bloco de 60 anos (1 registro em 10), o sucesso probabilístico a posteriori do adversário é dado por $50\% \cdot 60\% + 40\% \cdot 50\% + 10\% \cdot 100\% = 60\%$, o que significa que, ao usar idade como informação auxiliar, espera-se que um indivíduo aleatoriamente selecionado como alvo na base possa ter seu atributo sensível corretamente inferido com probabilidade de 60%.

A correspondente degradação probabilística de privacidade é, então, $60\%/50\% = 1.2$, refletindo que o sucesso probabilístico do adversário, ao utilizar idade como informação auxiliar, aumenta em 20%.

◁

4 Avaliação experimental de ataques em uma única base de dados nos Censos Educacionais

Nesta seção apresentamos uma extensiva análise quantitativa experimental sobre riscos à privacidade decorrentes dos ataques em uma única base de dados introduzidos na Seção 3. As análises medem a degradação de privacidade em termos do quanto a informação auxiliar a respeito de quaseidentificadores obtida por um adversário pode facilitar a reidentificação ou a inferência de atributos sensíveis de indivíduos nas bases. Analisamos as bases dos Censos Educacionais divulgadas pelo Inep na forma atual, em que são adotados os métodos de proteção de privacidade de desidentificação e de pseudonimização.

4.1 Configuração dos experimentos em uma única base

As análises foram realizadas sobre as tabelas com informações sobre alunos. De modo a garantir que cada aluno estivesse representado por no máximo um registro em cada tabela (conforme a Premissa **PS1** sobre ataques em uma única base apresentada na Seção 3), para cada titular com mais de um registro nas bases (conforme código de identificação único de aluno atribuído pelo Inep) foi mantido apenas um registro aleatoriamente selecionado. Este tratamento não altera significativamente o tamanho das bases, mantendo, por exemplo, 89% dos registros na base do Censo da Educação Superior de 2018 (10 811 601 registros de um total de 12 043 994) e 93% dos registros do Censo da Educação Básica de 2019 (47 640 822 registros de um total de 51 166 723).

Dado o significativo custo computacional de tempo e memória das análises executadas, restringimos o número de atributos considerados como candidatos a quaseidentificadores a no máximo 11, e o número de atributos considerados sensíveis a no máximo 5. Tais atributos foram selecionados de acordo com os seguintes critérios:

- Como candidatos a quaseidentificadores de alunos, selecionamos atributos cujos valores sejam presumivelmente conhecidos, ou possam ser facilmente descobertos,

por um adversário –em geral por serem informação pública ou considerada inofensiva. Exemplos de tais atributos incluem a data de aniversário e a cidade de residência de um aluno, ou instituição de ensino em que ele está matriculado. A Tabela 4.1.1 apresenta os candidatos a quaseidentificadores usados nos experimentos desta seção.

- Como atributos sensíveis, selecionamos aqueles que presumivelmente não sejam de conhecimento público, mas cujos valores, caso revelados, possam vir a causar incômodo ou danos ao titular dos dados. Exemplos de tais atributos incluem os indicadores de se o indivíduo é ou não portador de necessidades especiais ou de alguma deficiência. A Tabela 4.1.2 apresenta atributos sensíveis usados nos experimentos desta seção.

É importante ressaltar que a escolha de atributos que sejam candidatos a quaseidentificadores ou que devam ser considerados sensíveis pode variar de acordo com o contexto e o tempo. Por exemplo, atributos que hoje sejam considerados inofensivos podem passar a ser sensíveis no futuro (e.g., o posicionamento político de um indivíduo em um país que se torne autoritário). Neste documento não nos preocupamos em fazer afirmações categóricas sobre quais atributos seriam ou não sensíveis no contexto dos Censos Educacionais do Inep, e nossas escolhas devem ser encaradas apenas como ilustração dos riscos à privacidade causados em um cenário em que elas se apliquem.

4.2 Resultados de ataques de reidentificação individual em uma única base de dados (RIU)

Em um ataque de reidentificação individual em uma única base de dados (RIU, apresentado e exemplificado na Seção 3.2), o adversário tem acesso a uma única base de dados e é capaz de obter como informação auxiliar os valores de um conjunto de quaseidentificadores de um indivíduo específico pré-determinado como alvo. O adversário tem como objetivo reidentificar o indivíduo-alvo, i.e., estabelecer qual registro na base corresponde a esse indivíduo.

O seguinte experimento ilustra um ataque RIU sobre uma figura política conhecida em nível nacional, presente nos Censos Educacionais do Inep.

Experimento 7 (Ataques de reidentificação individual RIU sobre uma conhecida figura política nos Censos da Educação Superior de 2014 e 2018). Para este experimento de ataque RIU, selecionamos como alvo uma figura política conhecida nacionalmente. Utilizamos como quaseidentificadores apenas informações sobre esta figura que estivessem publicamente disponíveis na Internet, como sua data e cidade de nascimento, quais Instituições de Ensino Superior (IES's) ela frequentou, e em que cursos se matriculou.

Separamos a discussão dos resultados pelo tipo de degradação de privacidade.

Variável	Interpretação
NU_DIA_NASCIMENTO	Dia de nascimento do aluno.
NU_MES_NASCIMENTO	Mês de nascimento do aluno.
NU_ANO_NASCIMENTO	Ano de nascimento do aluno.
TP_SEXO	Gênero do aluno.
TP_COR_RACA	Etnia do aluno.
TP_NACIONALIDADE	Nacionalidade do aluno.
CO_PAIS_ORIGEM	Código do país de origem do aluno.
CO_MUNICIPIO_NASCIMENTO	Código do município de nascimento do aluno.
CO_IES	Código da Instituição de Ensino Superior (IES).
CO_CURSO	Código do curso da IES ao qual o aluno está matriculado.
TP_ESCOLA_CONCLUSAO_ENS_MEDIO	Dependência administrativa da escola na qual o aluno concluiu o Ensino Médio.

(a) Variáveis do Censo da Educação Superior de 2018 selecionadas como candidatas a quase-identificadores em ataques de reidentificação coletiva (RCU) do Experimento 8 e em ataques de inferência de atributo coletiva (ACU) do Experimento 11.

Variável	Interpretação
NU_MES	Mês de nascimento do aluno.
NU_ANO	Ano de nascimento do aluno.
TP_SEXO	Gênero do aluno.
TP_COR_RACA	Etnia do aluno.
TP_NACIONALIDADE	Nacionalidade do aluno.
CO_PAIS_ORIGEM	Código do país de origem do aluno.
CO_MUNICIPIO_NASC	Código do município de nascimento do aluno.
CO_MUNICIPIO_END	Código do município de residência do aluno.
CO_ENTIDADE	Código da escola.
TP_DEPENDENCIA	Dependência administrativa da escola.

(b) Variáveis do Censo da Educação Básica de 2019 selecionadas como candidatas a quase-identificadores em ataques de reidentificação coletiva (RCU) do Experimento 9 e em ataques de inferência de atributo coletiva (ACU) do Experimento 12. Apesar de presente no dicionário de variáveis disponibilizado com os dados do Censo da Educação Superior de 2019, a variável referente ao atributo dia de nascimento do aluno (NU_DIA_NASCIMENTO) não foi encontrada no arquivo correspondente publicado pelo Inep e, portanto, não pôde ser considerada aqui como candidata a quaseidentificador.

Tabela 4.1.1: Atributos usados como candidatos a quaseidentificadores nos experimentos de ataques em uma única base de dados.

Variável	Valores	Interpretação
IN_DEFICIENCIA	0 (Não) 1 (Sim) 9 (Sem resposta)	Aluno com deficiência, transtorno global do desenvolvimento ou altas habilidades/superdotação.
IN_FINANCIAMENTO_ESTUDANTIL	-1 (Indisponível) 0 (Não) 1 (Sim)	Uso de financiamento estudantil por parte do aluno.

(a) Experimento 11: Atributos sensíveis utilizados nos ataques de inferência de atributo coletiva em uma única base (ACU) no Censo da Educação Superior de 2018.

Variável	Valores	Interpretação
IN_NECESSIDADE_ESPECIAL	0 (Não) 1 (Sim)	Aluno com deficiência, transtorno do espectro autista ou altas habilidades/superdotação.
IN_TRANSPORTE_PUBLICO	-1 (Indisponível) 0 (Não) 1 (Sim)	Uso de transporte escolar público por parte do aluno.

(b) Experimento 12: Atributos sensíveis utilizados nos ataques de inferência de atributo coletiva em uma única base (ACU) no Censo da Educação Básica de 2019.

Tabela 4.1.2: Atributos sensíveis usados nos experimentos de ataques em uma única base de dados.

- **Degradação probabilística de privacidade** Na medição do sucesso probabilístico de um ataque RIU, não se exige que o adversário realize a reidentificação do indivíduo pré-determinado como alvo com absoluta certeza; em vez disso quantifica-se a probabilidade de que o adversário corretamente reidentifique o indivíduo-alvo na base. Quanto maior essa probabilidade, mais exitoso é o adversário.

A base de dados selecionada para o ataque foi a do Censo da Educação Superior de 2014. Composta por 10 793 936 registros, a base teve seu tamanho reduzido para 9 773 350 registros após o tratamento para a remoção de múltiplos registros referentes a um mesmo titular.

Antes de efetuar o ataque RIU, não pudemos utilizar na tentativa de reidentificação os valores dos quaseidentificadores do indivíduo-alvo. Neste caso, o melhor que pudemos fazer foi “adivinhar no escuro” qual registro, dentre todos os presentes na base de dados, corresponderia à figura política em questão. Dessa forma, nosso sucesso probabilístico a priori foi quantificado como o inverso da quantidade de registros na base, ou seja, $1/9\,773\,350 = 1.0232 \cdot 10^{-7} \approx 0.00001\%$.

Entretanto, durante a execução do ataque RIU, pudemos usar o conhecimento dos valores de quaseidentificadores do indivíduo-alvo para nos auxiliar na tentativa de reidentificação. Neste caso, utilizamos como quaseidentificadores apenas a data de nascimento (28 de janeiro de 1996) e a Instituição de Ensino Superior ao qual o indivíduo estava vinculado no ano de 2014 (Universidade Federal do ABC, código 4925). Ambas as informações são facilmente encontradas na Internet.

Filtrando os registros na base por essa informação auxiliar, identificamos apenas 2 registros na base com os mesmos valores de quaseidentificadores que a figura política. A partir daí, o melhor que pudemos fazer foi “adivinhar no escuro” qual registro do subconjunto de registros selecionados corresponderia ao indivíduo-alvo. Portanto, nosso sucesso probabilístico a posteriori na reidentificação do indivíduo foi quantificado como $1/2 = 0.50 = 50\%$.

Portanto, a degradação probabilística de privacidade para o indivíduo selecionado foi quantificada em $0.50/(1.0232 \cdot 10^{-7}) = 4\,886\,675$.

Este experimento demonstra que, para a figura política selecionada, um adversário que tenha acesso apenas a sua data de nascimento e IES no ano de 2014 tem sua probabilidade de reidentificar o alvo na base multiplicada por um fator de mais de 4 886 675 vezes, o que equivale a um aumento da ordem de 488 667 400%. ¹

- **Degradação determinística de privacidade** O adversário é considerado deterministicamente exitoso em um ataque RIU se, e somente se, ele é capaz de estabelecer com absoluta certeza qual registro na base de dados corresponde ao indivíduo pré-determinado como alvo.

¹É interessante notar que, ao estender a informação auxiliar com apenas com mais o curso (Ciências Econômicas, código 123345) da figura política em questão (informação que também pode ser facilmente encontradas na Internet), ela passaria a ser unicamente reidentificável na base.

Aqui mantivemos a mesma figura política selecionada como alvo, mas agora realizando o ataque na base do Censo da Educação Superior de 2018. Composta por 12 043 994 registros, esta base de dados teve seu tamanho reduzido para 10 811 601 registros após o tratamento para a remoção de indivíduos com registros múltiplos.

Antes de efetuar o ataque, não pudemos utilizar na tentativa de reidentificação os valores dos quaseidentificadores da figura política. Como a base tem mais de um registro, não foi possível determinar com absoluta certeza qual deles corresponderia ao indivíduo-alvo, e não obtivemos sucesso determinístico a priori.

Durante a execução do ataque RIU, entretanto, pudemos usar como informação auxiliar os valores quaseidentificadores da figura política para nos ajudar na tentativa de reidentificação. Utilizamos como quaseidentificadores apenas a data de nascimento do indivíduo-alvo (28 de janeiro de 1996) e a Instituição de Ensino Superior ao qual o mesmo estava vinculado no ano de 2018 (Instituto de Direito Público de São Paulo, código 17672). Também essas informações são facilmente encontradas na Internet.

Utilizando essa informação auxiliar, identificamos apenas 1 registro na base com os mesmos valores de quaseidentificadores. Portanto obtivemos sucesso determinístico a posteriori, e é possível afirmar que houve degradação determinística de privacidade para esta figura política.

Este experimento demonstra que o conhecimento de apenas data de nascimento e IES do político em 2018 levam à sua reidentificação com absoluta certeza na base.

<

Os exemplos de ataques individuais acima demonstram que a figura política selecionada como alvo corre um risco considerável de reidentificação (tanto probabilística quanto determinística) se o adversário tiver acesso a apenas alguns atributos triviais como informação auxiliar, todos publicamente disponíveis na Internet. Entretanto, tal político representa apenas um indivíduo dentre os 9 773 350 presentes na base do Censo da Educação Superior de 2014, ou dentre os 10 811 601 presentes na base equivalente de 2018. É natural, portanto, nos perguntarmos se o caso deste alvo em específico é típico –i.e., se a maioria dos indivíduos na base corre riscos similares–, ou se há algo de especial em relação ao alvo que o torna particularmente vulnerável a ataques de reidentificação. Na próxima seção averiguamos que, de fato, o caso deste alvo é típico nas bases dos Censos Educacionais analisadas.

4.3 Resultados de ataques de reidentificação coletiva em uma única base de dados (RCU)

Em um ataque de reidentificação coletiva em uma única base de dados (RCU, apresentado e exemplificado na Seção 3.3), o adversário tem acesso completo a uma única base

de dados e é capaz de obter como informação auxiliar os valores de um conjunto de quase-identificadores para todos os indivíduos cujos registros estão na base. O adversário tem como objetivo reidentificar o maior número possível de indivíduos, independentemente de quem sejam esses indivíduos.

A análise experimental deste tipo de ataque permite a generalização do risco individual avaliado na seção anterior, revelando o risco esperado para qualquer indivíduo aleatoriamente selecionado na base como alvo. Em particular, este tipo de análise nos permite constatar que o caso do político estudado no Experimento 7 não é atípico: de fato, a maioria dos indivíduos presentes nas bases estudadas está sujeita a um risco considerável de reidentificação (tanto probabilística quanto determinística).

Nossa primeira análise de ataques RCU concerne ao Censo da Educação Superior de 2018.

Experimento 8 (Ataques de reidentificação coletiva RCU no Censo da Educação Superior de 2018). O tratamento para remoção de registros múltiplos de um mesmo titular leva a base do Censo da Educação Superior de 2018 de 12 043 994 para 10 811 601 registros. Neste experimento, selecionamos como candidatos a quase-identificadores de alunos os 11 atributos listados na Tabela 4.1.1a. Consideramos que um adversário poderia obter como informação auxiliar qualquer subconjunto não-vazio desses candidatos a quase-identificadores, o que corresponde a $2^{11} - 1 = 2047$ combinações possíveis. Medimos, então, a degradação de privacidade (tanto determinística quanto probabilística) para cada uma dessas combinações de quase-identificadores.

Os resultados obtidos estão organizados da seguinte forma:

- A Figura 4.3.3 representa as medidas de sucesso determinístico e probabilístico do adversário para cada uma das diferentes combinações de quase-identificadores que podem ser usados como informação auxiliar pelo adversário.
- A Tabela 4.3.4 sumariza quais combinações de quase-identificadores levam à maior degradação de privacidade neste ataque.
- A Figura 4.3.5 apresenta histogramas referentes aos piores casos para conjuntos de quase-identificadores de variados tamanhos.

Separamos a discussão dos resultados pelo tipo de degradação de privacidade.

- **Sucesso determinístico do adversário:** Este tipo de sucesso é medido como a fração dos indivíduos da base que podem ser reidentificados com absoluta certeza. A Tabela 4.3.4 demonstra que o sucesso determinístico a priori do adversário é de 0%, significando que sem informação auxiliar nenhum indivíduo pode ser reidentificado com absoluta certeza na base. Por outro lado, uma combinação de 3 quase-identificadores permite ao adversário reidentificar com absoluta certeza até 38.87% dos indivíduos na base; enquanto uma combinação de 4 quase-identificadores pode levar à reidentificação de até 79.20% dos indivíduos. Já o uso de todos os 11 quase-identificadores eleva o risco a 97.22%.





Figura 4.3.3: Experimento 8: Sucesso do adversário em ataques de reidentificação coletiva em uma única base de dados (RCU) no Censo da Educação Superior de 2018. Nestes gráficos, a reta horizontal com o rótulo “*a priori*” representa o sucesso (determinístico ou probabilístico) a priori do adversário, ou seja, antes de executar o ataque. Cada ponto representa um ataque distinto em que o conhecimento auxiliar do adversário é uma das 2047 combinações possíveis de quaseidentificadores. Organizamos no eixo horizontal de cada gráfico as combinações de quaseidentificadores de acordo com seu tamanho, i.e., seu número de atributos. Por exemplo, os casos em que o adversário conhece o valor de apenas um quaseidentificador (e.g., TP_SEX0 ou CO_IES) são representados como pontos alinhados sobre a marcação “1” no eixo horizontal do gráfico; enquanto que o caso em que o adversário conhece o valor de todos os 11 quaseidentificadores é representado por um ponto sobre a marcação “11” no eixo horizontal. Já o eixo vertical de cada gráfico representa o sucesso (determinístico ou probabilístico) do adversário em cada caso.


- **Sucesso probabilístico do adversário:** Este tipo de sucesso é medido como a probabilidade de que um indivíduo escolhido aleatoriamente seja reidentificado com sucesso na base. A Tabela 4.3.4 demonstra que o sucesso probabilístico a priori do adversário (que é inversamente proporcional ao tamanho da base) neste caso é da ordem de 0.000092%, significando que sem nenhuma informação auxiliar o adversário tem uma chance ínfima de reidentificar qualquer indivíduo com absoluta certeza dentre os 10 811 601 registros na base. Por outro lado, uma combinação de 3 quaseidentificadores permite ao adversário reidentificar um indivíduo aleatoriamente selecionado como alvo com probabilidade de até 56.14% após a realização do ataque; enquanto que uma combinação de 4 quaseidentificadores eleva essa probabilidade a até 86.85%. Já o uso de todos os 11 quaseidentificadores eleva o risco a 98.45%.

#	Quaseidentificadores	Sucesso determinístico do adversário		Sucesso probabilístico do adversário	
		Sucesso a priori = 0.00%		Sucesso a priori = 0.000092%	
		Sucesso a posteriori	Degradação privacidade	Sucesso a posteriori	Degradação privacidade
1	CO_CURSO	0.0052%	0.0052%	0.35%	38 127
2	CO_MUNICIPIO_NASCIMENTO, CO_CURSO	9.71%	9.71%	14.99%	1 620 162
3	NU_DIA_NASCIMENTO, NU_ANO_NASCIMENTO, CO_CURSO	38.87%	38.87%	56.14%	6 069 562
4	NU_DIA_NASCIMENTO, NU_MES_NASCIMENTO, NU_ANO_NASCIMENTO, CO_CURSO	79.20%	79.20%	86.85%	9 390 109
5	NU_DIA_NASCIMENTO, NU_MES_NASCIMENTO, NU_ANO_NASCIMENTO, CO_MUNICIPIO_NASCIMENTO, CO_CURSO	92.13%	92.13%	95.42%	10 316 882
6	NU_DIA_NASCIMENTO, NU_MES_NASCIMENTO, NU_ANO_NASCIMENTO, TP_COR_RACA, CO_MUNICIPIO_NASCIMENTO, CO_CURSO	95.32%	95.32%	97.36%	10 526 308
7	NU_DIA_NASCIMENTO, NU_MES_NASCIMENTO, NU_ANO_NASCIMENTO, TP_SEXO, TP_COR_RACA, CO_MUNICIPIO_NASCIMENTO, CO_CURSO	96.66%	96.66%	98.15%	10 611 528
8	NU_DIA_NASCIMENTO, NU_MES_NASCIMENTO, NU_ANO_NASCIMENTO, TP_SEXO, TP_COR_RACA, CO_MUNICIPIO_NASCIMENTO, CO_CURSO, TP_ESCOLA_CONCLUSAO_ENS_MEDIO	97.22%	97.22%	98.45%	10 644 058
9	NU_DIA_NASCIMENTO, NU_MES_NASCIMENTO, NU_ANO_NASCIMENTO, TP_SEXO, TP_COR_RACA, CO_MUNICIPIO_NASCIMENTO, TP_NACIONALIDADE, CO_CURSO, TP_ESCOLA_CONCLUSAO_ENS_MEDIO	97.22%	97.22%	98.45%	10 644 308
10	NU_DIA_NASCIMENTO, NU_MES_NASCIMENTO, NU_ANO_NASCIMENTO, TP_SEXO, TP_COR_RACA, CO_MUNICIPIO_NASCIMENTO, TP_NACIONALIDADE, CO_PAIS_ORIGEM, CO_CURSO, TP_ESCOLA_CONCLUSAO_ENS_MEDIO	97.22%	97.22%	98.45%	10 644 312
11	NU_DIA_NASCIMENTO, NU_MES_NASCIMENTO, NU_ANO_NASCIMENTO, TP_SEXO, TP_COR_RACA, CO_MUNICIPIO_NASCIMENTO, TP_NACIONALIDADE, CO_PAIS_ORIGEM, CO_IES, CO_CURSO, TP_ESCOLA_CONCLUSAO_ENS_MEDIO	97.22%	97.22%	98.45%	10 644 312


Tabela 4.3.4: Experimento 8: Quaseidentificadores com maior degradação de privacidade em ataques de reidentificação coletiva (RCU) no Censo da Educação Superior de 2018. Recorde que a degradação determinística de privacidade é dada pela diferença entre o sucesso do a posteriori e o a priori do adversário, enquanto a degradação probabilística é dada pela razão dos mesmos dois termos.




(a) Usando `[CO_CURSO]` como quaseidentificador



(b) Usando `[NU_DIA_NASCIMENTO, NU_MES_NASCIMENTO, NU_ANO_NASCIMENTO, CO_CURSO]` como quaseidentificadores



(c) Usando `[NU_DIA_NASCIMENTO, NU_MES_NASCIMENTO, NU_ANO_NASCIMENTO, TP_SEXO, TP_COR_RACA, CO_MUNICIPIO_NASCIMENTO, CO_CURSO]` como quaseidentificadores



(d) Usando `[NU_DIA_NASCIMENTO, NU_MES_NASCIMENTO, NU_ANO_NASCIMENTO, TP_SEXO, TP_COR_RACA, CO_MUNICIPIO_NASCIMENTO, TP_NACIONALIDADE, CO_PAIS_ORIGEM, CO_IES, CO_CURSO, TP_ESCOLA_CONCLUSAO_ENS_MEDIO]` como quaseidentificadores

Figura 4.3.5: Experimento 8: Histogramas da distribuição de sucesso probabilístico a posteriori em ataques de reidentificação coletiva em uma única base de dados (RCU) no Censo da Educação Superior de 2018. O eixo horizontal representa os possíveis valores para o sucesso probabilístico a posteriori do adversário. Por exemplo, a Figura 4.3.5b mostra que usando dia, mês, ano de nascimento e código do curso como quaseidentificadores, cerca de 5% dos indivíduos podem ser reidentificados com 34% de probabilidade; 10% dos indivíduos correm risco de 50%; e 80% correm risco de 100% de reidentificação.

Nossa segunda análise de ataques RCU concerne ao Censo da Educação Básica de 2019.

Experimento 9 (Ataques de reidentificação coletiva RCU no Censo da Educação Básica de 2019). O tratamento para eliminação de registros múltiplos para um mesmo titular reduz a base do Censo da Educação Básica de 2019 de 51 166 723 para 47 640 822 registros. Em nossa análise de ataques RCU nesta base, selecionamos como candidatos a quaseidentificadores os 10 atributos listados na Tabela 4.1.1b. Consideramos que um adversário poderia obter como informação auxiliar qualquer subconjunto não-vazio desses candidatos a quaseidentificadores, o que equivale a $2^{10} - 1 = 1023$ combinações possíveis. Medimos, então, a degradação de privacidade (tanto determinística quando probabilística) para cada uma dessas combinações de quaseidentificadores.

Os resultados obtidos estão organizados da seguinte forma:

- A Figura 4.3.6 representa as medidas de sucesso determinístico e probabilístico do adversário para cada uma das diferentes combinações de quaseidentificadores que podem ser usados como informação auxiliar pelo adversário.
- A Tabela 4.3.7 sumariza quais combinações de quaseidentificadores levam à maior degradação de privacidade neste ataque.
- A Figura 4.3.8 apresenta histogramas referentes aos piores casos para conjuntos de quaseidentificadores de variados tamanhos.

Separamos a discussão dos resultados pelo tipo de degradação de privacidade.

- **Sucesso determinístico do adversário:** A Tabela 4.3.7 demonstra que o sucesso determinístico a priori do adversário é de 0%, significando que sem informação auxiliar nenhum indivíduo pode ser reidentificado com absoluta certeza na base. Por outro lado, uma combinação de 3 quaseidentificadores permite ao adversário reidentificar com absoluta certeza até 14.54% dos indivíduos na base; enquanto que uma combinação de 4 quaseidentificadores pode aumentar este valor a até 33.12%. Já o uso de todos os 10 quaseidentificadores eleva o risco a 60.90%.
- **Sucesso probabilístico do adversário:** A Tabela 4.3.7 demonstra que o sucesso probabilístico a priori do adversário (que é inversamente proporcional ao número de registros na base) neste caso é da ordem de 0.000002%, significando que sem nenhuma informação auxiliar o adversário tem uma chance ínfima de reidentificar qualquer indivíduo com absoluta certeza. Por outro lado, uma combinação de 3 quaseidentificadores permite ao adversário reidentificar um indivíduo aleatoriamente selecionado como alvo com probabilidade de até 29.64% após a realização do ataque; enquanto uma combinação de 4 quaseidentificadores pode elevar essa chance de sucesso a até 49.86%. Já o uso de todos os 10 quaseidentificadores eleva o risco a 75.51%.

		Sucesso determinístico do adversário		Sucesso probabilístico do adversário	
		Sucesso a priori = 0.00%		Sucesso a priori = 0.000002%	
#	Quaseidentificadores	Sucesso a posteriori	Degradação privacidade	Sucesso a posteriori	Degradação privacidade
1	CO_ENTIDADE	0.0002%	0.0002%	0.38%	182 434
2	CO_MUNICIPIO_NASC, CO_ENTIDADE	5.92%	5.92%	9.38%	4 468 395
3	NU_MES, NU_ANO, CO_ENTIDADE	11.80%	11.80%	29.64%	14 119 984
3	NU_ANO, CO_MUNICIPIO_NASC, CO_ENTIDADE	14.54%	14.54%	21.73%	10 352 649
4	NU_MES, NU_ANO, CO_MUNICIPIO_NASC, CO_ENTIDADE	33.12%	33.12%	49.86%	23 752 768
5	NU_MES, NU_ANO, TP_COR_RACA, CO_MUNICIPIO_NASC, CO_ENTIDADE	46.46%	46.46%	63.20%	30 107 590
6	NU_MES, NU_ANO, TP_SEXO, TP_COR_RACA, CO_MUNICIPIO_NASC, CO_ENTIDADE	58.94%	58.94%	74.18%	35 338 492
7	NU_MES, NU_ANO, TP_SEXO, TP_COR_RACA, CO_MUNICIPIO_NASC, CO_MUNICIPIO_END, CO_ENTIDADE	60.90%	60.90%	75.51%	35 972 591
8	NU_MES, NU_ANO, TP_SEXO, TP_COR_RACA, CO_PAIS_ORIGEM, CO_MUNICIPIO_NASC, CO_MUNICIPIO_END, CO_ENTIDADE	60.90%	60.90%	75.51%	35 973 629
9	NU_MES, NU_ANO, TP_SEXO, TP_COR_RACA, TP_NACIONALIDADE, CO_PAIS_ORIGEM, CO_MUNICIPIO_NASC, CO_MUNICIPIO_END, CO_ENTIDADE	60.90%	60.90%	75.51%	35 973 629
9	NU_MES, NU_ANO, TP_SEXO, TP_COR_RACA, CO_PAIS_ORIGEM, CO_MUNICIPIO_NASC, CO_MUNICIPIO_END, CO_ENTIDADE, TP_DEPENDENCIA	60.90%	60.90%	75.51%	35 973 629
10	NU_MES, NU_ANO, TP_SEXO, TP_COR_RACA, TP_NACIONALIDADE, CO_PAIS_ORIGEM, CO_MUNICIPIO_NASC, CO_MUNICIPIO_END, CO_ENTIDADE, TP_DEPENDENCIA	60.90%	60.90%	75.51%	35 973 629

Tabela 4.3.7: Experimento 9: Quaseidentificadores com maior degradação de privacidade em ataques de reidentificação coletiva (RCU) no Censo da Educação Básica de 2019. Recorde que a degradação determinística de privacidade é dada pela diferença entre o sucesso do a posteriori e o a priori do adversário, enquanto a degradação probabilística é dada pela razão dos mesmos dois termos.







Figura 4.3.6: Experimento 9: Sucesso do adversário em ataques de reidentificação coletiva em uma única base de dados (RCU) no Censo da Educação Básica de 2019. Estes gráficos devem ser interpretados da mesma forma que aqueles da Figura 4.3.3.




(a) Usando [CO_ENTIDADE] como quaseidentificador



(b) Usando [NU_MES, NU_ANO, CO_MUNICIPIO_NASC, CO_ENTIDADE] como quaseidentificadores



(c) Usando [NU_MES, NU_ANO, TP_SEXO, TP_COR_RACA, CO_MUNICIPIO_NASC, CO_MUNICIPIO_END, CO_ENTIDADE] como quaseidentificadores



(d) Usando [NU_MES, NU_ANO, TP_SEXO, TP_COR_RACA, TP_NACIONALIDADE, CO_PAIS_ORIGEM, CO_MUNICIPIO_NASC, CO_MUNICIPIO_END, CO_ENTIDADE, TP_DEPENDENCIA] como quaseidentificadores

Figura 4.3.8: Experimento 9: Histogramas da distribuição de sucesso probabilístico a posteriori em ataques de reidentificação coletiva em uma única base de dados (RCU) no Censo da Educação Básica de 2019. Estes histogramas devem ser interpretados da mesma forma que seus equivalentes na Figura 4.3.5.

4.4 Resultados de ataques de inferência de atributo individual em uma única base de dados (AIU)

Em um ataque de inferência de atributo individual em uma única base de dados (AIU, apresentado e exemplificado na Seção 3.4), o adversário tem acesso completo, o adversário tem acesso a uma única base de dados e é capaz de obter como informação auxiliar os valores de um conjunto de quaseidentificadores de um indivíduo específico pré-determinado como alvo. O adversário tem como objetivo inferir os valores de um atributo considerado como sensível para o indivíduo-alvo, independentemente de se esse indivíduo tenha sido reidentificado com sucesso ou não.

O seguinte experimento apresenta nossa análise de ataques AIU nos Censos Educacionais do Inep em sua atual forma de divulgação.

Experimento 10 (Ataques de inferência de atributo individual AIU sobre atributo sensível `IN_TRANSPORTE_PUBLICO` de um parente de um dos autores do documento no Censo da Educação Básica de 2019). Após tratamento para remoção de registros múltiplos para um mesmo titular, a base do Censo da Educação Básica de 2019 foi reduzida de 51 166 723 para 47 640 822 registros. Seleccionamos como alvo do ataque AIU um parente de um dos autores deste documento. Como o alvo é uma pessoa próxima, os valores de vários de seus atributos (como sua data de aniversário, cidade de residência, e escola onde estuda) são de nosso conhecimento. Além disso, estabelecemos como atributo sensível o indicador de se um indivíduo usa ou não transporte público (variável `IN_TRANSPORTE_PUBLICO`, especificada na Tabela 4.1.2b).

Separamos a discussão dos resultados pelo tipo de degradação de privacidade.

- **Degradação probabilística de privacidade** Na medição do sucesso probabilístico de um ataque individual AIU, não se exige que o adversário infira o valor do atributo sensível do indivíduo pré-determinado como alvo com absoluta certeza; em vez disso quantifica-se a probabilidade de que o adversário corretamente infira tal valor. Quanto maior essa probabilidade, mais exitoso é o adversário.

Antes de efetuar o ataque AIU, não pudemos utilizar os valores dos quaseidentificadores do indivíduo-alvo como informação auxiliar na tentativa inferir seu atributo sensível. Neste caso, o melhor que pudemos fazer foi “adivinhar no escuro” qual seria o valor do atributo sensível do indivíduo-alvo. Como o atributo em questão tem 3 valores possíveis, e o mais comum deles (valor 0, indicando que o aluno não utiliza transporte público) ocorre em 39 093 415 dos 47 640 822 registros na base, é natural escolhermos este valor como a estimativa do atributo sensível do indivíduo-alvo. Fazendo isso, nosso sucesso probabilístico a priori foi quantificado como $39\,093\,415 / 47\,640\,822 = 82.06\%$.

Durante a execução do ataque, entretanto, pudemos usar o conhecimento dos valores de quaseidentificadores do indivíduo-alvo como informação auxiliar para a tentativa de inferência do valor de seu atributo sensível. Neste caso utilizamos

como informação auxiliar os valores de gênero (masculino), mês (novembro), ano (2001), e cidade de nascimento (Belo Horizonte, código 3106200) do indivíduo. Todos esses valores são de conhecimento das pessoas próximas ao aluno-alvo.

Utilizando essa informação auxiliar, identificamos 1 589 registros na base com os mesmos valores de quaseidentificadores. A partir daí, o melhor que podemos fazer foi “adivinhar no escuro” qual valor de atributo sensível, dentre aqueles presentes no subconjunto assim selecionado, corresponderia ao valor do indivíduo-alvo. Dentre os 1 589 registros filtrados, o valor mais comum para o atributo sensível foi novamente 0, indicando que o aluno não utiliza transporte público, ocorrendo em 1 482 registros. Dessa forma, nosso sucesso probabilístico a posteriori na inferência do atributo sensível do indivíduo foi quantificado como $1\,482/1\,589 = 93.27\%$.

Portanto, a degradação probabilística de privacidade em relação ao atributo sensível para o aluno selecionado foi quantificada como $93.27\%/82.06\% = 1.1366$.

Este experimento demonstra que o conhecimento de apenas um conjunto trivial de quaseidentificadores do alvo selecionado multiplicou a probabilidade de inferirmos com sucesso o valor de seu atributo `IN_TRANSPORTE_PUBLICO` por um fator de 1.1366, o que corresponde a um aumento de 13.66%.

- **Degradação determinística de privacidade** O adversário é considerado deterministicamente exitoso em um ataque AIU se, e somente se, ele é capaz de estabelecer com absoluta certeza qual o valor do atributo sensível do indivíduo pré-determinado como alvo.

Antes de efetuar o ataque AIU, não pudemos utilizar os valores dos quaseidentificadores do indivíduo-alvo como informação auxiliar na tentativa de inferir o valor de seu atributo sensível. Como os registros da base tinham mais de um valor possível para o atributo sensível (na verdade, todos os 3 valores possíveis para `IN_TRANSPORTE_PUBLICO` ocorrem em pelo menos um registro na base), não foi possível inferir com absoluta certeza qual valor corresponderia ao indivíduo-alvo, e não obtivemos sucesso determinístico a priori.

Durante a execução do ataque AIU, entretanto, pudemos usar o conhecimento dos valores dos quaseidentificadores do indivíduo como informação auxiliar na tentativa de inferência do valor de seu atributo sensível. Usamos novamente como informação auxiliar os valores de gênero (masculino), mês (novembro), ano (2001), e a cidade de nascimento (Belo Horizonte, código 3106200). Além disso, usamos também a cidade de residência (Contagem, código 3118601) do indivíduo. Todos esses valores são conhecidos por pessoas próximas ao indivíduo-alvo.

Utilizando essa informação auxiliar, identificamos 26 registros na base com os mesmos valores de quaseidentificadores. Todos esses indivíduos tinham o mesmo valor para o atributo sensível (0, significando que o aluno não usa transporte público), e pudemos inferir com absoluta certeza que o indivíduo não usa transporte público. Portanto, obtivemos sucesso determinístico a posteriori, e é possível afirmar que houve degradação determinística de privacidade para este aluno específico.

Este experimento demonstra que o conhecimento de apenas alguns atributos triviais do indivíduo-alvo tornou possível a inferência com absoluta certeza de seu atributo `IN_TRANSPORTE_PUBLICO`, mesmo que o indivíduo não tenha sido reidentificado com absoluta certeza na base (na verdade, mesmo após a execução do ataque, o indivíduo ainda poderia ser qualquer um dentre um total de 26 possíveis).

◁

De forma similar ao caso dos ataques de reidentificação individual do Experimento 7, os exemplos de ataques de inferência de atributo individual acima demonstram que o indivíduo selecionado como alvo corre um risco considerável de ter seu atributo sensível inferido (determinística ou probabilisticamente) se o adversário tiver acesso a apenas a alguns quaseidentificadores triviais como informação auxiliar. Entretanto, o indivíduo selecionado é apenas um entre os 47 640 822 registros únicos na base de dados do Censo da Educação Básica de 2019. A fim de verificar se os demais indivíduos da base estão expostos a riscos semelhantes, na próxima seção realizamos a análise de ataques coletivos.

4.5 Resultados de ataques de inferência de atributo sensível coletiva em uma única base de dados (ACU)

Em um ataque de inferência de atributo coletiva em uma única base de dados (ACU, apresentado e exemplificado na Seção 3.5), o adversário tem acesso completo a uma única base e é capaz de obter como informação auxiliar os valores de um conjunto de quaseidentificadores para todos os indivíduos cujos registros estão na base. O adversário tem como objetivo inferir o valor de um atributo considerado sensível para o maior número possível de indivíduos, independentemente de se esses indivíduos tenham sido reidentificados com sucesso ou não.

A análise experimental deste tipo de ataque permite a generalização do risco individual avaliado na seção anterior para o risco esperado para qualquer indivíduo aleatoriamente selecionado na base como alvo. Em particular, esta análise nos permite constatar que o caso do aluno usado no Experimento 10 não é atípico, e a maioria dos indivíduos presentes nas bases estudadas está sujeita a um risco não-negligível de ter os valores de vários atributos potencialmente sensíveis inferidos pelo adversário.

Nossa primeira análise de ataque ACU concerne ao Censo da Educação Superior de 2018.

Experimento 11 (Ataques de inferência de atributo coletiva ACU sobre atributos sensíveis `IN_DEFICIENCIA` e `IN_FINANCIAMENTO_ESTUDANTIL` no Censo da Educação Superior de 2018). Inicialmente composta por 12 043 994 registros, a base de dados do Censo da Educação Superior de 2018 teve seu tamanho reduzido para 10 811 601 registros após o tratamento para a remoção de indivíduos com registros múltiplos. Assim como para os ataques de reidentificação coletiva, os 11 atributos selecionados como candidatos a

quaseidentificadores estão listados na Tabela 4.1.1a. Também aqui consideramos que um adversário poderia obter como informação auxiliar qualquer subconjunto não-vazio desses candidatos a quaseidentificadores, o que corresponde a $2^{11} - 1 = 2047$ combinações possíveis. Consideramos dois tipos de ataques ACU sobre a base de dados do Censo da Educação Superior de 2018: um em que o atributo sensível é `IN_DEFICIENCIA` e outro em que o atributo sensível é `IN_FINANCIAMENTO_ESTUDANTIL`. Ambos atributos estão especificados na Tabela 4.1.2a.

Os resultados obtidos estão organizados da seguinte forma:

- A Figura 4.5.9 representa as medidas de sucesso determinístico e probabilístico do adversário para cada uma das diferentes combinações de quaseidentificadores que podem ser usados como informação auxiliar pelo adversário.
- As Tabelas 4.5.10 e 4.5.11 resumizam quais combinações de quaseidentificadores levam à maior degradação de privacidade nestes ataques para os atributos sensíveis `IN_DEFICIENCIA` e `IN_FINANCIAMENTO_ESTUDANTIL`, respectivamente.
- As Figuras 4.5.12 e 4.5.13 apresentam histogramas referentes aos piores casos para conjuntos de quaseidentificadores de variados tamanhos para as variáveis sensíveis `IN_DEFICIENCIA` e `IN_FINANCIAMENTO_ESTUDANTIL`, respectivamente.

Separamos a discussão dos resultados pelo tipo de degradação de privacidade.

- **Sucesso determinístico do adversário:** Este tipo de sucesso é medido como a fração dos indivíduos da base cujos valores para o atributo sensível podem ser inferidos com absoluta certeza.

A Tabela 4.5.10 demonstra que, para o atributo sensível `IN_DEFICIENCIA`, o sucesso determinístico a priori do adversário é de 0%, significando que sem informação auxiliar nenhum indivíduo pode ter seu atributo `IN_DEFICIENCIA` inferido com absoluta certeza na base. Por outro lado, uma combinação de 2 quaseidentificadores permite ao adversário inferir com absoluta certeza o valor do atributo sensível em até 65.03% dos indivíduos na base; enquanto uma combinação de 4 quaseidentificadores já eleva essa fração a 99.28%.


Por sua vez, a Tabela 4.5.11 demonstra que, quando o atributo considerado como sensível é `IN_FINANCIAMENTO_ESTUDANTIL`, o sucesso determinístico a priori do adversário também é de 0%. Entretanto, quando comparado ao caso do atributo `IN_DEFICIENCIA`, o sucesso determinístico do adversário em inferir o valor do atributo `IN_FINANCIAMENTO_ESTUDANTIL` cresce mais lentamente com o número de quaseidentificadores usados. Por exemplo, uma combinação de 2 quaseidentificadores permite ao adversário inferir com absoluta certeza o valor do atributo sensível em até 38.74% dos registros na base, enquanto uma combinação de 4 quaseidentificadores já eleva essa fração a 92.25%. Já o uso de todos os 11 quaseidentificadores eleva esse risco para 99.52%.

- **Sucesso probabilístico do adversário:** Este tipo de sucesso é medido como a probabilidade de que um indivíduo escolhido aleatoriamente na base tenha o valor de seu atributo sensível inferido.

A Tabela 4.5.10 demonstra que, para o atributo sensível `IN_DEFICIENCIA`, o sucesso probabilístico a priori do adversário já é de 94%, significando que mesmo sem informação auxiliar alguma o adversário já tem uma probabilidade esperada de 94.04% de inferir o valor deste atributo para um indivíduo aleatoriamente selecionado. Além disso, uma combinação de 4 quaseidentificadores já eleva o sucesso probabilístico a posteriori a até 99.75%.


Por sua vez, a Tabela 4.5.11 demonstra que, quando o atributo considerado sensível é `IN_FINANCIAMENTO_ESTUDANTIL`, o sucesso probabilístico a priori do adversário é de 47.28%, o que é muito menor que seu correspondente para variável sensível `IN_DEFICIENCIA`. Como consequência, os diferentes conjuntos possíveis de atributos quaseidentificadores tornam-se mais relevantes. Para alguns casos, o adversário não aumenta significativamente sua chance de sucesso ao realizar um ataque, enquanto que, para outros conjuntos, é possível que ele alcance quase que 100% de chance de sucesso, como observado já em alguns casos com 5 atributos quaseidentificadores.

<




Quantidade de Quaseidentificadores Utilizados

(a) Sucesso determinístico para atributo sensível IN_DEFICIENCIA.




Quantidade de Quaseidentificadores Utilizados

(b) Sucesso probabilístico para atributo sensível IN_DEFICIENCIA.



Quantidade de Quaseidentificadores Utilizados

(c) Sucesso determinístico para atributo sensível IN_FINANCIAMENTO_ESTUDANTIL.



Quantidade de Quaseidentificadores Utilizados

(d) Sucesso probabilístico para atributo sensível IN_FINANCIAMENTO_ESTUDANTIL.


Figura 4.5.9: Experimento 11: Sucesso do adversário em ataques de inferência de atributo coletiva em uma única base de dados (ACU) no Censo da Educação Superior de 2018. Estes gráficos devem ser interpretados da mesma forma que aqueles da Figura 4.3.3.

#	Quaseidentificadores	Sucesso determinístico do adversário		Sucesso probabilístico do adversário	
		Sucesso a priori = 0.00%		Sucesso a priori = 94.04%	
		Sucesso a posteriori	Degradação privacidade	Sucesso a posteriori	Degradação privacidade
1	CO_CURSO	13.54%	13.54%	97.28%	1.0345
2	CO_MUNICIPIO_NASCIMENTO, CO_CURSO	50.29%	50.29%	97.80%	1.0400
2	NU_DIA_NASCIMENTO, CO_CURSO	65.03%	65.03%	97.45%	1.0363
3	NU_DIA_NASCIMENTO, NU_ANO_NASCIMENTO, CO_CURSO	94.23%	94.23%	98.90%	1.0517
4	NU_DIA_NASCIMENTO, NU_MES_NASCIMENTO, NU_ANO_NASCIMENTO, CO_CURSO	99.28%	99.28%	99.75%	1.0607
5	NU_DIA_NASCIMENTO, NU_MES_NASCIMENTO, NU_ANO_NASCIMENTO, CO_MUNICIPIO_NASCIMENTO, CO_CURSO	99.80%	99.80%	99.91%	1.0625
6	NU_DIA_NASCIMENTO, NU_MES_NASCIMENTO, NU_ANO_NASCIMENTO, TP_COR_RACA, CO_MUNICIPIO_NASCIMENTO, CO_CURSO	99.91%	99.91%	99.96%	1.063
7	NU_DIA_NASCIMENTO, NU_MES_NASCIMENTO, NU_ANO_NASCIMENTO, TP_SEXO, TP_COR_RACA, CO_MUNICIPIO_NASCIMENTO, CO_CURSO	99.94%	99.94%	99.97%	1.0631
8	NU_DIA_NASCIMENTO, NU_MES_NASCIMENTO, NU_ANO_NASCIMENTO, TP_SEXO, TP_COR_RACA, CO_MUNICIPIO_NASCIMENTO, CO_CURSO, TP_ESCOLA_CONCLUSAO_ENS_MEDIO	99.96%	99.96%	99.98%	1.0632
9	NU_DIA_NASCIMENTO, NU_MES_NASCIMENTO, NU_ANO_NASCIMENTO, TP_SEXO, TP_COR_RACA, CO_MUNICIPIO_NASCIMENTO, TP_NACIONALIDADE, CO_CURSO, TP_ESCOLA_CONCLUSAO_ENS_MEDIO	99.96%	99.96%	99.98%	1.0632
10	NU_DIA_NASCIMENTO, NU_MES_NASCIMENTO, NU_ANO_NASCIMENTO, TP_SEXO, TP_COR_RACA, CO_MUNICIPIO_NASCIMENTO, TP_NACIONALIDADE, CO_PAIS_ORIGEM, CO_CURSO, TP_ESCOLA_CONCLUSAO_ENS_MEDIO	99.96%	99.96%	99.98%	1.0632
11	NU_DIA_NASCIMENTO, NU_MES_NASCIMENTO, NU_ANO_NASCIMENTO, TP_SEXO, TP_COR_RACA, CO_MUNICIPIO_NASCIMENTO, TP_NACIONALIDADE, CO_PAIS_ORIGEM, CO_IES, CO_CURSO, TP_ESCOLA_CONCLUSAO_ENS_MEDIO	99.96%	99.96%	99.98%	1.0632


Tabela 4.5.10: Experimento 11: Quaseidentificadores com maior degradação de privacidade em ataques de inferência de atributo coletiva (ACU) sobre atributo sensível IN_DEFICIENCIA no Censo da Educação Superior de 2018. Recorde que a degradação determinística de privacidade é dada pela diferença entre o sucesso do a posteriori e o a priori do adversário, enquanto a degradação probabilística é dada pela razão dos mesmos dois termos.

#	Quaseidentificadores	Sucesso determinístico do adversário		Sucesso probabilístico do adversário	
		Sucesso a priori = 0.00%		Sucesso a priori = 47.28%	
		Sucesso a posteriori	Degradação privacidade	Sucesso a posteriori	Degradação privacidade
1	CO_CURSO	24.93%	24.93%	82.71%	1.7492
2	CO_MUNICIPIO_NASCIMENTO, CO_CURSO	38.74%	38.74%	85.26%	1.8032
3	NU_DIA_NASCIMENTO, NU_ANO_NASCIMENTO, CO_CURSO	72.23%	72.23%	91.28%	1.9305
4	NU_DIA_NASCIMENTO, NU_MES_NASCIMENTO, NU_ANO_NASCIMENTO, CO_CURSO	92.25%	92.25%	97.03%	2.0521
5	NU_DIA_NASCIMENTO, NU_MES_NASCIMENTO, NU_ANO_NASCIMENTO, CO_MUNICIPIO_NASCIMENTO, CO_CURSO	98.12%	98.12%	99.20%	2.0979
6	NU_DIA_NASCIMENTO, NU_MES_NASCIMENTO, NU_ANO_NASCIMENTO, TP_COR_RACA, CO_MUNICIPIO_NASCIMENTO, CO_CURSO	99.03%	99.03%	99.57%	2.1058
7	NU_DIA_NASCIMENTO, NU_MES_NASCIMENTO, NU_ANO_NASCIMENTO, TP_SEXO, TP_COR_RACA, CO_MUNICIPIO_NASCIMENTO, CO_CURSO	99.36%	99.36%	99.71%	2.1088
8	NU_DIA_NASCIMENTO, NU_MES_NASCIMENTO, NU_ANO_NASCIMENTO, TP_SEXO, TP_COR_RACA, CO_MUNICIPIO_NASCIMENTO, CO_CURSO, TP_ESCOLA_CONCLUSAO_ENS_MEDIO	99.52%	99.52%	99.78%	2.1103
9	NU_DIA_NASCIMENTO, NU_MES_NASCIMENTO, NU_ANO_NASCIMENTO, TP_SEXO, TP_COR_RACA, CO_MUNICIPIO_NASCIMENTO, TP_NACIONALIDADE, CO_CURSO, TP_ESCOLA_CONCLUSAO_ENS_MEDIO	99.52%	99.52%	99.78%	2.1103
10	NU_DIA_NASCIMENTO, NU_MES_NASCIMENTO, NU_ANO_NASCIMENTO, TP_SEXO, TP_COR_RACA, CO_MUNICIPIO_NASCIMENTO, TP_NACIONALIDADE, CO_PAIS_ORIGEM, CO_CURSO, TP_ESCOLA_CONCLUSAO_ENS_MEDIO	99.52%	99.52%	99.78%	2.1103
10	NU_DIA_NASCIMENTO, NU_MES_NASCIMENTO, NU_ANO_NASCIMENTO, TP_SEXO, TP_COR_RACA, CO_MUNICIPIO_NASCIMENTO, TP_NACIONALIDADE, CO_IES, CO_CURSO, TP_ESCOLA_CONCLUSAO_ENS_MEDIO	99.52%	99.52%	99.78%	2.1103
11	NU_DIA_NASCIMENTO, NU_MES_NASCIMENTO, NU_ANO_NASCIMENTO, TP_SEXO, TP_COR_RACA, CO_MUNICIPIO_NASCIMENTO, TP_NACIONALIDADE, CO_PAIS_ORIGEM, CO_IES, CO_CURSO, TP_ESCOLA_CONCLUSAO_ENS_MEDIO	99.52%	99.52%	99.78%	2.1103


Tabela 4.5.11: Experimento 11: Quaseidentificadores com maior degradação de privacidade em ataques de inferência de atributo coletiva (ACU) sobre atributo sensível IN_FINANCIAMENTO_ESTUDANTIL no Censo da Educação Superior de 2018. Recorde que a degradação determinística de privacidade é dada pela diferença entre o sucesso do a posteriori e o a priori do adversário, enquanto a degradação probabilística é dada pela razão dos mesmos dois termos.




(a) Usando [CO_CURSO] como quaseidentificador



(b) Usando [NU_DIA_NASCIMENTO, NU_MES_NASCIMENTO, NU_ANO_NASCIMENTO, CO_CURSO] como quaseidentificadores




(c) Usando [NU_DIA_NASCIMENTO, NU_MES_NASCIMENTO, NU_ANO_NASCIMENTO, TP_SEXO, TP_COR_RACA, CO_MUNICIPIO_NASCIMENTO, CO_CURSO] como quaseidentificadores




(d) Usando [NU_DIA_NASCIMENTO, NU_MES_NASCIMENTO, NU_ANO_NASCIMENTO, TP_SEXO, TP_COR_RACA, CO_MUNICIPIO_NASCIMENTO, TP_NACIONALIDADE, CO_PAIS_ORIGEM, CO_IES, CO_CURSO, TP_ESCOLA_CONCLUSAO_ENS_MEDIO] como quaseidentificadores


Figura 4.5.12: Experimento 11: Histogramas da distribuição de sucesso probabilístico a posteriori em ataques de inferência de atributo coletiva em uma única base de dados (ACU) sobre atributo sensível IN_DEFICIENCIA no Censo da Educação Superior de 2018. Estes histogramas devem ser interpretados da mesma forma que seus equivalentes na Figura 4.3.5.




(a) Usando [CO_CURSO] como quaseidentificador



(b) Usando [NU_DIA_NASCIMENTO, NU_MES_NASCIMENTO, NU_ANO_NASCIMENTO, CO_CURSO] como quaseidentificadores



(c) Usando [NU_DIA_NASCIMENTO, NU_MES_NASCIMENTO, NU_ANO_NASCIMENTO, TP_SEXO, TP_COR_RACA, CO_MUNICIPIO_NASCIMENTO, CO_CURSO] como quaseidentificadores



(d) Usando [NU_DIA_NASCIMENTO, NU_MES_NASCIMENTO, NU_ANO_NASCIMENTO, TP_SEXO, TP_COR_RACA, CO_MUNICIPIO_NASCIMENTO, TP_NACIONALIDADE, CO_PAIS_ORIGEM, CO_IES, CO_CURSO, TP_ESCOLA_CONCLUSAO_ENS_MEDIO] como quaseidentificadores

Figura 4.5.13: Experimento 11: Histogramas da distribuição de sucesso probabilístico a posteriori em ataques de inferência de atributo coletiva em uma única base de dados (ACU) sobre atributo sensível `IN_FINANCIAMENTO_ESTUDANTIL` no Censo da Educação Superior de 2018. Estes histogramas devem ser interpretados da mesma forma que seus equivalentes na Figura 4.3.5.

Nossa segunda análise de ataque ACU concerne ao Censo da Educação Básica de 2019.

Experimento 12 (Ataques de inferência de atributo coletiva ACU sobre atributos sensíveis IN_NECESSIDADE_ESPECIAL e IN_TRANSPORTE_PUBLICO no Censo da Educação Básica de 2019). Inicialmente composta por 51 166 723 registros, a base de dados do Censo da Educação Básica de 2019 teve seu tamanho reduzido para 47 640 822 registros após o tratamento para a remoção de indivíduos com registros múltiplos. Assim como para os ataques de reidentificação coletiva, os 10 atributos selecionados como candidatos a quaseidentificadores estão listados na Tabela 4.1.1b. Também aqui consideramos que um adversário poderia obter como informação auxiliar qualquer subconjunto não-vazio desses candidatos a quaseidentificadores, o que corresponde a $2^{10} - 1 = 1023$ combinações possíveis. Medimos, então, a degradação de privacidade (tanto determinística quanto probabilística) para cada uma dessas combinações de quaseidentificadores. Consideramos dois tipos de ataques ACU sobre a base de dados do Censo da Educação Básica de 2019: um em que o atributo sensível é IN_NECESSIDADE_ESPECIAL e outro em que o atributo sensível é IN_TRANSPORTE_PUBLICO. Ambos atributos estão especificados na Tabela 4.1.2b.

Os resultados obtidos estão organizados da seguinte forma:

- A Figura 4.5.14 representa as medidas de sucesso determinístico e probabilístico do adversário para cada uma das diferentes combinações de quaseidentificadores que podem ser usados como informação auxiliar pelo adversário.
- As Tabelas 4.5.15 e 4.5.16 resumizam quais combinações de quaseidentificadores levam à maior degradação de privacidade nestes ataques para os atributos sensíveis IN_NECESSIDADE_ESPECIAL e IN_TRANSPORTE_PUBLICO, respectivamente.
- As Figuras 4.5.17 e 4.5.18 apresentam histogramas referentes aos piores casos para conjuntos de quaseidentificadores de variados tamanhos para as variáveis sensíveis IN_NECESSIDADE_ESPECIAL e IN_TRANSPORTE_PUBLICO, respectivamente.

Separamos a discussão dos resultados pelo tipo de degradação de privacidade.

- **Sucesso determinístico do adversário:** A Tabela 4.5.15 demonstra que, quando o atributo considerado como sensível é IN_NECESSIDADE_ESPECIAL, o sucesso determinístico a priori do adversário é de 0%, significando que sem informação auxiliar nenhum indivíduo pode ter o valor deste atributo inferido com absoluta certeza. Por outro lado, uma combinação 2 quaseidentificadores permite ao adversário inferir com absoluta certeza o valor do atributo sensível em até 49.52% dos indivíduos na base; enquanto uma combinação de 4 quaseidentificadores já aumenta essa fração para 93.88%. Já o uso de todos os 10 quaseidentificadores eleva o risco a até 97.77%.


Por sua vez, Tabela 4.5.16 demonstra que, quando o atributo considerado como sensível é IN_TRANSPORTE_PUBLICO, o sucesso determinístico a priori do adversário

também é de 0%. Entretanto, comparado com o caso em que o atributo sensível é `IN_NECCESSIDADE_ESPECIAL`, aqui o sucesso determinístico do adversário cresce mais lentamente com o número de quaseidentificadores utilizados. Por exemplo, apesar de um conjunto de 2 quaseidentificadores já poder levar a até 55.44% dos registros terem seu atributo `IN_TRANSPORTE_PUBLICO` inferido; um conjunto de 4 identificadores aumenta essa fração para até 84.29%. Já o uso de todos os 10 quaseidentificadores eleva o risco a quase 93.38%.


- **Sucesso probabilístico do adversário:** A Tabela 4.5.15 demonstra que, quando o atributo considerado como sensível é `IN_NECCESSIDADE_ESPECIAL`, o sucesso probabilístico a priori do adversário já é de 97.38%. Além disso, um conjunto de 4 quaseidentificadores já eleva o sucesso probabilístico a posteriori a até 98.66%.

Por sua vez, a Tabela 4.5.16 demonstra que, quando o atributo considerado como sensível é `IN_TRANSPORTE_PUBLICO`, o sucesso probabilístico a priori do adversário é de 82.06%. Neste caso um conjunto de um conjunto de 2 quaseidentificadores eleva o risco a até 90.82% dos registros terem seu atributo `IN_TRANSPORTE_PUBLICO` inferido; um conjunto de 4 identificadores aumenta essa fração para até 95.23%. Já o uso de todos os 10 quaseidentificadores eleva o risco a quase 97.53%.


<




(a) Sucesso determinístico para atributo sensível IN_NECESSIDADE_ESPECIAL.



(b) Sucesso probabilístico para atributo sensível IN_NECESSIDADE_ESPECIAL.



(c) Sucesso determinístico para atributo sensível IN_TRANSPORTE_PUBLICO.



(d) Sucesso probabilístico para atributo sensível IN_TRANSPORTE_PUBLICO.


Figura 4.5.14: Experimento 12: Sucesso do adversário em ataques de inferência de atributo coletiva em uma única base de dados (ACU) no Censo da Educação Básica de 2019. Estes gráficos devem ser interpretados da mesma forma que aqueles da Figura 4.3.3.

#	Quaseidentificadores	Sucesso determinístico do adversário		Sucesso probabilístico do adversário	
		Sucesso a priori = 0.00%		Sucesso a priori = 97.38%	
		Sucesso a posteriori	Degradação privacidade	Sucesso a posteriori	Degradação privacidade
1	CO_ENTIDADE	11.29%	11.29%	97.74%	1.0037
2	CO_MUNICIPIO_NASC, CO_ENTIDADE	31.54%	31.54%	97.88%	1.0052
2	NU_MES, CO_ENTIDADE	49.52%	49.52%	97.74%	1.0038
3	NU_ANO, CO_MUNICIPIO_NASC, CO_ENTIDADE	65.29%	65.29%	98.19%	1.0083
3	NU_MES, NU_ANO, CO_ENTIDADE	88.17%	88.17%	98.18%	1.0082
4	NU_MES, NU_ANO, CO_MUNICIPIO_NASC, CO_ENTIDADE	92.88%	92.88%	98.66%	1.0131
4	NU_MES, NU_ANO, TP_COR_RACA, CO_ENTIDADE	93.28%	93.28%	98.53%	1.0118
5	NU_MES, NU_ANO, TP_COR_RACA, CO_MUNICIPIO_NASC, CO_ENTIDADE	95.91%	95.91%	98.97%	1.0163
5	NU_MES, NU_ANO, TP_SEXO, TP_COR_RACA, CO_ENTIDADE	96.08%	96.08%	98.84%	1.015
6	NU_MES, NU_ANO, TP_SEXO, TP_COR_RACA, CO_MUNICIPIO_NASC, CO_ENTIDADE	97.63%	97.63%	99.22%	1.0189
7	NU_MES, NU_ANO, TP_SEXO, TP_COR_RACA, CO_MUNICIPIO_NASC, CO_MUNICIPIO_END, CO_ENTIDADE	97.77%	97.77%	99.26%	1.0193
8	NU_MES, NU_ANO, TP_SEXO, TP_COR_RACA, CO_PAIS_ORIGEM, CO_MUNICIPIO_NASC, CO_MUNICIPIO_END, CO_ENTIDADE	97.77%	97.77%	99.26%	1.0193
9	NU_MES, NU_ANO, TP_SEXO, TP_COR_RACA, TP_NACIONALIDADE, CO_PAIS_ORIGEM, CO_MUNICIPIO_NASC, CO_MUNICIPIO_END, CO_ENTIDADE	97.77%	97.77%	99.26%	1.0193
9	NU_MES, NU_ANO, TP_SEXO, TP_COR_RACA, CO_PAIS_ORIGEM, CO_MUNICIPIO_NASC, CO_MUNICIPIO_END, CO_ENTIDADE, TP_DEPENDENCIA	97.77%	97.77%	99.26%	1.0193
10	NU_MES, NU_ANO, TP_SEXO, TP_COR_RACA, TP_NACIONALIDADE, CO_PAIS_ORIGEM, CO_MUNICIPIO_NASC, CO_MUNICIPIO_END, CO_ENTIDADE, TP_DEPENDENCIA	97.77%	97.77%	99.26%	1.0193


Tabela 4.5.15: Experimento 12: Quaseidentificadores com maior degradação de privacidade em ataques de inferência de atributo coletiva (ACU) sobre atributo sensível IN_NECCESSIDADE_ESPECIAL no Censo da Educação Básica de 2019. Recorde que a degradação determinística de privacidade é dada pela diferença entre o sucesso do a posteriori e o a priori do adversário, enquanto a degradação probabilística é dada pela razão dos mesmos dois termos.

#	Quaseidentificadores	Sucesso determinístico do adversário		Sucesso probabilístico do adversário	
		Sucesso a priori = 0.00%		Sucesso a priori = 82.06%	
		Sucesso a posteriori	Degradação privacidade	Sucesso a posteriori	Degradação privacidade
1	CO_ENTIDADE	41.48%	41.48%	89.65%	1.0926
2	CO_MUNICIPIO_NASC, CO_ENTIDADE	51.25%	51.25%	90.82%	1.1067
2	NU_ANO, CO_ENTIDADE	55.44%	55.44%	90.71%	1.1054
3	NU_MES, NU_ANO, CO_ENTIDADE	74.66%	74.66%	92.85%	1.1315
4	NU_MES, NU_ANO, CO_MUNICIPIO_NASC, CO_ENTIDADE	84.29%	84.29%	95.23%	1.1605
5	NU_MES, NU_ANO, TP_COR_RACA, CO_MUNICIPIO_NASC, CO_ENTIDADE	89.34%	89.34%	96.43%	1.1751
6	NU_MES, NU_ANO, TP_SEXO, TP_COR_RACA, CO_MUNICIPIO_NASC, CO_ENTIDADE	93.05%	93.05%	97.41%	1.1871
7	NU_MES, NU_ANO, TP_SEXO, TP_COR_RACA, CO_MUNICIPIO_NASC, CO_MUNICIPIO_END, CO_ENTIDADE	93.38%	93.38%	97.53%	1.1885
8	NU_MES, NU_ANO, TP_SEXO, TP_COR_RACA, CO_PAIS_ORIGEM, CO_MUNICIPIO_NASC, CO_MUNICIPIO_END, CO_ENTIDADE	93.38%	93.38%	97.53%	1.1885
9	NU_MES, NU_ANO, TP_SEXO, TP_COR_RACA, TP_NACIONALIDADE, CO_PAIS_ORIGEM, CO_MUNICIPIO_NASC, CO_MUNICIPIO_END, CO_ENTIDADE	93.38%	93.38%	97.53%	1.1885
9	NU_MES, NU_ANO, TP_SEXO, TP_COR_RACA, CO_PAIS_ORIGEM, CO_MUNICIPIO_NASC, CO_MUNICIPIO_END, CO_ENTIDADE, TP_DEPENDENCIA	93.38%	93.38%	97.53%	1.1885
10	NU_MES, NU_ANO, TP_SEXO, TP_COR_RACA, TP_NACIONALIDADE, CO_PAIS_ORIGEM, CO_MUNICIPIO_NASC, CO_MUNICIPIO_END, CO_ENTIDADE, TP_DEPENDENCIA	93.38%	93.38%	97.53%	1.1885


Tabela 4.5.16: Experimento 12: Quaseidentificadores com maior degradação de privacidade em ataques de inferência de atributo coletiva (ACU) sobre atributo sensível IN_TRANSPORTE_PUBLICO no Censo da Educação Básica de 2019. Recorde que a degradação determinística de privacidade é dada pela diferença entre o sucesso do a posteriori e o a priori do adversário, enquanto a degradação probabilística é dada pela razão dos mesmos dois termos.




(a) Usando [CO_ENTIDADE] como quaseidentificador



(b) Usando [NU_MES, NU_ANO, CO_MUNICIPIO_NASC, CO_ENTIDADE] como quaseidentificadores




(c) Usando [NU_MES, NU_ANO, TP_SEXO, TP_COR_RACA, CO_MUNICIPIO_NASC, CO_MUNICIPIO_END, CO_ENTIDADE] como quaseidentificadores




(d) Usando [NU_MES, NU_ANO, TP_SEXO, TP_COR_RACA, TP_NACIONALIDADE, CO_PAIS_ORIGEM, CO_MUNICIPIO_NASC, CO_MUNICIPIO_END, CO_ENTIDADE, TP_DEPENDENCIA] como quaseidentificadores


Figura 4.5.17: Experimento 12: Histogramas da distribuição de sucesso probabilístico a posteriori em ataques de inferência de atributo coletiva em uma única base de dados (ACU) sobre atributo sensível IN_NECCESSIDADE_ESPECIAL no Censo da Educação Básica de 2019. Estes histogramas devem ser interpretados da mesma forma que seus equivalentes na Figura 4.3.5.




(a) [CO_ENTIDADE]



(b) [NU_MES, NU_ANO, CO_MUNICIPIO_NASC, CO_ENTIDADE]



(c) [NU_MES, NU_ANO, TP_SEXO, TP_COR_RACA, CO_MUNICIPIO_NASC, CO_MUNICIPIO_END, CO_ENTIDADE]



(d) [NU_MES, NU_ANO, TP_SEXO, TP_COR_RACA, TP_NACIONALIDADE, CO_PAIS_ORIGEM, CO_MUNICIPIO_NASC, CO_MUNICIPIO_END, CO_ENTIDADE, TP_DEPENDENCIA]

Figura 4.5.18: Experimento 12: Histogramas da distribuição de sucesso probabilístico a posteriori em ataques de inferência de atributo coletiva em uma única base de dados (ACU) sobre atributo sensível IN_TRANSPORTE_PUBLICO no Censo da Educação Básica de 2019. Estes histogramas devem ser interpretados da mesma forma que seus equivalentes na Figura 4.3.5.

5 Modelo de ataques longitudinais

De forma análoga ao que fizemos na Seção 3 para ataques em uma única base de dados, na presente seção especificamos os ataques em que o adversário está tentando obter informação sensível a partir de um conjunto longitudinal de bases de dados. Nestes ataques o adversário pode se beneficiar de novas bases que são liberadas ao longo do tempo, usando-as como informação auxiliar para aumentar suas chances de sucesso.

O estudo de ataques longitudinais é particularmente importante no contexto do Inep porque a divulgação das bases dos Censos Educacionais é feita anualmente, gerando um conjunto de dados longitudinal que cresce ano a ano. Dessa forma um adversário poderia cruzar a informação a respeito de um titular de dados ao longo das divulgações em vários anos e assim aumentar consideravelmente a chance de inferência de informação sensível.

Para propiciar uma leitura mais fluida do presente documento, os detalhes matemáticos da formalização dos ataques longitudinais é reservada ao Anexo A.2. As análises experimentais quantitativas da aplicação do modelo às bases dos Censos Educacionais do Inep são apresentadas na Seção 6.

5.1 Premissas sobre ataques longitudinais

Para todos os ataques longitudinais apresentados a seguir, assumimos as seguintes premissas.

- PL0** Existe um *conjunto longitudinal* $\mathcal{L}_{\mathcal{D}} = \{D_1, D_2, \dots, D_k\}$ de $k \geq 1$ bases de dados de interesse, sendo cada base D_i (com $1 \leq i \leq k$) definida sobre um conjunto de atributos $\mathcal{A}_i$.
- PL1** Cada indivíduo de interesse possui no máximo um registro em cada base de dados $D_i \in \mathcal{L}_{\mathcal{D}}$.
- PL2** Todo indivíduo tem um identificador único que apresenta o mesmo valor em todos seus registros em qualquer base de $\mathcal{L}_{\mathcal{D}}$. Em outras palavras, toda vez que um mesmo indivíduo aparece em bases distintas, ele aparece com o mesmo identificador único. Formalmente, existe um *atributo de identificação única* a_{id} comum a todas as bases

em $\mathcal{L}_{\mathcal{D}}$ (i.e., $a_{id} \in \mathcal{A}_i$ para $1 \leq i \leq k$), tal que sempre que um mesmo indivíduo for titular de um registro $x \in D_i$ e um registro $x' \in D_j$ em duas bases $D_i, D_j \in \mathcal{L}_{\mathcal{D}}$, então $x[a_{id}] = x'[a_{id}]$.

PL3 Existe um conjunto $\mathcal{Q}_{ID}$ de *quaseidentificadores* comuns a todas as bases em $\mathcal{L}_{\mathcal{D}}$ (i.e., $\mathcal{Q}_{ID} \subseteq \mathcal{A}_i$ para $1 \leq i \leq k$), correspondendo a atributos cujos valores para alguns indivíduos podem ser conhecidos ou aprendidos pelo adversário em todas as bases.

PL4 O adversário pode agregar as informações contidas nas bases do conjunto longitudinal $\mathcal{L}_{\mathcal{D}} = \{D_1, D_2, \dots, D_k\}$ aplicando sucessivas operações de *left outer join*,¹ todas tomadas sobre o atributo identificador único a_{id} , da seguinte forma. Primeiro o adversário aplica um *left outer join* entre as bases D_1 e D_2 , obtendo uma nova base $D_1 \bowtie D_2$ sobre o conjunto de atributos $\mathcal{A}_1 \uplus (\{\mathcal{A}_2 \setminus \{a_{id}\}\})$.² Em seguida, o adversário aplica um novo *left outer join* entre $D_1 \bowtie D_2$ e a base D_3 , obtendo uma nova base $(D_1 \bowtie D_2) \bowtie D_3$ sobre o conjunto de atributos $\mathcal{A}_1 \uplus (\{\mathcal{A}_2 \setminus \{a_{id}\}\}) \uplus (\{\mathcal{A}_3 \setminus \{a_{id}\}\})$. O processo é sucessivamente repetido até se atingir a base D_k . Formalmente, a agregação de todas as bases em $\mathcal{L}_{\mathcal{D}}$ pode ser definida recursivamente como a seguir:

$$\text{agreg}(\mathcal{L}_{\mathcal{D}}) \stackrel{\text{def}}{=} \begin{cases} D_1, & \text{se } k=1, \\ \text{agreg}(\{D_1, D_2, \dots, D_{k-1}\}) \bowtie D_k, & \text{se } k \geq 2, \end{cases}$$

Note que $\text{agreg}(\mathcal{L}_{\mathcal{D}})$ é uma base de dados definida sobre o conjunto de atributos $\mathcal{A}_{\mathcal{L}_{\mathcal{D}}} = \mathcal{A}_1 \uplus \left(\biguplus_{i=2}^k \mathcal{A}_i \setminus \{a_{id}\} \right)$.³

¹O *left outer join* é uma operação de manipulação de bases de dados que, ao ser aplicada em duas bases D_l (normalmente chamada de *base da esquerda*) e D_r (normalmente chamada de *base da direita*), retorna uma nova base $D_l \bowtie D_r$ contendo todos os registros de D_l concatenados com os registros correspondentes em D_r , em que o pareamento é feito entre registros de cada base que compartilhem exatamente os mesmos valores para um determinado conjunto de atributos. Caso um registro em D_l não tenha correspondente em D_r , a base resultante $D_l \bowtie D_r$ contém apenas o registro da esquerda concatenado com valores nulos para o registro da direita. O *left outer join* entre as bases D_l e D_r tomado sobre o atributo a_{id} pode ser expresso na linguagem SQL como:

```
select *
from D_l left outer join D_r
where D_l.a_id = D_r.a_id
```

O Exemplo 13 provê uma ilustração concreta de como funciona o *left outer join*.

²Dados dois conjuntos A_i e A_j , com $i \neq j$, sua *união disjunta* é um novo conjunto $A_i \uplus A_j$ que contém cada elemento de A_i e cada elemento de A_j , todos devidamente rotulados com o seu conjunto de origem. Formalmente:

$$A_i \uplus A_j \stackrel{\text{def}}{=} (A_i \times \{i\}) \cup (A_j \times \{j\}) .$$

Por exemplo, se $A_1 = \{a, b\}$ e $A_2 = \{b, c\}$, então $A_1 \uplus A_2 = \{(a, 1), (b, 1), (b, 2), (c, 2)\}$. Em particular, note que uma vez que tanto A_1 quanto A_2 contêm o elemento b , a união disjunta $A_1 \uplus A_2$ contém duas cópias de b , cada uma devidamente rotulada com seu conjunto de origem: $(b, 1)$ para o elemento vindo de A_1 e $(b, 2)$ para o elemento vindo de A_2 .

³Note que $\mathcal{A}_{\mathcal{L}_{\mathcal{D}}}$ contém todos os atributos de $\mathcal{A}_1$, correspondentes à base D_1 , e, para cada base $D_i \in \mathcal{L}_{\mathcal{D}}$, com $i \neq 1$, contém apenas os atributos $\mathcal{A}_i \setminus \{a_{id}\}$ distintos do atributo identificador único a_{id} ,

Dado um elemento $x \in \text{agreg}(\mathcal{L}_{\mathcal{D}})$, denotamos por $x[(Q_{ID}, i)]$ o sub-registro de x correspondendo aos valores dos quaseidentificadores (Q_{ID}, i) de x na base $D_i \in \mathcal{L}_{\mathcal{D}}$, e (usando uma forma de polimorfismo notacional) por $x[Q_{ID}]$ o sub-registro correspondendo a todos os valores de todos os quaseidentificadores Q_{ID} em todas as bases $D_i \in \mathcal{L}_{\mathcal{D}}$, que têm como domínio o produto cartesiano $\text{dom}(Q_{ID} \mid \mathcal{L}_{\mathcal{D}}) = (\text{dom}(Q_{ID}))^k$.

PL5 O adversário pode computar distribuições marginais de probabilidade sobre registros e sobre atributos da nova base agregada $\text{agreg}(\mathcal{L}_{\mathcal{D}})$ usando fórmulas análogas às Equações 3.1 e 3.2, respectivamente.

PL6 O adversário visa obter informação sobre indivíduos presentes na base de dados D_1 –chamada de *base focal*– e usa as demais bases $D_2, D_3, \dots, D_k$ –chamadas de *bases auxiliares*– apenas como informação auxiliar para maximizar o sucesso do ataque à base focal. Por esta razão, o sucesso do adversário em ataques longitudinais, tanto determinísticos quando probabilísticos, segue as seguintes premissas.

PL6-A O sucesso a priori é medido em relação à base focal D_1 , ou seja, a primeira base à qual o adversário tem acesso.

PL6-B O sucesso a posteriori é medido em relação à agregação $\text{agreg}(\mathcal{L}_{\mathcal{D}})$ da informação presente em todas as bases do conjunto longitudinal, incluindo tanto a base focal D_1 quanto as bases auxiliares $D_2, D_3, \dots, D_k$.

PL7 O conhecimento prévio do adversário inclui a base focal D_1 do conjunto longitudinal $\mathcal{L}_{\mathcal{D}}$, mas não as bases auxiliares $D_2, D_3, \dots, D_k$, e o fato de que todos os indivíduos de interesse encontram-se em cada base do conjunto. O ataque consiste em o adversário obter como informação auxiliar (via outras fontes que não o conjunto $\mathcal{L}_{\mathcal{D}}$) os valores dos quaseidentificadores em Q_{ID} para alguns indivíduos e cruzar esses valores com as bases do conjunto (tanto a focal quanto as auxiliares) para obter informação sensível a respeito destes indivíduos na base focal D_1 . A degradação de privacidade é, portanto, medida como a comparação do sucesso do adversário a posteriori –i.e., após usar a informação auxiliar sobre os valores dos quaseidentificadores– e seu sucesso a priori –i.e., antes de poder usar a informação sobre quaseidentificadores. Esses elementos são esquematizados na Figura 5.1.1.

O seguinte exemplo demonstra o uso das premissas **PL0–PL5** estabelecidas acima e será utilizado como nosso exemplo condutor para ataques longitudinais.

Exemplo 13 (Exemplo condutor para ataques longitudinais). Considere o conjunto longitudinal $\mathcal{L}_{\mathcal{D}} = \{D_1, D_2\}$ em que a base focal D_1 (Tabela 5.1.2a) é definida sobre o conjunto de atributos $\mathcal{A}_1 = \{id, idade, sexo, profissão, condição\}$, enquanto a base auxiliar

uma vez que cada titular tem o mesmo valor para este atributo em todas as bases e ele é, portanto, redundante. Por exemplo, se $\mathcal{L}_{\mathcal{D}} = \{D_1, D_2, D_3\}$, com cada base definida sobre os conjuntos de atributos $\mathcal{A}_1 = \{a_{id}, doença\}$, $\mathcal{A}_2 = \{a_{id}, doença, data\}$ e $\mathcal{A}_3 = \{a_{id}, data, hospital\}$, respectivamente, teremos que a agregação $\text{agreg}(\mathcal{L}_{\mathcal{D}})$ é uma nova base de dados definida sobre o conjunto de atributos $\mathcal{A}_{\mathcal{L}_{\mathcal{D}}} = \{(a_{id}, 1), (doença, 1), (doença, 2), (data, 2), (data, 3), (hospital, 3)\}$.




Figura 5.1.1: Esquema de ataque longitudinal. No tipo de ataque aqui considerado a degradação de privacidade é medida em termos do quanto a informação auxiliar a respeito de quaseidentificadores obtida por um adversário pode facilitar a reidentificação ou a inferência de atributos sensíveis de indivíduos nas bases dos Censos Educacionais divulgadas pelo Inep na forma atual.

D_2 (Tabela 5.1.2b) é definida sobre o conjunto de atributos $\mathcal{A}_1 = \{id, idade, profissão\}$. Assuma, ainda, que id é o atributo de identificação única sobre as bases de $\mathcal{L}_D$. Dessa forma, os registros que têm valor de identificador 6, por exemplo, em ambas as tabelas correspondem ao mesmo titular. Note que cada indivíduo distinto possui no máximo um registro em cada base.

Como definido na Premissa **PL4**, podemos realizar a agregação das bases em $\mathcal{L}_D$ via consecutivas operações de *left outer join*, obtendo a nova base $agreg(\mathcal{L}_D) = D_1 \bowtie D_2$ (Tabela 5.1.2c) definida sobre o conjunto de atributos $\mathcal{A}_{agreg(\mathcal{L}_D)} = \{(id, 1), (idade, 1), (sexo, 1), (profissão, 1), (condição, 1), (idade, 2), (profissão, 2)\}$. Observe que como o registro de identificador 10 não consta na base D_2 , ele aparece na agregação $agreg(\mathcal{L}_D)$ com valores nulos para os atributos $(idade, 2)$ e $(profissão, 2)$. Observe também que, como o registro de identificador 11 não consta na base D_1 , ele não aparece na agregação $agreg(\mathcal{L}_D)$.

Por fim, note que o adversário pode computar distribuições marginais de probabilidade sobre registros e atributos da nova base de dados agregada $agreg(\mathcal{L}_D)$ usando formas análogas às Equações 3.1 e 3.2, conforme ilustrado no Exemplo 2.

◁

Estamos prontos, agora, para definir os ataques longitudinais de que tratamos neste documento.

<i>id</i>	<i>idade</i>	<i>sexo</i>	<i>profissão</i>	<i>condição</i>
1	25	F	1	coração
2	25	F	1	asma
3	25	F	3	asma
4	25	M	2	asma
5	25	M	2	coração
6	49	F	3	asma
7	49	F	3	asma
8	49	F	5	coração
9	49	M	4	coração
10	60	M	4	coração

(a) Base de dados focal D_1 .

<i>id</i>	<i>idade</i>	<i>profissão</i>
1	26	2
2	26	1
3	26	3
4	26	2
5	26	2
6	50	4
7	50	3
8	50	5
9	50	4
11	19	1

(b) Base de dados auxiliar D_2 .

$(id,1)$	$(idade,1)$	$(sexo,1)$	$(profissão,1)$	$(condição,1)$	$(idade,2)$	$(profissão,2)$
1	25	F	1	coração	26	2
2	25	F	1	asma	26	1
3	25	F	3	asma	26	3
4	25	M	2	asma	26	2
5	25	M	2	coração	26	2
6	49	F	3	asma	50	4
7	49	F	3	asma	50	3
8	49	F	5	coração	50	5
9	49	M	4	coração	50	4
10	60	M	4	coração	—	—

(c) Agregação $agreg(\mathcal{L}_D)=D_1 \bowtie D_2$.Tabela 5.1.2: Conjunto longitudinal $\mathcal{L}_D=\{D_1, D_2\}$ e sua agregação para o Exemplo 13.

5.2 Ataque de reidentificação individual longitudinal (RIL)

Em um *ataque de reidentificação individual longitudinal (RIL)*, o adversário tem acesso a uma coleção longitudinal de bases de dados e conhece os valores de um conjunto de quaseidentificadores de um indivíduo específico na base focal pré-determinado como alvo. O adversário tem como objetivo reidentificar o indivíduo-alvo, i.e., estabelecer qual registro na base focal corresponde a esse indivíduo. A especificação deste tipo ataque é análoga à de um ataque *RIU* (introduzido na Seção 3.2), com a única diferença de que, de acordo com as premissas **PL6**, **PL6a** e **PL6b** sobre ataques longitudinais, o sucesso a priori do adversário é tomado em relação à base focal, enquanto seu sucesso a posteriori é tomado em relação à agregação da informação presente em todas as bases do conjunto longitudinal.

A degradação de privacidade do ataque é medida como uma comparação entre o sucesso

a priori do adversário (i.e., conhecendo apenas a base focal, mas não as bases auxiliares nem os valores dos quaseidentificadores) e seu sucesso a posteriori (i.e., após descobrir os valores dos quaseidentificadores e cruzá-los com todo o conjunto longitudinal). Mais precisamente, temos as seguintes condições para um ataque RIL:

- **Quantificação da degradação determinística de privacidade** A degradação determinística de privacidade em um ataque RIL ocorre se, e somente se, o adversário não for capaz de reidentificar com absoluta certeza o indivíduo-alvo na base focal antes de efetuar o ataque, mas for capaz de fazê-lo após efetuar o ataque.
- **Quantificação da degradação probabilística de privacidade:** Na medição do sucesso probabilístico de um ataque RIL, não se exige que o adversário realize a reidentificação do indivíduo na base focal pré-determinado como alvo com absoluta certeza; em vez disso quantifica-se a probabilidade de que o adversário corretamente reidentifique tal indivíduo-alvo nessa base focal. Quanto maior essa probabilidade, mais exitoso é o adversário. A degradação probabilística de privacidade do ataque é definida, então, como a razão pela qual sua execução aumenta o sucesso probabilístico do adversário.

A Definição 28 no Anexo A.2 formaliza matematicamente o ataque RIL. A seguir ilustramos como o ataque é executado em nosso exemplo condutor.

Exemplo 14 (Execução de ataque de reidentificação individual longitudinal (RIL)). Considere novamente o conjunto longitudinal $\mathcal{L}_{\mathcal{D}} = \{D_1, D_2\}$ do Exemplo 13 e sua agregação $agreg(\mathcal{L}_{\mathcal{D}}) = D_1 \bowtie D_2$, ilustrada na Tabela 5.1.2c. Recorde que, de acordo com as premissas sobre ataques longitudinais, cada indivíduo de interesse possui no máximo um registro em cada base em $\mathcal{L}_{\mathcal{D}}$ e, logo, no máximo um registro também na agregação $agreg(\mathcal{L}_{\mathcal{D}})$.

Assuma que o adversário está interessado em reidentificar na base focal D_1 os registros de dois indivíduos pré-determinados como alvo: André e Bia. (Note que, para efeito de comparação, estamos usando aqui a mesma Bia do Exemplo 3.) Adicionalmente, considere que o adversário obteve como informação auxiliar os valores dos seguintes quaseidentificadores para cada um desses indivíduos:

- André é do sexo masculino, tem 25 anos na base D_1 e 26 anos na base D_2 , ou seja, os quaseidentificadores de André são $\mathcal{Q}'_{ID} = \{idade, sexo\}$; e
- Bia é do sexo feminino e sua profissão pertence ao grupo 1 tanto em D_1 quanto em D_2 , ou seja, os quaseidentificadores de Bia são $\mathcal{Q}''_{ID} = \{sexo, profissão\}$.

Vamos, então, computar a degradação determinística e probabilística de privacidade para ambos os indivíduos.

- **Degradação determinística de privacidade**

Note que, como a base focal D_1 possui mais que um registro, nem André nem Bia podem ser reidentificados com absoluta certeza nessa base sem uso de informação auxiliar de quaseidentificadores, e o adversário não obtém sucesso determinístico a priori para nenhum dos dois alvos.

Entretanto, na realização de um ataque com o objetivo de reidentificar Bia na base focal, o adversário tem como informação auxiliar os valores $x_{Bia}^*[\{(sexo, 1), (profissão, 1), (profissão, 2)\}] = \langle F, 1, 1 \rangle$ de seus quaseidentificadores. Note que existe exatamente um registro na base com os mesmos valores de quaseidentificadores: o registro com id 2. Dessa forma (diferentemente do que ocorreu com Bia no Exemplo 3), aqui o ataque de reidentificação determinística sobre o alvo é exitoso (descobre-se que ela é o indivíduo com id 2), e há sucesso determinístico a posteriori. Portanto, ocorre degradação determinística de privacidade no caso de Bia, uma vez que a realização do ataque usando sexo e grupo profissional como informação auxiliar permite ao adversário passar a ser capaz de reidentificá-la com absoluta certeza na base focal.

Por outro lado, ao realizar um ataque com o objetivo de reidentificar André, o adversário tem como informação auxiliar os valores $x_{André}^*[\{(idade, 1), (sexo, 1), (idade, 2)\}] = \langle 25, M, 26 \rangle$ de seus quaseidentificadores. Note que existem dois registros na base com os mesmos valores de quaseidentificadores: os registros de id 's 4 e 5. Logo, a tentativa de reidentificação determinística a posteriori de André não é exitosa, e o adversário não obtém sucesso determinístico a posteriori neste caso. Não há também degradação determinística de privacidade em relação a André, uma vez que o ataque usando sexo e grupo profissional como informação auxiliar no conjunto longitudinal não passa a permitir ao adversário reidentificá-lo com absoluta certeza na base focal.

- **Degradação probabilística de privacidade**

Note que o ataque determinístico, apesar de exitoso contra Bia, não permitiu a reidentificação com absoluta certeza de André. Entretanto, ainda é possível para o adversário ter algum sucesso probabilístico no caso de André.

Em primeiro lugar, note que, sem informação auxiliar, o melhor que o adversário pode fazer para reidentificar André é “adivinhar no escuro” qual registro, dentre todos os presentes na base focal D_1 , corresponde ao alvo. Como há 10 registros na base, a chance de o adversário “adivinhar no escuro” qual registro corresponde a André é de 10%. Portanto, seu sucesso probabilístico a priori em relação a André é de 10%.

Entretanto, ao realizar o ataque, o adversário usa como informação auxiliar os valores $x_{André}^*[\{(idade, 1), (sexo, 1), (idade, 2)\}] = \langle 25, M, 26, \rangle$ dos quaseidentificadores de André e pode usar esses dados para reduzir a quantidade de registros em $agreg(\mathcal{L}_D)$ passíveis de serem atribuídos ao alvo a apenas dois: os registros com id 's

4 e 5. Dessa forma, o sucesso probabilístico a posteriori do adversário em relação a André passa a ser de 50%.

A correspondente degradação probabilística de privacidade de André é, então, dada por $50\%/10\% = 5$, o que reflete que o ataque usando idade e sexo como informação auxiliar aumenta a probabilidade de o adversário reidentificar André por um fator de 5 vezes.

◁

5.3 Ataque de reidentificação coletiva longitudinal (RCL)

Em um *ataque de reidentificação coletiva longitudinal (RCL)*, o adversário tem acesso completo a um conjunto longitudinal de bases de dados e conhece os valores de um conjunto de quaseidentificadores para todos os indivíduos cujos registros estão nessas bases. O adversário tem como objetivo reidentificar o maior número possível de indivíduos na base focal, independentemente de quem sejam esses indivíduos. A especificação deste tipo de ataque é análoga à de um ataque *RCU* (introduzido na Seção 3.3), com a única diferença de que, de acordo com as premissas **PL6**, **PL6a**, e **PL6b** sobre ataques longitudinais, o sucesso a priori do adversário é tomado em relação à base focal, enquanto seu sucesso a posteriori é tomado em relação à agregação da informação presente em todas as bases do conjunto longitudinal.

A degradação de privacidade do ataque é medida como uma comparação entre o sucesso a priori do adversário (i.e., conhecendo apenas a base focal, mas não as bases auxiliares nem os valores dos quaseidentificadores) e seu sucesso a posteriori (i.e., após descobrir os valores dos quaseidentificadores e cruzá-los com todo o conjunto longitudinal). Mais precisamente, temos as seguintes condições para um ataque RCL:

- **Quantificação da degradação determinística de privacidade** A medição do sucesso determinístico de um ataque coletivo RCL leva em conta que o adversário tem como alvo todos os indivíduos da base focal, portanto, define-se tal sucesso como a fração dos indivíduos nessa base que pode ser reidentificada com absoluta certeza. A degradação determinística de privacidade do ataque é definida, então, como a diferença pela qual sua execução aumenta o sucesso determinístico do adversário.
- **Quantificação da degradação probabilística de privacidade:** Na medição do sucesso probabilístico de um ataque coletivo RCL, não se exige que o adversário realize a reidentificação de todos os indivíduos na base focal com absoluta certeza; em vez disso quantifica-se a probabilidade de um indivíduo da base focal aleatoriamente escolhido como alvo ser reidentificado com sucesso. Quanto maior essa probabilidade, mais exitoso é o adversário, e maior é o risco esperado de cada indivíduo presente na base focal ser reidentificado. A degradação probabilística

de privacidade do ataque é definida, então, como a razão pela qual sua execução aumenta o sucesso probabilístico do adversário.

A Definição 29 no Anexo A.2 formaliza matematicamente o ataque RCL. A seguir ilustramos como o ataque é executado em nosso exemplo condutor.

Exemplo 15 (Execução de ataque de reidentificação coletiva longitudinal (RCL)). Considere novamente o conjunto longitudinal $\mathcal{L}_{\mathcal{D}} = \{D_1, D_2\}$ do Exemplo 13 e sua agregação $agreg(\mathcal{L}_{\mathcal{D}}) = D_1 \bowtie D_2$, ilustrada na Tabela 5.1.2c.

Considere que o adversário tem como informação auxiliar os valores do quaseidentificador $\mathcal{Q}'_{ID} = \{sexo, profissão\}$ para todos os indivíduos no conjunto. Vamos computar tanto a degradação determinística de privacidade quanto a probabilística para este adversário.

- **Degradação determinística de privacidade**

Como a base focal D_1 possui mais do que um registro, nenhum indivíduo na base pode ser reidentificado com certeza sem informação auxiliar. Logo o sucesso determinístico a priori do adversário é de 0%, pois esta é a fração de indivíduos reidentificáveis com absoluta certeza na base.

Ao realizar o ataque, entretanto, o adversário pode utilizar como informação auxiliar tanto o sexo quanto a profissão dos indivíduos em todas as bases do conjunto longitudinal $\mathcal{L}_{\mathcal{D}}$. Note que em $agreg(\mathcal{L}_{\mathcal{D}})$ seis registros possuem combinação única para os atributos *sexo* e *profissão* (os registros de *id*'s 1, 2, 6, 8, 9, e 10), significando que seis registros podem ser reidentificados com absoluta certeza. Como o tamanho da base focal é $|D_1| = 10$ o sucesso determinístico a posteriori do adversário é dado por $6/10 = 60\%$, significando que usando apenas sexo e profissão como informação auxiliar o adversário pode reidentificar 60% dos registros na base focal.

A correspondente degradação determinística de privacidade é, portanto, de $60\% - 0 = 60\%$, significando que o uso de sexo e profissão como informação auxiliar produz um aumento absoluto de 60% na quantidade de registros que passam a ser reidentificáveis com absoluta certeza na base focal.⁴

- **Degradação probabilística de privacidade**

Note que sem informação auxiliar, o melhor que o adversário pode fazer para reidentificar um indivíduo aleatoriamente selecionado é “adivinhar no escuro” qual registro, dentre todos os presentes na base focal D_1 , corresponde ao indivíduo em

⁴Para efeito de comparação, suponha que o adversário realizasse um ataque em uma única base de dados, tendo acesso somente à base D_1 . Nesse caso, como há apenas um registro com combinação única de *sexo* e *profissão* na base D_1 (o registro de *id* 8, com *sexo* igual a F e *profissão* igual a 1), este seria o único registro passível de ser reidentificado com absoluta certeza, e o sucesso determinístico a posteriori do adversário seria de somente $1/10 = 10\%$. Note que este valor é bem menor que o sucesso a posteriori de 60% permitido pelo ataque longitudinal, afetando significativamente a correspondente degradação determinística de privacidade.

questão. Como na base há 10 registros, o sucesso probabilístico a priori do adversário é de 10%.

Entretanto, ao realizar o ataque o adversário pode utilizar os valores de sexo e profissão de todos os indivíduos como informação auxiliar. Note que, neste caso, o adversário pode particionar a base agregada $\text{agreg}(\mathcal{L}_{\mathcal{D}})$ em 8 blocos, cada um contendo todos os registros que compartilham o mesmo valor para os quaseidentificadores *sexo* e *profissão*: um bloco contendo os 2 registros com valores $\langle F, 3, 3 \rangle$, um bloco contendo os 2 registros com valores $\langle M, 2, 2 \rangle$, e seis blocos com um registro cada, correspondendo a todos os demais registros que têm valores únicos para a combinação de quaseidentificadores. Note que em cada bloco com 2 registros o adversário tem 50% de probabilidade de reidentificar um indivíduo corretamente, enquanto que em cada bloco com apenas 1 registro o adversário tem 100% de probabilidade de reidentificar o indivíduo corretamente. Ponderando pelo fato que um indivíduo aleatoriamente selecionado na base focal tem 40% de chance de pertencer a um bloco de tamanho 2 (pois 4 dos 10 registros caem em blocos de tamanho 2) e 60% de chance de pertencer a um bloco de tamanho 1 (6 registros em 10 caem em blocos de tamanho 1), o sucesso probabilístico a posteriori do adversário é dado por $40\% \cdot 50\% + 60\% \cdot 100\% = 80\%$, o que significa que, ao usar sexo e profissão como informação auxiliar no conjunto longitudinal, espera-se que um indivíduo aleatoriamente selecionado como alvo na base focal possa ser reidentificado com probabilidade de 80%.

Portanto, a correspondente degradação probabilística de privacidade é dada por $80\%/10\% = 8$, o que reflete que o sucesso probabilístico do adversário, ao utilizar sexo e profissão como informação auxiliar, aumenta por um fator de 8.⁵

◁

5.4 Ataque de inferência de atributo individual longitudinal (AIL)

Em um *ataque de inferência de atributo individual longitudinal (AIL)*, o adversário tem acesso a uma coleção longitudinal de bases de dados e conhece os valores de um conjunto de quaseidentificadores de um indivíduo específico na base focal pré-determinado como alvo. O adversário tem como objetivo inferir os valores de um atributo considerado como sensível para o indivíduo-alvo na base focal, independentemente de se esse indivíduo tenha sido reidentificado com sucesso ou não. A especificação deste tipo de ataque é

⁵Para efeito de comparação, suponha que o adversário realizasse um ataque em uma única base de dados, tendo acesso somente à base D_1 . Nesse caso, ele poderia separar os registros em apenas 5 blocos de acordo com *sexo* e *profissão* em D_1 , e seu sucesso determinístico a posteriori seria de somente $5/10 = 50\%$. Note que este valor é bem menor que o sucesso a posteriori de 80% permitido pelo ataque longitudinal, afetando significativamente a correspondente degradação probabilística de privacidade.

análoga à de um ataque *AIU* (introduzido na Seção 3.4), com a única diferença de que, de acordo com as premissas **PL6**, **PL6a** e **PL6b** sobre ataques longitudinais, o sucesso a priori do adversário é tomado em relação à base focal, enquanto seu sucesso a posteriori é tomado em relação à agregação da informação presente em todas as bases do conjunto longitudinal.

A degradação de privacidade do ataque é medida como uma comparação entre o sucesso a priori do adversário (i.e., conhecendo apenas a base focal, mas não as bases auxiliares nem os valores dos quaseidentificadores) e seu sucesso a posteriori (i.e., após descobrir os valores dos quaseidentificadores e cruzá-los com todo o conjunto longitudinal). Mais precisamente, temos as seguintes condições para um ataque AIL:

- **Quantificação da degradação determinística de privacidade:** A degradação determinística de privacidade em um ataque AIL ocorre se, e somente se, o adversário não for capaz de inferir com absoluta certeza o valor do atributo sensível do indivíduo-alvo antes de efetuar o ataque, mas for capaz de fazê-lo após efetuar o ataque.
- **Quantificação da degradação probabilística de privacidade:** Na medição do sucesso probabilístico de um ataque individual AIL, não se exige que o adversário infira o valor do atributo sensível do indivíduo na base focal pré-determinado como alvo com absoluta certeza; em vez disso quantifica-se a probabilidade de que o adversário corretamente infira tal valor. Quanto maior essa probabilidade, mais exitoso é o adversário. A degradação probabilística de privacidade do ataque é definida, então, como a razão pela qual sua execução aumenta o sucesso probabilístico do adversário.

A Definição 30 no Anexo A.2 formaliza matematicamente o ataque AIL. A seguir ilustramos como o ataque é executado em nosso exemplo condutor.

Exemplo 16 (Execução de ataque de inferência de atributo individual longitudinal (AIL)). Considere novamente o conjunto longitudinal $\mathcal{L}_D = \{D_1, D_2\}$ do Exemplo 13 e sua agregação $agreg(\mathcal{L}_D) = D_1 \bowtie D_2$, ilustrada na Tabela 5.1.2c.

Assuma que o adversário está interessado em inferir os valores do atributo sensível *condição* na base focal D_1 para os registros de dois indivíduos pré-determinados como alvo: Eva e Fábio. Adicionalmente, considere que o adversário obteve como informação auxiliar os valores dos seguintes quaseidentificadores para cada um desses indivíduos:

- Eva é do sexo feminino e sua profissão pertence ao grupo 3 tanto em D_1 quanto em D_2 , ou seja, os quaseidentificadores de Eva são $\mathcal{Q}'_{ID} = \{sexo, profissão\}$; e
- Fábio é do sexo masculino, tinha 25 anos em D_1 , e 26 anos em D_2 , ou seja, os quaseidentificadores de Fábio são $\mathcal{Q}''_{ID} = \{idade, sexo\}$.

Vamos, então, computar a degradação determinística e probabilística de privacidade para ambos os indivíduos.

- **Degradação determinística de privacidade**

De imediato, note que o atributo *condição* apresenta mais de um valor possível dentre os registros da base de dados D_1 : 5 registros apresentam valor **asma**, e 5 registros apresentam valor **coração**. Portanto, na ausência de informação auxiliar o adversário não pode determinar com absoluta certeza o valor do atributo sensível nem para Eva, nem para Fábio. Assim, não ocorre sucesso determinístico a priori do adversário em relação a nenhum desses dois alvos.

Entretanto, na realização de um ataque com o objetivo de inferir o valor do atributo sensível de Eva na base focal D_1 , o adversário tem como informação auxiliar os valores $x_{Eva}^*[\{(sexo, 1), (profissão, 1), (profissão, 2)\}] = \langle F, 3, 3 \rangle$ de seus quase-identificadores. Note que, apesar de haver 2 registros em $agreg(\mathcal{L}_D)$ com os mesmos valores de sexo e profissão que Eva (os registros de *id*'s 3 e 7), mesmo assim a inferência do atributo sensível de Eva pode ser feita com absoluta certeza, uma vez que ambos os registros apresentam o mesmo valor para o campo *condição* na base D_1 : **asma**. Portanto, ocorre sucesso determinístico a posteriori do adversário em inferir a condição de Eva na base focal. Também ocorre degradação determinística de privacidade em relação a Eva, uma vez que o uso de sexo e profissão como informação auxiliar torna o adversário capaz de inferir o atributo sensível de Eva na base focal (mesmo sem Eva ter sido reidentificada com absoluta certeza).

Por outro lado, ao realizar um ataque com o objetivo de inferir o valor do atributo sensível de Fábio na base focal D_1 , o adversário tem como informação auxiliar os valores $x_{Fábio}^*[\{(idade, 1), (sexo, 1), (idade, 2)\}] = \langle 25, M, 26 \rangle$ de seus quase-identificadores. Neste caso, a tentativa de inferência de atributo determinística de Fábio falha, uma vez que existem dois registros em $agreg(\mathcal{L}_D)$ com os mesmos valores de idade e gênero que Fábio (os registros de *id*'s 4 e 5), e cada um deles possui um valor diferente para o atributo sensível *condição* em D_1 (o registro de *id* 4 apresenta o valor **asma**, enquanto o registro de *id* 5 apresenta o valor **coração**). Portanto, não há sucesso determinístico a posteriori em relação a Fábio, nem degradação determinística de privacidade, uma vez que a informação auxiliar sobre o sexo e idade de Fábio não torna possível a inferência de sua condição de saúde na base focal.

- **Degradação probabilística de privacidade**

Note que o ataque determinístico, apesar de exitoso contra Eva, não permitiu a inferência do atributo sensível de Fábio com absoluta certeza. Entretanto, ainda é possível para o adversário ter algum sucesso probabilístico no caso de Fábio.

De imediato, note que na base focal D_1 o atributo *condição* apresenta o valor **asma** em 50% dos registros e o valor **coração** também em 50% dos registros. Dessa forma, sem nenhuma informação auxiliar, o adversário pode “adivinhar no escuro” qual o valor sensível de um indivíduo-alvo (tanto **asma** quanto **coração**) e mesmo assim ter 50% de probabilidade de sucesso na inferência. Logo o sucesso probabilístico a priori do adversário tanto para Eva quanto para Fábio é de 50%.

Entretanto, ao realizar o ataque, o adversário usa como informação auxiliar os valores $x_{Fábio}^*[\{(idade, 1), (sexo, 1), (idade, 2)\}] = \langle 25, \text{M}, 26 \rangle$ dos quaseidentificadores de Fábio, e assim reduz a quantidade de registros em $agreg(\mathcal{L}_{\mathcal{D}})$ passíveis de serem atribuídos a Fábio a apenas 2 (os registros de *id*'s 4 e 5). Como cada um dos dois registros tem um dos dois valores possíveis para o atributo sensível em D_1 , ao “adivinhar no escuro” esse valor o adversário ainda teria uma probabilidade de $1/2 = 50\%$ de acertar o valor correto do atributo *condição*. Dessa forma, o sucesso probabilístico a posteriori do adversário em relação a Fábio é de 50%.

A correspondente degradação probabilística de privacidade de Fábio é, então, de $50\%/50\% = 1$, significando que neste caso o uso de sexo e idade como informação auxiliar não altera a probabilidade de inferência da condição de Fábio pelo adversário. Note que este é um exemplo interessante de que em alguns casos, mesmo que raros, a informação auxiliar do adversário, mesmo em um ataque longitudinal, não causa degradação de privacidade.

◁

5.5 Ataque de inferência de atributo coletiva longitudinal (ACL)

Em um *ataque de inferência de atributo coletiva longitudinal (ACL)*, o adversário tem acesso completo a um conjunto longitudinal de bases de dados e conhece os valores de um conjunto de quaseidentificadores para todos os indivíduos cujos registros estão nessas bases. O adversário tem como objetivo inferir o valor de um atributo considerado como sensível para o maior número possível de indivíduos presentes na base focal, independentemente de se esses indivíduos tenham sido reidentificados com sucesso ou não. A especificação deste tipo ataque é análoga à de um ataque *ACU* (introduzido na Seção 3.5), com a única diferença de que, de acordo com as premissas **PL6**, **PL6a** e **PL6b** sobre ataques longitudinais, o sucesso a priori do adversário é tomado em relação à base focal, enquanto seu sucesso a posteriori é tomado em relação à agregação da informação presente em todas as bases do conjunto longitudinal.

A degradação de privacidade do ataque é medida como uma comparação entre o sucesso a priori do adversário (i.e., conhecendo apenas a base focal, mas não as bases auxiliares nem os valores dos quaseidentificadores) e seu sucesso a posteriori (i.e., após descobrir os valores dos quaseidentificadores e cruzá-los com todo o conjunto longitudinal). Mais precisamente, temos as seguintes condições para um ataque ACL:

- **Quantificação da degradação determinística de privacidade:** Na medição do sucesso determinístico de um ataque coletivo ACL, leva-se em conta que o adversário tem como alvo todos os indivíduos na base focal; portanto, define-se tal sucesso como a fração dos indivíduos nessa base cujo valor do atributo sensível

pode ser inferido com absoluta certeza. A degradação determinística de privacidade do ataque é definida, então, como a diferença pela qual sua execução aumenta o sucesso determinístico do adversário.

- **Quantificação da degradação probabilística de privacidade:** Na medição do sucesso probabilístico de um ataque coletivo ACL, não se exige que o adversário infira valor do atributo sensível de todos os indivíduos na base focal com absoluta certeza; em vez disso quantifica-se a probabilidade de um indivíduo da base focal aleatoriamente escolhido como alvo ter o valor de seu atributo sensível inferido com sucesso. Quanto maior essa probabilidade, mais exitoso é o adversário, e maior é o risco esperado de cada indivíduo presente na base ter seu atributo sensível inferido. A degradação probabilística de privacidade do ataque é definida, então, como a razão pela qual sua execução aumenta o sucesso probabilístico do adversário.

A Definição 31 no Anexo A.2 formaliza matematicamente o ataque ACL. A seguir ilustramos como o ataque é executado em nosso exemplo condutor.

Exemplo 17 (Execução de ataque de inferência de atributo coletiva longitudinal (ACL)). Considere novamente o conjunto longitudinal $\mathcal{L}_{\mathcal{D}} = \{D_1, D_2\}$ do Exemplo 13 e sua agregação $\text{agreg}(\mathcal{L}_{\mathcal{D}}) = D_1 \bowtie D_2$, ilustrada na Tabela 5.1.2c.

Considere que o adversário está interessado em inferir o valor do atributo sensível *condição* na base focal D_1 para o maior número possível de indivíduos, e tem como informação auxiliar os valores dos quaseidentificadores $\mathcal{Q}'_{ID} = \{\text{sexo}, \text{profissão}\}$ para todos os indivíduos no conjunto. Vamos computar tanto a degradação determinística de privacidade quanto a probabilística para este adversário.

- **Degradação determinística de privacidade**

Como a base focal D_1 possui mais do que um valor para o atributo sensível *condição* (5 registros possuem o valor **asma** e 5 registros possuem o valor **coração**), nenhum indivíduo na base pode ter o valor de seu atributo sensível inferido com absoluta certeza sem informação auxiliar. Portanto, o sucesso determinístico a priori é de 0%, pois esta é a fração de indivíduos na base cujo valor do atributo sensível pode ser inferido com absoluta certeza.

Entretanto, ao realizar o ataque, o adversário pode utilizar como informação auxiliar tanto o *sexo* quanto a *profissão* dos indivíduos em todas as bases do conjunto longitudinal $\mathcal{L}_{\mathcal{D}}$. Note que na agregação $\text{agreg}(\mathcal{L}_{\mathcal{D}})$, 6 registros possuem combinação única para os atributos *sexo* e *profissão* (os registros de *id*'s 1, 2, 6, 8, 9, e 10) e, portanto, o adversário pode imediatamente inferir o valor do atributo sensível destes registros. Além disso, apesar de os registros de *id*'s 3 e 7 compartilharem os mesmos valores para os quaseidentificadores (ambos têm *sexo* como F e *profissão* como 3), eles compartilham o mesmo valor para o atributo sensível (*condição* como **asma**), e também para estes registros o adversário pode inferir com absoluta certeza o valor do atributo sensível. Dessa forma, o adversário é capaz inferir com absoluta

certeza o valor do atributo sensível em um total de 8 registros. Como o tamanho da base focal é $|D_1| = 10$, o sucesso determinístico a posteriori do adversário é dado por $8/10 = 80\%$. Dessa forma, tem-se que usando apenas *sexo* e *profissão* como informação auxiliar, o adversário pode inferir o valor para o atributo sensível para 80% dos registros na base focal.

A correspondente degradação determinística de privacidade é, portanto, de $80\% - 0\% = 80\%$, uma vez que o uso de *sexo* e *profissão* como informação auxiliar produz um aumento absoluto de 80% na quantidade de registros que passam a ter o atributo sensível *condição* inferível com absoluta certeza na base focal.⁶

• Degradação probabilística de privacidade

De imediato, note que na base focal D_1 o atributo *condição* apresenta o valor **asma** em 50% dos casos e o valor **coração** também em 50% dos casos. Dessa forma, sem nenhuma informação auxiliar, o adversário pode “adivinhar no escuro” qual o valor sensível de qualquer indivíduo (tanto **asma** quanto **coração**) e mesmo assim ter 50% de probabilidade de inferi-lo com sucesso. Assim, o sucesso probabilístico a priori do adversário de inferir corretamente o atributo sensível na base focal de um indivíduo aleatoriamente selecionado como alvo é de 50%.

Entretanto, ao realizar o ataque o adversário pode utilizar os valores de *sexo* e *profissão* de todos os indivíduos como informação auxiliar. Note que, neste caso, o adversário pode particionar a base agregada $\text{agreg}(\mathcal{L}_{\mathcal{D}})$ em 8 blocos, cada um contendo todos os registros que compartilham o mesmo valor para os quaseidentificadores *sexo* e *profissão*: um bloco contendo os 2 registros com valores $\langle F, 3, 3 \rangle$, um bloco contendo os 2 registros com valores $\langle M, 2, 2 \rangle$, e 6 blocos com um registro cada, correspondendo a todos os demais registros que têm valores únicos para a combinação de quaseidentificadores. Note que no bloco contendo os 2 registros com valores $\langle M, 2, 2 \rangle$ o adversário tem 50% de probabilidade de inferir o valor para o atributo sensível de um dos registros corretamente, enquanto que no bloco contendo os 2 registros com valores $\langle F, 3, 3 \rangle$ e em cada bloco com apenas 1 registro, o adversário tem 100% de probabilidade de inferir o valor para o atributo sensível corretamente. Assim, o sucesso probabilístico a posteriori do adversário é dado por $2/10 \cdot 50\% + 2/10 \cdot 100\% + 6 \cdot 1/10 \cdot 100\% = 90\%$, significando que, ao usar *sexo* e *profissão* como informação auxiliar no conjunto longitudinal, espera-se que um indivíduo aleatoriamente selecionado como alvo na base focal possa ter o valor para o atributo sensível inferido corretamente com probabilidade de 90%.

Portanto, a correspondente degradação probabilística de privacidade é de $90\%/50\% =$

⁶Para efeito de comparação, suponha que o adversário realizasse um ataque em uma única base de dados, tendo acesso somente à base D_1 . Nesse caso, haveria 3 blocos tais que todos os registros compartilhassem do mesmo valor para o atributo sensível *condição* (o bloco formado pelos registros de *id* 3, 6, e 7, o bloco formado pelo registro de *id* 8, e o bloco formado pelos registros de *id* 9 e 10), e o sucesso determinístico a posteriori do adversário seria de $6/10 = 60\%$. Note que este valor é bem menor que o sucesso a posteriori de 80% permitido pelo ataque longitudinal, afetando significativamente a correspondente degradação determinística de privacidade.

1.8, o que reflete que o sucesso probabilístico do adversário, ao utilizar *sexo* e *profissão* como informação auxiliar, aumenta em 80%. ⁷

◁

⁷Para efeito de comparação, suponha que o adversário realizasse um ataque em uma única base de dados, tendo acesso somente à base D_1 . Nesse caso, ele poderia separar os registros em apenas 5 blocos de acordo com *sexo* e *profissão* em D_1 , e seu sucesso determinístico a posteriori do adversário seria de apenas $5/10 = 50\%$. Note que este valor é bem menor que o sucesso a posteriori de 90% permitido pelo ataque longitudinal, afetando significativamente a correspondente degradação probabilística de privacidade.

6 Avaliação experimental de ataques longitudinais nos Censos Educacionais

Nesta seção apresentamos uma extensiva análise quantitativa experimental sobre riscos à privacidade decorrentes dos ataques longitudinais introduzidos na Seção 5.

6.1 Configuração dos experimentos longitudinais

As configurações dos experimentos longitudinais são análogas àquelas adotadas para os experimentos em uma única base apresentadas na Seção 4.1. Mais precisamente, tratamos as bases para remover registros múltiplos pertencentes a um mesmo titular. Além disso, selecionamos como candidatos a quaseidentificadores atributos sobre os quais o adversário presumivelmente pode obter informação auxiliar e que estão sujeitos a variações ano a ano, sendo, portanto, capturadas por publicações longitudinais dos Censos Educacionais do Inep (e.g., a IES ou curso de um indivíduo no Censo da Educação Superior, ou a escola, etapa de ensino, ou cidade de residência de um indivíduo no Censo da Educação Básica).

Tais atributos foram selecionados de acordo com os seguintes critérios:

- Como candidatos a quaseidentificadores de alunos, selecionamos atributos cujos valores sejam presumivelmente conhecidos, ou possam ser facilmente descobertos, por um adversário –em geral por serem informação pública ou considerada inofensiva– e que estão sujeitos a variações ano a ano, sendo, portanto, capturadas por publicações longitudinais dos Censos Educacionais do Inep. A Tabela 6.1.1 apresenta os candidatos a quaseidentificadores usados nos experimentos desta seção.
- Como atributos sensíveis, selecionamos aqueles que presumivelmente não sejam de conhecimento público, mas cujos valores, caso revelados, possam vir a causar incômodo ou danos ao titular dos dados. A Tabela 6.1.2 apresenta atributos sensíveis usados nos experimentos desta seção.

Variável	Interpretação
CO_IES	Código da Instituição de Ensino Superior (IES).
CO_CURSO	Código do curso da IES ao qual o aluno está matriculado.

(a) Variáveis do Censo da Educação Superior de 2014 selecionadas como candidatas a quase-identificadores em ataques de reidentificação coletiva (RCL) do Experimento 19 e em ataques de inferência de atributo coletiva (ACL) do Experimento 22.

Variável	Interpretação
FK_COD_MUNICIPIO_END	Código do município de residência do aluno.
PK_COD_ENTIDADE	Código da escola.
FK_COD_ETAPA_ENSINO	Código da etapa de ensino do aluno.

(b) Variáveis do Censo da Educação Básica de 2014 selecionadas como candidatas a quase-identificadores em ataques de reidentificação coletiva (RCL) do Experimento 20 e em ataques de inferência de atributo coletiva (ACL) do Experimento 23.

Tabela 6.1.1: Atributos usados como candidatos a quase-identificadores nos experimentos de ataques longitudinais.

Variável	Valores	Interpretação
IN_ALUNO_DEF_TGD_SUPER	0 (Não) 1 (Sim) 2 (Sem informação)	Aluno com deficiência, transtorno global do desenvolvimento ou altas habilidades/superdotação.
IN_FINANC_ESTUDANTIL	-1 (Indisponível) 0 (Não) 1 (Sim)	Uso de financiamento estudantil por parte do aluno.

(a) Experimento 22: Atributos sensíveis utilizados nos ataques de inferência de atributo coletiva longitudinal (ACL) com o Censo da Educação Superior de 2014 como base focal.

Variável	Valores	Interpretação
ID_POSSUI_NEC_ESPECIAL	0 (Não) 1 (Sim)	Aluno com deficiência, transtorno global do desenvolvimento ou altas habilidades/superdotação.
ID_N_T_E_P	0 (Não) 1 (Sim)	Uso de transporte escolar público por parte do aluno.

(b) Experimento 23: Atributos sensíveis utilizados nos ataques de inferência de atributo coletiva longitudinal (ACL) com o Censo da Educação Básica de 2014 como base focal.

Tabela 6.1.2: Atributos sensíveis usados nos experimentos de ataques longitudinais.

6.2 Resultados de ataques de reidentificação individual longitudinal (RIL)

Em um ataque de reidentificação individual longitudinal (RIL, apresentado e exemplificado na Seção 5.2), o adversário tem acesso completo a uma coleção longitudinal de bases de dados –conhecendo todos os registros de todas as bases– e é capaz de obter como informação auxiliar os valores de um conjunto de quaseidentificadores de um indivíduo específico pré-determinado como alvo. O adversário tem como objetivo reidentificar o indivíduo-alvo, i.e., estabelecer qual registro na base focal corresponde a esse indivíduo. Neste tipo de ataque, o adversário pode usar as bases auxiliares do conjunto longitudinal como informação auxiliar para aumentar suas chances de sucesso.

O seguinte experimento ilustra um ataque RIL sobre os Censos Educacionais do Inep.

Experimento 18 (Ataques de reidentificação individual RIL nos Censos da Educação Superior). Neste experimento de ataque RIL selecionamos dois alvos: um membro da equipe executora deste projeto, além da mesma figura política conhecida nacionalmente já usada no Experimento 7. Em ambos os casos utilizamos como quaseidentificadores apenas quais IES's e cursos aos quais os alvos tenham estado vinculados em anos passados.

Separamos a discussão dos resultados pelo tipo de degradação de privacidade.

- **Degradação determinística de privacidade** O adversário é considerado deterministicamente exitoso em um ataque RIL se, e somente se, ele é capaz de estabelecer com absoluta certeza qual registro na base de dados focal corresponde ao indivíduo pré-determinado como alvo.

Para este ataque, o indivíduo selecionado como alvo foi a mesma figura política conhecida nacionalmente já usada no Experimento 7. A base de dados focal selecionada para o ataque foi a do Censo da Educação Superior de 2014. Composta por 10 793 936 registros, a base teve seu tamanho reduzido para 9 773 350 registros após o tratamento para a remoção de múltiplos registros referentes a um mesmo titular.

Antes de efetuar o ataque, não pudemos utilizar na tentativa de reidentificação os valores dos quaseidentificadores da figura política pré-determinada como alvo. Sendo assim, como a base focal tem mais de um registro, não foi possível determinar com absoluta certeza qual deles corresponderia ao indivíduo-alvo, e não obtivemos sucesso determinístico a priori.

Durante a execução do ataque RIL, entretanto, pudemos usar como informação auxiliar os valores quaseidentificadores do indivíduo-alvo para nos ajudar na tentativa de reidentificação. Neste caso, utilizamos como quaseidentificadores apenas o código da IES na qual o indivíduo-alvo estava matriculado em 2014 (Universidade Federal do ABC, código 4925) e em 2016 (Instituto de Direito Público de São Paulo, código 17672), informações facilmente encontradas na Internet. Utilizando essa informação auxiliar, identificamos apenas 1 registro na base de dados

longitudinal com os mesmos valores de quaseidentificadores. Portanto, obtivemos sucesso determinístico a posteriori e é possível afirmar, então, que houve degradação determinística de privacidade para esta figura política.

Este experimento demonstra que o conhecimento de apenas vínculos a diferentes Instituições de Ensino Superior do político em 2014 e em 2016 levam à sua reidentificação com absoluta certeza na base.

- **Degradação probabilística de privacidade** Na medição do sucesso probabilístico de um ataque RIL, não se exige que o adversário realize a reidentificação do indivíduo pré-determinado como alvo com absoluta certeza; em vez disso quantifica-se a probabilidade de que o adversário corretamente reidentifique o indivíduo-alvo na base. Quanto maior essa probabilidade, mais exitoso é o adversário.

Para este ataque, o indivíduo selecionado como alvo foi um membro da equipe executora do presente projeto. A base de dados focal selecionada para o ataque foi a do Censo da Educação Superior de 2014. Composta por 10 793 936 registros, a base teve seu tamanho reduzido para 9 773 350 registros após o tratamento para a remoção de múltiplos registros referentes a um mesmo titular.

Antes de efetuar o ataque RIL, não pudemos utilizar na tentativa de reidentificação os valores dos quaseidentificadores do indivíduo-alvo. Neste caso, o melhor que pudemos fazer foi “adivinhar no escuro” qual registro, dentre todos os presentes na base focal, corresponderia ao indivíduo-alvo. Dessa forma, nosso sucesso probabilístico a priori foi quantificado como o inverso da quantidade de registros na base, ou seja, $1/9\,773\,350 \approx 0.00001\%$.

Entretanto, durante a execução do ataque RIL, pudemos usar o conhecimento dos valores de quaseidentificadores do indivíduo-alvo para nos auxiliar na tentativa de reidentificação. Neste caso, utilizamos como quaseidentificadores apenas o conhecimento de que o membro da nossa equipe cursava Física em 2014 (variável NO_CURSO igual a FÍSICA), e Medicina em 2011 (variável NO_CURSO igual a MEDICINA). Ambas as informações são de conhecimento de pessoas próximas do alvo. Filtrando os registros na base de dados longitudinal por essa informação auxiliar, identificamos apenas 7 registros na base com os mesmos valores de quaseidentificadores. A partir daí, o melhor que pudemos fazer foi “adivinhar no escuro” qual registro do subconjunto de registros selecionados corresponderia ao indivíduo-alvo. Portanto, nosso sucesso probabilístico a posteriori na reidentificação do indivíduo como $1/7 = 14.29\%$.

Portanto, a degradação probabilística de privacidade para o indivíduo selecionado foi quantificada em $(1/7)/(1/9\,773\,350) \approx 1\,396\,192$.

Este experimento demonstra que, para o membro da nossa equipe selecionado, um adversário que tenha acesso apenas ao nome dos cursos em que ele estava matriculado nos anos de 2014 e de 2011, tem sua probabilidade de reidentificar o alvo na base multiplicada por um fator de quase 1.4 milhões de vezes.



Os exemplos de ataques individuais acima demonstram que tanto o membro de nossa equipe quanto a figura política selecionada como alvo correm riscos consideráveis de reidentificação (tanto determinística quanto probabilística) se o adversário tiver como informação auxiliar apenas a IES ou o curso ao qual o alvo esteve vinculado. Entretanto, esses indivíduos-alvo representam apenas dois estudantes dentre os 9 773 350 presentes na base do Censo da Educação Superior de 2014, utilizada como base focal em ambos os ataques. É natural, portanto, nos perguntarmos se esses casos são típicos –i.e., se a maioria dos indivíduos na base corre riscos similares–, ou se há algo de especial em relação aos indivíduos selecionados que os torna particularmente vulneráveis a ataques de reidentificação. Na próxima seção provemos evidência de que os casos acima são típicos nas bases dos Censos Educacionais analisadas.

6.3 Resultados de ataques de reidentificação coletiva longitudinal (RCL)

Em um ataque de reidentificação coletiva longitudinal (RCL, apresentado e exemplificado na Seção 5.3), o adversário tem acesso completo a uma coleção longitudinal de bases de dados –conhecendo todos os registros de todas as bases– e é capaz de obter como informação auxiliar os valores de um conjunto de quaseidentificadores para todos os indivíduos cujos registros estão na base. O adversário tem como objetivo reidentificar o maior número possível de indivíduos na base focal, independentemente de quem sejam. Neste tipo de ataque, o adversário pode usar as bases auxiliares do conjunto longitudinal como informação auxiliar para aumentar suas chances de sucesso.

A análise experimental deste tipo de ataque permite a generalização do risco individual avaliado na seção anterior, revelando o risco esperado para qualquer indivíduo aleatoriamente selecionado como alvo na base de dados focal. Em particular, este tipo de análise nos permite constatar que os casos estudados no Experimento 18 não são atípicos: de fato, uma grande parcela dos indivíduos presentes nas bases estudadas está sujeita a um risco considerável de reidentificação (tanto probabilística quanto determinística).

Nossa primeira análise de ataques RCL concerne aos Censos da Educação Superior de 2014 a 2017.

Experimento 19 (Ataques de reidentificação coletiva RCL nos Censos da Educação Superior de 2014 a 2017). Neste experimento usamos a base do Censo da Educação Superior de 2014 como base focal –i.e., aquela na qual os indivíduos devem ser reidentificados–, e as bases do mesmo Censo para os anos de 2015 a 2017 como bases auxiliares –i.e., aquelas que apenas servem de informação lateral para o ataque. O tratamento para remoção de registros múltiplos de um mesmo titular leva a base focal do Censo da Educação Superior de 2014 de 10 793 936 para 9 773 350 registros. Usamos como quaseidentificadores o

código da Instituição de Ensino Superior (CO_IES) e o código do curso (CO_CURSO) a que o aluno estava vinculado em cada ano. Medimos, então, a degradação de privacidade (tanto determinística quanto probabilística) para a base de dados focal, i.e. a base de 2014, e para cada uma das agregações longitudinais resultantes da adição, em ordem, das bases auxiliares, i.e. as bases de 2015, 2016, e 2017.

Os resultados obtidos estão organizados da seguinte forma:

- A Tabela 6.3.3 sumariza a evolução da degradação de privacidade via ataques RCL à medida em que se agregam novas bases de dados (2015, 2016, 2017) àquela do Censo da Educação Superior de 2014.
- A Figura 6.3.4 representa graficamente as medidas de sucesso determinístico e probabilístico do adversário correspondentes aos resultados das tabelas acima mencionadas.
- A Figura 6.3.5 apresenta histogramas referentes a cada uma das agregações longitudinais das bases de dados.

Separamos a discussão dos resultados pelo tipo de degradação de privacidade.

- **Sucesso determinístico do adversário:** Este tipo de sucesso é medido como a fração dos indivíduos da base de dados focal que podem ser reidentificados com absoluta certeza. Neste caso, portanto, o sucesso do adversário é medido como um valor entre 0% e 100%. A Tabela 6.3.3 demonstra que o sucesso determinístico a priori do adversário é de 0%, significando que sem informação auxiliar nenhum indivíduo pode ser reidentificado com absoluta certeza na base de dados focal, i.e., a base de 2014. Por outro lado, se o adversário pode usar os quaseidentificadores CO_IES e CO_CURSO apenas na base de 2014, então 0.0044% dos indivíduos podem ser reidentificados com absoluta certeza na base focal (aproximadamente 430 indivíduos).

À medida em que o conjunto longitudinal disponível para o adversário cresce, permitindo que as bases do Censo da Educação Superior dos anos seguintes sejam usadas como bases auxiliares, a fração de indivíduos na base que o adversário pode reidentificar na base focal com absoluta certeza aumenta. Mais especificamente, o sucesso a posteriori do adversário sobe para 5.11% ao usar como base auxiliar apenas a Base de 2015, para 10.33% ao usar as bases de 2015 e 2016, e para 15.25% ao usar as bases de 2014 a 2017.

- **Sucesso probabilístico do adversário:** Este tipo de sucesso é medido como a probabilidade de que um indivíduo escolhido aleatoriamente seja reidentificado com sucesso na base de dados focal. Nesse caso, a medida de sucesso também é um valor entre 0% e 100%. A Tabela 6.3.3 demonstra que o sucesso probabilístico a priori do adversário (que é inversamente proporcional ao número de registros na base focal) neste caso é da ordem de 10^{-8} , significando que sem nenhuma informação auxiliar o

Bases do conjunto longitudinal	Sucesso determinístico do adversário		Sucesso probabilístico do adversário	
	Sucesso a priori = 0.00%		Sucesso a priori = 0.00001%	
	Sucesso a posteriori	Degradação privacidade	Sucesso a posteriori	Degradação privacidade
2014	0.0044%	0.0044%	0.34%	33 197
2014 a 2015	5.11%	5.11%	6.72%	656 790
2014 a 2016	10.33%	10.33%	12.64%	1 235 822
2014 a 2017	15.25%	15.25%	17.95%	1 754 487

Tabela 6.3.3: Experimento 19: Degradação de privacidade em ataques de reidentificação coletiva longitudinal (RCL) no conjunto longitudinal dos Censos da Educação Superior de 2014 a 2017 e para os quaseidentificadores CO_IES e CO_CURSO. Recorde que a degradação determinística de privacidade é dada pela diferença entre o sucesso do a posteriori e o a priori do adversário, enquanto a degradação probabilística é dada pela razão dos mesmos dois termos.

adversário tem uma chance ínfima de reidentificar qualquer indivíduo com absoluta certeza. Por outro lado, se o adversário pode usar os quaseidentificadores CO_IES e CO_CURSO apenas na base de 2014, então a probabilidade de que um indivíduo aleatoriamente selecionado seja reidentificado cresce para 0.34% após a realização do ataque.

Ao realizar a agregação longitudinal das bases auxiliares, o sucesso probabilístico do adversário cresce para 6.72% ao usar como base auxiliar apenas a Base de 2015, para 12.64% ao usar as bases de 2015 e 2016, e para 17.95% ao usar as bases de 2014 a 2017.






Figura 6.3.4: Experimento 19: Sucesso do adversário em ataques de reidentificação coletiva longitudinal (RCL) no conjunto longitudinal dos Censos da Educação Superior de 2014 a 2017 para os quaseidentificadores CO_IES e CO_CURSO. Nestes gráficos cada barra representa um conjunto longitudinal diferente usado pelo adversário, e a altura da barra representa o sucesso do adversário (tanto determinístico quanto probabilístico) mantendo a Base de 2014 como focal. O rótulo “*a priori*” indica o sucesso a priori do adversário.




(a) Usando o conjunto longitudinal contendo apenas a base de 2014



(b) Usando o conjunto longitudinal contendo as bases de 2014 a 2015



(c) Usando o conjunto longitudinal contendo as bases de 2014 a 2016



(d) Usando o conjunto longitudinal contendo as bases de 2014 a 2017

Figura 6.3.5: Experimento 19: Histogramas da distribuição de sucesso probabilístico a posteriori em ataques de reidentificação coletiva longitudinal (RCL) no conjunto longitudinal dos Censos da Educação Superior de 2014 a 2017 para os quaseidentificadores CO_IES e CO_CURSO. Estes histogramas devem ser interpretados da mesma forma que seus equivalentes na Figura 4.3.5.

Nossa segunda análise de ataques RCL concerne aos Censos da Educação Básica de 2014 a 2017.

Experimento 20 (Ataques de reidentificação coletiva RCL nos Censos da Educação Básica de 2014 a 2017). Neste experimento usamos a base do Censo da Educação Básica de 2014 como base focal –i.e., aquela na qual os indivíduos devem ser reidentificados–, e as bases do mesmo Censo para os anos de 2015 a 2017 como bases auxiliares –i.e., aquelas que apenas servem de informação lateral para o ataque. O tratamento para remoção de registros múltiplos de um mesmo titular leva a base focal do Censo da Educação Básica de 2014 de 56 064 675 para 49 491 319 registros. Seleccionamos como quaseidentificadores o código do município (FK_COD_MUNICIPIO_END), o código da entidade (PK_COD_ENTIDADE), e o código da etapa de ensino (FK_COD_ETAPA_ENSINO) referentes aos alunos. Medimos, então, a degradação de privacidade (tanto determinística quanto probabilística) para a base de dados focal, i.e. a base de 2014, e para cada uma das agregações longitudinais resultantes da adição, em ordem, das bases auxiliares, i.e. as bases de 2015, 2016, e 2017.

Os resultados obtidos estão organizados da seguinte forma:

- A Tabela 6.3.6 sumariza a evolução da degradação de privacidade via ataques RCL à medida em que se agregam novas bases de dados (2015, 2016, 2017) àquela do Censo da Educação Superior de 2014.
- A Figura 6.3.7 representa graficamente as medidas de sucesso determinístico e probabilístico do adversário correspondentes aos resultados das tabelas acima mencionadas.
- A Figura 6.3.8 apresenta histogramas referentes a cada uma das agregações longitudinais das bases de dados.

Separamos a discussão dos resultados pelo tipo de degradação de privacidade.

- **Sucesso determinístico do adversário:** A Tabela 6.3.6 demonstra que o sucesso determinístico a priori do adversário é de 0%, significando que sem informação auxiliar nenhum indivíduo pode ser reidentificado com absoluta certeza na base de dados focal, i.e. a base de 2014. Por outro lado, o uso dos atributos FK_COD_MUNICIPIO_END, PK_COD_ENTIDADE, e FK_COD_ETAPA_ENSINO como quaseidentificadores permite ao adversário reidentificar com absoluta certeza até 1.44% dos indivíduos na base focal (aproximadamente 712 675 indivíduos).

À medida em que o conjunto longitudinal disponível para o adversário cresce, permitindo que as bases do Censo da Educação Básica dos anos seguintes sejam usadas como bases auxiliares, a fração de indivíduos na base que o adversário pode reidentificar na base focal com absoluta certeza aumenta. Mais especificamente, o sucesso a posteriori do adversário sobe para 12.88% ao usar como base auxiliar apenas a Base de 2015, para 25.26% ao usar as bases de 2015 e 2016, e para 36.31% ao usar as bases de 2014 a 2017.

Bases do conjunto longitudinal	Sucesso determinístico do adversário		Sucesso probabilístico do adversário	
	Sucesso a priori = 0.00%		Sucesso a priori = 0.000002%	
	Sucesso a posteriori	Degradação privacidade	Sucesso a posteriori	Degradação privacidade
2014	1.44%	1.44%	4.24%	2 103 225
2014 a 2015	12.88%	12.88%	20.08%	9 937 236
2014 a 2016	25.26%	25.26%	34.37%	17 008 936
2014 a 2017	36.31%	36.31%	45.60%	22 566 084

Tabela 6.3.6: Experimento 20: Degradação de privacidade em ataques de reidentificação coletiva longitudinal (RCL) no conjunto longitudinal dos Censos da Educação Básica de 2014 a 2017. Recorde que a degradação determinística de privacidade é dada pela diferença entre o sucesso do a posteriori e o a priori do adversário, enquanto a degradação probabilística é dada pela razão dos mesmos dois termos.

- **Sucesso probabilístico do adversário:** A Tabela 6.3.6 demonstra que o sucesso probabilístico a priori do adversário neste caso é da ordem de 10^{-8} , significando que sem nenhuma informação auxiliar o adversário tem uma chance ínfima de reidentificar qualquer indivíduo com absoluta certeza. Por outro lado, se o adversário pode usar os quaseidentificadores FK_COD_MUNICIPIO_END, PK_COD_ENTIDADE, e FK_COD_ETAPA_ENSINO apenas na base de 2014, então a probabilidade de que um indivíduo aleatoriamente selecionado seja reidentificado cresce para 4.24% após a realização do ataque.

Ao realizar a agregação longitudinal das bases auxiliares, o sucesso probabilístico do adversário cresce para 20.08% ao usar como base auxiliar apenas a Base de 2015, para 34.37% ao usar as bases de 2015 e 2016, e para 45.60% ao usar as bases de 2014 a 2017.







Figura 6.3.7: Experimento 20: Sucesso do adversário em ataques de reidentificação coletiva longitudinal (RCL) nos Censos da Educação Básica de 2014 a 2017 para os quase-identificadores FK_COD_MUNICIPIO_END, PK_COD_ENTIDADE, e FK_COD_ETAPA_ENSINO. Estes gráficos devem ser interpretados da mesma forma que aqueles da Figura 6.3.4.




(a) Usando a base de 2014 como base focal



(b) Usando conjunto longitudinal contendo as bases de 2014 e 2015.



(c) Usando conjunto longitudinal contendo as bases de 2014, 2015 e 2016.



(d) Usando conjunto longitudinal contendo as bases de 2014, 2015, 2016 e 2017.

Figura 6.3.8: Experimento 20: Histogramas da distribuição de sucesso probabilístico a posteriori em ataques de reidentificação coletiva longitudinal (RCL) no conjunto longitudinal dos Censos da Educação Básica de 2014 a 2017 para os quaseidentificadores FK_COD_MUNICIPIO_END, PK_COD_ENTIDADE, e FK_COD_ETAPA_ENSINO. Estes histogramas devem ser interpretados da mesma forma que seus equivalentes na Figura 4.3.5.

6.4 Resultados de ataques de inferência de atributo individual longitudinal (AIL)

Em um ataque de inferência de atributo individual longitudinal (AIL, apresentado e exemplificado na Seção 5.4), o adversário tem acesso completo a uma coleção longitudinal de bases de dados –conhecendo todos os registros de todas as bases– e é capaz de obter como informação auxiliar os valores de um conjunto de quaseidentificadores de um indivíduo específico pré-determinado como alvo. O adversário tem como objetivo inferir os valores de um atributo considerado como sensível para o indivíduo-alvo na base de dados focal, independentemente de se esse indivíduo tenha sido reidentificado com sucesso ou não. Neste tipo de ataque, o adversário pode usar as bases auxiliares do conjunto longitudinal como informação auxiliar para aumentar suas chances de sucesso.

O seguinte experimento apresenta nossa análise de ataques AIL nos Censos Educacionais do Inep.

Experimento 21 (Ataques de inferência de atributo individual AIL sobre atributo sensível nos Censos da Educação Básica). Neste experimento de ataque AIL selecionamos dois alvos: um membro da equipe executora deste projeto e um parente de outro membro da equipe. Em ambos os casos utilizamos como quaseidentificadores apenas quais cursos de ensino superior ou escolas aos quais estiveram vinculados em diferentes pontos do tempo.

Separamos a discussão dos resultados pelo tipo de degradação de privacidade.

- **Degradação determinística de privacidade** O adversário é considerado deterministicamente exitoso em um ataque AIL se, e somente se, ele é capaz de estabelecer com absoluta certeza qual o valor do atributo sensível do indivíduo pré-determinado como alvo.

Para este ataque, o indivíduo selecionado como alvo foi um parente de um membro da equipe executora deste projeto. Consideramos como atributo sensível o indicador de se o aluno é ou não portador de alguma necessidade especial (variável `IN_NECCESSIDADE_ESPECIAL`). A base de dados focal selecionada para o ataque foi a do Censo da Educação Básica de 2016. Composta por 52 356 383 registros, a base teve seu tamanho reduzido para 48 561 221 registros após o tratamento para a remoção de múltiplos registros referentes a um mesmo titular.

Antes de efetuar o ataque AIL, não pudemos utilizar os valores de quaseidentificadores do indivíduo-alvo como informação auxiliar na tentativa de inferir o valor de seu atributo sensível. Como os registros da base tinham mais de um valor possível para o atributo sensível na base focal (na verdade, todos os 2 valores possíveis para `IN_NECCESSIDADE_ESPECIAL` ocorrem em registros na base), não foi possível inferir com absoluta certeza qual valor corresponderia ao indivíduo-alvo, e não obtivemos sucesso determinístico a priori.

Entretanto, durante a execução do ataque AIL, pudemos usar o conhecimento dos valores dos quaseidentificadores do indivíduo como informação auxiliar na tentativa de inferência do valor de seu atributo sensível. Neste caso, utilizamos como quaseidentificadores apenas o conhecimento de que o indivíduo-alvo estudava no Colégio São Judas Tadeu (código 31014150) no ano de 2016 e no IEC - Unidade CENTEC (código 31014001) no ano de 2017. Ambas as informações são de conhecimento de pessoas próximas do alvo. Filtrando os registros na base de dados longitudinal por essa informação auxiliar, identificamos apenas 14 registros na base com os mesmos valores de quaseidentificadores.

Uma vez que todos esses indivíduos tinham o mesmo valor para o atributo sensível (0, significando que o aluno não apresenta necessidade especial), pudemos inferir com absoluta certeza que o indivíduo não apresenta necessidade especial. Portanto, obtivemos sucesso determinístico a posteriori, e é possível afirmar que houve degradação determinística de privacidade para este aluno específico.

Este experimento demonstra que, para o parente do membro da nossa equipe, um adversário que tenha acesso apenas ao nome das escolas em que ele estava matriculado nos anos de 2016 e de 2017, é capaz de inferir com absoluta certeza o valor de seu atributo `IN_NECCESSIDADE_ESPECIAL`, mesmo que o indivíduo-alvo não tenha sido reidentificado com absoluta certeza na base (na verdade, mesmo após a execução do ataque, o indivíduo ainda poderia ser qualquer um dentre um total de 14 registros possíveis).

- **Degradação probabilística de privacidade** Na medição do sucesso probabilístico de um ataque AIL, não se exige que o adversário infira o valor do atributo sensível do indivíduo pré-determinado como alvo com absoluta certeza; em vez disso quantifica-se a probabilidade de que o adversário corretamente infira tal valor. Quanto maior essa probabilidade, mais exitoso é o adversário.

Para este ataque, o indivíduo selecionado como alvo foi um membro da equipe executora do presente projeto, do qual se sabe o histórico de vínculos a alguns cursos de graduação, e.g., Física no ano de 2014 e Medicina no ano de 2011. Além disso, estabelecemos como atributo sensível a cidade de nascimento (variável `CO_MUNICIPIO_NASCIMENTO`). A base de dados focal selecionada para o ataque foi a do Censo da Educação Superior de 2014. Composta por 10 793 936 registros, a base teve seu tamanho reduzido para 9 773 350 registros após o tratamento para a remoção de múltiplos registros referentes a um mesmo titular.

Antes de efetuar o ataque AIL, não pudemos utilizar os valores dos quaseidentificadores do indivíduo-alvo como informação auxiliar na tentativa inferir seu atributo sensível. Neste caso, o melhor que pudemos fazer foi “adivinhar no escuro” qual seria o valor do atributo sensível do indivíduo-alvo. Como o atributo em questão tem 5 561 valores possíveis na base focal (incluindo a inexistência de um valor específico), e o mais comum dentre os valores existentes (3 550 308, para a cidade de São Paulo) ocorre em 556 398 dos 9 773 350 registros na base, é natural escolhermos

este valor como a estimativa do atributo sensível do indivíduo-alvo. Fazendo isso, nosso sucesso probabilístico a priori foi quantificado como $556\,398/9\,773\,350 = 5.69\%$.

Entretanto, durante a execução do ataque AIL, pudemos usar o conhecimento dos valores de quaseidentificadores do indivíduo-alvo para nos auxiliar na tentativa de inferência do valor de seu atributo sensível. Neste caso, utilizamos como quaseidentificadores apenas o conhecimento de que o membro da nossa equipe cursava Física em 2014 (variável `NO_CURSO` igual a `FISICA`), e Medicina em 2011 (variável `NO_CURSO` igual a `MEDICINA`). Ambas as informações são de conhecimento de pessoas próximas do alvo. Filtrando os registros na base de dados longitudinal por essa informação auxiliar, identificamos apenas 7 registros na base com os mesmos valores de quaseidentificadores.

A partir daí, o melhor que pudemos fazer foi “adivinhar no escuro” qual valor de atributo sensível, dentre aqueles presentes no subconjunto assim selecionado, corresponderia ao valor do indivíduo-alvo. Dentre os 7 registros filtrados, o valor mais comum para o atributo sensível foi o código 3304557 (correspondente à cidade do Rio de Janeiro), ocorrendo em 2 registros. Dessa forma, nosso sucesso probabilístico a posteriori na inferência do atributo sensível do indivíduo foi quantificado como $2/7 = 28.57\%$.

Portanto, a degradação probabilística de privacidade para o indivíduo selecionado foi quantificada em $0.2857/0.0569 = 5.0211$.

Este experimento demonstra que, para o membro da nossa equipe selecionado, um adversário que tenha acesso apenas ao nome dos cursos em que ele estava matriculado nos anos de 2014 e de 2011, tem sua probabilidade de inferir a cidade de nascimento do alvo multiplicada por um fator de mais de 5 vezes.

◁

De forma similar ao caso dos ataques de reidentificação individual do Experimento 18, os exemplos de ataques de inferência de atributo individual acima demonstram que os indivíduos selecionados como alvo correm riscos consideráveis de terem seus atributos sensíveis inferidos (determinística ou probabilisticamente) se o adversário tiver acesso a apenas alguns quaseidentificadores triviais como informação auxiliar. Entretanto, os indivíduos selecionados são ou apenas um entre os 9 773 350 registros únicos na base de dados do Censo da Educação Superior de 2014, ou apenas um entre os 48 561 221 registros únicos na base de dados do Censo da Educação Básica de 2016. A fim de verificar se os demais indivíduos das bases estão expostos a riscos semelhantes, na próxima seção realizamos a análise de ataques coletivos.

6.5 Resultados de ataques de inferência de atributo sensível coletiva longitudinal (ACL)

Em um ataque de inferência de atributo coletiva longitudinal (ACL, apresentado e exemplificado na Seção 5.5), o adversário tem acesso completo a uma coleção longitudinal de bases de dados –conhecendo todos os registros de todas as bases– e é capaz de obter como informação auxiliar os valores de um conjunto de quaseidentificadores para todos os indivíduos cujos registros estão na base. O adversário tem como objetivo inferir o valor de um atributo considerado sensível para o maior número possível de indivíduos na base focal, independentemente de se esses indivíduos tenham sido reidentificados com sucesso ou não. Neste tipo de ataque, o adversário pode usar as bases auxiliares do conjunto longitudinal como informação auxiliar para aumentar suas chances de sucesso.

A análise experimental deste tipo de ataque permite a generalização do risco individual avaliado na seção anterior, revelando o risco esperado para qualquer indivíduo aleatoriamente selecionado como alvo na base de dados focal. Em particular, este tipo de análise nos permite constatar que os casos estudados no Experimento 21 não são atípicos: de fato, uma grande parcela dos indivíduos presentes nas bases estudadas está sujeita a um risco considerável de inferência de atributo (tanto probabilística quanto determinística).

Nossa primeira análise de ataques ACL concerne aos Censos da Educação Superior de 2014 a 2017.

Experimento 22 (Ataques de inferência de atributo coletiva ACL sobre atributos sensíveis `IN_ALUNO_DEF_TGD_SUPER` e `IN_FINANC_ESTUDANTIL` nos Censos da Educação Superior de 2014 a 2017). Neste experimento usamos a base do Censo da Educação Superior de 2014 como base focal e as bases do mesmo Censo para os anos de 2015 a 2017 como bases auxiliares. O tratamento para remoção de registros múltiplos de um mesmo titular leva a base focal do Censo da Educação Superior de 2014 de 10 793 936 para 9 773 350 registros. Usamos como quaseidentificadores o código da Instituição de Ensino Superior (`CO_IES`) e o código do curso (`CO_CURSO`) a que o aluno estava vinculado em cada ano. Medimos, então, a degradação de privacidade (tanto determinística quanto probabilística) para ambos os atributos sensíveis, o primeiro referente à indicação de se o aluno é ou não portador de alguma necessidade especial (variável `IN_ALUNO_DEF_TGD_SUPER`), e o segundo referente ao uso ou não de financiamento estudantil por parte do aluno (variável `IN_FINANC_ESTUDANTIL`), na base de dados focal, i.e. a base de 2014, e para cada uma das agregações longitudinais resultantes da adição, em ordem, das bases auxiliares, i.e. as bases de 2015, 2016, e 2017.

Os resultados obtidos estão organizados da seguinte forma:

- A Tabela 6.5.9 sumariza a evolução da degradação de privacidade via ataques ACL à medida em que se agregam novas bases de dados (2015, 2016, 2017) àquela do Censo da Educação Superior de 2014 para os atributos sensíveis `IN_ALUNO_DEF_TGD_SUPER` e `IN_FINANC_ESTUDANTIL`.

- A Figura 6.5.10 representa graficamente as medidas de sucesso determinístico e probabilístico do adversário correspondentes aos resultados das tabelas acima mencionadas.
- As Figuras 6.5.11 e 6.5.12 apresentam histogramas referentes a cada uma das agregações longitudinais das bases de dados para, respectivamente, as variáveis sensíveis IN_ALUNO_DEF_TGD_SUPER e IN_FINANC_ESTUDANTIL.

Separamos a discussão dos resultados pelo tipo de degradação de privacidade.

- **Sucesso determinístico do adversário:** Este tipo de sucesso é medido como a fração dos indivíduos da base de dados focal cujos valores para o atributo sensível podem ser inferidos com absoluta certeza. Neste caso, portanto, o sucesso do adversário é medido como um valor entre 0% e 100%.

A Tabela 6.5.9a demonstra que, para o atributo sensível IN_ALUNO_DEF_TGD_SUPER, o sucesso determinístico a priori do adversário é de 0%, significando que sem informação auxiliar nenhum indivíduo pode ter seu atributo IN_ALUNO_DEF_TGD_SUPER inferido com absoluta certeza na base de dados focal, i.e., a base de 2014. Por outro lado, se o adversário pode usar os quaseidentificadores CO_IES e CO_CURSO apenas na base de 2014, então 19.89% dos indivíduos podem ter seu atributo IN_ALUNO_DEF_TGD_SUPER inferido com absoluta certeza na base de dados focal (aproximadamente 1 943 919 indivíduos).

À medida em que o conjunto longitudinal disponível para o adversário cresce, permitindo que as bases do Censo da Educação Superior dos anos seguintes sejam usadas como bases auxiliares, a fração de indivíduos na base para os quais o adversário pode inferir o valor do atributo IN_ALUNO_DEF_TGD_SUPER na base focal com absoluta certeza aumenta. Mais especificamente, o sucesso a posteriori do adversário sobe para 37.90% ao usar como base auxiliar apenas a Base de 2015, para 50.29% ao usar as bases de 2015 e 2016, e para 58.82% ao usar as bases de 2014 a 2017.

Por sua vez, a Tabela 6.5.9b demonstra que, quando o atributo considerado como sensível é IN_FINANC_ESTUDANTIL, o sucesso determinístico a priori do adversário também é de 0%. Entretanto, quando comparado ao caso em que o atributo sensível é IN_ALUNO_DEF_TGD_SUPER, o sucesso determinístico do adversário em inferir o valor do atributo IN_FINANC_ESTUDANTIL cresce mais lentamente com a quantidade de bases auxiliares usadas. Por exemplo, se o adversário pode usar os quaseidentificadores CO_IES e CO_CURSO apenas na base de 2014, então 24.35% dos indivíduos podem ter seu atributo IN_FINANC_ESTUDANTIL inferido com absoluta certeza na base de dados focal (aproximadamente 2 379 811 indivíduos).

À medida em que o conjunto longitudinal disponível para o adversário cresce, permitindo que as bases do Censo da Educação Superior dos anos seguintes sejam usadas como bases auxiliares, a fração de indivíduos na base para os quais o adversário pode inferir o valor do atributo IN_FINANC_ESTUDANTIL na base focal com

absoluta certeza também aumenta, mas mais lentamente do que para o caso do atributo `IN_ALUNO_DEF_TGD_SUPER`. Mais especificamente, o sucesso a posteriori do adversário sobe para 31.90% ao usar como base auxiliar apenas a Base de 2015, para 37.09% ao usar as bases de 2015 e 2016, e para 41.63% ao usar as bases de 2014 a 2017.

- **Sucesso probabilístico do adversário:** Este tipo de sucesso é medido como a probabilidade de que um indivíduo escolhido aleatoriamente tenha o valor de seu atributo sensível inferido na base de dados focal. Nesse caso, a medida de sucesso também é um valor entre 0% e 100%. A Figura 6.5.9a demonstra que, para o atributo sensível `IN_ALUNO_DEF_TGD_SUPER`, o sucesso probabilístico a priori do adversário já é de 92.09%, significando que mesmo sem informação auxiliar alguma o adversário já tem uma probabilidade esperada de 92.09% de inferir o valor deste atributo para um indivíduo aleatoriamente selecionado. Se o adversário pode usar os quaseidentificadores `CO_IES` e `CO_CURSO` apenas na base de 2014, então a probabilidade de que um indivíduo aleatoriamente selecionado tenha seu atributo sensível revelado cresce para 97.61% após a realização do ataque.

Ao realizar a agregação longitudinal das bases auxiliares, o sucesso probabilístico do adversário cresce para 97.98% ao usar como base auxiliar apenas a Base de 2015, para 98.21% ao usar as bases de 2015 e 2016, e para 98.39% ao usar as bases de 2014 a 2017.

Por sua vez, a Figura 6.5.9b demonstra que, quando o atributo considerado como sensível é `IN_FINANC_ESTUDANTIL`, o sucesso probabilístico a priori do adversário é de 52.10%, o que é muito menor que seu correspondente para variável sensível `IN_ALUNO_DEF_TGD_SUPER`. Se o adversário pode usar os quaseidentificadores `CO_IES` e `CO_CURSO` apenas na base de 2014, então a probabilidade de que um indivíduo aleatoriamente selecionado tenha seu atributo sensível revelado cresce para 83.47% após a realização do ataque.

Ao realizar a agregação longitudinal das bases auxiliares, o sucesso probabilístico do adversário cresce para 85.23% ao usar como base auxiliar apenas a Base de 2015, para 86.40% ao usar as bases de 2015 e 2016, e para 87.50% ao usar as bases de 2014 a 2017.


Bases do conjunto longitudinal	Sucesso determinístico do adversário		Sucesso probabilístico do adversário	
	Sucesso a priori = 0.00%		Sucesso a priori = 92.09%	
	Sucesso a posteriori	Degradação privacidade	Sucesso a posteriori	Degradação privacidade
2014	19.89%	19.89%	97.61%	1.0599
2014 a 2015	37.90%	37.90%	97.98%	1.0640
2014 a 2016	50.29%	50.29%	98.21%	1.0664
2014 a 2017	58.82%	58.82%	98.39%	1.0684

(a) Referente ao atributo sensível IN_ALUNO_DEF_TGD_SUPER


Bases do conjunto longitudinal	Sucesso determinístico do adversário		Sucesso probabilístico do adversário	
	Sucesso a priori = 0.00%		Sucesso a priori = 52.10%	
	Sucesso a posteriori	Degradação privacidade	Sucesso a posteriori	Degradação privacidade
2014	24.35%	24.35%	83.47%	1.6022
2014 a 2015	31.90%	31.90%	85.23%	1.6358
2014 a 2016	37.09%	37.09%	86.40%	1.6582
2014 a 2017	41.63%	41.63%	87.50%	1.6794

(b) Referente a atributo sensível IN_FINANC_ESTUDANTIL


Tabela 6.5.9: Experimento 22: Degradação de privacidade em ataques de inferência de atributo coletiva longitudinal (ACL) para o conjunto longitudinal dos Censos da Educação Superior de 2014 a 2017 e para os quaseidentificadores CO_IES e CO_CURSO. Recorde que a degradação determinística de privacidade é dada pela diferença entre o sucesso do a posteriori e o a priori do adversário, enquanto a degradação probabilística é dada pela razão dos mesmos dois termos.




(a) Sucesso determinístico para atributo sensível IN_ALUNO_DEF_TGD_SUPER.



(b) Sucesso probabilístico para atributo sensível IN_ALUNO_DEF_TGD_SUPER.




(c) Sucesso determinístico para atributo sensível IN_FINANC_ESTUDANTIL.




(d) Sucesso probabilístico para atributo sensível IN_FINANC_ESTUDANTIL.


Figura 6.5.10: Experimento 22: Sucesso do adversário em ataques de inferência de atributo coletiva longitudinal (ACL) no conjunto longitudinal dos Censos da Educação Superior de 2014 a 2017 e para os quaseidentificadores CO_IES e CO_CURSO. Nestes gráficos cada barra representa um conjunto longitudinal diferente usado pelo adversário, e a altura da barra representa o sucesso do adversário (tanto determinístico quanto probabilístico) mantendo a Base de 2014 como focal. O rótulo “a priori” indica o sucesso a priori do adversário.




(a) Usando apenas a base focal de 2014, sem bases auxiliares.



(b) Usando conjunto longitudinal contendo as bases de 2014 e 2015.




(c) Usando conjunto longitudinal contendo as bases de 2014, 2015 e 2016.




(d) Usando conjunto longitudinal contendo as bases de 2014, 2015, 2016 e 2017.


Figura 6.5.11: Experimento 22: Histogramas da distribuição de sucesso probabilístico a posteriori em ataques de inferência de atributo coletiva longitudinal (ACL) sobre atributo sensível `IN_ALUNO_DEF_TGD_SUPER` no conjunto longitudinal dos Censos da Educação Superior de 2014 a 2017. Estes histogramas devem ser interpretados da mesma forma que seus equivalentes na Figura 4.3.5.




(a) Usando apenas a base focal de 2014, sem bases auxiliares.



(b) Usando conjunto longitudinal contendo as bases de 2014 e 2015.



(c) Usando conjunto longitudinal contendo as bases de 2014, 2015 e 2016.



(d) Usando conjunto longitudinal contendo as bases de 2014, 2015, 2016 e 2017.

Figura 6.5.12: Experimento 22: Histogramas da distribuição de sucesso probabilístico a posteriori em ataques de inferência de atributo coletiva longitudinal (ACL) sobre atributo sensível `IN_FINANC_ESTUDANTIL` no conjunto longitudinal dos Censos da Educação Superior de 2014 a 2017. Estes histogramas devem ser interpretados da mesma forma que seus equivalentes na Figura 4.3.5.

Nossa segunda análise de ataques ACL concerne aos Censos da Educação Básica de 2014 a 2017.

Experimento 23 (Ataques de inferência de atributo coletiva ACL sobre atributos sensíveis `ID_POSSUI_NEC_ESPECIAL` e `ID_N_T_E_P` nos Censos da Educação Básica de 2014 a 2017). Neste experimento usamos a base do Censo da Educação Básica de 2014 como base focal e as bases do mesmo Censo para os anos de 2015 a 2017 como bases auxiliares. O tratamento para remoção de registros múltiplos de um mesmo titular leva a base focal do Censo da Educação Básica de 2014 de 56 064 675 para 49 491 319 registros. Usamos como quaseidentificadores o código do município (`FK_COD_MUNICIPIO_END`), o código da entidade (`PK_COD_ENTIDADE`), e o código da etapa de ensino (`FK_COD_ETAPA_ENSINO`) referentes aos alunos. Medimos, então, a degradação de privacidade (tanto determinística quanto probabilística) para ambos os atributos sensíveis, `ID_POSSUI_NEC_ESPECIAL` e `ID_N_T_E_P`, na base de dados focal, i.e. a base de 2014, e para cada uma das agregações longitudinais resultantes da adição, em ordem, das bases auxiliares, i.e. as bases de 2015, 2016, e 2017.

Os resultados obtidos estão organizados da seguinte forma:

- A Tabela 6.5.13 sumariza a evolução da degradação de privacidade via ataques ACL à medida em que se agregam novas bases de dados (2015, 2016, 2017) àquela do Censo da Educação Básica de 2014, considerando como atributos sensíveis as variáveis `ID_POSSUI_NEC_ESPECIAL` e `ID_N_T_E_P`.
- A Figura 6.5.14 representa graficamente as medidas de sucesso determinístico e probabilístico do adversário correspondentes aos resultados das tabelas acima mencionadas.
- As Figuras 6.5.15 e 6.5.16 apresentam histogramas referentes a cada uma das agregações longitudinais das bases de dados para, respectivamente, as variáveis sensíveis `ID_POSSUI_NEC_ESPECIAL` e `ID_N_T_E_P`.

Separamos a discussão dos resultados pelo tipo de degradação de privacidade.

- **Sucesso determinístico do adversário:** A Tabela 6.5.13a demonstra que, para o atributo sensível `ID_POSSUI_NEC_ESPECIAL`, o sucesso determinístico a priori do adversário é de 0%, significando que sem informação auxiliar nenhum indivíduo pode ter seu atributo `ID_POSSUI_NEC_ESPECIAL` inferido com absoluta certeza na base de dados focal, i.e., a base de 2014. Por outro lado, se o adversário pode usar os quaseidentificadores `FK_COD_MUNICIPIO_END`, `PK_COD_ENTIDADE`, e `FK_COD_ETAPA_ENSINO` apenas na base de 2014, então 57.17% dos indivíduos podem ter seu atributo `ID_POSSUI_NEC_ESPECIAL` inferido com absoluta certeza na base de dados focal (aproximadamente 28 294 187 indivíduos).

À medida em que o conjunto longitudinal disponível para o adversário cresce, permitindo que as bases do Censo da Educação Básica dos anos seguintes sejam usadas

como bases auxiliares, a fração de indivíduos na base para os quais o adversário pode inferir o valor do atributo `ID_POSSUI_NEC_ESPECIAL` na base focal com absoluta certeza aumenta. Mais especificamente, o sucesso a posteriori do adversário sobe para 79.21% ao usar como base auxiliar apenas a Base de 2015, para 87.59% ao usar as bases de 2015 e 2016, e para 91.28% ao usar as bases de 2014 a 2017.

Por sua vez, a Tabela 6.5.13b demonstra que, quando o atributo considerado como sensível é `ID_N_T_E_P`, o sucesso determinístico a priori do adversário também é de 0%. Entretanto, quando comparado ao caso do atributo `ID_POSSUI_NEC_ESPECIAL`, o sucesso determinístico do adversário em inferir o valor do atributo `ID_N_T_E_P` cresce mais lentamente com a quantidade de bases auxiliares usadas. Por exemplo, se o adversário pode usar os quaseidentificadores `FK_COD_MUNICIPIO_END`, `PK_COD_ENTIDADE`, e `FK_COD_ETAPA_ENSINO` apenas na base de 2014, então 58.07% dos indivíduos podem ter seu atributo `IN_FINANC_ESTUDANTIL` inferido com absoluta certeza na base de dados focal (aproximadamente 28 739 608 indivíduos).

À medida em que o conjunto longitudinal disponível para o adversário cresce, permitindo que as bases do Censo da Educação Básica dos anos seguintes sejam usadas como bases auxiliares, a fração de indivíduos na base para os quais o adversário pode inferir o valor do atributo `ID_N_T_E_P` na base focal com absoluta certeza também aumenta, mas mais lentamente do que para o caso do atributo `ID_POSSUI_NEC_ESPECIAL`. Mais especificamente, o sucesso a posteriori do adversário sobe para 68.60% ao usar como base auxiliar apenas a Base de 2015, para 75.32% ao usar as bases de 2015 e 2016, e para 79.92% ao usar as bases de 2014 a 2017.

- **Sucesso probabilístico do adversário:** A Tabela 6.5.13a demonstra que, para o atributo sensível `ID_POSSUI_NEC_ESPECIAL`, o sucesso probabilístico a priori do adversário já é de 98.21%, significando que mesmo sem informação auxiliar alguma o adversário já tem uma probabilidade esperada de 98.21% de inferir o valor deste atributo para um indivíduo aleatoriamente selecionado. Se o adversário pode usar os quaseidentificadores `FK_COD_MUNICIPIO_END`, `PK_COD_ENTIDADE`, e `FK_COD_ETAPA_ENSINO` apenas na base de 2014, então a probabilidade de que um indivíduo aleatoriamente selecionado tenha seu atributo sensível revelado cresce para 98.71% após a realização do ataque.

Ao realizar a agregação longitudinal das bases auxiliares, o sucesso probabilístico do adversário cresce para 99.03% ao usar como base auxiliar apenas a Base de 2015, para 99.30% ao usar as bases de 2015 e 2016, e para 99.49% ao usar as bases de 2014 a 2017.

Por sua vez, a Tabela 6.5.13b demonstra que, quando o atributo considerado como sensível é `ID_N_T_E_P`, o sucesso probabilístico a priori do adversário é de 82.50%, o que é inferior ao seu correspondente para variável sensível `ID_POSSUI_NEC_ESPECIAL`. Se o adversário pode usar os quaseidentificadores apenas na base de 2014, então a probabilidade de que um indivíduo aleatoriamente selecionado tenha seu atributo sensível revelado cresce para 91.64% após a realização do ataque.

Ao realizar a agregação longitudinal das bases auxiliares, o sucesso probabilístico do adversário cresce para para 93.03% ao usar como base auxiliar apenas a Base de 2015, para 94.17% ao usar as bases de 2015 e 2016, e para 95.07% ao usar as bases de 2014 a 2017.

◁


Bases do conjunto longitudinal	Sucesso determinístico do adversário		Sucesso probabilístico do adversário	
	Sucesso a priori = 0.00%		Sucesso a priori = 0.00001%	
	Sucesso a posteriori	Degradação privacidade	Sucesso a posteriori	Degradação privacidade
2014	57.17%	57.17%	98.71%	1.0051
2014 a 2015	79.21%	79.21%	99.03%	1.0083
2014 a 2016	87.59%	87.59%	99.30%	1.0111
2014 a 2017	91.28%	91.28%	99.49%	1.0130

(a) Referente ao atributo sensível ID_POSSUI_NEC_ESPECIAL

Bases do conjunto longitudinal	Sucesso determinístico do adversário		Sucesso probabilístico do adversário	
	Sucesso a priori = 0.00%		Sucesso a priori = 0.00001%	
	Sucesso a posteriori	Degradação privacidade	Sucesso a posteriori	Degradação privacidade
2014	58.07%	58.07%	91.64%	1.1109
2014 a 2015	68.60%	68.60%	93.03%	1.1277
2014 a 2016	75.32%	75.32%	94.17%	1.1414
2014 a 2017	79.92%	79.92%	95.07%	1.1524


(b) Referente ao atributo sensível ID_N_T_E_P

Tabela 6.5.13: Experimento 23: Degradação de privacidade em ataques de inferência de atributo coletiva longitudinal (ACL) no conjunto longitudinal dos Censos da Educação Básica de 2014 a 2017 e para os quaseidentificadores FK_COD_MUNICIPIO_END, PK_COD_ENTIDADE, e FK_COD_ETAPA_ENSINO. Recorde que a degradação determinística de privacidade é dada pela diferença entre o sucesso do a posteriori e o a priori do adversário, enquanto a degradação probabilística é dada pela razão dos mesmos dois termos.




Bases no Conjunto Longitudinal

(a) Sucesso determinístico para atributo sensível ID_POSSUI_NEC_ESPECIAL.




Bases no Conjunto Longitudinal

(b) Sucesso probabilístico para atributo sensível ID_POSSUI_NEC_ESPECIAL.



Bases no Conjunto Longitudinal


(c) Sucesso determinístico para atributo sensível ID_N_T_E_P.




Bases no Conjunto Longitudinal

(d) Sucesso probabilístico para atributo sensível ID_N_T_E_P.


Figura 6.5.14: Experimento 23: Sucesso do adversário em ataques de inferência de atributo coletiva longitudinal (ACL) nos Censos da Educação Básica de 2014 a 2017 para os quaseidentificadores FK_COD_MUNICIPIO_END, PK_COD_ENTIDADE, e FK_COD_ETAPA_ENSINO. Nestes gráficos cada barra representa um conjunto longitudinal diferente usado pelo adversário, e a altura da barra representa o sucesso do adversário (tanto determinístico quanto probabilístico) mantendo a Base de 2014 como focal. O rótulo “a priori” indica o sucesso a priori do adversário.




(a) Usando apenas a base focal de 2014, sem bases auxiliares.



(b) Usando conjunto longitudinal contendo as bases de 2014 e 2015.




(c) Usando conjunto longitudinal contendo as bases de 2014, 2015 e 2016.




(d) Usando conjunto longitudinal contendo as bases de 2014, 2015, 2016 e 2017.


Figura 6.5.15: Experimento 23: Histogramas da distribuição de sucesso probabilístico a posteriori em ataques de inferência de atributo coletiva longitudinal (ACL) sobre atributo sensível ID_POSSUI_NEC_ESPECIAL no conjunto longitudinal dos Censos da Educação Básica de 2014 a 2017. Estes histogramas devem ser interpretados da mesma forma que seus equivalentes na Figura 4.3.5.




(a) Usando apenas a base focal de 2014, sem bases auxiliares.



(b) Usando conjunto longitudinal contendo as bases de 2014 e 2015.



(c) Usando conjunto longitudinal contendo as bases de 2014, 2015 e 2016.



(d) Usando conjunto longitudinal contendo as bases de 2014, 2015, 2016 e 2017.

Figura 6.5.16: Experimento 23: Histogramas da distribuição de sucesso probabilístico a posteriori em ataques de inferência de atributo coletiva longitudinal (ACL) sobre atributo sensível ID_N_T_E_P no conjunto longitudinal dos Censos da Educação Básica de 2014 a 2017. Estes histogramas devem ser interpretados da mesma forma que seus equivalentes na Figura 4.3.5.

7 Considerações finais

Para fins de proteção de privacidade, a atual forma de divulgação dos microdados dos Censos Educacionais pelo Inep utiliza apenas as técnicas de desidentificação, em que se removem possíveis identificadores individuais óbvios dos registros (como nome, CPF, RG) e de pseudonimização, em que tais identificadores individuais óbvios são substituídos por um código único de identificação artificialmente criado. A análise preliminar desta forma de divulgação realizada no Produto 01 do presente TED 8750 revelou que a mesma está sujeita a vários riscos já apontados na literatura técnica na área de privacidade.

Mais especificamente, em 1998, Samarati e Sweeney observaram que, mesmo quando se removem ou se criptografam identificadores explícitos (como nomes, endereços e números de telefone) dos titulares dos microdados em uma divulgação, outros dados distintos, chamados de *quaseidentificadores*, podem se combinar de maneira inadequada e ser, assim, ser vinculados a informações publicamente disponíveis para reidentificar os indivíduos [18]. Como exemplo de quaseidentificadores poderosos, Sweeney demonstrou em 2000 que 87% da população dos EUA poderia ser unicamente identificada usando-se apenas o *zip-code* (o equivalente americano ao CEP brasileiro), o gênero e data de nascimento do indivíduo [20]. Portanto, qualquer divulgação de microdados que contivesse pelo menos estes três campos (e.g., algum censo ou base de dados médicos) permitiria a reidentificação de até 87% da população americana, levando a uma consequente exposição generalizada de atributos sensíveis individuais. Além disso, no contexto brasileiro, os pesquisadores Queiroz e Motta já haviam apontado em 2015 potenciais riscos à privacidade, oriundos do uso de quaseidentificadores como informação auxiliar, sobre os microdados dos Censos Educacionais divulgados pelo Inep relativos ao ano de 2013 [17].

No presente documento provemos uma extensa análise quantitativa experimental da degradação de privacidade causada por vários ataques executados sobre as bases dos Censos Educacionais do Inep em sua atual forma de divulgação. Nossas análises levam em conta que o adversário pode usar quaseidentificadores para auxiliar a inferência de informação sensível nas bases, e medem a correspondente degradação de privacidade como o aumento no sucesso do adversário ao inferir informação sensível causado pelo uso desses quaseidentificadores. Não temos conhecimento de qualquer outro trabalho que tenha efetuado uma análise quantitativa experimental tão profunda dos riscos à privacidade nos Censos Educacionais do Inep quanto a apresentada no presente documento.

Em particular, podemos destacar as seguintes lições aprendidas em nossas análises.

- (I) **Destaques da análise de ataques de reidentificação em uma única base de dados:** O Experimento 7 demonstrou que, na base do Censo da Educação Superior de 2014, uma figura política conhecida em nível nacional corre elevado risco de reidentificação caso seja usada como informação auxiliar apenas os quaseidentificadores referentes à sua data de nascimento e à IES à qual ela estava vinculada naquele ano (ambas as informações são facilmente encontradas na Internet). A execução do ataque multiplicou probabilidade de se reidentificar o alvo na base por um fator de cerca de 4 886 675 vezes, passando de $1/9\,773\,350 = 1.0232 \cdot 10^{-5} \%$ para 50%. Ao estender a informação auxiliar com apenas mais o curso em que a figura política em questão estava matriculada, foi possível reidentificá-la com absoluta certeza dentre os 9 773 350 registros únicos presentes na base.

Por sua vez, o Experimento 8 demonstrou que o caso da figura política mencionada acima não é atípico: de fato, a maioria dos indivíduos presentes nas bases estudadas está sujeita a um risco considerável de reidentificação (tanto probabilística quanto determinística). Ainda no caso do Censo da Educação Superior de 2018, uma combinação de 3 quaseidentificadores (dia e ano de nascimento, e código do curso) permite ao adversário reidentificar com absoluta certeza até 39% dos indivíduos na base, ou aproximadamente 4 200 000 estudantes; enquanto uma combinação de 4 quaseidentificadores (dia, mês e ano de nascimento, e código do curso) pode levar à reidentificação de até 80% dos indivíduos, ou aproximadamente 8 600 000 estudantes. Por outro lado, na mesma base a mesma combinação de 3 quaseidentificadores permite ao adversário reidentificar um indivíduo aleatoriamente selecionado como alvo com probabilidade de até 56% após a realização do ataque; enquanto que a mesma combinação de 4 quaseidentificadores eleva essa probabilidade a até 87%. O Experimento 9 demonstra que o Censo da Educação Básica de 2019 está sujeito a riscos semelhantes de reidentificação coletiva.

Destaque identificado: A atual forma de proteção de privacidade utilizada pelo Inep, consistindo em desidentificação, em que se removem possíveis identificadores individuais óbvios dos registros (como nome, CPF, RG) e de pseudonimização, em que tais identificadores individuais óbvios são substituídos por um código único de identificação artificialmente criado, mostraram-se absolutamente ineficazes para garantir aos indivíduos presentes na base uma proteção minimamente razoável contra riscos de reidentificação. Utilizando apenas quaseidentificadores facilmente descobríveis, podem-se reidentificar elevadas proporções dos indivíduos presentes em todas as bases estudadas. Como exemplo, informação auxiliar consistindo em um conjunto de apenas 4 quaseidentificadores (mês, ano e município de nascimento, além de código da entidade) já permite a reidentificação com absoluta certeza de 33% dos alunos no Censo da Educação Básica de 2019, ou aproximadamente 15 700 000 estudantes (Tabela 4.3.7), enquanto outro conjunto (dia, mês e ano de nascimento, e código do curso) possibilita a reidentificação completa de 79% dos alunos no Censo da Educação

Superior de 2018, ou aproximadamente 37 600 000 estudantes (Tabela 4.3.4). Observe que, devido à base do Ensino Básico ser significativamente maior que a do Ensino Superior, mesmo um risco relativo mais reduzido na primeira ainda afeta um número muito maior de estudantes do que na segunda.

- (II) **Destaques da análise de ataques de inferência de atributo coletiva em uma única base de dados:** Muitas vezes é possível inferir o valor de um atributo sensível de um indivíduo mesmo que este indivíduo não tenha sido unicamente re-identificado em um conjunto de microdados (por exemplo, quando todos os registros que podem ser ligados ao indivíduo compartilham o mesmo valor para o atributo).

O Experimento 10 demonstrou que, na base do Censo da Educação Básica de 2019, um parente de um autor deste documento, escolhido como alvo para efeito de ilustração, corre elevado risco de que seja inferido o atributo que indica se ele utiliza ou não transporte público, caso seja utilizada como informação auxiliar apenas seu gênero, mês, ano, e cidade de nascimento. A execução do ataque multiplicou probabilidade de se inferir o valor do atributo por um fator de 1.13 vezes, passando de 82.06% para 93.27%. Ao estender a informação auxiliar com apenas mais a cidade de residência do alvo, foi possível inferir o valor exato de seu atributo, mesmo a base contendo 47 640 822 registros únicos.

Por sua vez, o Experimento 11 demonstrou que o caso do indivíduo acima não é incomum na base do Censo da Educação Superior de 2018. A maioria dos indivíduos na base está sujeita a riscos consideráveis de que algum atributo potencialmente sensível seja inferido. Considerando como atributo sensível o indicador de se um aluno é ou não beneficiário de financiamento estudantil, a escolha de 1 quaseidentificador (código do curso) já permite ao adversário inferir com absoluta certeza o valor do atributo de 25% dos indivíduos na base, ou aproximadamente 1 600 000 estudantes; enquanto uma combinação de 4 quaseidentificadores (dia, mês e ano de nascimento, e código do curso) leva à inferência do atributo de 92% dos indivíduos, ou aproximadamente 9 900 000 estudantes. Por outro lado, na mesma base o mesmo quaseidentificador único permite ao adversário inferir o valor do atributo para um indivíduo aleatoriamente selecionado como alvo com probabilidade de 83%; enquanto que a mesma combinação de 4 quaseidentificadores eleva essa probabilidade a 97%. O Experimento 12 demonstra que o Censo da Educação Básica de 2019 está sujeito a riscos semelhantes de inferência de atributo sensível.

Destaque identificado: O uso de apenas desidentificação e pseudonimização mostrou-se ineficaz para garantir a uma grande parcela dos indivíduos presentes nas bases dos Censos Educacionais avaliadas uma proteção minimamente razoável contra inferência de atributos potencialmente sensíveis. Como exemplo, o uso de um conjunto de apenas 4 quaseidentificadores facilmente descobríveis

(dia, mês e ano de nascimento, além de código do curso) já permite inferência com absoluta certeza de se um aluno é beneficiário de financiamento estudantil para 92% daqueles presentes no Censo da Educação Superior de 2018, ou aproximadamente 9 900 000 estudantes (Tabela 4.5.11), enquanto outro conjunto também trivial (mês, ano e município de nascimento, além de código da entidade) possibilita a inferência de se um aluno possui necessidade especial em 93% dos indivíduos presentes no Censo da Educação Básica de 2019, ou aproximadamente 10 000 000 estudantes (Tabela 4.5.15).

- (III) **Destaques das análises de ataques longitudinais:** Os experimentos acima citados demonstram claramente a vulnerabilidade a que estão sujeitos os titulares de dados dos Censos quando o adversário tem acesso a apenas uma única base de dados. Entretanto, a divulgação das bases dos Censos Educacionais por parte do Inep é feita anualmente, o que gera um conjunto longitudinal de dados continuamente crescente. Devido à grande quantidade de anos em que um aluno tipicamente permanece no sistema educacional, um adversário pode cruzar a informação a respeito de um aluno ao longo dos anos e assim aumentar consideravelmente a chance de inferência de informação sensível. O cruzamento de dados é facilitado pelo fato de que o Inep usa o mesmo identificador único para alunos em diferentes bases.¹ Os Experimentos de 18 a 23 demonstram que, mesmo quando uma divulgação de microdados isoladamente não representa risco imediato à privacidade de indivíduos, o risco pode crescer de forma significativa à medida em que o número de bases disponibilizadas pelo Inep aumenta ano a ano.

Ataques longitudinais têm o potencial de serem particularmente danosos aos titulares de dados nos Censos Educacionais do Inep, mesmo com o uso de quase-identificadores ainda mais triviais do que os usados em ataques em uma única base de dados. Como exemplo, informação auxiliar consistindo em apenas 2 quase-identificadores (código do curso e IES de um aluno) possibilita a reidentificação com absoluta certeza de apenas 0.0044% dos alunos presentes no Censo da Educação Superior de 2014, ou aproximadamente 430 estudantes; entretanto

¹A existência de um identificador único que se mantenha em bases justapostas facilita ataques longitudinais. A remoção de tal identificador, ou a utilização de identificadores diferentes em bases distintas, seria uma forma eficaz de mitigação dos danos causados pelos ataques longitudinais como descritos no presente documento. Entretanto, neste caso o adversário poderia recorrer a um tipo de ataque longitudinal mais refinado, utilizando quase-identificadores para tentar associar os registros de indivíduos entre bases distintas. Tal abordagem por parte do adversário tenderia a provocar uma menor degradação de privacidade, porém em um nível ainda potencialmente significativo. No presente produto não efetuamos a análise deste tipo de ataque longitudinal mais refinado pelos seguintes motivos: (i) a atual forma de divulgação dos Censos Educacionais por parte do Inep utiliza, em sua maior parte, identificadores únicos perenes entre bases; e (ii) a metodologia e o modelo formal do ataque longitudinal baseado apenas em quase-identificadores seriam mais complexos e demandariam mais tempo do que o estipulado para o presente Produto 02 no plano de trabalho do TED 8750

ao usar como informação auxiliar os Censos de 2015, 2016 e 2017, a porcentagem de alunos reidentificáveis sobe a 15.25%, ou aproximadamente 1 400 000 estudantes (Tabela 6.3.3). Usando o mesmo conjunto de 2 quaseidentificadores, é possível inferir com absoluta certeza se um aluno é portador de deficiência para 19.89% dos indivíduos presentes no Censo da Educação Superior de 2014, ou aproximadamente 1 900 000 estudantes; porém o cruzamento de informação com os Censos de 2015, 2016 e 2017 eleva a proporção de alunos afetados para 58.82%, ou aproximadamente 5 700 000 estudantes (Tabela 6.5.9).

Por fim, acreditamos que nossas análises demonstram de forma inequívoca que a atual forma de divulgação dos Censos Educacionais por parte do Inep submete os titulares dos dados a sérios e generalizados riscos de violação de privacidade, em especial ao de reidentificação e de inferência de atributos sensíveis. Reiteramos que, conforme expressamos no Produto 01 do presente TED 8750, em nossa visão tal situação poderia constituir em uma violação da Lei Geral de Proteção de Dados Pessoais.

Referências Bibliográficas

- [1] Mário S. Alvim, Konstantinos Chatzikokolakis, Annabelle McIver, Carroll Morgan, Catuscia Palamidessi, and Geoffrey Smith. Additive and Multiplicative Notions of Leakage, and Their Capacities. In *Proc. of CSF*, pages 308–322. IEEE, 2014.
- [2] Mário S. Alvim, Konstantinos Chatzikokolakis, Annabelle McIver, Carroll Morgan, Catuscia Palamidessi, and Geoffrey Smith. *The Science of Quantitative Information Flow*. Springer, 2020.
- [3] Christelle Braun, Konstantinos Chatzikokolakis, and Catuscia Palamidessi. Quantitative Notions of Leakage for One-try Attacks. In *Proc. of MFPS*, volume 249 of *ENTCS*, pages 75–91. Elsevier, 2009.
- [4] Christian Cachin. *Entropy Measures and Unconditional Security in Cryptography*. PhD thesis, ETH, 1997.
- [5] Konstantinos Chatzikokolakis, Catuscia Palamidessi, and Prakash Panangaden. Anonymity Protocols as Noisy channels. *Inf. and Comp.*, 206(2–4):378–401, 2008.
- [6] David Clark, Sebastian Hunt, and Pasquale Malacaria. Quantitative Analysis of the Leakage of Confidential Data. In *Proc. of QAPL*, volume 59 (3) of *ENTCS*, pages 238–251. Elsevier, 2001.
- [7] David Clark, Sebastian Hunt, and Pasquale Malacaria. Quantitative Information Flow, Relations and Polymorphic Types. *J. of Logic and Computation*, 18(2):181–199, 2005.
- [8] Governo do Brasil. Lei 13.709, de 14 de agosto de 2018, Lei Geral de Proteção de Dados Pessoais (LGPD). Disponível em: http://www.planalto.gov.br/ccivil_03/_ato2015-2018/2018/Lei/L13709.htm.
- [9] Governo do Brasil. Lei de Acesso à Informação (LAI). Disponível em: http://www.planalto.gov.br/ccivil_03/_Ato2011-2014/2011/Lei/L12527.htm.
- [10] Cynthia Dwork, Frank McSherry, Kobbi Nissim, and Adam Smith. Calibrating noise to sensitivity in private data analysis. In *Theory of cryptography conference*, pages 265–284. Springer, 2006.

- [11] E. T. Jaynes. *Probability theory: The logic of science*. Cambridge University Press, Cambridge, 2003.
- [12] Boris Köpf and David A. Basin. An information-theoretic model for adaptive side-channel attacks. In *Proc. of CCS*, pages 286–296. ACM, 2007.
- [13] Gavin Lowe. Quantifying Information Flow. In *Proc. of CSFW 2002*, pages 18–31. IEEE, 2002.
- [14] Ashwin Machanavajjhala, Daniel Kifer, Johannes Gehrke, and Muthuramakrishnan Venkitasubramaniam. L-Diversity: Privacy beyond k-Anonymity. *ACM Transactions on Knowledge Discovery from Data*, 1(1):3–es, March 2007.
- [15] Fabian Prasser and Contributors. ARX - Data Anonymization Tool, 2020. Disponível em: <https://arx.deidentifier.org/>.
- [16] Fabian Prasser, Florian Kohlmayer, Ronald Lautenschlaeger, and Klaus A Kuhn. Arx-a comprehensive tool for anonymizing biomedical data. In *AMIA Annual Symposium Proceedings*, volume 2014, page 984. American Medical Informatics Association, 2014.
- [17] MJ Queiroz and GHMB Motta. Privacidade e Transparência no Setor público: Um Estudo de Caso da Publicação de Microdados do INEP. In *XV Simposio Brasileiro em Seguranca da Informacao e de Sistemas Computacionais-SBSeg*, 2015.
- [18] Pierangela Samarati and Latanya Sweeney. Protecting privacy when disclosing information: k-anonymity and its enforcement through generalization and suppression, 1998.
- [19] Geoffrey Smith. On the Foundations of Quantitative Information Flow. In *Proc. of FOSSACS*, volume 5504 of *LNCS*, pages 288–302. Springer, 2009.
- [20] Latanya Sweeney. Simple Demographics Often Identify People Uniquely, 2000. Disponível em: https://kilthub.cmu.edu/articles/Simple_Demographics_Often_Identify_People_Uniquely/6625769/1.

Anexos

A Formalização matemática dos ataques

A.1 Formalização de ataques em uma única base de dados

Nesta seção formalizamos matematicamente os ataques em uma única base de dados introduzidos na Seção 3.

Definição 24 (Ataque de reidentificação individual em uma única base de dados (RIU)). Em um *ataque de reidentificação individual em uma única base de dados (RIU)*, o adversário tem acesso completo a uma única base de dados –conhecendo todos os seus registros– e é capaz de obter como informação auxiliar os valores de um conjunto de quaseidentificadores de um indivíduo específico pré-determinado como alvo. O adversário tem como objetivo reidentificar o indivíduo-alvo, i.e., estabelecer qual registro na base de dados corresponde a esse indivíduo. A especificação deste ataque é como a seguir.

- **Conhecimento do adversário em um ataque RIU.** Em um ataque RIU, assume-se que o adversário:
 - (i) tem completo acesso a uma base de dados D (não vazia) sobre um conjunto de atributos $\mathcal{A}$;
 - (ii) possui um indivíduo específico $x^* \in D$ pré-determinado como alvo da tentativa de reidentificação;
 - (iii) dado um conjunto $\mathcal{Q}_{ID} \subseteq \mathcal{A}$ de quaseidentificadores, é capaz de obter como informação auxiliar o sub-registro $x^*[\mathcal{Q}_{ID}]$ correspondente aos valores dos quaseidentificadores para o indivíduo-alvo x^* .
- **Quantificação da degradação determinística de privacidade em um ataque RIU.** O adversário é considerado deterministicamente exitoso em um ataque RIU se, e somente se, ele é capaz de estabelecer com absoluta certeza qual registro na base de dados corresponde ao indivíduo pré-determinado como alvo.

- **Quantificação do sucesso determinístico a priori do adversário em um ataque RIU.** Antes de efetuar o ataque RIU, o adversário não pode utilizar na tentativa de reidentificação os valores dos quaseidentificadores do indivíduo pré-determinado como alvo. Neste caso, é fácil perceber que o adversário atinge absoluta certeza de qual registro na base de dados corresponde ao indivíduo-alvo se, e somente se, a base contém apenas um registro. Assim, o sucesso determinístico a priori do adversário em um ataque RIU sobre uma base D é definido como

$$suc-prior_{det}^{RIU}(D) \stackrel{\text{def}}{=} \begin{cases} \text{verdadeiro,} & \text{se } |D|=1, \\ \text{falso,} & \text{se } |D|\geq 2. \end{cases} \quad (\text{A.1})$$

- **Quantificação do sucesso determinístico a posteriori do adversário em um ataque RIU.** Durante a execução do ataque RIU, o adversário tem como informação auxiliar os valores quaseidentificadores do indivíduo pré-determinado como alvo para ajudá-lo na tentativa de reidentificação. O adversário procede, então, da seguinte forma. Primeiro ele seleciona na base de dados o subconjunto de todos os registros cujos valores de quaseidentificadores são idênticos aos valores dos quaseidentificadores do indivíduo-alvo, descartando os demais registros como irrelevantes. A partir daí, o adversário atinge absoluta certeza sobre qual registro na base de dados corresponde ao indivíduo-alvo se, e somente se, o subconjunto de registros selecionados no passo anterior contém exatamente um elemento. Assim, o sucesso determinístico a posteriori do adversário em um ataque RIU sobre uma base D , dado seu conhecimento sobre os valores $x^*[Q_{ID}]$ dos quaseidentificadores do indivíduo-alvo, é definido como

$$suc-post_{det}^{RIU}(D, x^*[Q_{ID}]) \stackrel{\text{def}}{=} \begin{cases} \text{verdadeiro,} & \text{se existe exatamente um} \\ & \text{registro } x \in D \text{ tal que} \\ & x[Q_{ID}] = x^*[Q_{ID}], \\ \text{falso,} & \text{caso contrário.} \end{cases} \quad (\text{A.2})$$

- **Quantificação da degradação determinística de privacidade em um ataque RIU.** A degradação determinística de privacidade em um ataque RIU ocorre se, e somente se, o adversário não for capaz de reidentificar com absoluta certeza o indivíduo-alvo antes de efetuar o ataque, mas for capaz de fazê-lo após efetuar o ataque. Formalmente,

$$degrad-priv_{det}^{RIU}(D, x^*[Q_{ID}]) \stackrel{\text{def}}{=} \begin{aligned} & suc-prior_{det}^{RIU}(D) = \text{falso} \quad \text{e} \\ & suc-post_{det}^{RIU}(D, x^*[Q_{ID}]) = \text{verdadeiro.} \end{aligned} \quad (\text{A.3})$$

- **Quantificação da degradação probabilística de privacidade em um ataque RIU.** Na medição do sucesso probabilístico de um ataque RIU, não se exige que o adversário realize a reidentificação do indivíduo pré-determinado como alvo com absoluta certeza; em vez disso quantifica-se a probabilidade de que o adversário corretamente reidentifique tal indivíduo-alvo na base. Quanto maior essa probabilidade, mais exitoso é o adversário.

- **Quantificação do sucesso probabilístico a priori do adversário em um ataque RIU.** Antes de efetuar o ataque RIU, o adversário não pode utilizar na tentativa de reidentificação os valores dos quaseidentificadores do indivíduo-alvo. Neste caso, o melhor que o adversário pode fazer é “adivinhar no escuro” qual registro, dentre todos os presentes na base de dados, corresponderia àquele do indivíduo-alvo. Uma vez que a cada indivíduo de interesse corresponde no máximo um registro na base, a probabilidade de o adversário adivinhar o registro que realmente corresponde àquele do indivíduo-alvo é justamente o inverso do tamanho da base. Assim, o sucesso probabilístico a priori do adversário em um ataque RIU sobre uma base D é definido como

$$suc-prior_{prob}^{RIU}(D) \stackrel{\text{def}}{=} \frac{1}{|D|} . \quad (\text{A.4})$$

- **Quantificação do sucesso probabilístico a posteriori do adversário em um ataque RIU.** Durante a execução do ataque RIU, o adversário dispõe do conhecimento dos valores dos quaseidentificadores do indivíduo-alvo para auxiliá-lo na tentativa de reidentificação. O adversário procede, então, da seguinte forma. Primeiro ele seleciona na base de dados o subconjunto de todos os registros cujos valores de quaseidentificadores são idênticos aos valores dos quaseidentificadores do indivíduo-alvo, descartando os demais registros como irrelevantes. A partir daí, o melhor que o adversário pode fazer é “adivinhar no escuro” qual registro do subconjunto de registros selecionados corresponde ao indivíduo-alvo. Uma vez que a cada indivíduo de interesse corresponde no máximo um registro na base, a probabilidade de o adversário adivinhar o registro que realmente corresponde àquele do indivíduo-alvo dentro do subconjunto selecionado é justamente o inverso do tamanho desse subconjunto. Assim, o sucesso probabilístico a posteriori do adversário em um ataque RIU sobre uma base D , dado seu conhecimento sobre os valores $x^*[Q_{ID}]$ dos quaseidentificadores do indivíduo-alvo, é definido como

$$suc-post_{prob}^{RIU}(D, x^*[Q_{ID}]) \stackrel{\text{def}}{=} \frac{1}{|\{x \in D \mid x[Q_{ID}] = x^*[Q_{ID}]\}|} . \quad (\text{A.5})$$

- **Quantificação da degradação probabilística de privacidade em um ataque RIU.** A degradação probabilística de privacidade em um ataque RIU é definida como a razão pela qual a execução do ataque aumenta o sucesso

probabilístico do adversário. Formalmente,

$$\text{degrad-priv}_{\text{prob}}^{\text{RIU}}(D, x^*[\mathcal{Q}_{ID}]) \stackrel{\text{def}}{=} \frac{\text{suc-post}_{\text{prob}}^{\text{RIU}}(D, x^*[\mathcal{Q}_{ID}])}{\text{suc-prior}_{\text{prob}}^{\text{RIU}}(D)}. \quad (\text{A.6})$$

◁

Definição 25 (Ataque de reidentificação coletiva em uma única base de dados (RCU)). Em um *ataque de reidentificação coletiva em uma única base de dados (RCU)*, o adversário tem acesso completo a uma única base de dados –conhecendo todos os seus registros– e é capaz de obter como informação auxiliar os valores de um conjunto de quaseidentificadores para todos os indivíduos cujos registros estão na base. O adversário tem como objetivo reidentificar o maior número possível de indivíduos, independentemente de quem sejam esses indivíduos. A especificação deste ataque é como a seguir.

- **Conhecimento do adversário em um ataque RCU.** Em um ataque RCU, assume-se que o adversário:
 - (i) tem completo acesso a uma base de dados D (não vazia) sobre um conjunto de atributos $\mathcal{A}$;
 - (ii) tem como alvo da tentativa de reidentificação todo indivíduo x presente na base de dados D , independente de quem x seja; e
 - (iii) dado um conjunto $\mathcal{Q}_{ID} \subseteq \mathcal{A}$ de quaseidentificadores, é capaz de obter como informação auxiliar os sub-registros $\{x[\mathcal{Q}_{ID}]\}_{x \in D}$ correspondentes aos valores dos quaseidentificadores de todos os indivíduos presentes na base.
- **Quantificação da degradação determinística de privacidade em um ataque RCU.** A medição do sucesso determinístico de um ataque coletivo RCU leva em conta que adversário tem como alvo todos os indivíduos da base; portanto, define-se tal sucesso como a fração de indivíduos na base que pode ser reidentificada com absoluta certeza.
 - **Quantificação do sucesso determinístico a priori do adversário em um ataque RCU.** Antes de efetuar o ataque RCU, o adversário não pode utilizar os valores dos quaseidentificadores dos indivíduos como informação auxiliar em sua tentativa de reidentificá-los. Logo, o adversário atinge absoluta certeza sobre qual registro na base de dados corresponde a um indivíduo qualquer se, e somente se, a base contém apenas um registro. Dessa forma, a fração de indivíduos na base que pode ser reidentificada com absoluta certeza antes da realização do ataque ou é 1, caso a base contenha apenas um registro, ou é 0, caso a base possua dois ou mais registros. Assim, o sucesso determinístico a priori do adversário em um ataque RCU sobre uma base D é definido como

$$\text{suc-prior}_{\text{det}}^{\text{RCU}}(D) \stackrel{\text{def}}{=} \begin{cases} 1, & \text{se } |D|=1, \\ 0, & \text{se } |D| \geq 2. \end{cases} \quad (\text{A.7})$$

- **Quantificação do sucesso determinístico a posteriori do adversário em um ataque RCU.** Durante a execução do ataque RCU, o adversário dispõe como informação auxiliar do conhecimento dos valores $\{x[\mathcal{Q}_{ID}]\}_{x \in D}$ dos quaseidentificadores de todos os indivíduos na base para tentar reidentificá-los. O adversário age, então, em turnos. Em cada turno ele fixa um indivíduo distinto na base como alvo e seleciona o subconjunto de todos os registros da base cujos valores de quaseidentificadores são idênticos aos valores dos quaseidentificadores do indivíduo ora fixado. É fácil perceber que o adversário atinge absoluta certeza na reidentificação do indivíduo-alvo de cada turno se, e somente se, o subconjunto de registros selecionados no turno contém exatamente um elemento (ou seja, o próprio indivíduo-alvo). O sucesso determinístico global tomado sobre o conjunto de todos os turnos é definido, então, como a razão entre o número de indivíduos que podem ser reidentificados com absoluta certeza em seu turno e o número total de indivíduos na base.

Para formalizar esta métrica, observamos o seguinte. Conhecendo os valores $\{x[\mathcal{Q}_{ID}]\}_{x \in D}$ dos quaseidentificadores de todos os indivíduos em D , o adversário pode derivar a partição $D/\sim_{\mathcal{Q}_{ID}}$ induzida na base de dados por esses quaseidentificadores. Assim, cada bloco da partição contém o conjunto de todos os indivíduos que compartilham entre si os mesmos valores para todos os quaseidentificadores. Claramente, são reidentificáveis com absoluta certeza apenas os indivíduos que estão sozinhos em seu bloco na partição. Logo, a quantidade de indivíduos unicamente reidentificáveis na base a partir de seus quaseidentificadores é justamente o número $|\{\alpha \in D/\sim_{\mathcal{Q}_{ID}} \mid |\alpha|=1\}|$ de blocos $\alpha \in D/\sim_{\mathcal{Q}_{ID}}$ da partição que contém exatamente um indivíduo. Naturalmente, a fração de indivíduos reidentificáveis após a execução do ataque é obtida dividindo-se esse número pelo número total $|D|$ de indivíduos na base. Assim, o sucesso determinístico a posteriori do adversário em um ataque RCU sobre uma base D , dado seu conhecimento sobre os valores $\{x[\mathcal{Q}_{ID}]\}_{x \in D}$ dos quaseidentificadores de todos os indivíduos na base, é definido como

$$suc-post_{det}^{RCU}(D, \{x[\mathcal{Q}_{ID}]\}_{x \in D}) \stackrel{\text{def}}{=} \frac{|\{\alpha \in D/\sim_{\mathcal{Q}_{ID}} \mid |\alpha|=1\}|}{|D|}. \quad (\text{A.8})$$

- **Quantificação da degradação determinística de privacidade em um ataque RCU.** A degradação determinística de privacidade em um ataque RCU é definida como a diferença pela qual a realização do ataque aumenta o sucesso determinístico do adversário. Formalmente,

$$degrad-priv_{det}^{RCU}(D, \{x[\mathcal{Q}_{ID}]\}_{x \in D}) \stackrel{\text{def}}{=} suc-post_{det}^{RCU}(D, \{x[\mathcal{Q}_{ID}]\}_{x \in D}) - suc-prior_{det}^{RCU}(D). \quad (\text{A.9})$$

- **Quantificação da degradação probabilística de privacidade em um ataque RCU.** Na medição do sucesso probabilístico de um ataque coletivo RCU, não se

exige que o adversário realize a reidentificação de todos os indivíduos com absoluta certeza; em vez disso quantifica-se a probabilidade de um indivíduo aleatoriamente escolhido como alvo ser reidentificado com sucesso. Quanto maior essa probabilidade, mais exitoso é o adversário, e maior é o risco esperado de cada indivíduo presente na base ser reidentificado.

- **Quantificação do sucesso probabilístico a priori do adversário em um ataque RCU.** Antes de efetuar o ataque RCU, o adversário não pode utilizar na tentativa de reidentificação os valores dos quaseidentificadores de nenhum indivíduo. Portanto, dado um indivíduo aleatoriamente selecionado como alvo pelo adversário, o melhor que o último pode fazer é “adivinhar no escuro” qual registro, dentre todos os presentes na base de dados, corresponderia a esse indivíduo-alvo. Uma vez que a cada indivíduo de interesse corresponde no máximo um registro na base, a probabilidade de o adversário adivinhar o registro que realmente corresponde àquele do indivíduo selecionado é justamente o inverso do tamanho da base. Assim, o sucesso probabilístico a priori do adversário em um ataque RCU sobre uma base D é definido como

$$suc-prior_{prob}^{RCU}(D) \stackrel{\text{def}}{=} \frac{1}{|D|} . \quad (\text{A.10})$$

- **Quantificação do sucesso probabilístico a posteriori do adversário em um ataque RCU.** Durante a execução do ataque RCU, o adversário dispõe do conhecimento dos valores $\{x[\mathcal{Q}_{ID}]\}_{x \in D}$ dos quaseidentificadores de todos os indivíduos na base como informação auxiliar na tentativa de reidentificação. Dado um indivíduo aleatoriamente fixado como alvo, o adversário seleciona o subconjunto de todos os registros da base cujos valores de quaseidentificadores são idênticos aos valores dos quaseidentificadores do indivíduo fixado. A partir daí, o melhor que o adversário pode fazer é “adivinhar no escuro” qual registro do subconjunto de registros selecionados corresponde ao indivíduo-alvo. Uma vez que a cada indivíduo de interesse corresponde no máximo um registro na base, a probabilidade de o adversário adivinhar o registro que realmente corresponde àquele do indivíduo-alvo dentro do subconjunto selecionado é justamente o inverso do tamanho desse subconjunto. O sucesso probabilístico global após o ataque é definido, então, como a esperança da probabilidade de sucesso tomada sobre a distribuição de probabilidade de que cada indivíduo da base tenha sido selecionado como alvo. Assim, o sucesso probabilístico a posteriori do adversário em um ataque RCU sobre uma base D , dado seu conhecimento sobre os valores $\{x[\mathcal{Q}_{ID}]\}_{x \in D}$ dos quaseidentificadores de todos os indivíduos na base, é definido como

$$\begin{aligned} suc-post_{prob}^{RCU}(D, \{x[\mathcal{Q}_{ID}]\}_{x \in D}) &\stackrel{\text{def}}{=} \sum_{x \in D} \pi_x^D \cdot \frac{1}{|\{x' \in D \mid x'[\mathcal{Q}_{ID}] = x[\mathcal{Q}_{ID}]\}|} \\ &= \frac{|D / \sim_{\mathcal{Q}_{ID}}|}{|D|} . \end{aligned} \quad (\text{A.11})$$

- **Quantificação da degradação probabilística de privacidade em um ataque RCU.** A degradação probabilística de privacidade em um ataque RCU é definida como a razão pela qual a realização do ataque aumenta o sucesso probabilístico do adversário. Formalmente,

$$\text{degrad-priv}_{\text{prob}}^{\text{RCU}}(D, \{x[\mathcal{Q}_{ID}]\}_{x \in D}) \stackrel{\text{def}}{=} \frac{\text{suc-post}_{\text{prob}}^{\text{RCU}}(D, \{x[\mathcal{Q}_{ID}]\}_{x \in D})}{\text{suc-prior}_{\text{prob}}^{\text{RCU}}(D)} . \quad (\text{A.12})$$

◁

Definição 26 (Ataque de inferência de atributo individual em uma única base de dados (AIU)). Em um *ataque de inferência de atributo individual em uma única base de dados (AIU)*, o adversário tem acesso completo a uma única base de dados –conhecendo todos os seus registros– e é capaz de obter como informação auxiliar os valores de um conjunto de quaseidentificadores de um indivíduo específico pré-determinado como alvo. O adversário tem como objetivo inferir os valores de um atributo considerado como sensível para o indivíduo-alvo, independentemente de se esse indivíduo tenha sido reidentificado com sucesso ou não. A especificação deste ataque é como a seguir.

- **Conhecimento do adversário em um ataque AIU.** Em um ataque AIU, assume-se que o adversário:
 - (i) tem completo acesso a uma base de dados D (não vazia) sobre um conjunto de atributos $\mathcal{A}$;
 - (ii) possui um indivíduo específico $x^* \in D$ pré-determinado como alvo da tentativa de inferência de atributo;
 - (iii) dado um conjunto $\mathcal{Q}_{ID} \subseteq \mathcal{A}$ de quaseidentificadores, é capaz de obter como informação auxiliar o sub-registro $x^*[\mathcal{Q}_{ID}]$ correspondente aos valores dos quaseidentificadores para o indivíduo-alvo x^* ; e
 - (iv) dado um atributo $a_{\text{sens}} \in \mathcal{A}$ considerado como sensível (tal que $a_{\text{sens}} \notin \mathcal{Q}_{ID}$), está interessado em determinar o valor $x^*[a_{\text{sens}}]$ deste atributo para o indivíduo-alvo x^* .
- **Quantificação da degradação determinística de privacidade em um ataque AIU.** O adversário é considerado deterministicamente exitoso em um ataque AIU se, e somente se, ele é capaz de estabelecer com absoluta certeza qual o valor do atributo sensível do indivíduo pré-determinado como alvo.
- **Quantificação do sucesso determinístico a priori do adversário em um ataque AIU.** Antes de efetuar o ataque RIU, o adversário não pode utilizar os valores dos quaseidentificadores do indivíduo-alvo como informação auxiliar na tentativa de inferir o valor de seu atributo sensível. Neste caso,

é fácil perceber que o adversário atinge absoluta certeza sobre qual é o valor do atributo sensível do indivíduo-alvo se, e somente se, todos os registros na base apresentam o mesmo valor para o atributo sensível. Assim, o sucesso determinístico a priori do adversário em um ataque AIU sobre uma base D , com respeito ao atributo sensível a_{sens} , é definido como

$$suc-prior_{det}^{AIU}(D, a_{sens}) \stackrel{\text{def}}{=} \begin{cases} \text{verdadeiro,} & \text{se para todo } x, x' \in D, \\ & x[a_{sens}] = x'[a_{sens}], \\ \text{falso,} & \text{caso contrário.} \end{cases} \quad (\text{A.13})$$

- **Quantificação do sucesso determinístico a posteriori do adversário em um ataque AIU.** Durante a execução do ataque AIU, o adversário dispõe do conhecimento dos valores dos quaseidentificadores do indivíduo pré-determinado como alvo como informação auxiliar na tentativa de inferência do valor de seu atributo sensível. O adversário procede, então, da seguinte forma. Primeiro ele seleciona na base de dados o subconjunto de todos os registros cujos valores de quaseidentificadores são idênticos aos valores dos quaseidentificadores do indivíduo-alvo, descartando os demais registros como irrelevantes. A partir daí, o adversário atinge absoluta certeza sobre qual é o valor do atributo sensível do indivíduo-alvo se, e somente se, todos os registros do subconjunto assim selecionado contêm exatamente o mesmo valor para o atributo sensível. Assim, o sucesso determinístico a posteriori do adversário em um ataque AIU sobre uma base D , com respeito ao atributo sensível a_{sens} , e dado seu conhecimento sobre os valores $x^*[Q_{ID}]$ dos quaseidentificadores do indivíduo-alvo, é definido como

$$suc-post_{det}^{AIU}(D, a_{sens}, x^*[Q_{ID}]) \stackrel{\text{def}}{=} \begin{cases} \text{verdadeiro,} & \text{se para todo } x, x' \in D \text{ tais que} \\ & x[Q_{ID}] = x'[Q_{ID}] = x^*[Q_{ID}], \\ & \text{tem-se que } x[a_{sens}] = x'[a_{sens}], \\ \text{falso,} & \text{caso contrário.} \end{cases} \quad (\text{A.14})$$

- **Quantificação da degradação determinística de privacidade em um ataque AIU.** A degradação determinística de privacidade em um ataque AIU ocorre se, e somente se, o adversário não for capaz de inferir com absoluta certeza o valor sensível do indivíduo-alvo antes de efetuar o ataque, mas for capaz de fazê-lo após efetuar o ataque. Formalmente,

$$\begin{aligned} degrad-priv_{det}^{AIU}(D, a_{sens}, x^*[Q_{ID}]) &\stackrel{\text{def}}{=} \\ (suc-prior_{det}^{AIU}(D, a_{sens}) = \text{falso}) &\text{ e} \\ (suc-post_{det}^{AIU}(D, a_{sens}, x^*[Q_{ID}]) = \text{verdadeiro}) &. \end{aligned} \quad (\text{A.15})$$

- **Quantificação da degradação probabilística de privacidade em um ataque AIU.** Na medição do sucesso probabilístico de um ataque individual AIU, não se exige que o adversário infira o valor do atributo sensível do indivíduo pré-determinado como alvo com absoluta certeza; em vez disso quantifica-se a probabilidade de que o adversário corretamente infira tal valor. Quanto maior essa probabilidade, mais exitoso é o adversário.

- **Quantificação do sucesso probabilístico a priori do adversário em um ataque AIU.** Antes de efetuar o ataque AIU, o adversário não pode utilizar os valores dos quaseidentificadores do indivíduo-alvo como informação auxiliar na tentativa inferir seu atributo sensível. Neste caso, o melhor que o adversário pode fazer é “adivinhar no escuro” qual seria o valor do atributo sensível do indivíduo-alvo. Uma vez que a cada indivíduo de interesse corresponde no máximo um registro na base, a melhor estratégia para o adversário é inferir como valor do atributo sensível aquele valor mais frequente na base de dados. Lembrando que a probabilidade de cada valor de atributo sensível na base é dada pela distribuição $\pi^{a_{sens}|D}$, derivada de acordo com a Equação 3.2, o sucesso probabilístico a priori do adversário em um ataque AIU sobre uma base D , com respeito ao atributo sensível a_{sens} , é definido como

$$\begin{aligned} suc\text{-}prior_{prob}^{AIU}(D, a_{sens}) &\stackrel{\text{def}}{=} \max_{s \in \text{dom}(a_{sens})} \pi_s^{a_{sens}|D} \\ &= \max_{s \in \text{dom}(a_{sens})} \frac{|\{x \in D \mid x[a_{sens}] = s\}|}{|D|}. \end{aligned} \quad (\text{A.16})$$

- **Quantificação do sucesso probabilístico a posteriori do adversário em um ataque AIU.** Durante a execução do ataque AIU, o adversário dispõe do conhecimento dos valores dos quaseidentificadores do indivíduo-alvo como informação auxiliar para a tentativa de inferência do valor de seu atributo sensível. O adversário procede, então, da seguinte forma. Primeiro ele seleciona na base de dados o subconjunto de todos os registros cujos valores de quaseidentificadores são idênticos aos valores de quaseidentificadores do indivíduo-alvo, descartando os demais registros como irrelevantes. A partir daí, o melhor que o adversário pode fazer é “adivinhar no escuro” qual valor de atributo sensível, dentre aqueles presentes no subconjunto assim selecionado, corresponde ao valor do indivíduo-alvo. Uma vez que a cada indivíduo de interesse corresponde no máximo um registro na base, a melhor estratégia para o adversário é inferir como valor do atributo sensível aquele valor mais frequente no subconjunto de registros selecionado. Lembrando que a probabilidade de cada valor de atributo sensível na base é dada pela distribuição $\pi^{a_{sens}|D}$, derivada de acordo com a Equação 3.2, o sucesso probabilístico a posteriori do adversário em um ataque AIU sobre uma base D , com respeito ao atributo sensível a_{sens} , e dado seu conhecimento sobre os valores $x^*[Q_{ID}]$

dos quaseidentificadores do indivíduo-alvo, é definido como

$$\begin{aligned} \text{suc-post}_{\text{prob}}^{\text{AIU}}(D, a_{\text{sens}}, x^*[\mathcal{Q}_{ID}]) &\stackrel{\text{def}}{=} \\ \max_{s \in \text{dom}(a_{\text{sens}})} &\frac{|\{x \in \text{bloco}(x^*[\mathcal{Q}_{ID}]) \mid x[a_{\text{sens}}]=s\}|}{|\text{bloco}(x^*[\mathcal{Q}_{ID}])|}, \end{aligned} \quad (\text{A.17})$$

onde $\text{bloco}(x^*[\mathcal{Q}_{ID}]) = \{x \in D \mid x[\mathcal{Q}_{ID}] = x^*[\mathcal{Q}_{ID}]\}$ é o bloco de todos os indivíduos da base de dados que compartilham os mesmos valores de quaseidentificadores em $\mathcal{Q}_{ID}$ com o indivíduo-alvo x^* .

- **Quantificação da degradação probabilística de privacidade em um ataque AIU.** A degradação probabilística de privacidade em um ataque AIU é definida como a razão pela qual a execução do ataque aumenta o sucesso probabilístico do adversário. Formalmente,

$$\text{degrad-priv}_{\text{prob}}^{\text{AIU}}(D, a_{\text{sens}}, x^*[\mathcal{Q}_{ID}]) \stackrel{\text{def}}{=} \frac{\text{suc-post}_{\text{prob}}^{\text{AIU}}(D, a_{\text{sens}}, x^*[\mathcal{Q}_{ID}])}{\text{suc-prior}_{\text{prob}}^{\text{AIU}}(D, a_{\text{sens}})}. \quad (\text{A.18})$$

◁

Definição 27 (Ataque de inferência de atributo coletiva em uma única base de dados (ACU)). Em um *ataque de inferência de atributo coletiva em uma única base de dados (ACU)*, o adversário tem acesso completo a uma única base de dados –conhecendo todos os seus registros– e é capaz de obter como informação auxiliar os valores de um conjunto de quaseidentificadores para todos os indivíduos cujos registros estão na base. O adversário tem como objetivo inferir o valor de um atributo considerado como sensível para o maior número possível de indivíduos, independentemente de se esses indivíduos tenham sido reidentificados com sucesso ou não. A especificação deste ataque é como a seguir.

- **Conhecimento do adversário em um ataque ACU.** Em um ataque RCU, assume-se que o adversário:
 - tem completo acesso a uma base de dados D (não vazia) sobre um conjunto de atributos $\mathcal{A}$;
 - tem como alvo da tentativa de inferência de atributo todo indivíduo x presente na base de dados D , independente de quem x seja; e
 - dado um conjunto $\mathcal{Q}_{ID} \subseteq \mathcal{A}$ de quaseidentificadores, é capaz de obter como informação auxiliar os sub-registros $\{x[\mathcal{Q}_{ID}]\}_{x \in D}$ correspondentes aos valores dos quaseidentificadores de todos os indivíduos presentes na base; e
 - dado um atributo $a_{\text{sens}} \in \mathcal{A}$ considerado como sensível (tal que $a_{\text{sens}} \notin \mathcal{Q}_{ID}$), está interessado em determinar o valor $x[a_{\text{sens}}]$ deste atributo para o maior número possível de indivíduos $x \in D$.

- **Quantificação da degradação determinística de privacidade em um ataque ACU.** Na medição do sucesso determinístico de um ataque coletivo ACU, leva-se em conta que adversário tem como alvo todos os indivíduos da base; portanto, define-se tal sucesso como a fração desses indivíduos cujo valor do atributo sensível pode ser inferido com absoluta certeza.

- **Quantificação do sucesso determinístico a priori do adversário em um ataque ACU.** Antes de efetuar o ataque ACU, o adversário não pode utilizar os valores dos quaseidentificadores dos indivíduos como informação auxiliar na tentativa de inferência dos valores de seu atributo sensível. Logo, o adversário atinge absoluta certeza sobre qual é o valor do atributo sensível de qualquer indivíduo se, e somente se, todos os registros na base de dados apresentam o mesmo valor para o atributo sensível. Dessa forma, a fração de indivíduos na base cujo valor para o atributo sensível pode ser inferido com absoluta certeza antes da realização do ataque ou é 1, caso todos os registros na base compartilhem o mesmo valor para o atributo sensível, ou é 0, em caso contrário. Assim, o sucesso determinístico a priori do adversário em um ataque ACU sobre uma base D , com respeito ao atributo sensível a_{sens} , é definido como

$$suc-prior_{det}^{ACU}(D, a_{sens}) \stackrel{\text{def}}{=} \begin{cases} 1, & \text{se para todo } x, x' \in D, \\ & x[a_{sens}] = x'[a_{sens}], \\ 0, & \text{caso contrário.} \end{cases} \quad (\text{A.19})$$

- **Quantificação do sucesso determinístico a posteriori do adversário em um ataque ACU.** Durante a execução do ataque ACU, o adversário dispõe do conhecimento dos valores $\{x[\mathcal{Q}_{ID}]\}_{x \in D}$ dos quaseidentificadores de todos os indivíduos na base como informação auxiliar na tentativa de inferência dos valores de seu atributo sensível. O adversário age, então, em turnos. Em cada turno ele fixa um indivíduo distinto na base como alvo e seleciona o subconjunto de todos os registros da base cujos valores de quaseidentificadores são idênticos aos valores dos quaseidentificadores do indivíduo ora fixado. É fácil perceber que o adversário atinge absoluta certeza na inferência do atributo sensível do indivíduo-alvo de cada turno se, e somente se, no subconjunto de registros selecionados no passo anterior todos possuem o mesmo valor para o atributo sensível. O sucesso determinístico global tomado sobre o conjunto de todos os turnos é definido, então, como a razão entre o número de indivíduos cujo valor de atributo sensível pode ser inferido com absoluta certeza em seu turno e o número total de indivíduos na base.

Para formalizar esta métrica, observamos o seguinte. Conhecendo os valores $\{x[\mathcal{Q}_{ID}]\}_{x \in D}$ dos quaseidentificadores de todos os indivíduos em D , o adversário pode derivar a partição $D/\sim_{\mathcal{Q}_{ID}}$ induzida na base de dados por esses quaseidentificadores. Assim, cada bloco da partição contém o conjunto de todos os indivíduos que compartilham entre si os mesmos valores para todos os

quaseidentificadores. Claramente, podem ter o atributo sensível inferido com absoluta certeza apenas os indivíduos que estão em blocos em que todos os registros compartilham o mesmo valor de atributo sensível. Assim, o sucesso determinístico a posteriori do adversário em um ataque ACU sobre uma base D , com respeito a um atributo sensível a_{sens} , dado seu conhecimento sobre os valores $\{x[\mathcal{Q}_{ID}]\}_{x \in D}$ dos quaseidentificadores de todos os indivíduos presentes na base, é definido como

$$\text{suc-post}_{det}^{ACU}(D, a_{sens}, \{x[\mathcal{Q}_{ID}]\}_{x \in D}) \stackrel{\text{def}}{=} \frac{\sum_{\alpha \in D / \sim_{\mathcal{Q}_{ID}}} |\alpha| \cdot \text{sens-único}(\alpha, a_{sens})}{|D|}, \quad (\text{A.20})$$

onde $D / \sim_{\mathcal{Q}_{ID}}$ é a partição sobre registros da base de dados induzida pelos quaseidentificadores $\mathcal{Q}_{ID}$, a variável α varia sobre os blocos desta partição, e a função $\text{sens-único}(\alpha, a_{sens})$ retorna 1 caso todos os registros no bloco α compartilhem o mesmo valor para o atributo sensível a_{sens} , ou retorna 0 em caso contrário:

$$\text{sens-único}(\alpha, a_{sens}) \stackrel{\text{def}}{=} \begin{cases} 1, & \text{se para todo } x, x' \in \alpha, \\ & x[a_{sens}] = x'[a_{sens}], \\ 0, & \text{caso contrário.} \end{cases} \quad (\text{A.21})$$

- **Quantificação da degradação determinística de privacidade em um ataque ACU.** A degradação determinística de privacidade em um ataque ACU é definida como a diferença pela qual a realização do ataque aumenta o sucesso determinístico do adversário. Formalmente,

$$\text{degrad-priv}_{det}^{ACU}(D, a_{sens}, \{x[\mathcal{Q}_{ID}]\}_{x \in D}) \stackrel{\text{def}}{=} \text{suc-post}_{det}^{ACU}(D, a_{sens}, \{x[\mathcal{Q}_{ID}]\}_{x \in D}) - \text{suc-prior}_{det}^{ACU}(D, a_{sens}). \quad (\text{A.22})$$

- **Quantificação da degradação probabilística de privacidade em um ataque ACU.** Na medição do sucesso probabilístico de um ataque coletivo RCU, não se exige que o adversário infira valor do atributo sensível de todos os indivíduos com absoluta certeza; em vez disso quantifica-se a probabilidade de um indivíduo aleatoriamente escolhido como alvo ter o valor de seu atributo sensível inferido com sucesso. Quanto maior essa probabilidade, mais exitoso é o adversário, e maior é o risco esperado de cada indivíduo presente na base ter seu atributo sensível inferido.
- **Quantificação do sucesso probabilístico a priori do adversário em um ataque ACU.** Antes de efetuar o ataque ACU, o adversário não pode utilizar os valores dos quaseidentificadores de nenhum indivíduo como informação auxiliar na tentativa de inferência do valor de seu atributo sensível. Portanto, dado um indivíduo aleatoriamente selecionado como alvo pelo adversário, o

melhor que o último pode fazer é “adivinhar no escuro” qual seu valor para o atributo sensível. Uma vez que a cada indivíduo de interesse corresponde no máximo um registro na base, a melhor estratégia para o adversário é inferir como valor do atributo sensível aquele valor mais frequente na base de dados. Lembrando que a probabilidade de cada valor de atributo sensível na base é dada pela distribuição $\pi^{a_{sens}|D}$, derivada de acordo com a Equação 3.2, o sucesso probabilístico a priori do adversário em um ataque ACU sobre uma base D , com respeito a um atributo sensível a_{sens} , é definido como

$$\begin{aligned} suc\text{-}prior_{prob}^{ACU}(D, a_{sens}) &\stackrel{\text{def}}{=} \max_{s \in \text{dom}(a_{sens})} \pi_s^{a_{sens}|D} \\ &= \max_{s \in \text{dom}(a_{sens})} \frac{|\{x \in D \mid x[a_{sens}] = s\}|}{|D|}. \end{aligned} \quad (\text{A.23})$$

- **Quantificação do sucesso probabilístico a posteriori do adversário em um ataque ACU.** Durante a execução do ataque RCU, o adversário dispõe do conhecimento dos valores $\{x[\mathcal{Q}_{ID}]\}_{x \in D}$ dos quaseidentificadores de todos os indivíduos na base como informação auxiliar para tentar inferir seu valor de atributo sensível. Dado um indivíduo aleatoriamente fixado como alvo, o adversário seleciona o subconjunto de todos os registros da base cujos valores de quaseidentificadores são idênticos aos valores dos quaseidentificadores do indivíduo fixado. A partir daí, o melhor que o adversário pode fazer é “adivinhar no escuro” qual valor de atributo sensível, dentre aqueles presentes no subconjunto assim selecionado, corresponde ao valor do indivíduo-alvo. Uma vez que a cada indivíduo de interesse corresponde no máximo um registro na base, a melhor estratégia para o adversário é inferir como valor do atributo sensível aquele valor mais frequente no subconjunto de registros selecionados. O sucesso probabilístico global após o ataque é definido, então, como a esperança da probabilidade de sucesso tomada sobre a distribuição de probabilidade de que cada indivíduo da base tenha sido selecionado como alvo. Assim, o sucesso probabilístico a posteriori do adversário em um ataque ACU com respeito a um atributo sensível a_{sens} , sobre uma base D , dado seu conhecimento sobre os valores $\{x[\mathcal{Q}_{ID}]\}_{x \in D}$ dos quaseidentificadores de todos os indivíduos na base, é definido como

$$\begin{aligned} suc\text{-}post_{prob}^{ACU}(D, a_{sens}, \{x[\mathcal{Q}_{ID}]\}_{x \in D}) &\stackrel{\text{def}}{=} \\ \sum_{x \in D} \pi_x^D \max_{s \in \text{dom}(a_{sens})} \frac{|\{x' \in D \mid x'[a_{sens}] = s, x'[\mathcal{Q}_{ID}] = x[\mathcal{Q}_{ID}]\}|}{|\{x' \in D \mid x'[\mathcal{Q}_{ID}] = x[\mathcal{Q}_{ID}]\}|} &= \\ \frac{1}{|D|} \sum_{q \in \text{dom}(\mathcal{Q}_{ID})} \max_{s \in \text{dom}(a_{sens})} |\{x \in D \mid x[a_{sens}] = s, x[\mathcal{Q}_{ID}] = q\}|. \end{aligned} \quad (\text{A.24})$$

- **Quantificação da degradação probabilística de privacidade em um ataque ACU.** A degradação probabilística de privacidade em um ataque

ACU é definida como a razão pela qual a realização do ataque aumenta o sucesso probabilístico do adversário. Formalmente,

$$\frac{\text{degrad-priv}_{\text{prob}}^{ACU}(D, a_{\text{sens}}, \{x[\mathcal{Q}_{ID}]\}_{x \in D})}{\text{suc-prior}_{\text{prob}}^{ACU}(D, a_{\text{sens}})} \stackrel{\text{def}}{=} \frac{\text{suc-post}_{\text{prob}}^{ACU}(D, a_{\text{sens}}, \{x[\mathcal{Q}_{ID}]\}_{x \in D})}{\text{suc-prior}_{\text{prob}}^{ACU}(D, a_{\text{sens}})} . \quad (\text{A.25})$$

◁

A.2 Formalização de ataques longitudinais

Nesta seção formalizamos matematicamente os ataques longitudinais introduzidos na Seção 5.

Definição 28 (Ataque de reidentificação individual longitudinal (RIL)). Em um *ataque de reidentificação individual longitudinal (RIL)*, o adversário tem acesso a uma coleção longitudinal de bases de dados e conhece os valores de um conjunto de quaseidentificadores de um indivíduo específico na base focal pré-determinado como alvo. O adversário tem como objetivo reidentificar o indivíduo-alvo, i.e., estabelecer qual registro na base focal corresponde a esse indivíduo. Neste tipo de ataque, o adversário pode usar as bases auxiliares do conjunto longitudinal como informação auxiliar para aumentar suas chances de sucesso. A especificação deste tipo ataque é análoga à de um ataque *RIU* (Definição 24), com a única diferença de que, de acordo com as premissas **PL6**, **PL6a** e **PL6b** sobre ataques longitudinais, o sucesso a priori do adversário é tomado em relação à base focal, enquanto seu sucesso a posteriori é tomado em relação à agregação da informação presente em todas as bases do conjunto longitudinal.

- **Conhecimento do adversário em um ataque RIL.** Em um ataque RIL, assume-se que o adversário:
 - (i) tem completo acesso a uma coleção longitudinal $\mathcal{L}_{\mathcal{D}} = \{D_1, D_2, \dots, D_k\}$ de bases de dados satisfazendo as premissas **PL0–PL3** sobre ataques longitudinais, sendo capaz de agregar a informação desse conjunto em uma nova base $\text{agreg}(\mathcal{L}_{\mathcal{D}})$ conforme a premissa **PL4**;
 - (ii) possui um indivíduo específico $x^* \in D_1$ na base focal pré-determinado como alvo da tentativa de reidentificação; e
 - (iii) dado um conjunto $\mathcal{Q}_{ID}$ de quaseidentificadores comuns a todas as bases em $\mathcal{L}_{\mathcal{D}}$, conhece o sub-registro $x^*[\mathcal{Q}_{ID}]$ correspondente aos valores desses quaseidentificadores para o indivíduo-alvo x^* em toda base $D_i \in \mathcal{L}_{\mathcal{D}}$.
- **Quantificação da degradação determinística de privacidade em um ataque RIL.** O adversário é considerado deterministicamente exitoso em um ataque

RIL se, e somente se, ele é capaz de estabelecer com absoluta certeza qual registro na base focal D_1 corresponde ao indivíduo pré-determinado como alvo.

- **Quantificação do sucesso determinístico a priori do adversário em um ataque RIL.** O sucesso determinístico a priori do adversário em um ataque RIL sobre um conjunto longitudinal $\mathcal{L}_{\mathcal{D}}$ de bases é definido como

$$suc-prior_{det}^{RIL}(\mathcal{L}_{\mathcal{D}}) \stackrel{\text{def}}{=} \begin{cases} \text{verdadeiro,} & \text{se } |D_1|=1, \\ \text{falso,} & \text{se } |D_1|\geq 2. \end{cases} \quad (\text{A.26})$$

- **Quantificação do sucesso determinístico a posteriori do adversário em um ataque RIL.** O sucesso determinístico a posteriori do adversário em um ataque RIL sobre um conjunto longitudinal $\mathcal{L}_{\mathcal{D}}$ de bases, dado seu conhecimento sobre os valores $x^*[Q_{ID}]$ dos quaseidentificadores do indivíduo-alvo, é definido como

$$suc-post_{det}^{RIL}(\mathcal{L}_{\mathcal{D}}, x^*[Q_{ID}]) \stackrel{\text{def}}{=} \begin{cases} \text{verdadeiro,} & \text{se existe exatamente um} \\ & \text{registro } x \in \text{agreg}(\mathcal{L}_{\mathcal{D}}) \\ & \text{tal que } x[Q_{ID}] = x^*[Q_{ID}], \\ \text{falso,} & \text{caso contrário.} \end{cases} \quad (\text{A.27})$$

- **Quantificação da degradação determinística de privacidade em um ataque RIL.** A degradação determinística de privacidade em um ataque RIL ocorre se, e somente se, o adversário não for capaz de reidentificar com absoluta certeza o indivíduo-alvo antes de efetuar o ataque, mas for capaz de fazê-lo após efetuar o ataque. Formalmente,

$$degrad-priv_{det}^{RIL}(\mathcal{L}_{\mathcal{D}}, x^*[Q_{ID}]) \stackrel{\text{def}}{=} suc-prior_{det}^{RIL}(\mathcal{L}_{\mathcal{D}}) = \text{falso} \quad \text{e} \quad (\text{A.28})$$

$$suc-post_{det}^{RIL}(\mathcal{L}_{\mathcal{D}}, x^*[Q_{ID}]) = \text{verdadeiro}. \quad (\text{A.29})$$

- **Quantificação da degradação probabilística de privacidade em um ataque RIL.** Na medição do sucesso probabilístico de um ataque RIL, não se exige que o adversário realize a reidentificação do indivíduo na base focal pré-determinado como alvo com absoluta certeza; em vez disso quantifica-se a probabilidade de que o adversário corretamente reidentifique tal indivíduo-alvo nessa base focal. Quanto maior essa probabilidade, mais exitoso é o adversário.

- **Quantificação do sucesso probabilístico a priori do adversário em um ataque RIL.** O sucesso probabilístico a priori do adversário em um ataque RIL sobre um conjunto longitudinal $\mathcal{L}_{\mathcal{D}}$ de bases é definido como

$$suc-prior_{prob}^{RIL}(\mathcal{L}_{\mathcal{D}}) \stackrel{\text{def}}{=} \frac{1}{|D_1|}. \quad (\text{A.30})$$

- **Quantificação do sucesso probabilístico a posteriori do adversário em um ataque RIL.** O sucesso probabilístico a posteriori do adversário em um ataque RIL sobre um conjunto longitudinal $\mathcal{L}_{\mathcal{D}}$ de bases, dado seu conhecimento sobre os valores $x^*[\mathcal{Q}_{ID}]$ dos quaseidentificadores do indivíduo-alvo, é definido como

$$suc-post_{prob}^{RIL}(\mathcal{L}_{\mathcal{D}}, x^*[\mathcal{Q}_{ID}]) \stackrel{\text{def}}{=} \frac{1}{|\{x \in agreg(\mathcal{L}_{\mathcal{D}}) \mid x[\mathcal{Q}_{ID}] = x^*[\mathcal{Q}_{ID}]\}|} . \quad (\text{A.31})$$

- **Quantificação da degradação probabilística de privacidade em um ataque RIL.** A degradação probabilística de privacidade em um ataque RIL é definida como a razão pela qual a execução do ataque aumenta o sucesso probabilístico do adversário. Formalmente,

$$degrad-priv_{prob}^{RIL}(\mathcal{L}_{\mathcal{D}}, x^*[\mathcal{Q}_{ID}]) \stackrel{\text{def}}{=} \frac{suc-post_{prob}^{RIL}(\mathcal{L}_{\mathcal{D}}, x^*[\mathcal{Q}_{ID}])}{suc-prior_{prob}^{RIL}(\mathcal{L}_{\mathcal{D}})} . \quad (\text{A.32})$$

◁

Definição 29 (Ataque de reidentificação coletiva longitudinal (RCL)). Em um *ataque de reidentificação coletiva longitudinal (RCL)*, o adversário tem acesso completo a um conjunto longitudinal de bases de dados e conhece os valores de um conjunto de quase-identificadores para todos os indivíduos cujos registros estão nessas bases. O adversário tem como objetivo reidentificar o maior número possível de indivíduos na base focal, independentemente de quem sejam esses indivíduos. Neste tipo de ataque, o adversário pode usar as bases auxiliares do conjunto longitudinal como informação auxiliar para aumentar suas chances de sucesso. A especificação deste tipo de ataque é análoga à de um ataque *RCU* (Definição 25), com a única diferença de que, de acordo com as premissas **PL6**, **PL6a**, e **PL6b** sobre ataques longitudinais, o sucesso a priori do adversário é tomado em relação à base focal, enquanto seu sucesso a posteriori é tomado em relação à agregação da informação presente em todas as bases do conjunto longitudinal.

- **Conhecimento do adversário em um ataque RCL.** Em um ataque RCL, assume-se que o adversário:
 - (i) tem completo acesso a uma coleção longitudinal $\mathcal{L}_{\mathcal{D}} = \{D_1, D_2, \dots, D_k\}$ de bases de dados satisfazendo as premissas **PL0–PL3** sobre ataques longitudinais, sendo capaz de agregar a informação desse conjunto em uma nova base $agreg(\mathcal{L}_{\mathcal{D}})$ conforme a premissa **PL4**;
 - (ii) tem como alvo da tentativa de reidentificação todo indivíduo x presente na base focal D_1 , independentemente de quem x seja; e
 - (iii) dado um conjunto $\mathcal{Q}_{ID}$ de quaseidentificadores comuns a todas as bases em $\mathcal{L}_{\mathcal{D}}$, conhece os sub-registros $\{x[\mathcal{Q}_{ID}]\}_{x \in agreg(\mathcal{L}_{\mathcal{D}})}$ correspondentes aos valores dos quaseidentificadores de todos os indivíduos presentes na agregação $agreg(\mathcal{L}_{\mathcal{D}})$ das bases.

- **Quantificação da degradação determinística de privacidade em um ataque RCL.** A medição do sucesso determinístico de um ataque coletivo RCL leva em conta que o adversário tem como alvo todos os indivíduos da base focal D_1 , portanto, define-se tal sucesso como a fração dos indivíduos nessa base que pode ser reidentificada com absoluta certeza.

- **Quantificação do sucesso determinístico a priori do adversário em um ataque RCL.** O sucesso determinístico a priori do adversário em um ataque RCL sobre um conjunto longitudinal $\mathcal{L}_{\mathcal{D}}$ de bases é definido como

$$suc-prior_{det}^{RCL}(\mathcal{L}_{\mathcal{D}}) \stackrel{\text{def}}{=} \begin{cases} 1, & \text{se } |D_1|=1, \\ 0, & \text{se } |D_1|\geq 2. \end{cases} \quad (\text{A.33})$$

- **Quantificação do sucesso determinístico a posteriori do adversário em um ataque RCL.** O sucesso determinístico a posteriori do adversário em um ataque RCL sobre um conjunto longitudinal $\mathcal{L}_{\mathcal{D}}$ de bases, dado seu conhecimento sobre os valores $\{x[\mathcal{Q}_{ID}]\}_{x \in agreg(\mathcal{L}_{\mathcal{D}})}$ dos quaseidentificadores de todos os indivíduos nesse conjunto, é definido como

$$suc-post_{det}^{RCL}(\mathcal{L}_{\mathcal{D}}, \{x[\mathcal{Q}_{ID}]\}_{x \in agreg(\mathcal{L}_{\mathcal{D}})}) \stackrel{\text{def}}{=} \frac{|\{\alpha \in agreg(\mathcal{L}_{\mathcal{D}}) / \sim_{\mathcal{Q}_{ID}} \mid |\alpha|=1\}|}{|agreg(\mathcal{L}_{\mathcal{D}})|}. \quad (\text{A.34})$$

- **Quantificação da degradação determinística de privacidade em um ataque RCL.** A degradação determinística de privacidade em um ataque RCL é definida como a diferença pela qual a realização do ataque aumenta o sucesso determinístico do adversário. Formalmente,

$$\begin{aligned} degrad-priv_{det}^{RCL}(\mathcal{L}_{\mathcal{D}}, \{x[\mathcal{Q}_{ID}]\}_{x \in agreg(\mathcal{L}_{\mathcal{D}})}) &\stackrel{\text{def}}{=} \\ suc-post_{det}^{RCL}(\mathcal{L}_{\mathcal{D}}, \{x[\mathcal{Q}_{ID}]\}_{x \in agreg(\mathcal{L}_{\mathcal{D}})}) - suc-prior_{det}^{RCL}(\mathcal{L}_{\mathcal{D}}). \end{aligned} \quad (\text{A.35})$$

- **Quantificação da degradação probabilística de privacidade em um ataque RCL.** Na medição do sucesso probabilístico de um ataque coletivo RCL, não se exige que o adversário realize a reidentificação de todos os indivíduos na base focal com absoluta certeza; em vez disso quantifica-se a probabilidade de um indivíduo da base focal aleatoriamente escolhido como alvo ser reidentificado com sucesso. Quanto maior essa probabilidade, mais exitoso é o adversário, e maior é o risco esperado de cada indivíduo presente na base focal ser reidentificado.

- **Quantificação do sucesso probabilístico a priori do adversário em um ataque RCL.** O sucesso probabilístico a priori do adversário em um ataque RCL sobre um conjunto longitudinal $\mathcal{L}_{\mathcal{D}}$ de bases é definido como:

$$suc-prior_{prob}^{RCL}(\mathcal{L}_{\mathcal{D}}) \stackrel{\text{def}}{=} \frac{1}{|D_1|}. \quad (\text{A.36})$$

- **Quantificação do sucesso probabilístico a posteriori do adversário em um ataque RCL.** O sucesso probabilístico a posteriori do adversário em um ataque RCL sobre um conjunto longitudinal $\mathcal{L}_{\mathcal{D}}$ de bases, dado seu conhecimento sobre os valores $\{x[\mathcal{Q}_{ID}]\}_{x \in \text{agreg}(\mathcal{L}_{\mathcal{D}})}$ dos quaseidentificadores de todos os indivíduos, é definido como

$$\begin{aligned} \text{suc-post}_{\text{prob}}^{\text{RCL}}(\mathcal{L}_{\mathcal{D}}, \{x[\mathcal{Q}_{ID}]\}_{x \in \text{agreg}(\mathcal{L}_{\mathcal{D}})}) &\stackrel{\text{def}}{=} \\ \sum_{x \in \text{agreg}(\mathcal{L}_{\mathcal{D}})} \pi_x^{D_1} \cdot \frac{1}{|\{x' \in \text{agreg}(\mathcal{L}_{\mathcal{D}}) \mid x'[\mathcal{Q}_{ID}] = x[\mathcal{Q}_{ID}]\}|} &= \frac{|\text{agreg}(\mathcal{L}_{\mathcal{D}})/\sim_{\mathcal{Q}_{ID}}|}{|\text{agreg}(\mathcal{L}_{\mathcal{D}})|}. \end{aligned} \quad (\text{A.37})$$

- **Quantificação da degradação probabilística de privacidade em um ataque RCL.** A degradação probabilística de privacidade em um ataque RCL é definida como a razão pela qual a realização do ataque aumenta o sucesso probabilístico do adversário. Formalmente,

$$\begin{aligned} \text{degrad-priv}_{\text{prob}}^{\text{RCL}}(\text{agreg}(\mathcal{L}_{\mathcal{D}}), \{x[\mathcal{Q}_{ID}]\}_{x \in \text{agreg}(\mathcal{L}_{\mathcal{D}})}) &\stackrel{\text{def}}{=} \\ \frac{\text{suc-post}_{\text{prob}}^{\text{RCL}}(\text{agreg}(\mathcal{L}_{\mathcal{D}}), \{x[\mathcal{Q}_{ID}]\}_{x \in \text{agreg}(\mathcal{L}_{\mathcal{D}})})}{\text{suc-prior}_{\text{prob}}^{\text{RCL}}(\text{agreg}(\mathcal{L}_{\mathcal{D}}))}. \end{aligned} \quad (\text{A.38})$$

◁

Definição 30 (Ataque de inferência de atributo individual longitudinal (AIL)). Em um *ataque de inferência de atributo individual longitudinal (AIL)*, o adversário tem acesso a uma coleção longitudinal de bases de dados e conhece os valores de um conjunto de quaseidentificadores de um indivíduo específico na base focal pré-determinado como alvo. O adversário tem como objetivo inferir os valores de um atributo considerado como sensível para o indivíduo-alvo na base focal, independentemente de se esse indivíduo tenha sido reidentificado com sucesso ou não. Neste tipo de ataque, o adversário pode usar as bases auxiliares do conjunto longitudinal como informação auxiliar para aumentar suas chances de sucesso. A especificação deste tipo ataque é análoga à de um ataque *AIU* (Definição 26), com a única diferença de que, de acordo com as premissas **PL6**, **PL6a** e **PL6b** sobre ataques longitudinais, o sucesso a priori do adversário é tomado em relação à base focal, enquanto seu sucesso a posteriori é tomado em relação à agregação da informação presente em todas as bases do conjunto longitudinal.

- **Conhecimento do adversário em um ataque AIL.** Em um ataque AIL, assume-se que o adversário:
 - (i) tem completo acesso a uma coleção longitudinal $\mathcal{L}_{\mathcal{D}} = \{D_1, D_2, \dots, D_k\}$ de bases de dados satisfazendo as premissas **PL0–PL3** sobre ataques longitudinais, sendo capaz de agregar a informação desse conjunto em uma nova base $\text{agreg}(\mathcal{L}_{\mathcal{D}})$ conforme a premissa **PL4**;

- (ii) possui um indivíduo específico $x^* \in D_1$ na base focal pré-determinado como alvo da tentativa de reidentificação;
 - (iii) dado um conjunto $\mathcal{Q}_{ID}$ de quaseidentificadores comuns a todas as bases em $\mathcal{L}_{\mathcal{D}}$, conhece o sub-registro $x^*[\mathcal{Q}_{ID}]$ correspondente aos valores desses quaseidentificadores para o indivíduo-alvo x^* em toda base $D_i \in \mathcal{L}_{\mathcal{D}}$; e
 - (iv) dado um atributo $a_{sens} \in \mathcal{A}_1$ na base focal D_1 considerado como sensível (tal que $a_{sens} \notin \mathcal{Q}_{ID}$), está interessado em determinar o valor $x^*[a_{sens}]$ deste atributo para o indivíduo-alvo x^* na base focal.
- **Quantificação da degradação determinística de privacidade em um ataque AIL.** O adversário é considerado deterministicamente exitoso em um ataque AIL se, e somente se, ele é capaz de estabelecer com absoluta certeza qual o valor do atributo sensível do indivíduo na base focal pré-determinado como alvo.

- **Quantificação do sucesso determinístico a priori do adversário em um ataque AIL.** O sucesso determinístico a priori do adversário em um ataque AIL sobre um conjunto longitudinal $\mathcal{L}_{\mathcal{D}}$ de bases, com respeito ao atributo sensível a_{sens} , é definido como

$$suc-prior_{det}^{AIL}(\mathcal{L}_{\mathcal{D}}, a_{sens}) \stackrel{\text{def}}{=} \begin{cases} \text{verdadeiro,} & \text{se para todo } x, x' \in D_1, \\ & x[a_{sens}] = x'[a_{sens}], \\ \text{falso,} & \text{caso contrário.} \end{cases} \quad (\text{A.39})$$

- **Quantificação do sucesso determinístico a posteriori do adversário em um ataque AIL.** O sucesso determinístico a posteriori do adversário em um ataque AIL sobre um conjunto longitudinal $\mathcal{L}_{\mathcal{D}}$ de bases, com respeito ao atributo sensível a_{sens} , e dado seu conhecimento sobre os valores $x^*[\mathcal{Q}_{ID}]$ dos quaseidentificadores do indivíduo-alvo, é definido como

$$suc-post_{det}^{AIL}(\mathcal{L}_{\mathcal{D}}, a_{sens}, x^*[\mathcal{Q}_{ID}]) \stackrel{\text{def}}{=} \begin{cases} \text{verdadeiro,} & \text{se para todo } x, x' \in \text{agreg}(\mathcal{L}_{\mathcal{D}}) \text{ tais que} \\ & x[\mathcal{Q}_{ID}] = x'[\mathcal{Q}_{ID}] = x^*[\mathcal{Q}_{ID}], \text{ tem-se que} \\ & x[(a_{sens}, 1)] = x'[(a_{sens}, 1)], \\ \text{falso,} & \text{caso contrário.} \end{cases} \quad (\text{A.40})$$

- **Quantificação da degradação determinística de privacidade em um ataque AIL.** A degradação determinística de privacidade em um ataque AIL ocorre se, e somente se, o adversário não for capaz de inferir com absoluta certeza o valor sensível do indivíduo-alvo antes de efetuar o ataque, mas for capaz de fazê-lo após efetuar o ataque. Formalmente,

$$degrad-priv_{det}^{AIL}(\mathcal{L}_{\mathcal{D}}, a_{sens}, x^*[\mathcal{Q}_{ID}]) \stackrel{\text{def}}{=}$$

$$\begin{aligned}
 & (suc-prior_{det}^{AIL}(\mathcal{L}_{\mathcal{D}}, a_{sens}) = \text{falso}) \quad \text{e} \\
 & (suc-post_{det}^{AIL}(\mathcal{L}_{\mathcal{D}}, a_{sens}, x^*[Q_{ID}]) = \text{verdadeiro}) . \quad (A.41)
 \end{aligned}$$

- **Quantificação da degradação probabilística de privacidade em um ataque AIL.** Na medição do sucesso probabilístico de um ataque individual AIL, não se exige que o adversário infira o valor do atributo sensível do indivíduo na base focal pré-determinado como alvo com absoluta certeza; em vez disso quantifica-se a probabilidade de que o adversário corretamente infira tal valor. Quanto maior essa probabilidade, mais exitoso é o adversário.

- **Quantificação do sucesso probabilístico a priori do adversário em um ataque AIL.** Lembrando que a probabilidade de cada valor de atributo sensível na base focal D_1 é dada pela distribuição $\pi^{a_{sens}|D_1}$, derivada de acordo com a Equação 3.2, o sucesso probabilístico a priori do adversário em um ataque AIL sobre um conjunto longitudinal $\mathcal{L}_{\mathcal{D}}$ de bases, com respeito ao atributo sensível a_{sens} , é definido como

$$\begin{aligned}
 suc-prior_{prob}^{AIL}(\mathcal{L}_{\mathcal{D}}, a_{sens}) & \stackrel{\text{def}}{=} \max_{s \in \text{dom}(a_{sens})} \pi_s^{a_{sens}|D_1} \\
 & = \max_{s \in \text{dom}(a_{sens})} \frac{|\{x \in D_1 \mid x[a_{sens}] = s\}|}{|D_1|} . \quad (A.42)
 \end{aligned}$$

- **Quantificação do sucesso probabilístico a posteriori do adversário em um ataque AIL.** O sucesso probabilístico a posteriori do adversário em um ataque AIL sobre um conjunto longitudinal $\mathcal{L}_{\mathcal{D}}$ de bases, com respeito ao atributo sensível a_{sens} , e dado seu conhecimento sobre os valores $x^*[Q_{ID}]$ dos quaseidentificadores do indivíduo-alvo, é definido como

$$\begin{aligned}
 suc-post_{prob}^{AIL}(\mathcal{L}_{\mathcal{D}}, a_{sens}, x^*[Q_{ID}]) & \stackrel{\text{def}}{=} \\
 \max_{s \in \text{dom}(a_{sens})} & \frac{|\{x \in \text{bloco}(x^*[Q_{ID}]) \mid x[(a_{sens}, 1)] = s\}|}{|\text{bloco}(x^*[Q_{ID}])|} , \quad (A.43)
 \end{aligned}$$

onde $\text{bloco}(x^*[Q_{ID}]) = \{x \in \text{agreg}(\mathcal{L}_{\mathcal{D}}) \mid x[Q_{ID}] = x^*[Q_{ID}]\}$ é o bloco de todos os indivíduos na base agregada $\text{agreg}(\mathcal{L}_{\mathcal{D}})$ que compartilham os mesmos valores de quaseidentificadores Q_{ID} com o indivíduo-alvo x^* .

- **Quantificação da degradação probabilística de privacidade em um ataque AIL.** A degradação probabilística de privacidade em um ataque AIL é definida como a razão pela qual a execução do ataque aumenta o sucesso probabilístico do adversário. Formalmente,

$$\text{degrad-priv}_{prob}^{AIL}(\mathcal{L}_{\mathcal{D}}, a_{sens}, x^*[Q_{ID}]) \stackrel{\text{def}}{=} \frac{suc-post_{prob}^{AIL}(\mathcal{L}_{\mathcal{D}}, a_{sens}, x^*[Q_{ID}])}{suc-prior_{prob}^{AIL}(\mathcal{L}_{\mathcal{D}}, a_{sens})} . \quad (A.44)$$

◁

Definição 31 (Ataque de inferência de atributo coletiva longitudinal (ACL)). Em um *ataque de inferência de atributo coletiva longitudinal (ACL)*, o adversário tem acesso completo a um conjunto longitudinal de bases de dados e conhece os valores de um conjunto de quaseidentificadores para todos os indivíduos cujos registros estão nessas bases. O adversário tem como objetivo inferir o valor de um atributo considerado como sensível para o maior número possível de indivíduos presentes na base focal, independentemente de se esses indivíduos tenham sido reidentificados com sucesso ou não. Neste tipo de ataque, o adversário pode usar as bases auxiliares do conjunto longitudinal como informação auxiliar para aumentar suas chances de sucesso. A especificação deste tipo de ataque é análoga à de um ataque *ACU* (Definição 27), com a única diferença de que, de acordo com as premissas **PL6**, **PL6a** e **PL6b** sobre ataques longitudinais, o sucesso a priori do adversário é tomado em relação à base focal, enquanto seu sucesso a posteriori é tomado em relação à agregação da informação presente em todas as bases do conjunto longitudinal.

- **Conhecimento do adversário em um ataque ACL.** Em um ataque RCL, assume-se que o adversário:
 - (i) tem completo acesso a uma coleção longitudinal $\mathcal{L}_{\mathcal{D}} = \{D_1, D_2, \dots, D_k\}$ de bases de dados satisfazendo as premissas **PL0–PL3** sobre ataques longitudinais, sendo capaz de agregar a informação desse conjunto em uma nova base $agreg(\mathcal{L}_{\mathcal{D}})$ conforme a premissa **PL4**;
 - (ii) tem como alvo da tentativa de inferência de atributo todo indivíduo x presente na base focal D_1 , independente de quem x seja; e
 - (iii) dado um conjunto $\mathcal{Q}_{ID}$ de quaseidentificadores comuns a todas as bases em $\mathcal{L}_{\mathcal{D}}$, conhece os sub-registros $\{x[\mathcal{Q}_{ID}]\}_{x \in agreg(\mathcal{L}_{\mathcal{D}})}$ correspondentes aos valores dos quaseidentificadores de todos os indivíduos presentes na agregação $agreg(\mathcal{L}_{\mathcal{D}})$ das bases; e
 - (iv) dado um atributo $a_{sens} \in \mathcal{A}_1$ na base focal D_1 considerado como sensível (tal que $a_{sens} \notin \mathcal{Q}_{ID}$), está interessado em determinar o valor $x[a_{sens}]$ deste atributo para o maior número possível de indivíduos x presentes na base focal.
- **Quantificação da degradação determinística de privacidade em um ataque ACL.** Na medição do sucesso determinístico de um ataque coletivo ACL, leva-se em conta que adversário tem como alvo todos os indivíduos na base focal; portanto, define-se tal sucesso como a fração dos indivíduos nessa base cujo valor do atributo sensível pode ser inferido com absoluta certeza.
 - **Quantificação do sucesso determinístico a priori do adversário em um ataque ACL.** O sucesso determinístico a priori do adversário em um

ataque ACL sobre um conjunto longitudinal $\mathcal{L}_{\mathcal{D}}$ de bases, com respeito ao atributo sensível a_{sens} , é definido como

$$suc-prior_{det}^{ACL}(\mathcal{L}_{\mathcal{D}}, a_{sens}) \stackrel{\text{def}}{=} \begin{cases} 1, & \text{se para todo } x, x' \in D_1, \\ & x[a_{sens}] = x'[a_{sens}], \\ 0, & \text{caso contrário.} \end{cases} \quad (\text{A.45})$$

- **Quantificação do sucesso determinístico a posteriori do adversário em um ataque ACL.** O sucesso determinístico a posteriori do adversário em um ataque ACL sobre um conjunto longitudinal $\mathcal{L}_{\mathcal{D}}$ de bases, com respeito a um atributo sensível a_{sens} , dado seu conhecimento sobre os valores $\{x[\mathcal{Q}_{ID}]\}_{x \in agreg(\mathcal{L}_{\mathcal{D}})}$ dos quaseidentificadores de todos os indivíduos presentes nas bases, é definido como

$$\frac{suc-post_{det}^{ACL}(\mathcal{L}_{\mathcal{D}}, a_{sens}, \{x[\mathcal{Q}_{ID}]\}_{x \in agreg(\mathcal{L}_{\mathcal{D}})}) \stackrel{\text{def}}{=} \sum_{\alpha \in agreg(\mathcal{L}_{\mathcal{D}})/\sim_{\mathcal{Q}_{ID}}} |\alpha| \cdot sens\text{-}\acute{u}nico(\alpha, a_{sens})}{|agreg(\mathcal{L}_{\mathcal{D}})|}, \quad (\text{A.46})$$

onde $agreg(\mathcal{L}_{\mathcal{D}})/\sim_{\mathcal{Q}_{ID}}$ é a partição sobre registos da agregação $agreg(\mathcal{L}_{\mathcal{D}})$ das bases de dados induzida pelos quaseidentificadores $\mathcal{Q}_{ID}$, a variável α varia sobre os blocos desta partição, e a função $sens\text{-}\acute{u}nico(\alpha, a_{sens})$ retorna 1 caso todos os registos no bloco α compartilhem o mesmo valor para o atributo sensível a_{sens} , ou retorna 0 em caso contrário:

$$sens\text{-}\acute{u}nico(\alpha, a_{sens}) \stackrel{\text{def}}{=} \begin{cases} 1, & \text{se para todo } x, x' \in \alpha, \\ & x[(a_{sens}, 1)] = x'[(a_{sens}, 1)], \\ 0, & \text{caso contrário.} \end{cases} \quad (\text{A.47})$$

- **Quantificação da degradação determinística de privacidade em um ataque ACL.** A degradação determinística de privacidade em um ataque ACL é definida como a diferença pela qual a realização do ataque aumenta o sucesso determinístico do adversário. Formalmente,

$$\begin{aligned} degrad-priv_{det}^{ACL}(\mathcal{L}_{\mathcal{D}}, a_{sens}, \{x[\mathcal{Q}_{ID}]\}_{x \in agreg(\mathcal{L}_{\mathcal{D}})}) &\stackrel{\text{def}}{=} \\ suc-post_{det}^{ACL}(\mathcal{L}_{\mathcal{D}}, a_{sens}, \{x[\mathcal{Q}_{ID}]\}_{x \in agreg(\mathcal{L}_{\mathcal{D}})}) - suc-prior_{det}^{ACL}(\mathcal{L}_{\mathcal{D}}, a_{sens}). \end{aligned} \quad (\text{A.48})$$

- **Quantificação da degradação probabilística de privacidade em um ataque ACL.** Na medição do sucesso probabilístico de um ataque coletivo RCL, não se exige que o adversário infira valor do atributo sensível de todos os indivíduos na base focal com absoluta certeza; em vez disso quantifica-se a probabilidade de um indivíduo da base focal aleatoriamente escolhido como alvo ter o valor de seu atributo sensível inferido com sucesso. Quanto maior essa probabilidade, mais exitoso é o adversário, e maior é o risco esperado de cada indivíduo presente na base ter seu atributo sensível inferido.

- **Quantificação do sucesso probabilístico a priori do adversário em um ataque ACL.** Lembrando que a probabilidade de cada valor de atributo sensível na base focal D_1 é dada pela distribuição $\pi^{a_{sens}|D_1}$, derivada de acordo com a Equação 3.2, o sucesso probabilístico a priori do adversário em um ataque ACL sobre um conjunto longitudinal $\mathcal{L}_{\mathcal{D}}$ de bases, com respeito a um atributo sensível a_{sens} , é definido como

$$\begin{aligned} suc-prior_{prob}^{ACL}(\mathcal{L}_{\mathcal{D}}, a_{sens}) &\stackrel{\text{def}}{=} \max_{s \in \text{dom}(a_{sens})} \pi_s^{a_{sens}|D_1} \\ &= \max_{s \in \text{dom}(a_{sens})} \frac{|\{x \in D_1 \mid x[a_{sens}] = s\}|}{|D_1|}. \end{aligned} \quad (\text{A.49})$$

- **Quantificação do sucesso probabilístico a posteriori do adversário em um ataque ACL.** O sucesso probabilístico a posteriori do adversário em um ataque RCL com respeito a um atributo sensível a_{sens} , sobre um conjunto longitudinal $\mathcal{L}_{\mathcal{D}}$ de bases, dado seu conhecimento sobre os valores $\{x[\mathcal{Q}_{ID}]\}_{x \in \text{agreg}(\mathcal{L}_{\mathcal{D}})}$ dos quaseidentificadores de todos os indivíduos, é definido como

$$\begin{aligned} suc-post_{prob}^{ACL}(\mathcal{L}_{\mathcal{D}}, a_{sens}, \{x[\mathcal{Q}_{ID}]\}_{x \in \text{agreg}(\mathcal{L}_{\mathcal{D}})}) &\stackrel{\text{def}}{=} \\ \frac{\sum_{q \in \text{dom}(\mathcal{Q}_{ID}|\mathcal{L}_{\mathcal{D}})} \max_{s \in \text{dom}(a_{sens})} |\{x \in \text{agreg}(\mathcal{L}_{\mathcal{D}}) \mid x[(a_{sens}, 1)] = s, x[\mathcal{Q}_{ID}] = q\}|}{|\text{agreg}(\mathcal{L}_{\mathcal{D}})|}. \end{aligned} \quad (\text{A.50})$$

- **Quantificação da degradação probabilística de privacidade em um ataque ACL.** A degradação probabilística de privacidade em um ataque ACL é definida como a razão pela qual a realização do ataque aumenta o sucesso probabilístico do adversário. Formalmente,

$$\begin{aligned} degrad-priv_{prob}^{ACL}(\mathcal{L}_{\mathcal{D}}, a_{sens}, \{x[\mathcal{Q}_{ID}]\}_{x \in \text{agreg}(\mathcal{L}_{\mathcal{D}})}) &\stackrel{\text{def}}{=} \\ \frac{suc-post_{prob}^{ACL}(\mathcal{L}_{\mathcal{D}}, a_{sens}, \{x[\mathcal{Q}_{ID}]\}_{x \in \text{agreg}(\mathcal{L}_{\mathcal{D}})})}{suc-prior_{prob}^{ACL}(\mathcal{L}_{\mathcal{D}}, a_{sens})}. \end{aligned} \quad (\text{A.51})$$

◁

B A ferramenta ARX

ARX [15] é um software *open source* que tem o objetivo de fornecer métodos e algoritmos para quantificar, avaliar e promover a privacidade em bases de dados. A ferramenta teve sua primeira versão disponível para uso em 2012, e desde então ela tem sido mantida por pesquisadores do Hospital Universitário Charité em Berlim (*Charité - Universitätsmedizin Berlin*), ¹ pela Universidade Técnica de Munique (*TUM - Technische Universität München*), ² e pelo Instituto de Saúde de Berlim (*BIH - Berlin Institute of Health*). ³ O código-fonte do software está disponível no GitHub, ⁴ e mais informações sobre a utilização e *download* estão disponíveis na própria página do projeto. ⁵ Atualmente a ferramenta está na versão 3.8.0.

O ARX disponibiliza suporte para implementação e análise de diferentes métodos de mitigação de danos à privacidade em conjuntos de microdados, incluindo *k*-anonymity e *ℓ*-diversity. A ferramenta é capaz de realizar análises de risco e de utilidade dos dados baseadas em várias métricas, incluindo *risco mínimo* (i.e., dado um conjunto de quase-identificadores, qual a probabilidade mínima de um adversário reidentificar um alvo pré-determinado) e *risco máximo* (i.e., dado um conjunto de quase-identificadores, qual a probabilidade máxima de um adversário reidentificar um alvo pré-determinado), mas estas não foram abordadas neste documento.

Por outro lado, o ARX não suporta várias análises realizadas no presente documento, incluindo a quantificação de risco de inferência de atributo em uma única base de dados, além de riscos em conjuntos longitudinais de dados.

Entretanto, a ferramenta ARX suporta análises de ataques de reidentificação coletiva em uma única base de dados (RCU, Seção 3.3). Por isso, utilizamos a ferramenta para validar independentemente algumas de nossas análises de riscos neste tipo de ataque. Para tanto, selecionamos as bases de 2014 até 2019 do Censo da Educação Básica e as bases de 2014 até 2018 do Censo da Educação Superior. Os conjuntos de candidatos a quase-identificadores foram os seguintes:

¹<https://www.charite.de/>

²<https://www.tum.de/>

³<https://www.bihealth.org/>

⁴<https://github.com/arx-deidentifier/arx>

⁵<https://arx.deidentifier.org>

- **Ensino Básico (2014 até 2018):** {NU_DIA_NASCIMENTO, NU_MES, NU_ANO, TP_SEXO, TP_COR_RACA, TP_NACIONALIDADE, CO_PAIS_ORIGEM, CO_MUNICIPIO_NASC, CO_MUNICIPIO_END, CO_ENTIDADE, TP_DEPENDENCIA}.
- **Ensino Básico (2019):** {NU_MES, NU_ANO, TP_SEXO, TP_COR_RACA, TP_NACIONALIDADE, CO_PAIS_ORIGEM, CO_MUNICIPIO_NASC, CO_MUNICIPIO_END, CO_ENTIDADE, TP_DEPENDENCIA}.
- **Ensino Superior (2014 até 2018):** {NU_DIA_NASCIMENTO, NU_MES_NASCIMENTO, NU_ANO_NASCIMENTO, TP_SEXO, TP_COR_RACA, TP_NACIONALIDADE, CO_PAIS_ORIGEM, CO_MUNICIPIO_NASCIMENTO, CO_IES, CO_CURSO, TP_ESCOLA_CONCLUSAO_ENS_MEDIO}.

A Tabela B.1 resume as vulnerabilidades encontradas nas bases de dados do Inep. Podemos observar que existem indivíduos unicamente reidentificáveis (com base nos atributos selecionados) em todas as bases. Em particular, cerca de 97% dos registros das três bases da Educação Superior são reidentificáveis. Sendo assim, um adversário que conhece os valores dos atributos selecionados, consegue identificar exatamente qual linha da base de dados corresponde ao alvo, e então obter informações dos atributos sensíveis.

Base	Sucesso determinístico a posteriori	Sucesso probabilístico a posteriori
Ensino Superior - 2014	97.66%	98.75%
Ensino Superior - 2015	97.55%	98.67%
Ensino Superior - 2016	97.29%	98.52%
Ensino Superior - 2017	97.26%	98.49%
Ensino Superior - 2018	97.22%	98.45%
Ensino Básico - 2014	96.13%	98.03%
Ensino Básico - 2015	96.48%	98.21%
Ensino Básico - 2016	96.38%	98.16%
Ensino Básico - 2017	96.32%	98.12%
Ensino Básico - 2018	96.34%	98.14%
Ensino Básico - 2019	60.90%	75.51%

Tabela B.1: Sucesso a posteriori do adversário em ataques de reidentificação coletiva em uma única base de dados (RCU) usando a ferramenta ARX.

Lista de Siglas

ACL Ataque de inferência de atributo coletiva longitudinal.

ACU Ataque de inferência de atributo coletiva em uma única base de dados.

AIL Ataque de inferência de atributo individual longitudinal.

AIU Ataque de inferência de atributo individual em uma única base de dados.

DCC Departamento de Ciência da Computação da UFMG.

DEED Diretoria de Estatísticas Educacionais do Inep.

ENADE Exame Nacional de Desempenho dos Estudantes.

ENEM Exame Nacional do Ensino Médio.

GDPR *General Data Protection Regulation*.

IES Instituição de Ensino Superior.

INEP Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira.

LAI Lei de Acesso à Informação.

LGPD Lei Geral de Proteção de Dados Pessoais.

LGPDP Lei Geral de Proteção de Dados Pessoais.

MEC Ministério da Educação.

RCL Ataque de reidentificação coletiva longitudinal.

RCU Ataque de reidentificação coletiva em uma única base de dados.

RGPD Regulamento Geral de Proteção de Dados.

RIL Ataque de reidentificação individual longitudinal.

RIU Ataque de reidentificação individual em uma única base de dados.

SAEB Sistema de Avaliação da Educação Básica.

TED Termo de Execução Descentralizada.

UFMG Universidade Federal de Minas Gerais.

Glossário

adversário Entidade contra quem se deseja proteger a informação sensível sobre indivíduos. O adversário pode ser uma pessoa física ou uma organização. Não necessariamente se atribuem intenções deletérias ao adversário: é possível que um consumidor legítimo de uma divulgação estatística (e.g., um pesquisador acadêmico) atue inadvertidamente como adversário ao inferir informação sensível de indivíduos no decurso de ações idôneas.

anonimização Utilização de meios técnicos razoáveis e disponíveis no momento do tratamento, por meio dos quais um dado perde a possibilidade de associação, direta ou indireta, a um indivíduo. Técnicas de anonimização incluem, mas não se limitam a, *desidentificação*, *k-anonymity*, *l-diversity* e *privacidade diferencial*, dentre outras. Diferentes técnicas têm diferentes graus de sucesso, e algumas são comprovadamente menos eficazes que outras.

ataque Ação ou conjunto de ações pelas quais o adversário pode obter informação sensível sobre titulares de dados. Ao termo “ataque” não se atribui uma intenção necessariamente deletéria: uma utilização legítima dos dados (e.g., para pesquisa científica) pode resultar inadvertidamente em um ataque se porventura revelar informação sensível.

ataque composicional Ataque que se utiliza do cruzamento de informações divulgadas por mais de uma fonte, ou por divulgações diferentes de uma mesma fonte (e.g., cruzamento de dados de um censo médico com registros públicos de eleitores).

ataque de inferência de atributo Ataque em que o objetivo do adversário é inferir o valor assumido por um atributo considerado como sensível para um conjunto de indivíduos, independentemente de se estes indivíduos tenham sido reidentificados com sucesso ou não.

ataque de reidentificação Ataque em que o objetivo do adversário é determinar uma correspondência entre registros presentes na base de dados e os titulares desses registros, i.e., os indivíduos do mundo real a quem os registros se refere.

ataque longitudinal Ataque que se utiliza de informações divulgadas ao longo do tempo (e.g., várias liberações de informação referentes a uma mesma pesquisa,

ou pesquisas em anos consecutivos que se referem aos mesmos titulares).

banco de dados O mesmo que *base de dados*.

base de dados Conjunto estruturado de dados pessoais, estabelecido em um ou em vários locais, em suporte eletrônico ou físico.

Censo da Educação Básica Principal pesquisa estatística educacional do país, abrangendo a Educação Básica e Profissional.

Censo da Educação Superior Mais completa pesquisa estatística sobre as Instituições de Educação Superior do país.

conhecimento a posteriori do adversário Conhecimento a respeito da informação sensível que o adversário adquire ao revisar seu conhecimento a priori de acordo com o resultado da execução de um ataque.

conhecimento a priori do adversário Conhecimento a respeito da informação sensível que o adversário possui antes mesmo de executar um ataque.

consulta Uma recuperação de dados ou informações a partir de uma base de dados, normalmente efetuada em linguagem específica.

dado agregado Dado sumarizado correspondendo a uma agregação das informações dos microdados para unidades mais amplas, ou mesmo a uma função computada sobre essas informações (e.g., frequência, média ou outros tipos de análises).

dado anonimizado Dado relativo a titular que não possa ser identificado, considerando a utilização de meios técnicos razoáveis e disponíveis na ocasião de seu tratamento.

dado pessoal Informação relacionada a pessoa natural identificada ou identificável.

dado pessoal sensível Dado pessoal sobre o qual a preocupação quanto à privacidade (e.g., sobre origem racial ou étnica, convicção religiosa, opinião política, filiação a sindicato ou a organização de caráter religioso, filosófico ou político, dado referente à saúde ou à vida sexual, dado genético ou biométrico), quando vinculado a uma pessoa natural.

degradação de privacidade Comparação entre o *sucesso a posteriori* do adversário –i.e., depois de executar o ataque– e o *sucesso a priori* do adversário –i.e., antes de executar o ataque–em seu intuito de inferir informação sensível. Intuitivamente, quanto maior a degradação de privacidade de um ataque, maior o incremento no sucesso esperado do adversário em obter informação sensível.

desanonimização O mesmo que *reidentificação*.

desidentificação Técnica de tratamento de dados pela qual são removidos possíveis identificadores individuais óbvios dos registros (e.g., nome, CPF, RG, ou endereços em níveis mais detalhados que as cidades), na expectativa de dificultar-se uma eventual reidentificação do titular.

Exame Nacional de Desempenho dos Estudantes (ENADE) Avaliação do rendimento dos concluintes dos Cursos de Graduação tanto em relação aos conteúdos programáticos previstos nas diretrizes curriculares dos cursos, quanto no que diz respeito às habilidades desenvolvidas e à atualização do aluno em relação ao Brasil e ao mundo.

Exame Nacional do Ensino Médio (ENEM) Avaliação do desempenho escolar ao final da Educação Básica.

General Data Protection Regulation (GDPR) Regulamento do direito europeu de 2018 que trata da privacidade e proteção de dados pessoais, aplicável a todos os indivíduos na União Europeia e do Espaço Econômico Europeu.

inferência de atributo Prática de combinar dados anonimizados com informações publicamente disponíveis ou dados auxiliares, a fim de descobrir o valor de algum atributo sensível de um indivíduo.

informação auxiliar Em relação a uma divulgação de dados de interesse, informação auxiliar é qualquer informação que se possa obter a respeito de um indivíduo através de outros canais que não sejam a divulgação de dados de interesse em si mesma (e.g, via *web*, outros registros públicos, jornais ou revistas, conhecimento prévio).

informação lateral O mesmo que *informação auxiliar*.

informação sensível Informação considerada como digna de proteção. Exemplos típicos incluem a situação médica, a renda, ou vida pessoal de um indivíduo.

Inscript *Laboratory of Information Security, Cryptography, Privacy, and Transparency*, laboratório de pesquisa do DCC/UFMG focado em segurança da informação, criptografia, privacidade e transparência.

Lei de Acesso à Informação (LAI) Lei brasileira 12.527/2011, que trata dos procedimentos a serem observados pelo Estado para garantir o acesso a informações previsto na Constituição Federal do Brasil de 1988.

Lei Geral de Proteção de Dados Pessoais (LGPD ou LGPDP) Lei brasileira 13.709/2018, que dispõe sobre o tratamento de dados pessoais, inclusive nos meios digitais, por pessoa natural ou por pessoa jurídica de direito público ou privado, com o objetivo de proteger os direitos fundamentais de liberdade e de privacidade e o livre desenvolvimento da personalidade da pessoa natural.

métrica determinística de sucesso do adversário Função que mensura o sucesso do adversário e forma absoluta, retornando um valor qualitativo dependendo de se a informação desejada foi ou não recuperada com absoluta certeza.

métrica probabilística de sucesso do adversário Função que mensura o sucesso do adversário de forma probabilística, retornando um valor quantitativo representando o grau de certeza com o qual a informação desejada foi recuperada.

microdado A menor fração de um dado e pode estar relacionado a uma pesquisa ou avaliação; o dado em sua menor forma de agregação. Microdados geralmente carregam informação sobre entidades em nível individual (e.g., pessoas, escolas, institutos).

mitigação, técnica ou método de O mesmo que *tratamento de dados*.

pseudonimização Técnica de tratamento de dados pela qual atribui-se um código individual artificialmente criado a cada registro de uma base de dados, acompanhada da transferência de identificadores diretos (como nome, CPF e RG) para outra base de dados. Dessa forma, o controlador é capaz de mapear identificadores diretos em uma base de dados a registros específicos na outra base através do uso dos códigos individuais, ao mesmo tempo em que se dificultam tentativas de reidentificação do titular por parte de agentes externos.

quaseidentificador Informações que não são, em si mesmas, identificadores únicos, mas que estão suficientemente correlacionadas com uma entidade a ponto de poderem ser combinadas com outros quaseidentificadores para criar um identificador exclusivo.

query O mesmo que *consulta*.

registro Informação em uma base de dados correspondente a um indivíduo específico.

Regulamento Geral de Proteção de Dados (RGPD) O mesmo que *General Data Protection Regulation*.

reidentificação Prática de combinar dados anonimizados com informações publicamente disponíveis ou dados auxiliares, a fim de descobrir o indivíduo ao qual os dados pertencem.

Sistema de Avaliação da Educação Básica (SAEB) Conjunto de testes e questionários aplicados na rede pública e em uma amostra da rede privada que auxilia no diagnóstico da Educação Básica e de possíveis fatores que interfiram no desempenho do estudante.

sucesso a posteriori do adversário Medida (determinística ou probabilística) do quanto de informação sensível o adversário possui após a execução do ataque, usando a informação a posteriori adquirida.

sucesso a priori do adversário Medida (determinística ou probabilística) do quanto de informação sensível o adversário já possui antes mesmo de executar um ataque, usando apenas seu conhecimento a priori.

titular Pessoa natural a quem se referem os dados pessoais que são objeto de tratamento.

tratamento (de dados) Toda operação realizada com dados pessoais, como as que se referem a coleta, produção, recepção, classificação, utilização, acesso, reprodução, transmissão, distribuição, processamento, arquivamento, armazenamento, eliminação, avaliação ou controle da informação, modificação, comunicação, transferência, difusão ou extração.

TED 8750 - PRICE

PRIVACIDADE NOS CENSOS EDUCACIONAIS

Termo de Execução Descentralizada entre o Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira - Inep e a Universidade Federal de Minas Gerais - UFMG

PRODUTO 03

Relatório técnico sobre métodos de tratamento aplicáveis aos microdados de divulgação dos Censos Educacionais do Inep



Mário S. ALVIM

Ramon G. GONZE

Jeroen van de GRAAF

Igor W. LEMES

Lucas LOPES

25 de setembro de 2020

Resumo

Para fins de proteção de privacidade, a atual forma de divulgação dos microdados dos Censos Educacionais pelo Inep utiliza apenas as técnicas de **desidentificação**, em que se removem possíveis identificadores individuais óbvios dos registros (como nome, CPF, RG) e de **pseudonimização**, em que tais identificadores individuais óbvios são substituídos por um código único de identificação artificialmente criado. As análises quantitativas experimentais realizadas no Produto 02 do presente TED 8750 demonstraram de forma inequívoca que esta abordagem submete os titulares dos dados a sérios e generalizados riscos de violação de privacidade, em especial aos de **reidentificação** e de **inferência de atributos sensíveis**. Em nossa visão tal situação poderia constituir em uma violação da Lei Geral de Proteção de Dados Pessoais (LGPD).

No presente documento apresentamos os principais métodos de mitigação de degradação de privacidade em princípio aplicáveis aos Censos Educacionais do Inep. Os pontos abaixo sumarizam as principais conclusões da nossa análise.

1. **Métodos não perturbativos** alteram a informação provida apenas por diminuir sua granularidade ou por suprimi-la por partes, mas sem introduzir informação ruidosa. Consideramos métodos não perturbativos tanto para a **divulgação de microdados**, a saber, os **métodos sintáticos** de **anonimidade- k** , **diversidade- ℓ** , **proximidade- t** , além da **divulgação de microdados por amostragem**, quanto para a **divulgação de dados agregados ou tabulares**, a saber, **sumários estatísticos** e **histogramas**. Tais métodos são facilmente implementáveis e mantidos, além de serem simples de compreender e explicar tanto para titulares quanto para analistas de dados.

Entretanto, as garantias de privacidade providas por estes métodos são seriamente limitadas, e grande parte da comunidade acadêmica já não mais os considera como alternativas satisfatórias se usadas isoladamente. Em primeiro lugar, os métodos sintáticos não apresentam a propriedade de **composicionalidade**, o que significa que o Inep não pode aplicá-los independentemente a cada uma de suas divulgações e ainda assim garantir a privacidade dos indivíduos contra ataques longitudinais. Em segundo lugar, a divulgação de microdados por amostragem, apesar de garantir privacidade para um grande número de indivíduos, não oferece **proteção individual a cada titular na base**. Com efeito, um indivíduo afetado por um ataque

contra dados amostrais pode encontrar pouco consolo no fato de que ele seja um raro desafortunado dentre um conjunto de milhares ou milhões de usuários, desde que o ataque tenha consequências catastróficas (e.g., permitir a um criminoso reidentificar em uma base de dados um participante de um programa de proteção a testemunhas). Adicionalmente, entendemos que LGPD exige **garantias em nível individual** para cada titular, especialmente contra reidentificação.

2. A **privacidade diferencial** e suas variantes são **métodos perturbativos**, que introduzem ruído de forma controlada em cada divulgação a fim de ofuscar informações individuais, ao mesmo tempo em que tenta preservar informações estatísticas. A privacidade diferencial é considerada o estado da arte em métodos de **controle de divulgação estatística**.

No caso dos Censos Educacionais do Inep, identificamos duas opções como as mais viáveis:

- (a) **Privacidade diferencial global aplicada sobre dados agregados.** Neste caso o Inep computaria histogramas ou sumários estatísticos predeterminados a partir das bases dos Censos Educacionais, e então os sanitizaria com ruído controlado antes de publicá-los.
- (b) **Privacidade diferencial local aplicada a microdados.** Neste caso o Inep adicionaria ruído a cada registro das Bases dos Censos Educacionais, obtendo assim uma base que pode ser considerada sanitizada de uma vez por todas e que pode, então, ser publicada livremente.

De forma geral, a variante global da privacidade diferencial seria mais facilmente implementada e gerida pelo Inep, mas eliminaria a granularidade dos dados para muitos analistas e poderia aumentar significativamente a demanda por acesso a **salas seguras** (i.e., ambientes controlados em que há acesso restrito a microdados). Já a variante local proveria microdados abertamente aos analistas, porém tem o potencial de diminuir a qualidade da informação prestada. Em ambos os casos, a privacidade diferencial demanda um expertise preciso para análise das bases, desenho da solução, estimação do ruído necessário, e ajuste de parâmetros a fim de encontrar um compromisso adequado entre privacidade e utilidade.

A opção por qualquer método de mitigação deve passar pela harmonização de interesses possivelmente conflitantes de vários atores. No caso dos Censos Educacionais do Inep, os atores incluem os **titulares de dados** (estudantes, professores, escolas, etc.), **analistas** (demógrafos, entidades civis e governamentais, etc.), o **governo** (que regulamenta tanto questões de privacidade quanto de transparência e acesso à informação), além do próprio **Inep** (que tem que conciliar de forma realista as demandas dos vários atores com a sua capacidade e recursos para atendê-las).

Além disso, o Inep dispõe de um **prazo exíguo** para implementação de uma solução que atenda às demandas da LGPD. Dada esta restrição de tempo, o Inep deve considerar adotar uma **solução emergencial de curto prazo** que garanta a privacidade dos

titulares –mesmo que seja possivelmente sub-ótima em relação à utilidade provida aos analistas (ou vice-versa)–, enquanto elabora-se uma **alternativa de longo prazo** que forneça um melhor **custo-benefício na relação de privacidade e utilidade**.

Levando em conta as observações acima, propomos então um plano de ação para o Inep dividido em etapas:

- **Etapas 1:** Eliminar imediatamente a divulgação de microdados em qualquer forma, a fim de garantir a privacidade em nível individual exigida pela LGPD. Esta medida inclui a remoção de todas as bases dos Censos Educacionais já publicadas pelo Inep de seus canais de comunicação.
- **Etapas 2:** Oferecer apenas informações agregadas (sumários estatísticos ou histogramas) em seus canais públicos de comunicação, protegidos com privacidade diferencial. Esta etapa inclui a identificação preliminar dos casos de uso mais comuns dos dados dos Censos Educacionais por analistas, o desenho das configurações de sumários e histogramas a serem publicados, a implementação dos algoritmos para sua produção, e a otimização de parâmetros.
- **Etapas 3:** Possibilitar a analistas o acesso a microdados apenas com autorização prévia e em salas seguras, considerando a viabilidade de salas seguras virtuais.

Reconhecidamente, a solução acima está contingenciada pela significativa restrição de tempo para execução do presente TED 8750. Além disso, ela tem o efeito colateral de aumentar a demanda por acesso a salas seguras. Para contornar este problema, sugerimos ao Inep considerar, futuramente, a seguinte continuação do plano.

- **Etapas 4:** Uma vez assegurado nível de privacidade individual dos dados demandado pela LGPD (obtido pela combinação das Etapas 1 e 2), proceder a um estudo aprofundado de como aumentar a utilidade das divulgações enquanto se mantém a privacidade conquistada. O **aumento gradual da utilidade dos dados visa a satisfazer a um número cada vez maior de analistas**, o que pode contribuir para arrefecer a demanda suplementar por acesso a salas seguras eventualmente causada pela implementação das Etapas 1 e 2 acima.

Nesta etapa deve-se aprofundar o estudo dos usos mais comuns dos dados dos Censos Educacionais a fim de encontrar a métrica de utilidade a ser otimizada. Então deve-se considerar o uso de **privacidade diferencial local** para produção de microdados sanitizados, incluindo suas variantes mais refinadas como a **privacidade diferencial**-(ϵ, δ), que permite violações de privacidade raras em troca de uma maior utilidade dos dados e a **privacidade-d**, que explora a noção de indistinguidibilidade entre segredos para aumentar a utilidade de divulgações.

Acreditamos que as recomendações acima devem ser discutidas profundamente entre a equipe executora do presente TED 8750 e os representantes do Inep, a fim de que sejam apropriadamente esclarecidas antes de qualquer tomada de decisão.

Sumário

1	Introdução	1
1.1	Objetivo deste documento	1
1.2	Contextualização	2
1.3	Organização deste documento	5
2	Fundamentação teórica	6
2.1	Privacidade	6
2.2	Métodos de mitigação de degradação à privacidade	13
2.3	Utilidade	15
3	Parecer sobre o emprego de métodos de mitigação de degradação de privacidade à divulgação dos Censos Educacionais	16
3.1	Desafios para implementação de métodos de mitigação de degradação à privacidade nos Censos Educacionais do Inep	17
3.1.1	Políticas e governança de dados	17
3.1.2	Compromisso entre privacidade e utilidade	21
3.1.3	Ataques longitudinais	28
3.2	Sumário comparativo dos métodos apresentados neste documento	29
3.3	Recomendações e plano de ação proposto	30
4	Especificação de métodos não perturbativos para divulgação de micro-dados	36
4.1	Métodos sintáticos	36
4.1.1	Anonimidade- k	37
4.1.2	Diversidade- ℓ	38

4.1.3	Proximidade- t	40
4.1.4	Algoritmos	41
4.1.5	Análise de prós e contras	41
4.2	Divulgação de microdados por amostragem	43
4.2.1	Análise de prós e contras	44
5	Especificação de métodos não perturbativos para divulgação de dados agregados ou tabulares	49
5.1	Divulgação de sumários estatísticos	49
5.2	Divulgação de histogramas	50
5.3	Análise de prós e contras	51
6	Especificação de métodos baseados em privacidade diferencial	53
6.1	Fundamentação de privacidade diferencial	54
6.1.1	Motivação para privacidade diferencial	55
6.1.2	O Desiderato de Dalenius e a busca por uma “definição razoável de privacidade”	57
6.1.3	A filosofia fundamental da privacidade diferencial	58
6.2	Privacidade diferencial global	60
6.2.1	Definição formal de privacidade diferencial- ϵ	61
6.2.2	A garantia provida por privacidade diferencial- ϵ	62
6.2.3	Mecanismos para se atingir privacidade diferencial- ϵ	64
6.2.3.1	Mecanismo de Laplace	65
6.2.3.2	Mecanismo geométrico	68
6.2.3.3	Mecanismo exponencial	69
6.2.4	Propriedades da privacidade diferencial- ϵ	70
6.3	Privacidade diferencial local	71
6.3.1	A filosofia da privacidade diferencial local	72
6.3.2	Definição formal de privacidade diferencial local- ϵ	73
6.3.3	Mecanismos para se atingir privacidade diferencial local- ϵ	74
6.3.4	Propriedades e garantias da privacidade diferencial local- ϵ	74
6.4	Outras aplicações de privacidade diferencial	76

6.4.1	Divulgação de microdados por amostragem	76
6.4.2	Divulgação de histogramas e dados sintéticos	77
6.4.3	A abordagem adotada no Censo Decenal de 2020 dos EUA	78
6.4.3.1	Desafios encontrados na implementação da privacidade diferencial	79
6.5	Análise de prós e contras	81
Referências Bibliográficas		89
Anexos		99
A	Resultados formais importantes sobre o compromisso entre privacidade e utilidade em divulgações estatísticas	100
A.1	Uma boa definição de privacidade esconde qualquer evidência de participação	100
A.2	Condições para a existência de mecanismos ótimos universais	105
A.2.1	Modelos de analistas racionais	105
A.2.2	Tipos de consultas	106
A.2.3	Existência de mecanismos ótimos universais	106
A.3	Relação entre quantidade de informação divulgada e o ruído adicionado .	108
B	Definição matemática de métricas de utilidade populares	112
C	Implementação dos algoritmos de anonimidade-k, diversidade-ℓ e proximidade-t provida pela ferramenta ARX	116
D	Variantes refinadas da privacidade diferencial que podem garantir maior utilidade das divulgações	119
D.1	Privacidade diferencial- (ϵ, δ)	119
D.2	Privacidade- d	120
E	Visão geral dos algoritmos para produção de histogramas e dados sintéticos respeitando privacidade diferencial	123
F	Aplicação de privacidade diferencial no Censo dos EUA em 2020	126
F.1	Métodos de coleta e divulgação dos dados	126
F.2	Algoritmos usados na nova abordagem	127
F.3	Análise experimental da nova abordagem	130

G O desafio de mitigação de ataques longitudinais	132
H Exemplos da aplicação de vários métodos de mitigação a uma mesma base de exemplo	134
H.1 Exemplos de aplicação de métodos não perturbativos para divulgação de microdados	136
H.2 Exemplos de aplicação de métodos não perturbativos para divulgação de dados agregados ou tabulares	143
H.3 Exemplos de aplicação de métodos baseados em privacidade diferencial . .	146
Lista de Siglas	161
Glossário	162

Lista de Tabelas

3.2.1	Sumário dos métodos não perturbativos para divulgação de microdados. .	33
3.2.2	Sumário dos métodos não perturbativos para divulgação de dados agregados ou tabulares.	34
3.2.3	Sumário dos métodos baseados em privacidade diferencial.	35
4.1.1	Exemplos 2 e 3: Aplicação de anonimidade- k e diversidade- ℓ a uma base de dados.	46
4.1.2	Exemplo 4: Diferentes generalizações que resultam em uma base de dados 2-anônima.	47
4.1.3	Exemplo 5: Diferentes possibilidades de bases 2-diversas	48
5.2.1	Exemplo 7: Histogramas que contém diferentes distribuições de valores referentes às bases de dados da Tabela 5.2.1a.	52
6.2.3	Exemplo de bases de dados adjacentes.	84
6.3.6	Exemplo 22: Resultado de uma pesquisa sobre uso de drogas ilícitas usando a técnica de reposta aleatorizada.	86
6.3.8	Exemplo 22: Probabilidade condicional de cada resposta dado se o indivíduo é mesmo usuário de drogas ou não, em função do viés b da primeira moeda.	86
6.4.10	Exemplo 26: Adição de ruído em um histograma.	87
A.1	Exemplo 27: Bases de dados sobre condições médicas nos anos de 2019 e 2020.	101
A.6	Sumário dos resultados sobre existência mecanismos ótimos universais de [58, 62, 24].	108
A.7	Exemplo 29: Tabela contendo divulgação não perturbativa (i.e., sem ruído) de estatísticas agregadas.	110

A.8	Exemplo 29: Base de dados reconstruída a partir de estatísticas agregadas.	111
B.1	Métricas de utilidade populares que avaliam a qualidade da informação em uma base de dados tratada por um método de mitigação de degradação à privacidade.	115
D.1	Exemplo de métrica de distância entre bases usada na privacidade- d	121
H.1	Exemplos 39 a 45: Base de dados original à qual diversos métodos de mitigação de degradação de privacidade serão aplicados.	135
H.3	Exemplo 39: Resultados retornados pela ferramenta ARX após aplicação de anonimidade- k com $k = 2$ e $k = 5$ à base da Tabela H.1.	139
H.4	Exemplo 39: Resultados retornados pela ferramenta ARX após aplicação de diversidade- ℓ com $\ell = 2$ e $\ell = 3$ à base da Tabela H.1.	140
H.5	Exemplo 39: Resultados retornados pela ferramenta ARX após aplicação de proximidade- t com $t = 0.1$, $t = 0.5$ e $t = 1$ à base da Tabela H.1. . . .	141
H.6	Exemplo 40: Resultados de diferentes amostragens de 25% da base de dados representada na Tabela H.1.	142
H.7	Exemplo 41: Divulgação não perturbativa de sumários estatísticos para a base da Tabela H.1.	143
H.8	Exemplo 42: Divulgação não perturbativa de histogramas para a base da Tabela H.1.	145
H.9	Exemplo 43: Divulgação de sumários estatísticos usando privacidade diferencial global, referentes à base da Tabela H.1.	148
H.10	Exemplo 44: Divulgação de histogramas marginais usando privacidade diferencial global, referentes à base da Tabela H.1.	150
H.11	Exemplo 44: Divulgação de histograma conjunto dos atributos <i>sexo</i> e <i>idade</i> usando privacidade diferencial global, referentes à base da Tabela H.1.	151
H.12	Exemplo 44: Divulgação de histograma conjunto dos atributos <i>sexo</i> e <i>deficiência</i> usando privacidade diferencial global, referentes à base da Tabela H.1.	152
H.13	Exemplo 44: Divulgação de histograma conjunto dos atributos <i>deficiência</i> e <i>idade</i> usando privacidade diferencial global, referentes à base da Tabela H.1.	153
H.14	Exemplo 45: Bases sanitizadas resultantes da aplicação de privacidade diferencial local à base da Tabela H.1.	155
H.15	Exemplo 45: Computação de sumários estatísticos sobre as bases sanitizadas usando privacidade diferencial local, referentes à base da Tabela H.1.	156

H.16	Exemplo 45: Computação de histogramas marginais sobre as bases sanitizadas usando privacidade diferencial local, referentes à base da Tabela H.1.	157
H.17	Exemplo 45: Computação do histograma conjunto dos atributos <i>sexo</i> e <i>idade</i> sobre as bases sanitizadas usando privacidade diferencial local, referentes à base da Tabela H.1.	158
H.18	Exemplo 45: Computação do histograma conjunto dos atributos <i>sexo</i> e <i>deficiência</i> sobre as bases sanitizadas usando privacidade diferencial local, referentes à base da Tabela H.1.	159
H.19	Exemplo 45: Computação do histograma conjunto dos atributos <i>deficiência</i> e <i>idade</i> sobre as bases sanitizadas usando privacidade diferencial local, referentes à base da Tabela H.1.	160

Lista de Definições

8	O Desiderato de Dalenius (<i>Dalenius' Desideratum</i>)	57
9	Bases de dados adjacentes	61
10	Privacidade diferencial- ε	62
12	Sensibilidade ℓ_1 de uma consulta	66
14	Mecanismo de Laplace	67
16	Mecanismo Geométrico	68
17	Sensibilidade de uma função de utilidade	69
18	Mecanismo exponencial	69
23	Privacidade diferencial- ε (local)	74
30	Erro quadrático	112
31	Erro quadrático por registro	112
32	Discernibilidade	113
33	Benefício do divulgador	113
34	Informação mútua ou ganho de informação	114
35	Média da distância da variação total ou Perda L1	114
36	Divergência de Kullback-Leiber	114
37	Privacidade diferencial- (ε, δ)	120
38	Privacidade- d	121

Lista de Resultados

19	Teorema (Composicionalidade sequencial de privacidade diferencial [47])	. .	70
20	Teorema (Composicionalidade paralela de privacidade diferencial [47])	. .	70
21	Teorema (Privacidade diferencial resiste a pós-processamento [45])		71

Lista de Exemplos

1	Utilidade pode variar de acordo com o analista de dados	24
2	Aplicação de anonimidade- k	37
3	Aplicação de diversidade- ℓ	39
4	Utilidade em métodos sintáticos	41
5	Não composicionalidade de métodos sintáticos	42
6	Divulgação de microdados por amostragem não garante privacidade em nível individual	44
7	Divulgação não perturbativa de histogramas	50
11	A garantia de privacidade diferencial global	63
13	Sensibilidade de consultas	66
15	Adição de ruído de Laplace	67
22	Resposta aleatorizada aplicada a uma pesquisa sobre uso de drogas ilícitas	72
24	O compromisso entre privacidade vs. utilidade em privacidade diferencial local	74
25	Negação plausível em histogramas não perturbativos	77
26	Negação plausível em histogramas com ruído	77
27	O princípio da negação plausível em divulgações estatísticas	101
28	A influência de um indivíduo na evolução de uma comunidade em uma rede social [70]	103
29	Ataque de reconstrução de base [56]	109
39	Aplicação de anonimidade- k , diversidade- ℓ e proximidade- t para divulgação não perturbativa de microdados	136

40	Divulgação não perturbativa de microdados por amostragem	142
41	Divulgação não perturbativa de sumários estatísticos	143
42	Divulgação não perturbativa de histogramas	144
43	Divulgação de sumários estatísticos usando privacidade diferencial global .	146
44	Divulgação de histogramas usando privacidade diferencial global	149
45	Divulgação de microdados usando privacidade diferencial local	154

1 Introdução

Este documento consiste no Produto 03, intitulado *Relatório técnico sobre métodos de tratamento aplicáveis aos microdados de divulgação dos Censos Educacionais do Inep*, do plano de trabalho do Termo de Execução Descentralizada (TED) 8750, firmado entre o Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira (Inep) e a Universidade Federal de Minas Gerais (UFMG), e em execução pelo Laboratório Ins-crypt (*Laboratory of Information Security, Cryptography, Privacy, and Transparency*) do Departamento de Ciência da Computação (DCC) da Universidade.

1.1 Objetivo deste documento

De acordo com o plano de trabalho do TED 8750, o Produto 03 que este documento implementa consiste em um:

Documento técnico com a apresentação e a discussão comparativa dos métodos de tratamento aplicáveis aos microdados de divulgação pública do Censo da Educação Básica e do Censo da Educação Superior, realizados pelo Inep.

Mais especificamente, visa-se a atender ao Objetivo Específico 04 do plano de trabalho:

Apresentar alternativas, a partir do panorama encontrado, de métodos de controle de divulgação com base nas abordagens pesquisadas. Estas alternativas devem fornecer aos gestores do Inep uma percepção clara dos benefícios, custos e riscos da adoção de cada abordagem. Este estudo técnico deve apresentar as técnicas propostas para o tratamento dos dados de forma que as equipes do Inep sejam capazes de compreender e reproduzi-las, inclusive independentemente do apoio de ferramentas estranhas ao ambiente do Inep e sem o auxílio de equipes externas, após o repasse de conhecimento.

1.2 Contextualização

Para fins de proteção de privacidade, a atual forma de divulgação dos microdados dos Censos Educacionais pelo Inep utiliza apenas as técnicas de *desidentificação*, em que se removem possíveis identificadores individuais óbvios dos registros (como nome, CPF, RG) e de *pseudonimização*, em que tais identificadores individuais óbvios são substituídos por um código único de identificação artificialmente criado. As análises quantitativas experimentais realizadas no Produto 02 do presente TED 8750 demonstraram de forma inequívoca que esta abordagem submete os titulares dos dados a sérios e generalizados riscos de violação de privacidade, em especial aos de reidentificação e de inferência de atributos sensíveis. Para citar alguns destaques resultantes desta análise, foi averiguado que as atuais divulgações dos Censos Educacionais estão sujeitas a elevados riscos de:

- **Reidentificação, em que é possível ligar um registro na base a seu titular.** Informação auxiliar consistindo em um conjunto de apenas 4 quaseidentificadores (mês, ano e município de nascimento, além de código da entidade) já permite a reidentificação com absoluta certeza de 33% dos alunos no Censo da Educação Básica de 2019, ou aproximadamente 15 700 000 estudantes, enquanto outro conjunto (dia, mês e ano de nascimento, e código do curso) possibilita a reidentificação completa de 79% dos alunos no Censo da Educação Superior de 2018, ou aproximadamente 8 500 000 estudantes.
- **Inferência de atributo sensível, em que é possível determinar o valor de um atributo sensível de um titular, mesmo sem necessariamente reidentificá-lo.** O uso de um conjunto de apenas 4 quaseidentificadores facilmente descobriáveis (dia, mês e ano de nascimento, além de código do curso) já permite inferência com absoluta certeza de se um aluno é beneficiário de financiamento estudantil para 92% daqueles presentes no Censo da Educação Superior de 2018, ou aproximadamente 9 900 000 estudantes, enquanto outro conjunto também trivial (mês, ano e município de nascimento, além de código da entidade) possibilita a inferência de se um aluno possui necessidade especial em 93% dos indivíduos presentes no Censo da Educação Básica de 2019, ou aproximadamente 44 300 000 estudantes.
- **Ataques longitudinais, em que as várias bases dos Censos Educacionais são cruzadas para aumentar a chance de inferência de informação sensível.** Informação auxiliar consistindo em apenas 2 quaseidentificadores (código do curso e IES de um aluno) possibilita a reidentificação com absoluta certeza de apenas 0.0044% dos alunos presentes no Censo da Educação Superior de 2014, ou aproximadamente 430 estudantes. Entretanto ao usar como informação auxiliar os Censos de 2015, 2016 e 2017, a porcentagem de alunos reidentificáveis sobe a 15.25%, ou aproximadamente 1 400 000 estudantes. Usando o mesmo conjunto de 2 quaseidentificadores é possível inferir com absoluta certeza se um aluno é portador de deficiência para 19.89% dos indivíduos presentes no Censo da Educação

Superior de 2014, ou aproximadamente 1 900 000 estudantes. Porém o cruzamento de informação com os Censos de 2015, 2016 e 2017 eleva a proporção de alunos afetados para 58.82%, ou aproximadamente 5 700 000 estudantes.

Como já expressamos anteriormente, em nossa visão a situação exposta acima poderia constituir em uma violação da Lei Geral de Proteção de Dados Pessoais (LGPD) [44]. De fato, o objetivo do presente TED 8750 é justamente encontrar métodos de tratamento de dados adequados para mitigar a degradação de privacidade causada pelas divulgações dos Censos Educacionais do Inep.

A área de pesquisa que se ocupa deste tipo de questão é conhecida como *controle de divulgação estatística* (*statistical disclosure control*, no original em inglês). Seu foco é encontrar maneiras de compartilhar publicamente informações sobre um conjunto de dados, revelando padrões estatísticos a respeito dos mesmos ao mesmo tempo em que se protegem informações sensíveis sobre os indivíduos no conjunto de dados. Um desafio crucial desta área é encontrar métodos de mitigação de degradação de privacidade que mantenham um equilíbrio adequado entre:

- a garantia de *privacidade* aos titulares dos dados contra *adversários*, i.e., pessoas ou entidades que podem inferir informação sensível a respeito dos titulares; e
- a manutenção da *utilidade* dos dados com relação aos *analistas*, i.e., consumidores legítimos dos dados.

A área de controle de divulgação estatístico é muito ampla, existindo livros inteiros escritos apenas sobre o assunto. Alguns livros cobrem o tema de forma geral [73, 54, 65], enquanto outros se especializam em nichos específicos, como na divulgação de dados médicos [60], em técnicas baseadas em privacidade diferencial [51], em aplicações em R [103], ou nos fundamentos científicos do fluxo de informação [14]. Além disso, a literatura técnica apresenta avanços constantes e contínuos na conciliação de privacidade e utilidade em divulgações estatísticas, com novas soluções sendo produzidas e publicadas em um ritmo acelerado dentro da comunidade científica.

No presente documento apresentamos uma análise dos principais métodos de mitigação de degradação de privacidade em princípio aplicáveis aos Censos Educacionais do Inep. Nosso objetivo neste documento não é exaurir o campo de possibilidades técnicas para o problema, mas sim cobrir os fundamentos dos métodos mais utilizados e do estado da arte, apontando sua aplicabilidade, vantagens, desvantagens e custos de implementação e manutenção para que o Inep possa efetuar uma escolha bem informada.

Segundo os especialistas em privacidade em dados médicos Divanis e Loukides [60], não existe uma solução única que funcione em todos os casos, e, apesar dos avanços científicos, vários desafios ainda permanecem. Qualquer abordagem deve considerar todo o ciclo de vida dos dados, desde sua coleta, comunicação, acesso por terceiros, e divulgação.

De forma geral, os métodos de mitigação podem ser agrupados pelo tipo de divulgação em que se baseiam, a saber: (i) microdados; (ii) dados agregados; (iii) salas seguras;

(iv) aplicações web; e (v) dados sintéticos. Cada uma dessas formas possui vantagens e desvantagens em termos da privacidade garantida aos titulares e da utilidade provida aos analistas, mas podem ser combinadas em uma estratégia holística de governança de dados. Embora no contexto dos Censos Educacionais do Inep haja uma expectativa arraigada de que os analistas sempre tenham acesso a microdados, a literatura técnica é inequívoca sobre a dificuldade de se proverem garantias de privacidade individuais sobre estes dados sem um custo significativo em sua utilidade. Soluções mais modernas de divulgação de microdados se baseiam em privacidade diferencial local, que demandam uma quantidade significativamente maior de recursos humanos e computacionais para sua implementação, além de tenderem a diminuir a utilidade dos dados para os analistas. Soluções intermediárias combinam a divulgação pública de apenas dados agregados protegidos com alguma forma de privacidade diferencial, enquanto garantem acesso a microdados via salas seguras –físicas ou virtuais– com controle de acesso.

Ressaltamos, entretanto, que a ciência pode apenas informar quais são as possíveis configurações do compromisso entre privacidade e utilidade atingíveis em variados contextos, assim como o custo necessário para se atingir cada configuração. A decisão final em cada caso concreto abarca, além de questões técnico-científicas, também dimensões políticas e sociológicas, que devem ser cuidadosamente ponderadas.

Em particular, um desafio crucial na escolha de qualquer método de mitigação é a harmonização de interesses possivelmente conflitantes de vários atores. No caso dos Censos Educacionais do Inep, os atores incluem os titulares de dados (estudantes, professores, escolas, etc.), analistas (demógrafos, entidades civis e governamentais, etc.), o governo (que regulamenta tanto questões de privacidade quanto de transparência e acesso à informação), além do próprio Inep (que tem que conciliar de forma realista as demandas dos vários atores com a sua capacidade e recursos para atendê-las).

Adicionalmente, o Inep dispõe de um prazo exíguo para implementação de uma solução que atenda às demandas da LGPD. Dada esta restrição de tempo, o Inep deve considerar adotar uma solução emergencial de curto prazo que garanta a privacidade dos titulares –mesmo que seja possivelmente sub-ótima em relação à utilidade provida aos analistas (ou vice-versa)–, enquanto elabora-se uma alternativa de longo prazo que forneça um melhor custo-benefício na relação de privacidade e utilidade.

Neste documento propomos um plano de ação para o Inep que contempla tanto a solução de curto prazo quanto a de longo prazo. O Resumo do presente documento funciona como um sumário executivo com o desenho geral do nosso parecer. Uma descrição mais detalhada e fundamentada das nossas recomendações encontra-se na Seção 3, logo após a exposição de uma fundamentação teórica mínima necessária para o mesmo, provida na Seção 2. O restante do documento provê, então, o detalhamento das técnicas sumarizadas no parecer.

1.3 Organização deste documento

O restante deste documento está organizado da seguinte forma.

- **Fundamentação teórica** (Seção 2): Nesta seção apresentamos a fundamentação teórica que serve de base para este documento, incluindo conceitos sobre privacidade, métodos de mitigação de degradação de privacidade, e utilidade de dados.
- **Parecer sobre o emprego de métodos de mitigação de degradação de privacidade à divulgação dos Censos Educacionais** (Seção 3): Nesta seção apresentamos nosso parecer técnico sobre a viabilidade de aplicação de variados métodos de tratamento à divulgação dos Censos Educacionais pelo Inep. Esta seção é o cerne do presente documento, e foi concebida de forma a ser tão auto-contida quanto possível.
- **Especificação de métodos não perturbativos para divulgação de microdados** (Seção 4): Nesta seção apresentamos um sumário dos principais métodos da literatura para divulgação de microdados de forma não perturbativa.
- **Especificação de métodos não perturbativos para divulgação de dados agregados ou tabulares** (Seção 5): Nesta seção apresentamos métodos para divulgação de dados agregados de forma não perturbativa.
- **Especificação de métodos baseados em privacidade diferencial** (Seção 6): Nesta seção apresentamos métodos baseados em privacidade diferencial e suas variantes, que são consideradas o estado da arte em controle de divulgação estatística.
- **Anexos**: Apresentamos aqui o seguinte material suplementar.
 - Resultados formais importantes sobre o compromisso entre privacidade e utilidade em divulgações estatísticas (Anexo A)
 - Definição matemática de métricas de utilidade populares (Anexo B)
 - Implementação dos algoritmos de anonimidade- k , diversidade- ℓ e proximidade- t provida pela ferramenta ARX (Anexo C)
 - Variantes refinadas da privacidade diferencial que podem garantir maior utilidade das divulgações (Anexo D)
 - Visão geral dos algoritmos para produção de histogramas e dados sintéticos respeitando privacidade diferencial (Anexo E)
 - O desafio de mitigação de ataques longitudinais (Anexo G)
 - Exemplos da aplicação de vários métodos de mitigação a uma mesma base de exemplo (Anexo H)

2 Fundamentação teórica

Nesta seção apresentamos a fundamentação teórica que serve de base para este documento. Em particular, apresentamos conceitos essenciais sobre privacidade, sobre métodos de mitigação de degradação de privacidade, e sobre utilidade dos dados usados em nosso parecer sobre os Censos Educacionais do Inep.

2.1 Privacidade

Iniciamos nossa formalização relembrando o significado técnico preciso de alguns termos da literatura sobre proteção à privacidade [49, 99, 28, 31, 33, 76, 34, 72, 54, 60, 91] usados recorrentemente neste documento. Uma introdução unificada a todos estes termos é provida em [47, 14].

A fim de garantir que o conteúdo do presente documento seja tão auto contido quanto possível, repetimos aqui algumas definições já apresentadas em documentos anteriores do presente TED 8750. Por outro lado, introduzimos também vários conceitos essenciais utilizados pela primeira vez no contexto do presente projeto.

Conceitos básicos sobre controle de divulgação estatística A seguir introduzimos os conceitos essenciais da área.

- **Controle de divulgação estatística** é a área que estuda como compartilhar publicamente informações sobre um conjunto de dados, revelando padrões estatísticos a respeito dos mesmos ao mesmo tempo em que se protegem informações sensíveis sobre os indivíduos no conjunto de dados. O controle de divulgação estatística deve balancear a manutenção da utilidade dos dados (com relação a um analista legítimo) com garantias de privacidade para os titulares dos dados (contra um adversário).
- **Curador de dados** é a pessoa ou entidade responsável pela integração de dados coletados de várias fontes, além da organização, publicação e apresentação dos dados de forma que o valor dos dados seja mantido ao longo do tempo e os dados permaneçam disponíveis para reutilização e preservação. A curadoria de dados

inclui “todos os processos necessários para a criação, manutenção e gerenciamento de dados controlados e com princípios, juntamente com a capacidade de agregar valor aos dados” [84].

No contexto do presente projeto, o Inep é o curador dos dados de seus Censos Educacionais.

- **Analista de dados** é a pessoa ou entidade considerada como usuária legítima de uma divulgação de dados.

No contexto do presente projeto todo o público que tem acesso às divulgações dos Censos Educacionais são considerados analistas de dados, incluindo pesquisadores, demógrafos, entidades civis e governamentais.

- **Utilidade** é a propriedade de uma divulgação servir aos propósitos legítimos do analista de dados, provendo a ele a informação desejada.

No contexto do presente projeto, a utilidade dos Censos Educacionais está atrelada à capacidade do analista de inferir informações estatísticas a respeito de estudantes, escolas, docentes, etc., representados nas pesquisas.

- **Informação sensível (ou segredo)** é aquela considerada como digna de proteção. Exemplos típicos de informação sensível incluem dados pessoais de um indivíduo (e.g., seu número de cartão de crédito, senha bancária, ou condição médica), mas outros tipos de valores podem ser considerados sensíveis, como a própria identidade do indivíduo (e.g., caso o anonimato do remetente de uma mensagem seja importante, como em denúncias jornalísticas ou em países sujeitos a forte censura governamental), ou o território específico de circulação no qual pessoas em programas de proteção a testemunhas podem ser acessíveis.

No contexto brasileiro, a LGPD [44], em seu Artigo 5º, inciso II, define como *dado pessoal sensível* todo aquele “dado pessoal sobre origem racial ou étnica, convicção religiosa, opinião política, filiação a sindicato ou a organização de caráter religioso, filosófico ou político, dado referente à saúde ou à vida sexual, dado genético ou biométrico, quando vinculado a uma pessoa natural”.

Neste documento nos focamos nos seguintes tipos de informação sensível ou segredo:

- a *ligação de um registro na base de dados a seu titular*, que é a informação sensível relevante em um ataque de reidentificação; e
 - o *valor de um atributo sensível de um indivíduo*, que é a informação sensível relevante em um ataque de inferência de atributo.
- **Adversário** é entidade contra quem se deseja proteger a informação sensível sobre indivíduos. O adversário pode ser uma pessoa física ou uma organização. É importante notar que não necessariamente se atribuem intenções deletérias ao adversário: é possível que um analista legítimo de uma divulgação estatística (e.g., um pesquisador acadêmico) atue inadvertidamente como adversário ao inferir informação sensível de indivíduos no decurso de suas ações idôneas.

No contexto do presente projeto, por se tratar de um problema de controle de divulgação estatística, em princípio qualquer analista de dados pode ser um adversário em potencial, seja intencionalmente (e.g., uma agência de empregos que tenta inferir a partir dos dados Censos Educacionais se um candidato a uma vaga possui ou não alguma forma de deficiência a fim de negar-lhe emprego), seja não intencionalmente (e.g., um pesquisador que inadvertidamente descobre o paradeiro de um estudante ou docente participante de um programa de proteção a testemunhas).

- **Ataque** é uma ação ou conjunto de ações pelas quais o adversário pode obter informação sensível sobre indivíduos. É importante notar que também ao termo “ataque” não se atribui uma intenção necessariamente deletéria: uma utilização legítima dos dados (e.g., para pesquisa científica) pode resultar inadvertidamente em um ataque se porventura revelar informação sensível.
- **Informação auxiliar ou lateral** é qualquer informação que, em relação a uma divulgação de dados de interesse, se possa obter a respeito de um indivíduo através de outros canais que não sejam a divulgação de dados de interesse em si mesma (e.g., via *web*, outros registros públicos, mídia, conhecimento prévio). Um exemplo de obtenção de informação auxiliar por parte do adversário é quando ele consegue via outras fontes (e.g., um cartório) o valor de um quaseidentificador de um indivíduo (e.g., sua data de nascimento).
- **Negação plausível** (*plausible deniability*, no original em inglês) é a capacidade de um titular de dados negar de forma crível para um adversário alguma propriedade sobre sua informação sensível (e.g., negar sua participação em um estudo, ou que um de seus atributos tenha um valor específico), mesmo após um ataque. A possibilidade de negação plausível é essencial para convencer indivíduos a participar honestamente –i.e., sem mentir– de pesquisas que envolvam o fornecimento de informação sensível [51]. Métricas de privacidade são baseadas na quantificação do nível de negação plausível de que os titulares gozam.

Tipos de risco à privacidade De acordo com o tipo de informação considerada sensível em um contexto, os riscos à privacidade podem ser agrupados como a seguir [54, 60, 91].

- **Risco de reidentificação** (*record linkage* ou *deanonymization*, no original em inglês) é aquele de que o adversário determine uma correspondência entre registros presentes na base de dados e os titulares desses registros, i.e., os indivíduos do mundo real a quem os registros se referem.
- **Risco de inferência de atributo sensível** (*attribute linkage*, no original em inglês) é aquele de que o adversário infira o valor assumido por um atributo considerado como sensível para alguns indivíduos, independentemente de se esses indivíduos tenham sido reidentificados com sucesso ou não.

- **Risco de inferência de pertinência (*table linkage*, no original em inglês)** é aquele de que o adversário consiga determinar se um grupo de indivíduos está ou não representado em uma base de dados. Este risco é particularmente importante quando a própria presença na base de dados é considerada informação sensível, por exemplo, quando trata-se de uma base de dados contendo apenas pacientes com uma condição médica rara.

No caso dos Censos Educacionais do Inep nos focamos nos dois primeiros tipos de risco, reidentificação e inferência de atributo sensível. O Produto 02 do presente TED 8750 provê uma extensa avaliação quantitativa destes riscos nos Censos Educacionais.

Não nos focamos no terceiro tipo de risco, inferência de pertinência, uma vez que, em princípio, todos os possíveis indivíduos de interesse (estudantes, professores) deveriam estar presentes nas bases de dados. Entretanto, dependendo da técnica de mitigação de degradação de privacidade adotada pelo Inep, esta premissa pode ser quebrada (por exemplo, se fossem divulgadas apenas amostras das bases, e não mais as bases completas). Neste caso, riscos de inferência de pertinência deverão ser considerados com mais cuidado no contexto do Inep.

Classificação de atributos Muitas técnicas de proteção à privacidade baseadas em divulgação de microdados cobertas neste documento utilizam a seguinte classificação de atributos individuais [54, 60].

- **Identificadores diretos** são atributos que podem unicamente identificar um indivíduo, como nome, RG, CPF, ou número de telefone celular.
- **Quaseidentificadores** são atributos que não são, em si mesmos, identificadores únicos de um indivíduo (como nome, CPF ou RG), mas que estão suficientemente correlacionadas com o titular a ponto de poderem ser combinadas com outros quaseidentificadores para criar um identificador exclusivo. Por exemplo, Sweeney demonstrou em 2000 que o *zip-code* (o equivalente americano ao CEP brasileiro), o gênero e a data de nascimento de um indivíduo são quaseidentificadores poderosos, uma vez que 87% da população dos EUA poderia ser unicamente identificada usando-se apenas estes três atributos combinados [101].
- **Atributos sensíveis** são atributos cujos valores são considerados dignos de proteção. Exemplos típicos incluem a senha bancária de um indivíduo ou sua condição médica, mas podem também conter informação considerada digna de proteção dentro de um contexto, como etnia, ou orientação sexual.
- **Atributos não sensíveis** são atributos cujos valores não são considerados dignos de proteção em si mesmos em um dado contexto, como possivelmente a idade ou altura de um indivíduo em algumas situações.

É importante ressaltar que a classificação de atributos nas categorias acima dependem diretamente do cenário de interesse. Uma informação considerada sensível em um contexto pode não o ser em outro, e um atributo pode não ser um quaseidentificador viável em um instante no tempo, mas ser em outro posterior. Por essa razão, alguns métodos de proteção de privacidade mais sofisticados não dependem da categorização de atributos da forma acima.

Degradação de privacidade devida a um ataque, e suas métricas O estudo de privacidade só é preciso quando há medidas quantitativas formais do quanto a privacidade é degradada em cada cenário. A seguir apresentamos os fundamentos de como a degradação de privacidade é formalizada na área de fluxo de informação quantitativo [83, 81, 66, 33, 59, 79, 72, 31, 99, 35, 22, 16, 11, 80, 12, 13, 30, 17]. Uma apresentação unificada destes princípios pode ser encontrada em [14].

- **Conhecimento a priori e sucesso a priori do adversário** Antes mesmo de o ataque ser realizado, presume-se que o adversário tenha algum *conhecimento a priori* sobre o segredo. Tal conhecimento pode advir de várias fontes: informação prévia sobre a distribuição de probabilidade a partir da qual o segredo foi amostrado (e.g., em caso de segredos aleatórios, como uma senha automaticamente gerada por um aplicativo); fontes auxiliares de informação (como jornais, revistas, mídia, ou conhecimento comum); ou mesmo de ataques anteriores. O *sucesso a priori do adversário* é, então, uma medida do quanto de informação sensível o adversário já possui antes mesmo de executar um ataque, usando apenas seu conhecimento a priori.

Por exemplo, considere um cenário em que a informação sensível seja o dia da semana em que um indivíduo escolhido como alvo nasceu. Antes mesmo de executar o ataque, o adversário pode ter o conhecimento a priori (advindo, e.g., de jornais, revistas, censos demográficos, etc.) de que a distribuição de datas de nascimento na população em que o indivíduo alvo se insere é uniforme sobre os dias da semana. Usando apenas essa informação, o adversário poderia “adivinhar no escuro”¹ o dia de nascimento do indivíduo-alvo e mesmo assim teria uma chance de 1 em 7 de inferir corretamente o valor do atributo sensível. Nesse caso, sua probabilidade de sucesso a priori na inferência do atributo sensível pode ser quantificada como $1/7 \approx 14\%$.

¹Em alguns momentos usamos informalmente a expressão “adivinhar no escuro” para descrever a melhor estratégia possível para se estimar o valor de uma variável desconhecida. Apesar do uso desta expressão coloquial, tal abordagem é solidamente baseada no *Princípio da máxima entropia*, que afirma que a distribuição de probabilidade que melhor representa um estado de conhecimento é aquela com a maior entropia possível, dadas as informações já conhecidas [67]. No nosso contexto, isso geralmente significa que, na ausência de mais informação, deve-se assumir que a distribuição de probabilidade sobre um conjunto é uniforme e, portanto, o melhor que o adversário tem a fazer é mesmo “adivinhar no escuro” o valor de uma variável desconhecida.

- **Conhecimento a posteriori e sucesso a posteriori do adversário** Ao longo da execução do ataque, o adversário combina a observação dos resultados obtidos com seu conhecimento a priori, revisando assim sua informação sobre o segredo a fim de obter o que se chama de *conhecimento a posteriori*. O *sucesso a posteriori do adversário* é, então, uma medida (determinística ou probabilística) do quanto de informação sensível o adversário detém após a execução do ataque.

Considere novamente o exemplo acima em que o segredo é o dia da semana em que um indivíduo nasceu. Suponha que o adversário execute um ataque sobre uma base de dados que contém informação sobre o indivíduo-alvo e averigue, assim, que esse indivíduo não nasceu nem em um sábado nem em um domingo. Neste caso o adversário revisa seu conhecimento a priori (de que qualquer dia da semana é igualmente provável como valor do atributo sensível) para um conhecimento a posteriori (de que qualquer dia entre segunda-feira e sexta-feira são igualmente prováveis como valor do atributo sensível, enquanto sábado e domingo estão descartados). Consequentemente, a probabilidade de sucesso a posteriori do adversário (i.e., a sua chance de inferir corretamente o valor do atributo sensível após a realização do ataque) neste caso é de $1/5 = 20\%$.

- **Degradação de privacidade de um ataque** Um princípio fundamental da formalização de privacidade é que a *degradação de privacidade de um ataque* é uma comparação entre o sucesso a priori do adversário (i.e., informação a respeito do segredo antes mesmo da execução do ataque, contando apenas com seu conhecimento a priori) e seu sucesso a posteriori (i.e., informação a respeito do segredo após a execução do ataque, contando já com seu conhecimento a posteriori). Intuitivamente, quanto maior a degradação de privacidade de um ataque, maior êxito do adversário em obter informação sensível a respeito de seu alvo e maior o dano incorrido à privacidade *por causa direta do ataque*.²

²Como ilustração da razão pela qual a degradação de privacidade é definida como o *aumento na medida de sucesso do adversário devido a um ataque*, em vez de simplesmente como a medida de sucesso a posteriori (i.e., após a execução do ataque), apreciemos os seguintes exemplos. Considere novamente o cenário em que a informação sensível é o dia da semana em que um indivíduo-alvo nasceu. Suponha que o ataque consista em o adversário acessar uma base de dados em que o indivíduo está representado, juntamente com seu CPF e dia de nascimento, e usar o CPF do indivíduo como informação auxiliar para recuperar a informação sensível. Entretanto, dessa vez, suponha que um adversário *A* já tenha como conhecimento a priori (por exemplo, porque ele teve acesso à certidão do nascimento do indivíduo e cruzou essa informação com um calendário) de que o indivíduo nasceu em uma segunda-feira. Como o CPF é único, esse adversário terá sucesso em reidentificar o indivíduo na base e recuperar o seu dia de nascimento como uma segunda-feira. Note, entretanto, que *o ataque em si não alterou a informação que o adversário A já tinha sobre o segredo*. Intuitivamente, portanto, este ataque pode ser considerado inócuo, já que o sucesso a posteriori do adversário permanece o mesmo que seu sucesso a priori. Por outro lado, considere um adversário *B* cujo conhecimento a priori (e.g, vindo de informação auxiliar, ou de um ataque anterior) seja apenas de que é igualmente provável que o indivíduo alvo tenha nascido em qualquer dia entre segunda-feira e sexta-feira, mas não no final de semana. Claramente, assim como o adversário *A*, o adversário *B* também atinge certeza absoluta, após realizar o ataque, de que o indivíduo nasceu em uma segunda-feira. Entretanto, note que no caso do adversário *B* o ataque aumenta seu conhecimento sobre o segredo e pode, intuitivamente, ser considerado de alguma forma eficaz. Portanto,

Quando a comparação se faz pela razão entre o sucesso a posteriori e o sucesso a priori do adversário, temos uma *medida multiplicativa de degradação de privacidade* [23, 12]:

$$\text{degradação multiplicativa de privacidade} \stackrel{\text{def}}{=} \frac{\text{sucesso do adversário a posteriori}}{\text{sucesso do adversário a priori}}.$$

Já quando a comparação é feita tomando-se a diferença entre o sucesso a posteriori e o sucesso a priori do adversário, temos uma *medida aditiva de degradação de privacidade* [23, 12]:

$$\text{degradação aditiva de privacidade} \stackrel{\text{def}}{=} \text{sucesso do adversário a posteriori} - \text{sucesso do adversário a priori}.$$

Ainda considerando o mesmo exemplo de data de aniversário acima, a degradação multiplicativa de privacidade devida ao ataque seria de $(1/5)/(1/7) = 7/5 = 1.4$, indicando que a realização do ataque conferiria ao adversário um ganho relativo de 40% em sua chance de sucesso na inferência do atributo sensível. Por outro lado, a degradação aditiva de privacidade devida ao ataque seria dada pela diferença $1/5 - 1/7 = 2/35 \approx 0.06$, indicando que a realização do ataque conferiria ao adversário um ganho absoluto de aproximadamente 6% em sua chance de sucesso na inferência do atributo sensível.

- **Classificação de métricas de privacidade quanto ao grau de sucesso atingido pelo adversário**

- **Métricas determinísticas de sucesso** mensuram o sucesso do adversário de forma absoluta –i.e., retornam um valor qualitativo dependendo de se a informação desejada foi ou não recuperada com absoluta certeza.

Exemplos típicos de métricas determinísticas incluem o número de indivíduos em uma base de dados que podem ser unicamente reidentificados, ou ter o valor de um atributo sensível inferido, com absoluta certeza.

- **Métricas probabilísticas de sucesso** provêm um valor quantitativo representando o grau de certeza com o qual a informação desejada foi recuperada. Exemplos típicos de métricas probabilísticas incluem a chance de que um indivíduo aleatoriamente selecionado como alvo seja reidentificado em uma base de dados, ou a probabilidade de que um indivíduo tenha o valor de seu atributo sensível corretamente inferido, mesmo que sem absoluta certeza.

apesar do sucesso a posteriori de ambos os adversários A e B ser o mesmo (ambos sabem com certeza, a posteriori, o dia de nascimento do indivíduo alvo), a contribuição do ataque em si para o estabelecimento desse conhecimento é distinta em cada caso: para o adversário A o ataque não altera sua medida de sucesso, enquanto que para o adversário B o ataque aumenta significativamente sua medida de sucesso. Por essa razão, considera-se que a degradação de privacidade causada pelo ataque seja maior no caso do adversário B do que no caso do adversário A .

- **Métricas de caso médio** mensuram a esperança ou média do sucesso do adversário, levando em conta alguma distribuição de probabilidade sobre possíveis configurações do ataque.

Um exemplo típico de métrica de caso médio seria a medida do risco esperado de reidentificação de um indivíduo aleatoriamente selecionado como alvo em uma base de dados. Neste caso, quantifica-se o risco de reidentificação para todos os indivíduos que podem ser escolhidos como alvo de um ataque em uma base de dados e, em seguida, computa-se a média ponderada do risco levando em conta uma distribuição de probabilidade sobre os indivíduos (e.g., a distribuição uniforme).

- **Métricas de pior caso** mensuram o sucesso do adversário sobre a configuração de ataque mais vantajosa para ele possível, independentemente do quão improvável ela seja.

Um exemplo típico de métrica de pior caso seria a medida do risco máximo de reidentificação de um indivíduo em uma base de dados. Neste caso, quantifica-se o risco de reidentificação para todos os indivíduos que podem ser escolhidos como alvo de um ataque em uma base de dados e, em seguida, retorna-se o maior risco dentre todos os encontrados.

É importante destacar que, por levar em conta a esperança do risco, métricas de caso médio podem ocultar o risco a que incorrem poucos indivíduos. Por outro lado, por destacar o pior risco possível, métricas de pior caso podem retornar valores que não são representativos do caso geral. A escolha entre métricas de caso médio e pior caso é uma decisão a ser tomada caso a caso, com cuidado.

2.2 Métodos de mitigação de degradação à privacidade

Um *método de mitigação de degradação de privacidade* é um conjunto de ações que podem ser tomadas pelo curador dos dados para preservar em algum nível a informação sensível dos titulares de dados. Existe um grande número de métodos na literatura, que podem ser agrupados em algumas famílias que guardam entre si similaridades. Apesar de não haver uma nomenclatura única para estas famílias, é comum encontrar métodos sendo classificados (inclusive como fazemos no presente documento) de acordo com as dimensões abaixo.

- **Não perturbativos (*non-perturbative*, no original em inglês) vs. perturbativos (*perturbative*, no original em inglês)** *Métodos não perturbativos* alteram a informação provida apenas por diminuir sua granularidade ou por suprimi-la por partes, mas sem introduzir informação ruidosa. Exemplos incluem os métodos de anonimidade- k , diversidade- ℓ e proximidade- t quando não se utilizam de introdução de dados falsos (discutidos na Seção 4), e divulgação de histogramas e estatísticas de forma determinística (discutidas na Seção 5).

Métodos perturbativos podem introduzir informação inverídica de forma controlada na divulgação, seja por criação de dados falsos ou pela inserção de ruído nos dados. Exemplos incluem os métodos de anonimidade- k , diversidade- ℓ e proximidade- t quando se utilizam de introdução de dados falsos (o que não consideramos neste documento), e todas as variantes de privacidade diferencial, que se baseiam na introdução de ruído nos dados (discutidas na Seção 6).

- **Sintáticos vs. semânticos** *Métodos sintáticos* formulam condições puramente sintáticas –que geralmente podem ser checadas apenas analisando-se os dados produzidos– para a divulgação de informação. Exemplos típicos incluem os métodos de k -anonymity, l -diversity e t -closeness (discutidos na Seção 4.1).

Métodos semânticos formulam condições semânticas para a divulgação de informação, incorporando em si mesmos a formalização de privacidade almejada. Um exemplo típico é a privacidade diferencial, em suas mais variadas formas (discutidas na Seção 6).

- **Globais vs. locais:** *Métodos globais* contam com um *curador de dados* responsável pela coleta de informações individuais e aplicação das técnicas de proteção. Nesse tipo de método assume-se que o curador é uma entidade digna de confiança para tratamento da informação sensível, e o tratamento é aplicado ao conjunto dos dados de forma holística. Exemplos típicos incluem k -anonymity, l -diversity e t -closeness (discutidos na Seção 4.1), assim como as divulgações de dados agregados ou tabulares (discutidas na Seção 5). Também a privacidade diferencial tem uma variante global (discutida na Seção 6.2).

Métodos locais são aqueles em que a proteção de privacidade é aplicada aos dados de cada titular individualmente. Nesse tipo de método geralmente se assume que ou não há um curador central para os dados ou que, quando há, ele não é digno de confiança e pode agir como adversário. Também é possível que próprio curador, mesmo que confiável, aplique tratamento local a cada dado individualmente em situações especiais (por exemplo, quando se desejam divulgar microdados sanitizados). A própria privacidade diferencial tem uma variante local (discutida na Seção 6.3).

- **Produtores de microdados vs. produtores de dados agregados** *Métodos produtores de microdados*, como o próprio nome diz, produzem como resultado para divulgação informação em nível individual, porém possivelmente tratada de alguma forma. Exemplos típicos incluem os métodos de k -anonymity, l -diversity e t -closeness (discutidos na Seção 4.1), além de algumas forma de privacidade diferencial local (discutida na Seção 6.3).

Métodos produtores de dados agregados, também como indicado pelo próprio nome, produzem como resultado informação agregada para divulgação. Exemplos típicos incluem divulgação de estatísticas a respeito dos dados, ou de histogramas para algumas combinações de atributos (alguns deles discutidos na Seção 5).

2.3 Utilidade

Todo método de mitigação de degradação de privacidade vem acompanhado de um maior ou menor custo à utilidade dos dados divulgados –i.e., à qualidade da informação provida aos analistas. É amplamente conhecida na literatura técnica sobre controle de divulgação estatística a dificuldade inerente de se conciliar a utilidade dos dados divulgados com a privacidade dos indivíduos que participam das pesquisas [49, 58, 24, 70, 10, 57, 17].

Na Seção 3.1.2 resumizamos os resultados fundamentais sobre o compromisso entre utilidade e privacidade para uma tomada de decisão bem informada por parte do Inep sobre seus Censos Educacionais. O Anexo B apresenta um sumário de métricas de utilidade comumente utilizadas na literatura.

3 Parecer sobre o emprego de métodos de mitigação de degradação de privacidade à divulgação dos Censos Educacionais

Nesta seção apresentamos nosso parecer técnico sobre a viabilidade de aplicação de variados métodos de mitigação de danos à privacidade à divulgação dos Censos Educacionais pelo Inep. O presente parecer é o cerne do presente documento, e foi concebido de forma a ser tão auto-contido quanto possível. As seções seguintes servem de suporte técnico para a discussão aqui provida.

O parecer se inicia com uma exposição dos desafios cruciais na implementação de técnicas de mitigação de degradação de privacidade em divulgações estatísticas. Em particular, discutimos os desafios que envolvem: (i) a escolha da forma de divulgação de informações, incluindo as baseadas em microdados, dados agregados, salas seguras, aplicações web, dados sintéticos, ou uma combinação dos mesmos; (ii) as dimensões científicas, técnicas e políticas do desafio de se conciliar a privacidade dos titulares dos dados com a utilidade da informação provida aos analistas em qualquer divulgação estatística; e (iii) a dificuldade de se protegerem as divulgações periódicas dos Censos Educacionais pelo Inep contra ataques longitudinais. Em seguida apresentamos um sumário dos principais métodos de mitigação aplicáveis ao contexto dos Censos Educacionais, apresentando quadros-resumos com os princípios, prós, contras e custos de implementação de cada método. O leitor interessado pode encontrar o detalhamento de cada método nas seções e anexos do presente documento. Por fim, provemos nossa lista de recomendações para o Inep, incluindo um plano de ação que leva em conta tanto a urgência de adequação da forma de divulgação dos Censos Educacionais à LGPD quanto a necessidade de refinamento dos métodos no médio e longo prazo a fim de otimizar a utilidade da informação provida aos analistas de dados, ao mesmo tempo em que se mantêm as garantias de privacidade aos titulares.

3.1 Desafios para implementação de métodos de mitigação de degradação à privacidade nos Censos Educacionais do Inep

Nesta seção resumizamos alguns dos desafios cruciais para desenho e implementação de métodos de mitigação de degradação à privacidade em divulgações estatísticas, com foco em sua aplicação nos Censos Educacionais do Inep. Começamos com o problema de se decidir qual o tipo de divulgação mais adequado –seja ele baseado em microdados, em dados agregados, em uso de salas seguras, em provimento de aplicações web, ou em produção de dados sintéticos (Seção 3.1.1).

Prosseguimos com um sumário do desafio de se atingir um compromisso razoável entre privacidade e utilidade em divulgações estatísticas (Seção 3.1.2), incluindo suas principais facetas no contexto do Inep: (i) a escolha de uma noção formal de privacidade adequada; (ii) dimensionamento do ruído necessário para soluções baseadas em privacidade diferencial; (iii) a inexistência de mecanismos que sejam universalmente úteis e a necessidade de se priorizar alguma métrica de utilidade; (iv) as limitações da granularidade das informações prestadas via divulgação de histogramas, dados agregados, ou privacidade diferencial global; e (v) a dificuldade de se atingirem bons níveis de utilidade em soluções baseadas em privacidade diferencial local.

3.1.1 Políticas e governança de dados

Um desafio crucial para o Inep, que motiva o presente TED 8750, é adaptação de suas políticas e de sua governança de dados às novas exigências impostas pela LGPD. Este desafio passa pela determinação da melhor forma de divulgação das informações dos Censos Educacionais. A seguir apresentamos um sumário das principais alternativas consideradas na literatura, baseando-nos na excelente discussão provida por Shlomo [96]. Cada uma destas alternativas é posteriormente detalhada ao longo do corpo do presente documento.

- (I) **Divulgação de Microdados.** *Microdados* são dados em sua menor unidade de agregação, com informações sobre titulares em nível individual. Sua principal vantagem é a alta precisão na informação prestada, o que geralmente provê alta utilidade para os analistas dos dados.

Os microdados dos Censos Educacionais do Inep são atualmente divulgados em sua totalidade, sendo tratados apenas com as técnicas de desidentificação (pela qual se removem possíveis identificadores individuais óbvios dos registros) e pseudonimização (pela qual identificadores únicos naturais são substituídos por identificadores artificiais). Como exposto no Produto 02 do presente TED, tais medidas, em isolamento, não são suficientes para mitigar satisfatoriamente riscos à privacidade dos indivíduos, incluindo reidentificação e inferência de atributos sensíveis.

No presente documento apresentamos um conjunto de técnicas de mitigação de danos à privacidade que são aplicáveis à divulgação de microdados (Seção 4). Tais técnicas podem ser tanto não perturbativas (i.e., limitando a quantidade de informação prestada, mas sem inserir informação ruidosa) quanto perturbativas (i.e., introduzindo ruído na informação prestada).

As técnicas não perturbativas apresentadas incluem a divulgação de microdados por amostragem (Seção 4.2), assim como a generalização e/ou supressão de valores sensíveis ou valores incomuns dos registros (abordagem utilizada pelos métodos sintáticos cobertos na Seção 4.1). Essas técnicas, embora muito difundidas no passado, não satisfazem garantias individuais de privacidade –i.e., elas podem proteger uma grande parte, ou mesmo a maioria, dos titulares de dados, mas não necessariamente todos, como é requerido por parte das regulamentações atuais. Além disso, tais técnicas não são resilientes a ataques composicionais, o que significa que o Inep não pode aplicá-las de forma independente a cada uma de suas bases e ainda assim produzir garantias de privacidade globais. Neste sentido, é de crucial importância uma avaliação jurídica de se as garantias providas por estas técnicas satisfariam os requerimentos da LGPD e outras regulamentações cabíveis.

Por outro lado, as técnicas de divulgação perturbativas de microdados do estado da arte incluem o uso de privacidade diferencial local em diversas formas: para sanitização da base de microdados (Seção 6.3), para amostragem de um subconjunto de microdados para divulgação (Seção 6.4.1), e para geração de dados sintéticos que substituem os dados reais na divulgação (Seção 6.4.2). Tais técnicas proveem garantias robustas de privacidade, mas podem em alguns casos diminuir drasticamente a utilidade dos dados, mesmo a ponto de tornar a divulgação inviável. Além disso, são significativamente mais complexas de serem apropriadamente implementadas, demandando mão de obra humana com expertise no assunto.

- (II) **Divulgação de dados agregados** *Dados agregados* são aqueles em que, ao contrário do que ocorre com microdados, a informação não é disponibilizada em nível individual. Na literatura é comum se referir a este tipo de dado também como *dados tabulares*, já que tipicamente eles são organizados em tabelas em que cada célula representa o número de indivíduos correspondente a uma coluna ou linha (e.g., faixa de idade ou instituição de ensino) ou a uma soma/média (e.g., número esperado de anos completos no ensino fundamental por unidade da federação).

As técnicas de divulgação de dados agregados cobertas no presente documento incluem as baseadas em sumários estatísticos predeterminados (Seção 5.1) e as baseadas em histogramas contendo apenas projeções marginais da distribuição de registros por valores (Seção 5.2). A divulgação de sumários estatísticos e histogramas proveem níveis médios de privacidade aos titulares significativamente superiores àqueles providos pela divulgação de microdados. Entretanto, elas ainda não proveem garantias individuais, como requerido por algumas regulamentações. Além disso, a divulgação de informação agregada sobre uma população inteira –e não apenas para uma amostra da população– está sujeita ao risco de ataques de

reconstrução da base de dados (descritos no Anexo A.3) e ao risco de inferência de atributos causado por diversos tipos de ataques em divulgações longitudinais.

De fato, o estado da arte indica que mesmo a divulgação de dados agregados não garante, por si só, privacidade em nível individual [47]. Por esta razão, a privacidade diferencial global é atualmente aplicada em dados agregados, seja em sumários estatísticos (diretamente à resposta de cada consulta, como descrito na Seção 6.2) seja em histogramas (com os métodos mais refinados introduzidos na Seção 6.4.2).

Uma desvantagem de métodos baseados em dados agregados é sua menor utilidade para analistas que precisem de informação em nível individual. Esta diminuição de utilidade pode ser particularmente significativa no contexto do Inep, em que já há uma expectativa por parte de analistas de acesso a microdados, como vem sendo feito desde pelo menos 2007. Para estes analistas, uma solução possível é prover acesso controlado a microdados como, e.g., via salas seguras.

- (III) **Salas seguras** *Salas seguras* (*safe rooms*, no original em inglês) são lugares físicos seguros que possuem servidores que contêm os dados reais de pesquisas sociais e pesquisas estatísticas de alguma natureza (por exemplo, dados médicos ou dados de censos populacionais) e terminais que os analistas podem utilizar para acessar esses dados. Os terminais não possuem conexão com a Internet nem com impressoras, e somente usuários legítimos e autorizados podem acessá-los. Para garantir que os dados não serão utilizados de maneira indevida, um monitoramento rigoroso do fluxo de informação da sala segura deve ser implementado e constantemente reforçado. Políticas de segurança devem assegurar auditoria em tempo real das operações realizadas sobre os dados pelos usuários e a utilização exclusiva de softwares padrões para análise de dados já instalado nos terminais (como STATA, ¹ SAS ² e R ³).

Uma outra forma de implementação de salas seguras é através de acesso remoto. Essa alternativa possibilita que analistas e usuários dos dados estatísticos não precisem viajar longas distâncias para realizar suas pesquisas. Entretanto, salas remotas demandam que as políticas de segurança sejam mais rígidas. Neste cenário, são criadas salas seguras de acesso remoto em instituições governamentais e universidades, ou então o analista pode realizar o acesso remoto pelo próprio computador. Para isso, é necessário uma configuração de conexões seguras com os servidores que contêm os dados, através de *Virtual Private Networks (VPNs)* rigorosamente monitoradas. Toda atividade deve ser registrada e auditorada a nível de teclas pressionadas, e deve ser revisada por um profissional qualificado antes que os resultados sejam enviados aos analistas através da conexão estabelecida.

- (IV) **Aplicações Web** A necessidade de dados especializados para certas aplicações

¹<https://www.stata.com/>

²<https://www.sas.com/>

³<https://www.r-project.org/>

requer uma flexibilidade que as técnicas de mitigação de propósito geral geralmente não possuem. Todas as técnicas prejudicam em algum nível a utilidade dos dados para pelo menos alguns analistas.

Para que essa flexibilidade seja alcançada, métodos de consulta a base de dados estatísticas têm sido desenvolvidos de forma que cada analista possa acessar uma aplicação web e gerar tabelas ou realizar análises exploratórias de acordo com suas necessidades.

Nessa abordagem, duas técnicas se destacam: servidores de geração flexível de dados tabulares (*flexible table generating servers*) [97] e servidores de análise remota (*remote analysis servers*) [88, 89].

Servidores de geração flexível de dados tabulares são acessíveis aos pesquisadores, que montam suas consultas de acordo com suas necessidades e recebem em resposta dados tabulares ou histogramas sobre os quais foram aplicadas técnicas de Limitação de Divulgação Estatística. O servidor também deve calcular os impactos da divulgação do resultado para cada tabela gerada e decidir se deve retornar os resultados ao pesquisador ou não. Além disso, várias técnicas (tanto pré-tabulares quanto pós-tabulares) podem ser combinadas, como supressão de células com contagens baixas, arredondamento aleatório e privacidade diferencial sobre os dados das tabelas.

Os servidores de análise remota são sistemas web seguros que aceitam consultas de análises exploratórias sobre os dados e retornam os resultados das análises aos pesquisadores. Esses resultados podem incluir plotagens, modelos de regressão, medidas de associação, dentre outros. As consultas podem ser executadas sobre os dados originais ou sobre os dados sintéticos, e diferentes técnicas podem ser combinadas para garantir a privacidade dos indivíduos presentes nessas análises. Essas técnicas podem envolver perturbar os dados subjacentes ou os resultados das consultas. Dependendo do nível de privacidade requerido para os dados, pode ser necessário implementar restrições e auditorias sobre as consultas realizadas.

Soluções web como descritas acima, entretanto, demandam um investimento significativamente superior em seu desenho, implementação e manutenção do que técnicas usuais de divulgação de microdados ou dados agregados.

- (V) **Dados sintéticos** *Dados sintéticos* são dados especialmente criados para substituir dados reais em divulgações de microdados ou para geração de dados tabulares. Os dados sintéticos são gerados de forma a preservar algumas propriedades estatísticas dos dados originais, tais como distribuições marginais, médias e quartis. A geração de dados que respeita todas as correlações entre as variáveis ainda é um problema complexo que se discute hoje na literatura de privacidade diferencial. Entretanto, diversos métodos podem ser utilizados para gerar modelos apropriados para a criação de dados sintéticos de tal forma que ainda seja possível realizar inferências válidas a partir deles. Dados sintéticos têm particular aplicação em cenários de aprendizado de máquina, em que os dados são usados para treinar algum

modelo.

Destaque: A literatura apresenta técnicas de mitigação de danos à privacidade para várias formas de divulgação de informação, incluindo aquelas baseadas em: (i) microdados; (ii) dados agregados; (iii) salas seguras; (iv) aplicações web; e (v) dados sintéticos. Cada uma dessas formas possui vantagens e desvantagens em termos da privacidade garantida aos titulares e da utilidade provida aos analistas, mas podem ser combinadas em uma estratégia holística de governança de dados. Embora no contexto dos Censos Educacionais do Inep haja uma expectativa arraigada de que os analistas sempre tenham acesso a microdados, a literatura técnica é inequívoca sobre a dificuldade de se proverem garantias de privacidade individuais sobre estes dados sem um custo significativo em sua utilidade. Soluções mais modernas de divulgação de microdados se baseiam em privacidade diferencial local, que demandam uma quantidade significativamente maior de recursos humanos e computacionais para sua implementação, além de tenderem a diminuir a utilidade dos dados para os analistas. Soluções intermediárias combinam a divulgação pública de apenas dados agregados protegidos com alguma forma de privacidade diferencial, enquanto garantem acesso a microdados via salas seguras –físicas ou virtuais– com controle de acesso.

3.1.2 Compromisso entre privacidade e utilidade

Conforme mencionado anteriormente neste projeto, é amplamente conhecida na literatura técnica sobre controle de divulgação estatística a dificuldade inerente de se conciliar a utilidade da informação prestada aos analistas com a privacidade dos titulares dos dados [49, 58, 24, 70, 10, 57]. De fato, todo método de mitigação de degradação de privacidade vem acompanhado de um maior ou menor custo à utilidade da informação divulgada. A seguir discutimos as principais dimensões deste problema.

Destaque: A literatura técnica apresenta avanços constantes e contínuos na conciliação de privacidade e utilidade em divulgações estatísticas, com novas soluções sendo produzidas em um ritmo acelerado. Entretanto, a ciência pode apenas informar quais são as possíveis configurações do compromisso entre privacidade e utilidade atingíveis em variados contextos, assim como o custo necessário para se atingir cada configuração. A decisão final em cada caso concreto abarca, além de questões técnico-científicas, também dimensões políticas e sociológicas, que devem ser cuidadosamente ponderadas. Harmonizar interesses conflitantes por parte de vários atores é um desafio não trivial. No caso dos Censos Educacionais do Inep, os atores incluem os titulares de dados (estudantes, professores, escolas, etc.), analistas (demógrafos, entidades civis e governamentais, etc.), o governo (que regulamenta tanto questões de privacidade quanto de transparência e acesso à informação), além do próprio Inep (que tem que conciliar de

forma realista as demandas dos vários atores com a sua capacidade e recursos para atendê-las). Além disso, o Inep dispõe de um prazo exíguo para implementação de uma solução que atenda às demandas da LGPD. Dada esta restrição de tempo, o Inep deve considerar adotar uma solução emergencial de curto prazo que garanta a privacidade dos titulares –mesmo que seja possivelmente sub-ótima em relação à utilidade provida aos analistas (ou vice-versa)–, enquanto elabora-se uma alternativa de longo prazo que forneça um melhor custo-benefício na relação de privacidade e utilidade.

No restante desta seção sumarizamos alguns resultados fundamentais sobre o compromisso entre utilidade e privacidade que consideramos relevantes para uma tomada de decisão bem informada por parte do Inep no contexto do presente projeto. Nos focamos aqui nas lições e implicações práticas de cada resultado, reservando detalhes técnicos para o Anexo A.

- (I) **Desafios na escolha de uma noção formal de privacidade adequada.** Cada método apresentado neste documento adota sua própria noção de garantia de privacidade. O Inep deve compreender estas garantias e avaliar qual delas melhor se adequa ao cenário de seus Censos Educacionais, com especial foco nas expectativas de privacidade individual previstas na LGPD.

Com exemplo, métodos sintáticos de divulgação de microdados podem prover garantias apenas contra ataques de reidentificação (anonimidade- k , Seção 4.1.1), apenas contra ataques determinísticos de inferência de atributo (diversidade- ℓ , Seção 4.1.2), ou apenas contra ataques probabilísticos de inferência de atributo em uma única base de dados (proximidade- t , Seção 4.1.3). Nenhum destes métodos, entretanto, é composicional, e portanto eles falham em proteger indivíduos contra ataques que usem múltiplas bases. Esta preocupação é particularmente crucial no caso dos Censos Educacionais do Inep, que são divulgados com frequência anual e constituem, portanto, uma base longitudinal em crescente expansão.

A divulgação de microdados por amostragem de forma não perturbativa (Seção 4.2), por outro lado, provê garantias de proteção para a maioria, ou a média, dos titulares dos dados, mas não para indivíduos isoladamente. Conforme argumentado por Dwork [47], o uso destas técnicas de forma indevida pode permitir que, mesmo que com baixa probabilidade, alguns indivíduos tenham sua privacidade severamente comprometida (como ilustrado no Exemplo 6). A permanência de riscos individuais pode ser considerada inaceitável, dependendo da interpretação legal da LGPD.

Por fim, métodos que se baseiam em privacidade diferencial (Seção 6) proveem garantias individuais e são composicionais, o que os coloca no estado da arte do controle de divulgação estatística. Entretanto, tais métodos têm garantias muito mais intrincadas de se atingir apropriadamente, demandando mais recursos e expertise que outras técnicas. Tais garantias também são, frequentemente, de difícil

compreensão por parte de analistas e titulares de dados. Uma outra dificuldade crucial no uso de privacidade diferencial é a obtenção de uma boa utilidade dos dados.

Destaque: O Inep deve escolher criteriosamente qual a garantia de privacidade adotar, levando em conta sua aderência às expectativas de privacidade individual garantias pela LGPD. Métodos sintáticos proveem garantias em uma única base, mas não em bases longitudinais; amostragem não perturbativa de microdados provê garantias coletivas, mas não individuais. As garantias de privacidade mais robustas atualmente conhecidas se baseiam em alguma variante de privacidade diferencial. Entretanto tais métodos demandam um expertise e investimento significativamente maior em seu desenho e implementação do que métodos menos refinados, além de serem mais complexos de se explicarem a analistas e titulares de dados.

(II) **Desafios no dimensionamento do ruído necessário para soluções baseadas em privacidade diferencial.** Kifer e Machanavajjhala, assim como Dwork, ressaltam que métodos efetivos de proteção de privacidade precisam se certificar que qualquer evidência de participação (ou do valor dos registros) de um indivíduo em uma base seja ofuscada, e não somente se um registro relativo àquele indivíduo está ou não presente na base de dados [49, 70].

Muitos métodos de mitigação de privacidade assumem que indivíduos são incluídos ou excluídos de bases de dados de forma independente uns dos outros. Esta hipótese, entretanto, nem sempre é verdadeira. Kifer e Machanavajjhala demonstraram que se o processo de geração dos dados cria correlações entre os indivíduos presentes na base de dados, pode ser possível que o adversário infira a presença de indivíduos de forma indireta [70]. Eles ilustram o problema com uma rede social em que a presença ou ausência de um indivíduo em um momento do tempo pode ter um efeito de longo prazo na configuração da rede. Discutimos tal exemplo em mais detalhes no Anexo A.1. No contexto dos Censos Educacionais do Inep também é possível, em princípio, haver correlações entre registros de diferentes indivíduos.⁴

De forma geral, podemos contornar esse problema adicionando mais ruído aos dados. O ruído a ser introduzido de uma consulta de contagem, por exemplo, cresce com a multiplicidade de registros que podem se referir a um mesmo indivíduo; se

⁴Considere, por exemplo, uma professora que se mude de estado, levando seus dois filhos em idade escolar consigo. Isto faz com que ao menos 3 registros –sendo 1 na tabela referente a docentes e 2 na tabela referente a discentes– sejam alterados em bloco. Portanto, a decisão de se mudar por parte da professora tem impacto em pelo menos 3 registros, e não apenas um. Um adversário que saiba da situação familiar da professora pode checar os registros de seus filhos para inferir informação a respeito dela. Outra fonte possível de correlações entre registros é quando um mesmo estudante está matriculado em mais de um curso por ano e tem, portanto, vários registros na mesma base de dados.

esta multiplicidade for grande, o ruído pode se tornar deletério demais à utilidade dos dados.⁵ Desta forma, é necessário um estudo cuidadoso sobre quais as correlações entre os registros nos Censos Educacionais para avaliação da eficácia de definições de privacidade como a privacidade diferencial.

Desafio identificado: Uma eventual adoção de soluções baseadas em privacidade diferencial na divulgação dos Censos Educacionais do Inep demandaria um estudo profundo e minucioso das correlações existentes entre registros nas bases de dados. Tal estudo é fundamental para encontrar o nível mínimo de ruído demandado para se garantir a privacidade em cada divulgação, sob pena de se estar comprometendo sua utilidade além do estritamente necessário.

- (III) **No geral não existe mecanismo de divulgação de dados que garanta privacidade e, ao mesmo tempo, seja perfeitamente útil para todos os analistas.** Em geral, analistas podem ter objetivos variados e buscar informações diferentes a partir de uma mesma base. Um mecanismo que se foque em atender a um objetivo específico de um analista pode causar danos à utilidade dos dados para outros analistas com objetivos distintos.

Um *mecanismo ótimo* para um analista é aquele que respeita suas preferências e tolerâncias com relação ao ruído é adicionado. O seguinte exemplo ilustra, entretanto, que mecanismos que satisfazem um analista podem prejudicar a outro.

Exemplo 1 (Utilidade pode variar de acordo com o analista de dados). Considere uma base de dados que contém informações sobre alunos de escolas públicas e particulares da Educação Básica. Essa base possui um identificador único por registro, o ano escolar do aluno e se a escola em que ele está matriculado é pública ou privada.

Após sua publicação, analistas podem consultar essa base de dados através de um mecanismo privado desenhado para não possibilitar a reidentificação de qualquer estudante a partir das informações sobre seu ano escolar e se ele estuda na rede pública ou privada.

Considere dois analistas potenciais para esta base:

- Um pesquisador da área de saúde pública que deseja realizar uma pesquisa relacionada a *bullying* na infância está interessado na resposta da consulta

⁵Por exemplo, considere um aluno que em um mesmo ano se matriculou em 3 cursos distintos, tendo todos os vínculos registrados em uma base de dados. Considere ainda um mecanismo de consulta que satisfaça privacidade diferencial- ϵ e que responda a pergunta “*Quantos novas matrículas foram feitas neste ano?*”. Tal mecanismo deverá adicionar ruído para esconder a participação do indivíduo na base; como o indivíduo participa 3 vezes na base, o ruído deve ser pelo menos 3 vezes maior do que seria caso dada indivíduo pudesse aparecer na base uma única vez.

“Qual a quantidade total de crianças em cada ano escolar?”. O pesquisador pretende comparar os resultados com dados conhecidos sobre as faixas etárias em que o *bullying* acontece com maior frequência na vida das crianças, para argumentar a favor de centros de apoio psicológico para crianças naquela população.

- Uma pesquisadora associada a uma escola de ensino privado está interessada na resposta “Quantas crianças estão matriculadas em escolas particulares em comparação com escolas públicas?”. De posse dessa resposta, ela avaliará se a abertura de uma nova unidade de escola do ensino privado para aquela população seria bem aceita e traria lucro para a rede de ensino em que ela trabalha.

Considerando consultas que retornam valores inteiros como resposta (e.g., “Qual a quantidade total de alunos em cada ano escolar?” ou “Qual a quantidade de alunos matriculados em escolas de ensino privado no 5º e 6º anos?”), três mecanismos podem ser usados. Todos perturbam os dados com ruído (e.g., via privacidade diferencial global ou local, usando o mecanismo geométrico descrito na Seção 6.2.3):

- O mecanismo M_1 adiciona pouco ruído à quantidade de alunos matriculados em cada ano escolar, mas adiciona muito ruído à quantidade de alunos por setor da educação (público ou privado).
- O mecanismo M_2 adiciona muito ruído à quantidade de alunos matriculados em cada ano escolar, mas adiciona pouco ruído à quantidade de alunos por setor da educação.
- O mecanismo M_3 adiciona uma quantidade moderada de ruído tanto à quantidade de alunos matriculados em cada ano escolar como à quantidade de alunos por setor da educação.

Claramente, o pesquisador ligado à saúde pública preferiria o mecanismo M_1 , enquanto consideraria o mecanismo M_2 inaceitável. Já para a pesquisadora associada a uma escola de ensino privado, a avaliação dos mecanismos M_1 e M_2 se invertéria. Por outro lado, o mecanismo M_3 seria sub-ótimo para ambos os atores: nem acurado, nem inaceitável.

Consequentemente, um curador que tenha que escolher somente entre os três mecanismos acima necessariamente frustraria a utilidade de pelo menos um analista. <

Neste contexto, seria desejável se obter, sempre que possível, o que se chama de *mecanismo ótimo universal*, i.e., um mecanismo capaz de ser simultaneamente ótimo para todos os (ou uma grande maioria dos) potenciais analistas da base de dados. As condições para a existência de tal mecanismo têm sido amplamente pesquisadas na literatura [58, 62, 24]. Infelizmente, entretanto, as situações em que tal mecanismo é possível são muito restritas. No Anexo A.2 provemos um sumário do estado da arte sobre o assunto.

Tendo em vista a grande variedade de analistas que podem consultar uma base de dados, é visivelmente impossível conseguir prever todas as suas finalidades, de modo a disponibilizar mecanismos ótimos individualizados para cada um deles.

Nesse sentido, para escolha do método de mitigação a ser utilizado nos Censos Educacionais o Inep precisa decidir qual a métrica de utilidade será adotada. Os mecanismos de mitigação de danos à privacidade podem ser, então, otimizados para maximizar a utilidade dos dados em relação a esta métrica. No geral, podemos classificar as métricas em dois tipos, como a seguir.

- **Métricas de utilidade específicas** partem do princípio de que uma divulgação será utilizada para uma tarefa preestabelecida e então medem a qualidade da divulgação para esta tarefa. Por exemplo, quando um conjunto de dados serve de treino para técnicas de aprendizado de máquina, é comum adotarem-se métricas de utilidade relacionadas à qualidade da tarefa de classificação pretendida (e.g., acurácia em relação à decisão sobre se um aluno tem maior ou menor chance de cursar um curso universitário).
- **Métricas de utilidade de propósito geral** tentam diminuir ao máximo a distorção entre os dados originais e os dados tratados. No caso de *k-anonymity* e outros métodos sintáticos para divulgação de microdados (discutido na Seção 4), por exemplo, é comum usarem-se métricas de propósito geral baseadas no tamanho das classes de equivalências geradas entre registros. No caso de dados sanitizados por privacidade diferencial local (discutida na Seção 6.3), é comum usarem-se métricas de propósito geral que quantificam distância (de acordo, e.g., com a medida de *Kullback-Leibler*) entre a distribuição induzida pelos dados reais e a induzida pelos dados sanitizados. A premissa central de tais métricas é que se a distribuição de probabilidade sobre registros após o tratamento for similar à distribuição antes do tratamento, então os dados tratados serão úteis para a maioria dos analistas aplicações.

O Anexo B apresenta um sumário de métricas de utilidade populares na literatura.

Destaque: No geral é impossível que um método de mitigação de degradação de privacidade seja completamente satisfatório para todos os possíveis analistas de dados. O Inep deve optar entre: (i) priorizar algum(ns) tipo(s) de analista e adotar uma métrica de utilidade que reflita seus objetivos; ou (ii) adotar métricas de utilidade de propósito geral que satisfaçam de forma razoável (porém não necessariamente perfeita) uma grande parte dos analistas. Os mecanismos de mitigação de danos à privacidade podem ser, então, otimizados para maximizar a utilidade dos dados em relação à métrica escolhida.

(IV) **Limitação da granularidade das informações prestadas via divulgação de histogramas, dados agregados, ou privacidade diferencial global**

Um dos principais resultados no estudo de privacidade em publicações estatísticas diz respeito à reconstrução das bases de dados subjacentes a divulgações estatísticas. Dinur e Nissim demonstraram que um adversário que realiza um número relativamente pequeno de consultas a uma base pode, talvez surpreendentemente, obter informação suficiente para inferir os registros de todos os indivíduos da base (e, conseqüentemente, inferir todos os seus atributos sensíveis) [43]. O estudo mostra que o número de consultas necessário para reconstruir completamente a base de dados subjacente a uma publicação estatística depende diretamente da quantidade de ruído adicionado às respostas das consultas: quanto menos ruído é adicionado, mais fácil é para o adversário reconstruir a base.⁶

Claramente o resultado de Dinur e Nissim representa más notícias para a utilidade dos dados. De fato, quanto maior o ruído adicionado às respostas das consultas, menor é a utilidade dos dados. Desta forma, ao utilizar privacidade diferencial, é necessária uma avaliação cautelosa da ordem do ruído ε a ser adicionado em cada consulta para que a utilidade dos dados seja maximizada sem que a base de dados possa ser reconstruída por um adversário. Para que não haja perda significativa de utilidade, é recomendado que o ruído seja baixo. Entretanto, isso implica na avaliação detalhada de especialistas no assunto.

Desafio identificado: Mecanismos de privacidade diferencial global impõem limitações sobre o número máximo de consultas que analistas podem realizar sem incorrer em uma degradação inaceitável à privacidade dos indivíduos. De forma semelhante, métodos de divulgação de histogramas e de sumários estatísticos apresentam limitação na quantidade de informação que pode ser disponibilizada. A escolha de qualquer um destes métodos demanda um estudo detalhado de quais as limitações da informação que pode ser prestada.

(V) Mecanismos de privacidade diferencial local geralmente têm alto custo na utilidade dos dados

Métodos baseados em privacidade diferencial local contornam o problema de limitação da informação divulgada ao sanitizar a base de uma vez por todas e divulgá-la publicamente. Por outro lado, tais métodos tendem a degradar de forma mais significativa a utilidade dos dados. Mais precisamente, como discutido na Seção 6.3, a privacidade diferencial local apresenta várias vantagens, em especial:

- (i) Ela permite a divulgação de microdados de forma privada com garantias para todos os indivíduos participantes das bases.

⁶Mais precisamente, para uma base de dados com n registros em que um ruído $\varepsilon < \sqrt{n}$ é adicionado ao resultado de cada consulta realizada, o adversário pode reconstruir completamente a base de dados em tempo razoável (i.e., polinomial no tamanho da entrada) se a quantidade total de consultas não for apropriadamente limitada, causando violação da privacidade. Uma discussão aprofundada deste resultado encontra-se no Anexo A.3.

- (ii) Ela não demanda do Inep a curadoria de quais consultas podem ser feitas à base e por quais analistas, permitindo que uma única base sanitizada seja divulgada e que os analistas possam trabalhar livremente em cima dela.

Por estas razões a privacidade diferencial local tem sido adotada por empresas como Apple [90, 2], Google [53] e Microsoft [42]. Entretanto, a privacidade diferencial local impõe, de forma geral, um custo muito maior à utilidade dos dados. De fato, há desafios técnicos elevados para a implementação satisfatória deste tipo de método [37]. Dependendo do contexto, o uso de privacidade diferencial pode prejudicar de forma irremediável a utilidade dos dados.

A fim de contornar alguns dos pontos negativos da privacidade diferencial, variantes mais refinadas têm sido propostas e estudadas a fundo. Em particular, podemos destacar a privacidade diferencial- (ϵ, δ) , que permite violações de privacidade raras em troca de uma maior utilidade dos dados (apresentada no Anexo D.1) e a privacidade- d , que explora a noção de indistinguibilidade entre segredos para aumentar a utilidade de divulgações (apresentada no Anexo D.2). Ambas as variantes podem apresentar vantagens significativas sobre a privacidade diferencial tradicional em termos da utilidade dos dados divulgados. Entretanto, elas demandam um expertise substancialmente maior do desenhista da solução, além de mais tempo e recursos, para que tais benefícios sejam atingidos.

Destaque: A privacidade diferencial local permite a divulgação de microdados sanitizados para os analistas de uma vez por todas, sem a demanda por mais interferências por parte do Inep. Entretanto, é reconhecido que este tipo de técnica impõe um custo muito elevado e, por vezes, proibitivo à utilidade dos dados. A eventual adoção da privacidade diferencial local nos Censos Educacionais demandaria um expertise substancialmente maior do desenhista da solução, além de mais tempo e recursos, para se averiguar se os benefícios da técnica podem ser efetivamente atingidos neste contexto.

3.1.3 Ataques longitudinais

A divulgação anual dos Censos Educacionais pelo Inep apresenta uma camada extra de complexidade ao problema, pois abre a possibilidade de ataques longitudinais –i.e., ataques em que o adversário combina informação de várias bases para aumentar sua chance de sucesso.

No Exemplo 5 ilustramos a vulnerabilidade de métodos sintáticos não perturbativos a ataques composicionais e longitudinais (aqueles em que o adversário observa não só uma, mas várias bases de dados em conjunto). O método anonimidade- k , por exemplo, garante que qualquer indivíduo será indistinguível de pelo menos outros $k-1$, em relação a um conjunto de atributos. Esta garantia, porém, é mantida somente em uma única

base de dados. Suponha que existam duas bases de dados D_1 e D_2 , onde a primeira seja k_1 -anônima, e a segunda, k_2 -anônima. Temos a garantia de que cada indivíduo em D_1 é indistinguível de pelo menos outros k_1-1 , e cada indivíduo em D_2 é indistinguível de outros k_2-1 em suas respectivas bases. Porém, se um adversário realizar um ataque utilizando ambas as bases, não há garantias de o indivíduo não possa ser reidentificado. As garantias dos outros métodos sintáticos apresentados na Seção 4.1 também são quebradas quando o adversário tem acesso a múltiplas bases.

Por outro lado, a privacidade diferencial é mais robusta contra esse tipo de ataque, por ser composicional (conforme explicado nas Seções 6.2.4 e 6.3.4). A composicionalidade da privacidade diferencial, entretanto, se degrada à medida em que o número de bases no conjunto longitudinal aumenta. De fato, é conhecido na literatura que, mesmo com os trabalhos mais recentes na área, ainda não é possível alcançar uma solução definitiva para o problema de ataques longitudinais. O Anexo G discute uma das poucas alternativas existentes para esta questão, que emprega privacidade diferencial. Mesmo no contexto dos Censos Decenais dos EUA, que são realizados periodicamente, a nova e refinada solução adotada para o Censo de 2020 (Seção 6.4.3) não prevê nenhuma garantia explícita contra este tipo de ataque.

Desafio identificado: As bases dos Censos Educacionais do Inep são divulgadas periodicamente, com frequência anual, gerando um conjunto longitudinal de dados crescente. Não é incomum que cidadãos brasileiros se encontrem, ao longo de sua vida, em várias das pesquisas do Inep (e.g., de diferentes anos dos Censos da Educação Básica e Superior, além do ENEM.). A eventual opção do Inep por divulgar microdados destas pesquisas com frequência anual apresenta desafios consideráveis para mitigação de danos à privacidade causados por ataques longitudinais. A literatura ainda não apresenta uma solução definitiva para o problema de ataques longitudinais em microdados, e é possível que a busca por garantias de privacidade longitudinais limite o Inep à publicação de apenas dados agregados.

3.2 Sumário comparativo dos métodos apresentados neste documento

No restante deste documento apresentamos as principais técnicas de mitigação de danos à privacidade da literatura de controle de divulgação estatístico. Na presente seção provemos quadros-sumários destes métodos, que podem ajudar o leitor a se orientar na comparação dos mesmos. Os quadros estão organizados da seguinte forma:

- a Tabela 3.2.1 apresenta um quadro-sumário dos métodos não perturbativos para divulgação de microdados (detalhados na Seção 4), incluindo técnicas sintáticas de anonimidade- k , diversidade- ℓ e proximidade- t , além de amostragem de microdados;

- a Tabela 3.2.2 apresenta um quadro-sumário dos métodos não perturbativos para divulgação de dados agregados ou tabulares (detalhados na Seção 5), incluindo sumários estatísticos e histogramas; e
- a Tabela 3.2.3 apresenta um quadro-sumário dos métodos baseados em privacidade diferencial (detalhados na Seção 6), incluindo sua variante global e local, além de outras aplicações como divulgação por amostragem, histogramas e dados sinéticos, e o estudo de caso do Censo dos EUA em 2020.

O Anexo H ilustra a aplicação de variados métodos de mitigação de degradação à privacidade descritos neste documento a uma mesma base de tamanho reduzido, especialmente criada como exemplo.

3.3 Recomendações e plano de ação proposto

Nesta seção elaboramos nossas recomendações para a mitigação de danos à privacidade na divulgação dos Censos Educacionais do Inep. As recomendações estão baseadas nas seguintes premissas:

- **Premissa 1:** A LGPD prevê garantias de privacidade individualmente a cada titular de dados –em especial, contra reidentificação.
- **Premissa 2:** Amostragem de microdados não proveem esta garantia, mas apenas garantias médias.
- **Premissa 3:** Métodos sintáticos não proveem garantias composicionais, impedindo o Inep de aplicar tais medidas independentemente em cada uma de suas bases.
- **Premissa 4:** O Inep possui apenas alguns meses para adequar suas formas de divulgação às exigências da LGPD.

Neste contexto, recomendamos ao Inep um plano de ação dividido nas seguintes etapas.

- **Etapa 1:** Eliminar imediatamente a divulgação de microdados em qualquer forma, a fim de garantir a privacidade em nível individual exigida pela LGPD. Esta medida inclui a remoção de todas as bases dos Censos Educacionais já publicadas pelo Inep de seus canais de comunicação.
- **Etapa 2:** Oferecer apenas informações agregadas em seus canais públicos de comunicação. Recomendamos a publicação de sumários estatísticos e/ou histogramas protegidos com privacidade diferencial. Esta etapa possui as seguintes sub-etapas:
 - **Etapa 2.a:** Identificar preliminarmente (levando em consideração o exíguo tempo disponível para atender a LGPD) os usos mais comuns dos dados pelos analistas de dados dos Censos Educacionais.

- **Etapa 2.b:** Desenhar variadas configurações de sumários estatísticos e histogramas que atendam às utilidades levantadas na Etapa 2.a.
- **Etapa 2.c:** Implementar os algoritmos de privacidade diferencial para construção dos dados agregados escolhidos na Etapa 2.b.
- **Etapa 2.d:** Executar a otimização de parâmetros para atingir o melhor custo-benefício de privacidade e utilidade com os dados divulgados.
- **Etapa 3:** Possibilitar a analistas o acesso a microdados apenas com autorização prévia e em salas seguras, considerando a viabilidade de salas seguras virtuais. Esta etapa pode ser realizada concomitantemente com a anterior.

Reconhecidamente, a solução acima está contingenciada pela significativa restrição de tempo para execução do presente TED 8750. Além disso, ela tem o efeito colateral de aumentar a demanda por acesso a salas seguras. Para contornar este problemas, sugerimos ao Inep considerar, futuramente, a seguinte continuação do plano.

- **Etapa 4:** Uma vez assegurado nível de privacidade individual dos dados demandado pela LGPD (obtido pela combinação das Etapas 1 e 2), iniciar um estudo aprofundado de como aumentar a utilidade das divulgações enquanto se mantém a privacidade conquistada. O aumento gradual da utilidade dos dados visa a satisfazer a um número cada vez maior de analistas, o que pode contribuir para arrefecer a demanda crescente por acesso a salas seguras eventualmente causada pela implementação das Etapas 1 e 2 acima. Esta etapa contém as seguintes sub-etapas:
 - **Etapa 4.a:** Aprofundar o estudo sobre os usos mais comuns dos dados dos Censos Educacionais por analistas, de forma a identificar as métricas de utilidade a serem priorizadas. Apesar de ser geralmente impossível atender a todas as demandas de utilidade de forma satisfatória, pode-se otimizar a solução para os usos mais comuns, potencialmente desafogando a busca por microdados. Esta etapa pode ser imediatamente utilizada no redesenho de quais dados agregados divulgar.
 - **Etapa 4.b:** Estudar o comportamento do uso de privacidade diferencial local, produzindo microdados sanitizados, diretamente nos Censos Educacionais do Inep. Esta etapa provavelmente demandará a eliminação de vários atributos das divulgações. Será preciso, ainda, um ajuste criterioso dos parâmetros que controlam o compromisso de utilidade e privacidade na privacidade diferencial local.
 - **Etapa 4.c:** Estudar o comportamento do uso de privacidade diferencial em amostragem de microdados, produzindo microdados sanitizados, diretamente nos Censos Educacionais do Inep.
 - **Etapa 4.d:** Considerar o uso de variantes da privacidade diferencial que apresentam vantagens significativas sobre a privacidade diferencial tradicional

em termos da utilidade dos dados divulgados: (i) a privacidade diferencial- (ε, δ) , que permite violações de privacidade raras em troca de uma maior utilidade dos dados (Seção D.1); e (ii) a privacidade- d , que explora a noção de indistinguibilidade entre segredos para aumentar a utilidade de divulgações (Seção D.2).

Destaque: Acreditamos que as recomendações acima devem ser discutidas profundamente entre a equipe executora do presente TED 8750 e os representantes do Inep, a fim de que sejam apropriadamente esclarecidas antes de qualquer tomada de decisão.

Métodos sintáticos não perturbativos para divulgação de microdados - Seção 4.1			
Anonimidade- k - Seção 4.1.1		Diversidade- ℓ - Seção 4.1.2	Proximidade- t - Seção 4.1.3
Princípios gerais	Estes métodos assumem que o adversário conhece os valores de uma coleção predeterminada de atributos quaseidentificadores para um conjunto de indivíduos-alvo. Os métodos agrupam, então, os registros da base em blocos, usando operações de supressão e generalização de atributos para uniformizar os quaseidentificadores em cada bloco. Isto visa a tornar os registros dentro de cada bloco indistinguíveis para o adversário, permitindo aos titulares um certo nível de negação plausível sobre sua informação sensível.		
Noção de proteção de privacidade	Sabendo apenas os valores de uma coleção predeterminada de quaseidentificadores, o adversário não consegue distinguir qualquer indivíduo de pelo menos outros $k-1$ na base.	Sabendo apenas os valores de uma coleção predeterminada de quaseidentificadores, o adversário fica em dúvida entre pelo menos ℓ valores para o atributo sensível de cada indivíduo.	Aprender apenas os valores de uma coleção predeterminada de quaseidentificadores não altera significativamente o conhecimento probabilístico do adversário a respeito dos atributos sensíveis de cada indivíduo.
Complexidade e custos de implementação	O algoritmo apresentado em [71] pode ser utilizado para implementar as três técnicas com complexidade computacional $\mathcal{O}(n \cdot m)$, onde n é o número de registros e m é o número de atributos da base de dados. Uma implementação já está disponível na ferramenta ARX [91], suportando tabelas que contenham até $2^{31} - 1 \approx 2.1$ bilhões de células (número de registros $\times$ número de atributos). A eventual adoção destes algoritmos pelo Inep demandaria uma extensão da ferramenta ARX, uma vez que as bases dos Censos Educacionais podem exceder em muito este limite: só o Censo do Ensino Básico de 2019 já possui cerca de 5.3 bilhões de células (105 colunas e 51 milhões de registros).		
Prós	As garantias providas pelos métodos são facilmente compreensíveis e comunicáveis tanto aos titulares quanto aos analistas de dados. Ao usar apenas generalização e supressão de atributos, os métodos são não perturbativos e não inserem ruído ou valores falsos nos dados. Há algoritmos eficientes para implementação dos métodos, e não é demandada expertise avançada para seu uso e manutenção.		
Contras	Protege apenas contra ataques de reidentificação, mas não contra a inferência de atributos sensíveis. Não é composicional.	Protege contra ataques de reidentificação e inferência determinística de atributos sensíveis, mas permite ao adversário ganhar conhecimento probabilístico sobre tais atributos. Não é composicional.	Não é composicional, significando que mesmo que duas bases sejam protegidas independentemente com proximidade- t , um adversário pode combinar as bases para quebrar a garantia.
Observações	Suas garantias dependem de hipóteses fortes sobre conhecimento auxiliar do adversário: (i) há garantias apenas contra o uso de um conjunto predeterminado de quaseidentificadores, mas a definição de quais atributos podem ou não contar como quaseidentificadores varia com o tempo e o espaço; e (ii) Aggarwal [9] demonstrou que quando o número de quaseidentificadores é grande, tais métodos devem apagar a maior parte das entradas para atingir as garantias de anonimidade- k , diversidade- ℓ ou proximidade- t , o que degrada de forma significativa a utilidade dos dados. Família de métodos abandonada por grande parte da comunidade [36], utilizada somente em situações em que ruído seja intolerável (e.g., em pesquisas médicas).		
Divulgação não perturbativa de microdados por amostragem - Seção 4.2			
Princípios gerais	Em vez de se divulgar todo o conjunto de microdados, uma amostra é aleatoriamente selecionada para publicação.		
Noção de proteção de privacidade	Espera-se que, mesmo que o adversário consiga isolar na base um único registro que combine com a informação auxiliar que ele possui sobre um indivíduo-alvo, não haja certeza de se o registro isolado pertence mesmo ao alvo pois ele pode nem mesmo estar na amostra.		
Complexidade e custos de implementação	Facilmente implementável, mas a escolha das amostras tem que ser feita cuidadosamente para se preservarem as propriedades estatísticas da população.		
Prós	Método fácil de compreender e de comunicar tanto aos titulares quanto aos analistas de dados. No geral sua aplicação pode levar a uma significativa redução do risco médio dos indivíduos na base (tanto de reidentificação quanto de inferência de atributo).		
Contras	Como apontado por Dwork [47], apesar da amostragem poder reduzir o risco médio dos titulares, ela não garante privacidade em nível individual. Indivíduos com valores raros de quaseidentificadores ainda podem ser vítimas de ataques na base amostral.		
Observações	Há métodos mais sofisticados para tornar a amostragem de microdados mais segura, utilizando principalmente a privacidade diferencial. Estas abordagens são cobertas na Seção 6.4.1.		

Tabela 3.2.1: Sumário dos métodos não perturbativos para divulgação de microdados.

Métodos não perturbativos para divulgação de dados agregados ou tabulares - Seção 5		
	Divulgação de sumários estatísticos - Seção 5.1	Divulgação de histogramas - Seção 5.2
Princípios gerais	O curador de dados divulga uma coleção de repostas a consultas estatísticas predefinidas (e.g., médias, medianas, contagens, etc.), mas não permite que analistas realizem sua próprias consultas (potencialmente de forma controlada) nem tenham acesso aos microdados da base.	O curador de dados divulga uma tabela em que cada linha consiste em um par contendo um possível valor para um conjunto pré-selecionado de atributos e o número de registros na tabela que apresenta exatamente aquele valor para os atributos. Podem-se divulgar histogramas com diferentes níveis de correlações entre os atributos; a maior correlação possível acontece quando o histograma equivale à base de dados original, enquanto a menor ocorre quando divulgam-se apenas as distribuições marginais de cada atributo. Entretanto, há um ponto intermediário onde divulga-se a distribuição conjunta de dois, três, ou mais atributos.
Noção de proteção de privacidade	Em ambos os métodos assume-se que a proteção de um indivíduo é aumentada por sua indistinguibilidade dentro da informação agregada. Esta premissa, entretanto, não é válida para garantias individuais, apenas garantias médias.	
Complexidade e custos de implementação	Relativamente fácil de implementar, desde que as escolhas das estatísticas a serem computadas já esteja feita.	Relativamente fácil de implementar para histogramas conjuntos de poucas variáveis. O método demanda mais recursos quando se deseja otimizar a granularidade de cada célula do histograma em relação à utilidade provida.
Prós	Métodos fáceis de compreender e explicar tanto a analistas quanto a titulares de dados. Quando executada de forma criteriosa, a divulgação tanto de sumários estatísticos quanto de histogramas provê mais privacidade que a divulgação de microdados.	
Contras	Proveem pouca utilidade em análises finas. Dependem de análise do curador pra priorizar quais sumários ou histogramas publicar, levando possivelmente à insatisfação de alguns analistas de dados. Apesar de sumários estatísticos e histogramas proverem, no geral, um nível médio de privacidade mais elevado do que o permitido pela divulgação de microdados, eles não apresentam garantias individuais: (i) alguns indivíduos com características raras ainda podem ter sua privacidade violada; e (ii) adversários podem usar cruzamentos de dados para ferir a privacidade de indivíduos.	
Observações	O Documento 22 [87], que descreve o que as agências federais dos EUA adotavam em 2005 como formas de divulgação de informação, reconhece que a simples agregação não garante necessariamente a proteção dos mesmos, e diversas técnicas aplicáveis a microdados já eram aplicadas à época também a dados agregados de magnitude e de frequência. A divulgação de sumários e histogramas é um método muito usado por agências internacionais, entretanto em versão que satisfaça privacidade diferencial, conforme discutido na Seção 6.4.2.	

Tabela 3.2.2: Sumário dos métodos não perturbativos para divulgação de dados agregados ou tabulares.

Privacidade diferencial - Seção 6			
Privacidade diferencial global - Seção 6.2		Privacidade diferencial local - Seção 6.3	
Princípios gerais	O curador mantém uma base contendo os dados reais de cada titular. A cada consulta enviada pelo analista, um mecanismo randomizado é aplicado da seguinte forma: primeiro a consulta é realizada na base de dados, obtendo uma resposta real, e em seguida ruído é adicionado a essa resposta antes de reportá-la ao analista.	Ruído é adicionado aos dados de cada titular, e o curador agrupa esses dados já randomizados em uma base que pode ser considerada sanitizada de uma vez por todas. A partir daí, qualquer consulta é diretamente realizada sobre a base sanitizada, podendo o curador até mesmo divulgar esta base em sua forma completa para os analistas.	
Noção de proteção de privacidade	Princípio geral: <i>se o efeito de uma única alteração arbitrária na base de dados –seja pela inserção, remoção ou alteração de um único registro– for pequeno o suficiente, então naturalmente o resultado de uma divulgação não pode ser utilizado para inferir informação significativa sobre nenhum indivíduo.</i> A garantia de privacidade reside no fato de que se o adversário não consegue distinguir se um indivíduo faz ou não parte de uma pesquisa (ou qual é seu valor na pesquisa), então ele também não consegue distinguir nenhum valor sensível para este indivíduo.		
Complexidade e custos de implementação	Cada tipo de consulta e de dados demanda o desenho de um mecanismo específico. Parâmetros têm que ser ajustados cuidadosamente, sob pena de introduzir mais ruído que o estritamente necessário e, assim, comprometer desnecessariamente a utilidade das informações. A otimização de parâmetros é uma tarefa que pode demandar um tempo significativo, e deve ser feita após estudo criterioso das propriedades particulares do conjunto de dados em questão. Especialistas altamente qualificados são necessários no desenho e implementação de cada solução.		
Prós	Provê garantias de privacidade individuais. Apresenta composicionalidade, significando que se duas divulgações estão protegidas independentemente com privacidade diferencial, um adversário pode combinar as informações das mesmas sem degradar significativamente a garantia de privacidade. Apresenta maior utilidade que a privacidade diferencial local.	Provê garantias de privacidade individuais e também composicionalidade. Permite, em princípio, aplicar níveis de privacidade distintos para indivíduos distintos. Uma vez que a base seja sanitizada usando privacidade diferencial local, os microdados podem ser divulgados para os analistas sem risco de que a privacidade seja corrompida, eliminando o trabalho de curadoria contínua dos dados após sua publicação.	
Contras	Necessita do controle contínuo de um curador selecionando que consultas podem ser respondidas e com que nível de ruído.	Em comparação à privacidade diferencial global, tende a apresentar uma degradação de utilidade significativamente maior e, em muitos casos, proibitiva.	
Observações	A privacidade diferencial e suas variantes são consideradas o estado da arte em controle de divulgação estatística. Entretanto, as garantias de privacidade providas são em geral difíceis de entender e de comunicar tanto a analistas quanto a titulares de dados. A implementação de técnicas de privacidade diferencial necessita de acompanhamento de especialistas de forma próxima. Há variantes refinadas, como a privacidade diferencial- (ϵ, δ) , que permite violações de privacidade raras em troca de uma maior utilidade dos dados (Anexo D.1) e a privacidade- d , que explora a noção de indistinguibilidade entre segredos para aumentar a utilidade de divulgações (Anexo D.2).		
Outras aplicações de privacidade diferencial - Seção 6.4			
	Divulgação de microdados por amostragem - Seção 6.4.1	Divulgação de histogramas e dados sintéticos - Seção 6.4.2	A abordagem do Censo 2020 dos EUA - Seção 6.4.3
Princípios gerais	Dwork demonstrou que a pura amostragem de dados não é suficiente para garantia de privacidade individual [47]. Técnicas modernas combinam amostragem de dados com privacidade diferencial para contornar esse problema.	A privacidade diferencial global é aplicada a cada contagem de um histograma de forma a fornecer garantias de privacidade individuais aos participantes do estudo. Alternativamente, a distribuição dos dados pode ser aprendida usando privacidade diferencial, e a partir dela gerar-se uma base sintética, com distribuição semelhante, para divulgação.	O Escritório do Censo dos EUA (<i>United States Census Bureau</i> USCB) abandonou técnicas puramente sintáticas para divulgação de seus Censos Decenais a partir de 2020, e está propondo uma solução baseada em privacidade diferencial [57].
Observações	A ferramenta ARX [91] oferece suporte a um algoritmo que aplica princípios da privacidade diferencial na seleção das amostras dos microdados [21].	Divulgação de histogramas com privacidade diferencial é uma das maneiras mais modernas de divulgação de dados estatísticos. Já dados sintéticos são mais utilizados quando o objetivo é treinar algoritmos de aprendizado de máquina.	A implementação da privacidade diferencial pelo USCB enfrentou e enfrenta diversas dificuldades, tanto técnicas [57] quanto de comunicação com o restante da comunidade de estatística [82].

Tabela 3.2.3: Sumário dos métodos baseados em privacidade diferencial.

4 Especificação de métodos não perturbativos para divulgação de microdados

Nesta seção apresentamos um sumário dos principais métodos da literatura para divulgação de microdados –i.e., informação em nível individual– de forma não perturbativa. Tais métodos alteram a informação provida apenas por diminuir sua granularidade ou por suprimi-la por partes, sem, entretanto, introduzir informação inverídica.

Começamos pela apresentação de métodos sintáticos, que formulam condições de privacidade que podem ser checadas apenas analisando-se os dados produzidos. Em particular, definimos os métodos sintáticos de *anonimidade- k* , *diversidade- ℓ* e *proximidade- t* , apresentamos os algoritmos utilizados para implementá-los, e analisamos os prós e contras destes métodos. Em seguida, discutimos a divulgação de microdados por amostragem, em que um subconjunto dos dados é selecionado para publicação.

4.1 Métodos sintáticos

Métodos sintáticos são aqueles que formulam condições puramente sintáticas para a divulgação de informação, isto é, condições que se restringem à forma dos dados e não necessariamente incluem uma definição implícita de privacidade.

Nesta seção resumizamos os métodos sintáticos para divulgação de microdados mais influentes na literatura: *anonimidade- k* , *diversidade- ℓ* e *proximidade- t* . Tais métodos assumem que o adversário tem como informação auxiliar os valores de um conjunto de atributos quaseidentificadores para um conjunto de indivíduos-alvo, e pode cruzar essa informação com uma base de dados a fim de inferir informação sensível sobre estes indivíduos. A garantia de privacidade destes métodos consiste em agrupar registros na divulgação de forma a torná-los indistinguíveis do ponto de vista do adversário. Este agrupamento visa a permitir aos titulares um certo nível de negação plausível sobre sua informação sensível dentro do grupo em que eles se encontram.

Aqui consideramos apenas as versões não perturbativas destes métodos. Elas utilizam duas operações principais sobre os valores de quaseidentificadores das bases tratadas:

- *supressão*, em que os valores de certos atributos são eliminados da base e substituídos por um caractere especial (geralmente um asterisco “*”); e
- *generalização*, em que valores de alguns atributos são substituídos por uma categoria mais genérica (por exemplo, a idade exata de “37 anos” pode ser substituída por uma faixa genérica como “35 a 40 anos”, “maior que 30 anos”, ou “menor que 60 anos”).

4.1.1 Anonimidade- k

O método de *anonimidade- k* (*k-anonymity*, no original em inglês) é uma das primeiras e mais conhecidas técnicas de mitigação de danos à privacidade da literatura. O método foi originalmente proposto por Samarati e Sweeney [94] tendo em vista o seguinte objetivo [93, 102]: dado um conjunto de dados estruturados em nível individual (e.g., microdados), produzir uma divulgação destes dados com garantias científicas de que os titulares dos dados não possam ser reidentificados, ao mesmo tempo em que os dados permaneçam úteis de forma prática.

O método de *anonimidade- k* procura mitigar ataques de reidentificação (em que um registro de uma base de dados é associado a um titular específico). Mais precisamente, o método garante que mesmo que o adversário conheça os valores de um conjunto de quaseidentificadores para um indivíduo-alvo escolhido na base, ainda assim ele não seja capaz de distinguir o alvo de pelo menos outros $k-1$ registros na mesma base. Uma base que satisfaça esta propriedade é dita ser *k-anônima* ou *k-anonimizada*.

O exemplo abaixo ilustra a aplicação do método de *anonimidade- k* não perturbativo a uma base de dados, usando apenas operações de generalização e supressão de atributos.

Exemplo 2 (Aplicação de *anonimidade- k*). Considere a base de dados representada na Tabela 4.1.1a, em que o atributo *enfermidade* é considerado sensível. Se o adversário tem como informação auxiliar o fato de que Joana é uma mulher representada na base, que ela mora no Brasil, e que ela tem 25 anos, ele consegue reidentificá-la como titular do registro de *id* 1 (pois este é o único registro em que o valor dos atributos *região*, *sexo* e *idade* são, respectivamente, F, Brasil e 25). Além disso, o adversário pode imediatamente inferir que Joana tem gripe, o que seria uma violação da privacidade de seu atributo sensível.

Podemos aplicar o método de *anonimidade- k* a esta base para obter uma nova base sanitizada, representada na Tabela 4.1.1b, visando a garantir que nenhum registro apresente uma combinação única de valores para os quaseidentificadores *região*, *sexo* e *idade*. Mais precisamente, adotamos o valor $k=2$, de forma que cada registro tenha os valores destes quaseidentificadores indistinguíveis de pelo menos um outro registro. Esta base 2-anonimizada foi obtida através das seguintes operações:

- generalização do atributo *região*, substituindo os valores originais **Brasil**, **Bolívia**, **França** e **Espanha** pelo novo valor **Ocidente**; e substituindo os valores originais **Japão** e **China** pelo novo valor **Oriente**;
- supressão do atributo *sexo*; e
- generalização do atributo *idade* para as categorias $[18-29]$, $[30-44]$ e $[45-70]$ que agrupam idades por faixas, onde $[x-y]$ denota a faixa de idade “de x a y anos”.

Note que mesmo que o adversário saiba que Joana mora no Brasil, é mulher e tem 25 anos, ele não mais pode reidentificá-la com absoluta certeza na base sanitizada. De fato, sua informação auxiliar indica que os valores dos quaseidentificadores de Joana estão representados na base por *região*=**Ocidente**, *sexo*=*, e *idade*= $[18-29]$, mas há 2 registros na base com os mesmos valores (aqueles de *id*'s 1 e 2). De forma mais geral, mesmo que um adversário saiba os valores de *região*, *sexo* e *idade* de qualquer indivíduo, isso não é suficiente para reidentificar o alvo na base 2-anonimizada, pois sempre haverá pelo menos 2 indivíduos com a mesma combinação de valores para estes quaseidentificadores. $\triangleleft$

Limitações da anonimidade- k Apesar da anonimidade- k ser, no exemplo acima, efetiva contra ataques de reidentificação, ela não oferece garantias contra ataques de inferência de atributo sensível. Mais especificamente, se um agrupamento de k pessoas possuir o mesmo valor para um atributo sensível, mesmo sem saber qual registro exato corresponde ao alvo, o adversário pode inferir com absoluta certeza seu atributo sensível.

Considere, por exemplo, a base k -anonimizada da Tabela 4.1.1b. Se o adversário tiver como informação auxiliar que um indivíduo-alvo possui 50 anos de idade, ele pode reduzir os registros possivelmente correspondentes a este indivíduo a apenas 2 (os registros de *id*'s 5 e 6), e a anonimidade- k previne a reidentificação com absoluta certeza do alvo. Entretanto, ambos os registros retornados possuem o mesmo valor para o atributo *enfermidade* (AIDS), e o adversário é, assim, capaz de inferir o valor do atributo sensível.

Esta limitação da anonimidade- k em mitigar ataques de inferência de atributos sensíveis levou à elaboração da técnica mais refinada de diversidade- ℓ , que cobrimos a seguir.

4.1.2 Diversidade- ℓ

O método de *diversidade- ℓ* (*ℓ -diversity*, no original em inglês) foi proposto por Machanavajjhala, Kifer, Gehrke e Venkitasubramaniam [77] como um refinamento do método de anonimidade- k . A técnica visa a mitigar o risco de inferência de atributos ao exigir que após o agrupamento de registros via supressão e generalização de quaseidentificadores, qualquer atributo sensível possua ao menos ℓ valores distintos dentro de cada grupo.

Formalmente, a diversidade- ℓ se baseia no seguinte princípio: um grupo de registros é ℓ -diverso se ele contém pelo menos ℓ valores distintos para qualquer atributo sensível. Uma base de dados é dita ser ℓ -diversa se todo subgrupo de registros é ℓ -diverso.

Abaixo provemos um exemplo que ilustra a aplicação não perturbativa de diversidade- ℓ .

Exemplo 3 (Aplicação de diversidade- ℓ). Considere novamente a base de dados k -anonimizada representada na Tabela 4.1.1. Recorde que, mesmo após a base ter sido k -anonimizada, conforme a Tabela 4.1.1b, um adversário que saiba apenas que um indivíduo-alvo tem 50 anos de idade ainda poderia inferir com absoluta certeza que tal indivíduo é portador de AIDS.

Para mitigar este ataque de inferência de atributo sensível, aplicamos o método de diversidade- ℓ à base original, obtendo a nova base representada na Tabela 4.1.1c. Também neste caso consideramos como quaseidentificadores os atributos *região*, *sexo* e *idade*. O método visa, então, a garantir que não seja possível inferir com absoluta certeza qual o valor do atributo sensível *enfermidade* após o agrupamento de registros por quaseidentificadores. Estabelecemos $\ell = 2$, de forma que qualquer subgrupo de registros selecionado utilizando valores de *região*, *sexo* e *idade* possui pelo menos 2 valores distintos para o atributo *enfermidade*. A nova base é considerada 2-diversa e foi obtida a partir das seguintes operações:

- supressão dos atributos *região* e *sexo*;
- generalização do atributo *idade*, criando categorias [18–34] e [35–70] que agrupam idades por faixas.

Desse modo, mesmo com a informação auxiliar de que o indivíduo-alvo tem 50 anos de idade, o adversário não pode inferir sua enfermidade com absoluta certeza na base 2-diversa. De fato, a informação auxiliar do adversário o permite identificar que o indivíduo tem valor *idade*=[35–70], e há 3 registros na base com os mesmos valores (os registros de *id*'s 4, 5 e 6). Porém, neste agrupamento de registros, há pelo menos 2 valores para *enfermidade* (*leucemia* para o registro de *id* 4 e *AIDS* para os registros de *id*'s 5 e 6). $\triangleleft$

Limitações da diversidade- ℓ Uma desvantagem da diversidade- ℓ em relação à anonimidade- k é uma tendência a uma maior degradação da utilidade dos dados. Note que para obtermos a base 2-diversa da Tabela 4.1.1c, suprimimos os atributos *região* e *sexo* e agrupamos o atributo *idade* em apenas duas categorias. Tais operações eliminaram qualquer informação sobre os dois primeiros atributos, enquanto reduziram drasticamente a precisão do terceiro.

Outra limitação da diversidade- ℓ é a sua proteção apenas contra inferência determinística (i.e., com absoluta certeza) de atributos, mas não contra inferência probabilística. Considere novamente a base 2-diversa representada na Tabela 4.1.1c. Note que o conhecimento do adversário *a priori* (i.e., antes de usar a informação auxiliar sobre a idade do alvo para filtrar os registros da base) sobre a enfermidade de um indivíduo lhe confere sucesso com 33.33% de probabilidade (pois todas as 3 enfermidades possíveis são igualmente frequentes nos registros da base). Usando o conhecimento de que o alvo tem 50 anos de idade, o

adversário pode selecionar o subgrupo de registros de *id*'s 4, 5 e 6 (que possuem o valor [35–70] para o atributo *idade*), levando seu sucesso a 66.66% de probabilidade (pois 2 dentre os 3 indivíduos retornados possuem AIDS). Desta forma, apesar de o adversário não conseguir inferir exatamente qual a enfermidade do indivíduo-alvo, suas chances de sucesso dobram com o ataque sobre a base 2-diversa.

Por fim, mesmo que um grupo seja ℓ -diverso, é possível que todos os ℓ valores para o atributo sensível no grupo sejam considerados problemáticos. Tomando novamente a base 2-diversa representada na Tabela 4.1.1c, todos os indivíduos de idade no grupo [35–70] anos possuem uma enfermidade relativamente grave (leucemia ou AIDS), enquanto todos os indivíduos no grupo [18–34] possuem uma enfermidade relativamente leve (gripe ou otite). Desta forma, mesmo havendo diversidade em cada grupo, o adversário pode inferir a gravidade da enfermidade de um alvo, o que pode constituir em uma violação de privacidade.

A fim de contornar a ineficácia da diversidade- ℓ contra ataques de inferência de atributos probabilística, foi proposta a técnica de proximidade- t , descrita a seguir.

4.1.3 Proximidade- t

Proposto por Ninghui Li, Tiancheng Li e Venkatasubramanian [75], o método proximidade- t (*t-closeness*, no original em inglês) tem como objetivo garantir que a distribuição dos valores dos atributos sensíveis em cada agrupamento de registros seja similar à distribuição dos valores sensíveis na base como um todo. Desta forma, limita-se a degradação de privacidade de qualquer atributo sensível, uma vez que o conhecimento probabilístico a posteriori do adversário (i.e., a distribuição de valores sensíveis após usar os valores de quaseidentificadores para selecionar um subconjunto de registros) é sempre similar a seu conhecimento a priori (i.e., a distribuição de valores sensíveis na base toda).

Formalmente, o princípio que sustenta a proximidade- t pode ser descrito da seguinte forma. Um grupo de registros apresenta proximidade- t se a distância entre a distribuição dos valores dos atributos sensíveis deste grupo e a distribuição dos mesmos atributos na base dados inteira não ultrapassa um limiar t . Uma base de dados é dita satisfazer proximidade- t se todos os seus agrupamentos de registros apresentam proximidade- t .

Para medição da similaridade entre as distribuições a posteriori e a priori utiliza-se normalmente a *distância do movimentador de terra* (*earth mover's distance* - *EMD*, no original em inglês).¹

Assim como os métodos anonimidade- k e diversidade- ℓ , a proximidade- t recorre às operações de supressão e generalização de atributos para satisfazer suas restrições.

¹A função EMD é baseada na mínima quantidade de trabalho necessária para transformar uma distribuição de probabilidade em outra. Formalmente, sejam $p = (p_1, \dots, p_n)$ e $q = (q_1, \dots, q_n)$ duas distribuições de probabilidade sobre um mesmo domínio. A distância entre as duas distribuições, ou a quantidade de trabalho necessária para transformar p em q é dada pela função $EMD(p, q) \stackrel{\text{def}}{=} \frac{1}{(n-1)} \sum_{i=1}^n \left| \sum_{j=1}^i p_j - q_j \right|$.

Limitações da proximidade- t Um problema crucial do método é que ele tende a ser ainda mais destrutivo da utilidade dos dados que a diversidade- ℓ [54]. De fato, ao exigir que a distribuição dos valores dos atributos sensíveis seja a mesma em todos os subgrupos de registros, o método esconde potenciais correlações entre quaseidentificadores e atributos sensíveis, o que pode ser muito problemático em alguns estudos. Além disso, mesmo a proximidade- t ainda é ineficaz contra ataques composicionais, conforme descrito mais adiante na Seção 4.1.5.

4.1.4 Algoritmos

Em todos os três métodos sintáticos mencionados (anonimidade- k , diversidade- ℓ e proximidade- t), a chave para satisfação das garantias de privacidade são as operações de supressão e generalização de quaseidentificadores. O desafio de qualquer algoritmo que implemente tais métodos é justamente utilizar estas operações de forma cautelosa a fim de manter o maior nível possível de utilidade na base resultante. O exemplo abaixo ilustra a dificuldade prática de se atingir este objetivo.

Exemplo 4 (Utilidade em métodos sintáticos). Considere que desejemos aplicar anonimidade- k à base da Tabela 4.1.2a, para $k=2$ e usando *região*, *idade* e *sexo* como quaseidentificadores. Existem diferentes combinações de operações de supressão e generalização de atributos que podem resultar em uma base 2-anônima; as Tabelas 4.1.2b e 4.1.2c representam duas possíveis soluções. Note que na primeira houve uma generalização mais severa do atributo *região* (todos os valores foram generalizados para **Ocidente** e **Oriente**), enquanto que na segunda a generalização foi mais branda (os valores foram generalizados apenas até o nível continente: **América**, **Europa** e **Ásia**). Por outro lado, o inverso aconteceu com o atributo *idade*: a generalização da primeira solução foi mais branda que a da segunda.

Apesar de ambas as soluções resultarem em bases 2-anônimas, a utilidade dos dados é diferente em cada uma. Se o usuário que for utilizar os dados estiver interessado em analisar a distribuição de enfermidades por região, a Tabela 4.1.2b é a mais adequada, enquanto que o usuário que tem interesse na distribuição de enfermidades por faixa etária, tem a Tabela 4.1.2c como a que apresenta maior utilidade. <

De forma geral, existem diversas soluções para satisfazer as restrições dos métodos sintáticos, e os algoritmos propostos na literatura buscam explorar estas soluções de acordo com o objetivo do divulgador ou do analista dos dados. Conforme discutimos na Seção 3.1.2, a harmonização de objetivos de utilidade é uma tarefa não trivial. No Anexo C apresentamos os algoritmos providos pela ferramenta de anonimização ARX [91], incluindo o que seria demandado do Inep caso opte por esta solução.

4.1.5 Análise de prós e contras

As principais vantagens dos métodos sintáticos de anonimidade- k , diversidade- ℓ e proximidade- t incluem:

- As garantias providas pelos métodos são facilmente compreensíveis e comunicáveis tanto aos titulares quanto aos analistas de dados.
- Ao usar apenas generalização e supressão de atributos, os métodos são não perturbativos e, portanto, não inserem ruído nos dados.
- Há algoritmos eficientes para implementação dos métodos.

Entretanto, tais métodos apresentam desvantagens significativas, incluindo:

- Suas garantias dependem de hipóteses fortes sobre conhecimento auxiliar do adversário. Em particular, os métodos proveem garantias apenas contra o uso de um conjunto predeterminado de quaseidentificadores, mas a definição de quais atributos podem ou não contar como quaseidentificadores varia com o tempo e o espaço. Conforme demonstrado por Dwork, qualquer pedaço de informação pode ser prejudicial se usado como informação auxiliar [47], o que torna as garantias dos métodos sintáticos frágeis. Além disso, Aggarwal [9] demonstrou que a “maldição da dimensionalidade” (*curse of dimensionality*, no original em inglês), um problema conhecido na literatura de aprendizado de máquina, pode afetar fortemente métodos sintáticos. De fato, quando o número de quaseidentificadores é grande, tais métodos devem apagar a maior parte das entradas para atingir as garantias de anonimidade- k , diversidade- ℓ ou proximidade- t , o que degrada de forma significativa a utilidade dos dados [36]. É relevante notar que o Produto 02 do presente TED 8750, em sua extensa análise quantitativa experimental, demonstra que mesmo um número pequeno de quaseidentificadores já é suficiente para unicamente reidentificar proporções elevadas de estudantes nas bases dos Censos Educacionais do Inep.
- Os métodos acima não são composicionais. Mais precisamente, se um indivíduo consta em duas bases distintas, mesmo que ambas estejam protegidas por um mesmo método sintático, não há garantias de ainda valham as garantias de privacidade que o método implica em cada base individualmente. Esta é uma preocupação particularmente crucial no caso dos Censos Educacionais do Inep, que são divulgados anualmente: mesmo que a base de cada ano proveja, digamos, diversidade- ℓ , o adversário poderia cruzar as bases de vários anos e eliminar a garantia de privacidade. O Exemplo 5 ilustra esta possibilidade.

Exemplo 5 (Não composicionalidade de métodos sintáticos). Considere um cenário em que duas bases de dados sejam divulgadas após serem tratadas para garantir diversidade- ℓ (e.g., porque institutos distintos executam e divulgam pesquisas distintas em paralelo, ou por um mesmo instituto que executa pesquisas sobre uma mesma população em anos distintos e então as divulga sequencialmente).

As Tabelas 4.1.3a e 4.1.3b representam, respectivamente, duas bases d_1 e d_2 , ambas 2-diversas com respeito ao atributo sensível *enfermidade* e aos quaseidentificadores *região*, *sexo* e *idade*. Isso significa que um adversário que tenha acesso a apenas uma

dessas bases sempre tem dúvida entre pelo menos dois valores para a enfermidade de qualquer indivíduo-alvo, mesmo que ele conheça os valores de região, sexo e idade deste alvo.

Entretanto, vamos analisar o que ocorre quando o adversário tem acesso às duas bases d_1 e d_2 . Suponha que o adversário deseja descobrir qual a enfermidade de Teresa e que ele tem como informação auxiliar que ela tem 43 anos de idade e está nestas duas bases. Filtrando os registros de $idade=[0-49]$ na Tabela 4.1.3a, o adversário infere que o registro de Teresa deve corresponder àqueles de id 's 1 ou 2, que têm os valores **gripe** e **leucemia**, respectivamente, para o atributo *enfermidade*. Já na Tabela 4.1.3b, ao filtrar os registros de $idade=[35-70]$, o adversário obtém aqueles de id 's 4, 5 e 6, com os valores **leucemia**, **AIDS** e **AIDS**, respectivamente, para o atributo sensível.

O acesso a apenas a base d_1 manteria o adversário em dúvida entre Teresa ter gripe ou leucemia, enquanto o acesso a apenas a base d_2 manteria o adversário em dúvida entre leucemia e AIDS. Entretanto, se o adversário tem acesso às duas bases d_1 e d_2 , e sabendo que Teresa está em ambas as bases, ele pode concluir que a enfermidade de Teresa com certeza é leucemia. Além disso, o adversário pode concluir que o registro de Teresa é aquele de id 2 na base d_1 e aquele de id 4 na base d_2 . Assim, mesmo que tanto d_1 e d_2 provejam individualmente diversidade- ℓ para $\ell=2$, sua composição não oferece a mesma garantia de privacidade. $\triangleleft$

Pelos motivos expostos acima, uma grande parte da comunidade de pesquisa descarta métodos sintáticos como uma solução viável para proteção de anonimidade [36]. Em particular, o Escritório do Censo dos EUA (USCB) reconhece que os métodos sintáticos acima são insuficientes para garantia de privacidade e tem adotado versões de privacidade diferencial [4] na divulgação de seu Censo Decenal de 2020.

4.2 Divulgação de microdados por amostragem

Vários curadores de dados utilizam a técnica de divulgar microdados de apenas uma amostra aleatoriamente selecionada da população. Como relatado no Produto 01 do presente TED, todas as agências federais dos Estados Unidos que publicam microdados o fazem, necessariamente, por meio da divulgação de amostras da população. Ao todo, 11 agências federais reportavam a publicação de microdados por amostragem em 2005, incluindo o *Bureau of Economic Analysis*, o *United States Census Bureau*, o *National Center for Education Statistics*, o *National Center for Health Statistics*, e o *Bureau of Labor Statistics* [87].

Ainda no cenário internacional, o Escritório Australiano de Estatística, responsável pela realização do Censo na Austrália, também disponibilizou, até o Censo de 2016, microdados apenas para amostras da população e, ainda assim, sob restrições de acesso. O mesmo ocorre para o Censo Longitudinal Australiano, criado a partir de amostras aleatórias com correspondência entre as edições do Censo [86]. Já a Holanda optou, em

1991, por abolir o Censo em favor de técnicas por amostragem, ou seja, não apenas a divulgação, mas a coleta de dados por amostras aleatórias [1].

Já no cenário nacional, o IBGE divulga microdados por amostragem tanto no contexto das Pesquisas Domiciliares por Amostragem Probabilística, quanto dos Censos Demográficos Decenais. No primeiro caso, a seleção da amostra aleatória da população ocorre ainda durante a etapa da coleta dos dados, como realizado pela Holanda, enquanto que no caso dos Censos Demográficos, o IBGE divulga microdados apenas para a parcela de investigação por amostragem [40].

A técnica de amostragem não perturbativa visa a mitigar os riscos de reidentificação ou inferência de atributo sensível de indivíduos ao quebrar a premissa de que o adversário já sabe a priori que todos os indivíduos estão na base. Mais especificamente, espera-se que, mesmo que o adversário consiga isolar na amostra um único registro que combine com a informação auxiliar que ele possui sobre um indivíduo-alvo, não haja certeza de se o registro isolado pertence mesmo ao alvo pois ele pode nem mesmo estar na amostra.

4.2.1 Análise de prós e contras

As principais vantagens do método de amostragem são:

- É fácil de compreender e de comunicar tanto aos titulares quanto aos analistas de dados.
- No geral sua aplicação pode levar a uma significativa redução do risco médio dos indivíduos na base (tanto de reidentificação quanto de inferência de atributo).

Entretanto, tais métodos apresentam desvantagens significativas, incluindo:

- Como apontado por Dwork, apesar da amostragem poder reduzir o risco médio dos titulares, ela não garante privacidade em nível individual. O seguinte exemplo ilustra esta situação.

Exemplo 6 (Divulgação de microdados por amostragem não garante privacidade em nível individual). Considere que seja amostrado um subconjunto dos professores do Departamento de Ciência da Computação da UFMG, criando uma base contendo informações individuais destes professores, incluindo sua nacionalidade e eventuais enfermidades. Suponha ainda que um adversário tenha a informação auxiliar de que um professor específico é o único docente de origem holandesa no departamento.

Se a base amostrada contém um registro indicando um titular de nacionalidade holandesa, o adversário pode facilmente reidentificar professor holandês na base e, conseqüentemente, inferir com absoluta certeza se ele é ou não portador de enfermidades. ◁

Apesar do exemplo acima ser simples, ataques baseados no mesmo princípio podem ser executados em bases muito maiores, com até milhões de registros. Um indivíduo afetado pelo ataque pode encontrar pouco consolo no fato de que a amostragem garante que ele é um raro desafortunado dentre um conjunto de milhares ou milhões de usuários, desde que o ataque tenha consequências catastróficas para si (e.g., permitir a um criminoso reidentificar em uma base de dados um participante de um programa de proteção a testemunhas). Além disso, a LGPD prevê garantias em nível individual para cada titular.

Há, entretanto, métodos mais sofisticados para tornar a amostragem de microdados mais segura, utilizando principalmente a privacidade diferencial. Estas abordagens são cobertas na Seção [6.4.1](#).

<i>id</i>	<i>região</i>	<i>sexo</i>	<i>idade</i>	<i>enfermidade</i>
1	Brasil	F	25	gripe
2	Bolívia	M	18	otite
3	França	F	32	gripe
4	Espanha	F	43	leucemia
5	Japão	M	50	AIDS
6	China	M	70	AIDS

(a) Base de dados original.

<i>id</i>	<i>região</i>	<i>sexo</i>	<i>idade</i>	<i>enfermidade</i>
1	Ocidente	*	[18–29]	gripe
2	Ocidente	*	[18–29]	otite
3	Ocidente	*	[30–44]	gripe
4	Ocidente	*	[30–44]	leucemia
5	Oriente	*	[45–70]	AIDS
6	Oriente	*	[45–70]	AIDS

(b) Base de dados k -anonimizada ($k = 2$) usando generalização dos atributos *região* e *idade* e supressão do atributo *sexo*. Neste caso todo registro é indistinguível de pelo menos outro registro usando-se apenas estes 3 quaseidentificadores.

<i>id</i>	<i>região</i>	<i>sexo</i>	<i>idade</i>	<i>enfermidade</i>
1	*	*	[18–34]	gripe
2	*	*	[18–34]	otite
3	*	*	[18–34]	gripe
4	*	*	[35–70]	leucemia
5	*	*	[35–70]	AIDS
6	*	*	[35–70]	AIDS

(c) Base de dados submetida a diversidade- ℓ ($\ell = 2$) usando generalização do atributo *idade* e supressão dos atributos *região* e *sexo*.

Tabela 4.1.1: Exemplos 2 e 3: Aplicação de anonimidade- k e diversidade- ℓ a uma base de dados. Nestes exemplos temos que os atributos *região*, *sexo* e *idade* são potenciais quaseidentificadores, e o atributo *enfermidade* é considerado sensível.

<i>id</i>	<i>região</i>	<i>sexo</i>	<i>idade</i>	<i>enfermidade</i>
1	Brasil	F	25	gripe
2	Bolívia	M	18	otite
3	França	F	32	gripe
4	Espanha	F	43	leucemia
5	Japão	M	50	AIDS
6	China	M	70	AIDS

(a) Base de dados original.

<i>id</i>	<i>região</i>	<i>sexo</i>	<i>idade</i>	<i>enfermidade</i>
1	Ocidente	*	[18–29]	gripe
2	Ocidente	*	[18–29]	otite
3	Ocidente	*	[30–44]	gripe
4	Ocidente	*	[30–44]	leucemia
5	Oriente	*	[45–70]	AIDS
6	Oriente	*	[45–70]	AIDS

(b) Base de dados 2-anônima, usando generalização dos atributos *região* e *idade* e supressão do atributo *sexo*.

<i>id</i>	<i>região</i>	<i>sexo</i>	<i>idade</i>	<i>enfermidade</i>
1	América	*	[18–34]	gripe
2	América	*	[18–34]	otite
3	Europa	*	[18–34]	gripe
4	Europa	*	[35–70]	leucemia
5	Ásia	*	[35–70]	AIDS
6	Ásia	*	[35–70]	AIDS

(c) Base de dados 2-anônima, usando generalização dos atributos *região* e *idade* e supressão do atributo *sexo*.

Tabela 4.1.2: Exemplo 4: Diferentes generalizações que resultam em uma base de dados 2-anônima. Neste exemplo temos que os atributos *região*, *sexo* e *idade* são potenciais quaseidentificadores, e o atributo *enfermidade* é considerado sensível.

<i>id</i>	<i>região</i>	<i>sexo</i>	<i>idade</i>	<i>enfermidade</i>
1	Europa	*	[0–49]	gripe
2	Europa	*	[0–49]	leucemia
3	América	*	[50–100]	otite
4	América	*	[50–100]	otite
5	Oceania	*	[50–100]	AIDS
6	Oceania	*	[50–100]	gripe

(a) Base de dados 2-diversa d_1 , usando generalização dos atributos *região* e *idade* e supressão do atributo *sexo*.

<i>id</i>	<i>região</i>	<i>sexo</i>	<i>idade</i>	<i>enfermidade</i>
1	América	*	[18–34]	AIDS
2	América	*	[18–34]	gripe
3	Europa	*	[18–34]	gripe
4	Europa	*	[35–70]	leucemia
5	Ásia	*	[35–70]	AIDS
6	Ásia	*	[35–70]	AIDS

(b) Base de dados 2-diversa d_2 , usando generalização dos atributos *região* e *idade* e supressão do atributo *sexo*.

Tabela 4.1.3: Exemplo 5: Diferentes possibilidades de bases 2-diversas em relação ao atributo sensível *enfermidade* e quaseidentificadores *região*, *sexo* e *idade*.

5 Especificação de métodos não perturbativos para divulgação de dados agregados ou tabulares

Nesta seção apresentamos métodos para divulgação de dados agregados de forma não perturbativa, i.e., sem adição de ruído ou informações inverídicas. Dados agregados são aqueles em que, ao contrário do que ocorre com microdados, a informação não é disponibilizada em nível individual. Na literatura é comum se referir a este tipo de dado também como *dados tabulares*, já que tipicamente eles são organizados em tabelas em que cada célula representa o número de indivíduos correspondente a uma coluna ou linha (e.g., faixa de idade ou instituição de ensino) ou a uma soma/média (e.g., número esperado de anos completos no ensino fundamental por estado da federação).

Iniciamos a seção com a apresentação de dados agregados em forma de sumários estatísticos e em seguida passamos à divulgação em forma de histogramas. Por fim, analisamos os prós e contras destes métodos.

Ressaltamos que, por serem não perturbativos, os métodos aqui apresentados alteram a informação provida apenas por diminuir sua granularidade ou por suprimi-la por partes, sem, entretanto, introduzir ruído. Por esta razão, tais métodos proveem garantias de privacidade mais frágeis que suas versões perturbativas baseadas em privacidade diferencial, discutidas na Seção 6.4.2.

5.1 Divulgação de sumários estatísticos

Uma técnica amplamente utilizada de mitigação de danos à privacidade é a divulgação de sumários estatísticos predefinidos, em contraposição a permitir que analistas realizem suas próprias consultas (potencialmente de forma controlada) à base ou a divulgar o conjunto de microdados.

A título de exemplo, temos a divulgação de dados educacionais pelo Ministério da Educação da Holanda [41] discutido no Produto 01 do presente TED. Naquele contexto, são divulgadas apenas algumas estatísticas gerais predefinidas sobre os estudantes, como a

média de suas notas, indicadores de qualidade por instituição de ensino, e a distância média entre a residência do estudante até sua escola.

Quando executada de forma criteriosa, a divulgação de apenas sumários estatísticos sobre uma base provê maior proteção à privacidade do que a divulgação de microdados ou histogramas muito detalhados. Entretanto, em muitos casos a informação contida nestes sumários não são suficientes para determinados analistas, o que pode causar uma diminuição considerável na utilidade da divulgação.

5.2 Divulgação de histogramas

Um outro método bastante utilizado é a divulgação de dados agregados em forma de histogramas. Histogramas podem ser representados tanto como gráficos de barras, onde a altura de cada barra corresponde à multiplicidade (i.e., quantidade) de registros que satisfazem certa propriedade (e.g., quantidade de registros que possuem os valores "Brasil, F, 25" para as colunas *região*, *sexo*, *idade*, respectivamente), quanto como em forma de dados tabulares, onde uma coluna contém as propriedades e outra coluna contém a multiplicidade de registros que a satisfazem. Por exemplo, a base de dados da Tabela 5.2.1a pode ser graficamente representada pelo histograma da Figura 5.2.1b.

É possível divulgar histogramas com diferentes níveis de correlações entre os atributos. A maior correlação possível acontece quando o histograma equivale à base de dados original. Já a menor correlação ocorre quando divulga-se histogramas com as distribuições marginais de cada atributo. Entretanto, há um ponto intermediário onde divulga-se a distribuição conjunta de dois, três, ou mais atributos.

Exemplo 7 (Divulgação não perturbativa de histogramas). A Tabela 5.2.1 apresenta diferentes conjuntos de histogramas com diferentes níveis de correlação entre os atributos em relação à base de dados original representada na Tabela 5.2.1a.

A Tabela 5.2.1b contém um histograma que representa exatamente a base de dados original, já que apresenta a multiplicidade (i.e., quantidade) de registros que contém cada combinação de valores para todos os atributos conjuntamente. Já a Tabela 5.2.1c, por exemplo, contém histogramas com a distribuição marginal dos valores para *região*, *sexo*, *idade* e *enfermidade*. Já a Tabela 5.2.1d apresenta um histograma que contém a distribuição conjunta dos atributos *idade* (generalizado em intervalos) e *enfermidade*.

Intuitivamente, a privacidade dos dados da Tabela 5.2.1c parece maior que a da Tabela 5.2.1b. Entretanto, a correlação entre os atributos foi totalmente perdida. Em outras palavras, dizemos que a utilidade dos quatro histogramas é menor que a utilidade do histograma único.

Quanto menor a correlação dos atributos, maior a privacidade, mas consequentemente, menor a utilidade. A operação de generalização de atributos também pode estar presente na divulgação de histogramas. Recorde que a generalização de um atributo diminui o nível de detalhamento dos valores, como por exemplo, o atributo *idade* da Tabela 5.2.1a sendo generalizado para intervalos de idades, representados na Tabela 5.2.1d. <

5.3 Análise de prós e contras

Dentre as principais vantagens da divulgação de dados agregados de forma não perturbativa, podemos citar:

- É fácil de entender e implementar.
- Apresenta menos risco à privacidade quando comparada com a pura e simples divulgação de microdados.

Entretanto, tais métodos apresentam as seguintes desvantagens:

- Proveem pouca utilidade em análises finas, que buscam correlações entre atributos e valores específicos.
- Dependem de análise do curador para priorizar quais sumários ou histogramas publicar, levando possivelmente a uma insatisfação de alguns analistas de dados.
- Apesar de sumários estatísticos e histogramas proverem, no geral, um nível médio de privacidade mais elevado do que o permitido pela divulgação de microdados, eles não apresentam garantias individuais. O próprio Documento 22 [87], que descreve o que as agências federais dos EUA adotavam em 2005 como formas de divulgação de informação, reconhece que a simples agregação não garante necessariamente a proteção dos dados individuais, e diversas técnicas aplicáveis a microdados já eram aplicadas à época também a dados agregados de magnitude e de frequência.

Mais precisamente, podemos citar as seguintes vulnerabilidades da agregação de dados. Em primeiro lugar, alguns indivíduos com características raras ainda podem ter sua privacidade violada. Por exemplo, se um indivíduo é sabidamente o único de nacionalidade holandesa em um grupo, um histograma que revele nacionalidade e enfermidade teria multiplicidade 1 exatamente na tupla correspondente à enfermidade do indivíduo, o que revelaria seu valor sensível. Em segundo lugar, adversários podem usar cruzamentos de dados para ferir a privacidade de indivíduos. O Exemplo 25 mais adiante neste documento ilustra essa possibilidade.

- Caso o conjunto de sumários estatísticos ou de histogramas seja detalhado o suficiente, é possível reconstruir a base de dados original, total ou parcialmente, o que violaria a privacidade dos indivíduos. Este fato é demonstrado pelo *Teorema da Reconstrução da Base de Dados* [43], explicado no Anexo A.3.

A divulgação de histogramas é um método muito usado por agências internacionais, entretanto em sua versão que satisfaça privacidade diferencial, conforme discutido na Seção 6.4.2.

<i>id</i>	<i>região</i>	<i>sexo</i>	<i>idade</i>	<i>enfermidade</i>
1	Brasil	F	25	gripe
2	Bolívia	M	18	otite
3	França	F	32	gripe
4	Espanha	F	43	leucemia
5	Japão	M	50	AIDS
6	China	M	70	AIDS

(a) Base de dados original.

<i>(região, sexo, idade, enfermidade)</i>	Multiplicidade
(Brasil,F,25,gripe)	1
(Bolívia,M,18,otite)	1
(França,F,32,gripe)	1
(Espanha,F,43,leucemia)	1
(Japão,M,50,AIDS)	1
(China,M,70,AIDS)	1

(b) Histograma de valores completos dos registros.

<i>região</i>	Mult.	<i>sexo</i>	Mult.	<i>idade</i>	Mult.	<i>enfermidade</i>	Mult.
Brasil	1	F	3	18	1	gripe	2
Bolívia	1	M	3	25	1	otite	1
França	1			32	1	leucemia	1
Espanha	1			43	1	AIDS	2
Japão	1			50	1		
China	1			70	1		

(c) Histogramas com a distribuição marginal de cada atributo individual.

<i>(idade, enfermidade)</i>	Multiplicidade
([18-34], câncer)	2
([18-34], gripe)	1
([35-70], vírus)	1
([35-70], AIDS)	2

(d) Histogramas com a distribuição marginal conjunta dos atributos *idade* (generalizado em intervalos) e *enfermidade*.

Tabela 5.2.1: Exemplo 7: Histogramas que contêm diferentes distribuições de valores referentes às bases de dados da Tabela 5.2.1a.

6 Especificação de métodos baseados em privacidade diferencial

Na última década e meia a privacidade diferencial (*differential privacy*, no original em inglês) e suas variantes têm se consolidado como os mais refinados métodos para garantia de privacidade em divulgações estatísticas. Sua popularidade se deve em grande parte à sua capacidade de mitigar de forma significativamente mais efetiva violações de privacidade às quais métodos sintáticos não perturbativos estão sujeitos. Em particular, ao contrário de tais métodos, a privacidade diferencial não depende de premissas demasiado fortes a respeito das capacidades e informação auxiliar do adversário. Além disso, a privacidade diferencial apresenta composicionalidade, o que significa que problemas complexos de divulgação de dados (e.g., envolvendo múltiplas bases) possam ser quebrados em sub-problemas de forma mais segura.

A área de pesquisa em privacidade diferencial é extremamente ativa, com novos resultados e algoritmos sendo apresentados a todo momento. Nesta seção resumizamos os conceitos fundamentais sobre privacidade diferencial e suas variantes, assim como suas principais propriedades e métodos de emprego, analisando suas vantagens e desvantagens.

Iniciamos com uma exposição dos princípios da privacidade diferencial. Prosseguimos com a apresentação da variante de privacidade diferencial global, em que ruído é adicionado ao resultado de consultas e a variante de privacidade diferencial local, em que ruído é adicionado individualmente aos dados de cada titular. Provemos, então, alguns exemplos de aplicação da privacidade diferencial na prática que ilustram tanto as vantagens quanto os desafios apresentados pela técnica, incluindo a divulgação de microdados por amostragem, a divulgação de histogramas e dados sintéticos, e, por fim, uma visão geral da abordagem utilizada pelo Escritório do Censo dos EUA (*United States Census Bureau - USBC*) para o Censo de 2020. Encerramos com uma análise de prós e contras do uso da privacidade diferencial. No Anexo [D](#) resumizamos algumas das variantes mais refinadas da privacidade diferencial.

6.1 Fundamentação de privacidade diferencial

Uma vez que a privacidade diferencial se baseia em princípios sutis, apresentamos aqui um sumário de como a busca por uma “definição razoável de privacidade” levou ao atual conceito de privacidade diferencial. Acreditamos que esta fundamentação possa ajudar o leitor a compreender porque as técnicas mais simples (como as sintáticas e não perturbativas) não são mais consideradas, por grande parte da comunidade, adequadas para o problema de controle de divulgação estatística.

A privacidade diferencial é fundamentada no seguinte princípio: *se o efeito de uma única alteração arbitrária na base de dados –seja pela inserção, remoção ou alteração de um único registro– for pequeno o suficiente, então naturalmente o resultado de uma consulta não pode ser utilizado para inferir informação significativa sobre nenhum indivíduo*. Proposta por Cynthia Dwork em 2006 [49, 45], a privacidade diferencial e suas variantes são hoje consideradas parte do estado da arte em controle de divulgação estatística.¹

O sumário apresentado na presente seção é diretamente baseado em um artigo de Dwork para introduzir e motivar a privacidade diferencial para um público mais abrangente [47]. Iniciamos o com o próprio resumo do referido artigo sobre o escopo da privacidade diferencial:

No domínio da informação, a perda de privacidade está geralmente associada à falha em controlar o acesso às informações, controlar o fluxo de informações, ou controlar os propósitos para os quais as informações são empregadas. A privacidade diferencial surgiu em um contexto em que garantir a privacidade é um desafio mesmo que todos esses problemas de controle tenham sido resolvidos: a análise estatística de dados que preserve a privacidade. O problema do controle de divulgação estatística –que consiste em revelar estatísticas precisas sobre um conjunto de entrevistados ao mesmo tempo em que se preserva a privacidade dos indivíduos– tem uma história venerável, com uma extensa literatura abrangendo as áreas de estatística, ciência da computação teórica, segurança, bancos de dados e criptografia [...] Os dados podem ser obtidos de diversas maneiras. [...] Normalmente, os doadores altruístas de dados recebem a promessa de que seus dados individuais serão mantidos em sigilo –em resumo, eles recebem a promessa de “privacidade”. Da mesma forma, dados médicos e aqueles demandados por lei, como dados de censos ou dados de declaração de impostos, têm mandatos legais de privacidade. [...] Os problemas permanecem: mesmo que a criptografia de dados, o gerenciamento de

¹O desenvolvimento da privacidade diferencial foi uma das justificativas para a contemplação de Cynthia Dwork com o *Prêmio Donald E. Knuth para Contribuições Notáveis aos Fundamentos da Ciência da Computação* em 2020, concedido pelo Grupo de Interesse Especial em Algoritmos e Teoria da Computação (*Special Interest Group on Algorithms and Computation Theory - SIGACT*) da ACM (*Association for Computing Machinery*) e pelo Comitê Técnico sobre Fundamentos Matemáticos da Computação (*Technical Committee on Mathematical Foundations of Computing - TCMF*) da IEEE (*Institute of Electrical and Electronics Engineers*). <https://www.sigact.org/prizes/knuth.html>




Figura 6.1.1: Cenário original motivador para privacidade diferencial.

chaves, o controle de acesso e as motivações do curador de dados sejam todos incontestáveis, o que significa preservar a privacidade e como isso pode ser feito?

6.1.1 Motivação para privacidade diferencial

O cenário originalmente considerado por Dwork, ilustrado na Figura 6.1.1, supõe que haja uma única base de dados e que um conjunto de um ou mais analistas procure obter informações estatísticas sobre esses dados através da realização de consultas (ou *queries*) à base. O cenário considera, ainda, que a base de dados esteja protegida contra acesso indevido por terceiros (e.g., porque o servidor de dados está em um ambiente seguro, porque os dados estão criptografados, ou ambos). Entretanto, tal proteção, apesar de eficiente contra ataques de terceiros, não previne a degradação de privacidade causada pela ação de usuários legítimos dos dados, os analistas de dados.

Mais especificamente, a fim de se preservar a privacidade dos titulares dos dados, os analistas não devem poder inferir informações sobre indivíduos a partir do acesso à base. Em uma base de dados educacionais, por exemplo, é tipicamente considerado válido que o analista obtenha informações estatísticas como “*Quantos estudantes da rede pública são portadores de deficiência*” ou “*Qual a renda média dos estudantes portadores de deficiência*”, mas é considerada inaceitável a obtenção (direta ou indireta) de informações individualizadas como “*Ana é portadora de deficiência*” ou “*A renda de Bruno é de R\$ 1 000.00 mensais*”.

A dificuldade de conciliar o provimento de informação estatística com a proteção de informação individualizada surge porque o analista, apesar de ser um usuário legítimo dos dados, pode agir (intencionalmente ou não) como adversário ao obter informação sobre indivíduos.

Várias abordagens foram propostas ao longo dos anos, inclusive por profissionais de TI de variadas especialidades, para lidar com o problema. Entretanto, várias delas, apesar de poderem parecer promissoras a princípio, revelam-se ineficazes sob uma inspeção mais minuciosa. A seguinte lista cita algumas destas estratégias consideradas na literatura, juntamente com justificativas de porque elas falham.

- *Criptografar os dados não funciona.* Métodos criptográficos pressupõem uma distinção clara entre partes consideradas legítimas e partes consideradas como adversárias; as primeiras devem ter a capacidade de descriptografar os dados, enquanto

as segundas, não. Como no cenário de controle de divulgação estatística há uma coincidência entre os papéis de usuário legítimo e de adversário, a criptografia não é capaz de resolver o problema (e nem mesmo de modelá-lo apropriadamente).

- *Desidentificar os dados (i.e., remover identificadores óbvios como nome ou CPF) ou pseudonimizá-los (i.e., substituir identificadores únicos naturais por identificadores artificiais) não funciona.* Com o uso de informação auxiliar (como quase-identificadores), é frequentemente possível reidentificar indivíduos com altas taxas de sucesso. As limitações de técnicas de desidentificação foram extensivamente discutidas no Produto 02 do presente projeto.
- *Proibir consultas à base de dados que retornem poucos registros como resposta não funciona.* Considere que consultas que retornem menos que 10 registros como resultado sejam vedadas ao analista de dados, esperando-se que, assim, informações individuais sejam preservadas e apenas informações estatísticas possam ser reveladas. Mesmo assim, o analista sempre poderia obter informação de se um indivíduo x qualquer na base de dados satisfaz ou não uma dada propriedade P da seguinte forma: primeiro o analista consulta quantas pessoas na base satisfazem a propriedade P , obtendo um resultado a ; em seguida, o analista consulta quantas pessoas na base com um nome diferente do de x satisfazem a propriedade P , obtendo um resultado b ; por fim, computando a diferença $b-a$ o analista consegue inferir com absoluta certeza se o indivíduo x satisfaz ou não a propriedade P desejada.
- *Permitir apenas determinados tipos de consultas não funciona.* Imagine que seja criada uma lista de consultas proibidas na base de dados, com a intenção de evitar a violação de privacidade de indivíduos (e.g., toda consulta que faça referência explícita a um único indivíduo ou um pequeno grupo de indivíduos). Entretanto, é possível demonstrar que em linguagens de consulta expressivas o suficiente (como SQL), não existe um algoritmo capaz de determinar quais consultas seriam permitidas e quais não seriam,² tornando a estratégia ineficaz.
- *Armazenar um histórico de consultas anteriores não funciona.* Considere que, na expectativa de evitar o problema de duas ou mais consultas serem cruzadas para obter informação individual, tente-se armazenar o histórico de consultas realizadas e fazer uma checagem de risco antes de autorizar qualquer nova consulta. Esta abordagem também seria falha pelos mesmos motivos expostos no item anterior.
- *Criar uma amostra (subconjunto) aleatória dos dados e fazer consultas nesta amostra não funciona.* Esta abordagem pode proteger alguns indivíduos na base, mas tem o potencial de ser extremamente danosa para os indivíduos presentes na amostra. O Exemplo 6 da Seção 4.2.1 ilustra este tipo de risco. Como mencionado

²A existência de tal algoritmo implicaria a existência de um algoritmo para o *problema da parada*, o que seria uma contradição [98, 64]. No jargão de ciência da computação dizemos que o problema de se determinar se uma consulta é válida é *indecidível*, o que significa que não existe solução computacional geral para ele.

naquela seção, um indivíduo afetado pelo ataque pode encontrar pouco consolo no fato de que a amostragem garante que ele é um raro desafortunado dentre um conjunto de milhares ou milhões de usuários, desde que o ataque tenha consequências catastróficas para si (e.g., permitir a um criminoso reidentificar em uma base de dados um participante de um programa de proteção a testemunhas). É importante ressaltar que a própria LGPD indica a necessidade de proteções individuais de privacidade.

6.1.2 O Desiderato de Dalenius e a busca por uma “definição razoável de privacidade”

Em 1977, o estatístico Tore Dalenius formulou o seguinte desiderato (i.e., propriedade desejável) que se poderia querer impor a uma base de dados estatística [39]:

Definição 8 (O Desiderato de Dalenius (*Dalenius’ Desideratum*)). Nada deve ser aprendível sobre um indivíduo através de acesso a uma base de dados que não possa ser aprendido sem acesso à base. ◁

Em outras palavras, o Desiderato de Dalenius demanda que a divulgação de uma base de dados não possa causar nenhum dano à privacidade de um indivíduo que já não pudesse ser causado mesmo sem a divulgação da base.

Apesar de parecer natural, tal desiderato é demasiadamente restritivo para ser de uso prático. Por exemplo, suponha que um analista acredite a priori (antes de ter acesso à base) que 2% dos alunos participantes de Censo Educacional do Inep sejam portadores de alguma necessidade especial. Portanto, tal analista acreditaria que a probabilidade de um aluno qualquer, digamos, Clarissa, ser portador de necessidade especial é de 2%. Considere, entretanto, que ao executar uma consulta na base, o analista descubra que na verdade apenas 0.1% dos alunos têm essa deficiência. A partir daí, o analista passaria a acreditar que a probabilidade de Clarissa ser portadora de necessidade especial é de 0.1% (uma alteração multiplicativa por um fator de 20 vezes). Claramente a consulta à base de dados alterou o conhecimento do analista sobre as chances de Clarissa ser ou não portadora de necessidades especiais. De acordo com o Desiderato de Dalenius teria ocorrido uma violação de privacidade de Clarissa, mas isso vai contra nossa intuição.

Para sermos mais precisos, podemos formalizar este exemplo levando em conta os princípios expostos na Seção 2.1, da seguinte forma.

- o conhecimento a priori do analista/adversário é aquilo que ele já sabe sobre um indivíduo antes mesmo de executar uma consulta à base de dados;
- o conhecimento a posteriori do analista/adversário é aquilo que ele sabe após incorporar ao seu conhecimento a priori o resultado retornado pela consulta; e
- a degradação de privacidade devida ao acesso à base é a comparação entre os conhecimentos a posteriori e a priori acima.

Intuitivamente, o Desiderato de Dalenius diz que uma consulta preserva a privacidade se o conhecimento a posteriori “não difere muito” do conhecimento a priori. Ou seja, a probabilidade que um adversário atribui a Clarissa ser portadora de necessidades especiais deve ser mais ou menos a mesma antes e depois de consultar a base (ao contrário da grande alteração que observamos acima).³

O exemplo acima ilustra uma limitação intrínseca do Desiderato de Dalenius como noção de privacidade: *uma razão fundamental pela qual consultas são realizadas a bases de dados é justamente a busca por alterar nosso conhecimento sobre a população contida na base*. De outra forma, faria pouco sentido manter a base como fonte de informação.

Uma das contribuições fundamentais de Dwork foi demonstrar que o Desiderato de Dalenius é restritivo demais: para qualquer divulgação de dados sempre existe uma informação auxiliar que é praticamente inútil sem a base, mas que leva à inferência de informação sensível quando cruzada com a base [45]. Para ilustrar este resultado, considere que um analista tenha como informação auxiliar que a nota de Elisa em Geografia é 10 pontos superior à nota média de todos os alunos na mesma escola. Se o analista não sabe a nota média de todos os alunos na escola de Elisa, a informação auxiliar não lhe serve de muita coisa. Entretanto, após consultar a base, o analista descobre que a nota média é, na verdade, 62 (e, portanto, consegue inferir que a nota de Elisa é exatamente 72). A consulta à base levou a uma violação de privacidade de Elisa, mas intuitivamente não parece ser “culpa” da base que tal violação tenha ocorrido.

Partindo dessa ideia, Dwork propôs o conceito de privacidade diferencial como uma noção “razoável” de privacidade, que não vá contra nossa intuição e seja ao mesmo tempo precisa. Apresentamos sua filosofia a seguir.

6.1.3 A filosofia fundamental da privacidade diferencial

Em vez de comparar o conhecimento do adversário a priori com seu conhecimento a posteriori para determinar se houve violação de privacidade, a privacidade diferencial

³Mais precisamente, se modelarmos o conhecimento a priori do adversário como a variável aleatória X e seu conhecimento a posteriori como a variável aleatória Y , o Desiderato de Dalenius pode ser formalizado como

$$\underbrace{Pr[X = x]}_{\text{conhecimento a priori}} \approx \underbrace{Pr[X = x \mid Y = y]}_{\text{conhecimento a posteriori}},$$

onde x e y são valores possíveis para X e Y , respectivamente.

No exemplo de Clarissa acima, teríamos que X é a variável aleatória binária indicando se Clarissa é ou não portadora de necessidades especiais, enquanto Y corresponde ao resultado da consulta referentes a qual a porcentagem dos alunos na base é portador de necessidades. Poderíamos desejar que probabilidade que o adversário atribui a Clarissa ser portadora antes de consultar a base (dada por $Pr[X = \text{sim}]$, que nesse caso é 2%) seja similar à probabilidade que o adversário atribui a Clarissa após aprender que 0.1% dos indivíduos na base tem a enfermidade (dada por $Pr[X = \text{sim} \mid Y = 0.1\%]$, que neste caso é 0.1%). Dessa forma, a consulta à base não teria revelado nada sobre a enfermidade de Clarissa se $Pr[X = \text{sim}] \approx Pr[X = \text{sim} \mid Y = 0.1\%]$, o que não ocorre.

compara o risco em que um indivíduo que participa da base de dados incorre com o risco em que ele incorreria se não participasse da base. Se os riscos forem similares, a privacidade diferencial diria que é seguro para o indivíduo optar por participar da base, o que é um incentivo que as pesquisas continuem sendo feitas.

Note que a garantia acima não afirma que um adversário não pode aprender informação sensível a respeito de um indivíduo ao consultar uma base, mas apenas que a eventual opção do indivíduo por não participar da base não alteraria significativamente a informação sensível que o adversário pode aprender sobre ele. Por exemplo, retomemos o cenário em que o adversário tem como informação auxiliar que a nota em Geografia de Elisa é 10 pontos acima da média dos alunos em sua escola. Recorde que o Desiderato de Dalenius consideraria que há uma violação de privacidade quando o analista/adversário consulta a base e descobre que a média dos alunos é 62 –e, portanto, que a nota de Elisa é exatamente 72. Já a privacidade diferencial consideraria que, apesar de o adversário ter aprendido informação sensível sobre Elisa, este aprendizado não poderia ser significativamente evitado se Elisa sáísse da base. Se a escola tiver 101 alunos, por exemplo, uma eventual opção de Elisa por não autorizar a inclusão de sua nota na base levaria a média global dos alunos restantes a 61.9 pontos. Dessa forma, ao usar a informação auxiliar de que Elisa realizou a prova e obteve um nota 10 pontos acima da média, o adversário estimaria que a nota de Elisa é 71.9. Note que esta estimativa é bem próxima da nota real de Elisa, 72.

No exemplo acima, a opção de Elisa por sair da base não alteraria significativamente o que o adversário pôde aprender sobre ela. Isso pode incentivar Elisa a continuar na base, em particular quando ela tiver a percepção de que os benefícios da manutenção de uma base como esta –por exemplo, porque Censos Educacionais podem auxiliar na construção de políticas públicas de qualidade– suplantam a sua ínfima perda de privacidade.

A chave para implementação prática da privacidade diferencial é uma cuidadosa introdução de ruído a fim de confundir o adversário sobre a participação ou não de um indivíduo em uma base de dados. Se o adversário não consegue nem mesmo distinguir se um indivíduo está ou não na base, então há garantias de que ele não consegue inferir informação sensível sobre o indivíduo a partir de sua participação na base.

A privacidade diferencial tem duas variantes principais relativas a como o ruído é adicionado:

- **Privacidade diferencial global:** nesta variante, o ruído é adicionado ao resultado de cada consulta realizada. Mais precisamente, o curador mantém uma base contendo os dados reais de cada titular. A cada consulta enviada pelo analista, o curador realiza a consulta na base, obtendo a resposta real, e depois adiciona ruído a essa resposta antes de reportá-la ao analista. Esta variante da privacidade diferencial é discutida na Seção 6.2.
- **Privacidade diferencial local:** nesta variante, o ruído é adicionado diretamente aos dados coletados. Mais precisamente, ruído é adicionado aos dados de cada




Figura 6.2.2: Esquema de funcionamento da privacidade diferencial global. O curador mantém uma base com os dados reais dos titulares, e um mecanismo de consulta adiciona ruído à resposta de cada consulta antes de retorná-la ao analista de dados. O parâmetro ϵ controla o nível de ruído utilizado (e, portanto, de privacidade provida).

titular, e o curador agrupa esses dados já randomizados em uma base que pode ser considerada sanitizada de uma vez por todas. A partir daí, qualquer consulta pode ser realizada diretamente sobre a base sanitizada, ou mesmo pode-se divulgar esta base completa. Esta variante da privacidade diferencial é discutida na Seção 6.3.

Apesar de suas vantagens, a privacidade diferencial é, no geral, uma técnica complexa e que demanda uma expertise refinada de seus implementadores. Uma análise de seus prós e contras é provida na Seção 6.5.

6.2 Privacidade diferencial global

Na privacidade diferencial global, ilustrada na Figura 6.2.2, o curador mantém uma base contendo os dados reais de cada titular. A cada consulta enviada pelo analista, um mecanismo randomizado é aplicado da seguinte forma: primeiro a consulta é realizada na base de dados, obtendo uma resposta real, e em seguida ruído é adicionado a essa resposta antes de reportá-la ao analista.

Esta abordagem, entretanto, deve ser adotada com cuidado. Suponha, por exemplo, que a consulta se refira à altura de uma pessoa em centímetros, e que ao resultado de cada consulta adicione-se um ruído normal com média 0 e variância 10. O adversário simplesmente pode repetir a mesma consulta um certo número de vezes até conseguir a precisão que deseja. Tentar impedir a repetição de consultas não funciona pelos motivos já expostos anteriormente (é impossível no caso geral distinguir se duas consultas SQL formuladas de forma diferente são ou não equivalentes). Esse tipo de ataque pode ser generalizado: se existe um limite superior no ruído incluído, sempre há um adversário que consiga quebrar a privacidade. Uma análise mais aprofundada desse resultado se encontra no Anexo A.3.

6.2.1 Definição formal de privacidade diferencial- ϵ

Seja $\mathcal{R}$ o domínio de todos os valores que registros de uma base de dados podem assumir em um cenário de interesse. Uma base de dados é um multiconjunto $D = \{\{r_1, r_2, \dots, r_n\}\}$ ⁴ de registros $r_i \in \mathcal{R}$. Na literatura sobre privacidade diferencial é usual formalizar uma base de dados D como um histograma (ou um vetor) em que cada posição (ou classe) corresponde a um possível valor de registro em $r \in \mathcal{R}$, e o conteúdo da posição (ou a frequência da classe) correspondente a r , denotado por $mult_D(r)$, corresponde à multiplicidade (i.e., o número de ocorrências distintas) daquele registro r na base de dados D . Assim, o domínio de todas as bases possíveis sobre um domínio de registros $\mathcal{R}$ é denotado por $\mathcal{D}(\mathcal{R}) = \mathbb{N}^{|\mathcal{R}|}$, onde $\mathbb{N} = \{0, 1, 2, \dots\}$ denota o conjunto dos números naturais. Quando o conjunto de registros estiver claro pelo contexto, denotamos $\mathcal{D}(\mathcal{R})$ simplesmente por $\mathcal{D}$. Denotamos por $|D| = \sum_{r \in \mathcal{R}} mult_D(r)$ a *cardinalidade* (i.e., o número total de registros, incluindo repetições) de D .

Como exemplo, a base de dados representada na Tabela 5.2.1a pode ser representada pelo histograma na Tabela 5.2.1b.

Definição 9 (Bases de dados adjacentes). Duas bases $D, D' \in \mathcal{D}$ são ditas *adjacentes* quando elas diferem entre si exatamente pela adição, remoção, ou alteração no valor de um único registro. Formalmente, D e D' são adjacentes se, e somente se,

$$\|D - D'\| = 1 ,$$

onde $\|D - D'\|$ é a *norma* L_1 entre D e D' , definida como

$$\|D - D'\| \stackrel{\text{def}}{=} \sum_{r \in \mathcal{R}} |mult_D(r) - mult_{D'}(r)| .$$

◁

Algumas formulações de privacidade diferencial consideram adjacentes somente pares de bases de dados que diferem pela adição ou remoção de um único registro, mas não pela alteração. Entretanto, como uma operação de alteração pode ser sempre simulada por uma operação de remoção seguida por uma operação de adição, as definições são essencialmente equivalentes. A Tabela 6.2.3 ilustra o conceito de adjacência entre bases de dados.

A fim de evitar a extração detalhada de dados individuais, a privacidade diferencial global emprega adição de ruído às repostas das consultas realizadas sobre a base de dados. Intuitivamente, o ruído é cuidadosamente introduzido de forma que a resposta de qualquer consulta seja uma função probabilística da entrada, o que ajuda a ocultar a contribuição de qualquer indivíduo específico para esta resposta. Esta ideia, ilustrada na Figura 6.2.2, é formalizada a seguir.

⁴Um *multiconjunto* é a generalização de um conjunto, de tal forma que se permite a repetição de elementos. Ao usar multiconjuntos para modelar bases de dados, estamos permitindo que um mesmo registro apareça múltiplas vezes em uma mesma base.

Definição 10 (Privacidade diferencial- ε). Seja ε um valor real positivo, e $\mathcal{M}$ um *mecanismo de consulta* (ou um *algoritmo randomizado*) que recebe como entrada uma base de dados $D \in \mathcal{D}$ e produz como saída um valor pertencente a um conjunto $\text{img}(\mathcal{M})$. Dizemos que $\mathcal{M}$ satisfaz *privacidade diferencial- ε* se, e somente se, para todo par D, D' de bases adjacentes e para todo $S \subseteq \text{img}(\mathcal{M})$,

$$\Pr[\mathcal{M}(D) \in S] \leq e^\varepsilon \cdot \Pr[\mathcal{M}(D') \in S], \quad (6.1)$$

onde a probabilidade é tomada sobre a aleatoriedade do mecanismo e $e \approx 2.71828$ é a *constante de Euler*. $\triangleleft$

Note que a definição de privacidade diferencial é simétrica em relação ao par de bases adjacentes D e D' e, portanto, pode-se facilmente concluir que a Equação 6.1 equivale a

$$e^{-\varepsilon} \cdot \Pr[\mathcal{M}(D') \in S] \leq \Pr[\mathcal{M}(D) \in S] \leq e^\varepsilon \cdot \Pr[\mathcal{M}(D') \in S]. \quad (6.2)$$

Desta forma, a privacidade diferencial exige que a probabilidade de um mecanismo $\mathcal{M}$ retornar uma resposta em S para uma base D não seja “muito diferente” da probabilidade de o mesmo mecanismo retornar a mesma resposta em S caso a entrada fosse uma base D' adjacente. O “quão diferente” a probabilidade pode ser é definido pelo fator multiplicativo e^ε . Quanto menor ε , mais e^ε e $e^{-\varepsilon}$ se aproximam de 1 e $\Pr[\mathcal{M}(D) \in S]$ tende a se aproximar de $\Pr[\mathcal{M}(D') \in S]$. Intuitivamente, portanto, quanto menor ε , menos a alteração de um único registro na base pode alterar a resposta do mecanismo de consulta⁵, ou seja, maior é a garantia de privacidade para cada indivíduo.

6.2.2 A garantia provida por privacidade diferencial- ε

A garantia de privacidade da Definição 10 advém do fato de que se a presença, ausência ou alteração do registro de um único indivíduo pouco altera a probabilidade de qualquer resposta de um mecanismo de consulta, então um adversário não pode aprender muita informação sobre este indivíduo ao observar a resposta provida pelo mecanismo. Esta garantia vale para um adversário que conhece todo o conteúdo da base de dados, exceto justamente o registro do indivíduo alvo. Esta intuição pode ser melhor entendida ao aplicarmos o Teorema de Bayes⁶ à definição de degradação de privacidade provida na Seção 2.1. Mais precisamente, considere um cenário em que:

- (i) Antes de observar o mecanismo, o adversário conhece todos os registros de uma base de dados, exceto o de um indivíduo-alvo específico. O conhecimento a priori

⁵Note que $e^{-\varepsilon} < 1 - \varepsilon < e^0 = 1 < 1 + \varepsilon < e^\varepsilon$.

⁶O *Teorema de Bayes* diz que, dados dois eventos quaisquer A e B :

$$\Pr(A | B) = \Pr(A) \cdot \frac{\Pr(B | A)}{\Pr(B)},$$

onde $\Pr(A)$ e $\Pr(B)$ são as probabilidades a priori de A e B , respectivamente, e $\Pr(B | A)$ é a probabilidade a posteriori de B dado A .

do adversário é, então, uma distribuição de probabilidades sobre as bases adjacentes à base sobre a qual ele tem conhecimento. Em particular, para quaisquer bases adjacentes D e D' (e.g., uma base D em que o indivíduo-alvo não está e uma base adjacente D' em que ele está), o adversário tem a *razão de probabilidades a priori* $Pr[D]/Pr[D']$ representando o quão mais provável ele acha que D é em relação a D' .

- (ii) Quanto um mecanismo $\mathcal{M}$ de consulta é executado, o adversário não sabe exatamente sobre qual base ele foi executado –ele sabe apenas que trata-se de uma das bases adjacentes àquela que ele conhece. Chamemos de $Pr[\mathcal{M} \in S]$ a probabilidade de o mecanismo retornar um valor em S sobre essa base desconhecida. Ao observar o resultado em S retornado pelo mecanismo $\mathcal{M}$, o adversário pode usar o Teorema de Bayes para atualizar seu conhecimento sobre a base utilizada para uma versão a posteriori. Mais precisamente, ele pode computar a *razão de probabilidades a posteriori* como

$$\frac{Pr[D \mid \mathcal{M} \in S]}{Pr[D' \mid \mathcal{M} \in S]} = \frac{Pr[D]}{Pr[D']} \cdot \frac{Pr[\mathcal{M}(D) \in S]}{Pr[\mathcal{M}(D') \in S]}. \quad (6.3)$$

Entretanto, se o mecanismo satisfaz privacidade diferencial para um valor ε , pela Equação 6.1 temos que $Pr[D]/Pr[D'] \leq e^\varepsilon$, e a Equação 6.3 se torna

$$\frac{Pr[D \mid \mathcal{M} \in S]}{Pr[D' \mid \mathcal{M} \in S]} \leq e^\varepsilon \cdot \frac{Pr[D]}{Pr[D']}. \quad (6.4)$$

Novamente, levando em conta que a Definição de privacidade diferencial é simétrica em relação a duas bases adjacentes D e D' , a Equação 6.3 implica

$$e^{-\varepsilon} \cdot \frac{Pr[D]}{Pr[D']} \leq \frac{Pr[D \mid \mathcal{M} \in S]}{Pr[D' \mid \mathcal{M} \in S]} \leq e^\varepsilon \cdot \frac{Pr[D]}{Pr[D']}. \quad (6.5)$$

Agora a Equação 6.5 é a garantia da privacidade diferencial: a observação de qualquer resposta em qualquer intervalo S altera a razão a posteriori do conhecimento do adversário ($Pr[D \mid \mathcal{M} \in S]/Pr[D' \mid \mathcal{M} \in S]$) em relação à razão a priori ($Pr[D]/Pr[D']$) por um fator multiplicativo de, no máximo, e^ε .

Note, portanto, que quanto menor o valor de ε , menor o valor de e^ε , e mais privado é o mecanismo.

O seguinte exemplo ilustra a garantia provida pela privacidade diferencial global.

Exemplo 11 (A garantia de privacidade diferencial global). Considere que um adversário conheça todos os registros de uma base de dados, exceto aquele correspondente ao indivíduo-alvo Marco. Mais precisamente, o adversário está em dúvida entre se a base real é D (sem Marco), ou D' (com Marco).

O adversário pode consultar um mecanismo $\mathcal{M}$ que retorna a resposta para a consulta “Quantas pessoas na base têm idade maior que 15 anos?”. Se o mecanismo satisfaz

privacidade diferencial com parâmetro $\varepsilon = \ln 1.2$, então para qualquer resposta $n \in \mathbb{N}$ que o mecanismo retornar, o conhecimento a posteriori do adversário é limitado, de acordo com a Equação 6.2, por

$$\frac{1}{1.2} \cdot \Pr[\mathcal{M}(D') = n] \leq \Pr[\mathcal{M}(D) = n] \leq 1.2 \cdot \Pr[\mathcal{M}(D') = n] .$$

Isso quer dizer que Marco estar ou não na base não pode alterar o comportamento do mecanismo por um fator multiplicativo maior que 1.2.

Entretanto, a garantia de privacidade fica mais clara quando empregamos a Equação 6.5. Assuma que o adversário considere a priori que a probabilidade de Marco estar na base é de 50%. Assim, sua razão de probabilidades a priori é dada por

$$\frac{\Pr[D]}{\Pr[D']} = \frac{50\%}{50\%} = 1 .$$

Empregando a Equação 6.5, vemos que seu conhecimento a posteriori é, então, limitado por

$$\frac{1}{1.2} \cdot \frac{\Pr[D]}{\Pr[D']} \leq \frac{\Pr[D \mid \mathcal{M} \in S]}{\Pr[D' \mid \mathcal{M} \in S]} \leq 1.2 \cdot \frac{\Pr[D]}{\Pr[D']} .$$

Sabendo que $\Pr[D]/\Pr[D'] = 1$ e que $\Pr[D] + \Pr[D'] = 1$, podemos derivar a partir da equação acima que a probabilidade que o adversário atribui às bases D e D' , que era de 50% a priori para cada uma, deve ficar dentro do intervalo $[45\%, 55\%]$ mesmo após a observação da saída do mecanismo. Ou seja, há uma limitação do quanto o adversário aprendeu ao observar a base e, conseqüentemente, da correspondente degradação de privacidade.

Para efeito de comparação, se o valor do parâmetro fosse $\varepsilon = \ln 3$, o intervalo de probabilidade seria $[25\%, 75\%]$, permitindo uma maior revelação de informação sensível. De fato, quanto menor o valor de ε , maior a privacidade garantida. $\triangleleft$

6.2.3 Mecanismos para se atingir privacidade diferencial- ε

Dwork demonstrou que qualquer tipo de mecanismo de consulta que forneça algum tipo de privacidade não trivial deve necessariamente empregar aleatoriedade de alguma forma [51]. Em particular, é impossível implementar a privacidade diferencial sem utilização de ruído.

De fato, quando um mecanismo de consulta sobre uma base de dados produz como saída uma função determinística da entrada, a adição, remoção ou alteração de um registro pode ser completamente revelada, com absoluta certeza, a um adversário.

Considere, por exemplo, que um adversário tenha o conhecimento a priori de que Nélio está em uma base D , e que ele é a única pessoa na base nascida em 1990. Agora suponha que D' seja a base (adjacente à D) que possui todas as pessoas de D , exceto Nélio.

O adversário pode usar um mecanismo $\mathcal{M}$ que retorna a resposta à consulta “*Quantas pessoas na base nasceram em 1990?*”. Se o mecanismo $\mathcal{M}$ for determinístico, temos que, ao ser aplicado na base D , a resposta retornada é sempre 1 (i.e., $Pr[\mathcal{M}(D) = 1] = 100\%$), enquanto que, ao ser aplicado na base D' , a resposta retornada é sempre 0 (i.e., $Pr[\mathcal{M}(D') = 1] = 0\%$). Portanto, mesmo que as bases D e D' sejam adjacentes (elas diferem apenas pela presença ou ausência de Nélío), temos que não existe nenhum valor de $\varepsilon > 0$ satisfazendo

$$Pr[\mathcal{M}(D) = 1] \leq e^\varepsilon \cdot Pr[\mathcal{M}(D') = 1] .$$

Portanto, tal mecanismo determinístico não satisfaz privacidade diferencial- ε para nenhum valor de ε .

Neste contexto, apresentamos a seguir as abordagens mais populares para se atingir privacidade diferencial. Todas se baseiam na adição de ruído, e a forma como isso é feito depende do tipo de dados. Interessantemente, o ruído gaussiano não é conveniente para este tipo de aplicação. Os mecanismos recebem o nome do tipo de distribuição que empregam.

- *Mecanismo de Laplace*: usado para consultas que retornam como resposta valores numéricos contínuos (e.g., altura média de uma população).
- *Mecanismo geométrico*: usado para consultas que retornam como resposta valores numéricos discretos (e.g., número de indivíduos que satisfaz uma certa propriedade).
- *Mecanismo exponencial*: usando para consultas que retornam como resposta valores categóricos (e.g., a enfermidade mais comum em uma população, ou o estado da federação com a maior proporção de alunos no sistema público de ensino).

A seguir apresentamos cada mecanismo em mais detalhes.

6.2.3.1 Mecanismo de Laplace

O mecanismo de Laplace é adequado quando a consulta retorna valores numéricos contínuos. Seja $f: \mathcal{D} \rightarrow \mathbb{R}^k$ uma consulta que recebe uma base de dados como entrada e retorna como resultado um vetor de $k \geq 1$ valores reais. Dada uma base D fornecida como entrada, o mecanismo de Laplace primeiramente realiza a consulta f em D , obtendo um resultado $f(D)$, e, em seguida, adiciona um ruído η a $f(D)$ tomado por uma distribuição de Laplace.

Um passo crucial no processo de adição de ruído é o cálculo do impacto máximo que a adição, remoção ou alteração do registro de um único indivíduo ocasiona na resposta de uma consulta. Para este fim, definimos a sensibilidade de uma consulta como a maior influência que a adição, remoção ou alteração de um único registro em uma base de dados pode ocasionar na resposta retornada por f .

Definição 12 (Sensibilidade ℓ_1 de uma consulta). A *sensibilidade* ℓ_1 de uma consulta $f: \mathcal{D} \rightarrow \mathbb{R}^k$, com $k \geq 1$, é dada por

$$\Delta f \stackrel{\text{def}}{=} \max_{\substack{D, D' \in \mathcal{D} \\ D, D' \text{ adjacentes}}} \|f(D) - f(D')\|_1.$$

◁

O seguinte exemplo ilustra o cálculo da sensibilidade de consultas.

Exemplo 13 (Sensibilidade de consultas). Considere D como sendo a base de dados representada na Tabela 5.2.1a. Vamos analisar a sensibilidade de dois tipos de consulta.

- (I) Considere uma consulta de contagem (*counting query*, do original em inglês) $f =$ “*Quantas pessoas possuem AIDS?*”. Temos que a resposta desta consulta em D é $f(D) = 2$ (que corresponde aos registros de *id*’s 5 e 6). A sensibilidade ℓ_1 de f captura o impacto máximo que a adição ou remoção de um registro ocasiona na resposta retornada por f . Como f é uma consulta de contagem, que neste caso retorna o número de registros que possuem o valor **AIDS** para o atributo *enfermidade*, então a adição ou remoção de um registro pode, no máximo, incrementar ou decrementar 1 no resultado retornada por f .

Sendo assim, o impacto máximo que a adição, remoção ou alteração do valor de um único registro causa na resposta da consulta f é $\Delta f = 1$. Ressaltamos que este resultado também é válido para qualquer outra consulta de contagem, isto é, qualquer consulta do tipo “*Quantos registros satisfazem a propriedade P?*”.

- (II) Considere agora, a consulta $f' =$ “*Qual a média das idades dos indivíduos?*”. Temos que a resposta para esta consulta é $f'(D) = 39.67$. Para calcular a sensibilidade ℓ_1 de f' , vamos considerar que as idades dos indivíduos estão no intervalo $[0, 120]$ (i.e., o domínio do atributo *idade*, onde 0 representa uma pessoa que ainda não completou um ano de vida). Devemos então analisar qual a maior diferença entre médias de idade de bases de dados vizinhas.

Em se tratando de média de valores, quanto menor a quantidade de elementos do conjunto analisado, maior é o impacto que um valor específico pode causar na média. Como queremos capturar o maior impacto que adição, alteração ou remoção de um registro pode ocasionar no resultado da consulta f' , tomaremos uma base D que possui somente 1 indivíduo. Se considerarmos que a idade deste indivíduo é 0, então a média das idades dos registros em D é 0. A base de dados vizinha D' com a média das idades mais distante de 0 é aquela que também possui somente 1 indivíduo, mas que tem 120 anos de idade. Desta forma, a diferença entre estas médias é $\|f(D) - f(D')\|_1 = 120$. É fácil observar que a diferença entre as médias das idades de quaisquer outras duas bases de dados vizinhas não será superior a 120.

Sendo assim, o impacto máximo que a adição, remoção ou alteração do valor de um único registro causa na resposta da consulta f' é $\Delta f' = 120$.

Note que a sensibilidade é definida em termos da influência de um registro em cada consulta, não de um titular de dados. Se cada titular possui no máximo um registro na base de dados, e sua opção por participar ou não da mesma ocorre de forma independente dos demais titulares, então sua influência em uma consulta é a mesma influência de um único registro. Entretanto, o estudo da sensibilidade é mais delicado quando um indivíduo pode aparecer múltipla vezes em uma base de dados, ou quando há correlação entre registros. Nesse caso, a adição ou remoção de um indivíduo pode alterar mais do que um registro, o que afeta a sensibilidade da consulta com relação à influência de indivíduos. Essa sutileza é melhor discutida na Seção 3.1.2. $\triangleleft$

Idealmente o ruído deve ser o menor possível que ainda seja capaz de ocultar a influência de um único indivíduo no resultado. A sensibilidade ℓ_1 de uma função f é utilizada no cálculo desde ruído mínimo.

A distribuição de Laplace é uma distribuição de probabilidade contínua com um parâmetro de localidade μ e um parâmetro de escala b . Uma variável aleatória segue uma distribuição $Lap(\mu, b)$ se a sua função de densidade de probabilidade é dada por

$$Lap(x \mid \mu, b) = \frac{1}{2b} \cdot e^{-\frac{|x-\mu|}{b}}. \quad (6.6)$$

A distribuição de Laplace tem grande aplicabilidade em privacidade diferencial. Em particular, de acordo com o Teorema 3.6 em [51], um mecanismo aleatório $\mathcal{M}_L$ que adicione ruído à resposta real amostrado de uma distribuição de Laplace com centralidade $\mu = 0$ e escala $b = \Delta f/\varepsilon$ satisfaz privacidade diferencial- ε . Formalmente, tal mecanismo é definido como a seguir.

Definição 14 (Mecanismo de Laplace). Seja $f: \mathcal{D} \rightarrow \mathbb{R}^k$, com $k \geq 1$ uma consulta, e $\varepsilon > 0$ um parâmetro de privacidade. Um mecanismo de Laplace $\mathcal{M}_L$ é definido, para toda base de dados $D \in \mathcal{D}$ fornecida como entrada, como

$$\mathcal{M}_L(D, f(\cdot), \varepsilon) = f(D) + (Y_1, \dots, Y_k),$$

onde cada Y_i é a variável aleatória correspondendo ao ruído a ser adicionado ao componente i da resposta, amostrada de acordo com a distribuição $Lap(0, \Delta f/\varepsilon)$. $\triangleleft$

O seguinte exemplo ilustra a adição de ruído de Laplace à resposta de uma consulta.

Exemplo 15 (Adição de ruído de Laplace). A Figura 6.2.4 ilustra como funciona a adição de ruído de Laplace para o Exemplo 13, onde a consulta $f = \text{“Quantos indivíduos possuem AIDS?”}$. Para alcançar privacidade diferencial com um valor ε , o mecanismo em questão deve obter a resposta real $f(D)$ (que neste exemplo é igual a 2) e então adicionar um ruído de acordo com $Lap(0, 1/\varepsilon)$.⁷ Na Figura 6.2.4a podemos ver aproximadamente com qual probabilidade o mecanismo retornará cada um dos valores para a consulta f .

⁷Note que $f(D) + x$, onde $x \sim Lap(0, 1/\varepsilon)$ é equivalente a $y \sim Lap(f(D), 1/\varepsilon)$.

Suponha que haja um adversário que deseje descobrir qual o valor real da consulta f . Ele observará um valor $(0, 1, \dots)$, e sabendo que um ruído foi adicionado pelo mecanismo a este valor, ele tentará inferir qual o valor real. Na Figura 6.2.4b podemos ver com quais probabilidades o mecanismo retornaria um valor para quando o valor real fosse 2 (curva vermelha) ou 3 (curva azul). É possível ver que o valor retornado está bem próximo do valor real em ambas as curvas, o que indica que pouco ruído é adicionado. Ao mesmo tempo o gráfico nos mostra que a interseção das duas curvas é pequena, o que significa que, se o valor retornado pelo mecanismo foi 2, com alta probabilidade o valor real é 2, e com baixa probabilidade ele é 3. O mesmo raciocínio pode ser aplicado se o mecanismo retornar o valor 3. Sendo assim, um ε alto adiciona pouco ruído nos dados, contudo, o nível de privacidade permanece baixo.

Atente agora para o gráfico da Figura 6.2.4c. Ele é semelhante ao gráfico da Figura 6.2.4b, com a diferença de que o ruído adicionado agora é proporcional a $\varepsilon = 1$. De forma direta, é possível ver que a interseção das curvas é bem maior que a da figura anterior. Isto indica que, se o valor retornado pelo mecanismo foi 2, o adversário não conseguirá inferir com alta precisão se o valor real da consulta é 2 ou 3. Em contrapartida, podemos ver que a quantidade de ruído adicionada é maior, isto é, o mecanismo atribui uma distribuição de probabilidade mais dispersa do valor real.

Já na Figura 6.2.4d, é possível ver que com um ε pequeno (comparado ao $\varepsilon = 4$ da Figura 6.2.4b), a interseção entre as duas curvas é pequena, ou seja, se o valor retornado pelo mecanismo foi 4, o adversário não conseguirá inferir com alta precisão se o valor real é 2 ou 5.⁸

◁

6.2.3.2 Mecanismo geométrico

O mecanismo geométrico é adequado quanto a consulta retorna valores numéricos discretos. Seja $f: \mathcal{D} \rightarrow \mathbb{Z}$ uma consulta que recebe uma base de dados como entrada e retorna como resultado um valor inteiro. Dada uma base D fornecida como entrada, o mecanismo geométrico primeiramente realiza a consulta f em D , obtendo um resultado $f(D)$, e, em seguida, adiciona um ruído X a $f(D)$ tomado por uma distribuição geométrica.

Definição 16 (Mecanismo Geométrico). Seja $f: \mathcal{D} \rightarrow \mathbb{Z}$ uma consulta, e $\varepsilon > 0$ um parâmetro de privacidade. Um mecanismo geométrico $\mathcal{M}_G$ é definido, para toda base de dados $D \in \mathcal{D}$ fornecida como entrada, como

$$\mathcal{M}_G(D, f(\cdot), \varepsilon) \stackrel{\text{def}}{=} f(D) + X ,$$

⁸Os gráficos da Figura 6.2.4 apresentam simplificações da adição de ruído, e isto foi feito para fins didáticos. Conforme dito anteriormente, o Mecanismo de Laplace é utilizado para consultas que retornam como resposta valores numéricos contínuos, e os gráficos da Figura 6.2.4 estão relacionados à uma pergunta que retorna valores discretos (números inteiros). No contexto da consulta $f = \text{"Quantos indivíduos possuem AIDS?"}$ o mais adequado seria a utilização do Mecanismo Geométrico, visto que a resposta de f pertence ao conjunto dos números inteiros positivos.

em que X é a variável aleatória correspondendo ao ruído a ser adicionado à resposta, amostrada de acordo com a distribuição geométrica definida, para todo $x \in \mathbb{Z}$,

$$Pr(X = x) = \frac{1 - \alpha}{1 + \alpha} \cdot \alpha^{|x|},$$

onde $\alpha = e^{-\varepsilon/\Delta f}$ e Δf é a sensibilidade ℓ_1 de f . $\triangleleft$

É possível demonstrar que o mecanismo geométrico definido acima satisfaz privacidade diferencial- ε [58].

A fim de evitar ter que lidar com um ruído que pode ter domínio infinito no caso do mecanismo geométrico (o ruído pode ser qualquer valor inteiro), podemos usar a versão truncada do mecanismo. A ideia central desta adaptação é que a massa de probabilidade de qualquer valor fora do domínio é remapeada para os limites do domínio. O mecanismo geométrico truncado também satisfaz privacidade diferencial [58].

6.2.3.3 Mecanismo exponencial

O mecanismo de exponencial é adequado quando a consulta retorna valores categóricos não numéricos, como raça, cor de olhos, estado de nascimento. Seja $f : \mathcal{D} \rightarrow \mathcal{C}$ uma consulta que recebe uma base de dados como entrada e retorna como resultado um valor categórico de um conjunto $\mathcal{C}$. Nestes casos, não é tão imediato adicionar ruído à resposta da consulta, uma vez que não se trata de valores numéricos. O mecanismo exponencial utiliza uma função de utilidade $u : \mathcal{D} \times \mathcal{C} \rightarrow \mathbb{R}$, tal que cada valor $u(D, c)$ representa a utilidade de se retornar a resposta $c \in \mathcal{C}$ quando a base utilizada na consulta é $D \in \mathcal{D}$.

O ruído adicionado é, então, proporcional ao maior impacto que a adição, remoção ou alteração de um registro pode acarretar na utilidade de uma consulta.

Definição 17 (Sensibilidade de uma função de utilidade). Seja $\mathcal{C}$ a imagem da consulta f sobre bases de dados em $\mathcal{D}$, e $u : \mathcal{D} \times \mathcal{C} \rightarrow \mathbb{R}$ uma função de utilidade para esta consulta. A *sensibilidade de u* é definida como

$$\Delta u \stackrel{\text{def}}{=} \max_{c \in \mathcal{C}} \max_{\substack{D, D' \in \mathcal{D} \\ D, D' \text{ adjacentes}}} |u(D, c) - u(D', c)|.$$

$\triangleleft$

Assim sendo, definimos o mecanismo exponencial a seguir.

Definição 18 (Mecanismo exponencial). Seja $\mathcal{A}$ a imagem do mecanismo exponencial $\mathcal{M}_E(b, u(\cdot, \cdot), \varepsilon)$ e u a função de utilidade $\mathbb{N}^{|\mathcal{R}|} \times \mathcal{A} \rightarrow \mathbb{R}$. Temos que $\mathcal{M}_E$ retorna $a \in \mathcal{A}$ com probabilidade $e^{(\varepsilon u(b, a) / 2 \Delta u)}$. $\triangleleft$

É possível demonstrar que o mecanismo geométrico definido acima satisfaz privacidade diferencial- ε [47] (Teorema 3.10).

6.2.4 Propriedades da privacidade diferencial- ε

Uma das maiores fragilidades dos métodos sintáticos vistos na Seção 4 é a sua não composicionalidade. De fato, o Exemplo 5 ilustra que mesmo que duas bases satisfaçam uma noção como anonimidade- k , diversidade- ℓ ou proximidade- t , a composição das duas não necessariamente também satisfaz a propriedade.

Por outro lado, a privacidade diferencial satisfaz importantes propriedades de composicionalidade. Mais especificamente, imagine que dois mecanismos $\mathcal{M}_1$ e $\mathcal{M}_2$ satisfaçam privacidade diferencial para valores ε_1 e ε_2 , respectivamente. Se o conjunto das possíveis respostas que $\mathcal{M}_1$ e $\mathcal{M}_2$ podem dar são C_1 e C_2 , respectivamente, então a combinação destes dois mecanismos, i.e., um mecanismo $\mathcal{M}_{1,2}$, retorna um par ordenado $(i, j) \in C_1 \times C_2$ como resposta para a consulta combinada. Ao se combinarem mecanismos desta forma, temos a propriedade de que os diferentes ε_i se somam, ou seja, $\mathcal{M}_{1,2}$ neste caso satisfaz privacidade diferencial- $(\varepsilon_1 + \varepsilon_2)$. Este resultado é formalizado no seguinte teorema.

Teorema 19 (Composicionalidade sequencial de privacidade diferencial [47]). *Seja $\mathcal{M}_1, \dots, \mathcal{M}_n$ um conjunto de n mecanismos, cada $\mathcal{M}_i$ satisfazendo privacidade diferencial para um valor ε_i , e aplicados de forma independente. Então, qualquer função $g(\mathcal{M}_1, \dots, \mathcal{M}_n)$ destes mecanismos satisfaz privacidade diferencial para o valor $\sum_{i=1}^n \varepsilon_i$.*

A título de exemplo da utilidade do teorema acima, suponha que um adversário realize uma consulta a uma base de dados usando um mecanismo de consulta $\mathcal{M}$ que satisfaça privacidade diferencial para um valor ε . Se o adversário utilizar o mesmo mecanismo para uma nova consulta à mesma base, a combinação das duas consultas satisfaz privacidade diferencial para um valor 2ε .

De fato, quando se tem um mecanismo aleatório que retorna respostas probabilisticamente, quanto mais respostas ele retorna, a resposta média, dada por cada instância do mecanismo, irá eventualmente convergir para o valor real da estatística [47]. A privacidade diferencial apresenta uma forma de composicionalidade sequencial, pois a garantia de privacidade se degrada de forma suave e gradual com o uso repetido dos mecanismos aleatórios.

Uma outra propriedade importante da privacidade diferencial é a seguinte.

Teorema 20 (Composicionalidade paralela de privacidade diferencial [47]). *Seja $\mathcal{M}_1, \dots, \mathcal{M}_n$ um conjunto de n mecanismos, cada $\mathcal{M}_i$ satisfazendo privacidade diferencial para um valor ε_i . Se cada mecanismo é aplicado a um subconjunto disjunto da base de dados de entrada, então qualquer função $g(\mathcal{M}_1, \dots, \mathcal{M}_n)$ destes mecanismos satisfaz privacidade diferencial para o valor $\max_i \varepsilon_i$.*

Por fim, a privacidade diferencial é resistente a pós-processamento. Isso significa que um adversário que realize computações arbitrárias apenas sobre a saída de um mecanismo que respeita privacidade diferencial- ε , esse adversário não consegue reverter a garantia de privacidade do mecanismo. Esta propriedade é formalizada a seguir.

Teorema 21 (Privacidade diferencial resiste a pós-processamento [45]). *Seja $\mathcal{M}$ um mecanismo satisfazendo privacidade diferencial para um valor ε , e seja F uma função (determinística ou probabilística) definida sobre a imagem de $\mathcal{M}$. Então $F(\mathcal{M})$ também satisfaz privacidade diferencial para o mesmo valor ε .*

Em seguida, apresentamos a variante local de privacidade diferencial.

6.3 Privacidade diferencial local

Na privacidade diferencial local, cujo esquema geral de funcionamento é ilustrado na Figura 6.3.5, ruído é adicionado aos dados de cada titular, e o curador agrupa esses dados já randomizados em uma base que pode ser considerada sanitizada de uma vez por todas. A partir daí, qualquer consulta é diretamente realizada sobre a base sanitizada, podendo o curador até mesmo divulgar esta base em sua forma completa para os analistas.

De forma similar ao que ocorre em sua variante global, também na privacidade diferencial local o ruído deve ser adicionado cuidadosamente. Mais precisamente, visa-se a que, apesar dos dados de cada titular serem individualmente transformados, as propriedades estatísticas do conjunto de dados sejam mantidas tanto quanto possível. Adicionar ruído diretamente aos dados dos titulares pode ser conveniente nas seguintes situações.

- **Quando os titulares não confiam no curador.** Em algumas situações os titulares podem considerar que o curador é um adversário em potencial. Neste caso os próprios titulares podem adicionar ruído aos seus dados antes de enviá-los ao curador, tornando-o incerto sobre os dados de qualquer indivíduo em particular.
- **Quando o curador não deseja ou não tem condições de aplicar mecanismos de privacidade diferencial global para responder individualmente a cada consulta dos analistas.** Em algumas situações o curador pode ser considerado confiável e ter acesso aos dados reais dos titulares, mas mesmo assim não ter interesse ou os recursos necessários para empregar mecanismos de privacidade diferencial global e responder individualmente a cada consulta posta por analistas (e.g., porque manter o controle de consultas é dispendioso, ou porque o número de consultas permitidas em uma versão global de privacidade diferencial é limitado, como discutido na Seção 3.1.2.) Neste caso, o curador pode, ele mesmo, introduzir ruído aos dados de cada titular individualmente, obtendo assim uma base sanitizada, e, em seguida, disponibilizar esta base para os analistas realizarem livremente as próprias consultas sobre a mesma. Como a privacidade diferencial local também goza da propriedade de resistência a pós-processamento (equivalente ao Teorema 21 para privacidade diferencial global), é garantido que nenhum analista pode reverter as garantias de privacidade embutidas na base sanitizada.

No contexto dos Censos Educacionais do Inep, fica claro que a primeira motivação acima não se aplica, mas potencialmente a segunda. Mais precisamente, o Inep pode aplicar

privacidade diferencial local para sanitizar os microdados e disponibilizar a base assim obtida para os analistas. Entretanto, é importante ressaltar que, conforme discutido na Seção 3.1.2, o uso de privacidade diferencial local pode ter um custo elevado na utilidade dos dados. No restante desta seção apresentamos a filosofia central da privacidade diferencial local e discutimos suas formas de implementação mais usuais e suas propriedades essenciais.

6.3.1 A filosofia da privacidade diferencial local

Um dos pilares da privacidade é o conceito de *negação plausível*, que garante que um indivíduo possa negar de forma crível a um adversário que ele tenha participado em um estudo, ou que um de seus atributos tenha um valor específico. A possibilidade de negação plausível é essencial para convencer indivíduos a participar honestamente –i.e., sem mentir– de pesquisas que envolvam o fornecimento de informação sensível [51].

Em 1965, o pesquisador S. L. Warner propôs a técnica de *resposta aleatorizada* (*randomized response*, no original em inglês), para lidar com o problema [105]. O emprego da técnica é ilustrado no exemplo seguinte.

Exemplo 22 (Reposta aleatorizada aplicada a uma pesquisa sobre uso de drogas ilícitas). Suponha que pesquisadores desejem estimar a proporção de indivíduos em uma população que fazem uso de drogas ilícitas. Naturalmente há receio por parte das pessoas em participar da pesquisa, uma vez que o provimento de respostas honestas pode produzir consequências sociais e judiciais negativas.

Para contornar o problema, pode-se aplicar o mecanismo de resposta aleatorizada ao estudo da seguinte forma. Ao ser indagado com a pergunta “*Você faz uso de alguma droga ilícita?*”, cada participante da pesquisa é instruído a prover uma resposta “**sim**” ou “**não**” de acordo com o seguinte procedimento.

1. Jogue uma moeda para cima.
2. Se o resultado obtido no lançamento for **cara**, responda honestamente à pergunta.
3. Se o resultado for **coroa**, jogue uma segunda moeda para cima; se o resultado obtido neste segundo lançamento for **cara**, responda “**sim**”, caso contrário, responda “**não**”.

A Tabela 6.3.6 ilustra a aplicação da metodologia sobre uma população de 10 pessoas. Note que o procedimento garante a possibilidade de negação plausível para cada respondente: mesmo que ele tenha respondido “**sim**” à pergunta (como no caso de Ana, Danilo e Hugo), ele pode alegar de forma crível que a resposta seja falsa e se deva tão somente ao resultado aleatório do lançamento das moedas.

Entretanto, mesmo após a adição de ruído às respostas de cada participante, o procedimento ainda permite a estimação da proporção de indivíduos na população que faz uso de drogas. Note que o desenho do experimento leva à expectativa, caso o número de respondentes seja grande o suficiente, de que:

- metade dos indivíduos forneça a resposta honesta para a pergunta (aqueles que obtiverem **cara** no primeiro lançamento da moeda);
- um quarto dos indivíduos forneça a resposta “**sim**” independentemente de se ela é ou não acurada (aqueles que obtiverem **coroa** no primeiro lançamento e **cara** no segundo); e
- um quarto dos indivíduos forneça a resposta “**não**” independentemente de se ela é ou não acurada (aqueles que obtiverem **coroa** em ambos os lançamentos).

Assim, espera-se que forneçam a resposta “**sim**” à pergunta cerca de $3/4$ dos participantes que fazem uso da droga e cerca de $1/4$ dos participantes que não usam a droga. Portanto, sendo f a fração de pessoas na população que fazem o uso da droga, e s a fração de pessoas que responderam “**sim**” à pergunta, obtemos a relação

$$s \approx \frac{3}{4}f + \frac{1}{4}(1 - f) ,$$

e a partir dela obtemos uma estimativa $\hat{f}$ da real proporção f como

$$\hat{f} = 2s - \frac{1}{2} . \quad (6.7)$$

Voltando à Tabela 6.3.6, temos que $f = 20\%$ da população amostrada realmente faz uso da droga, enquanto $s = 30\%$ dos respondentes proveram a resposta “**sim**” à pergunta. Logo, de acordo com a Equação 6.7, o resultado desta pesquisa levaria à estimação de que a proporção de usuários de droga na população é de $\hat{f} = 2 \cdot 30\% - 1/2 = 10\%$.

Note que o emprego do mecanismo resposta aleatorizada aumentou a privacidade dos respondentes a um custo na utilidade dos dados: a estimativa dos usuários de drogas se desviou do número real por 10%. Entretanto, o exemplo aqui utilizado consiste em uma base muito pequena. No geral, quanto maior a base, maior tende a ser a utilidade dos dados. $\triangleleft$

A privacidade diferencial local foi formalizada em 2008 por Kasiviswanathan, Lee, Nissim, Raskhodnikova e Smith [68], tendo como espírito filosofia semelhante à da técnica de resposta aleatorizada. Na próxima seção formalizamos seu conceito.

6.3.2 Definição formal de privacidade diferencial local- ϵ

A formalização de privacidade diferencial local é análoga à sua contrapartida global (Definição 10). A principal diferença é que na versão global a probabilidade é considerada sobre os valores de toda uma base de dados tomada como entrada, enquanto na versão local a probabilidade considerada é sobre apenas o registro de cada indivíduo.

Recorde que denotamos por $\mathcal{R}$ o domínio de todos os valores que registros de uma base de dados podem assumir em um cenário de interesse. Na privacidade diferencial local consideramos que um mecanismo aleatório é aplicado a cada registro $x \in \mathcal{R}$, produzindo uma versão sanitizada deste registro. Esta ideia é formalizada abaixo.

Definição 23 (Privacidade diferencial- ε (local)). Seja ε um valor real positivo, e $\mathcal{M}$ um mecanismo local de aleatorização (ou um algoritmo randomizado local) que recebe como entrada um registro $x \in \mathcal{R}$ de um indivíduo e produz como saída um valor pertencente a um conjunto $\text{img}(\mathcal{M})$. Dizemos que $\mathcal{M}$ satisfaz *privacidade diferencial- ε (local)* se, e somente se, para todo par x, x' registros que devam ser indistinguíveis e para todo $S \subseteq \text{img}(\mathcal{M})$,

$$\Pr[\mathcal{M}(x) \in S] \leq e^\varepsilon \cdot \Pr[\mathcal{M}(x') \in S] , \quad (6.8)$$

onde a probabilidade é tomada sobre a aleatoriedade do mecanismo. $\triangleleft$

6.3.3 Mecanismos para se atingir privacidade diferencial local- ε

Os mecanismos básicos para se atingir a privacidade diferencial local são análogos aos para se atingir a versão global, descritos na Seção 6.2.3. A diferença essencial consiste apenas em aplicar a randomização ao registro de cada indivíduo, em vez de aplicá-la ao resultado final de uma consulta. Por exemplo, versões similares ao Mecanismo de Laplace (Definição 14), ao Mecanismo Geométrico (Definição 16) e ao Mecanismo Exponencial (Definição 18) podem ser usadas para randomizar, respectivamente, atributos numéricos contínuos, atributos numéricos discretos e atributos categóricos de um registro individual.

Entretanto, o uso de privacidade diferencial local tem um impacto significativamente maior na utilidade dos dados que a privacidade diferencial global. (A Seção 3.1.2 discute isso em mais detalhes). Por esta razão, técnicas muito mais sofisticadas têm sido propostas para tentar tornar a privacidade diferencial local viável [37, 108].

6.3.4 Propriedades e garantias da privacidade diferencial local- ε

A privacidade diferencial local satisfaz propriedades análogas às da sua versão global fornecidas na Seção 6.2.4. Mais especificamente, a privacidade diferencial local apresenta composicionalidade em paralelo e sequencial, e é resistente a pós-processamento. Além disso, as garantias da privacidade diferencial local são análogas às da sua versão global fornecidas na Seção 6.2.2.

O Exemplo a seguir ilustra com mais detalhes as garantias da privacidade diferencial local e seu custo em termos da utilidade dos dados.

Exemplo 24 (O compromisso entre privacidade vs. utilidade em privacidade diferencial local). Considere novamente o cenário do Exemplo 22, em que pesquisadores desejam estimar a proporção de indivíduos em uma população que fazem uso de drogas ilícitas. A pesquisa usa a metodologia de resposta aleatorizada, em que, ao ser indagado com a pergunta “Você faz uso de alguma droga ilícita?”, cada participante é instruído a prover uma resposta “sim” ou “não” seguindo o procedimento ilustrado na Figura 6.3.7. Mais precisamente, cada respondente joga uma moeda para cima: se o resultado for cara, responde

honestamente à pergunta; se for coroa, joga outra moeda e responde “sim” ou “não” dependendo de se o resultado desta segunda moeda foi cara ou coroa, respectivamente.

Considere que a primeira moeda lançada por cada participante tenha um viés $b \in [0, 1]$ em favor do resultado **coroa**, (i.e., b é a probabilidade da moeda retornar **coroa**, e $1 - b$ é a probabilidade da moeda retornar **cara**), mas que a segunda moeda seja justa (i.e., a probabilidade de **cara** e **coroa** é de 0.5 para cada). A Tabela 6.3.8 provê as probabilidades condicionais de um indivíduo responder afirmativa ou negativamente à pergunta da pesquisa dependendo de se ele é ou não consumidor de drogas.

Seria natural desejar que o mecanismo de resposta aleatorizada provesse máxima privacidade aos respondentes, ao mesmo tempo em que permitisse ao analista de dados obter a proporção correta de usuários de drogas na população. Entretanto, tal cenário ideal não é atingível, como explicamos abaixo.

Chamemos de *drogas* e *resposta* as variáveis aleatórias, ambas com domínio $\{\text{sim}, \text{não}\}$, que indicam, respectivamente, se um indivíduo é usuário de drogas e se ele respondeu à pergunta da pesquisa afirmativamente. Intuitivamente, neste mecanismo:

- (i) A privacidade para cada respondente está ligada à sua capacidade de poder recorrer à negação plausível, mesmo que sua resposta para a pergunta seja afirmativa. Em outras palavras, o nível de credibilidade da negação do titular é dado pela probabilidade de ele realmente não usar drogas mesmo que ele tenha respondido “sim” à pergunta, que é dada por $p(\text{drogas} = \text{não} \mid \text{resposta} = \text{“sim”})$.
- (ii) A utilidade para o analista de dados é tão maior quanto mais próximas forem a proporção de respostas afirmativas obtidas na pesquisa, dada por $p(\text{resposta} = \text{“sim”})$, e a proporção de indivíduos que realmente usam drogas na população, dada por $p(\text{drogas} = \text{sim})$.

Note que o viés b da primeira moeda funciona como um parâmetro que controla o compromisso entre privacidade e utilidade. Quanto maior o valor de b , mais privado é o mecanismo (pois mais provável é que a resposta de cada indivíduo seja aleatória, o que aumenta a plausibilidade de sua negação), porém menos útil é o resultado da pesquisa para o analista de dados (pois a proporção de respostas afirmativas na pesquisa se afasta da proporção real de usuário de drogas na população de interesse, que, de acordo com a Tabela 6.3.6, é de $p(\text{drogas} = \text{sim}) = 0.20$). A Figura 6.3.9a ilustra a relação do valor de b com a utilidade e a privacidade do mecanismo resultante.⁹

⁹Para o leitor interessado, aqui apresentamos os cálculos que levaram aos gráficos da Figura 6.3.9. Primeiro note que a probabilidade de se obter uma resposta afirmativa nesta população é dada por

$$\begin{aligned}
 p(\text{resposta} = \text{“sim”}) &= p(\text{drogas} = \text{sim}) \cdot p(\text{resposta} = \text{“sim”} \mid \text{drogas} = \text{sim}) + \\
 &\quad p(\text{drogas} = \text{não}) \cdot p(\text{resposta} = \text{“sim”} \mid \text{drogas} = \text{não}) \quad (\text{marginalização}) \\
 &= p(\text{drogas} = \text{sim}) \cdot (1 - 0.5b) + (1 - p(\text{drogas} = \text{sim})) \cdot 0.5b \quad (\text{Tabela 6.3.8}) \\
 &= (1 - b) \cdot p(\text{drogas} = \text{sim}) + 0.5b, \quad (6.9)
 \end{aligned}$$

Por fim, note que, através da análise da Tabela 6.3.8, percebemos que para cada valor do viés b da primeira moeda o mecanismo resultante atinge um valor de ε diferente para a privacidade diferencial, dado por ¹⁰

$$\varepsilon(b) = \ln \frac{1 - 0.5b}{0.5b}.$$

Esta relação é ilustrada na Figura 6.3.9b: quanto maior o valor de b , mais a resposta de cada indivíduo é puramente aleatória, e mais privado é o mecanismo resultante (i.e., menor é o valor de ε).

Por fim, a Figura 6.3.9c apresenta a relação entre o valor do parâmetro ε , utilidade e privacidade. $\triangleleft$

6.4 Outras aplicações de privacidade diferencial

Nesta seção provemos alguns exemplos de aplicação da privacidade diferencial na prática que ilustram tanto as vantagens quanto os desafios apresentados pela técnica.

6.4.1 Divulgação de microdados por amostragem

Conforme discutido na Seção 4.2, vários curadores de dados utilizam a técnica de divulgar microdados de apenas uma amostra aleatoriamente selecionada da população a fim de mitigar danos à privacidade. Entretanto, como ilustra o Exemplo 6 daquela mesma seção, enquanto a probabilidade de um indivíduo não usar drogas mesmo tendo respondido afirmativamente à pergunta da pesquisa é dada por

$$\begin{aligned} p(\text{drogas} = \text{não} \mid \text{resposta} = \text{"sim"}) &= && \text{(pelo Teorema de Bayes)} \\ \frac{p(\text{drogas} = \text{não}) \cdot p(\text{resposta} = \text{"sim"} \mid \text{drogas} = \text{não})}{p(\text{resposta} = \text{"sim"})} &= && \text{(Tabela 6.3.8 e Eq. 6.9)} \\ \frac{0.5b \cdot (1 - p(\text{drogas} = \text{sim}))}{(1 - b) \cdot p(\text{drogas} = \text{sim}) + 0.5b} &= && (6.10) \end{aligned}$$

Levando em conta que de acordo com a Tabela 6.3.6, 20% da população realmente usa drogas, temos que $p(\text{drogas} = \text{sim}) = 0.20$. Substituindo este valor nas Equações 6.9 e 6.10 obtemos, respectivamente, que a equação relaciona a proporção de respostas afirmativas ao viés b da primeira moeda é $p(\text{resposta} = \text{"sim"}) = 0.2 + 0.3b$, enquanto a equação que relaciona a negação plausível ao viés b é $p(\text{drogas} = \text{não} \mid \text{resposta} = \text{"sim"}) = 0.40b/(0.2+0.3b)$.

¹⁰Isto porque o mecanismo de resposta aleatorizada utilizado neste exemplo está inteiramente representado na Tabela 6.3.8. Chamando este mecanismo de $\mathcal{M}$, a privacidade diferencial local- ε (Definição 23) exige que para todo valor possível do registro real do titular (**sim** ou **não**) e para toda resposta possível (**"sim"** ou **"não"**) do mecanismo $\mathcal{M}$, tenhamos $Pr[\mathcal{M}(x) \in S] \leq e^\varepsilon \cdot Pr[\mathcal{M}(x') \in S]$. Pode-se verificar, então, que $\mathcal{M}$ satisfaz privacidade diferencial- ε para um valor ε qualquer se, e somente se,

$$e^{-\varepsilon} \leq \frac{Pr[\text{resposta} = \text{"sim"} \mid \text{drogas} = \text{sim}]}{Pr[\text{resposta} = \text{"sim"} \mid \text{drogas} = \text{não}]} \leq e^\varepsilon \quad \text{e} \quad e^{-\varepsilon} \leq \frac{Pr[\text{resposta} = \text{"não"} \mid \text{drogas} = \text{sim}]}{Pr[\text{resposta} = \text{"não"} \mid \text{drogas} = \text{não}]} \leq e^\varepsilon,$$

o que implica que o menor valor de ε possível é justamente $\varepsilon(b) = \ln(1-0.5b)/0.5b$.

a amostragem pode reduzir o risco médio, mas não necessariamente provê garantias de privacidade em nível individual.

Alguns trabalhos tentam quantificar rigorosamente o risco de privacidade individual de técnicas de amostragem [32, 52].

Mais recentemente, a ferramenta ARX [91] passou a oferecer suporte a um algoritmo que aplica princípios da privacidade diferencial na seleção das amostras dos microdados [21], o que provê garantias individuais mais robustas do que a técnica usual de pura e simples amostragem aleatória.

6.4.2 Divulgação de histogramas e dados sintéticos

Como discutido na Seção 5.2, histogramas são um formato popular de divulgação de dados. Entretanto, a divulgação de histogramas de forma não perturbativa (i.e., sem adição de ruído) está vulnerável a ataques de reidentificação e principalmente de inferência de atributo. O seguinte exemplo ilustra esta situação.

Exemplo 25 (Negação plausível em histogramas não perturbativos). Considere a base de dados representada no histograma da Tabela 6.4.10a e a seguinte consulta $f = \text{“Quantos indivíduos possuem AIDS?”}$. Suponha que um adversário deseja descobrir se João possui AIDS ou não. Na privacidade diferencial assumimos que o adversário conhece todos os registros na base, exceto o de seu alvo –neste caso João. Observando o histograma, temos que a resposta desta consulta é 2. O adversário pode comparar este resultado com a quantidade de indivíduos, diferentes de João, que ele sabe que têm AIDS. Se esta quantidade for 2, então ele pode concluir que João não tem AIDS. Se for 1, então o adversário pode concluir que João tem AIDS. $\triangleleft$

O exemplo acima ilustra que mecanismos que divulgam as contagens exatas nos histogramas não fornecem negação plausível para os titulares dos dados. No caso, João não pode negar de forma crível a conclusão obtida pelo adversário com observação do histograma.

Como argumentado por Dwork [47], a adição de ruído se faz necessária na divulgação de histogramas para contornar esta vulnerabilidade. A adição de ruído em histogramas consiste em alterar a contagem dos registros.¹¹ O seguinte exemplo ilustra como a adição de ruído pode proteger a privacidade.

Exemplo 26 (Negação plausível em histogramas com ruído). Retomando o Exemplo 25, suponha agora que o adversário observe o histograma da Tabela 6.4.10b que sofreu

¹¹Como já dito na Seção 6.2.3, para alcançar a privacidade diferencial, é necessário avaliar qual o impacto máximo que a adição ou remoção de um registro na base de dados varia a saída do mecanismo aleatório, ou seja, a sensibilidade ℓ_1 de uma função que representa a consulta em questão. Quando os dados publicados são histogramas, esta sensibilidade sempre será igual a 1. Considerando que um histograma apresenta o número de registros que possui cada um dos valores de um atributo (ou conjunto de atributos), então a adição ou remoção dele irá variar em +1 ou -1 em uma das contagens que o histograma apresenta. De modo geral, essa propriedade indica que uma menor quantidade de ruído deve ser adicionada aos dados para que o mecanismo aleatório satisfaça a privacidade diferencial.

adição de ruído. A resposta para $f = \text{“Quantos indivíduos possuem AIDS?”}$ é igual a 1 neste caso. Porém, agora não é possível que o adversário faça nenhuma conclusão, pois ele não sabe se a quantidade real de indivíduos na base com AIDS é realmente 1 ou se esta resposta é fruto da adição de ruído. Neste caso, se o adversário concluir que João tem AIDS, João pode negar esta afirmação dizendo que fora adicionado um ruído de -1 no valor real da resposta (o que levaria à conclusão de que ele não tem AIDS).

◁

Por outro lado, dados sintéticos podem ser utilizados para substituir os dados reais em divulgações de microdados ou para geração de dados tabulares. Os dados sintéticos são gerados de forma a preservar algumas propriedades estatísticas dos dados originais, tais como distribuições marginais, médias e quartis. A geração de dados que respeita todas as correlações entre as variáveis ainda é um problema complexo que se discute hoje na literatura de privacidade diferencial [60]. Entretanto, diversos métodos podem ser utilizados para gerar modelos apropriados para a criação de dados sintéticos de tal forma que ainda seja possível realizar inferências válidas a partir deles.

O Anexo E apresenta um sumário dos principais algoritmos para geração de histogramas e dados sintéticos. Na próxima seção apresentamos o exemplo do Censo Decenal de 2020 dos EUA, que utiliza privacidade diferencial em divulgação de dados agregados.

6.4.3 A abordagem adotada no Censo Decenal de 2020 dos EUA

O Escritório de Censo dos Estados Unidos (*United States Census Bureau - USCB*),¹² é uma das maiores agências de estatística do país, e é responsável por gerenciar o Censo Decenal previsto na Constituição dos EUA. A divulgação pública do censo tem vários propósitos, como por exemplo, dividir os assentos da Câmara dos Deputados. Juntamente com a divulgação do censo, a agência também tem a obrigação de proteger a privacidade dos cidadãos.

Como discutido no Produto 01 do presente projeto, o USCB está atualmente executando o Censo de 2020, no qual ocorrerá a maior alteração já realizada pela agência no que diz respeito às suas práticas de controle de divulgação estatística. As mudanças são devidas ao reconhecimento de que métodos sintáticos como descritos na Seção 4, utilizados até o Censo Decenal de 2010, são inerentemente inseguros e sujeitam os registros individuais à possibilidade de reidentificação [26].

Dessa forma, o USCB anunciou em 2018 sua decisão de substituir métodos sintáticos por soluções baseadas em privacidade diferencial a partir do Censo de 2020 [6]. Neste mesmo anúncio o Escritório ressaltou que não existia *software* disponível no mercado que aplicasse privacidade diferencial em um censo nacional. Por esse motivo, foi necessário que a própria equipe do USCB desenvolvesse a solução, a um elevado custo tanto financeiro quanto de pessoal. Devido às alterações nos métodos utilizados pelo USCB

¹²<https://www.census.gov/>

para o controle da divulgação de dados estatísticos, mudanças também são esperadas no que diz respeito aos produtos que serão disponibilizados pelo Escritório a partir dos dados coletados pelo Censo de 2020. O Anexo F apresenta detalhes técnicos da solução, ilustrando seu alto grau de sofisticação e complexidade.

6.4.3.1 Desafios encontrados na implementação da privacidade diferencial

Como já mencionado no Produto 01 do presente TED, a implementação da privacidade diferencial pelo USCB enfrentou e enfrenta diversas dificuldades, tanto técnicas [57] quanto de comunicação com o restante da comunidade de estatística [82]. Apesar disso, o Escritório do Censo continua a preparação para o uso da privacidade diferencial, inclusive com a publicação de produtos de demonstração derivados dos microdados do Censo de 2010 [25]. A seguir resumizamos as principais dificuldades reportadas pela própria agência durante o desenho, implementação e comunicação à sociedade da nova solução adotada.

(I) Desafios científicos:

- **Mecanismos hierárquicos.** É preciso controlar cuidadosamente o erro introduzido à medida em que estatísticas são relatadas de geolocalidades menores para maiores. Mais precisamente, o erro deve diminuir conforme a população aumenta. Foi necessário o desenvolvimento de um conjunto de novos mecanismos hierárquicos projetados para otimizar a precisão de várias consultas simultaneamente.
- **Invariantes.** Invariantes descrevem estatísticas que não podem ser alteradas pela aplicação da privacidade diferencial. Algumas estatísticas devem ser, então, reportadas de forma exata (e.g., número de pessoas que vivem em cada quarteirão), enquanto outras estatísticas podem ser sanitizadas via ruído (e.g., o número de hispânicos que vivem em cada quarteirão). Não existe uma teoria bem desenvolvida sobre como a privacidade diferencial opera na presença de tais invariantes.
- **Emprego em amostragens estratificadas.** Deste 2005 o USCB vem utilizando a Pesquisa da Comunidade Americana (*American Community Survey*) que realiza uma amostragem probabilística estratificada para medir continuamente a população dos EUA. Não há um mecanismo aceito para aplicar a privacidade diferencial aos resultados de amostras probabilísticas estratificadas.
- **Métricas de qualidade.** A troca entre precisão estatística e perda de privacidade está no cerne da privacidade diferencial. Existem diversas métricas para avaliar a qualidade de um conjunto de dados. Os usos pretendidos das estatísticas devem ser previamente conhecidos para que possam ser incorporados ao mecanismo de privacidade de modo a aumentar a utilidade para um mesmo orçamento de perda de privacidade.

- **Apresentar e resolver questões de equidade.** Publicar muitas tabelas a partir da mesma base de dados confidencial permite aumentar a precisão de algumas tabelas em detrimento da precisão de outras, sob um mesmo limite de perda de privacidade. A privacidade diferencial carece de uma teoria bem desenvolvida para medir o impacto relativo do ruído adicional sobre a utilidade de diferentes produtos de dados, ajustando as compensações de equidade e apresentando o impacto de tais decisões.
- **Estabelecer o valor do parâmetro ε .** A configuração da perda de privacidade, determinada pelo valor do parâmetro ε , é uma questão política, e não meramente técnica. A literatura sobre privacidade diferencial neste assunto ainda é muito escassa.
O Comitê de Política Executiva de Administração de Dados do Escritório do Censo selecionou um especialista para preparar um estudo sobre a relação entre o valor de ε e a utilidade. Em seguida o comitê escolheu um valor de ε que fornecia precisão suficiente.
- **Desenvolvimento do mecanismo.** Mecanismos mais eficientes e provas com limites mais rígidos são necessários para reduzir os níveis de ruído para um mesmo nível de perda de privacidade e para fazer uso eficiente do orçamento de perda de privacidade para liberações iterativas de estatísticas editadas e corrigidas.

(II) Desafios operacionais:

- **Obtenção de pessoal qualificado e ferramentas.** O Escritório do Censo não contava com especialistas em teoria e prática de privacidade diferencial. Ainda há falta de ferramentas para realizar cálculos de privacidade diferencial e para verificar a correção de implementações específicas.
- **Reformulação de consultas de alta sensibilidade.** Conforme apresentado no Exemplo 13, consultas de contagem possuem sensibilidade 1. Entretanto, outros tipos de consulta podem apresentar sensibilidade significativamente mais elevada, o que torna necessária a adição de uma grande quantidade de ruído.
- **Zeros estruturais e de amostragem.** Existem algumas regras de edição do censo que buscam manter certas consistências, como “*Não pode haver mães de seis anos com crianças de 30 anos*”, ou “*Não pode haver um cidadão que mora na cidade de São Francisco e no estado de Nova Iorque*”. A adição de ruído da privacidade diferencial não pode alterar os zeros estruturais.
- **Obtenção de ambiente de computação adequado.** Os algoritmos desenvolvidos para o Censo 2020 exigem pós-processamento significativo após a aplicação do ruído. Estima-se pelo menos três ordens de magnitude de recursos computacionais a mais do que os necessários para o censo de 2010 serão utilizados no censo de 2020. O Escritório está migrando de computação local para um ambiente baseado processamento em nuvem.

- **Contabilização de todos os usos de dados confidenciais.** Um requisito fundamental da privacidade diferencial é que todos os cálculos envolvendo dados privados devem ter ruído acrescentado antes de poderem ser tornados públicos. O Escritório do Censo teve que identificar previamente cada uso dos dados confidenciais na execução e processamento do Censo de 2020. Requisitos novos e imprevistos surgiram durante o projeto do sistema após a equipe considerar que o projeto estava fechado.
- **Falta de especificações finais.** Muitos dos produtos de dados do Escritório do Censo foram tradicionalmente desenvolvidos perto do final da década, em consulta com os usuários de dados. Esse processo colaborativo ajuda a garantir a utilidade dos dados do Censo, mas está em desacordo com boas práticas de desenho e desenvolvimento de um sistema de privacidade diferencial. Todos os cálculos devem ser conhecidos antecipadamente ou uma parte do orçamento para perda de privacidade deve ser reservada para uso futuro.

(III) Desafio para os analistas de dados:

- **Acesso a microdados.** Muitos usuários de dados do Escritório do Censo estão acostumados a usar microdados brutos ou que passaram por edições limitadas de confidencialidade. Os dados em nível de registro são extremamente difíceis de proteger de uma maneira que ofereça proteção real à privacidade. Atualmente, o Escritório do Censo aconselha que tais usuários considerem as modalidades de acesso restrito, as quais dependem de aprovação prévia.
- **Aumento da transparência.** Os usuários estarão cientes de que o ruído foi adicionado e poderão calcular a margem de erro que o ruído introduz. Alguns analistas de dados ainda estão confusos sobre essa margem de erro, um termo que tradicionalmente associam a pesquisas por amostragem. A discussão do erro causado pelos procedimentos de privacidade foi, até então, concisa e limitada a declarações qualitativas.
- **Incompreensão sobre aleatoriedade e ruído.** Uma das bases da privacidade diferencial é a adição de ruído aleatório aos dados tabulados antes da publicação. Por definição, os mecanismos de adição de ruído usados pelo Escritório do Censo resultam em maior precisão à medida em que o tamanho da população aumenta. Explicar isso aos analistas de dados, líderes comunitários e ao público em geral será fundamental para a aceitação dessa nova metodologia de garantia de privacidade. A falta de materiais simplificados para promover uma compreensão geral da privacidade diferencial aumenta a probabilidade de mal-entendidos.

6.5 Análise de prós e contras

As principais vantagens dos métodos baseados em privacidade diferencial incluem:

- Baseiam-se em premissas mais fracas sobre o conhecimento prévio do adversário, provendo, portanto, garantias de privacidade mais robustas.
- Proveem garantias de privacidade em nível individual, garantindo que todos os participantes de estudos estejam protegidos (e não apenas um grande número ou apenas a média dos participantes).
- Apresentam propriedades composicionais tanto em sequência quanto em paralelo, o que permite que diferentes divulgações (de curadores diferentes ou de um mesmo curador) que aplicam a técnica sejam combinadas sem que as garantias de privacidade se percam por completo.

Entretanto, tais métodos apresentam as seguintes desvantagens:

- Dependem de expertise refinado de especialistas para serem implementadas.
- As garantias de privacidade providas são em geral difíceis de entender e de comunicar tanto a analistas quanto a titulares de dados.
- Ainda não há guias claros de como a escolha do parâmetro ε de privacidade deve ser feita, apesar de vários esforços nessa direção.
- De forma geral, a alta dimensionalidade dos dados (i.e., muitos atributos), faz com que existam distribuições de valores inesperadas, e isto torna necessário a adição de mais ruído. A utilidade dos dados diminui a medida que a dimensionalidade aumenta. De fato, as correlações e distribuições conjuntas dos atributos são perdidas quando uma alta quantidade de ruído é adicionada.
- Alguns atributos, por definição, possuem restrições naturais em relação a outros. Por exemplo, um atributo *cidade* está altamente correlacionado com o atributo *estado*, então se um registro possui o valor **Belo Horizonte** na coluna *cidade*, necessariamente ele deve possuir o valor **MG** na coluna *estado*. Ademais, podem existir atributos onde a adição de ruído não é aceitável, como por exemplo, em bases de dados médicas, a quantidade de droga recomendada para um paciente deve ser extremamente precisa. Ao introduzir ruído, eventualmente pode ocorrer a quebra dessas restrições, e portanto, a confiabilidade dos dados diminui consideravelmente. É possível tratar essas restrições no momento da adição do ruído, porém, isto pode afetar o custo computacional e a quantidade de ruído introduzida.
- Os métodos são perturbativos, o que permite que algumas informações divulgadas sejam inverídicas, o que pode ser inaceitável em alguns contextos (e.g., em pesquisas sobre a eficácia e efeitos colaterais de medicamentos).
- A publicação de um conjunto de dados agregados, mesmo com privacidade diferencial, é equivalente à divulgação dos resultados de um conjunto predeterminado de consultas estatísticas. Por esse motivo, ela está sujeita ao resultado já discutido

na Seção 3.1.2 sobre a reconstrução da base de dados subjacente à divulgação estatística. Portanto, ao divulgar dados agregados o curador deve ser cuidadoso na escolha das consultas e do valor ε que deve ser adicionado ao resultado de cada uma delas para combater ataques de reconstrução de base de dados. Este tipo de ataque é discutido no Anexo A.3.

A fim de contornar alguns dos pontos negativos da privacidade diferencial, variantes mais refinadas têm sido propostas e estudadas a fundo. Em particular, podemos destacar a privacidade diferencial- (ε, δ) , que permite violações de privacidade raras em troca de uma maior utilidade dos dados (apresentada no Anexo D.1) e a privacidade- d , que explora a noção de indistinguibilidade entre segredos para aumentar a utilidade de divulgações (apresentada no Anexo D.2). Ambas as variantes podem apresentar vantagens significativas sobre a privacidade diferencial tradicional em termos da utilidade dos dados divulgados. Entretanto, elas demandam um expertise substancialmente maior do desenhista da solução, além de mais tempo e recursos, para que tais benefícios sejam atingidos.

<i>id</i>	<i>região</i>	<i>sexo</i>	<i>idade</i>	<i>enfermidade</i>
1	Brasil	F	25	gripe
2	Bolívia	M	18	resfriado
3	França	F	32	gripe
4	Espanha	F	43	leucemia
5	Japão	M	50	AIDS
6	China	M	70	AIDS

(a) Base de dados D .


<i>id</i>	<i>região</i>	<i>sexo</i>	<i>idade</i>	<i>enfermidade</i>
1	Brasil	F	25	gripe
2	Bolívia	M	18	gripe
3	França	F	32	gripe
4	Espanha	F	43	leucemia
5	Japão	M	50	AIDS
6	China	M	70	AIDS

(b) Base de dados D' , que é adjacente a D por diferir da mesma apenas pelo registro de id 2.


<i>id</i>	<i>região</i>	<i>sexo</i>	<i>idade</i>	<i>enfermidade</i>
1	Brasil	F	25	gripe
2	Bolívia	M	18	resfriado
3	França	F	32	gripe
4	Espanha	F	43	leucemia
5	Japão	M	50	AIDS
6	China	M	70	AIDS
7	Índia	F	29	resfriado

(c) Base de dados D'' , que é adjacente a D por diferir da mesma apenas pela inclusão do registro id 7.


Tabela 6.2.3: Exemplo de bases de dados adjacentes. As bases D e D' diferem apenas no valor da *enfermidade* do registro de id 2 (**resfriado** vs. **gripe**). As bases D e D'' diferem apenas pela inclusão do registro de id 7. Note que D é adjacente a D' e a D'' , mas que D' e D'' não são adjacentes entre si, uma vez elas diferem em mais de um registro (o valor do registro de id 2 e a presença do registro de id 7).




(a) Exemplo de adição de ruído ao valor 2 quando o parâmetro de escala $b=1$ (i.e., $\varepsilon=1$).



(b) Adição de ruído para valores próximos, onde a curva vermelha representa o ruído adicionado ao valor 2 e a azul o ruído adicionado ao valor 3. Em ambos, $\varepsilon=4$.



(c) Adição de ruído para valores próximos, onde a curva vermelha representa o ruído adicionado ao valor 2 e a azul o ruído adicionado ao valor 3. Em ambos, $\varepsilon=1$.



(d) Adição de ruído para valores distantes, onde a curva vermelha representa o ruído adicionado ao valor 2 e a azul o ruído adicionado ao valor 5. Em ambos, $\varepsilon=1$.

Figura 6.2.4: Exemplo 15: Adição de ruído de Laplace. As figuras apresentam a função de densidade de probabilidade em diferentes casos. Os gráficos demonstram o ruído adicionado à consulta de contagem “*Quantos indivíduos possuem AIDS?*”. Recorde que no Mecanismo de Laplace (Definição 14) o ruído é obtido da função para a escala $b=\Delta f/\varepsilon$. Conforme explicado no Exemplo 13, a sensibilidade de uma consulta de contagem f é $\Delta f=1$, portanto, o ruído é adicionado para a escala $b=1/\varepsilon$.




Figura 6.3.5: Esquema de funcionamento da privacidade diferencial local. Ruído é adicionado individualmente aos dados de cada titular, antes dos mesmos serem coletados em uma base sanitizada. A partir daí, consultas propostas pelo analista são realizadas sobre a base sanitizada, ou então a base sanitizada pode ser ela mesma publicada integralmente.

Respondente	Faz uso da droga ilícita	Resultado da 1ª moeda	Resultado da 2ª moeda	Resposta fornecida
Ana	sim	cara	-	“sim”
Bruno	não	cara	-	“não”
Clara	não	coroa	coroa	“não”
Danilo	não	coroa	cara	“sim”
Eva	não	cara	-	“não”
Felipe	sim	coroa	coroa	“não”
Gabriela	não	cara	-	“não”
Hugo	não	coroa	cara	“sim”
Iara	não	cara	-	“não”
João	não	cara	-	“não”

Tabela 6.3.6: Exemplo 22: Resultado de uma pesquisa sobre uso de drogas ilícitas usando a técnica de reposta aleatorizada. A proporção real de usuários de drogas na população é de $f = 20\%$, enquanto a proporção de respondentes que afirmam usar drogas na pesquisa é de $s = 30\%$. O tratamento estatístico das respostas da pesquisa estimaria, então, que a proporção de usuários de drogas é $\hat{f} = 2s - 1/2 = 10\%$.

$p(\text{resposta} \mid \text{drogas})$	$\text{resposta} = \text{“sim”}$	$\text{resposta} = \text{“não”}$
$\text{drogas} = \text{sim}$	$(1 - b) + 0.5b = 1 - 0.5b$	$0.5b$
$\text{drogas} = \text{não}$	$0.5b$	$(1 - b) + 0.5b = 1 - 0.5b$

Tabela 6.3.8: Exemplo 22: Probabilidade condicional de cada resposta dado se o indivíduo é mesmo usuário de drogas ou não, em função do viés b da primeira moeda.




Figura 6.3.7: Exemplo 22: Procedimento adotado por cada respondente a uma pesquisa a fim de garantir resposta aleatorizada. O valor $b \in [0, 1]$ representa a probabilidade da primeira moeda retornar o valor coroa.


<i>enfermidade</i>	<i>contagem</i>
gripe	2
resfriado	1
leucemia	1
AIDS	2

(a) Dados originais.


<i>enfermidade</i>	<i>contagem</i>
gripe	2
resfriado	2
leucemia	1
AIDS	1

(b) Dados com ruído.


Tabela 6.4.10: Exemplo 26: Adição de ruído no histograma da distribuição marginal do atributo *enfermidade*, referente à base de dados da Tabela 5.2.1a.



(a) Relação do viés b da primeira moeda com os níveis de utilidade e de negação plausível do mecanismo resultante. Quanto maior o valor de b , mais a negação de um titular de que ele usa drogas é plausível (i.e., maior o valor de $p(\text{drogas} = \text{não} \mid \text{resposta} = \text{"sim"})$), porém mais distante se torna a proporção esperada de respostas afirmativas na pesquisa (i.e., $p(\text{resposta} = \text{"sim"})$) em relação à proporção real de usuários de droga na população (i.e., $p(\text{drogas} = \text{sim})$).



(b) Relação entre o viés b da segunda moeda e o nível ε de privacidade diferencial atingido ($\varepsilon = \ln(1-0.5b)/0.5b$). Quanto maior o viés da moeda, mais a resposta de cada indivíduo é puramente aleatória, e mais mais privado é o mecanismo resultante (i.e., menor é o valor de ε).



(c) Relação do parâmetro ε da privacidade diferencial com os níveis de utilidade e de negação plausível do mecanismo resultante. Quanto maior o valor de ε , menos privado é o mecanismo (i.e., menor é a credibilidade $p(\text{drogas} = \text{não} \mid \text{resposta} = \text{"sim"})$ da negação plausível), mas maior é sua utilidade (i.e., mais $p(\text{resposta} = \text{"sim"})$ se aproxima de $p(\text{drogas} = \text{sim})$).

Figura 6.3.9: Exemplo 24: Compromisso entre utilidade e privacidade num mecanismo de privacidade diferencial local baseado em resposta aleatorizada. Recorde que quanto menor o valor do parâmetro ε , mais privado é o mecanismo resultante.

Referências Bibliográficas

- [1] Volkstelling. In *Wikipedia: de vrije encyclopedie*. Wikimedia, 2020. Disponível em: <https://nl.wikipedia.org/wiki/Volkstelling>.
- [2] WWDC 2016. Wwdc 2016 keynote, 2016. Apple Worldwide Developers Conference 2016. Disponível em: <https://www.apple.com/apple-events/#june-2016>.
- [3] John Abowd, Daniel Kifer, Brett Moran, Robert Ashmead, Philip Leclerc, William Sexton, Simson Garfinkel, and Ashwin Machanavajjhala. Census TopDown: Differentially Private Data, Incremental Schemas, and Consistency with Public Knowledge. Technical report, US Census Bureau, 2019.
- [4] John Abowd, Daniel Kifer, Brett Moran, Robert Ashmead, Philip Leclerc, William Sexton, Simson Garfinkel, and Ashwin Machanavajjhala. Census TopDown: Differentially Private Data, Incrementalschemas, and Consistency with Public Knowledge, 2019. Disponível em: <https://columbia.github.io/private-systems-class/papers/Abowd2019Census.pdf>.
- [5] John M Abowd. Disclosure Avoidance for Block Level Data and Protection of Confidentiality in Public Tabulations. In *Census Scientific Advisory Committee (Fall Meeting)*, pages 2018–12, 2018.
- [6] John M. Abowd. The U.S. Census Bureau Adopts Differential Privacy. In *Proceedings of the 24th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining*, KDD '18, page 2867. Association for Computing Machinery, 2018.
- [7] John M. Abowd and Ian M. Schmutte. An economic analysis of privacy protection and statistical accuracy as social choices. *American Economic Review*, 109(1):171–202, 2019.
- [8] Gergely Acs, Claude Castelluccia, and Rui Chen. Differentially Private Histogram Publishing through Lossy Compression. In *2012 IEEE 12th International Conference on Data Mining*, pages 1–10. IEEE, 2012.
- [9] Charu C. Aggarwal. On k-anonymity and the Curse of Dimensionality. In *Proceedings of the 31st International Conference on Very Large Data Bases, Trondheim, Norway, August 30 - September 2, 2005*, pages 901–909. ACM, 2005.

- [10] Mário S. Alvim, Miguel E. Andrés, Konstantinos Chatzikokolakis, Pierpaolo Degano, and Catuscia Palamidessi. On the information leakage of differentially-private mechanisms. *Journal of Computer Security*, 23(4):427–469, 2015.
- [11] Mário S. Alvim, Miguel E. Andres, and Catuscia Palamidessi. Information Flow in Interactive Systems. *Journal of Computer Security*, 1(20):3–50, 2012.
- [12] Mário S. Alvim, Konstantinos Chatzikokolakis, Annabelle McIver, Carroll Morgan, Catuscia Palamidessi, and Geoffrey Smith. Additive and Multiplicative Notions of Leakage, and Their Capacities. In *Proc. of CSF*, pages 308–322. IEEE, 2014.
- [13] Mário S. Alvim, Konstantinos Chatzikokolakis, Annabelle McIver, Carroll Morgan, Catuscia Palamidessi, and Geoffrey Smith. Axioms for Information Leakage. In *IEEE 29th Computer Security Foundations Symposium, CSF 2016, Lisbon, Portugal, June 27 - July 1, 2016*, pages 77–92, 2016.
- [14] Mário S. Alvim, Konstantinos Chatzikokolakis, Annabelle McIver, Carroll Morgan, Catuscia Palamidessi, and Geoffrey Smith. *The Science of Quantitative Information Flow*. Springer, 2020.
- [15] Mário S. Alvim, Konstantinos Chatzikokolakis, Catuscia Palamidessi, and Anna Pazii. Local Differential Privacy on Metric Spaces: Optimizing the Trade-off with Utility. In *2018 IEEE 31st Computer Security Foundations Symposium (CSF)*, pages 262–267. IEEE Computer Society, 2018.
- [16] Mário S. Alvim, Konstantinos Chatzikokolakis, Catuscia Palamidessi, and Geoffrey Smith. Measuring Information Leakage Using Generalized Gain Functions. In *25th IEEE Computer Security Foundations Symposium, CSF 2012, Cambridge, MA, USA, June 25-27, 2012*, pages 265–279, 2012.
- [17] Mário S. Alvim, Natasha Fernandes, Annabelle McIver, and Gabriel H. Nunes. On Privacy and Accuracy in Data Releases (Invited Paper). In *31st International Conference on Concurrency Theory, CONCUR 2020, September 1-4, 2020, Vienna, Austria (Virtual Conference)*, volume 171 of *LIPICs*, pages 1:1–1:18. Schloss Dagstuhl - Leibniz-Zentrum für Informatik, 2020.
- [18] Miguel E. Andrés, Nicolás E. Bordenabe, Konstantinos Chatzikokolakis, and Catuscia Palamidessi. Geo-indistinguishability: differential privacy for location-based systems. In *Proc. of CCS*, pages 901–914. ACM, 2013.
- [19] Boaz Barak, Kamalika Chaudhuri, Cynthia Dwork, Satyen Kale, Frank McSherry, and Kunal Talwar. Privacy, Accuracy, and Consistency too: A Holistic Solution to Contingency Table Release. In *Proceedings of the Twenty-Sixth ACM SIGMOD-SIGACT-SIGART Symposium on Principles of Database Systems, PODS '07*, pages 273–282. Association for Computing Machinery, 2007.
- [20] Armin Biere. PicoSAT Essentials. *Journal on Satisfiability, Boolean Modeling and Computation*, 4(2-4):75–97, 2008.

- [21] Raffael Bild, Klaus A. Kuhn, and Fabian Prasser. SafePub: A Truthful Data Anonymization Algorithm With Strong Privacy Guarantees. *Proceedings on Privacy Enhancing Technologies*, 2018(1):67–87, 2018.
- [22] Michele Boreale, Francesca Pampaloni, and Michela Paolini. Asymptotic Information Leakage under One-Try Attacks. In *Foundations of Software Science and Computational Structures - 14th International Conference, FOSSACS 2011, Held as Part of the Joint European Conferences on Theory and Practice of Software, ETAPS 2011, Saarbrücken, Germany, March 26-April 3, 2011. Proceedings*, volume 6604 of *LNCS*, pages 396–410. Springer, 2011.
- [23] Christelle Braun, Konstantinos Chatzikokolakis, and Catuscia Palamidessi. Quantitative Notions of Leakage for One-try Attacks. In *Proc. of MFPS*, volume 249 of *ENTCS*, pages 75–91. Elsevier, 2009.
- [24] Hai Brenner and Kobbi Nissim. Impossibility of Differentially Private Universally Optimal Mechanisms. In *2010 IEEE 51st Annual Symposium on Foundations of Computer Science*, pages 71–80, 2010.
- [25] United States Census Bureau. 2010 Demonstration Data Products, 2019. Disponível em: <https://www.census.gov/programs-surveys/decennial-census/2020-census/planning-management/2020-census-data-products/2010-demonstration-data-products.html>.
- [26] United States Census Bureau. Legacy Techniques and Current Research in Disclosure Avoidance at the U.S. Census Bureau, 2019. Disponível em <https://www.census.gov/library/working-papers/2019/adrm/legacy-da-techniques.html>.
- [27] United States Census Bureau. Status Update on the 2020 Census Data Products Plan, 2019. Disponível em: <https://www2.census.gov/cac/nac/meetings/2019-11/devine-hollingsworth-status-update-2020-data-products-plan.pdf>.
- [28] Christian Cachin. *Entropy Measures and Unconditional Security in Cryptography*. PhD thesis, ETH, 1997.
- [29] Konstantinos Chatzikokolakis, Miguel E. Andrés, Nicolás Emilio Bordenabe, and Catuscia Palamidessi. Broadening the Scope of Differential Privacy Using Metrics. In *Privacy Enhancing Technologies - 13th International Symposium, PETS 2013, Bloomington, IN, USA, July 10-12, 2013. Proceedings*, volume 7981 of *Lecture Notes in Computer Science*, pages 82–102. Springer, 2013.
- [30] Konstantinos Chatzikokolakis, Natasha Fernandes, and Catuscia Palamidessi. Comparing Systems: Max-Case Refinement Orders and Application to Differential privacy. In *32nd IEEE Computer Security Foundations Symposium, CSF 2019, Hoboken, NJ, USA, June 25-28, 2019*, pages 442–457. IEEE, 2019.

- [31] Konstantinos Chatzikokolakis, Catuscia Palamidessi, and Prakash Panangaden. Anonymity Protocols as Noisy channels. *Inf. and Comp.*, 206(2–4):378–401, 2008.
- [32] Kamalika Chaudhuri and Nina Mishra. When Random Sampling Preserves Privacy. In *Advances in Cryptology - CRYPTO 2006*, pages 198–213. Springer Berlin Heidelberg, 2006.
- [33] David Clark, Sebastian Hunt, and Pasquale Malacaria. Quantitative Analysis of the Leakage of Confidential Data. In *Proc. of QAPL*, volume 59 (3) of *ENTCS*, pages 238–251. Elsevier, 2001.
- [34] David Clark, Sebastian Hunt, and Pasquale Malacaria. Quantitative Information Flow, Relations and Polymorphic Types. *J. of Logic and Computation*, 18(2):181–199, 2005.
- [35] Michael R. Clarkson, Andrew C. Myers, and Fred B. Schneider. Belief in information flow. *Journal of Computer Security*, 17(5):655–701, 2009.
- [36] Chris Clifton and Tamir Tassa. On syntactic anonymity and differential privacy. In *2013 IEEE 29th International Conference on Data Engineering Workshops (ICDEW)*, pages 88–93. IEEE Computer Society, 2013.
- [37] Graham Cormode, Somesh Jha, Tejas Kulkarni, Ninghui Li, Divesh Srivastava, and Tianhao Wang. Privacy at Scale: Local Differential Privacy in Practice. In *Proceedings of the 2018 International Conference on Management of Data*, SIGMOD '18, pages 1655–1658. Association for Computing Machinery, 2018.
- [38] Rachel Cummings. ISYE/CS 8803: Foundations of Data Privacy, Lecture 8: Small DB, 2017. Disponível em: <https://cpb-us-w2.wpmucdn.com/sites.gatech.edu/dist/c/679/files/2017/09/lecture8.pdf>.
- [39] Tore Dalenius. Towards a methodology for statistical disclosure control. *Statistik Tidskrift*, 15:429–444, 1977.
- [40] Instituto Brasileiro de Geografia e Estatística. Confidencialidade no IBGE - procedimentos adotados na preservação do sigilo das informações individuais nas divulgações de resultados das operações estatísticas, 2018. Disponível em: <http://biblioteca.ibge.gov.br/index.php/biblioteca-catalogo?view=detalhes&id=2101636>.
- [41] Dienst Uitvoering Onderwijs. Open data van DUO. Disponível em: https://duo.nl/open_onderwijsdata/.
- [42] Bolin Ding, Janardhan Kulkarni, and Sergey Yekhanin. Collecting Telemetry Data Privately. In *Advances in Neural Information Processing Systems 30: Annual Conference on Neural Information Processing Systems 2017, 4-9 December 2017, Long Beach, CA, USA*, pages 3571–3580, 2017.

- [43] Irit Dinur and Kobbi Nissim. Revealing Information While Preserving Privacy. In *Proceedings of the Twenty-Second ACM SIGMOD-SIGACT-SIGART Symposium on Principles of Database Systems*, PODS '03, pages 202–210. Association for Computing Machinery, 2003.
- [44] Governo do Brasil. Lei 13.709, de 14 de agosto de 2018, Lei Geral de Proteção de Dados Pessoais (LGPD). Disponível em: http://www.planalto.gov.br/ccivil_03/_ato2015-2018/2018/Lei/L13709.htm.
- [45] Cynthia Dwork. Differential Privacy. In *Proceedings of the 33rd International Conference on Automata, Languages and Programming - Volume Part II*, ICALP'06, pages 1–12. Springer-Verlag, 2006.
- [46] Cynthia Dwork. Differential privacy. *Encyclopedia of Cryptography and Security*, pages 13–14, 2011.
- [47] Cynthia Dwork. A firm foundation for private data analysis. *Communications of the ACM*, 54(1):86–95, 2011.
- [48] Cynthia Dwork, Krishnaram Kenthapadi, Frank McSherry, Ilya Mironov, and Moni Naor. Our Data, Ourselves: Privacy Via Distributed Noise Generation. In *Advances in Cryptology (EUROCRYPT 2006)*, volume 4004 of *Lecture Notes in Computer Science*, pages 486–503. Springer Verlag, 2006.
- [49] Cynthia Dwork, Frank McSherry, Kobbi Nissim, and Adam Smith. Calibrating noise to sensitivity in private data analysis. In *Theory of cryptography conference*, pages 265–284. Springer, 2006.
- [50] Cynthia Dwork and Moni Naor. On the Difficulties of Disclosure Prevention in Statistical Databases or The Case for Differential Privacy. *Journal of Privacy and Confidentiality*, 2, 09 2010.
- [51] Cynthia Dwork, Aaron Roth, et al. The Algorithmic Foundations of Differential Privacy. *Foundations and Trends® in Theoretical Computer Science*, 9(3–4):211–407, 2014.
- [52] Hamid Ebadi, Thibaud Antignac, and David Sands. Sampling and partitioning for differential privacy. In *14th Annual Conference on Privacy, Security and Trust, PST 2016, Auckland, New Zealand, December 12-14, 2016*, pages 664–673. IEEE, 2016.
- [53] Úlfar Erlingsson, Vasył Pihur, and Aleksandra Korolova. RAPPOR: Randomized Aggregatable Privacy-Preserving Ordinal Response. In *Proceedings of the 2014 ACM SIGSAC Conference on Computer and Communications Security*, CCS '14, pages 1054–1067. Association for Computing Machinery, 2014.

- [54] Benjamin C. M. Fung, Ke Wang, Ada Wai-Chee Fu, and Philip S. Yu. *Introduction to Privacy-Preserving Data Publishing: Concepts and Techniques*. Chapman & Hall/CRC, 1st edition, 2010.
- [55] Simson Garfinkel. Deploying Differential Privacy for the 2020 Census of Population and Housing, 2019. Disponível em <http://simson.net/ref/2019/2019-07-16%20Deploying%20Differential%20Privacy%20for%20the%202020%20Census.pdf>.
- [56] Simson Garfinkel, John Abowd, and Christian Martindale. Understanding Database Reconstruction Attacks on Public Data. *Communications of the ACM*, 62:46–53, 02 2019.
- [57] Simson Garfinkel, John M Abowd, and Sarah Powazek. Issues Encountered Deploying Differential Privacy. In *Proceedings of the 2018 Workshop on Privacy in the Electronic Society, WPES'18*, pages 133–137. Association for Computing Machinery, 2018.
- [58] Arpita Ghosh, Tim Roughgarden, and Mukund Sundararajan. Universally Utility-maximizing Privacy Mechanisms. *SIAM Journal on Computing*, 2012.
- [59] Pablo Giambiagi, Gerardo Schneider, and Frank D. Valencia. On the Expressiveness of Infinite behavior and Name Scoping in Process Calculi. In *Foundations of Software Science and Computation Structures, 7th International Conference, FOSSACS 2004, Held as Part of the Joint European Conferences on Theory and Practice of Software, ETAPS 2004, Barcelona, Spain, March 29 - April 2, 2004, Proceedings*, volume 2987 of *LNCS*, pages 226–240. Springer, 2004.
- [60] Aris Gkoulalas-Divanis and Grigorios Loukides. *Medical Data Privacy Handbook*. Springer, 1st edition, 2015.
- [61] Jacob Goldberger and Tamir Tassa. Efficient Anonymizations with Enhanced Utility. In *2009 IEEE International Conference on Data Mining Workshops*, pages 106–113. IEEE, 2009.
- [62] Mangesh Gupte and Mukund Sundararajan. Universally Optimal Privacy Mechanisms for Minimax Agents. In *Proceedings of the Twenty-Ninth ACM SIGMOD-SIGACT-SIGART Symposium on Principles of Database Systems, PODS '10*, page 135–146. Association for Computing Machinery, 2010.
- [63] Naoise Holohan, Stefano Braghin, Pól Mac Aonghusa, and Killian Levacher. Diff-privlib: the ibm differential privacy library. *arXiv preprint arXiv:1907.02444*, 2019.
- [64] John E. Hopcroft, Rajeev Motwani, and Jeffrey D. Ullman. *Introduction to Automata Theory, Languages, and Computation*. Pearson, 2006.
- [65] Anco Hundepool, Josep Domingo-Ferrer, Luisa Franconi, Sarah Giessing, Eric Schulte Nordholt, Keith Spicer, and Peter-Paul de Wolf. *Statistical Disclosure Control*. Wiley, 2012.

- [66] James W. Gray III. Toward a Mathematical Foundation for Information Flow Security. In *Proceedings of the 1991 IEEE Symposium on Security and Privacy, Oakland, California, USA, May 20-22, 1991*, pages 21–35, 1991.
- [67] Edwin T. Jaynes. *Probability theory: The logic of science*. Cambridge University Press, Cambridge, 2003.
- [68] Shiva Prasad Kasiviswanathan, Homin K. Lee, Kobbi Nissim, Sofya Raskhodnikova, and Adam D. Smith. What Can We Learn Privately? In *49th Annual IEEE Symposium on Foundations of Computer Science, FOCS 2008, October 25-28, 2008, Philadelphia, PA, USA*, pages 531–540. IEEE Computer Society, 2008.
- [69] Georgios Kellaris, Stavros Papadopoulos, Xiaokui Xiao, and Dimitris Papadias. Differentially private event sequences over infinite streams, 2014. Disponível em: <http://www.vldb.org/pvldb/vol7/p1155-kellaris.pdf>.
- [70] Daniel Kifer and Ashwin Machanavajjhala. No Free Lunch in Data Privacy. In *Proceedings of the 2011 ACM SIGMOD International Conference on Management of Data, SIGMOD '11*, page 193–204. Association for Computing Machinery, 2011.
- [71] Florian Kohlmayer, Fabian Prasser, Claudia Eckert, Alfons Kemper, and Klaus A Kuhn. Flash: Efficient, Stable and Optimal K-Anonymity. In *2012 International Conference on Privacy, Security, Risk and Trust and 2012 International Conference on Social Computing*, pages 708–717. IEEE, 2012.
- [72] Boris Köpf and David A. Basin. An information-theoretic model for adaptive side-channel attacks. In *Proc. of CCS*, pages 286–296. ACM, 2007.
- [73] Ton de Waal Leon Willenborg. *Elements of Statistical Disclosure Control*. Lecture Notes in Statistics 155. Springer-Verlag New York, 1 edition, 2001.
- [74] Haoran Li, Li Xiong, and Xiaoqian Jiang. Differentially Private Synthesization of Multi-Dimensional Data using Copula Functions. In *Advances in database technology: proceedings. International conference on extending database technology*, volume 2014, page 475. NIH Public Access, 2014.
- [75] Ninghui Li, Tiancheng Li, and Suresh Venkatasubramanian. t-Closeness: Privacy Beyond k-Anonymity and l-Diversity. In *2007 IEEE 23rd International Conference on Data Engineering*, pages 106–115. IEEE, 2007.
- [76] Gavin Lowe. Quantifying Information Flow. In *Proc. of CSFW 2002*, pages 18–31. IEEE, 2002.
- [77] Ashwin Machanavajjhala, Johannes Gehrke, Daniel Kifer, and Muthuramakrishnan Venkitasubramanian. l-diversity: Privacy beyond k-anonymity. In *22nd International Conference on Data Engineering (ICDE'06)*, pages 24–24. IEEE, 2006.

- [78] Ashwin Machanavajjhala, Daniel Kifer, John Abowd, Johannes Gehrke, and Lars Vilhuber. Privacy: Theory meets Practice on the Map. In *2008 IEEE 24th international conference on data engineering*, pages 277–286. IEEE, 2008.
- [79] Pasquale Malacaria. Assessing security threats of looping constructs. In *Proceedings of the 34th ACM SIGPLAN-SIGACT Symposium on Principles of Programming Languages, POPL 2007, Nice, France, January 17-19, 2007*, pages 225–235. ACM, 2007.
- [80] Annabelle McIver, Carroll Morgan, Geoffrey Smith, Barbara Espinoza, and Larissa Meinicke. Abstract Channels and Their Robust Information-Leakage Ordering. In *Principles of Security and Trust - Third International Conference, POST 2014, Held as Part of the European Joint Conferences on Theory and Practice of Software, ETAPS 2014, Grenoble, France, April 5-13, 2014, Proceedings*, volume 8414 of *LNCs*, pages 83–102. Springer, 2014.
- [81] John McLean. Security Models and Information Flow. In *Proceedings of the 1990 IEEE Symposium on Security and Privacy, Oakland, California, USA, May 7-9, 1990*, pages 180–189. IEEE Computer Society, 1990.
- [82] Jeffrey Mervis. Can a set of equations keep U.S. census data private? *Science Magazine*, 2019. Disponível em: <https://www.sciencemag.org/news/2019/01/can-set-equations-keep-us-census-data-private>.
- [83] Jonathan K. Millen. Covert Channel Capacity. In *Proceedings of the 1987 IEEE Symposium on Security and Privacy, Oakland, California, USA, April 27-29, 1987*, pages 60–66. IEEE Computer Society, 1987.
- [84] Renée Miller. Big Data Curation. In *Proceedings of the 20th International Conference on Management of Data, COMAD '14*, page 4, Mumbai, Maharashtra, India, 2014. Computer Society of India.
- [85] Noman Mohammed, Rui Chen, Benjamin C. M. Fung, and Philip S. Yu. Differentially Private Data Release for Data Mining. In *Proceedings of the 17th ACM SIGKDD international conference on Knowledge discovery and data mining, KDD '11*, pages 493–501. Association for Computing Machinery, 2011.
- [86] Australian Bureau of Statistics. Census Microdata. Disponível em: <https://www.abs.gov.au/ausstats/abs@.nsf/Lookup/by%20Subject/2011.0.55.001~2016~Main%20Features~Census%20Microdata~13>.
- [87] Government of the United States of America. Statistical Policy Working Paper 22 - Report on Statistical Disclosure Limitation Methodology, 2005. Disponível em: <https://nces.ed.gov/FCSM/pdf/spwp22.pdf>.
- [88] Christine M. O’Keefe and Norm M. Good. A Remote Analysis Server - What Does Regression Output Look Like? In *Privacy in Statistical Databases, UNESCO Chair*

- in *Data Privacy International Conference, PSD 2008, Istanbul, Turkey, September 24-26, 2008. Proceedings*, volume 5262 of *Lecture Notes in Computer Science*, pages 270–283. Springer, 2008.
- [89] Christine M. O’Keefe and Natalie Shlomo. Comparison of Remote Analysis with Statistical Disclosure Control for Protecting the Confidentiality of Business Data. *Transactions on Data Privacy*, 5:403–432, 08 2012.
 - [90] Jessie Pease and Julien Freudiger. Engineering Privacy for Your Users, 2016. Apple Worldwide Developers Conference 2016. Disponível em: <https://developer.apple.com/videos/play/wwdc2016/709/>.
 - [91] Fabian Prasser and Contributors. ARX - Data Anonymization Tool, 2020. Disponível em: <https://arx.deidentifier.org/>.
 - [92] Fabian Prasser, James Gaupp, Zhiyu Wan, Weiyi Xia, Yevgeniy Vorobeychik, Murat Kantarcioglu, Klaus Kuhn, and Brad Malin. An Open Source Tool for Game Theoretic Health Data De-Identification. In *AMIA Annual Symposium Proceedings*, volume 2017, page 1430. American Medical Informatics Association, 2017.
 - [93] Pierangela Samarati. Protecting Respondents’ Identities in Microdata Release. *IEEE Transactions on Knowledge and Data Engineering*, 13(6):1010–1027, 2001.
 - [94] Pierangela Samarati and Latanya Sweeney. Protecting Privacy when Disclosing Information: k-Anonymity and Its Enforcement through Generalization and Suppression. Technical report, SRI International, 1998.
 - [95] David Sánchez, Sergio Martínez, and Josep Domingo-Ferrer. How to Avoid Re-identification with Proper Anonymization. *arXiv preprint arXiv:1808.01113*, 2018.
 - [96] Natalie Shlomo. *Statistical Disclosure Limitation for Health Data: A Statistical Agency Perspective*, pages 201–230. Springer, 2015.
 - [97] Natalie Shlomo, Iaszlo Antal, and Mark Elliot. Measuring Disclosure Risk and Data Utility for Flexible Table Generators. *Journal of Official Statistics*, 31:305–324, 06 2015.
 - [98] Michael Sipser. *Introduction to the Theory of Computation*. Cengage Learning, 2012.
 - [99] Geoffrey Smith. On the Foundations of Quantitative Information Flow. In *Proc. of FOSSACS*, volume 5504 of *LNCS*, pages 288–302. Springer, 2009.
 - [100] Jordi Soria-Comas, Josep Domingo-Ferrer, David Sanchez, and Sergio Martinez. t-Closeness through Microaggregation: Strict Privacy with Enhanced Utility Preservation. *IEEE Transactions on Knowledge and Data Engineering*, 27(11):3098–3110, 2015.

- [101] Latanya Sweeney. Simple Demographics Often Identify People Uniquely, 2000. Disponível em: https://kilthub.cmu.edu/articles/Simple_Demographics_Often_Identify_People_Uniquely/6625769/1.
- [102] Latanya Sweeney. k-Anonymity: A Model for Protecting Privacy. *International Journal of Uncertainty, Fuzziness and Knowledge-Based Systems*, 10(5):557–570, 2002.
- [103] Matthias Templ. *Statistical Disclosure Control for Microdata: Methods and Applications in R*. Springer, 2017.
- [104] Salil Vadhan. The complexity of differential privacy. In *Tutorials on the Foundations of Cryptography: Dedicated to Oded Goldreich*, pages 347–450. Springer International Publishing, 2017.
- [105] Stanley L. Warner. Randomized Response: A Survey Technique for Eliminating Evasive Answer Bias. *Journal of the American Statistical Association*, 60(309):63–69, 1965. PMID: 12261830.
- [106] Weiyi Xia, Raymond Heatherly, Xiaofeng Ding, Jiuyong Li, and Bradley A Malin. R-U policy frontiers for health data de-identification. *Journal of the American Medical Informatics Association*, 22(5):1029–1041, 2015.
- [107] Jia Xu, Zhenjie Zhang, Xiaokui Xiao, Yin Yang, Ge Yu, and Marianne Winslett. Differentially private histogram publication. *The VLDB Journal*, 22(6):797–822, 2013.
- [108] Mengmeng Yang, Lingjuan Lyu, Jun Zhao, Tianqing Zhu, and Kwok-Yan Lam. Local Differential Privacy and Its Applications: A Comprehensive Survey, 2020.

Anexos

A Resultados formais importantes sobre o compromisso entre privacidade e utilidade em divulgações estatísticas

Com mencionamos ao longo deste projeto, a área de controle de divulgação estatística reconhece que, de forma geral, há uma oposição entre os objetivos de se maximizarem, ao mesmo tempo, tanto a utilidade da informação divulgada quanto a privacidade dos titulares dos dados. O compromisso entre tais objetivos é comumente difícil de identificar e medir, e frequentemente envolve o uso de um arcabouço matemático sofisticado.

Neste anexo discutimos com mais rigor os resultados mais relevantes sobre este assunto abordados na Seção 3.1.2. Em particular, aqui passamos pelas seguintes questões:

1. O que caracteriza uma definição de privacidade “razoável”?
2. É possível desenvolver um mecanismo de divulgação de informação que respeite privacidade diferencial e que permita que a utilidade seja máxima para qualquer usuário (i.e., um mecanismo ótimo universal)?
3. Quanto ruído deve ser adicionado às respostas de um mecanismo de divulgação arbitrário para que ele garanta privacidade?

A.1 Uma boa definição de privacidade esconde qualquer evidência de participação

O estudo de privacidade em bancos de dados estatísticos foi significativamente influenciado pelo estatístico Tore Dalenius, que considerou o desiderato de que, para que “privacidade” seja satisfeita, *“qualquer coisa que possa ser aprendida sobre um indivíduo presente no banco de dados estatístico deva ser aprendível sem acesso ao banco de dados”* [39]. Embora esta possa parecer, a princípio, uma noção razoável de “privacidade”,

	<i>nome</i>	<i>enfermidade</i>
1	Pedro	câncer
2	Gabriela	diabetes
3	Vinícius	câncer
4	Júlia	Hemofilia

(a) Base de dados do ano de 2019

	<i>nome</i>	<i>enfermidade</i>
1	Pedro	câncer
2	Gabriela	diabetes
3	Vinícius	câncer
4	Júlia	hemofilia
5	Maria	câncer

(b) Base de dados do ano de 2020

Tabela A.1: Exemplo 27: Bases de dados sobre condições médicas nos anos de 2019 e 2020.

trabalhos recentes demonstraram ser impossível garantir qualquer utilidade dos dados ao tentar eliminar todas as lições que poderiam ser tiradas desses dados [49, 47, 50]. De fato, para que um banco de dados estatístico seja útil, ele deve de fato ensinar algo novo através dos dados.


Motivada por essa mudança de paradigma, Dwork propôs a privacidade diferencial como uma noção alternativa de privacidade [49], baseada no princípio de *negação plausível*. Essencialmente, a negação plausível determina que qualquer pessoa possa negar de forma crível sua participação em uma pesquisa e, portanto, negar que qualquer informação confidencial eventualmente liberada pela pesquisa esteja realmente relacionada a ela. Para atingir este objetivo, a privacidade diferencial garante que a presença ou a ausência de uma pessoa arbitrária nos dados não cause uma diferença impactante no resultado de qualquer consulta.

Entretanto, Daniel Kifer e Ashwin Machanavajjhala demonstraram que ocultar a participação de indivíduos em bases de dados nem sempre é uma tarefa simples, ressaltando a importância de avaliar os meios pelos quais os dados foram gerados para garantir negação plausível [70]. O exemplo abaixo mostra como a presença ou ausência de um registro pode ser protegida através de um mecanismo de divulgação de dados que preserva privacidade.

Exemplo 27 (O princípio da negação plausível em divulgações estatísticas). Considere o seguinte cenário. Uma instituição realiza uma pesquisa sobre condições médicas de uma população, produzindo duas bases de dados referentes aos anos de 2019 e 2020, representadas na Tabela A.1.

A instituição não publica essas tabelas, mas disponibiliza um mecanismo de acesso onde analistas autorizados podem realizar consultas sobre elas (os atributos identificadores, como o nome de cada indivíduo, são suprimidos).

Maria é uma pessoa que não participou da pesquisa em 2019, mas participou da pesquisa no ano 2020 (e, para simplificar o exemplo, Maria foi a única pessoa com esse comportamento). Assuma que um adversário que possui essa informação auxiliar gostaria de descobrir se Maria tem câncer. Para isso, ele consulta as tabelas realizando uma contagem do número de registros cuja enfermidade é **câncer** em 2019 e em 2020. Caso



(a) Distribuição de Laplace centralizada em 2. (b) Distribuição de Laplace centralizada em 3.

Figura A.2: Exemplo 27: Distribuição de Laplace centralizada em diferentes valores.

a diferença seja de exatamente um a mais para o ano 2020, ele saberá que Maria tem câncer, pois apenas ela foi adicionada à tabela.

Entretanto, Maria gostaria que a instituição se responsabilizasse pelo seu direito de negar o acesso às suas condições sensíveis a terceiros. Para isso, a instituição emprega um mecanismo de divulgação de dados que adiciona ruído ao resultado da consulta, garantindo privacidade.

O mecanismo funciona da seguinte maneira: para o resultado real da consulta em 2019 (em que 2 pessoas possuem câncer), o mecanismo adiciona ruído de acordo com a distribuição de Laplace centrada em 2 (Figura A.2a). Para o ano de 2020 (em que 3 pessoas possuem câncer), o mecanismo adiciona ruído de acordo com a distribuição de Laplace centrada em 3 (Figura A.2b).

Ao consultar pelo número de pessoas cuja enfermidade é **câncer**, no ano de 2019, o adversário recebe como resposta o número 2 com 50% de probabilidade, mas também pode receber os números 1 ou 3 com aproximadamente 20% de probabilidade. Outros resultados também são possíveis, como 0 ou 4, mas a probabilidade do mecanismo retornar esses valores é baixa, e diminui conforme o valor se afasta do valor real (de forma que a utilidade dos dados não é perdida).

Da mesma maneira, ao consultar o ano de 2020, o adversário recebe como resposta o número 3 com 50% de probabilidade, e os números 2 e 4 com aproximadamente 20% de probabilidade.

Este mecanismo implementa uma forma de negação plausível. Qualquer que seja a resposta fornecida pelo mecanismo, o adversário terá dúvidas razoáveis sobre se Maria tem ou não câncer, pois a presença ou ausência de seu registro na base de dados não afeta significativamente o resultado ruidoso da consulta (o resultado de um ano para o outro pode ter variado simplesmente pela adição de ruído em ambas as consultas). ◁




Figura A.3: Exemplo 28: Disposição inicial dos usuários na rede social. A existência da aresta vermelha entre Bob e um usuário na Comunidade 2 é a informação que o adversário pretende descobrir observando a evolução da rede.

A técnica usada no Exemplo 27, entretanto, foca apenas em esconder a presença de um único registro. O exemplo abaixo, produzido por Kifer e Machanavajjhala [70], demonstra que nem sempre esconder apenas a presença de um registro é suficiente para esconder a evidência de participação de uma pessoa na base de dados.

Exemplo 28 (A influência de um indivíduo na evolução de uma comunidade em uma rede social [70]). Considere a rede social, ilustrada na Tabela A.3, em que os usuários e suas relações são representados por um grafo não direcionado: os usuários são representados por vértices e as conexões entre eles são as arestas do grafo.

Esta rede social se inicia com duas comunidades distintas que compartilham no máximo uma aresta. O adversário sabe que, se essa aresta existe, é entre Bob (um membro da Comunidade 1) e outra pessoa na Comunidade 2. O adversário pode consultar o número de arestas entre as comunidades à medida que a rede evolui. A privacidade é violada quando o invasor pode dizer com alta probabilidade se Bob tinha ou não uma aresta para alguém da Comunidade 2 inicialmente.

A rede cresce durante um período em que as pessoas interagem umas com as outras, após o qual o adversário realiza a consulta “*quantas arestas existem entre as duas comunidades?*”. A exclusão da aresta de Bob depois do crescimento da rede, sob as garantias de privacidade diferencial, não implica mudanças drásticas na resposta dada à consulta (e.g. se o resultado da consulta fosse 20 arestas, remover o nó e as arestas de Bob resultaria em 19 arestas entre a Comunidade 1 e a Comunidade 2, que poderia ser considerado um resultado ruidoso). No entanto, a presença ou ausência de uma aresta entre Bob e alguém da Comunidade 2 no início afeta diretamente o crescimento da rede. De fato, se




Figura A.4: Exemplo 28: Efeitos causais no Copying Model como uma função do tamanho final da rede [70]. A rede cresce da seguinte maneira: quando um novo indivíduo entra para a rede, ele seleciona um nó pivô de maneira aleatória, uniformemente, e entra para a mesma comunidade deste nó. O novo indivíduo se conecta com cada nó na vizinhança do nó pivô com probabilidade 0.95 e se conecta com algum nó aleatório em qualquer comunidade com probabilidade 0.05.

a aresta existisse, Bob seria capaz de apresentar as pessoas com quem ele tem conexões na Comunidade 1 a seus amigos na Comunidade 2.

Portanto, o número esperado de arestas difere significativamente se Bob começa com uma aresta para alguém na Comunidade 2 ou não.

O gráfico na Figura A.4 mostra a diferença no número total de arestas entre as duas comunidades quando Bob tem a aresta inicial para alguém na Comunidade 2 (triângulo vermelho), e quando Bob não tem a aresta no início (círculo azul), depois que a rede cresce de 10 indivíduos para o tamanho correspondente (eixo horizontal). Cada novo nó tem uma probabilidade de 0.05 de gerar uma aresta para um nó aleatório na rede (inclusive em outra comunidade). Claramente, a existência de uma aresta inicial entre Bob e um membro da Comunidade 2 afeta diretamente o crescimento da rede e isso representa uma grande ameaça às técnicas de privacidade que tentariam ocultar a evidência de participação de Bob simplesmente apagando seu nó e suas arestas do grafo da rede (o que corresponde a apagar o registro de Bob depois de a rede já ter crescido).

◁

O exemplo demonstra que esconder a evidência de participação de indivíduos nem sempre é uma tarefa simples e, em alguns casos, não basta apenas esconder a evidência do registro

de um indivíduo na base de dados. Cada contexto deve ser cuidadosamente estudado para que a aplicação da privacidade diferencial seja, de fato, efetiva.

A.2 Condições para a existência de mecanismos ótimos universais

Um *mecanismo ótimo* para um analista é aquele que respeita suas preferências e tolerâncias com relação ao ruído adicionado. Neste contexto, seria desejável se obter, sempre que possível, o que se chama de *mecanismo ótimo universal*, i.e., um mecanismo capaz de ser simultaneamente ótimo para todos os (ou uma grande maioria dos) potenciais analistas da base de dados. Nesta seção discutimos alguns resultados da literatura que indicam em que condições podem existir mecanismos ótimos universais.

A.2.1 Modelos de analistas racionais

Um *analista racional* é aquele que, sabendo que o mecanismo de divulgação adapta sua resposta adicionando ruído para garantir privacidade, utiliza o resultado da consulta em conjunto com seus conhecimentos e convicções prévias para inferir a partir da resposta ruidosa qual é a resposta que minimize sua perda de acordo com uma função de utilidade subjetiva.

Há mais de um modelo para analistas racionais. Pra descrevê-los, assuma que q uma consulta que tem como entrada uma base de dados D de n registros e cuja saída é $q(D) = i$, $i \in \{0, \dots, n\}$. Seja $\mathcal{M}$ um mecanismo de divulgação de dados que garante privacidade, cuja entrada é uma base de dados D e a saída é $\mathcal{M}(D) = r$, $r \in \mathcal{R}$. Assim, os dois modelos são os seguintes.

- **Modelo Bayesiano** [58, 24] Neste modelo, a informação auxiliar do analista é representada por um vetor $\vec{p}$, onde p_i é a probabilidade à priori de que $q(D) = i$. As preferências do analista sobre o mecanismo de divulgação de dados são modeladas por uma função de perda $l(i, r)$, onde i é a resposta real da consulta ($q(D) = i$), r é a resposta ruidosa ($\mathcal{M}(D) = r$) e $l(i, r)$ retorna um valor que representa o quanto o analista é afetado pelo quão distante a resposta ruidosa se encontra da resposta real. A perda esperada para esse analista é calculada utilizando sua informação auxiliar, sua função de perda e o mecanismo de divulgação de dados: $\sum_{i \in N} p_i \sum_{r \in R} Pr[\mathcal{M}(D) = r | q(D) = i] \cdot l(i, r)$. Mecanismos ótimos para esse analista devem minimizar sua perda esperada.
- **Modelo averso ao risco** [62, 24] Neste modelo, a informação sensível do analista restringe o conjunto de valores de resultados reais de uma consulta $q(D)$. Isso é representado por um subconjunto $S \subseteq \{0, \dots, n\}$ dos possíveis valores que $q(D)$ pode retornar. A perda esperada máxima para esse analista é $\max_{i \in S} \sum_{r \in R} Pr[\mathcal{M}(D) =$

$r|q(D) = i] \cdot l(i, r)$. Mecanismos ótimos para esse analista procuram minimizar sua perda esperada máxima.

A.2.2 Tipos de consultas

Uma das dimensões a ser especificada para a existência de mecanismos ótimo é o tipo de consulta a ser realizada. Ghosh, Roughgarden e Sundararajan estudaram, para o Modelo Bayesiano de analista, a existência de um mecanismo ótimo para consultas de contagem (*count queries*) [58]. Gupte e Sundararajan estudaram a existência de um mecanismo ótimo para tais consultas para modelos de analistas aversos ao risco [62]. Por fim, Brenner e Nissim estendem esses resultados para outros tipos de consultas [24]. A seguir definimos os tipos de consulta estudados e ao final da seção apresentamos os resultados gerais encontrados nestes trabalhos.

- **Consulta de contagem (*count query*)**: consulta que toma uma base de dados como entrada e retorna o número de registros da base que satisfazem um predicado.
- **Consulta de soma (*sum query*)**: consulta que toma uma base de dados como entrada e, para uma coluna com valores numéricos na base, retorna a soma dos valores dessa coluna.
- **Consulta de histograma (*histogram query*)**: consulta que seleciona uma combinação de valores para um certo conjunto de colunas de uma base de dados, retornando quantos registros possuem exatamente essa combinação de valores.
- **Conjunto de consultas de contagem (*bundle of count queries*)**: conjunto de várias consultas de contagem respondidas simultaneamente.

A.2.3 Existência de mecanismos ótimos universais

Ghosh et al. mostram que é possível desenvolver um mecanismo ótimo universal para consultas de contagem e analistas com modelo de utilidade Bayesiano [58]. O resultado é descrito como um arcabouço que requer que o analista realize um pós-processamento da resposta ruidosa para adequá-la à função de perda, minimizando sua perda esperada.

O arcabouço funciona através da fatoração de qualquer mecanismo arbitrário desenhado para responder consultas de contagem de forma a garantir privacidade, como ilustrado na Figura A.5. O mecanismo é fatorado em um mecanismo geométrico (Definição 16) e uma etapa de pós-processamento, delegada ao analista, cujo objetivo é adaptar a resposta ruidosa do mecanismo geométrico à seu conhecimento a priori e à sua função de perda, minimizando a perda esperada.

O mecanismo geométrico é combinado a um mapeamento das respostas ruidosas, cujo desenvolvimento fica a cargo do analista. O analista utiliza sua informação auxiliar




Figura A.5: Esquema de mecanismo ótimo universal para consultas de contagem [58].

(i.e., seu conhecimento a priori $\vec{p}$) e sua função de perda, $l(i, r)$ para criar um mapeamento que transforme o mecanismo em um mecanismo ótimo para ele. O mapeamento ótimo resulta de aplicar o Teorema de Bayes para minimizar a perda esperada do analista.

Neste cenário, qualquer analista que deseje realizar uma consulta de contagem sobre a base de dados pode aplicar seu próprio mapeamento ótimo ao resultado do mecanismo geométrico, tornando o mecanismo, em conjunto com o mapeamento individual de cada analista, universalmente ótimo.

A etapa de pós-processamento não apresenta nenhum risco às garantias de privacidade, pois a privacidade diferencial resiste a pós-processamento (Teorema 21).

Mangesh Gupte e Mukund Sundararajan discutem um resultado similar ao apresentado acima [62], mas para analistas aversos a risco. A existência de um mecanismo ótimo universal neste caso é similar àquele referente ao analista do modelo Bayesiano: o mecanismo ótimo universal existe para consultas de contagem utilizando o mecanismo geométrico (Teorema 1 em [62]).

Por fim, Hai Brenner e Kobbi Nissim estudam a existência de mecanismos ótimos universais para analistas racionais nos dois modelos anteriores [24]. Seu objetivo é descobrir se resultados similares de existência de mecanismos ótimos universais se estendem a outros tipos de consultas.

O primeiro tipo de consulta analisado é a consulta de soma, que pode ser interpretada como uma generalização de consultas de contagem (cada consulta de contagem pode ser vista como uma consulta de soma cujo domínio dos atributos somados é $\{0, 1\}$). O Teorema 3.4 em [24] revela que, para ambos os modelos de utilidade Bayesiano e averso ao risco, não existe um mecanismo ótimo universal para consultas de soma.

Em seguida, são analisadas consultas de histogramas e conjuntos de consultas de somas. Os Teoremas 3.5 e 3.6 em [24] mostram que não existe um mecanismo ótimo universal

Modelo de analista	Tipo de consulta	Existe mecanismo ótimo universal?
Bayesiano e avesso a risco	Contagem	Existe
Bayesiano e avesso a risco	Soma	Não existe
Bayesiano e avesso a risco	Histograma	Não existe
Bayesiano e avesso a risco	Conjunto de contagens	Não existe

Tabela A.6: Sumário dos resultados sobre existência mecanismos ótimos universais de [58, 62, 24].

para nenhum dos dois tipos de consulta, respectivamente. O resultado é válido para ambos os modelos de utilidade.

A Tabela A.6 sumariza os resultados descritos acima. É possível notar que a existência de mecanismos ótimos universais não é a regra, mas a exceção. Consequentemente, na divulgação de dados estatísticos a utilidade dos dados será afetada negativamente para algum conjunto de analistas com alta probabilidade.

A.3 Relação entre quantidade de informação divulgada e o ruído adicionado

Um equívoco comum relacionado ao controle de divulgação estatística é assumir que estatísticas agregadas sejam, em si mesmas, garantias de privacidade individual. Um influente trabalho de Dinur e Nissim mostra que mesmo a publicação de apenas estatísticas agregadas pode revelar mais informação do que deveria, inclusive possibilitando a reconstrução completa da base de dados [43].

Esse risco pode ser mitigado de duas maneiras: inserindo ruído suficiente para impossibilitar a reconstrução da base de dados original ou limitando a quantidade total de consultas sobre a base.

No mesmo trabalho, Dinur e Nissim examinam especificamente qual a quantidade mínima de ruído ε que deve ser adicionado ao resultado de cada consulta para que não seja necessário limitar a quantidade de consultas que podem ser realizadas. Para isso, eles desenvolvem um algoritmo que reconstrói a base de dados original com grande acurácia a partir de uma publicação de estatísticas agregadas sem adição de ruído. Vale notar que uma publicação de estatísticas agregadas é equivalente à divulgação de um conjunto de resultados de consultas. Portanto, esse mesmo algoritmo poderia ser utilizado para um adversário que executasse consultas diretamente na base de dados, ao contrário de utilizar uma publicação estatística.

O resultado principal deste trabalho é que o tempo levado para reconstruir a base de dados (em função da quantidade de registros na base original) depende diretamente da quantidade de ruído adicionado à resposta de cada consulta realizada sobre a base. Para uma base de dados com n registros, um ruído $\varepsilon > \sqrt{n}$ deve ser adicionado ao resultado de cada consulta estatística para que um adversário não consiga reconstruir completamente a base de dados em tempo razoável. Adicionalmente, é necessário adicionar ruído $\varepsilon > n$ para que se torne impossível reconstruir a base de dados. Vale notar que quanto maior o ruído introduzido, menor é a utilidade dos dados publicado. Portanto, a escolha da quantidade de ruído introduzido deve balancear a privacidade e a utilidade.

Geralmente, adicionar ruído suficiente nas respostas para permitir um número ilimitado de consultas destrói a utilidade dos dados, fazendo com que a melhor estratégia seja adicionar menos ruído e limitar a quantidade total de consultas. Em uma publicação de estatísticas agregadas isso significa selecionar cuidadosamente o conjunto de estatísticas que será divulgado e verificar que ele não viola a privacidade dos indivíduos envolvidos no estudo. Em um sistema de consultas interativas ao banco de dados, isso implica na auditoria e limitação da quantidade máxima de consultas permitidas ao analista.

Reproduzimos abaixo um exemplo de ataque de reconstrução de base de dados de Dinur e Nissim, em que um conjunto de estatísticas é publicado sem adição de ruído. Algoritmos similares podem ser utilizados para reconstruir qualquer base de dados sobre a qual um conjunto de estatísticas agregadas tenha sido divulgado com pouco ou nenhum ruído adicionado ao resultado das consultas.

Exemplo 29 (Ataque de reconstrução de base [56]). Considere a Tabela A.7 que contém uma divulgação não perturbativa (i.e., sem ruído) de estatísticas agregadas sobre uma base de dados que contém informações sobre 7 indivíduos. Alguns atributos foram suprimidos (denotados como *) pois a agência que realiza a publicação oculta estatísticas que são baseadas em um número de pessoas menor que 3.

A base de dados que gerou esse conjunto de estatísticas pode ser reconstruída tratando os atributos dos indivíduos da pesquisa como um conjunto de variáveis. O algoritmo de reconstrução da base encontra um conjunto de valores para as variáveis que são consistentes com a tabela publicada. Se as estatísticas publicadas restringem os possíveis valores das variáveis o suficiente, o algoritmo encontra exatamente a base de dados que foi utilizada para gerar a tabela. Caso contrário, o algoritmo encontra algumas possíveis bases que podem ter gerado a tabela. Vale notar que pelo menos uma solução será encontrada, visto que a tabela foi gerada a partir de uma base de dados real.

O algoritmo funciona da seguinte maneira: o atacante extrai todas as restrições impostas pelas estatísticas publicadas e cria um modelo matemático que as contém. Essas restrições se manifestam como um sistema de equações lineares e não lineares em que as variáveis são limitadas a um certo intervalo. Em seguida, um programa próprio para resolver esses sistemas de equações recebe esse modelo como entrada e encontra os valores das variáveis que satisfazem todas as restrições simultaneamente.

A tabela possui informações sobre 7 indivíduos, cada um tendo 4 atributos: *idade*, *sexo*,

Categoria	Quantidade	Mediana da idade	Média da idade
Total de pessoas	7	30	38
Mulheres	4	30	33.5
Homens	3	30	44
Negros	4	51	48.5
Branco	3	24	24
Adultos solteiros	*	*	*
Adultos casados	4	51	54
Mulheres negras	3	36	36.7
Homens negros	*	*	*
Mulheres brancas	*	*	*
Homens brancos	*	*	*
Pessoas com menos de 5 anos	*	*	*
Pessoas com menos de 18 anos	*	*	*
Pessoas com mais de 64 anos	*	*	*

Tabela A.7: Exemplo 29: Tabela contendo divulgação não perturbativa (i.e., sem ruído) de estatísticas agregadas [56].

etnia e estado civil, o que gera 28 variáveis representando esses atributos para cada indivíduo. Para construir o modelo matemático chamaremos as variáveis de: $A_1, \dots, A_7$ para a idade de cada indivíduo em ordem crescente, $S_1, \dots, S_7$ para o sexo, $R_1, \dots, R_7$ para a etnia e $M_1, \dots, M_7$ para o estado civil.

As restrições sobre a idade de cada indivíduo são

$$A_1 + A_2 + A_3 + A_4 + A_5 + A_6 + A_7 = 7 \times 38 = 266, \quad (\text{A.1})$$

e

$$0 < A_n < 125, \quad n \in \{1, \dots, 7\}. \quad (\text{A.2})$$

A Equação A.1 surge do fato de que a média das idades é 38. A restrição sobre os valores das idades, dada pela Equação A.2, existe pois é razoável assumir que nenhum dos indivíduos tem mais do que 125 anos. Além disso, como as idades são ordenadas de forma crescente, pode-se afirmar que $A_4 = 30$, pois 30 é a mediana das idades.

Considerando que o atributo sexo seja um atributo binário e que os valores 0, 1 representem, respectivamente, indivíduos do sexo feminino e masculino, as restrições sobre o sexo de cada indivíduo são modeladas como

$$S_1 + S_2 + S_3 + S_4 + S_5 + S_6 + S_7 = 3. \quad (\text{A.3})$$

<i>idade</i>	<i>sexo</i>	<i>Etnia</i>	<i>estado civil</i>
8	mulher	branca	solteira
18	homem	branca	solteiro
24	mulher	branca	solteira
30	homem	branca	casado
36	mulher	branca	casada
66	mulher	branca	casada
84	homem	branca	casado

Tabela A.8: Exemplo 29: Base de dados reconstruída a partir de estatísticas agregadas [56].

Para três indivíduos arbitrários $i, j, k \in \{1, \dots, 7\}$, que consideraremos indivíduos da tabela cujo atributo sexo seja masculino (ou seja, $S_i + S_j + S_k = 3$) e cuja média de idade é 44, temos

$$A_i + A_j + A_k = 3 \times 44 = 132. \quad (\text{A.4})$$

Da mesma forma, as restrições sobre os atributos etnia e estado civil podem ser modeladas matematicamente. Esse conjunto de restrições é usado como entrada em qualquer programa que solucione sistemas de equações lineares e não lineares com um grande número de variáveis, como um solucionador SAT. O programa retorna um conjunto de variáveis que satisfaz todas as restrições simultaneamente. Se a solução for única, então esse conjunto de variáveis representa exatamente a base de dados utilizada para construir a tabela.

Para as estatísticas publicadas neste exemplo, Simson Garfinkel, John M. Abowd e Christian Martindale mostram que a solução encontrada pelo algoritmo é única [56], utilizando o solucionador PicoSAT [20]. A Tabela A.8 mostra o resultado do ataque.

◁

O exemplo acima nos mostra que é possível reconstruir uma base de dados que possui um conjunto de estatísticas agregadas divulgadas sem adição de ruído através de um algoritmo. O Teorema 3 em [43] afirma que a adição de ruído ao resultado de cada consulta estatística utilizada na tabela deve ser pelo menos $\sqrt{n}$, para uma base de dados com n registros, para que um algoritmo como o do exemplo acima não funcione para reconstruir corretamente a base de dados. Entretanto, com um ruído dessa ordem, um algoritmo que explore todas as possíveis combinações de valores dos registros ainda é capaz de encontrar a base de dados original, embora demande um tempo exorbitante. O Teorema 2 em [43] mostra que é necessário adicionar um ruído de ordem n ao resultado de cada consulta estatística para que seja impossível reconstruir a base de dados.

B Definição matemática de métricas de utilidade populares

Todo método de mitigação de degradação de privacidade vem acompanhado de um maior ou menor custo à utilidade dos dados divulgados –i.e., à qualidade da informação provida aos analistas. Nesta seção apresentamos um sumário de métricas de utilidade comumente utilizadas na literatura para medir o quanto um método de mitigação preserva a utilidade de uma divulgação. A Tabela B.1 apresenta sucintamente tais métricas.

No restante deste anexo, utilizamos a seguinte nomenclatura. Seja $B = (R, A)$ uma base de dados que pode ser vista como uma tabela onde $R = \{r_1, \dots, r_n\}$ é o conjunto de linhas (registros) e $A = \{A_1, \dots, A_m\}$ é o conjunto de colunas (atributos). Cada registro $r_i = (r_{i1}, \dots, r_{im})$ é uma tupla onde r_{ij} corresponde ao valor da tabela B da i -ésima linha e j -ésima coluna. Chamemos de $\Omega_1, \dots, \Omega_m$ os domínios dos atributos $A_1, \dots, A_m$, respectivamente.

Seja $\hat{B}$ a base de dados resultante da aplicação de técnicas para o controle de privacidade (modificação dos valores r_{ij}) na base B . Temos que $\hat{B} = (\hat{R}, \hat{A})$, $\hat{R} = \{\hat{r}_1, \dots, \hat{r}_n\}$, onde $\hat{r}_i = (\hat{r}_{i1}, \dots, \hat{r}_{im})$, $\hat{A} = \{\hat{A}_1, \dots, \hat{A}_m\}$ e os respectivos domínios dos atributos $\hat{\Omega}_1, \dots, \hat{\Omega}_m$.

Por fim, assuma que exista em toda base de dados B um atributo A_1 tal que $\Omega_1 \subset \mathbb{N}$ que corresponde ao número da linha na tabela.

A seguir sumarizamos as principais métricas de utilidade utilizadas na literatura.

Definição 30 (Erro quadrático). O *erro quadrático* entre duas bases B e $\hat{B}$ é definido como

$$\text{EQ}(B, \hat{B}) = \frac{1}{n \cdot m} \sum_{i=1}^n \sum_{j=1}^m \text{DEN}(r_{ij}, \hat{r}_{ij}) ,$$

onde $\text{DEN}(r_{ij}, \hat{r}_{ij})$ é a *distância Euclidiana normalizada*. A distância Euclidiana (não normalizada) não é utilizada pois os atributos possuem domínios diferentes. $\triangleleft$

Definição 31 (Erro quadrático por registro). O *erro quadrático por registro* entre duas bases B e $\hat{B}$ é definido como

$$\text{EQR}(B, \hat{B}) = \frac{1}{n \cdot m} \sum_{i=1}^n \text{distancia}(r_i, \hat{r}_i) ,$$

onde $distancia(r_i, \hat{r}_i)$ é a distância euclidiana dos registros (tuplas) r_i e $\hat{r}_i$. $\triangleleft$

Definição 32 (Discernibilidade). Seja $Q = \{Q_1, \dots, Q_p\}$ uma família de quasidentificadores, onde cada Q_i é um atributo cujo valor seja possivelmente conhecido pelo adversário. A métrica de *discernibilidade* sobre $\hat{B}$ é definida como

$$DM(\hat{B}) = \sum_{Q_i \in Q} |\hat{B}[Q_i]|^2 ,$$

onde $\hat{B}[Q_i]$ corresponde ao conjunto de registros que são indistinguíveis por Q_i . $\triangleleft$

Definição 33 (Benefício do divulgador). Considere um jogo com dois jogadores: um *divulgador* (de um banco dados) e um *adversário* (alguém que quer obter informações de um alvo com o banco de dados). Considere que ambos os jogadores tem motivações financeiras. Definimos a seguir quatro parâmetros:

- *Ganho do adversário*: O benefício do adversário em reidentificar um registro com sucesso.
- *Custo do adversário*: O custo para um adversário executar um ataque de reidentificação contra um registro.
- *Benefício do divulgador*: O benefício do divulgador em publicar um registro em sua forma original.
- *Perda do divulgador*: A perda do divulgador referente a cada registro reidentificado pelo adversário.

Seja $PS(r)$ a probabilidade de sucesso do adversário. Um adversário ataca um registro r se o lucro dele é positivo, isto é

$$Ataque(r) = \begin{cases} 1 & , \text{ if } PS(r) \cdot Ganho > Custo \\ 0 & , \text{ caso contrário.} \end{cases}$$

O *lucro do divulgador* por publicar um registro r é definido como

$$Benefício(r) = (1 - IL(r)) \cdot Benefício .$$

Quando um registro é atacado com sucesso, o divulgador perde dinheiro. A perda esperada por registro é relativa a probabilidade de sucesso do adversário. Consequentemente, o lucro total esperado do Divulgador para um registro r é

$$Lucro(r) = Benefício(r) - Ataque(r) \cdot PS(r) \cdot Perda .$$

$\triangleleft$

Definição 34 (Informação mútua ou ganho de informação). A *informação mútua* ou *ganho de informação* $I(B; \hat{B})$ entre B e $\hat{B}$ é definida como

$$I(B; \hat{B}) = \frac{1}{m} \sum_{j=1}^m I(A_j; \hat{A}_j) ,$$

onde

$$I(A_j; \hat{A}_j) = H(A_j) - H(A_j | \hat{A}_j) ,$$

onde $H(X)$ é a entropia da variável aleatória X . Apesar de A_j ser um atributo (conjunto de valores), podemos pensar em A_j como variável aleatória se olharmos para as frequências dos valores. $\triangleleft$

Definição 35 (Média da distância da variação total ou Perda L1). Seja Q um conjunto de consultas, X_q , para $q \in Q$, a variável aleatória correspondente aos valores de uma consulta q em uma base de dados B e $\Pr(X_q = x)$ a frequência do valor x no conjunto de valores retornado por q . A *média da variação total das distâncias* entre X_q , que corresponde a base original B e $\hat{X}_q$ que corresponde a base modificada $\hat{B}$ é definida como

$$\text{MDVT}(X_q, \hat{X}_q) = \frac{1}{2|Q|} \sum_{q \in Q} \sum_{x \in \Omega_q} |\Pr(X_q = x) - \Pr(\hat{X}_q = x)| ,$$

onde Ω_q é o domínio dos valores retornado pela consulta q . $\triangleleft$

Definição 36 (Divergência de Kullback-Leiber). Seja P a distribuição de probabilidade dos valores dos quase-identificadores da base de dados original B , e $\hat{P}$ a distribuição de probabilidade dos valores para a base modificada $\hat{B}$. A *divergência de Kullback-Leiber* entre P e Q é definida como

$$\text{KL}(P || \hat{P}) = \sum_{x \in \Omega} \Pr(P = x) \ln \left(\frac{\Pr(P = x)}{\Pr(\hat{P} = x)} \right) ,$$

onde Ω é o domínio de P e $\hat{P}$. $\triangleleft$

Métrica	Definição	Significado operacional
Erro quadrático [100]	Avalia o impacto da criação de classes de equivalência	Soma dos erros (ao quadrado) de cada célula da tabela modificada em relação à original
Erro quadrático por registro [95]	Distância entre a base de dados original e a modificada (registros são tratados como vetores em um espaço m dimensional, onde m é o número de atributos)	Distância média entre os registros da base de dados modificada e a original
Discernibilidade [54]	O quão indistinguível os registros são um do outro associando uma penalidade para os registros que se tornam indistinguíveis	Nível total de “discernibilidade” das células da tabela
Benefício do divulgador [92]	Benefício ao se publicar um registro com os dados originais	Ganho esperado do divulgador ao <i>não</i> modificar os registros
Informação mútua ou ganho de informação [61, 106]	Quantidade de informação que os grupos de equivalência da base de dados generalizada carregam sobre os registros originais	Informação mútua (em bits) entre a base generalizada e a original
Média da Distância da Variação Total ou Perda L1 [5]	Distância média entre as distribuições de probabilidade das consultas feitas na base modificada e na original	Variação média na distribuição dos valores das consultas
Divergência de KullBack-Lieber [106]	Distância entre as distribuições de probabilidade da base de dados modificada e a original	Ineficiência que a base modificada tem em representar a original

Tabela B.1: Métricas de utilidade populares que avaliam a qualidade da informação em uma base de dados tratada por um método de mitigação de degradação à privacidade.

C Implementação dos algoritmos de anonimidade- k , diversidade- ℓ e proximidade- t provida pela ferramenta ARX

Neste anexo apresentamos a implementação que a ferramenta ARX fornece para os algoritmos não perturbativos para divulgação de microdados descritos na Seção 4.1. Nossa apresentação inclui uma descrição de quais parâmetros a ferramenta precisa para operar corretamente, e suas limitações para ser aplicada aos Censos Educacionais do Inep.

ARX é um software *open source* que tem o objetivo de prover métodos e algoritmos para quantificar, avaliar e promover a privacidade em bases de dados. A ferramenta teve sua primeira versão disponível para uso em 2012, e desde então ela tem sido mantida por pesquisadores do Hospital Universitário Charité em Berlim (*Charité - Universitätsmedizin Berlin*),¹ pela Universidade Técnica de Munique (*TUM - Technische Universität München*),² e pelo Instituto de Saúde de Berlim (*BIH - Berlin Institute of Health*).³ O código-fonte do software está disponível no GitHub,⁴ e mais informações sobre a utilização e *download* estão disponíveis na própria página do projeto.⁵ Atualmente a ferramenta está na versão 3.8.0.

Nesta ferramenta, o objetivo do divulgador de dados em um método sintático é expresso na forma de uma *função de utilidade* que deve ser fornecida ao algoritmo a fim de decidir qual solução mais útil no espaço de soluções possíveis (cada uma consistindo em uma combinação específica de operações de generalização e supressão de atributos).

O espaço de soluções é formalizado através de *árvores de generalização* para cada atributo, onde os nós nos níveis mais altos da árvore contém valores mais genéricos para o

¹<https://www.charite.de/>

²<https://www.tum.de/>

³<https://www.bihealth.org/>

⁴<https://github.com/arx-deidentifier/arx>

⁵<https://arx.deidentifier.org>

atributo, enquanto as *folhas* (nós no nível mais baixo) contém os valores mais específicos. A Figura C.1 apresenta 3 possíveis árvores de generalização para os atributos *região*, *sexo* e *idade* dos Exemplos 4 da Seção 4.1.4.

O divulgador de dados é o responsável por construir as árvores de generalização para cada atributo. Após a definição das árvores, temos o espaço de soluções definido. Uma solução é formada pelo nível de generalização que cada atributo deve assumir relacionado à sua árvore de generalização. Como exemplo, considere as árvores da Figura C.1. As alturas das árvores (i.e., o número de níveis) dos atributos *região*, *sexo* e *idade* são 3, 1 e 3, respectivamente. Neste caso, uma solução será uma tripla $(a_{\text{região}}, a_{\text{sexo}}, a_{\text{idade}})$, onde a_i corresponde o nível de generalização escolhido para o atributo i . A solução (1,1,2) por exemplo, indica que os valores do atributo *região* devem ser generalizados para **América**, **Europa** e **Ásia**, o atributo *sexo* deve ser suprimido e, por fim, os valores do atributo *idade* devem ser generalizados para os intervalos [18–44] e [45–70].

Desta forma, é possível produzir diferentes bases de dados com diferentes combinações de generalizações para os atributos. O objetivo dos algoritmos que implementam os métodos sintáticos é explorar o espaço de soluções e encontrar a tupla que possui a maior utilidade enquanto satisfaz a restrição do método escolhido. O algoritmo do estado-da-arte para o problema é conhecido como *flash algorithm*, e foi proposto por Kohlmayer, Prasser, Eckert, Kemper e Kuhn em 2012 [71]. Os algoritmos para anonimidade- k , diversidade- ℓ e proximidade- t disponibilizados na ferramenta ARX utilizam o *flash*, e apresentam complexidade computacional (i.e., o tempo de execução que ele gasta para encontrar a solução como uma função do tamanho da entrada) linear no número de células da base de dados (i.e., número de registros $\times$ número de atributos).

Entretanto, é preciso notar que a ferramenta ARX suporta apenas tabelas de até $2^{31} - 1 \approx 2.1$ bilhões de células. A eventual adoção destes algoritmos pelo Inep demandaria uma extensão da ferramenta ARX, uma vez que as bases dos Censos Educacionais excedem em muito este limite. Por exemplo, o Censo do Ensino Básico de 2019 possui cerca de 5.3 bilhões de células (105 colunas e 51 milhões de registros), enquanto o maior Censo até hoje em quantidade de registros, do Ensino Básico de 2014, possui cerca de 4.7 bilhões de células (85 colunas e 56 milhões de registros).




(a) Possível árvore de generalização do atributo *região*.(b) Possível árvore de generalização do atributo *sexo*.(c) Possível árvore de generalização do atributo *idade*.

Figura C.1: Possíveis árvores de generalização para os atributos *região*, *sexo* e *idade*, selecionados como quase-identificadores. As folhas (nós no nível 0) contêm os valores originais dos atributos, e os nós em níveis mais altos contêm valores cada vez mais generalizados. O mais alto nível da árvore, que contém o nó raiz com o símbolo “ $*$ ”, representa a supressão completa do valor do atributo.

D Variantes refinadas da privacidade diferencial que podem garantir maior utilidade das divulgações

Neste anexo discutimos duas variantes da privacidade diferencial que podem apresentar vantagens significativas sobre a privacidade diferencial tradicional em termos da utilidade da informação divulgada. Por esta razão, tais variantes podem ser consideradas como uma alternativa para a divulgação de microdados dos Censos Educacionais de forma privada. Por outro lado, elas demandam um expertise substancialmente maior do desenhista da solução, além de mais tempo e recursos, para que tais benefícios sejam atingidos. Mais precisamente, apresentamos a privacidade diferencial- (ϵ, δ) , que permite violações de privacidade raras em troca de uma maior utilidade dos dados e a privacidade- d , que explora a noção de indistinguibilidade entre segredos para aumentar a utilidade de divulgações.

D.1 Privacidade diferencial- (ϵ, δ)

A privacidade diferencial- ϵ é uma garantia bastante forte, uma vez que ela garante a todo e qualquer indivíduo na base de dados o mesmo nível de proteção. Por mais improvável que seja a inserção, remoção, ou alteração do valor de um indivíduo qualquer, ele tem a mesma privacidade que indivíduos sobre os quais alterações são mais prováveis.

Neste sentido, existe um relaxamento da definição de privacidade diferencial baseada na ideia de que é aceitável garantir a privacidade da maioria dos indivíduos ao custo do relaxamento das garantia para “somente alguns” indivíduos. Esta filosofia não é muito distinta daquela adotada por métodos de amostragem de microdados. Como exemplo, suponha que haja uma base com diversos dados sobre uma população, inclusive informações sensíveis. Se for feita uma amostragem de 2% das pessoas dessa base, então haverá uma grande chance (98%) de um indivíduo em específico não ter sido selecionado. Desta forma, com alta probabilidade, a maioria da população não terá os seus dados publicados, e portanto, a privacidade estará garantida para estes indivíduos. Porém, os 2% selecionados na amostra terão todos os seus dados publicados, com resultados potencialmente

catastróficos para esta minoria. Na privacidade diferencial, esta filosofia é capturada pela definição de privacidade diferencial- (ε, δ) [48, 47].

Definição 37 (Privacidade diferencial- (ε, δ)). Seja ε um valor real positivo, δ um valor real não negativo, e $\mathcal{M}$ um *mecanismo de consulta* (ou um *algoritmo randomizado*) que recebe como entrada uma base de dados $D \in \mathcal{D}$ e produz como saída um valor pertencente a um conjunto $\text{img}(\mathcal{M})$. Dizemos que $\mathcal{M}$ satisfaz *privacidade diferencial- (ε, δ)* se, e somente se, para todo par D, D' de bases adjacentes e para todo $S \subseteq \text{img}(\mathcal{M})$,

$$\Pr[\mathcal{M}(D) \in S] \leq e^\varepsilon \cdot \Pr[\mathcal{M}(D') \in S] + \delta. \quad (\text{D.1})$$

◁

O parâmetro δ controla justamente a probabilidade de um indivíduo não estar coberto pela proteção de privacidade diferencial. Intuitivamente, a Equação D.1 garante que com probabilidade no mínimo $1 - \delta$ indivíduos têm a garantia de privacidade diferencial com parâmetro ε . O caso particular em que $\delta = 0$ (ou seja, indivíduos devem ter a garantia de privacidade diferencial- ε com 100% de probabilidade), se reduz à Definição 10.

D.2 Privacidade- d

A *privacidade- d* (*d-privacy*, no original em inglês) é uma generalização dos conceitos tanto de privacidade diferencial global quanto local, proposta por Chatzikokolakis, Andrés, Bordenabe e Palamidessi em 2013 [29].

Recorde que a ideia central da privacidade diferencial é limitar a informação que um adversário, ao observar a saída de um mecanismo, pode inferir a respeito de segredos que devem ser considerados “indistinguíveis”. No caso da privacidade diferencial original (Definição 10), tais segredos seriam pares de bases adjacentes, i.e., que diferem em apenas um registro; enquanto na privacidade diferencial local (Definição 23) os segredos seriam quaisquer valores que um registro pode assumir. O cerne da privacidade- d é permitir a generalização da noção de “indistinguíbilidade” para quaisquer pares de bases (ou segredos em geral), dependendo de cada contexto. Mais especificamente, assume-se que existe uma noção de *distância* sobre bases de dados (ou segredos) que capture o quão indistinguíveis elas devam ser (i.e., quanto menor a distância, maior a indistinguíbilidade desejada). A definição de tal distância fica a critério do curador da base de dados, levando em conta cada contexto de interesse.

Por exemplo, considere as bases de dados da Tabela D.1. Segundo a definição original de privacidade diferencial global, as bases de dados D_1 , D_2 e D_3 são todas adjacentes entre si, pois elas diferem apenas no primeiro registro –mais precisamente, no valor do atributo *idade* do registro de *id* 1. Se o objetivo do curador é proteger a privacidade o valor do atributo *idade* de qualquer indivíduo, a privacidade diferencial original demandaria o mesmo nível de ruído para ofuscar o adversário entre as bases D_1 , D_2 e D_3 . Entretanto,

<i>id</i>	<i>UF</i>	<i>sexo</i>	<i>idade</i>
1	MG	F	20
2	DF	M	18
3	AC	F	16

(a) Base de dados D_1

<i>id</i>	<i>UF</i>	<i>sexo</i>	<i>idade</i>
1	MG	F	22
2	DF	M	18
3	AC	F	16

(b) Base de dados D_2

<i>id</i>	<i>UF</i>	<i>sexo</i>	<i>idade</i>
1	MG	F	60
2	DF	M	18
3	AC	F	16

(c) Base de dados D_3 Tabela D.1: Exemplo de métrica de distância entre bases usada na privacidade- d .

intuitivamente, a base D_1 é mais “próxima” da base D_2 do que da base D_3 no que se refere à idade dos indivíduos: somente o indivíduo de *id* 1 varia de idade, e a variação é de 2 anos de D_1 para D_2 , mas de 40 anos de D_1 para D_3 . Podemos, então, definir a distância d entre as bases de dados como a diferença absoluta entre o valor do atributo *idade* do primeiro indivíduo. Desta forma, $d(D_1, D_2) = |20 - 22| = 2$, $d(D_1, D_3) = |20 - 60| = 40$ e $d(D_2, D_3) = |22 - 60| = 38$, e explorar esta noção de proximidade para ajustar o ruído adicionado de forma proporcional à distância. Esta ideia é formalizada a seguir.

Definição 38 (Privacidade- d). Seja ε um valor real positivo e $\mathcal{M}$ um *mecanismo de consulta* (ou um *algoritmo randomizado*) que recebe como entrada uma base de dados $D \in \mathcal{D}$ e produz como saída um valor pertencente a um conjunto $\text{img}(\mathcal{M})$, como definido em 10, e seja $d(D, D')$ uma medida de distância entre duas bases de dados $D, D' \in \mathcal{D}$.

Dizemos que $\mathcal{M}$ satisfaz *privacidade- d* se, para quaisquer duas bases de dados $D, D' \in \mathcal{D}$ cuja distância é dada por $d(D, D')$ e para todo $S \subseteq \text{img}(\mathcal{M})$:

$$\Pr[\mathcal{M}(D) \in S] \leq e^{\varepsilon d(D, D')} \cdot \Pr[\mathcal{M}(D') \in S] .$$

◁

A privacidade- d generaliza tanto a privacidade global quanto a local,¹ e tem sido utilizada em alguns contextos para aumentar significativamente a utilidade de divulgações de dados

¹A privacidade diferencial global é um caso particular da Definição 38 da seguinte maneira. Seja $d_H(D, D')$ a distância de Hamming entre duas bases de dados d e d' , i.e., o número de registros nos quais as bases diferem. Então um mecanismo $\mathcal{M}$ que satisfaz privacidade diferencial- ε para duas bases de dados adjacentes pode ser generalizado para quaisquer bases de dados D e D' utilizando privacidade- d . Esse mecanismo satisfaz privacidade- d se, e somente se, para todo $S \subseteq \text{img}(\mathcal{M})$,

$$\Pr[\mathcal{M}(D) \in S] \leq e^{\varepsilon d_H(D, D')} \cdot \Pr[\mathcal{M}(D') \in S] .$$

Já a privacidade diferencial local é um caso particular da privacidade- d da seguinte maneira. Seja $d_l(D, D')$ a distância discreta entre duas bases, i.e.,

$$d_l(D, D') = \begin{cases} 1 & \text{se } D \neq D' \\ 0 & \text{se } D = D' \end{cases}$$

Então um mecanismo $\mathcal{M}$ que satisfaz privacidade diferencial- ε (local) para duas bases de dados adjacentes pode ser generalizado para quaisquer duas bases de dados D e D' utilizando privacidade- d . Esse

ao mesmo tempo em que se mantêm as mesmas garantias de privacidade de definições originais [15], com particular sucesso no contexto de geolocalização [18].

mecanismo satisfaz privacidade- d se, e somente se, para todo $S \subseteq \text{img}(\mathcal{M})$,

$$\Pr[\mathcal{M}(D) \in S] \leq e^{\varepsilon d_l(D, D')} \cdot \Pr[\mathcal{M}(D') \in S] .$$

E Visão geral dos algoritmos para produção de histogramas e dados sintéticos respeitando privacidade diferencial

Neste anexo apresentamos os principais algoritmos existentes na literatura para produção de histogramas e dados sintéticos de forma a respeitar a privacidade diferencial. O objetivo é apresentar os principais desafios envolvidos na implementação das técnicas discutidas na Seção 6.4.2. A descrição dos algoritmos aqui apresentada se baseia no capítulo 3 do livro *Medical Data Privacy Handbook* [60].

Os algoritmos podem ser classificados em 3 categorias:

1. **Algoritmos paramétricos**, que, a partir dos dados originais, constroem uma distribuição multivariada estimando seus parâmetros, e, em seguida, geram uma nova base com dados sintéticos, onde os valores são gerados a partir da distribuição multivariada que foi construída.

Dentre os algoritmos desta família, podemos destacar o seguinte:

- **Multinomial-Dirichlet (MD)** [78]. O algoritmo constrói uma distribuição multivariada que melhor se adequa aos valores presentes na base de dados, e, em seguida, gera novos dados a partir desta distribuição. Uma característica interessante deste algoritmo é o fato dele contornar o problema da geração de dados que são inexistentes na base original (e.g., valores de atributos que apareciam em 0 registros na base original que passam a ser maior que 0 nos dados sintéticos devido ao ruído). Entretanto, é necessário utilizar a definição de privacidade diferencial- (ϵ, δ) , discutida no Anexo D.1.
2. **Algoritmos semi-paramétricos**, que, considerando cada atributo da base de dados como sendo uma dimensão, capturam a dependência implícita de bases com alta dimensionalidade (i.e., com muitos atributos), e utilizam métodos que não

possuem parâmetros para criar histogramas marginais de cada atributo. Por fim, os dados sintéticos são gerados a partir dos histogramas marginais e das dependências dos atributos.

Dentre os algoritmos desta família, podemos destacar o seguinte:

- **DPCopula** [74]. O algoritmo tem como objetivo produzir dados sintéticos de alta dimensionalidade. A função *copula*¹ é utilizada juntamente com uma matriz de dependência dos atributos para criar o modelo estatístico de onde os dados sintéticos serão gerados.

3. Algoritmos não paramétricos, que utilizam as frequências dos valores originais da base para poder adicionar ruído.

Dentre os algoritmos desta família, podemos destacar os seguintes:

- **LPA** [49]. Dado um histograma de n dimensões (atributos), o algoritmo LPA adiciona ruído em cada célula do histograma utilizando a distribuição de Laplace (Definição 14). Ele funciona bem para dados com poucas dimensões, entretanto, em dados de alta dimensionalidade, a quantidade de ruído adicionada pela distribuição de Laplace pode ser extremamente grande.
- **SmallDB** [51, 38, 104]. O *SmallDB* é um método que utiliza o mecanismo exponencial (Definição 18) para satisfazer a privacidade diferencial. A ideia principal é responder o mais acuradamente possível um conjunto fixo de consultas, enquanto que outras consultas não fixadas são ignoradas. Sendo assim, o método tem como saída uma “pequena base de dados”, mais especificamente, uma amostra da base original, que pode ser utilizada para responder acuradamente um conjunto predeterminado de consultas. Para consultas nesta pequena base que não foram pré-determinadas, não há garantias de que a resposta será acurada. Além disso, uma consulta só pode ser respondida uma única vez, o que não abre margem para o adversário analisar os diferentes ruídos adicionados à mesma consulta, com o objetivo de obter o valor real dos dados.
- **NoiseFirst e StructureFirst** [107]. A ideia principal desses algoritmos é explorar a estrutura dos histogramas, i.e., a quantidade de *bins* (quantidade de intervalos/barras verticais). Este tipo de informação ajuda a balancear a quantidade de ruído adicionada, visando manter a utilidade dos dados. Ambos os algoritmos se baseiam na mesma ideia, mas executam-na em ordens diferentes. O NoiseFirst primeiramente adiciona ruído no histograma, utilizando a distribuição de Laplace, e posteriormente utiliza programação dinâmica pra encontrar a melhor estrutura para o histograma. Já o StructureFirst primeiro encontra a estrutura ótima do histograma para depois adicionar o ruído. Os dois algoritmos funcionam bem para bases de dados com poucas dimensões

¹Uma distribuição multivariada onde distribuições marginais de todas as variáveis são uniformes.

(atributos), contudo, por conta do seu custo computacional, o tempo de execução do algoritmo pode ser extremamente alto em bases com alta dimensionalidade.

Por fim, existem outros algoritmos que exploram diferentes características do processo de adição do ruído e utilizam diferentes ferramentas para satisfazer a privacidade diferencial, como os trabalhos [19, 8] que utilizam a transformada de Fourier para tratar os dados e o ruído, e o algoritmo DiffGen [85] que visa produzir dados que serão utilizados para classificação, entre outros, que não serão detalhados neste documento.

F Aplicação de privacidade diferencial no Censo dos EUA em 2020

Como discutido no Produto 01 deste projeto e na Seção 6.4.3 do presente documento, o Escritório do Censo dos Estados Unidos (*United States Census Bureau - USCB*) está atualmente executando o Censo de 2020. O USCB anunciou em 2018 sua decisão de substituir métodos sintáticos por soluções baseadas em privacidade diferencial a partir do Censo de 2020 [6]. Neste mesmo anúncio o Escritório ressaltou que não existia *software* disponível no mercado que aplicasse privacidade diferencial em um censo nacional. Por esse motivo, foi necessário que a própria equipe do USCB desenvolvesse a solução, a um elevado custo tanto financeiro quanto de pessoal. Devido às alterações nos métodos utilizados pelo USCB para o controle da divulgação de dados estatísticos, mudanças também são esperadas no que diz respeito aos produtos que serão disponibilizados pelo Escritório a partir dos dados coletados pelo Censo de 2020.

Até a última atualização divulgada pelo USCB, em 08 de novembro de 2019, por volta de um terço das publicações agregadas tabulares planejadas já são suportadas pelo novo sistema baseado em privacidade diferencial, ou estão em fase de implementação [27]. Entretanto, os outros dois terços das publicações agregadas tabulares ainda estão em fase de pesquisa para adaptação, ou por serem dependentes de operações complexas, ou por serem muito específicas no que se refere à população abordada, ou ainda por dependerem de publicações ainda não suportadas.

Neste anexo apresentamos detalhes técnicos da solução, ilustrando seu alto grau de sofisticação e complexidade.

F.1 Métodos de coleta e divulgação dos dados

De acordo com [57], os dados coletados da população para o censo dos EUA proveem da Internet, de chamadas telefônicas e de formulários entregues por funcionários da agência na residência de cada cidadão. Todos esses dados confidenciais são coletados e processados para formar a primeira base de dados não editada, chamada de Arquivo Não Editado do Censo (*Census Unedited File - CUF*). Especialistas de diversas áreas realizam, então, correções de problemas de diferentes naturezas no CUF utilizando como




Figura F.1: Fluxo dos dados desde a sua coleta até a divulgação pública no Censo dos EUA.

auxílio outras fontes de dados, e a partir disso é gerada a primeira base editada, chamada de Arquivo Editado do Censo (*Census Edited File - CEF*). Em seguida, algumas modificações são realizadas no CEF pelo Sistema de Prevenção de Divulgação (*Disclosure Avoidance System - DAS*), e o resultado destas modificações compõe a base chamada de Arquivo Detalhado de Microdados (*Microdata Detailed File - MDF*). Todos os dados disponibilizados publicamente são obtidos utilizando a MDF.

Atualmente o DAS está em desenvolvimento. A partir da base de dados MDF, são extraídas as estatísticas que serão divulgadas publicamente. Os dados finais são publicados em formato de histogramas, que são uma forma diferente de representar tabelas de dados. A Figura F.1 mostra o fluxo completo dos dados, desde a coleta até a publicação.

O DAS do censo de 2020 é o passo onde será introduzido ruído aos dados, visando satisfazer a privacidade diferencial. Na próxima seção discutiremos duas abordagens criadas pelo Escritório do Censo dos EUA que lidam com a adição de ruído exigido pela privacidade diferencial ao mesmo tempo em que mantém a consistência na coleta de dados exigida pela Constituição dos EUA.

F.2 Algoritmos usados na nova abordagem

Como demonstrado por Dwork, qualquer garantia de privacidade não trivial necessita de aleatoriedade [51]. Portanto, é necessário introduzir ruído nos dados coletados pela USCB. Entretanto, a Constituição dos EUA força a instituição a publicar algumas informações sem a introdução de ruído, devido a necessidades políticas [3]. Basicamente, a restrição imposta pela Constituição é de publicar exatamente o número de pessoas que vive em diferentes geolocalidades, sendo estas o país, os estados, as cidades, *tracts*, grupos de bairros e bairros.

A fim de satisfazer essas restrições, foram considerados dois algoritmos, o *Block-by-block* e o *TopDown*. Este último foi escolhido como o algoritmo de melhor custo-benefício, enquanto que o primeiro foi descartado por acrescentar uma quantidade de ruído não aceitável. A seguir descrevemos ambas as soluções.




Figura F.2: Esquema do algoritmo *Block-by-block*. Os dados por quarteirão são aqueles com o maior nível de detalhamento da informação presente no Censo Decenal dos EUA.

- **Algoritmo *Block-by-block*** O primeiro algoritmo proposto pela equipe do censo é conhecido como *Block-by-block* (“quarteirão a quarteirão”, em tradução livre). Ele consiste em proteger as informações individuais das pessoas de cada quarteirão introduzindo ruído em cada um dos 8 milhões de quarteirões dos EUA. Como os dados por quarteirão são aqueles que possuem o maior nível de detalhamento da informação presente no censo, introduzir ruído individualmente em cada quarteirão pode ser considerado uma versão de privacidade diferencial local. As vantagens deste algoritmo são a facilidade de paralelização, a independência do custo de privacidade em relação ao número de quarteirões, uma introdução única de ruído para cada quarteirão e uma quantidade ilimitada de consultas permitidas à base de dados. A Figura F.2 apresenta o fluxo de dados do censo dos EUA ao se utilizar o algoritmo.

Entretanto, introduzir ruído em cada quarteirão gera uma enorme quantidade de erro nas estatísticas obtidas sobre a base como um todo, devido a propriedade de composicionalidade apresentada na Seção 6.3.4. Essa propriedade nos diz que o erro total será proporcional ao ϵ escolhido e ao número de registros em que foi introduzido o ruído, que neste caso, são os 8 milhões de quarteirões. Por esta razão esta solução foi considerada inviável e foi abandonada pela equipe.

- **Algoritmo *TopDown*** O segundo algoritmo proposto é conhecido como *TopDown* (“do topo para baixo”, em tradução livre). A ideia é introduzir ruído em diferentes níveis de granularidade, isto é, para diferentes agregações dos dados (como país, estado, quarteirão). Primeiramente, um valor ϵ_0 é escolhido para introduzir ruído no histograma H_0 , que contém informação a nível de país e não fornece nenhuma referência sobre onde cada cidadão vive. Após a adição do ruído, obtemos um histograma $\tilde{H}_0$ que respeita privacidade diferencial ϵ_0 . Em seguida, a informação sobre o estado onde cada pessoa vive é adicionada a $\tilde{H}_0$, isto é, uma nova coluna *estado*




Figura F.3: Esquema do algoritmo *TopDown*. A privacidade diferencial é aplicada em todos os níveis de granularidade dos dados.

é adicionada à base de dados representada por $\tilde{H}_0$, gerando assim o histograma H_1 . Em seguida um novo ε_1 é escolhido para se introduzir ruído à H_1 , a fim de se obter um histograma $\tilde{H}_1$ que respeite privacidade diferencial para um valor $\varepsilon_0 + \varepsilon_1$. Este processo continua passando pelos histogramas de cidades, *tracts*, grupos de bairros e bairros, o que resulta em um histograma final $\tilde{H}_5$ que respeita privacidade diferencial com um valor $\varepsilon_0 + \dots + \varepsilon_5$.

A base de dados final, representada por $\tilde{H}_5$, tem um erro limitado ao ruído introduzido por $\varepsilon_0 + \dots + \varepsilon_5$, que é consideravelmente menor que o erro produzido pelo algoritmo *Block-by-block*, segundo os experimentos realizados pela equipe do USCB. Entretanto, um ponto negativo deste algoritmo é o limite do número de consultas feitas à base de dados. A dificuldade presente no algoritmo *TopDown* se encontra em manter a consistência do número de cidadãos por geolocalização ao mesmo tempo em que se introduz ruído. A cada passo em que se é adicionado ruído a um histograma H_i , o número de pessoas na geolocalização i deve permanecer o mesmo que o número de pessoas na geolocalização $i + 1$, representada pelo histograma H_{i+1} . Por exemplo, se a população total do país é igual a n (histograma H_0), o número de pessoas no histograma H_1 (isto é, o a soma do número de cidadãos de todos os estados) também deve ser igual a n . A Figura F.3 apresenta o fluxo de dados do censo dos EUA ao se utilizar o algoritmo *TopDown*.

O problema de consistência da contagem de cidadãos por geolocalização é modelado como um problema de otimização linear, onde as restrições são criadas visando garantir o mesmo número de pessoas em todos os histogramas. A relação entre as restrições lineares e a adição de ruído nos dados é descrito como um *problema de decisão de restrições implícitas* (*implied constraints decision problem*), que é

NP-Completo de acordo com o Teorema 1 em [3]. Isto significa que é necessária uma capacidade de processamento computacional imensa para que o algoritmo seja executado em tempo razoável. Mais detalhes sobre as decisões tomadas pela equipe do censo para contornar este problema se encontram disponíveis na Seção 5 em [3].

Em ambos os algoritmos a equipe do censo utilizou o Mecanismo Geométrico como o mecanismo aleatório do esquema das Figuras F.2 e F.3.


F.3 Análise experimental da nova abordagem

Alguns testes foram feitos com os censos dos EUA de 1940 e o *End-To-End* de 2018 pela equipe do USCB designada para desenvolver o Sistema de Prevenção de Divulgação, a fim de comparar o comportamento dos dois algoritmos propostos [55].

A Figura F.4 apresenta um sumário de alguns resultados obtidos. A perda de privacidade e a acurácia com relação aos dados originais foram os critérios adotados para comparar os algoritmos. Mais precisamente, a acurácia é calculada utilizando a Variação Total da Distância (*Total Variation Distance* - *TVD*) entre os dados originais e a base de dados final que possui ruído (mais detalhes disponíveis em [5]). A perda de privacidade está relacionada ao valor de ε do mecanismo que respeita a privacidade diferencial. Quanto maior o valor de ε , maior é a perda de privacidade.

Analisando as curvas FPP de ambos os algoritmos na Figura F.4, podemos ver de forma direta que o algoritmo *TopDown* é superior ao *Block-by-block*. Devido à grande quantidade de ruído introduzido pelo algoritmo *Block-by-block*, a acurácia das estatísticas permaneceu baixa em todas as geolocalizações (distritos, estados, e outros). Por outro lado, o algoritmo *TopDown* manteve a acurácia para cidade, estado e país acima dos 99% para qualquer nível de perda de privacidade.

O algoritmo *TopDown* foi escolhido pelo Escritório do Censo dos EUA como a melhor solução a ser aplicada no censo de 2020. O desafio seguinte que a equipe lidou foi a escolha do ε . Como a curva FPP da Figura F.4 apresenta uma troca entre perda de privacidade e acurácia, o USCB teve que tomar uma decisão sobre qual seria o melhor balanceamento entre acurácia e perda de privacidade. Abowd e Schumtte [7] propuseram utilizar teoria econômica como um princípio básico para decidir a melhor escolha para esta troca. Outros desafios relatados pela equipe na implementação da privacidade diferencial ao Censo dos EUA são detalhados na Seção 6.4.3.1.

(a) Algoritmo *TopDown*

(b) Algoritmo Block-by-block

Figura F.4: Curva da Fronteira de Possibilidade de Produção (FPP) com relação à acurácia e perda de privacidade por geolocalização para o algoritmo *TopDown* aplicado ao Censo dos EUA de 1940. Em 1940 o censo era feito utilizando-se distritos ao invés de quarteirões como uma unidade de geolocalização. Imagem retirada de [55].

G O desafio de mitigação de ataques longitudinais

Como vimos no corpo deste documento, a privacidade diferencial apresenta propriedades de composicionalidade contra ataques longitudinais. Isto significa que é possível aplicar técnicas baseadas em privacidade diferencial de forma independente a cada base dos Censos Educacionais do Inep e, ainda assim, contar com um certo nível de proteção global contra ataques longitudinais.

Entretanto, mesmo as garantias de privacidade diferencial podem se degradar de forma inaceitável à medida em que o número de bases no conjunto longitudinal se torna muito grande. De fato, é conhecido na literatura que, mesmo com os trabalhos mais recentes na área, ainda não é possível alcançar uma solução definitiva para o problema de ataques longitudinais. Mesmo a solução do Censo Decenal dos EUA em 2020 (Seção 6.4.3) não prevê nenhuma garantia explícita contra este tipo de ataque (uma vez que o Censo também é publicado periodicamente).

Neste anexo apresentamos uma das poucas (e limitadas) técnicas de mitigação que se preocupam explicitamente com ataques longitudinais.

Começamos por notar que a privacidade diferencial possui duas definições quando aplicada a mecanismos aleatórios que lidam com múltiplas bases de dados sequenciais:

- **Privacidade a nível de evento** protege um evento específico, que esteja em qualquer uma das bases.
- **Privacidade a nível de indivíduo** protege todos os eventos de qualquer indivíduo que esteja presente em qualquer uma das bases.

Dos três métodos citados em [69] que buscam equilibrar o nível de privacidade e utilidade para múltiplas bases de dados, somente um se aplica ao contexto do Inep, o método denominado *w-event privacy*, no original em inglês.

A ideia do método *w-event privacy* é atingir a privacidade a nível de indivíduo para sequências infinitas de bases de dados, como por exemplo, censos sobre a população. A definição é de que o mecanismo satisfaça privacidade diferencial- ϵ para uma janela de

w bases, e quando w tende ao infinito, a privacidade a nível de indivíduo é atingida. Kellaris, Georgios, et al. [69] propõem uma abordagem de amostragem, onde são feitos cálculos do ruído adicionado na última amostra feita, e são calculadas distâncias para a base de dados mais atual. De acordo com essas distâncias, é definida a quantidade de ruído que deve ser adicionada na base mais atual.

Sobre a distribuição do ruído ao longo das bases, os autores propuseram dois mecanismos, a *distribuição de orçamento* (*BD - Budget Distribution*) e a *absorção de orçamento* (*BA - Budget Absorption*), onde “orçamento” deve ser entendido como a quantidade de recursos disponíveis (divulgação de dados úteis) para quando um valor de ε é fixado. O primeiro atribui uma distribuição exponencial do orçamento para a sequência de bases, onde as primeiras bases obtêm exponencialmente mais orçamento do que as últimas. Já o método BA distribui uniformemente o orçamento para todas as bases existentes no momento, e utiliza uma regra de “acumulação” do ruído no momento de decidir a quantidade de ruído introduzida na base mais atual.

A principal desvantagem destes mecanismos é que, quando são feitas muitas amostragens nas primeiras bases, o orçamento pode ser gasto prematuramente, o que dificulta a divulgação de novas bases. E quando não são feitas amostragens suficientes, pode ter “sobrado” orçamento, isto é, introduziu-se mais ruído do que o necessário nas bases, o que levou a divulgação delas com uma utilidade abaixo do que era alcançável.

Podemos observar que, mesmo com os trabalhos mais recentes na área, não é possível alcançar uma solução definitiva para o problema, o que indica que é um problema bastante difícil e que ainda necessita de estudos futuros.

H Exemplos da aplicação de vários métodos de mitigação a uma mesma base de exemplo

Neste anexo aplicamos variados métodos de mitigação de degradação à privacidade, descritos neste documento, a uma mesma base de tamanho reduzido, especialmente criada como exemplo. Nosso objetivo aqui não é a exploração minuciosa dos resultados obtidos por cada método, mas apenas ajudar o leitor a visualizar qual seria o aspecto da divulgação produzida por cada um, assim como as decisões que precisam ser tomadas em sua aplicação.

Importante: O objetivo dos exemplos apresentados neste anexo é tão somente ilustrar de forma didática o formato de cada divulgação proporcionado por cada método apresentado neste documento. Acreditamos que estes exemplos podem ajudar o leitor a compreender cada etapa utilizada e as decisões tomadas na aplicação das variadas técnicas. Os resultados aqui apresentados não devem ser tomados, de forma alguma, como uma análise quantitativa significativa da capacidade de cada método de atingir um bom compromisso entre privacidade e utilidade. A base utilizada nos exemplos é reduzida demais (contendo apenas 20 registros) para ter qualquer representatividade estatística sobre o que ocorreria se os métodos fossem aplicados em bases maiores e mais realistas. Além disso, os métodos baseados em privacidade diferencial reconhecidamente se comportam melhor em bases de tamanho considerável, e a utilidade por eles provida fica seriamente comprometida em bases tão pequenas como aquela aqui utilizada.

Em todos os exemplos consideramos a base de dados fictícia ilustrada na Tabela [H.1](#), contendo informação sobre crianças e jovens adultos, todos estudantes em uma certa população de interesse. Esta base contém 20 registros sobre os seguintes atributos:

- *id*, consistindo na identificação única de um indivíduo, formada por um número inteiro positivo;

<i>id</i>	<i>sexo</i>	<i>idade</i>	<i>deficiência</i>
1	F	10	cognitiva
2	F	10	cognitiva
3	F	12	física
4	M	13	física
5	M	15	nenhuma
6	M	15	física
7	F	17	física
8	F	18	física
9	M	18	física
10	F	20	física
11	M	24	física
12	M	24	nenhuma
13	F	25	física
14	F	25	nenhuma
15	M	25	nenhuma
16	M	26	nenhuma
17	F	27	nenhuma
18	F	29	nenhuma
19	M	29	nenhuma
20	M	29	nenhuma

Tabela H.1: Exemplos 39 a 45: Base de dados original à qual diversos métodos de mitigação de degradação de privacidade serão aplicados. Para os métodos que precisam desta especificação, os atributos considerados quaseidentificadores são *sexo* e *idade*, enquanto o atributo considerado sensível é *deficiência*.

- *sexo*, indicando se um indivíduo é do sexo feminino (F) ou masculino (M);
- *idade*, consistindo na idade de um indivíduo, em anos completos, assumindo um valor no conjunto $\{10, 11, \dots, 29\}$;
- *deficiência*, indicando se um indivíduo é portador de uma dentre duas deficiências mutuamente exclusivas (*cognitiva* ou *física*), ou se não é portador de nenhuma delas (*nenhuma*).


Adicionalmente, para os métodos que necessitam desta especificação, assumimos que os atributos *sexo* e *idade* são potenciais quaseidentificadores (i.e., cujos valores podem ser conhecidos por um adversário), enquanto o atributo *deficiência* é considerado sensível.

H.1 Exemplos de aplicação de métodos não perturbativos para divulgação de microdados


Aqui exemplificamos a aplicação dos métodos não perturbativos para divulgação de microdados, apresentados na Seção 4, à base da Tabela H.1.

Exemplo 39 (Aplicação de anonimidade- k , diversidade- ℓ e proximidade- t para divulgação não perturbativa de microdados). Neste exemplo consideramos os métodos não perturbativos para divulgação de microdados descritos na Seção 4: anonimidade- k , diversidade- ℓ e proximidade- t . Empregamos a implementação destes métodos disponibilizada pela ferramenta ARX¹ (que usa o algoritmo descrito na Seção 4.1.4) para sanitizar a base da Tabela H.1.

Tais métodos aplicam operações de generalização e supressão de atributos da base para atingir suas garantias. Para isto, todos eles precisam que o curador forneça árvores de generalização que indiquem como os valores dos atributos devem ser agrupados. Neste exemplo empregamos as árvores apresentadas na Figura H.2.



(a) Árvore de generalização do atributo *sexo*.



(b) Árvore de generalização do atributo *idade*.

Figura H.2: Exemplo 39: Árvores para generalização e supressão dos atributos quase-identificadores *sexo* e *idade* na Tabela H.1. As folhas (nós no nível 0) contêm os valores originais dos atributos, e os nós em níveis mais altos contêm valores cada vez mais generalizados. O mais alto nível da árvore, que contém o nó raiz com o símbolo “*”, representa a supressão completa do valor do atributo.

Os resultados obtidos foram os seguintes.

¹<https://arx.deidentifier.org>

- **Anonimidade- k** Aplicamos a implementação de anonimidade- k provida pela ferramenta ARX à base da Tabela H.1 com duas configurações de parâmetros: uma com $k = 2$ e outra com $k = 5$. Os resultados encontram-se na Tabela H.3.

Note que em cada caso a ferramenta retornou duas soluções distintas que satisfazem a restrição da anonimidade- k através de diferentes combinações de generalização e supressão dos quaseidentificadores *sexo* e *idade*. Em todos os casos é possível ver que o problema de reidentificação nesta base específica é solucionado, a troca da diminuição do nível de detalhamento dos atributos *sexo* e *idade*. Entretanto, apesar de valor de $k = 5$ prover mais privacidade que o valor de $k = 2$ (no primeiro caso cada registro é indistinguível de pelo menos outros 4, enquanto no segundo caso cada registro é indistinguível de pelo menos apenas 1 outro), isto acontece às custas de maior degradação da utilidade dos dados. A escolha de qual base sanitizada em cada caso fica a critério do curador, que julgará qual a importância relativa do nível de detalhamento dos atributos *sexo* e *idade*.

Note, entretanto, que a anonimidade- k não provê garantias contra ataques de inferência de atributo nos casos em que alguma utilidade ainda é preservada (isto é, nas bases 2-anônimas das Tabelas H.3a e H.3b, já que nas bases 5-anônimas as Tabelas H.3c e H.3d a supressão e generalização de atributos é drástica). Por exemplo:

- Se o indivíduo alvo for uma mulher de 10 de idade, é possível inferir tanto a partir da base 2-anônima da Tabela H.3a quanto da base 2-anônima da Tabela H.3b que, com absoluta certeza, ela possui alguma deficiência (cognitiva ou física).
- Na base 2-anônima da Tabela H.3b, é possível inferir que se o alvo tiver entre 18 e 21 anos então ele tem deficiência física, e que se ele tiver entre 26 e 29 anos, ele não possui deficiência.

- **Diversidade- ℓ** Aplicamos a implementação de diversidade- ℓ provida pela ferramenta ARX à base da Tabela H.1 com duas configurações de parâmetros: uma com $\ell = 2$ e outra com $\ell = 3$. Os resultados encontram-se na Tabela H.4.

Note que, ao contrário do que acontece com as bases k -anônimas, não é mais possível para o adversário inferir com absoluta certeza o atributo sensível de nenhum indivíduo alvo.

Entretanto, na base 3-diversa da Tabela H.4b todos os quaseidentificadores tiveram que ser suprimidos para atingir a garantia de privacidade, eliminando grande parte da utilidade da divulgação. Basicamente isto ocorre porque há um valor raro para a deficiência (*cognitiva*), e nesses casos as generalizações tendem a ser fortes.

Por outro lado, a base 2-diversa da Tabela H.4a ainda preserva alguma utilidade. Porém, ainda é possível haver violações de privacidade quanto ao atributo sensível. Por exemplo, se o indivíduo alvo for uma mulher na faixa de 10 a 17 anos, é possível inferir que ela possui alguma deficiência (cognitiva ou física).

- **Proximidade- t** Aplicamos a implementação de proximidade- t provida pela ferramenta ARX à base da Tabela H.1 com duas configurações de parâmetros: uma com $t = 0.1$ e outra com $t = 0.5$, significando que a distância EMD entre a distribuição sobre os valores do atributo sensível *deficiência* em cada bloco de registros em relação à distribuição dos mesmos valores na base como um todo deve estar limitada a 10% ou 50% do máximo possível, respectivamente. Quanto menor o valor de t , mais próxima a distribuição em cada bloco deve ser da original, e mais privada é a divulgação. Os resultados encontram-se na Tabela H.5.

Note que na base 0.1-próxima da Tabela H.5a é demandado que a distribuição do atributo sensível em cada bloco seja muito próxima da sua distribuição na base como um todo. Isso só é atingível ao se suprimirem todos os valores de quase-identificadores, comprometendo seriamente a utilidade da divulgação. Este tipo de problema tende a ocorrer quando a base contém atributos com valores raros, como aqui é o caso do valor *cognitiva* para o atributo *deficiência*.

Já a base 0.5-próxima da Tabela H.5b permite que a distribuição em cada bloco seja mais variada, o que aumenta a utilidade da divulgação (uma vez que nenhum atributo é mais suprimido por completo). Entretanto, nessa base ainda é possível inferir que um alvo do sexo feminino entre 10 e 17 com certeza tem alguma deficiência.

Este exemplo demonstra que, mesmo em tabelas com poucos atributos, as técnicas sintáticas não perturbativas de anonimidade- k , diversidade- ℓ e proximidade- t podem não ser eficientes em proteger atributos sensíveis de indivíduos, mesmo a um alto custo em utilidade. Por esta razão, tais métodos não são considerados mais satisfatórios por grande parte da comunidade acadêmica [46, 36].

◁

<i>id</i>	<i>sexo</i>	<i>idade</i>	<i>deficiência</i>
1	F	10-17	cognitiva
2	F	10-17	cognitiva
3	F	10-17	física
7	F	10-17	física
4	M	10-17	física
5	M	10-17	nenhuma
6	M	10-17	física
8	F	18-29	física
10	F	18-29	física
13	F	18-29	física
14	F	18-29	nenhuma
17	F	18-29	nenhuma
18	F	18-29	nenhuma
9	M	18-29	física
11	M	18-29	física
12	M	18-29	nenhuma
15	M	18-29	nenhuma
16	M	18-29	nenhuma
19	M	18-29	nenhuma
20	M	18-29	nenhuma

(a) Base 2-anônima obtida com a generalização do atributo *idade* até o nível 3.

<i>id</i>	<i>sexo</i>	<i>idade</i>	<i>deficiência</i>
1	*	10-13	cognitiva
2	*	10-13	cognitiva
3	*	10-13	física
4	*	10-13	física
5	*	14-17	nenhuma
6	*	14-17	física
7	*	14-17	física
8	*	18-21	física
9	*	18-21	física
10	*	18-21	física
11	*	22-25	física
12	*	22-25	nenhuma
13	*	22-25	física
14	*	22-25	nenhuma
15	*	22-25	nenhuma
16	*	26-29	nenhuma
17	*	26-29	nenhuma
18	*	26-29	nenhuma
19	*	26-29	nenhuma
20	*	26-29	nenhuma

(b) Base 2-anônima obtida com a supressão do atributo *sexo* e generalização do atributo *idade* até o nível 2.

<i>id</i>	<i>sexo</i>	<i>idade</i>	<i>deficiência</i>
1	F	*	cognitiva
2	F	*	cognitiva
3	F	*	física
7	F	*	física
8	F	*	física
10	F	*	física
13	F	*	física
14	F	*	nenhuma
17	F	*	nenhuma
18	F	*	nenhuma
4	M	*	física
5	M	*	nenhuma
6	M	*	física
9	M	*	física
11	M	*	física
12	M	*	nenhuma
15	M	*	nenhuma
16	M	*	nenhuma
19	M	*	nenhuma
20	M	*	nenhuma

(c) Base 5-anônima obtida com a supressão do atributo *idade*.

<i>id</i>	<i>sexo</i>	<i>idade</i>	<i>deficiência</i>
1	*	10-17	cognitiva
2	*	10-17	cognitiva
3	*	10-17	física
4	*	10-17	física
5	*	10-17	nenhuma
6	*	10-17	física
7	*	10-17	física
8	*	18-29	física
9	*	18-29	física
10	*	18-29	física
11	*	18-29	física
12	*	18-29	nenhuma
13	*	18-29	física
14	*	18-29	nenhuma
15	*	18-29	nenhuma
16	*	18-29	nenhuma
17	*	18-29	nenhuma
18	*	18-29	nenhuma
19	*	18-29	nenhuma
20	*	18-29	nenhuma

(d) Base 5-anônima obtida com a supressão do atributo *sexo* e generalização do atributo *idade* até o nível 3.

Tabela H.3: Exemplo 39: Resultados retornados pela ferramenta ARX após aplicação de anonimidade- k com $k = 2$ e $k = 5$ à base da Tabela H.1. Existem 2 soluções que satisfazem a restrição da anonimidade- k em cada caso, com diferentes combinações de supressão e generalização para os quaseidentificadores *sexo* e *idade*.

<i>id</i>	<i>sexo</i>	<i>idade</i>	<i>deficiência</i>
1	F	10-17	cognitiva
2	F	10-17	cognitiva
3	F	10-17	física
7	F	10-17	física
4	M	10-17	física
5	M	10-17	nenhuma
6	M	10-17	física
8	F	18-29	física
10	F	18-29	física
13	F	18-29	física
14	F	18-29	nenhuma
17	F	18-29	nenhuma
18	F	18-29	nenhuma
9	M	18-29	física
11	M	18-29	física
12	M	18-29	nenhuma
15	M	18-29	nenhuma
16	M	18-29	nenhuma
19	M	18-29	nenhuma
20	M	18-29	nenhuma

(a) Base 2-diversa obtida com a generalização do atributo *idade* até o nível 3.

<i>id</i>	<i>sexo</i>	<i>idade</i>	<i>deficiência</i>
1	*	*	cognitiva
2	*	*	cognitiva
3	*	*	física
4	*	*	física
5	*	*	nenhuma
6	*	*	física
7	*	*	física
8	*	*	física
9	*	*	física
10	*	*	física
11	*	*	física
12	*	*	nenhuma
13	*	*	física
14	*	*	nenhuma
15	*	*	nenhuma
16	*	*	nenhuma
17	*	*	nenhuma
18	*	*	nenhuma
19	*	*	nenhuma
20	*	*	nenhuma

(b) Base 3-diversa obtida com a supressão dos atributos *sexo* e *idade*.

Tabela H.4: Exemplo 39: Resultados retornados pela ferramenta ARX após aplicação de diversidade- ℓ com $\ell = 2$ e $\ell = 3$ à base da Tabela H.1.

<i>id</i>	<i>sexo</i>	<i>idade</i>	<i>deficiência</i>
1	*	*	cognitiva
2	*	*	cognitiva
3	*	*	física
4	*	*	física
5	*	*	nenhuma
6	*	*	física
7	*	*	física
8	*	*	física
9	*	*	física
10	*	*	física
11	*	*	física
12	*	*	nenhuma
13	*	*	física
14	*	*	nenhuma
15	*	*	nenhuma
16	*	*	nenhuma
17	*	*	nenhuma
18	*	*	nenhuma
19	*	*	nenhuma
20	*	*	nenhuma

(a) Base 0.1-próxima obtida com a supressão dos atributo *sexo* e *idade*.

<i>id</i>	<i>sexo</i>	<i>idade</i>	<i>deficiência</i>
1	F	10-17	cognitiva
2	F	10-17	cognitiva
3	F	10-17	física
7	F	10-17	física
4	M	10-17	física
5	M	10-17	nenhuma
6	M	10-17	física
8	F	18-29	física
10	F	18-29	física
13	F	18-29	física
14	F	18-29	nenhuma
17	F	18-29	nenhuma
18	F	18-29	nenhuma
9	M	18-29	física
11	M	18-29	física
12	M	18-29	nenhuma
15	M	18-29	nenhuma
16	M	18-29	nenhuma
19	M	18-29	nenhuma
20	M	18-29	nenhuma

(b) Base 0.5-próxima obtida com a generalização do atributo *idade* até o nível 3.

Tabela H.5: Exemplo 39: Resultados retornados pela ferramenta ARX após aplicação de proximidade- t com $t = 0.1$ e $t = 0.5$ à base da Tabela H.1.

Exemplo 40 (Divulgação não perturbativa de microdados por amostragem). Neste exemplo aplicamos o método não perturbativo de amostragem de um subconjunto de microdados para divulgação, conforme descrito na Seção 4.2. Definimos o tamanho da amostra como sendo 25% do total de registros, e efetuamos duas amostragens sobre a base da Tabela H.1. Os resultados são apresentados na Tabela H.6.

Note que a amostragem tende a proteger melhor os indivíduos do que a divulgação de toda a base de microdados, mas ela não elimina riscos individuais. Por exemplo, um adversário que saiba que seu alvo é a única mulher de 20 anos de idade na população de interesse pode inferir com certeza através da primeira amostragem, representada na Tabela H.6a, que este indivíduo tem deficiência física.

A segunda amostragem, apresentada na Tabela H.6b, não selecionou a partir da base original da Tabela H.1 nenhum indivíduo que naquela base tivesse combinações únicas para seus quaseidentificadores. Entretanto, riscos individuais ainda estão presentes: se o adversário sabe que só há 2 pessoas na população que sejam do sexo feminino e tenham 10 anos de idade, então ele infere que essas pessoas necessariamente têm deficiência cognitiva. Além disso, a exigência de que apenas registros com quaseidentificadores não únicos na base original sejam incluídos na base amostral deixa de atender a critérios puramente randômicos, o que pode ocultar correlações entre atributos e suprimir valores raros, diminuindo a utilidade da divulgação.

<i>id</i>	<i>sexo</i>	<i>idade</i>	<i>deficiência</i>
1	F	10	cognitiva
5	M	15	nenhuma
9	M	18	física
10	F	20	física
20	M	29	nenhuma

(a) Primeira amostragem aleatória.

<i>id</i>	<i>sexo</i>	<i>idade</i>	<i>deficiência</i>
1	F	10	cognitiva
2	F	10	cognitiva
5	M	15	nenhuma
13	F	25	física
14	F	25	nenhuma

(b) Segunda amostragem aleatória.

Tabela H.6: Exemplo 40: Resultados de diferentes amostragens de 25% da base de dados representada na Tabela H.1.

H.2 Exemplos de aplicação de métodos não perturbativos para divulgação de dados agregados ou tabulares

Aqui exemplificamos a aplicação dos métodos não perturbativos para divulgação de dados agregados ou tabulares, apresentados na Seção 5, à base da Tabela H.1.

Exemplo 41 (Divulgação não perturbativa de sumários estatísticos). Neste exemplo aplicamos à base da Tabela H.1 o método de divulgação não perturbativa de sumários estatísticos coberto na Seção 5.1. Os resultados encontram-se na Tabela H.7. Note que todos os valores divulgados correspondem exatamente aos valores reais de cada estatística, e nenhum ruído foi adicionado. Apesar de aqui haver, intuitivamente, um ganho de privacidade em relação à divulgação de microdados, a utilidade dos dados fica comprometida para análises finas que dependam, e.g., da correlação entre atributos arbitrários. Por exemplo, a divulgação omite as correlações entre *deficiência* e *sexo*.

Estatística	Valor
Idade média de estudantes homens	21.8
Idade média de estudantes mulheres	19.3
Deficiência mais comum entre estudantes	física

(a) Algumas estatísticas agregadas.

idade	Frequência
10	10%
12	5%
13	5%
15	10%
17	5%
18	10%
20	5%
24	10%
25	15%
26	5%
27	5%
29	15%

(b) Distribuição de idades.

Tabela H.7: Exemplo 41: Divulgação não perturbativa de sumários estatísticos para a base da Tabela H.1. Note que todos os valores divulgados correspondem exatamente aos valores reais de cada estatística, e nenhum ruído foi adicionado.

Exemplo 42 (Divulgação não perturbativa de histogramas). Neste exemplo aplicamos à base da Tabela H.1 o método de divulgação não perturbativa de histogramas coberto na Seção 5.2. Histogramas podem ser divulgados em diferentes níveis de correlações entre os atributos: desde histogramas marginais individuais de cada atributo até a divulgação completa da base de dados. A Tabela H.8 apresenta a divulgação tanto de histogramas marginais quanto de histogramas conjuntos de atributos dois a dois. Note que todos os valores divulgados correspondem exatamente aos valores reais, e nenhum ruído foi adicionado.

A divulgação não perturbativa de histogramas apresenta maior privacidade, de forma geral, que a divulgação de microdados, ao custo de diminuir a granularidade da informação prestada. Entretanto, ela permite infrações individuais de privacidade. Um adversário que tenha como alvo um indivíduo do sexo masculino pode inferir, a partir do histograma conjunto de *sexo* e *deficiência* da Tabela H.8b, que o alvo não tem deficiência cognitiva. Já se o alvo for um indivíduo de 10 anos de idade, é possível inferir, a partir do histograma conjunto de *deficiência* e *idade*, que ele tem deficiência cognitiva.

◁

<i>sexo</i>	Mult.	<i>idade</i>	Mult.	<i>idade</i>	Mult.	<i>deficiência</i>	Mult.
F	10	10	2	20	1	cognitiva	2
M	10	12	1	24	2	física	9
		13	1	25	3	nenhuma	9
		15	2	26	1		
		17	1	27	1		
		18	2	29	3		

(a) Divulgação de histogramas marginais individuais.

<i>sexo</i>	<i>idade</i>	Mult.	<i>sexo</i>	<i>idade</i>	Mult.
F	10	2	M	13	1
	12	1		15	2
	17	1		18	1
	18	1		24	2
	20	1		25	1
	25	2		26	1
	27	1		29	2
	29	1		-	-

<i>sexo</i>	<i>deficiência</i>	Mult.	<i>sexo</i>	<i>deficiência</i>	Mult.
F	cognitiva	2	M	cognitiva	0
	física	5		física	4
	nenhuma	3		nenhuma	6

<i>deficiência</i>	<i>idade</i>	Mult.	<i>deficiência</i>	<i>idade</i>	Mult.	<i>deficiência</i>	<i>idade</i>	Mult.
cognitiva	10	2	física	12	1	nenhuma	15	1
	-	-		13	1		24	1
	-	-		15	1		25	2
	-	-		17	1		26	1
	-	-		18	2		27	1
	-	-		20	1		29	3
	-	-		24	1		-	-
	-	-		25	1		-	-

(b) Divulgação de histogramas de atributos conjuntos 2 a 2.

Tabela H.8: Exemplo 42: Divulgação não perturbativa de histogramas para a base da Tabela H.1. Note que todos os valores divulgados correspondem exatamente aos valores reais, e nenhum ruído foi adicionado. Para economia de espaço, combinações de valores de atributos com multiplicidade 0 foram omitidas das tabelas.

H.3 Exemplos de aplicação de métodos baseados em privacidade diferencial

Aqui exemplificamos a aplicação dos métodos baseados em privacidade diferencial, apresentados na Seção 6, à base da Tabela H.1.

É extremamente relevante ressaltar aqui os seguintes pontos:

- O objetivo destes exemplos não é prover uma análise quantitativa acurada do comportamento da privacidade diferencial em bases reais. A base utilizada nesta seção é extremamente pequena, tendo apenas 20 registros e, portanto, qualquer pequena variação na aleatoriedade utilizada pelos mecanismos pode ter um grande efeito na divulgação final.
Em particular, na privacidade diferencial local normalmente é preciso que o número de registros em uma base seja muito grande para que haja alguma utilidade visível na divulgação. Dado o tamanho da base aqui usada, esses efeitos não são visíveis.
- Nestes exemplos não aplicamos uma análise minuciosa para escolha dos parâmetros dos mecanismos utilizados –em especial, o parâmetro ε que controla o nível de privacidade desejado. Utilizamos valores comumente utilizados na literatura, variando do relativamente pequeno ($\varepsilon = \ln 1.5$) ao relativamente grande ($\varepsilon = \ln 50$). Quanto menor o valor de ε , mais privado é o mecanismo, porém geralmente a um custo maior na utilidade da divulgação. Novamente, dado que a base de dados utilizada como exemplo é pequena, nem sempre essa tendência pode ser observada nos experimentos aqui realizados.
- Por fim, utilizamos nestes exemplos implementações simples da privacidade diferencial, até pela limitação de tempo natural dos prazos do presente produto.

Em todos os exemplos foram utilizados os mecanismos de privacidade diferencial disponibilizadas pela biblioteca `diffprivlib`, desenvolvida pela IBM [63]. Esta ferramenta é *open source* e está disponível no GitHub.²

Exemplo 43 (Divulgação de sumários estatísticos usando privacidade diferencial global). No Exemplo 41 apresentamos a divulgação não perturbativa de quatro sumários estatísticos sobre a base da Tabela H.1. No presente exemplo aplicamos a privacidade diferencial global aos resultados obtidos naquele exemplo. Mais precisamente, sobre os resultados reais de cada estatística, providos na Tabela H.7, foi adicionado ruído utilizando diferentes mecanismos e configurações conforme abaixo:

- Para os dois sumários referentes à idade média dos indivíduos foi utilizado o mecanismo de Laplace truncado, restringindo o valor retornado para o intervalo $[10, 29]$

²<https://github.com/IBM/differential-privacy-library/>

e com sensibilidade $\ell_1 = 19$ (uma vez que, como idades variam de 10 a 29 anos, o impacto máximo que a adição, remoção ou alteração de um registro pode ter sobre o atributo *idade* é 19).

- Para o sumário que contém a distribuição das idades foi utilizado o mecanismo geométrico truncado, restringindo o valor retornado para o intervalo $[0, 20]$ (pois 20 é o número de indivíduos na base), e com sensibilidade $\ell_1 = 1$ (uma vez que a adição ou remoção de um único indivíduo na base pode alterar a contagem de indivíduos com uma mesma idade em no máximo 1 unidade).
- Para o sumário referente à deficiência mais comum da base de dados foi utilizado o mecanismo exponencial, em que a distância d entre os valores foi definida como:
 - $d(\text{cognitiva}, \text{cognitiva}) = d(\text{física}, \text{física}) = d(\text{nenhuma}, \text{nenhuma}) = 0$, indicando que se considera que não há perda de utilidade quando a deficiência correta é reportada;
 - $d(\text{cognitiva}, \text{física}) = d(\text{física}, \text{cognitiva}) = 1$, indicando que se a deficiência real for física, mas reportada for cognitiva (ou vice-versa), ocorre uma perda de 1 unidade de utilidade;
 - $d(\text{cognitiva}, \text{nenhuma}) = d(\text{nenhuma}, \text{cognitiva}) = d(\text{física}, \text{nenhuma}) = d(\text{nenhuma}, \text{física}) = 3$, indicando que quando não há deficiência real, mas uma é reportada (ou vice-versa), ocorre uma perda de 3 unidades de utilidade.

Consideramos os seguintes valores para o parâmetro ε que controla a privacidade desejada: $\ln 1.5$, $\ln 3$, $\ln 10$ e $\ln 50$. Recorde que quanto menor o valor de ε , mais privado é o mecanismo, porém, em geral, menos ele preserva a utilidade da divulgação. Os resultados encontram-se na Tabela [H.9](#).

◁

Estatística	Valor real (sem ruído)	Valor divulgado ($\varepsilon = \ln 1.5$)	Valor divulgado ($\varepsilon = \ln 3$)	Valor divulgado ($\varepsilon = \ln 10$)	Valor divulgado ($\varepsilon = \ln 50$)
Idade média de estudantes homens	21.8	26.14	22.05	22.13	20.29
Idade média de estudantes mulheres	19.3	24.3	20.64	20.97	17.95
Deficiência mais comum entre estudantes	física	nenhuma	física	física	nenhuma

(a) Algumas estatísticas agregadas com privacidade diferencial global para diferentes valores de ε .

<i>idade</i>	Frequência real (sem ruído)	Freq. divulgada ($\varepsilon = \ln 1.5$)	Freq. divulgada ($\varepsilon = \ln 3$)	Freq. divulgada ($\varepsilon = \ln 10$)	Freq. divulgada ($\varepsilon = \ln 50$)
10	10%	0.00%	8.33%	10.53%	23.08%
11	0%	5.33%	0.00%	0.00%	11.54%
12	5%	2.67%	4.17%	0.00%	7.69%
13	5%	5.33%	0.00%	0.00%	0.00%
14	0%	0.00%	0.00%	0.00%	0.00%
15	10%	6.67%	8.33%	10.53%	0.00%
16	0%	4.00%	0.00%	0.00%	0.00%
17	5%	0.00%	4.17%	10.53%	3.85%
18	10%	6.67%	8.33%	10.53%	0.00%
19	0%	0.00%	0.00%	0.00%	0.00%
20	5%	8.00%	16.67%	5.26%	15.38%
21	0%	13.33%	0.00%	0.00%	3.85%
22	0%	10.67%	8.33%	0.00%	0.00%
23	0%	0.00%	0.00%	0.00%	0.00%
24	10%	8.00%	4.16%	10.53%	0.00%
25	15%	5.33%	8.33%	15.79%	15.38%
26	5%	8.00%	12.50%	5.26%	7.69%
27	5%	9.33%	4.17%	5.26%	3.85%
28	0%	0.00%	0.00%	0.00%	0.00%
29	15%	6.67%	12.50%	15.79%	7.69%

(b) Distribuição de idades com privacidade diferencial global para diferentes valores de ε .

Tabela H.9: Exemplo 43: Divulgação de sumários estatísticos usando privacidade diferencial global, referentes à base da Tabela H.1. Vários valores para o parâmetro ε foram usados, e quanto menor seu valor, mais privada é a divulgação. A divulgação real, sem perturbação, dos sumários estatísticos encontra-se na Tabela H.7.

Exemplo 44 (Divulgação de histogramas usando privacidade diferencial global). No Exemplo 42 apresentamos a divulgação de possíveis histogramas sobre os dados da base representada na Tabela H.1. Neste exemplo aplicamos a privacidade diferencial em sua variante global com diferentes níveis de privacidade para os mesmos histogramas. A seguir apresentamos os resultados.

Por se tratar de histogramas, o mecanismo utilizado foi o geométrico truncado, restringindo o valor retornado para o intervalo $[0, 20]$ (pois 20 é o número de indivíduos na base) e com sensibilidade $\ell_1 = 1$ (uma vez que, pelos motivos explicitados na Seção 6.2.3.2, a adição ou remoção de um único indivíduo na base pode alterar a contagem de qualquer grupo do histograma em no máximo 1 unidade).

Consideramos os seguintes valores para o parâmetro ε que controla a privacidade desejada: $\ln 1.5$, $\ln 3$, $\ln 10$ e $\ln 50$.

A Tabela H.10 apresenta os histogramas marginais para os atributos *sexo*, *idade* e *deficiência*, enquanto as Tabelas H.11, H.12 e H.13 apresentam os histogramas conjuntos destes atributos 2 a 2.

◁

<i>sexo</i>	Mult. real (sem ruído)	Mult. divulgada ($\varepsilon = \ln 1.5$)	Mult. divulgada ($\varepsilon = \ln 3$)	Mult. divulgada ($\varepsilon = \ln 10$)	Mult. divulgada ($\varepsilon = \ln 50$)
F	10	11	15	10	10
M	10	19	10	10	10

<i>idade</i>	Mult. real (sem ruído)	Mult. divulgada ($\varepsilon = \ln 1.5$)	Mult. divulgada ($\varepsilon = \ln 3$)	Mult. divulgada ($\varepsilon = \ln 10$)	Mult. divulgada ($\varepsilon = \ln 50$)
10	2	0	3	2	2
11	0	4	0	0	0
12	1	2	2	1	1
13	1	4	0	1	2
14	0	0	0	0	0
15	2	5	2	2	2
16	0	3	2	0	0
17	1	0	1	1	1
18	2	5	6	2	2
19	0	0	0	0	0
20	1	6	2	1	1
21	0	10	0	0	0
22	0	8	0	0	0
23	0	0	0	0	0
24	2	6	2	2	2
25	3	4	2	3	3
26	1	6	1	1	1
27	1	7	1	1	1
28	0	0	1	0	0
29	3	5	3	2	3

<i>deficiência</i>	Mult. real (sem ruído)	Mult. divulgada ($\varepsilon = \ln 1.5$)	Mult. divulgada ($\varepsilon = \ln 3$)	Mult. divulgada ($\varepsilon = \ln 10$)	Mult. divulgada ($\varepsilon = \ln 50$)
cognitiva	2	3	2	2	2
física	9	9	9	9	9
nenhuma	9	7	6	9	9

Tabela H.10: Exemplo 44: Divulgação de histogramas marginais usando privacidade diferencial global, referentes à base da Tabela H.1. Vários valores para o parâmetro ε foram usados, e quanto menor seu valor, mais privada é a divulgação. A divulgação real, sem perturbação, dos sumários estatísticos encontra-se na Tabela H.8.

<i>sexo</i>	<i>idade</i>	Mult. real (sem ruído)	Mult. divulgada ($\varepsilon = \ln 1.5$)	Mult. divulgada ($\varepsilon = \ln 3$)	Mult. divulgada ($\varepsilon = \ln 10$)	Mult. divulgada ($\varepsilon = \ln 50$)
F	10	2	3	0	2	2
	11	0	3	0	0	0
	12	1	2	0	1	1
	13	0	0	0	0	0
	14	0	5	0	0	0
	15	0	0	0	0	0
	16	0	0	0	0	0
	17	1	0	1	1	1
	18	1	0	1	1	1
	19	0	0	0	0	0
	20	1	1	1	1	0
	21	0	2	1	0	0
	22	0	0	0	0	0
	23	0	0	1	0	0
	24	0	4	0	0	0
	25	2	3	0	2	2
	26	0	0	0	0	0
	27	1	0	1	1	1
	28	0	0	0	0	0
	29	1	1	1	1	1
M	10	0	0	0	0	0
	11	0	0	0	0	0
	12	0	1	2	0	0
	13	1	0	1	0	1
	14	0	3	0	0	0
	15	2	3	1	2	2
	16	0	0	0	2	0
	17	0	0	1	0	0
	18	1	0	1	1	2
	19	0	0	0	0	0
	20	0	2	0	0	0
	21	0	0	0	0	0
	22	0	0	0	0	0
	23	0	0	0	0	0
	24	2	3	3	1	2
	25	1	0	2	1	1
	26	1	1	3	1	1
	27	0	2	0	0	0
	28	0	1	0	1	0
	29	2	8	2	3	2

Tabela H.11: Exemplo 44: Divulgação de histograma conjunto dos atributos *sexo* e *idade* usando privacidade diferencial global, referentes à base da Tabela H.1. Vários valores para o parâmetro ε foram usados, e quanto menor seu valor, mais privada é a divulgação. A divulgação real, sem perturbação, dos sumários estatísticos encontra-se na Tabela H.8.

<i>sexo</i>	<i>deficiência</i>	Mult. real (sem ruído)	Mult. divulgada ($\varepsilon = \ln 1.5$)	Mult. divulgada ($\varepsilon = \ln 3$)	Mult. divulgada ($\varepsilon = \ln 10$)	Mult. divulgada ($\varepsilon = \ln 50$)
F	cognitiva	2	4	1	2	2
	física	5	8	5	5	5
	nenhuma	3	3	3	3	3
M	cognitiva	0	0	2	0	0
	física	4	5	4	4	4
	nenhuma	6	9	6	6	6

Tabela H.12: Exemplo 44: Divulgação de histograma conjunto dos atributos *sexo* e *deficiência* usando privacidade diferencial global, referentes à base da Tabela H.1. Vários valores para o parâmetro ε foram usados, e quanto menor seu valor, mais privada é a divulgação. A divulgação real, sem perturbação, dos sumários estatísticos encontra-se na Tabela H.8.

<i>deficiência</i>	<i>idade</i>	Mult. real (sem ruído)	Mult. div. ($\varepsilon = \ln 1.5$)	Mult. div. ($\varepsilon = \ln 3$)	Mult. div. ($\varepsilon = \ln 10$)	Mult. div. ($\varepsilon = \ln 50$)
cognitiva	10	2	4	3	2	2
	11	0	1	0	0	0
	12	0	0	0	0	0
	13	0	0	2	0	0
	14	0	1	0	0	0
	15	0	1	0	0	0
	16	0	0	0	0	0
	17	0	0	0	0	0
	18	0	0	0	0	0
	19	0	4	0	0	0
	20	0	0	0	0	1
	21	0	2	0	0	0
	22	0	0	0	0	0
	23	0	0	0	0	0
	24	0	0	0	0	0
	25	0	0	0	1	0
	26	0	0	1	0	0
	27	0	0	0	3	0
	28	0	0	0	0	0
	29	0	0	0	0	0
física	10	0	0	0	0	0
	11	0	0	0	0	0
	12	1	0	1	0	1
	13	1	0	1	1	1
	14	0	0	0	1	0
	15	1	1	0	1	1
	16	0	0	0	0	0
	17	1	3	1	1	1
	18	2	0	2	2	2
	19	0	4	1	0	0
	20	1	0	1	0	1
	21	0	1	0	0	0
	22	0	4	1	0	0
	23	0	0	0	2	0
	24	1	0	1	1	1
	25	1	0	0	1	1
	26	0	0	1	0	0
	27	0	0	0	0	0
	28	0	0	0	0	0
	29	0	1	0	0	0
nenhuma	10	0	0	0	1	0
	11	0	0	0	0	0
	12	0	0	3	0	0
	13	0	9	0	0	0
	14	0	0	1	0	0
	15	1	3	2	2	1
	16	0	4	0	0	0
	17	0	0	0	0	0
	18	0	3	3	0	0
	19	0	0	0	0	0
	20	0	1	0	0	0
	21	0	0	1	0	0
	22	0	0	0	0	0
	23	0	1	0	0	0
	24	1	5	1	0	1
	25	2	2	2	2	2
	26	1	0	2	1	1
	27	1	5	1	1	1
	28	0	0	0	0	0
	29	3	5	3	3	4

Tabela H.13: Exemplo 44: Divulgação de histograma conjunto dos atributos *deficiência* e *idade* usando privacidade diferencial global, referentes à base da Tabela H.1. Vários valores para o parâmetro ε foram usados, e quanto menor seu valor, mais privada é a divulgação. A divulgação real, sem perturbação, dos sumários estatísticos encontra-se na Tabela H.8.

Exemplo 45 (Divulgação de microdados usando privacidade diferencial local). No presente exemplo aplicamos a privacidade diferencial local à base representada na Tabela H.1. Conforme apresentado na Seção 6.3, ao se aplicar a privacidade diferencial local em uma base de dados, adicionamos ruído individualmente a cada registro. Por fim é gerada ao final uma base totalmente sanitizada que pode ser divulgada.

Neste exemplo utilizamos uma abordagem simples para aplicação de ruído, de forma independente a cada atributo de cada registro, da seguinte forma:

- Para o atributo *sexo* utilizamos o mecanismo exponencial, onde a função de distância entre pessoas do mesmo sexo foi definida como 0 e a distância entre pessoas de sexo oposto como 1.
- Para o atributo *deficiência* utilizamos o mecanismo exponencial, onde a distância d entre os valores foi definida da mesma forma como a usada no Exemplo 43.
- Para o atributo *idade* utilizamos o mecanismo geométrico truncado, restringindo o valor retornado para o intervalo $[0, 20]$ (pois 20 é o número de indivíduos na base) e com a sensibilidade $\ell_1 = 19$ (uma vez que, como idades variam de 10 a 29 anos, o impacto máximo que a adição, remoção ou alteração de um registro pode ter sobre o atributo *idade* é 19).

Formas mais sofisticadas de adição de ruído, que preservam mais a utilidade dos dados, existem. Entretanto, devido à complexidade de sua aplicação elas fogem ao escopo do presente produto.

Consideramos como valores para o parâmetro ε que controla a privacidade desejada: $\ln 1.5$, $\ln 3$, $\ln 10$ e $\ln 50$. As bases sanitizadas resultantes encontram-se na Tabela H.14.

A fim de ilustrar o impacto tanto do uso da privacidade diferencial local quanto da escolha do parâmetro ε , computamos sobre as quatro bases sanitizadas da Tabela H.14 os mesmos sumários estatísticos e histogramas computados nos seguintes exemplos:

- Exemplos 41 e 42, em que a divulgação é feita de forma não perturbativa.
- Exemplos 43 e 44, em que ruído é adicionado usando privacidade diferencial global.

O resultado da computação de sumários estatísticos sobre as bases sanitizadas encontra-se na Tabela H.15. Já a Tabela H.16 apresenta os histogramas marginais computados para os atributos *sexo*, *idade* e *deficiência*, enquanto as Tabelas H.17, H.18 e H.19 apresentam os histogramas computados sobre conjuntos destes atributos 2 a 2. Em particular, estes resultados ilustram que, no geral, a privacidade diferencial local tende a apresentar menor utilidade que sua versão global.

Entretanto, como mencionado neste documento, há variantes da privacidade diferencial local (descritas no Anexo D), que podem ser consideradas para procurar um melhor compromisso entre privacidade e utilidade.

◁

<i>id</i>	<i>sexo</i>	<i>idade</i>	<i>deficiência</i>
1	M	10	nenhuma
2	F	29	cognitiva
3	F	29	física
4	M	13	cognitiva
5	M	10	cognitiva
6	M	29	cognitiva
7	F	29	cognitiva
8	M	29	nenhuma
9	M	26	cognitiva
10	F	29	física
11	M	10	nenhuma
12	F	10	cognitiva
13	F	10	física
14	F	10	cognitiva
15	M	29	nenhuma
16	F	22	nenhuma
17	F	29	cognitiva
18	M	10	física
19	M	10	física
20	M	29	nenhuma

(a) Parâmetro $\varepsilon = \ln 1.5$.

<i>id</i>	<i>sexo</i>	<i>idade</i>	<i>deficiência</i>
1	F	29	física
2	M	10	cognitiva
3	F	23	nenhuma
4	M	10	física
5	M	10	física
6	M	10	cognitiva
7	F	15	cognitiva
8	M	10	nenhuma
9	M	10	física
10	M	15	nenhuma
11	M	10	nenhuma
12	M	10	cognitiva
13	M	17	cognitiva
14	F	17	física
15	F	10	física
16	M	19	nenhuma
17	M	25	nenhuma
18	F	16	nenhuma
19	M	29	física
20	F	10	nenhuma

(b) Parâmetro $\varepsilon = \ln 3$.

<i>id</i>	<i>sexo</i>	<i>idade</i>	<i>deficiência</i>
1	F	10	cognitiva
2	F	29	cognitiva
3	F	13	física
4	M	24	nenhuma
5	M	10	nenhuma
6	M	14	cognitiva
7	F	10	nenhuma
8	F	22	física
9	M	10	nenhuma
10	F	20	física
11	M	25	cognitiva
12	M	29	nenhuma
13	F	25	cognitiva
14	F	21	nenhuma
15	M	28	nenhuma
16	M	10	nenhuma
17	F	10	nenhuma
18	F	13	nenhuma
19	M	23	nenhuma
20	M	10	nenhuma

(c) Parâmetro $\varepsilon = \ln 10$.

<i>id</i>	<i>sexo</i>	<i>idade</i>	<i>deficiência</i>
1	F	10	cognitiva
2	F	10	cognitiva
3	F	17	física
4	M	16	cognitiva
5	M	11	nenhuma
6	M	28	cognitiva
7	F	12	física
8	F	18	física
9	M	18	cognitiva
10	F	21	cognitiva
11	M	19	nenhuma
12	M	14	nenhuma
13	F	27	física
14	F	28	nenhuma
15	M	19	nenhuma
16	M	10	nenhuma
17	F	27	nenhuma
18	F	23	nenhuma
19	M	29	nenhuma
20	M	22	nenhuma

(d) Parâmetro $\varepsilon = \ln 50$.

Tabela H.14: Exemplo 45: Bases sanitizadas resultantes da aplicação de privacidade diferencial local à base da Tabela H.1. Vários valores para o parâmetro ε foram usados, e quanto menor seu valor, mais privada é a divulgação.

Estatística	Valor real (sem ruído)	Valor computado ($\varepsilon = \ln 1.5$)	Valor computado ($\varepsilon = \ln 3$)	Valor computado ($\varepsilon = \ln 10$)	Valor computado ($\varepsilon = \ln 50$)
Idade média de estudantes homens	21.8	18.64	14.23	18.3	18.6
Idade média de estudantes mulheres	19.3	21.89	17.14	17.3	19.3
Deficiência mais comum entre estudantes	física	nenhuma	nenhuma	nenhuma	nenhuma

(a) Algumas estatísticas agregadas computadas sobre as bases sanitizadas com privacidade diferencial local para diferentes valores de ε .

<i>idade</i>	Frequência real (sem ruído)	Freq. computada ($\varepsilon = \ln 1.5$)	Freq. computada ($\varepsilon = \ln 3$)	Freq. computada ($\varepsilon = \ln 10$)	Freq. computada ($\varepsilon = \ln 50$)
10	10%	40%	50%	35%	10%
11	0%	0%	0%	0%	5%
12	5%	0%	0%	0%	5%
13	5%	5%	0%	10%	0%
14	0%	0%	0%	5%	5%
15	10%	0%	10%	0%	0%
16	0%	0%	5%	0%	5%
17	5%	0%	10%	0%	5%
18	10%	0%	0%	0%	10%
19	0%	0%	5%	0%	10%
20	5%	0%	0%	5%	0%
21	0%	0%	0%	5%	5%
22	0%	5%	0%	5%	5%
23	0%	0%	5%	5%	5%
24	10%	0%	0%	5%	0%
25	15%	0%	5%	10%	0%
26	5%	5%	0%	0%	0%
27	5%	0%	0%	0%	10%
28	0%	0%	0%	5%	10%
29	15%	45%	10%	10%	5%

(b) Distribuição de idades computadas sobre as bases sanitizadas com privacidade diferencial local para diferentes valores de ε .

Tabela H.15: Exemplo 45: Computação de sumários estatísticos sobre as bases sanitizadas usando privacidade diferencial local, referentes à base da Tabela H.1. Vários valores para o parâmetro ε foram usados, e quanto menor seu valor, mais privada é a divulgação. A divulgação real, sem perturbação, dos sumários estatísticos encontra-se na Tabela H.7.

<i>sexo</i>	Mult. real (sem ruído)	Mult. divulgada ($\varepsilon = \ln 1.5$)	Mult. divulgada ($\varepsilon = \ln 3$)	Mult. divulgada ($\varepsilon = \ln 10$)	Mult. divulgada ($\varepsilon = \ln 50$)
F	10	9	7	10	10
M	10	11	13	10	10

<i>idade</i>	Mult. real (sem ruído)	Mult. divulgada ($\varepsilon = \ln 1.5$)	Mult. divulgada ($\varepsilon = \ln 3$)	Mult. divulgada ($\varepsilon = \ln 10$)	Mult. divulgada ($\varepsilon = \ln 50$)
10	2	8	10	7	3
11	0	0	0	0	1
12	1	0	0	0	1
13	1	1	0	2	0
14	0	0	0	1	1
15	2	0	2	0	0
16	0	0	1	0	1
17	1	0	2	0	1
18	2	0	0	0	2
19	0	0	1	0	2
20	1	0	0	1	0
21	0	0	0	1	1
22	0	1	0	1	1
23	0	0	1	1	1
24	2	0	0	1	0
25	3	0	1	2	0
26	1	1	0	0	0
27	1	0	0	0	2
28	0	0	0	1	2
29	3	9	2	2	1

<i>deficiência</i>	Mult. real (sem ruído)	Mult. divulgada ($\varepsilon = \ln 1.5$)	Mult. divulgada ($\varepsilon = \ln 3$)	Mult. divulgada ($\varepsilon = \ln 10$)	Mult. divulgada ($\varepsilon = \ln 50$)
cognitiva	2	9	5	5	6
física	9	5	7	3	4
nenhuma	9	6	8	12	10

Tabela H.16: Exemplo 45: Computação de histogramas marginais sobre as bases sanitizadas usando privacidade diferencial local, referentes à base da Tabela H.1. Vários valores para o parâmetro ε foram usados, e quanto menor seu valor, mais privada é a divulgação. A divulgação real, sem perturbação, dos sumários estatísticos encontra-se na Tabela H.8.

<i>sexo</i>	<i>idade</i>	Mult. real (sem ruído)	Mult. divulgada ($\varepsilon = \ln 1.5$)	Mult. divulgada ($\varepsilon = \ln 3$)	Mult. divulgada ($\varepsilon = \ln 10$)	Mult. divulgada ($\varepsilon = \ln 50$)
F	10	2	3	2	3	2
	11	0	0	0	0	0
	12	1	0	0	0	1
	13	0	0	0	2	0
	14	0	0	0	0	0
	15	0	0	1	0	0
	16	0	0	1	0	0
	17	1	0	1	0	1
	18	1	0	0	0	1
	19	0	0	0	0	0
	20	1	0	0	1	0
	21	0	0	0	1	1
	22	0	1	0	1	0
	23	0	0	1	0	1
	24	0	0	0	0	0
	25	2	0	0	1	0
	26	0	0	0	0	0
	27	1	0	0	0	2
	28	0	0	0	0	1
	29	1	5	1	1	0
M	10	0	5	8	4	1
	11	0	0	0	0	1
	12	0	0	0	0	0
	13	1	1	0	0	0
	14	0	0	0	1	1
	15	2	0	1	0	0
	16	0	0	0	0	1
	17	0	0	1	0	0
	18	1	0	0	0	1
	19	0	0	1	0	2
	20	0	0	0	0	0
	21	0	0	0	0	0
	22	0	0	0	0	1
	23	0	0	0	1	0
	24	2	0	0	1	0
	25	1	0	1	1	0
	26	1	1	0	0	0
	27	0	0	0	0	0
	28	0	0	0	1	1
	29	2	4	1	1	1

Tabela H.17: Exemplo 45: Computação do histograma conjunto dos atributos *sexo* e *idade* sobre as bases sanitizadas usando privacidade diferencial local, referentes à base da Tabela H.1. Vários valores para o parâmetro ε foram usados, e quanto menor seu valor, mais privada é a divulgação. A divulgação real, sem perturbação, dos sumários estatísticos encontra-se na Tabela H.8.

<i>sexo</i>	<i>deficiência</i>	Mult. real (sem ruído)	Mult. divulgada ($\varepsilon = \ln 1.5$)	Mult. divulgada ($\varepsilon = \ln 3$)	Mult. divulgada ($\varepsilon = \ln 10$)	Mult. divulgada ($\varepsilon = \ln 50$)
F	cognitiva	2	5	1	3	3
	física	5	3	3	3	4
	nenhuma	3	1	3	4	3
M	cognitiva	0	4	4	2	3
	física	4	2	4	0	0
	nenhuma	6	5	5	8	7

Tabela H.18: Exemplo 45: Computação do histograma conjunto dos atributos *sexo* e *deficiência* sobre as bases sanitizadas usando privacidade diferencial local, referentes à base da Tabela H.1. Vários valores para o parâmetro ε foram usados, e quanto menor seu valor, mais privada é a divulgação. A divulgação real, sem perturbação, dos sumários estatísticos encontra-se na Tabela H.8.

<i>deficiência</i>	<i>idade</i>	Mult. real (sem ruído)	Mult. div. ($\varepsilon = \ln 1.5$)	Mult. div. ($\varepsilon = \ln 3$)	Mult. div. ($\varepsilon = \ln 10$)	Mult. div. ($\varepsilon = \ln 50$)
cognitiva	10	2	3	3	1	2
	11	0	0	0	0	0
	12	0	0	0	0	0
	13	0	1	0	0	0
	14	0	0	0	1	0
	15	0	0	1	0	0
	16	0	0	0	0	1
	17	0	0	1	0	0
	18	0	0	0	0	1
	19	0	0	0	0	0
	20	0	0	0	0	0
	21	0	0	0	0	1
	22	0	0	0	0	0
	23	0	0	0	0	0
	24	0	0	0	0	0
	25	0	0	0	2	0
	26	0	1	0	0	0
	27	0	0	0	0	0
	28	0	0	0	0	1
	29	0	4	0	1	0
física	10	0	3	4	0	0
	11	0	0	0	0	0
	12	1	0	0	0	1
	13	1	0	0	1	0
	14	0	0	0	0	0
	15	1	0	0	0	0
	16	0	0	0	0	0
	17	1	0	1	0	1
	18	2	0	0	0	1
	19	0	0	0	0	0
	20	1	0	0	1	0
	21	0	0	0	0	0
	22	0	0	0	1	0
	23	0	0	0	0	0
	24	1	0	0	0	0
	25	1	0	0	0	0
	26	0	0	0	0	0
	27	0	0	0	0	1
	28	0	0	0	0	0
	29	0	2	2	0	0
nenhuma	10	0	2	3	6	1
	11	0	0	0	0	1
	12	0	0	0	0	0
	13	0	0	0	1	0
	14	0	0	0	0	1
	15	1	0	1	0	0
	16	0	0	1	0	0
	17	0	0	0	0	0
	18	0	0	0	0	0
	19	0	0	1	0	1
	20	0	0	0	0	0
	21	0	0	0	1	0
	22	0	1	0	0	1
	23	0	0	1	1	1
	24	1	0	0	1	0
	25	2	0	1	0	0
	26	1	0	0	0	0
	27	1	0	0	0	1
	28	0	0	0	1	1
	29	3	3	0	1	1

Tabela H.19: Exemplo 45: Computação do histograma conjunto dos atributos *deficiência* e *idade* sobre as bases sanitizadas usando privacidade diferencial local, referentes à base da Tabela H.1. Vários valores para o parâmetro ε foram usados, e quanto menor seu valor, mais privada é a divulgação. A divulgação real, sem perturbação, dos sumários estatísticos encontra-se na Tabela H.8.

Lista de Siglas

DCC Departamento de Ciência da Computação da UFMG.

DEED Diretoria de Estatísticas Educacionais do Inep.

ENEM Exame Nacional do Ensino Médio.

GDPR *General Data Protection Regulation*.

INEP Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira.

LAI Lei de Acesso à Informação.

LGPD Lei Geral de Proteção de Dados Pessoais.

LGPD Lei Geral de Proteção de Dados Pessoais.

MEC Ministério da Educação.

RGPD Regulamento Geral de Proteção de Dados.

TED Termo de Execução Descentralizada.

UFMG Universidade Federal de Minas Gerais.

Glossário

adversário Entidade contra quem se deseja proteger a informação sensível sobre indivíduos. O adversário pode ser uma pessoa física ou uma organização. Não necessariamente se atribuem intenções deletérias ao adversário: é possível que um consumidor legítimo de uma divulgação estatística (e.g., um pesquisador acadêmico) atue inadvertidamente como adversário ao inferir informação sensível de indivíduos no decurso de ações idôneas.

analista de dados Pessoa ou entidade considerada como usuária legítima de uma divulgação de dados.

analista racional Analista que, sabendo que o mecanismo de divulgação adapta sua resposta adicionando ruído para garantir privacidade, utiliza o resultado da consulta em conjunto com seus conhecimentos e convicções prévias para inferir a partir da resposta ruidosa qual é a resposta que minimize sua perda de acordo com uma função de utilidade/perda subjetiva.

anonimidade- k (*k-anonymity*) Método sintático de tratamento que garante que os dados de cada indivíduo pertencente a uma divulgação de dados não possam ser distinguidos dos dados de pelo menos outros $k-1$ indivíduos também pertencentes à mesma divulgação.

anonimização Utilização de meios técnicos razoáveis e disponíveis no momento do tratamento, por meio dos quais um dado perde a possibilidade de associação, direta ou indireta, a um indivíduo. Técnicas de anonimização incluem, mas não se limitam a, *desidentificação*, *k-anonymity*, *l-diversity* e *privacidade diferencial*, dentre outras. Diferentes técnicas têm diferentes graus de sucesso, e algumas são comprovadamente menos eficazes que outras.

ataque Ação ou conjunto de ações pelas quais o adversário pode obter informação sensível sobre titulares de dados. Ao termo “ataque” não se atribui uma intenção necessariamente deletéria: uma utilização legítima dos dados (e.g., para pesquisa científica) pode resultar inadvertidamente em um ataque se porventura revelar informação sensível.

ataque composicional Ataque que se utiliza do cruzamento de informações divulgadas por mais de uma fonte, ou por divulgações diferentes de uma mesma fonte (e.g., cruzamento de dados de um censo médico com registros públicos de eleitores).

ataque de inferência de atributo Ataque em que o objetivo do adversário é inferir o valor assumido por um atributo considerado como sensível para um conjunto de indivíduos, independentemente de se estes indivíduos tenham sido reidentificados com sucesso ou não.

ataque de reconstrução da base de dados Método para reconstruir parcialmente um conjunto de dados privado a partir de informações agregadas públicas.

ataque de reidentificação Ataque em que o objetivo do adversário é determinar uma correspondência entre registros presentes na base de dados e os titulares desses registros, i.e., os indivíduos do mundo real a quem os registros se refere.

ataque longitudinal Ataque que se utiliza de informações divulgadas ao longo do tempo (e.g., várias liberações de informação referentes a uma mesma pesquisa, ou pesquisas em anos consecutivos que se referem aos mesmos titulares).

atributo não sensível Atributo cujo valor não é considerado digno de proteção em si mesmo em um dado contexto.

banco de dados O mesmo que *base de dados*.

base de dados Conjunto estruturado de dados pessoais, estabelecido em um ou em vários locais, em suporte eletrônico ou físico.

Censo da Educação Básica Principal pesquisa estatística educacional do país, abrangendo a Educação Básica e Profissional.

Censo da Educação Superior Mais completa pesquisa estatística sobre as Instituições de Educação Superior do país.

composicionalidade Propriedade de um método de tratamento de poder ser aplicado independentemente a divulgações distintas e ainda preservar garantias de privacidade globais.

conhecimento a posteriori do adversário Conhecimento a respeito da informação sensível que o adversário adquire ao revisar seu conhecimento a priori de acordo com o resultado da execução de um ataque.

conhecimento a priori do adversário Conhecimento a respeito da informação sensível que o adversário possui antes mesmo de executar um ataque.

consulta Uma recuperação de dados ou informações a partir de uma base de dados, normalmente efetuada em linguagem específica.

controle de divulgação estatística Área que estuda como compartilhar publicamente informações sobre um conjunto de dados, revelando padrões estatísticos a respeito dos mesmos ao mesmo tempo em que se protegem informações sensíveis sobre os indivíduos no conjunto de dados. O controle de divulgação estatística deve balancear a manutenção da utilidade dos dados (com relação a um analista legítimo) com garantias de privacidade para os titulares dos dados (contra um adversário).

curador de dados Pessoa ou entidade responsável pela integração de dados coletados de várias fontes, além da organização, publicação e apresentação dos dados de forma que o valor dos dados seja mantido ao longo do tempo e os dados permaneçam disponíveis para reutilização e preservação. A curadoria de dados inclui todos os processos necessários para a criação, manutenção e gerenciamento de dados controlados e com princípios, juntamente com a capacidade de agregar valor aos dados.

dado agregado Dado sumarizado correspondendo a uma agregação das informações dos microdados para unidades mais amplas, ou mesmo a uma função computada sobre essas informações (e.g., frequência, média ou outros tipos de análises).

dado anonimizado Dado relativo a titular que não possa ser identificado, considerando a utilização de meios técnicos razoáveis e disponíveis na ocasião de seu tratamento.

dado pessoal Informação relacionada a pessoa natural identificada ou identificável.

dado pessoal sensível Dado pessoal sobre o qual a preocupação quanto à privacidade (e.g., sobre origem racial ou étnica, convicção religiosa, opinião política, filiação a sindicato ou a organização de caráter religioso, filosófico ou político, dado referente à saúde ou à vida sexual, dado genético ou biométrico), quando vinculado a uma pessoa natural.

dados sintéticos Dados especialmente criados para substituir dados reais em divulgações de microdados ou para geração de dados tabulares. São gerados de forma a preservar algumas propriedades estatísticas dos dados originais, tais como distribuições marginais, médias e quartis.

degradação de privacidade Comparação entre o *sucesso a posteriori* do adversário –i.e., depois de executar o ataque– e o *sucesso a priori* do adversário –i.e., antes de executar o ataque– em seu intuito de inferir informação sensível. Intuitivamente, quanto maior a degradação de privacidade de um ataque, maior o incremento no sucesso esperado do adversário em obter informação sensível.

desanonimização O mesmo que *reidentificação*.

desidentificação Técnica de tratamento de dados pela qual são removidos possíveis identificadores individuais óbvios dos registros (e.g., nome, CPF, RG, ou endereços em níveis mais detalhados que as cidades), na expectativa de dificultar-se uma eventual reidentificação do titular.

differential privacy O mesmo que *privacidade diferencial*.

diversidade- ℓ (*ℓ -diversity*) Método sintático de tratamento que aperfeiçoa a técnica de anonimidade- k ao garantir um nível mínimo de diversidade nos atributos sensíveis de cada conjunto de indivíduos agrupados.

Exame Nacional de Desempenho dos Estudantes (ENADE) Avaliação do rendimento dos concluintes dos Cursos de Graduação tanto em relação aos conteúdos programáticos previstos nas diretrizes curriculares dos cursos, quanto no que diz respeito às habilidades desenvolvidas e à atualização do aluno em relação ao Brasil e ao mundo.

Exame Nacional do Ensino Médio (ENEM) Avaliação do desempenho escolar ao final da Educação Básica.

General Data Protection Regulation (GDPR) Regulamento do direito europeu de 2018 que trata da privacidade e proteção de dados pessoais, aplicável a todos os indivíduos na União Europeia e do Espaço Econômico Europeu.

histograma Forma de divulgação de informação sobre uma base de dados contendo apenas projeções marginais da distribuição de registros por valores.

identificador direto Atributo que pode unicamente identificar um indivíduo, como nome, RG, CPF, ou número de telefone celular.

inferência de atributo Prática de combinar dados anonimizados com informações publicamente disponíveis ou dados auxiliares, a fim de descobrir o valor de algum atributo sensível de um indivíduo.

informação auxiliar Em relação a uma divulgação de dados de interesse, informação auxiliar é qualquer informação que se possa obter a respeito de um indivíduo através de outros canais que não sejam a divulgação de dados de interesse em si mesma (e.g, via *web*, outros registros públicos, jornais ou revistas, conhecimento prévio).

informação lateral O mesmo que *informação auxiliar*.

informação sensível Informação considerada como digna de proteção. Exemplos típicos incluem a situação médica, a renda, ou vida pessoal de um indivíduo.

Inscrypt *Laboratory of Information Security, Cryptography, Privacy, and Transparency*, laboratório de pesquisa do DCC/UFMG focado em segurança da informação, criptografia, privacidade e transparência.

Lei de Acesso à Informação (LAI) Lei brasileira 12.527/2011, que trata dos procedimentos a serem observados pelo Estado para garantir o acesso a informações previsto na Constituição Federal do Brasil de 1988.

Lei Geral de Proteção de Dados Pessoais (LGPD ou LGPDP) Lei brasileira 13.709/2018, que dispõe sobre o tratamento de dados pessoais, inclusive nos meios digitais, por pessoa natural ou por pessoa jurídica de direito público ou privado, com o objetivo de proteger os direitos fundamentais de liberdade e de privacidade e o livre desenvolvimento da personalidade da pessoa natural.

mecanismo ótimo Mecanismo que respeita as preferências e tolerâncias de um analista em específico com relação ao ruído adicionado.

mecanismo de Laplace Mecanismo que implementa a privacidade diferencial sobre um domínio de dados numérico contínuo, aplicando ruído de acordo com uma distribuição de probabilidade de Laplace.

mecanismo exponencial Mecanismo que implementa a privacidade diferencial sobre um domínio de dados categórico, aplicando ruído de acordo com uma distribuição de probabilidade proporcional a uma noção de distância sobre as categorias.

mecanismo geométrico Mecanismo que implementa a privacidade diferencial sobre um domínio de dados numérico discreto, aplicando ruído de acordo com uma distribuição de probabilidade geométrica.

mecanismo ótimo universal Mecanismo capaz de ser simultaneamente ótimo para todos os (ou uma grande maioria dos) potenciais analistas da base de dados.

método composicional Método de mitigação de degradação de privacidade que apresenta a propriedade de *composicionalidade*.

método global Método de tratamento que conta com um curador de dados responsável pela coleta de informações individuais e aplicação das técnicas de proteção. Nesse tipo de método assume-se que o curador é uma entidade digna de confiança para tratamento da informação sensível, e o tratamento é aplicado ao conjunto dos dados de forma holística.

método local Método de tratamento em que a proteção de privacidade é aplicada aos dados de cada titular individualmente.

método não perturbativo Método de tratamento que altera a informação provida apenas por diminuir sua granularidade ou por suprimi-la por partes, mas sem introduzir informação ruidosa.

método perturbativo Método de tratamento que pode introduzir informação inverídica de forma controlada na divulgação, seja por criação de dados falsos ou pela inserção de ruído nos dados.

método semântico Qualquer método de tratamento de dados que formule condições semânticas para a divulgação de informação, incorporando em si mesmo a formalização de privacidade almejada (e.g., privacidade diferencial).

método sintático Qualquer método de tratamento de dados que formule condições puramente sintáticas para a divulgação de informação (e.g., desidentificação, *k-anonymity* e *l-diversity*).

métrica de privacidade de caso médio Medida de privacidade que quantifica a esperança ou média do sucesso do adversário, levando em conta alguma distribuição de probabilidade sobre possíveis configurações do ataque.

métrica de privacidade de pior caso Medida de privacidade que quantifica o sucesso do adversário sobre a configuração de ataque mais vantajosa para ele possível, independentemente do quão improvável ela seja.

métrica determinística de sucesso do adversário Função que mensura o sucesso do adversário e forma absoluta, retornando um valor qualitativo dependendo de se a informação desejada foi ou não recuperada com absoluta certeza.

métrica de utilidade específica Métrica de utilidade que parte do princípio de que uma divulgação será utilizada para uma tarefa preestabelecida e então medem a qualidade da divulgação para esta tarefa.

métrica de utilidade geral Métrica de utilidade que tenta diminuir ao máximo a distorção entre os dados originais e os dados tratados, sob a premissa de se a distribuição de probabilidade sobre registros após o tratamento for similar à distribuição antes do tratamento, então os dados tratados serão úteis para a maioria dos analistas aplicações.

métrica probabilística de sucesso do adversário Função que mensura o sucesso do adversário de forma probabilística, retornando um valor quantitativo representando o grau de certeza com o qual a informação desejada foi recuperada.

microdado A menor fração de um dado e pode estar relacionado a uma pesquisa ou avaliação; o dado em sua menor forma de agregação. Microdados geralmente carregam informação sobre entidades em nível individual (e.g., pessoas, escolas, institutos).

mitigação, técnica ou método de O mesmo que *tratamento de dados*.

negação plausível (*plausible deniability*) Capacidade de um titular de dados negar de forma crível para um adversário alguma propriedade sobre sua informação sensível (e.g., negar sua participação em um estudo, ou que um de seus atributos tenha um valor específico), mesmo após um ataque.

privacidade-*d* (*d-privacy*) Variante da privacidade diferencial que explora a noção de indistinguibilidade entre segredos para aumentar a utilidade de divulgações.

privacidade diferencial Método semântico de tratamento de dados que garante formalmente que apenas uma quantidade negligível de informação sobre um dado indivíduo pode ser obtida a partir dos dados publicados, independentemente da participação ou não do indivíduo na pesquisa.

privacidade diferencial global Variante da privacidade diferencial em que o ruído é adicionado ao resultado de cada consulta realizada.

privacidade diferencial local Variante da privacidade diferencial em que o ruído é adicionado diretamente aos dados coletados.

proximidade- t (*t-closeness*) Método sintático de tratamento que aperfeiçoa a técnica de diversidade- ℓ ao garantir que aprender apenas os valores de uma coleção predefinida de quaseidentificadores não altera o conhecimento probabilístico do adversário a respeito dos atributos sensíveis de cada indivíduo.

pseudonimização Técnica de tratamento de dados pela qual atribui-se um código individual artificialmente criado a cada registro de uma base de dados, acompanhada da transferência de identificadores diretos (como nome, CPF e RG) para outra base de dados. Dessa forma, o controlador é capaz de mapear identificadores diretos em uma base de dados a registros específicos na outra base através do uso dos códigos individuais, ao mesmo tempo em que se dificultam tentativas de reidentificação do titular por parte de agentes externos.

quaseidentificador Informações que não são, em si mesmas, identificadores únicos, mas que estão suficientemente correlacionadas com uma entidade a ponto de poderem ser combinadas com outros quaseidentificadores para criar um identificador exclusivo.

query O mesmo que *consulta*.

registro Informação em uma base de dados correspondente a um indivíduo específico.

Regulamento Geral de Proteção de Dados (RGPD) O mesmo que *General Data Protection Regulation*.

reidentificação Prática de combinar dados anonimizados com informações publicamente disponíveis ou dados auxiliares, a fim de descobrir o indivíduo ao qual os dados pertencem.

sala segura Lugar físico seguro que possui servidores que contém os dados reais de pesquisas sociais e pesquisas estatísticas de alguma natureza (por exemplo, dados médicos ou dados de censos populacionais) e terminais que os usuários podem utilizar para acessar esses dados de forma controlada.

sensibilidade ℓ_1 Dada uma consulta, trata-se da maior influência que a adição, remoção ou alteração de um único registro em uma base de dados pode ocasionar na resposta retornada por esta consulta.

Sistema de Avaliação da Educação Básica (SAEB) Conjunto de testes e questionários aplicados na rede pública e em uma amostra da rede privada que auxilia no diagnóstico da Educação Básica e de possíveis fatores que interfiram no desempenho do estudante.

sucesso a posteriori do adversário Medida (determinística ou probabilística) do quanto de informação sensível o adversário possui após a execução do ataque, usando a informação a posteriori adquirida.

sucesso a priori do adversário Medida (determinística ou probabilística) do quanto de informação sensível o adversário já possui antes mesmo de executar um ataque, usando apenas seu conhecimento a priori.

sumário estatístico Forma de divulgação de informação sobre uma base de dados contendo apenas resposta a um conjunto de consultas estatísticas predeterminadas.

Teorema de Reconstrução da Base de Dados (*Dataset Reconstruction Theorem*) Resultado formal que mostra que, dado acesso a uma quantidade suficientemente grande de informações, alguém pode reconstruir bancos de dados subjacentes e, em teoria, reidentificar indivíduos.

titular Pessoa natural a quem se referem os dados pessoais que são objeto de tratamento.

tratamento (de dados) Toda operação realizada com dados pessoais, como as que se referem a coleta, produção, recepção, classificação, utilização, acesso, reprodução, transmissão, distribuição, processamento, arquivamento, armazenamento, eliminação, avaliação ou controle da informação, modificação, comunicação, transferência, difusão ou extração.

United States Census Bureau (USCB) Agência federal dos EUA responsável por divulgar dados sobre população e economia.

utilidade Propriedade de uma divulgação servir aos propósitos legítimos do analista de dados, provendo a ele a informação desejada.

TED 8750 - PRICE

PRIVACIDADE NOS CENSOS EDUCACIONAIS

Termo de Execução Descentralizada entre o Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira - Inep e a Universidade Federal de Minas Gerais - UFMG

PRODUTO 04

Solução tecnológica e sua documentação



Mário S. ALVIM
Ramon G. GONZE
Jeroen van de GRAAF

Igor W. LEMES
Lucas LOPES
Gabriel H. NUNES

Data de entrega

Resumo

O presente documento consiste na apresentação da *Solução tecnológica e sua documentação*, prevista como Produto 05 no plano de trabalho do Termo de Execução Descentralizada (TED) 8750. Este TED foi firmado entre o Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira (Inep) e a Universidade Federal de Minas Gerais (UFMG), e encontra-se em execução pelo Laboratório Inscript (*Laboratory of Information Security, Cryptography, Privacy, and Transparency*) do Departamento de Ciência da Computação (DCC) da Universidade.

Neste documento apresentamos a solução tecnológica para o tratamento da base de dados da pesquisa escolhida para o projeto piloto descrito no Produto 05. O presente documento inclui a documentação e componentes da solução tecnológica desenvolvida, bem como os requisitos e configurações necessárias para a aplicação a outras bases de dados no ambiente computacional do Inep. Além disso, instruímos o Inep a como ter acesso às bases sanitizadas criadas no projeto piloto.

Sumário

1	Introdução	1
1.1	Objetivo deste documento	1
1.2	Contextualização	2
1.3	Organização deste documento	3
2	Instruções para utilização da biblioteca do projeto piloto	4
2.1	Código fonte e documentação	4
2.2	Configuração do ambiente de execução	5
2.3	Instalação	5
2.4	Recursos de hardware	6
3	Instruções para acesso às bases sanitizadas no projeto piloto	8
3.1	Lista das bases sanitizadas	8
3.2	Como acessar as bases sanitizadas	9
	Referências Bibliográficas	12
	Anexos	13
A	Documentação da biblioteca utilizada no projeto piloto	14

Lista de Tabelas

2.4.1	Gasto de memória RAM e tempo de execução dos três módulos da biblioteca <code>price-library</code>	7
3.1.1	Arquivos referentes às bases de dados tratadas para os estudos sobre amostragem.	10
3.1.2	Arquivos referentes às bases de dados tratadas e sanitizadas para os estudos sobre privacidade diferencial local em todo o Brasil.	10
3.1.3	Arquivos referentes às bases de dados tratadas e sanitizadas para os estudos sobre privacidade diferencial local no Distrito Federal.	10
3.2.4	Credenciais para acesso ao servidor FTP do laboratório INSCRYPT.	11
3.2.5	Informações sobre o certificado para conexão segura FTPS ao servidor FTP.	11

1 Introdução

Este documento consiste no Produto 04, intitulado *Solução tecnológica e sua documentação*, do plano de trabalho do Termo de Execução Descentralizada (TED) 8750, firmado entre o Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira (Inep) e a Universidade Federal de Minas Gerais (UFMG), e em execução pelo Laboratório Inscrypt (*Laboratory of Information Security, Cryptography, Privacy, and Transparency*) do Departamento de Ciência da Computação (DCC) da Universidade.

1.1 Objetivo deste documento

De acordo com o plano de trabalho do TED 8750, o Produto 05 que este documento implementa consiste em um:

Documento técnico com a apresentação da solução tecnológica para o tratamento da base de dados da pesquisa escolhida para o projeto piloto, incluindo manual, documentação e componentes da solução tecnológica desenvolvida, bem como os requisitos e configurações necessárias para a aplicação a outras bases de dados no ambiente computacional no Inep.

Mais especificamente, em conjunto com o Produto 05, visa-se a atender ao Objetivo Específico 05 do plano de trabalho:

Desenvolver e implantar um processo computacional baseado em até dois métodos de controle de divulgação escolhidos pelo Inep dentre aqueles elencados pelo DCC/UFMG no item anterior, como forma de aprimorar sua atual política de disseminação de microdados educacionais. Este processo deverá respeitar o ambiente tecnológico de infraestrutura e de sistemas existente no Inep e considerar, dentre as bases de dados dos Censos Educacionais, a que melhor se adequa aos objetivos de complexidade necessários para a realização de uma aplicação piloto dos métodos escolhidos. O objetivo do teste de conceito é apresentar os resultados da aplicação prática, quando será possível observar os resultados e identificar a sua aderência às necessidades iniciais.

1.2 Contextualização

Para fins de proteção de privacidade, a atual forma de divulgação dos microdados dos Censos Educacionais pelo Inep utiliza apenas as técnicas de *desidentificação*, em que se removem possíveis identificadores individuais óbvios dos registros (como nome, CPF, RG) e de *pseudonimização*, em que tais identificadores individuais óbvios são substituídos por um código único de identificação artificialmente criado.

No Produto 02 deste TED 8750, provemos extensivas análises quantitativas experimentais que demonstraram de forma inequívoca que esta abordagem submete os titulares dos dados a sérios e generalizados riscos de violação de privacidade, em especial aos de reidentificação e de inferência de atributos sensíveis. Como já expressamos anteriormente, em nossa visão esta situação poderia constituir em uma violação da Lei Geral de Proteção de Dados Pessoais (LGPD) [1].

No Produto 03 do presente TED 8750 provemos um parecer técnico sobre a adequação de variadas técnicas de mitigação de danos à privacidade aos Censos Educacionais do Inep. Em particular, consideramos que a LGPD prevê garantias de privacidade individualmente a cada titular de dados –em especial, contra reidentificação– que devem ser atendidas pelos Censos Educacionais. Também consideramos que qualquer método adotado devesse manter a maior utilidade possível para os analistas e consumidores dos dados dos Censos.

À época observamos que o Inep dispunha de um prazo exíguo para implementação de uma solução coerente com a nova legislação. Sugerimos, então, a adoção de uma solução emergencial de curto prazo que garantisse a privacidade dos titulares –mesmo que fosse possivelmente sub-ótima em relação à utilidade provida aos analistas (ou vice-versa)–, enquanto elaborar-se-ia uma alternativa de longo prazo que fornecesse um melhor custo-benefício na relação entre privacidade e utilidade.

O plano emergencial proposto na ocasião consistia, essencialmente, em eliminar imediatamente a divulgação de microdados sob qualquer forma que não fosse via salas seguras (físicas ou virtuais) e oferecer apenas informações agregadas (sumários estatísticos ou histogramas) em canais públicos de comunicação, protegidos por privacidade diferencial. Uma vez assegurado o nível de privacidade individual dos dados demandado pela LGPD (obtido nos passos anteriores), proceder-se-ia a um estudo aprofundado de como aumentar a utilidade das divulgações enquanto manter-se-ia a privacidade conquistada. Tal aumento gradual da utilidade dos dados visaria a satisfazer a um número cada vez maior de analistas, o que poderia contribuir para arrefecer a demanda suplementar por acesso a salas seguras eventualmente causada pela implementação da solução emergencial.

Várias reuniões foram realizadas entre a equipe executora e o Inep para discutir o parecer provido no Produto 03. Após deliberação, o Inep optou por não considerar divulgação de dados agregados no presente momento, mantendo o escopo do presente TED 8750 centrado no estudo de técnicas de divulgação de microdados. Mais especificamente, o Inep escolheu como objeto de análise do presente projeto piloto as seguintes duas técnicas de sanitização de microdados:

- *sanitização por amostragem não-perturbativa*; e
- *sanitização por privacidade diferencial- ϵ local*.

Além disso, fixou-se como dados de estudo a base do Censo da Educação Básica de 2019. No Produto 05 apresentamos várias análises experimentais quantitativas sobre a privacidade e a utilidade de dados providas pelos dois métodos de sanitização selecionados pelo Inep para o projeto piloto: amostragem e privacidade diferencial local. As análises foram realizadas sobre os dados do Censo da Educação Básica de 2019. Em todas elas consideramos como informação auxiliar para o adversário atributos cujos valores sejam presumivelmente conhecidos, ou possam ser facilmente descobertos, em geral por serem informação pública ou considerada inofensiva (e.g., a idade de um aluno, seu sexo ou dados sobre sua entidade de ensino).

O presente documento é complementar ao Produto 05. Aqui apresentamos a documentação técnica da solução tecnológica empregada no projeto piloto, além de provermos ao Inep acesso às bases sanitizadas criadas para o mesmo.



Para uma melhor compreensão desse Produto (4) sugerimos a leitura prévia do Produto 5.

1.3 Organização deste documento

O restante deste documento está organizado da seguinte forma.

- **Instruções para utilização da biblioteca do projeto piloto** (Seção 2): Nesta seção provemos instruções para acesso ao código fonte e à documentação da biblioteca empregada nas análises do projeto piloto deste TED 8750. Provemos ainda uma descrição dos requisitos e configurações necessárias para emprego da biblioteca pelo Inep em seu ambiente computacional, assim como instruções para sua instalação.
- **Instruções para acesso às bases sanitizadas no projeto piloto** (Seção 3): Nesta seção instruímos o Inep a como ter acesso às bases sanitizadas criadas no projeto piloto.
- **Anexos**: Apresentamos aqui o seguinte material suplementar.
 - **Documentação da biblioteca utilizada no projeto piloto** (Anexo A)

2 Instruções para utilização da biblioteca do projeto piloto

Nesta seção provemos instruções para acesso ao código fonte e à documentação da biblioteca empregada nas análises do projeto piloto deste TED 8750. Provemos ainda uma descrição dos requisitos e configurações necessárias para emprego da biblioteca pelo Inep em seu ambiente computacional, assim como instruções para sua instalação.

A biblioteca foi implementada na linguagem Python e é composta dos seguintes módulos.

- Módulo de análise de degradação de privacidade em ataque de reidentificação coletiva em uma única base sanitizada por amostragem (RCU^{ams}).
- Módulo de análise de degradação de privacidade em ataque de reidentificação coletiva em uma única base sanitizada por privacidade diferencial local ($\widehat{RCU}^{ldp}$).
- Módulo de análise de utilidade estatística de uma divulgação de microdados.

Todos os requisitos descritos a seguir são *open source* e, portanto, não acarretam custos financeiros para instalação e uso.

2.1 Código fonte e documentação

O código fonte desta biblioteca está disponível no seguinte repositório do GitLab: ¹

<https://gitlab.com/ted8750/price-library>

A documentação está disponível em formato HTML no diretório `docs/html` do repositório acima. Além disso, o Anexo A deste documento apresenta esta documentação.

¹Conforme discutido previamente com o Inep, a biblioteca está privada, isto é, não disponível publicamente na Internet. O Inep deve informar à equipe executora quais contas do GitLab (e.g., pertencentes a membros da equipe do Inep) devem ter o acesso liberado ao repositório e a equipe executora providenciará este acesso.

2.2 Configuração do ambiente de execução

Para a utilização da biblioteca, é necessário um ambiente computacional com os seguintes requisitos:

- Python ² na versão 3.8 ou superior;
- Repositório de software Python Package Index (PyPi), ³ para instalação da biblioteca e dependências.

Abaixo seguem instruções para utilização em distribuições Linux e em macOS:

- **Linux:** Em distribuições Linux (como Ubuntu⁴ e Debian⁵) nas suas versões mais recentes, o interpretador Python já vem previamente instalado. Já o repositório de software PyPi, pode ser facilmente instalado a partir dos repositórios padrão da distribuição Unix com o comando “`sudo apt install python3-pip`”.
- **macOS:** O download do interpretador python para macOS pode ser feito através do site oficial. ⁶ Também é possível utilizar uma IDE, como o PYCharm. ⁷

Uma outra alternativa é instalar ambientes virtuais que já possuem tanto o Python quanto o PyPi, como o Anaconda ⁸ (disponível tanto para macOS quanto para Linux).

2.3 Instalação

Após a configuração do ambiente, para fazer a instalação da biblioteca basta fazer o *download* do repositório e realizar a instalação via o comando `pip`, utilizando uma das opções abaixo.

- **Download via git (SSH ou HTTPS).** Digitar no terminal um dos seguintes comandos:

```
git clone ssh://git@gitlab.com/ted8750/price-library.git ou
```

```
git clone https://gitlab.com/ted8750/price-library.git .
```

²<https://www.python.org>

³<https://www.pypi.org>

⁴<https://www.ubuntu.com/>

⁵<https://www.debian.org/>

⁶<https://www.python.org/downloads/mac-osx>

⁷<https://www.jetbrains.com/pycharm/download/#section=mac>

⁸<https://www.anaconda.com/products/individual>

- **Download via GitLab.** Fazer *login* no GitLab ⁹ utilizando uma conta que possui permissão de acesso ao repositório da biblioteca, acessar o *link* do repositório, clicar em *Download* → *zip*.
- **Instalação via pip.** Acessar a pasta do repositório no terminal e digitar o seguinte comando:

```
pip install ./      (ou python -m pip install ./)
```

A biblioteca contém um conjunto de testes que podem ser utilizados para verificar se a instalação foi bem sucedida. Para isto, digite os seguintes comandos no terminal:

```
cd price-library/tests
pytest                (ou python -m pytest)
```

2.4 Recursos de hardware

Os recursos necessários para a utilização da biblioteca dependem da quantidade de dados que será processada por ela. O principal fator que interfere na utilização da mesma é a quantidade de memória RAM disponível. Quanto maior for a base de dados processada (em número de linhas e colunas), maior será a quantidade de memória RAM exigida. A Tabela 2.4.1 apresenta o tempo de execução gasto pelos módulos da biblioteca com a execução no seguinte *hardware*:

- **Sistema Operacional:** Debian 10.4;
- **Processador:** (2x) Intel Xeon CPU E5-2690 v2 @ 3.00GHz, 10 cores/ 20 threads;
- **Memória RAM:** 96GB, DDR3 @ 1866MHz.

⁹<https://gitlab.com>

	Base de dados	Memória RAM utilizada	Tempo de execução
Adição de ruído com privacidade diferencial local	Ensino Básico de 2019 (Brasil)	>90GB	4h 40min
Cálculo do risco $\widehat{RCU}^{ldp}$	Ensino Básico de 2019 (DF)	~20GB	1h 35min
Cálculo do risco RCU^{ams}	Ensino Básico de 2019 (Brasil)	~30GB	30min
	Ensino Básico de 2019 (DF)	~15GB	10min
Cálculo da utilidade	Ensino Básico de 2019 (Brasil)	~20GB	20min
	Ensino Básico de 2019 (DF)	~10GB	20s

Tabela 2.4.1: Gasto de memória RAM e tempo de execução dos três módulos da biblioteca `price-library`. Não foi possível executar a adição de ruído diretamente na base de dados completa do Ensino Básico de 2019 (que possui aproximadamente 47 milhões de registros) pois a quantidade de memória RAM necessária é superior a 90GB. Sendo assim, foi necessário particionar a base de dados do Ensino Básico de 2019 em 3 partes, cada uma com aproximadamente 15 milhões de registros, adicionar o ruído separadamente em cada parte (que utiliza aproximadamente 40GB de memória RAM) e por fim juntá-las para formar a base completa aleatorizada. A soma do tempo gasto em todo esse processo é o apresentado nesta tabela. 

3 Instruções para acesso às bases sanitizadas no projeto piloto

Para as análises experimentais descritas no Produto 05 do presente TED 8750, criamos várias versões sanitizadas, com diferentes parâmetros, da base do Censo da Educação Básica de 2019.

Conforme descrito no Produto 05, criamos as seguintes bases:

- Bases do Censo da Educação Básica de 2019 sanitizadas por amostragem pelo Inep e tratadas para a remoção de duplicatas.
- Bases do Censo da Educação Básica de 2019 contendo registros de todo o país, tratadas para a remoção de duplicatas e sanitizadas por privacidade diferencial local. Foram criadas 5 versões desta base, uma para cada um dos seguintes valores do parâmetro ε : $\ln 3$, $\ln 5$, $\ln 100$, $\ln 1\,000$, $\ln 100\,000$.
- Bases do Censo da Educação Básica de 2019 contendo registros apenas do Distrito Federal, tratadas para a remoção de duplicatas e sanitizadas por privacidade diferencial local. Foram criadas 5 versões desta base, uma para cada um dos seguintes valores do parâmetro ε : $\ln 3$, $\ln 5$, $\ln 100$, $\ln 1\,000$, $\ln 100\,000$.

A seguir listamos os respectivos arquivos e descrevemos o método de acesso a tais bases.

3.1 Lista das bases sanitizadas

Conforme descrito no Produto 05 do presente TED 8750, tratamos as bases de dados fornecidas pelo Inep com o objetivo de remover registros múltiplos para um mesmo indivíduo.

Dessa forma, disponibilizamos como resultado do projeto piloto para os estudos sobre amostragem, as bases de dados listadas na Tabela 3.1.1, compactadas no arquivo

sampling.zip. Nosso tratamento para a remoção de duplicatas sobre a amostra disponibilizada pelo Inep resultou no arquivo **TED8750-SAMPLE-SMALL.csv**, constituído por 13 592 097 registros. O mesmo tratamento realizado sobre a base contendo todos os registros para o Censo da Educação Básica de 2019, conforme descrito no Produto 05, resultou no arquivo **TED8750-SAMPLE-FULL.csv**, constituído por 47 640 822 registros. Finalmente, a concatenação de todos os atributos selecionados pelo Inep para divulgação no caso dos estudos sobre amostragem ao arquivo **TED8750-SAMPLE-SMALL.csv**, resultou no arquivo **TED8750-SAMPLE.csv**, efetivamente utilizado nas análises sobre amostragem apresentadas no Produto 05.

Já para os estudos sobre privacidade diferencial local, disponibilizamos as bases de dados listadas nas Tabelas 3.1.2 e 3.1.3, compactadas nos arquivos **localDP-br.zip** e **localDP-df.zip**, para o Brasil e o Distrito Federal, respectivamente. Conforme descrito no Produto 05, nosso tratamento para a remoção de duplicatas sobre a base contendo todos os registros para o Censo da Educação Básica de 2019 resultou no arquivo **TED8750-LDP.csv**, constituído por 47 640 822 registros. A partir dessa base de dados tratada, geramos várias bases sanitizadas por privacidade diferencial local com os seguintes valores do parâmetro de privacidade ε : $\ln 3$, $\ln 5$, $\ln 100$, $\ln 1\,000$, $\ln 100\,000$. Os seguintes arquivos contêm tais bases:

- **TED8750-LDP-RAND-EP3.csv**,
- **TED8750-LDP-RAND-EP5.csv**,
- **TED8750-LDP-RAND-EP100.csv**,
- **TED8750-LDP-RAND-EP1000.csv** e
- **TED8750-LDP-RAND-EP100000.csv**.

Finalmente, geramos o arquivo **TED8750-LDP-DF.csv** a partir do arquivo **TED8750-LDP.csv**, selecionando apenas os estudantes para os quais a escola se encontra no Distrito Federal, o que constitui 654 412 registros. Este mesmo processo foi feito para todas as bases aleatorizadas com os valores do parâmetro de privacidade ε $\ln 3$, $\ln 5$, $\ln 100$, $\ln 1\,000$, $\ln 100\,000$, resultando nas bases presentes nos arquivos

- **TED8750-LDP-DF-RAND-EP3.csv**,
- **TED8750-LDP-DF-RAND-EP5.csv**,
- **TED8750-LDP-DF-RAND-EP100.csv**,
- **TED8750-LDP-DF-RAND-EP1000.csv** e
- **TED8750-LDP-DF-RAND-EP100000.csv**.

Como descrito no Produto 05, essas foram as bases efetivamente utilizadas nas análises sobre privacidade diferencial local, dada a elevada demanda computacional.

3.2 Como acessar as bases sanitizadas

Descrevemos a seguir como acessar os arquivos compactados **sampling.zip**, **localDP-br.zip** e **localDP-df.zip**, descritos nas Tabelas 3.1.1, 3.1.2 e 3.1.3, respectivamente.

sampling.zip	
90fbdcfce48400d89eafd80e8fe54d40f	
Arquivo	MD5
TED8750-SAMPLE.csv	1bb652ac00bebad4d96c66e4cfa9a6d3
TED8750-SAMPLE-FULL.csv	6800bcd18795ffb1e49b711f3868f2f2
TED8750-SAMPLE-SMALL.csv	48cd5654f1ad9e457ebe167d77074cc9

Tabela 3.1.1: Arquivos referentes às bases de dados tratadas para os estudos sobre amostragem, com seus respectivos valores para o hash MD5. Os arquivos CSV encontram-se compactados no arquivo `sampling.zip`.

localDP-br.zip	
fb8c4ef181fa14c4ec381da833d709b3	
Arquivo	MD5
TED8750-LDP.csv	a992ca80a76dfbc1fd0665d652e10121
TED8750-LDP-RAND-EP3.csv	02ee87ffb2e63033f68ee897904427b7
TED8750-LDP-RAND-EP5.csv	0f86ad1c747fc7962613abfc8acc1224
TED8750-LDP-RAND-EP100.csv	4cc847674df3504e5ceb1c34d1c26324
TED8750-LDP-RAND-EP1000.csv	4cd5a298e9a3451bbc3f7b28d7332a65
TED8750-LDP-RAND-EP100000.csv	627f6fe0e7cedc0e26f15cd54a5638e7

Tabela 3.1.2: Arquivos referentes às bases de dados tratadas e sanitizadas para os estudos sobre privacidade diferencial local em todo o Brasil, com seus respectivos valores para o hash MD5. Os arquivos CSV encontram-se compactados no arquivo `localDP-br.zip`.

localDP-df.zip	
5ca93189b3a742a01cf1813560fa3225	
Arquivo	MD5
TED8750-LDP-DF.csv	ed7b6fab52ef42aefbf43442b54adc10
TED8750-LDP-DF-RAND-EP3.csv	7c34b1ceecaea100c61cf7c7c998fc2e
TED8750-LDP-DF-RAND-EP5.csv	0d397225715a8bc9765d845c64e1440a
TED8750-LDP-DF-RAND-EP100.csv	f5f7d36276e3226a0cdc0acd9db9a628
TED8750-LDP-DF-RAND-EP1000.csv	159d10938c58733e8632c614917d5478
TED8750-LDP-DF-RAND-EP100000.csv	469972f62255acad7e4dcbf812e41cf8

Tabela 3.1.3: Arquivos referentes às bases de dados tratadas e sanitizadas para os estudos sobre privacidade diferencial local no Distrito Federal, com seus respectivos valores para o hash MD5. Os arquivos CSV encontram-se compactados no arquivo `localDP-df.zip`.

IP (Host)	Porta	Usuário	Senha	Pasta
150.164.7.199	21	inep	xFVaomL5vJZCjUY	ted8750

Tabela 3.2.4: Credenciais para acesso ao servidor FTP do laboratório INSCRYPT.

Série	6d:e5:df:36:40:b7:36:7d:30:87:fb:fe:e0:74:2d:dc:22:7e:bb:45
Validade	09/02/2023 22:04:32
SHA-1	d2:97:3b:50:4f:a9:86:b2:d4:f3:2d:61:85:f6:ad:4b:44:c4:2b:b4
Chave	RSA with 4096 bits

Tabela 3.2.5: Informações sobre o certificado TLS 1.3 para conexão segura FTPS ao servidor FTP emitido pelo laboratório INSCRYPT.

Esses arquivos estão disponíveis no servidor FTP do laboratório INSCRYPT e serão mantidos por um prazo de, ao menos, um ano a partir da entrega deste Produto 04. De modo a garantirmos a segurança da conexão ao servidor, optamos pelo protocolo seguro FTPS. Essa decisão limita as opções de acesso ao servidor, o que não é possível via navegador web ou linha de comando, sendo necessário o uso de software específico com suporte ao protocolo FTPS. Para tanto, sugerimos o software open source FileZilla,¹ disponível para os principais sistemas operacionais.

O servidor FTP é acessível pelo IP 150.164.7.199, via porta padrão do protocolo FTP (21). Para o acesso, criamos o usuário `inep`, com a senha `xFVaomL5vJZCjUY`, conforme Tabela 3.2.4, o qual tem acesso à pasta `ted8750` onde se encontram os arquivos compactados `sampling.zip`, `localDP-br.zip` e `localDP-df.zip`. A conexão é protegida por um certificado TLS 1.3 emitido pelo laboratório INSCRYPT, conforme detalhado na Tabela 3.2.5.

Caso o acesso seja realizado através do software FileZilla, uma vez instalado, basta utilizar a opção “Conexão rápida”, ou *Quickconnect* em inglês. Para tanto, entre com as informações providas na Tabela 3.2.4 nos campos à esquerda do botão de “Conexão rápida” e, em seguida, clique no botão. Um aviso sobre “Certificado desconhecido” surgirá na tela com as informações apresentadas na Tabela 3.2.5. Por segurança, confira as informações e, caso estejam compatíveis, clique no botão “OK”. Uma vez estabelecida a conexão, a pasta raiz do servidor FTP será exibida. Acesse a pasta `ted8750`, selecione os arquivos compactados e baixe-os para a máquina local.

¹Para download do software FileZilla, acesse: <https://filezilla-project.org/download.php>

Referências Bibliográficas

- [1] Governo do Brasil. Lei 13.709, de 14 de agosto de 2018, Lei Geral de Proteção de Dados Pessoais (LGPD). Disponível em: http://www.planalto.gov.br/ccivil_03/_ato2015-2018/2018/Lei/L13709.htm.

Anexos

A Documentação da biblioteca utilizada no projeto piloto

A seguir apresentamos a documentação da biblioteca empregada nas análises do projeto piloto deste TED 8750.

O código fonte desta biblioteca está disponível no seguinte repositório:

<https://gitlab.com/ted8750/price-library>

A documentação está disponível em formato HTML no diretório `docs/html` do repositório acima.

PRICE - Privacidade dos Censos Educacionais

Release 1.0.0

Lucas Lopes; Ramon G. Gonze

12 fev. 2021

1	Instruções de uso	3
1.1	Configuração do ambiente	3
1.2	Instalação	3
2	Tutoriais	5
2.1	Tutorial - Privacidade diferencial local	5
2.1.1	Leitura de dados	5
2.1.2	Adição de ruído	6
2.1.3	Cálculo do risco $\widehat{RCU}^{ldp}$	7
2.1.4	Salvar uma base aleatorizada	8
2.2	Tutorial - Amostragem	8
2.2.1	Instanciação da classe que realiza o cálculo RCU^{ams}	8
2.2.2	Execução do cálculo de risco à privacidade em sanitização por amostragem	8
2.3	Tutorial - Utilidade	9
2.3.1	Cálculo da utilidade	9
3	Pacote localdp	11
3.1	pricelib.localdp.data	11
3.1.1	Classes base para dados	11
3.1.2	Bases do Ensino básico	13
3.2	pricelib.localdp.randomizer	14
3.2.1	Classe base para adição de ruído	14
3.2.2	Adição de ruído em bases do Ensino básico	15
3.2.3	Correção de colunas em bases do Ensino básico	16
3.3	pricelib.localdp.risk	17
3.3.1	Ataque $\widehat{RCU}^{ldp}$	17
3.3.2	Ataque $\widehat{RCU}^{ldp}$ em bases do Ensino básico	17
3.4	pricelib.localdp.util	18
3.4.1	Utilidades e funções de uso geral	18
4	Pacote sampling	21
4.1	pricelib.sampling.risk	21
4.1.1	Ataque RCU^{ams}	21
5	Pacote utility	25
5.1	pricelib.utility.utility	25

5.1.1 Cálculo da utilidade	25
Índice de Módulos Python	27
Índice	29

A biblioteca pricelib consiste no Produto 04, intitulado Solução tecnológica e sua documentação, do plano de trabalho do Termo de Execução Descentralizada (TED) 8750, firmado entre o Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira (Inep) e a Universidade Federal de Minas Gerais (UFMG), e em execução pelo Laboratório Inscript (*Laboratory of Information Security, Cryptography, Privacy, and Transparency*) do Departamento de Ciência da Computação (DCC) da Universidade.

1.1 Configuração do ambiente

A solução tecnológica desenvolvida consiste em uma biblioteca na linguagem Python. É importante ressaltar que todos os requisitos descritos a seguir são *open source*, e, portanto, não acarretam custos financeiros para instalação e uso. Para a utilização da biblioteca, é necessário um ambiente computacional com os seguintes requisitos:

- Python na versão 3.8 ou superior;
- Repositório de software Python Package Index (PyPi).

Abaixo seguem instruções para utilização em distribuições Linux e macOS:

- **Linux:** Em distribuições Linux (como [Ubuntu](#) e [Debian](#)) nas suas versões mais recentes, o interpretador Python já vem previamente instalado. Já o repositório de software PyPi, pode ser facilmente instalado a partir dos repositórios padrão da distribuição Unix com o comando `sudo apt install python3-pip`.
- **macOS:** O download do interpretador python para macOS pode ser feito através do [site oficial](#). Também é possível utilizar uma IDE, como o [PYCharm](#).

Uma outra alternativa é instalar ambientes virtuais que já possuem tanto o Python quanto o PyPi, como o [Anaconda](#) (disponível tanto para macOS quanto para Linux).

1.2 Instalação

Após a configuração do ambiente, para fazer a instalação da biblioteca basta fazer o download do repositório e realizar a instalação via o comando `pip`, utilizando uma das opções abaixo.

- **Download via git (SSH ou HTTPS):** Digitar no terminal um dos seguintes comandos:

```
git clone ssh://git@gitlab.com/ted8750/price-library.git
git clone https://gitlab.com/ted8750/price-library.git
```


- **Download via GitLab:** Fazer login no [GitLab](#) utilizando uma conta que possui permissão de acesso ao repositório da biblioteca, acessar o link do repositório, clicar em *Download* → *zip*.
- **Instalação via pip:** Acessar a pasta do repositório no terminal e digitar o seguinte comando:

```
pip install ./ # ou python -m pip install ./
```

A biblioteca contém um conjunto de testes que podem ser utilizados para verificar se a instalação foi bem sucedida. Para isto, digite os seguintes comandos no terminal:

```
cd price-library/tests  
pytest # ou python -m pytest
```

2.1 Tutorial - Privacidade diferencial local

Aqui está um tutorial de como aplicar a privacidade diferencial local em bases do Ensino Básico, desde a leitura dos dados, configuração dos mecanismos e o cálculo do risco $\widehat{RCU}^{ldp}$.

2.1.1 Leitura de dados

A leitura dos dados deve ser feita utilizando-se a classe *BasicEducation*:

```
from pricelib.localdp.data.basiceducation import BasicEducation
from pricelib.localdp.randomizer.core import RandomizerBasicEducation
from pricelib.localdp.risk.reidentification import RCUBasicEducation
from math import log
import numpy

colunas = [
    'ID_MATRICULA', 'NU_IDADE', 'TP_SEXO', 'ID_TURMA',
    'TP_ETAPA_ENSINO', 'CO_ENTIDADE', 'CO_UF', 'TP_DEPENDENCIA'
]

# Tipo de dados: 'num' para numéricos e 'str' para não numéricos
tipos = {
    'ID_MATRICULA': 'num',
    'NU_IDADE': 'num',
    'TP_SEXO': 'num',
    'ID_TURMA': 'num',
    'TP_ETAPA_ENSINO': 'num',
    'CO_ENTIDADE': 'num',
    'CO_UF': 'num',
    'TP_DEPENDENCIA': 'num'
}
```

(continua na próxima página)

(continuação da página anterior)

```
base = BasicEducation(  
    year=2019, # Ano do censo  
    data_path='dados/ensinobasico2019.csv', # Arquivo csv contendo a base  
    usecols=colunas,  
    datatypes=tipos,  
    delimiter=',' # Separador csv  
)
```

2.1.2 Adição de ruído

Após a leitura dos dados, deve-se definir os mecanismos de cada atributo para que seja adicionado ruído:

```
# Faz uma cópia da base original para se calcular o risco posteriormente  
base_original = base.copy()  
  
# Define colunas dependentes da turma  
cols_dep_turma = ['TP_ETAPA_ENSINO', 'CO_ENTIDADE']  
  
# Define colunas dependentes da escola  
cols_dep_escola = ['CO_UF', 'TP_DEPENDENCIA']  
  
mecanismos = RandomizerBasicEducation(  
    data=base,  
    class_dep_cols=cols_dep_turma,  
    school_dep_cols=cols_dep_escola  
)  
  
# Parâmetro de privacidade  
epsilon = log(3)  
  
# Define o mecanismo geométrico truncado para adicionar ruído em NU_IDADE  
mecanismos.set_mechanism('NU_IDADE', 'geot', epsilon,  
    {'lower':0, 'upper':120, 'sensitivity':120})  
  
# Define o mecanismo k-RR para adicionar ruído em TP_SEXO  
dominio_sexo = ['',1,2]  
mecanismos.set_mechanism('TP_SEXO', 'krr', epsilon,  
    {'domain_values': dominio_sexo})  
  
# Obtém o domínio de turmas (todos os valores possíveis presentes na base)  
index_turma = base_original.getidx('ID_TURMA')  
dominio_turmas = numpy.unique(base_original.matrix[:,index_turma]).tolist()  
  
# Define o mecanismo k-RR para adicionar ruído em ID_TURMA  
mecanismos.set_mechanism('ID_TURMA', 'krr', epsilon,  
    {'domain_values': dominio_turmas})
```

Após a definição dos mecanismos, chamamos a função `randomise_dataset()`. É necessário passar como parâmetro os arquivos da Tabela de turmas e Tabela de escolas (**classes.csv** e **schools.csv**) contendo todas as turmas e escolas presentes na base de dados lida. A função `randomise_dataset()` suporta execução em paralelo, e o número de *threads* utilizadas deve ser passado no parâmetro `num_threads`.

```
mecanismos.randomise_dataset(  
    classes_file='dados/classes.csv',
```

(continua na próxima página)

(continuação da página anterior)

```

classes_delimiter='|', # Separador csv
schools_file='dados/schools.csv',
schools_delimiter='|', # Separador csv
num_threads=20
)

```

Aviso: Os arquivos com a Tabela de turmas e Tabela de escolas devem conter **somente** as turmas e escolas presentes na base de dados lida, para que o valor do risco $\widehat{RCU}^{ldp}$ seja calculado corretamente.

2.1.3 Cálculo do risco $\widehat{RCU}^{ldp}$

Após a adição de ruído, a variável `base` contém agora os dados aleatorizados, enquanto que a variável `base_original` contém os dados sem nenhuma adição de ruído. Sendo assim, podemos calcular o risco $\widehat{RCU}^{ldp}$ para um conjunto de quaseidentificadores:

```

qids = ['TP_SEXO', 'TP_ETAPA_ENSINO', 'CO_UF']

risco = RCUBasicEducation(
    original_data=base_original,
    randomised_data=base,
    unique_id='ID_MATRICULA', # Identificador único de cada registro
    randomizer=mecanismos,
    qids=qids,
    class_qids=['TP_ETAPA_ENSINO'], # quaseidentificadores dependentes da turma
    classes_file='dados/classes.csv',
    classes_delimiter='|',
    school_qids=['CO_UF'], # quaseidentificadores dependentes da escola
    schools_file='dados/schools.csv',
    schools_delimiter='|'
)

sucesso_a_priori = risco.prior_success()
sucesso_a_posteriori = risco.posterior_success(num_threads=20)

print("Risco a priori: %.8f"%(sucesso_a_priori))
print("Risco a posteriori: %.8f"%(sucesso_a_posteriori))

```

Por fim, as variáveis `sucesso_a_priori` e `sucesso_a_posteriori` contém os sucessos a prior e a posteriori, respectivamente, e a degradação da privacidade pode ser obtida fazendo-se `sucesso_a_posteriori/sucesso_a_priori`.

2.1.4 Salvar uma base aleatorizada

Após a adição de ruído em uma base de dados, pode-se utilizar a função `to_csv()` para salvar a nova base aleatorizada:

```
base.to_csv('dados/novabase.csv', delimiter=',')
```

2.2 Tutorial - Amostragem

Neste tutorial se encontram as instruções para realização do cálculo de risco à privacidade em sanitização por amostragem, RCU^{ams} .

2.2.1 Instanciação da classe que realiza o cálculo RCU^{ams}

A leitura dos dados é feita durante a instanciação da classe `Calculator`, responsável pelo cálculo de risco de privacidade na sanitização por amostragem

```
from pricelib.sampling.risk import Calculator

RCUam_calculator = Calculator(
    sample_path='dados/amostra.csv', # Arquivo csv contendo a amostra
    database_path='dados/ensinobasico2019.csv', # Arquivo csv contendo a base
    column_id='ID_MATRICULA', # Coluna identificadora
    delimiter=',' # Separador csv
)
```

2.2.2 Execução do cálculo de risco à privacidade em sanitização por amostragem

O cálculo de risco à privacidade em sanitização por amostragem, RCU^{ams} é feito através da função `calc_privacy_loss()`. Essa função recebe como parâmetro o conjunto de quaseidentificadores que deve ser levado em consideração durante o cálculo.

```
qids = ['TP_LOCALIZACAO_DIFERENCIADA',
        'TP_DEPENDENCIA',
        'CO_MUNICIPIO',
        'TP_SEXO',
        'TP_ZONA_RESIDENCIAL',
        'NU_IDADE_0_5',
        'ID_AREA_CURSO_PROFISSIONAL']

privacy_metrics = RCUam_calculator.calc_privacy_loss(qids)
```

A função `calc_privacy_loss()` retorna um dicionário contendo o resultado final do cálculo de risco à privacidade, assim como os resultados intermediários. Para visualizar ou utilizar esses resultados, basta acessar o dicionário no índice correspondente:

```
prior_success_det = privacy_metrics.prior_success_det
prior_success_prob = privacy_metrics.prior_success_prob
posterior_success_det = privacy_metrics.posterior_success_det
posterior_success_prob = privacy_metrics.posterior_success_prob
rcuam_det = privacy_metrics.privacy_loss_det
```

(continua na próxima página)

(continuação da página anterior)

```
rcuam_prob = privacy_metrics.privacy_loss_prob  
elapsed_time = privacy_metrics.elapsed_time
```

2.3 Tutorial - Utilidade

Este tutorial mostra um passo a passo para utilização da função de cálculo da utilidade estatística baseada em Total Variation Distance, *util-estatística_A*

2.3.1 Cálculo da utilidade

Para realizar o cálculo, basta importar a função `tvd()` do módulo de utilidade. Esta função recebe como parâmetros: a base de dados original, `original_db` e a base de dados processada por algum método de sanitização (amostragem ou LDP), `processed_db`, no formato `pandas.DataFrame`; e o conjunto de colunas sobre as quais deseja-se avaliar a utilidade estatística

```
import pandas as pd  
from pricelib.utility.utility import tvd  
  
original_db = pd.read_csv('dados/ensinobasico2019.csv')  
sample = pd.read_csv('dados/amostra.csv')  
cols = ['TP_SEXO', 'TP_ZONA_RESIDENCIAL', 'NU_IDADE_0_5']  
  
utility = tvd(original_db = original_db, processed_db = sample, cols = cols)
```


Contém as principais funcionalidades para a aplicação da privacidade diferencial local e a análise de risco.

3.1 `pricelib.localdp.data`

3.1.1 Classes base para dados

class `pricelib.localdp.data.Data` (*matrix*, *columns*, *datatypes*, *str2int*)

Classe base para lidar com dados. Todos os dados são convertidos para inteiros. Se existe algum dado não-numérico em alguma coluna ele será convertido para inteiro, e a relação entre o antigo valor não-numérico e o novo valor selecionado será mantido nos atributos de classe `str2int` e `int2str`.

Parâmetros

- **matrix** (*numpy.ndarray*) – Matriz 2D contendo os dados.
- **columns** (*list*) – Nomes das colunas.
- **datatypes** (*dict*) – Dicionário contendo o tipo de dado de todas as colunas. Os valores no dicionário devem ser 'num' para valores numéricos e 'str' para valores não-numéricos, enquanto que as chaves devem ser nomes de colunas.
- **str2int** (*dict*) – Chaves são nomes de colunas e valores são dicionários. No dicionário mais interno, chaves são valores originais não-numéricos e valores são inteiros associados a eles.

Exemplo:

```
str2int['nome'] = {'Ana':0, 'Bob':1, 'Carol':2}
str2int['sobrenome'] = {'Miller':0, 'Johnson':1, 'Jones':2}
```

copy()

Produz uma cópia da classe.

Retorna self – Retorna uma cópia.

Tipo de retorno class

getidx(*column*)

Retorna o índice da coluna na matriz que contém os dados.

Parâmetros *column*(*string*) – Nome da coluna.

Retorna *index* – Índice da coluna na matriz que contém os dados.

Tipo de retorno int

to_csv(*output_file*, *delimiter*=',')

Salva os dados em um arquivo csv. Valores inteiros em colunas que originalmente possuíam valores não-numéricos são convertidos de volta para seus valores não-numéricos. A ordem das colunas é definida pelo atributo de classe *columns*. Todos os valores -1 nas colunas com valores inteiros são escritos como valores vazios ("").

Parâmetros

- **output_file**(*string*) – Nome do arquivo de saída.
- **delimiter**(*string*, *default*: ', ') – Separador csv.

class *pricelib.localdp.data.DataFromFile*(*data_path*, *usecols*, *datatypes*, *delimiter*=',')

Dados lidos a partir de um arquivo.

Parâmetros

- **data_path**(*string*) – Arquivo csv.
- **usecols**(*list*) – Nome das colunas que devem ser lidas do arquivo csv.
- **datatypes**(*dict*) – Dicionário contendo o tipo de dado de todas as colunas. Os valores no dicionário devem ser 'num' para valores numéricos e 'str' para valores não-numéricos, enquanto que as chaves devem ser nomes de colunas.
- **delimiter**(*string*, *default*: ', ') – Separador csv.

copy()

Produz uma cópia da classe.

Retorna *self* – Retorna uma cópia.

Tipo de retorno class

static **get_header**(*data_path*, *delimiter*=',')

Retorna o cabeçalho de um arquivo csv.

Parâmetros

- **data_path**(*string*) – Arquivo csv.
- **delimiter**(*string*, *default*: ', ') – Separador csv.

Retorna *header* – Lista com os nomes das colunas.

Tipo de retorno list

getidx(*column*)

Retorna o índice da coluna na matriz que contém os dados.

Parâmetros *column*(*string*) – Nome da coluna.

Retorna *index* – Índice da coluna na matriz que contém os dados.

Tipo de retorno int

to_csv(*output_file*, *delimiter*=',')

Salva os dados em um arquivo csv. Valores inteiros em colunas que originalmente possuíam valores não-numéricos são convertidos de volta para seus valores não-numéricos. A ordem das colunas é a mesma do arquivo csv original (definido pelo atributo de classe `original_header`). Todos os valores -1 nas colunas com valores inteiros são escritos como valores vazios ("").

Parâmetros

- **output_file**(*string*) – Nome do arquivo de saída.
 - **delimiter**(*string*, *default*: ', ') – Separador csv.
-

3.1.2 Bases do Ensino básico

class pricelib.localdp.data.**BasicEducation**(*year*, *data_path*, *usecols*, *datatypes*, *delimiter*=',')

Classe para lidar com bases de dados do Ensino básico. Os dados devem ser lidos de um arquivo csv.

Parâmetros

- **year**(*int*) – Ano do censo da base de dados lida.
- **data_path**(*string*) – Arquivo csv.
- **usecols**(*list*) – Nome das colunas que devem ser lidas do arquivo csv.
- **datatypes**(*dict*) – Dicionário contendo o tipo de dado de todas as colunas. Os valores no dicionário devem ser 'num' para valores numéricos e 'str' para valores não-numéricos, enquanto que as chaves devem ser nomes de colunas. Exemplo:

```
datatypes = {'ID_ALUNO': 'str', 'ID_TURMA': 'num', 'NU_IDADE': 'num'}
```

- **delimiter**(*string*, *default*: ', ') – Separador csv.

copy()

Produz uma cópia da classe.

Retorna self – Retorna uma cópia.

Tipo de retorno class

static get_header(*data_path*, *delimiter*=',')

Retorna o cabeçalho de um arquivo csv.

Parâmetros

- **data_path**(*string*) – Arquivo csv.
- **delimiter**(*string*, *default*: ', ') – Separador csv.

Retorna header – Lista com os nomes das colunas.

Tipo de retorno list

getidx(*column*)

Retorna o índice da coluna na matriz que contém os dados.

Parâmetros **column**(*string*) – Nome da coluna.

Retorna index – Índice da coluna na matriz que contém os dados.

Tipo de retorno int

to_csv(*output_file*, *delimiter*=',')

Salva os dados em um arquivo csv. Valores inteiros em colunas que originalmente possuíam valores não-numéricos são convertidos de volta para seus valores não-numéricos. A ordem das colunas é a mesma do arquivo csv original (definido pelo atributo de classe `original_header`). Todos os valores -1 nas colunas com valores inteiros são escritos como valores vazios ("").

Parâmetros

- **output_file**(*string*) – Nome do arquivo de saída.
- **delimiter**(*string*, *default*: ', ') – Separador csv.

3.2 pricelib.localdp.randomizer

3.2.1 Classe base para adição de ruído

class pricelib.localdp.randomizer.**Randomizer**(*data*)

Classe principal utilizada para se aplicar a privacidade local.

Parâmetros *data* (*Data*) – Instância da classe *Data* contendo a base de dados a ser aleatorizada.

classmethod **check_epsilon**(*epsilon*)

Verifica a corretude do parâmetro epsilon de mecanismos que satisfazem privacidade diferencial.

Parâmetros *epsilon* (*float*) – Parâmetro de privacidade ϵ . Deve estar no intervalo $(0, \infty)$.

randomise_dataset(*num_threads*=1)

Adiciona ruído em cada célula da base de dados original de acordo com os mecanismo pré-definidos (via método `set_mechanisms`). A coluna em que não se foi definido um mecanismo não sofrerá adição de ruído.

Parâmetros *num_threads* (*int*, *default*: 1) – Número de threads para execução em paralelo.

set_mechanism(*column*, *mechanism*, *epsilon*, *parameters*)

Define um mecanismo para uma coluna.

Parâmetros

- **column**(*string*) – Nome da coluna.
- **mechanism**(*string*) – Mecanismo que satisfaz privacidade diferencial para um dado ϵ .
 - 'exp' para o mecanismo exponencial
 - 'geot' para o mecanismo geométrico truncado
 - 'krr' para o mecanismo k-RR.
- **epsilon**(*float*) – Parâmetro de privacidade ϵ . Deve estar no intervalo $(0, \infty)$.
- **parameters**(*dict*) – Parâmetros do mecanismo selecionado. Chaves são nomes do parâmetro do mecanismo e valores seguem conforme definido a seguir.

Se mechanism = 'exp', o dicionário deve conter:

'distances_list': list Lista de distâncias do mecanismo. Deve ser especificado como uma lista de tuplas da forma ("valor1","valor2", distância), onde cada valor é uma string e distância é um valor float estritamente positivo. A distância deve ser especificada para cada par de valores possíveis.

Se mechanism = 'geot', o dicionário deve conter:

'lower': int Limite inferior do truncamento.

'upper': int Limite superior do truncamento.

'sensitivity': int, float Sensibilidade do mecanismo. Deve estar no intervalo $[0, \infty)$.

Se **mechanism = 'krr'**, o dicionário deve conter:

'domain_values': list Conjunto imagem do mecanismo (possíveis valores que o mecanismo pode retornar).

3.2.2 Adição de ruído em bases do Ensino básico

class pricelib.localdp.randomizer.RandomizerBasicEducation (*data*,
class_dep_cols=[],
school_dep_cols=[])

Classe utilizada para se aplicar a privacidade diferencial local em bases de dados do Ensino básico.

Parâmetros

- **data** (*BasicEducation*) – Instância da classe *BasicEducation* contendo a base de dados a ser aleatorizada.
- **class_dep_cols** (*list*, *default: []*) – Lista de colunas dependentes de 'ID_TURMA' que não serão aleatorizadas e devem ter os seus valores atualizados de acordo com o novo valor de 'ID_TURMA' definido no processo de adição de ruído.
- **school_dep_cols** (*list*, *default: []*) – Lista de colunas dependentes de 'CO_ENTIDADE' que não serão aleatorizadas e devem ter os seus valores atualizados de acordo com o novo valor de 'ID_TURMA' definido no processo de adição de ruído.

classmethod check_epsilon (*epsilon*)

Verifica a corretude do parâmetro epsilon de mecanismos que satisfazem privacidade diferencial.

Parâmetros **epsilon** (*float*) – Parâmetro de privacidade ϵ . Deve estar no intervalo $(0, \infty)$.

randomise_dataset (*classes_file=None*, *classes_delimiter=None*, *schools_file=None*, *schools_delimiter=None*, *num_threads=1*)

Adiciona ruído em cada célula da base de dados original de acordo com os mecanismo pré-definidos (via método `set_mechanisms`). A coluna em que não se foi definido um mecanismo não sofrerá adição de ruído.

Parâmetros

- **classes_file** (*string*, *default: None*) – Arquivo csv contendo informação sobre turmas brasileiras do ensino básico. Também chamado de Tabela de turmas.
- **classes_delimiter** (*string*, *default: None*) – Separador csv da tabela de turmas.
- **schools_file** (*string*, *default: None*) – Arquivo csv contendo informação sobre escolas brasileiras. Também chamado de Tabela de escolas.
- **schools_delimiter** (*string*, *default: None*) – Separador csv da Tabela de escolas.
- **num_threads** (*int*, *default: 1*) – Número de threads para execução em paralelo.

set_mechanism (*column*, *mechanism*, *epsilon*, *parameters*)

Define um mecanismo para uma coluna.

Parâmetros

- **column** (*string*) – Nome da coluna.
- **mechanism** (*string*) – Mecanismo que satisfaz privacidade diferencial para um dado ϵ .
 - 'exp' para o mecanismo exponencial
 - 'geot' para o mecanismo geométrico truncado
 - 'krr' para o mecanismo k-RR.
- **epsilon** (*float*) – Parâmetro de privacidade ϵ . Deve estar no intervalo $(0, \infty)$.
- **parameters** (*dict*) – Parâmetros do mecanismo selecionado. Chaves são nomes do parâmetro do mecanismo e valores seguem conforme definido a seguir.

Se **mechanism** = 'exp', o dicionário deve conter:

'distances_list': list Lista de distâncias do mecanismo. Deve ser especificado como uma lista de tuplas da forma ("valor1", "valor2", distância), onde cada valor é uma string e distância é um valor float estritamente positivo. A distância deve ser especificada para cada par de valores possíveis.

Se **mechanism** = 'geot', o dicionário deve conter:

'lower': int Limite inferior do truncamento.

'upper': int Limite superior do truncamento.

'sensitivity': int, float Sensibilidade do mecanismo. Deve estar no intervalo $[0, \infty)$.

Se **mechanism** = 'krr', o dicionário deve conter:

'domain_values': list Conjunto imagem do mecanismo (possíveis valores que o mecanismo pode retornar).

3.2.3 Correção de colunas em bases do Ensino básico

class pricelib.localdp.randomizer.FixerBasicEducation (*data*)

Classe utilizada para corrigir os valores de colunas dependentes.

Parâmetros **data** (*BasicEducation*) – Instância da classe *BasicEducation* contendo a base de dados a ser aleatorizada.

fix_dependent_columns ()

Corrige os valores das colunas NU_IDADE_0_5, IN_DIST_IDADE_SERIE e IN_TEMPO_INTEGRAL, de acordo com o novo valor de ID_TURMA.

3.3 pricelib.localdp.risk

3.3.1 Ataque $\widehat{RCU}^{ldp}$

class pricelib.localdp.risk.RCU(*original_data*, *randomised_data*, *unique_id*, *randomizer*, *qids*)

Classe base utilizada para calcular o risco de Reidentificação Coletiva em uma Única base ($\widehat{RCU}^{ldp}$) quando se aplica a privacidade diferencial local.

Parâmetros

- **original_data** (*Data*) – Base de dados original sem ruído.
- **randomised_data** (*Data*) – Base de dados aleatorizada.
- **unique_id** (*string*) – Coluna que identifica unicamente os registros tanto da base de dados original quanto da base aleatorizada.
- **randomizer** (*Randomizer*) – Conjunto de mecanismos utilizados para gerar a base aleatorizada.
- **qids** (*list*) – Lista de quaseidentificadores (nomes de colunas). Deve ser uma lista de strings.

posterior_success (*num_threads=1*)

Sucesso a posteriori em um ataque RCU.

Parâmetros **num_threads** (*int*, *default: 1*) – Número de threads para execução em paralelo.

prior_success ()

Sucesso a priori em um ataque $\widehat{RCU}^{ldp}$.

3.3.2 Ataque $\widehat{RCU}^{ldp}$ em bases do Ensino básico

class pricelib.localdp.risk.RCUBasicEducation(*original_data*, *randomised_data*, *unique_id*, *randomizer*, *qids*, *class_qids*=[], *classes_file*=None, *classes_delimiter*=',', *school_qids*=[], *schools_file*=None, *schools_delimiter*=',')

Classe utilizada para calcular o risco de Reidentificação Coletiva em uma Única base ($\widehat{RCU}^{ldp}$) do Ensino básico quando se aplica a privacidade diferencial local.

Parâmetros

- **original_data** (*BasicEducation*) – Base de dados original sem ruído.
- **randomised_data** (*BasicEducation*) – Base de dados aleatorizada.
- **unique_id** (*string*) – Coluna que identifica unicamente os registros tanto da base de dados original quanto da base aleatorizada.
- **randomizer** (*RandomizerBasicEducation*) – Conjunto de mecanismos utilizados para gerar a base aleatorizada.
- **qids** (*list*) – Lista de quaseidentificadores (nomes de colunas). Deve ser uma lista de strings.

- **class_qids**(*list*, *default*: []) – Lista de quaseidentificadores dependentes de ID_TURMA.
- **classes_file**(*string*, *default*: None) – Arquivo csv contendo informação sobre turmas brasileiras do ensino básico. Também chamado de Tabela de turmas.
- **classes_delimiter**(*string*, *default*: ', ') – Separador csv da tabela de turmas.
- **school_qids**(*list*, *default*: []) – Lista de quaseidentificadores dependentes de CO_ENTIDADE.
- **schools_file**(*string*, *default*: None) – Arquivo csv contendo informação sobre escolas brasileiras. Também chamado de Tabela de escolas.
- **schools_delimiter**(*string*, *default*: ', ') – Separador csv da Tabela de escolas.

class_qids_original

i-ésima posição = qids do i-ésimo registro na base de dados aleatorizada.

posterior_success(*num_threads*=1)

Sucesso a posteriori em um ataque $\widehat{RCU}^{ldp}$.

Parâmetros **num_threads**(*int*, *default*: 1) – Número de threads para execução em paralelo.

prior_success()

Sucesso a priori em um ataque $\widehat{RCU}^{ldp}$.

3.4 pricelib.localdp.util

3.4.1 Utilidades e funções de uso geral

pricelib.localdp.util.distance(*p1*, *p2*)

Distância entre dois pontos (longitude, latitude) na Terra.

Parâmetros

- **p1**(*tuple*) – Ponto p1.
- **p2**(*tuple*) – Ponto p2.

Retorna Distância entre p1 e p2.

Tipo de retorno float

pricelib.localdp.util.gendistances(*cities_path*, *output_path*)

Usando a saída gerada pelo método `kml2csv()`, gera um arquivo csv contendo as distâncias entre todas as cidades brasileiras. No arquivo de saída cada linha contém um par de cidades e a distância entre elas em Km. As três colunas são nomeadas como COD_MUNICIPIO_1, COD_MUNICIPIO_2, DISTANCIA.

Parâmetros

- **cities_path**(*string*) – Arquivo contendo coordenadas das cidades (gerado pelo método `kml2csv()`).
- **output_path**(*string*) – Arquivo de saída.

pricelib.localdp.util.file_len(*fname*)

Retorna o número de linhas de um arquivo.

Parâmetros `fname` (*string*) – Caminho para o arquivo.

Retorna Número de linhas do arquivo.

Tipo de retorno `int`

`pricelib.localdp.util.gensample(csv_path, output_path, sample_size, seed=7)`

Gera uma amostra de uma base de dados de um arquivo csv.

Parâmetros

- `csv_path` (*string*) – Arquivo csv.
- `output_path` (*string*) – Arquivo de saída.
- `sample_size` (*int*) – Tamanho da sample (número de linhas).
- `seed` (*int*, *default*: 7) – Semente de aleatoriedade.

`pricelib.localdp.util.kml2csv(kml_path, output_path)`

Converte o arquivo kml contendo informações sobre os municípios brasileiros obtido no site do IBGE para um arquivo csv contendo as cidades e suas localizações geográficas (latitude e longitude). A base pode ser baixada [aqui](#).

Nome do arquivo: Google_KML/BR_Localidades_2010_v1.kml

Parâmetros

- `kml_path` (*string*) – Arquivo kml de entrada.
 - `output_path` (*string*) – Arquivo csv de saída.
-

Contém as principais funcionalidades para a análise de risco em bases de dados amostrais.

4.1 `pricelib.sampling.risk`

4.1.1 Ataque RCU^{ams}

class `pricelib.sampling.risk.Calculator` (*sample_path*, *database_path*, *column_id*, *delimiter*)

Classe principal utilizada para cálculo do risco à privacidade em amostragem.

Parâmetros

- **sample_path** (*string*) – Caminho para o arquivo (csv) que contém a amostra.
- **database_path** (*string*) – Caminho para o arquivo (csv) que contém a base de dados completa.
- **column_id** (*string*) – Coluna identificadora da base de dados.
- **delimiter** (*string*) – Delimitador utilizado no arquivo csv.

calc_posterior_success (*columns_qid*)

Calcula os sucessos determinístico e probabilístico a posteriori.

Parâmetros **columns_qid** (*list of strings*) – Lista de nomes das colunas de valores quaseidentificadores.

Retorna

- **posterior_success_det** (*float*) – Resultado do cálculo de sucesso determinístico a posteriori.
- **posterior_success_prob** (*float*) – Resultado do cálculo de sucesso probabilístico a posteriori.

calc_prior_and_posterior (*columns_qid*)

Centraliza o resultado dos cálculos de sucesso determinístico e probabilístico a priori e a posteriori.

Parâmetros *columns_qid* (*list of strings*) – Lista de nomes das colunas de valores quaseidentificadores.

Retorna

- **prior_success_det** (*float*) – Resultado do cálculo de sucesso determinístico a priori.
- **prior_success_prob** (*float*) – Resultado do cálculo de sucesso probabilístico a priori.
- **posterior_success_det** (*float*) – Resultado do cálculo de sucesso determinístico a posteriori.
- **posterior_success_prob** (*float*) – Resultado do cálculo de sucesso probabilístico a posteriori.

calc_prior_success ()

Calcula os sucessos determinístico e probabilístico a priori.

Retorna

- **prior_success_det** (*float*) – Resultado do cálculo de sucesso determinístico a priori.
- **prior_success_prob** (*float*) – Resultado do cálculo de sucesso probabilístico a priori.

calc_privacy_loss (*columns_qid*)

Centraliza o cálculo de degradação de privacidade para ambos os modelos de degradação determinística e probabilística.

Parâmetros *columns_qid* (*list of strings*) – Lista de nomes das colunas de valores quaseidentificadores.

Retorna *privacy_metrics* – O resultado dos cálculos de degradação determinística e probabilística de privacidade.

Tipo de retorno dict

create_partition (*columns_qid*)

Gera as partições na amostra e na base de dados original de acordo com o conjunto de quaseidentificadores.

Retorna

- **partition_sample** (*pandas.Series*) – Série contendo o número de registros na amostra para cada combinação de valores de Qids.
- **partition_original_db** (*pandas.Series*) – Séries contendo o número de registros na base original para cada combinação de valores de Qids.

get_db_size ()

Calcula a quantidade de memória utilizada pela base de dados original.

Retorna O tamanho da base de dados e a quantidade (em bytes) de memória gasta pela estrutura que contém a base de dados.

Tipo de retorno (int,float)

get_sample_size ()

Calcula a quantidade de memória utilizada pela amostra.

Retorna O tamanho da amostra e a quantidade (em bytes) de memória gasta pela estrutura que contém a amostra.

Tipo de retorno (int,float)

rcuam_attack (*columns_qid*)

Calcula a proporção de indivíduos reidentificados (valor necessário para o cálculo do sucesso determinístico a posteriori) e o sucesso esperado (valor necessário para o cálculo do sucesso probabilístico a posteriori) para um conjunto de quaseidentificadores. O cálculo é feito simultaneamente para aproveitar as partições geradas, necessárias para ambos os cálculos.

Parâmetros **columns_qid** (*list of strings*) – Lista de nomes das colunas de valores quaseidentificadores.

Retorna

- **reidentified_individuals** (*float*) – A fração de indivíduos na amostra que podem ser reidentificados.
- **expected_success** (*float*) – O sucesso esperado para a reidentificação probabilística de indivíduos na amostra.

set_sample (*sample_path, delimiter*)

Altera o arquivo de amostra definido na instanciação.

Parâmetros

- **sample_path** (*string*) – Caminho para o arquivo da amostra.
 - **delimiter** (*string*) – Separador utilizado no arquivo CSV da amostra.
-

Contém as principais funcionalidades para a análise de utilidade.

5.1 `pricelib.utility.utility`

5.1.1 Cálculo da utilidade

`pricelib.utility.utility.tvd(original_db, processed_db, cols)`

Calcula a utilidade baseada na métrica Total Variation Distance de distância entre distribuições. As distribuições podem ser sobre atributos individuais, combinações de atributos ou sobre a base completa.

Parâmetros

- **`original_db`** (*pandas.DataFrame*) – Dataframe contendo a base de dados original.
- **`processed_db`** (*pandas.DataFrame*) – Dataframe contendo a base de dados processada (amostra ou base com ruído LDP).
- **`cols`** (*list*) – Uma lista de colunas cuja distribuição (conjunta) será utilizada para o cálculo de TVD.

Retorna `utility` – Resultado do cálculo de utilidade: 1 - TVD

Tipo de retorno `float`

p

- `pricelib.localdp.data`, 11
- `pricelib.localdp.randomizer`, 14
- `pricelib.localdp.risk`, 17
- `pricelib.localdp.util`, 18
- `pricelib.sampling.risk`, 21
- `pricelib.utility.utility`, 25

B

`BasicEducation` (classe em `pricelib.localdp.data`), 13

C

`calc_posterior_success()` (método `price-lib.sampling.risk.Calculator`), 21

`calc_prior_and_posterior()` (método `price-lib.sampling.risk.Calculator`), 21

`calc_prior_success()` (método `price-lib.sampling.risk.Calculator`), 22

`calc_privacy_loss()` (método `price-lib.sampling.risk.Calculator`), 22

`Calculator` (classe em `pricelib.sampling.risk`), 21

`check_epsilon()` (método de classe `price-lib.localdp.randomizer.Randomizer`), 14

`check_epsilon()` (método de classe `price-lib.localdp.randomizer.RandomizerBasicEducation`), 15

`class_qids_original` (atributo `price-lib.localdp.risk.RCUBasicEducation`), 18

`copy()` (método `pricelib.localdp.data.BasicEducation`), 13

`copy()` (método `pricelib.localdp.data.Data`), 11

`copy()` (método `pricelib.localdp.data.DataFromFile`), 12

`create_partition()` (método `price-lib.sampling.risk.Calculator`), 22

D

`Data` (classe em `pricelib.localdp.data`), 11

`DataFromFile` (classe em `pricelib.localdp.data`), 12

`distance()` (no módulo `pricelib.localdp.util`), 18

F

`file_len()` (no módulo `pricelib.localdp.util`), 18

`fix_dependent_columns()` (método `price-lib.localdp.randomizer.FixerBasicEducation`), 16

`FixerBasicEducation` (classe em `price-lib.localdp.randomizer`), 16

G

`gendistances()` (no módulo `pricelib.localdp.util`), 18

`gensample()` (no módulo `pricelib.localdp.util`), 19

`get_db_size()` (método `price-lib.sampling.risk.Calculator`), 22

`get_header()` (método estático `price-lib.localdp.data.BasicEducation`), 13

`get_header()` (método estático `price-lib.localdp.data.DataFromFile`), 12

`get_sample_size()` (método `price-lib.sampling.risk.Calculator`), 22

`getidx()` (método `price-lib.localdp.data.BasicEducation`), 13

`getidx()` (método `pricelib.localdp.data.Data`), 12

`getidx()` (método `price-lib.localdp.data.DataFromFile`), 12

K

`kml2csv()` (no módulo `pricelib.localdp.util`), 19

M

módulo

`pricelib.localdp.data`, 11

`pricelib.localdp.randomizer`, 14

`pricelib.localdp.risk`, 17

`pricelib.localdp.util`, 18

`pricelib.sampling.risk`, 21

`pricelib.utility.utility`, 25

P

`posterior_success()` (método `price-lib.localdp.risk.RCU`), 17

`posterior_success()` (método `price-lib.localdp.risk.RCUBasicEducation`), 18

`pricelib.localdp.data`

módulo, 11
pricelib.localdp.randomizer
 módulo, 14
pricelib.localdp.risk
 módulo, 17
pricelib.localdp.util
 módulo, 18
pricelib.sampling.risk
 módulo, 21
pricelib.utility.utility
 módulo, 25
prior_success() (método price-
 lib.localdp.risk.RCU), 17
prior_success() (método price-
 lib.localdp.risk.RCUBasicEducation), 18

R

randomise_dataset() (método price-
 lib.localdp.randomizer.Randomizer), 14
randomise_dataset() (método price-
 lib.localdp.randomizer.RandomizerBasicEducation),
 15
Randomizer (classe em pricelib.localdp.randomizer),
 14
RandomizerBasicEducation (classe em price-
 lib.localdp.randomizer), 15
RCU (classe em pricelib.localdp.risk), 17
rcuam_attack() (método price-
 lib.sampling.risk.Calculator), 22
RCUBasicEducation (classe em price-
 lib.localdp.risk), 17

S

set_mechanism() (método price-
 lib.localdp.randomizer.Randomizer), 14
set_mechanism() (método price-
 lib.localdp.randomizer.RandomizerBasicEducation),
 15
set_sample() (método price-
 lib.sampling.risk.Calculator), 23

T

to_csv() (método price-
 lib.localdp.data.BasicEducation), 13
to_csv() (método pricelib.localdp.data.Data), 12
to_csv() (método price-
 lib.localdp.data.DataFromFile), 12
tvd() (no módulo pricelib.utility.utility), 25

TED 8750 - PRICE

PRIVACIDADE NOS CENSOS EDUCACIONAIS

Termo de Execução Descentralizada entre o Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira - Inep e a Universidade Federal de Minas Gerais - UFMG

PRODUTO 05

Relatório técnico final do projeto piloto



Mário S. ALVIM
Ramon G. GONZE
Jeroen van de GRAAF

Igor W. LEMES
Lucas LOPES
Gabriel H. NUNES

05 de fevereiro de 2021

Resumo

O presente documento consiste em um *Relatório técnico final do projeto piloto*, previsto como Produto 05 no plano de trabalho do Termo de Execução Descentralizada (TED) 8750. Este TED foi firmado entre o Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira (Inep) e a Universidade Federal de Minas Gerais (UFMG), e encontra-se em execução pelo Laboratório Inscript (*Laboratory of Information Security, Cryptography, Privacy, and Transparency*) do Departamento de Ciência da Computação (DCC) da Universidade.

Neste documento apresentamos várias **análises experimentais quantitativas sobre a privacidade e a utilidade** de dados providas pelos **dois métodos de sanitização** selecionados pelo Inep para o projeto piloto deste TED: **amostragem** e **privacidade diferencial local**. As análises foram realizadas sobre os dados do **Censo da Educação Básica de 2019**. Em todas elas consideramos como informação auxiliar para o adversário atributos cujos valores sejam presumivelmente conhecidos, ou possam ser facilmente descobertos, em geral por serem informação pública ou considerada inofensiva (e.g., a idade de um aluno, seu sexo ou dados sobre sua entidade de ensino).

Mais precisamente, quantificamos a degradação de privacidade sob as seguintes condições:

1. **Ataques de reidentificação coletiva sobre uma única base de dados sanitizada por desidentificação e pseudonimização.** Tais técnicas são as atualmente empregadas pelo Inep na divulgação dos dados dos Censos Educacionais. As análises levam em conta a restrição no número e granularidade de atributos divulgados determinada pelo Inep para o presente projeto piloto e servem de base de comparação para as demais técnicas de sanitização avaliadas neste documento.
2. **Ataques de reidentificação coletiva sobre uma única base sanitizada por amostragem.** O plano amostral utilizado foi desenhado pelo Inep.
3. **Ataques de reidentificação coletiva sobre uma única base sanitizada por privacidade diferencial local.** Empregamos o método padrão na literatura, em que atributos são sanitizados de forma independente. Dado o prazo deste projeto piloto, foi realizada uma exploração apenas preliminar do vasto espaço de valores possíveis para os parâmetros de privacidade do método.

Além disso, provemos uma **análise comparativa da privacidade e utilidade atingidas por cada método de sanitização empregado**. Adotamos a métrica de propósito geral de **utilidade estatística**, que mede a similaridade entre a distribuição de probabilidade sobre atributos antes e após a sanitização. Destacamos os seguintes pontos.

- A sanitização por amostragem reduziu significativamente a degradação determinística de privacidade, mas teve pouco efeito na degradação probabilística. O resultado está em conformidade com o conhecimento da literatura técnica: a amostragem diminui o número absoluto de indivíduos expostos a risco, entretanto aqueles presentes na amostra ainda podem estar sujeitos a graves violações. Por outro lado, a amostragem demonstrou uma manutenção razoável da utilidade estatística.
- A sanitização por privacidade diferencial local praticamente eliminou a degradação probabilística de privacidade. (a ela não se aplicam análises determinísticas). Por outro lado, o método em sua forma atual apresentou um custo elevado –e potencialmente proibitivo– na utilidade estatística dos dados divulgados. Os resultados confirmam o conhecimento da literatura técnica: na maioria dos casos um trabalho longo e laborioso de ajuste de parâmetros e técnicas normalmente é necessário para se atingir o potencial máximo de utilidade da privacidade diferencial local.

Os resultados encontrados evidenciam a **inviabilidade da manutenção no curto prazo da divulgação de microdados dos Censos Educacionais de forma privada e útil**. Tal constatação está em consonância com a literatura técnica e constitui uma contribuição central deste projeto piloto. Primeiramente, ela provê ao Inep informação crucial para tomadas de decisões futuras, balanceando **soluções de curto prazo** –implementáveis de forma relativamente rápida, mas potencialmente sub-ótimas quanto à utilidade provida– e **soluções de longo prazo** –mais úteis, porém que demandem maior investimento de tempo e pessoal especializado. Em segundo lugar, subsidia uma **comunicação efetiva com as partes interessadas** sobre os desafios técnicos na divulgação de microdados, facilitando a compreensão sobre eventuais decisões futuras.

Os resultados obtidos foram naturalmente impactados pelo **exíguo prazo** disponível para adequação da divulgação de microdados dos Censos Educacionais à **LGPD**. Entretanto, não se deve concluir que não há solução possível para divulgação dos dados dos Censos de forma privada e com razoável utilidade, mas sim que é necessária uma **criteriosa ponderação sobre passos futuros**. Neste sentido, identificamos duas alternativas:

- **Alternativa 1:** Abandono da divulgação de microdados –exceto em salas seguras– em favor da divulgação de dados agregados sanitizados por privacidade diferencial. Conforme plano de ação proposto no Produto 03 deste TED 8750, avaliamos esta opção como a mais promissora para os Censos Educacionais do Inep.
- **Alternativa 2:** Desenvolvimento de um método de sanitização de microdados por privacidade diferencial local desenhado e refinado especificamente para Censos Educacionais. Esta opção demandaria tempo e recursos significativamente maiores, incluindo atividades de pesquisa e desenvolvimento.

Sumário

1	Introdução	1
1.1	Objetivo deste documento	1
1.2	Contextualização	2
1.3	Contribuições deste documento	4
1.4	Organização deste documento	5
2	Conceitos fundamentais	7
2.1	Privacidade	7
2.2	Métodos de mitigação de degradação à privacidade	14
2.3	Utilidade	16
2.4	Modelo de bases de dados, registros e atributos	17
3	Configuração dos experimentos deste projeto piloto	21
3.1	Tratamento dos conjuntos de dados fornecidos pelo Inep	21
3.2	Criação de uma base nacional e uma base restrita ao Distrito Federal	24
3.3	Especificação do conhecimento auxiliar do adversário	25
4	Análise de privacidade após sanitização por desidentificação e pseudo-nimização	28
4.1	Ataque em uma única base de dados sanitizada apenas por anonimização e pseudonimização	29
4.1.1	Ataque de reidentificação coletiva em uma única base de dados sanitizada apenas por desidentificação e pseudonimização (RCU)	29
4.1.1.1	Premissas	29
4.1.1.2	Descrição do ataque	30

4.1.2	Considerações sobre riscos de inferência de atributo sensível	34
4.2	Resultados de ataques de reidentificação coletiva em uma única base de dados sanitizada por desidentificação e pseudonimização (RCU)	34
5	Análise de privacidade após sanitização por amostragem	38
5.1	Fundamentos da sanitização de microdados por amostragem	38
5.2	Modelo de sanitização por amostragem empregado neste projeto piloto . .	39
5.3	Modelo de degradação de privacidade em uma única base de dados sanitizada por amostragem	39
5.3.1	Ataque de reidentificação coletiva em uma única base de dados sanitizada por amostragem (RCU^{ams})	40
5.3.1.1	Premissas	40
5.3.1.2	Descrição do ataque	41
5.3.2	Considerações sobre riscos de inferência de atributo sensível	47
5.4	Resultados de ataques de reidentificação coletiva em uma única base de dados sanitizada por privacidade diferencial local (RCU^{ams})	47
6	Análise de privacidade após sanitização por privacidade diferencial local	51
6.1	Fundamentos da sanitização de microdados por privacidade diferencial local	51
6.2	Aplicação de privacidade diferencial local no exemplo condutor	53
6.3	Modelo de degradação de privacidade em uma única base de dados sanitizada por privacidade diferencial local	58
6.3.1	Ataque de reidentificação coletiva em uma única base de dados sanitizada por privacidade diferencial local ($\widehat{RCU}^{ldp}$)	59
6.3.1.1	Premissas	60
6.3.1.2	Descrição do ataque	62
6.3.2	Considerações sobre riscos de inferência de atributo sensível	70
6.4	Método de sanitização por privacidade diferencial local empregado neste projeto piloto	72
6.5	Resultados de ataques de reidentificação coletiva em uma única base de dados sanitizada por privacidade diferencial local ($\widehat{RCU}^{ldp}$)	78

7	Análise comparativa de privacidade e utilidade após cada método de sanitização empregado	81
7.1	Sumário comparativo da degradação de privacidade dos métodos de mitigação analisados	81
7.2	Sumário comparativo da utilidade dos métodos de mitigação analisados . .	87
7.2.1	Modelo de utilidade empregado	87
7.2.2	Resultados da análise experimental de utilidade	93
8	Considerações finais	97
	Referências Bibliográficas	103
	Anexos	109
A	Formalização matemática de privacidade diferencial local	110
A.1	Definição formal de privacidade diferencial- ϵ local	110
A.2	Mecanismos para se atingir privacidade diferencial- ϵ local	111
A.3	Propriedades da privacidade diferencial- ϵ	112
A.4	Exemplo de negação plausível em resposta aleatorizada	113
A.5	Exemplo do compromisso entre privacidade vs. utilidade em privacidade diferencial- ϵ local	115
B	Formalização de ataque de reidentificação coletiva sobre uma única base de dados sanitizada por desidentificação e pseudonimização (RCU)	119
C	Formalização de ataque de reidentificação coletiva sobre uma única base de dados sanitizada por amostragem (RCU^{ams})	123
D	Formalização de ataque de reidentificação coletiva sobre uma única base de dados sanitizada por privacidade diferencial local ($\widehat{RCU}^{ldp}$)	128
E	Histogramas das distribuições conjuntas de atributos antes e após mitigação	134
F	Desafios no uso de sanitização por privacidade diferencial no Censo Decenal de 2020 dos EUA	141
F.1	Desafios encontrados na implementação da privacidade diferencial	142

Lista de Siglas	145
------------------------	------------

Glossário	146
------------------	------------

Lista de Tabelas

2.4.1	Exemplo 1: Base de dados D utilizada no exemplo condutor.	19
3.1.1	Experimentos 8 e 12: Atributos da base do Censo da Educação Básica de 2019 selecionados pelo Inep para divulgação em cada estudo de caso. .	23
3.3.2	Experimentos 8 e 12: Atributos usados como quaseidentificadores, selecionados a partir da Base do Censo da Educação Básica de 2019.	27
4.2.2	Experimento 5: Resultados de ataques de reidentificação coletiva em uma única base de dados sanitizada por desidentificação e pseudonimização (RCU), sobre o Censo da Educação Básica de 2019.	37
5.3.2	Exemplo 6: Ataque de reidentificação coletiva em uma única base sanitizada por amostragem (RCU^{ams}) sobre o exemplo condutor.	46
5.4.3	Experimento 8: Resultados de ataques de reidentificação coletiva em uma única base de dados sanitizada por amostragem (RCU^{ams}), sobre a base amostral do Censo da Educação Básica de 2019.	50
6.2.2	Exemplo 9: Sanitização por privacidade diferencial local aplicada ao exemplo condutor.	54
6.2.3	Exemplo 9: Mecanismos de sanitização por privacidade diferencial local para cada atributo do exemplo condutor.	57
6.3.5	Exemplo 10: Ataque de reidentificação coletiva em uma única base sanitizada por privacidade diferencial local ($\widehat{RCU}^{ldp}$) sobre o exemplo condutor. .	67
6.3.6	Exemplo 10: Computação da verossimilhança aproximada de cada registro original do arquivo auxiliar ter gerado cada registro sanitizado no exemplo condutor.	68
6.3.7	Exemplo 10: Identificação dos valores de quaseidentificadores mais verossímeis para cada registro-alvo e do correspondente conjunto de indivíduos candidatos à reidentificação no exemplo condutor.	69

6.4.8	Tratamento aplicado a cada atributo da base do Censo da Educação Básica de 2019 na sanitização por privacidade diferencial local.	77
6.5.10	Experimento 12: Resultados de ataques de reidentificação coletiva em uma única base de dados sanitizada por privacidade diferencial local ($\widehat{RCU}^{ldp}$), sobre a base do Censo da Educação Básica de 2019 restrita a registros do Distrito Federal.	80
7.1.1	Experimentos 5, 8 e 12: Quadro-resumo do sucesso determinístico de ataques de reidentificação coletiva RCU, RCU^{ams} e $\widehat{RCU}^{ldp}$ sobre a base do Censo da Educação Básica de 2019 sanitizada por diferentes métodos.	83
7.1.2	Experimentos 5, 8 e 12: Quadro-resumo do sucesso determinístico de ataques de reidentificação coletiva RCU, RCU^{ams} e $\widehat{RCU}^{ldp}$ sobre a base do Censo da Educação Básica de 2019 restrita a registros do Distrito Federal e sanitizada por diferentes métodos.	84
7.1.3	Experimentos 5, 8 e 12: Quadro-resumo do sucesso probabilístico de ataques de reidentificação coletiva RCU, RCU^{ams} e $\widehat{RCU}^{ldp}$ sobre a base do Censo da Educação Básica de 2019 sanitizada por diferentes métodos.	85
7.1.4	Experimentos 5, 8 e 12: Quadro-resumo do sucesso probabilístico de ataques de reidentificação coletiva RCU, RCU^{ams} e $\widehat{RCU}^{ldp}$ sobre a base do Censo da Educação Básica de 2019 restrita a registros do Distrito Federal e sanitizada por diferentes métodos.	86
7.2.5	Exemplo 15: Utilidade estatística para várias combinações conjuntas de atributos após emprego da sanitização por amostragem no exemplo condutor.	89
7.2.7	Exemplo 16: Utilidade estatística para várias combinações conjuntas de atributos após emprego da sanitização por privacidade diferencial local no exemplo condutor.	91
7.2.9	Experimentos 8 e 12: Quadro-resumo da utilidade estatística medida para estudos de caso envolvendo a base do Censo da Educação Básica de 2019.	95
7.2.10	Experimentos 8 e 12: Quadro-resumo da utilidade estatística medida para estudos de caso envolvendo a base do Censo da Educação Básica de 2019 restrita aos registros do Distrito Federal.	96
A.1	Exemplo 23: Resultado de uma pesquisa sobre uso de drogas ilícitas usando a técnica de reposta aleatorizada.	114
A.3	Exemplo 23: Probabilidade condicional de cada resposta dado se o indivíduo é mesmo usuário de drogas ou não, em função do viés b da primeira moeda.	116

Lista de Definições

13	Distância de variação total	87
14	Utilidade estatística de uma base sanitizada em relação a um conjunto de atributos	88
17	Privacidade diferencial- ε (local)	110
18	Mecanismo geométrico truncado local	111
19	Mecanismo de reposta aleatorizada k -RR	112
25	Ataque de reidentificação coletiva em uma única base de dados sanitizada por desidentificação e pseudonimização (RCU)	119
26	Ataque de reidentificação coletiva em uma única base de dados sanitizada por amostragem (RCU^{ams})	123
27	Ataque de reidentificação coletiva em uma única base de dados sanitizada por privacidade diferencial local ($\widehat{RCU}^{ldp}$)	128

Lista de Exemplos

1	Exemplo condutor para ataques em uma única base de dados	18
2	Distribuição de probabilidade marginal sobre um subconjunto de atributos	20
3	Execução de ataque de reidentificação coletiva em uma única base de dados sanitizada por desidentificação e pseudonimização (RCU)	31
4	Inferência de atributo sensível após reidentificação exitosa em uma única base de dados sanitizada por desidentificação e pseudononimização	34
6	Execução de ataque de reidentificação coletiva em uma única base de dados sanitizada por amostragem (RCU^{ams})	43
7	Inferência de atributo sensível após reidentificação exitosa em uma única base de dados sanitizada por amostragem	47
9	Aplicação de privacidade diferencial- ϵ local no exemplo condutor	53
10	Execução de ataque de reidentificação coletiva em uma única base de dados sanitizada por privacidade diferencial local ($\widehat{RCU}^{ldp}$)	63
11	Inferência de atributo sensível após reidentificação exitosa em uma única base de dados sanitizada por privacidade diferencial local	70
15	Utilidade estatística da sanitização por amostragem aplicada ao exemplo condutor	88
16	Utilidade estatística da sanitização por privacidade diferencial local aplicada ao exemplo condutor	91
23	Reposta aleatorizada aplicada a uma pesquisa sobre uso de drogas ilícitas	113
24	O compromisso entre privacidade vs. utilidade em privacidade diferencial local	115

Lista de Experimentos

5	Ataques de reidentificação coletiva sobre uma única base sanitizada por desidentificação e pseudonimização RCU, sobre o Censo da Educação Básica de 2019	34
8	Ataques de reidentificação coletiva sobre uma única base sanitizada por amostragem RCU^{ams} , sobre o Censo da Educação Básica de 2019	47
12	Ataques de reidentificação coletiva sobre uma única base sanitizada por privacidade diferencial local $\widehat{RCU}^{ldp}$, sobre o Censo da Educação Básica de 2019	78

1 Introdução

Este documento consiste no Produto 05, intitulado *Relatório técnico final do projeto piloto*, do plano de trabalho do Termo de Execução Descentralizada (TED) 8750, firmado entre o Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira (Inep) e a Universidade Federal de Minas Gerais (UFMG), e em execução pelo Laboratório Inscript (*Laboratory of Information Security, Cryptography, Privacy, and Transparency*) do Departamento de Ciência da Computação (DCC) da Universidade.

1.1 Objetivo deste documento

De acordo com o plano de trabalho do TED 8750, o Produto 05 que este documento implementa consiste em um:

Relatório técnico apresentando os resultados do projeto piloto, mudanças e replanejamento do plano de execução inicial, comparação entre os métodos testados, lições aprendidas, nível de atendimento ao escopo e aos objetivos definidos para a aplicação.

Mais especificamente, em conjunto com o Produto 04, visa-se a atender ao Objetivo Específico 05 do plano de trabalho:

Desenvolver e implantar um processo computacional baseado em até dois métodos de controle de divulgação escolhidos pelo Inep dentre aqueles elencados pelo DCC/UFMG no item anterior, como forma de aprimorar sua atual política de disseminação de microdados educacionais. Este processo deverá respeitar o ambiente tecnológico de infraestrutura e de sistemas existente no Inep e considerar, dentre as bases de dados dos Censos Educacionais, a que melhor se adequa aos objetivos de complexidade necessários para a realização de uma aplicação piloto dos métodos escolhidos. O objetivo do teste de conceito é apresentar os resultados da aplicação prática, quando será possível observar os resultados e identificar a sua aderência às necessidades iniciais.

1.2 Contextualização

Para fins de proteção de privacidade, a atual forma de divulgação dos microdados dos Censos Educacionais pelo Inep utiliza apenas as técnicas de *desidentificação*, em que se removem possíveis identificadores individuais óbvios dos registros (como nome, CPF, RG) e de *pseudonimização*, em que tais identificadores individuais óbvios são substituídos por um código único de identificação artificialmente criado.

No Produto 02 deste TED 8750, provemos extensivas análises quantitativas experimentais que demonstraram de forma inequívoca que esta abordagem submete os titulares dos dados a sérios e generalizados riscos de violação de privacidade, em especial aos de reidentificação e de inferência de atributos sensíveis. Como já expressamos anteriormente, em nossa visão esta situação poderia constituir em uma violação da Lei Geral de Proteção de Dados Pessoais (LGPD) [22].

De fato, o objetivo do presente TED 8750 é justamente investigar métodos de tratamento de dados adequados para mitigar a degradação de privacidade causada pelas divulgações dos Censos Educacionais do Inep. A área de pesquisa que se ocupa deste tipo de questão é conhecida como *controle de divulgação estatística* (*statistical disclosure control*, no original em inglês). Seu foco é encontrar maneiras de compartilhar publicamente informações sobre um conjunto de dados, revelando padrões estatísticos a respeito dos mesmos ao mesmo tempo em que se protegem informações sensíveis sobre os indivíduos no conjunto de dados. Um desafio crucial desta área é encontrar métodos de mitigação de degradação de privacidade que mantenham um equilíbrio adequado entre:

- a garantia de *privacidade* aos titulares dos dados contra *adversários*, i.e., pessoas ou entidades que podem inferir informação sensível a respeito dos titulares; e
- a manutenção da *utilidade* dos dados com relação aos *analistas*, i.e., consumidores legítimos dos dados.

Segundo os especialistas em privacidade em dados médicos Divanis e Loukides [31], não existe uma solução única que funcione em todos os casos, e, apesar dos avanços científicos, vários desafios ainda permanecem. Qualquer abordagem deve considerar todo o ciclo de vida dos dados, desde sua coleta, comunicação, acesso por terceiros, e divulgação.

Neste contexto, no Produto 03 do presente TED 8750 provemos um parecer técnico sobre a adequação de variadas técnicas de mitigação de danos à privacidade aos Censos Educacionais do Inep. Em particular, consideramos que a LGPD prevê garantias de privacidade individualmente a cada titular de dados –em especial, contra reidentificação– que devem ser atendidas pelos Censos Educacionais. Também consideramos que qualquer método adotado devesse manter a maior utilidade possível para os analistas e consumidores dos dados dos Censos.

À época observamos que o Inep dispunha de um prazo exíguo para implementação de uma solução coerente com a nova legislação. Sugerimos, então, a adoção de uma solução

emergencial de curto prazo que garantisse a privacidade dos titulares –mesmo que fosse possivelmente sub-ótima em relação à utilidade provida aos analistas (ou vice-versa)–, enquanto elaborar-se-ia uma alternativa de longo prazo que fornecesse um melhor custo-benefício na relação entre privacidade e utilidade.

O plano emergencial proposto na ocasião consistia, essencialmente, em eliminar imediatamente a divulgação de microdados sob qualquer forma que não fosse via salas seguras (físicas ou virtuais) e oferecer apenas informações agregadas (sumários estatísticos ou histogramas) em canais públicos de comunicação, protegidos por privacidade diferencial. Uma vez assegurado o nível de privacidade individual dos dados demandado pela LGPD (obtido nos passos anteriores), proceder-se-ia a um estudo aprofundado de como aumentar a utilidade das divulgações enquanto manter-se-ia a privacidade conquistada. Tal aumento gradual da utilidade dos dados visaria a satisfazer a um número cada vez maior de analistas, o que poderia contribuir para arrefecer a demanda suplementar por acesso a salas seguras eventualmente causada pela implementação da solução emergencial.

Várias reuniões foram realizadas entre a equipe executora e o Inep para discutir o parecer provido no Produto 03. Após deliberação, o Inep optou por não considerar divulgação de dados agregados no presente momento, mantendo o escopo do presente TED 8750 centrado no estudo de técnicas de divulgação de microdados. Mais especificamente, o Inep escolheu como objeto de análise do presente projeto piloto as seguintes duas técnicas de sanitização de microdados:

- *sanitização por amostragem não-perturbativa*; e
- *sanitização por privacidade diferencial- ϵ local*.

Além disso, fixou-se como dados de estudo a base do Censo da Educação Básica de 2019.

A motivação para sanitização por amostragem é a expectativa de que o adversário, não tendo certeza da presença de um indivíduo-alvo na base divulgada, teria mais dificuldades em reidentificar registros. Isto supostamente levaria a maior privacidade para os titulares dos dados.

A motivação central por trás da privacidade diferencial local é que uma cuidadosa introdução de ruído em cada registro produz no adversário um nível de incerteza sobre os valores reais dos atributos divulgados, assim como sobre se um indivíduo alvo estaria ou não na base. Como consequência, o titular pode negar de forma plausível que qualquer de seus atributos tenha um valor específico, mesmo no pior caso em que seu registro tenha sido reidentificado e o adversário tenha tido acesso aos valores sanitizados divulgados. O nível de ruído introduzido é controlado pelo valor do parâmetro de privacidade ϵ : quanto menor este valor, mais privados são os dados, porém corre-se o risco de que o ruído adicionado prejudique a utilidade dos mesmos.

No presente documento apresentamos várias análises experimentais quantitativas sobre a privacidade e a utilidade de dados providas pelos dois métodos de sanitização selecionados pelo Inep para o presente projeto piloto.

1.3 Contribuições deste documento

Neste documento apresentamos várias análises experimentais quantitativas sobre a privacidade e a utilidade de dados providas pelos dois métodos de sanitização selecionados pelo Inep para o presente projeto piloto: amostragem e privacidade diferencial local. As análises foram realizadas sobre os dados do Censo da Educação Básica de 2019. Em todas elas consideramos como informação auxiliar para o adversário atributos cujos valores sejam presumivelmente conhecidos, ou possam ser facilmente descobertos, em geral por serem informação pública ou considerada inofensiva (e.g., a idade de um aluno, seu sexo ou dados sobre sua entidade de ensino).

Listamos a seguir as principais contribuições deste documento.

1. **Extensas análises quantitativas experimentais da degradação de privacidade dos métodos de sanitização por amostragem e privacidade diferencial local.** As análises englobam os seguintes ataques.
 - Ataques de reidentificação coletiva sobre uma única base de dados (RCU) sanitizada por desidentificação e pseudonimização. Tais técnicas são as atualmente empregadas pelo Inep na divulgação dos dados dos Censos Educacionais. As análises levam em conta a restrição no número e granularidade de atributos divulgados determinada pelo Inep para o presente projeto piloto e servem de base de comparação para as demais técnicas de sanitização avaliadas neste documento.
 - Ataques de reidentificação coletiva sobre uma única base sanitizada por amostragem (RCU^{ams}). O plano amostral utilizado foi desenhado pelo Inep.
 - Ataques de reidentificação coletiva sobre uma única base sanitizada por privacidade diferencial local ($\widehat{RCU}^{ldp}$). Empregamos o método padrão na literatura, em que atributos são sanitizados de forma independente. Dada o prazo deste projeto piloto, foi realizada uma exploração apenas preliminar do vasto espaço de valores possíveis para os parâmetros de privacidade do método.
2. **Uma análise comparativa da privacidade e utilidade atingidas por cada método de sanitização empregado.** Como medida de utilidade, adotamos a métrica de propósito geral de utilidade estatística, que mede a similaridade entre a distribuição de probabilidade sobre atributos antes e após a sanitização.
3. **Uma discussão da nossa visão de futuro e alternativas identificadas para o tratamento dos Censos Educacionais.** Tal discussão leva em conta o contexto do presente projeto, os atores envolvidos, e as descobertas técnicas apresentadas nos produtos entregues até o momento no presente TED 8750.

1.4 Organização deste documento

O restante deste documento está organizado da seguinte forma.

- **Conceitos fundamentais** (Seção 2): Nesta seção apresentamos a fundamentação teórica que serve de base para este documento, incluindo conceitos sobre privacidade, métodos de mitigação de degradação de privacidade, e utilidade de dados.
- **Configuração dos experimentos deste projeto piloto** (Seção 3): Nesta seção descrevemos as configurações comuns aos vários experimentos executados neste projeto piloto e descritos nas seções seguintes.
- **Análise de privacidade após sanitização por desidentificação e pseudonimização** (Seção 4): Nesta seção refazemos parte da análise de privacidade sobre o Censo da Educação Básica de 2019, usando o conjunto restrito de atributos selecionado pelo Inep para o presente projeto piloto. A nova análise ainda é aplicada sobre a base do Censo em sua atual forma de divulgação (i.e., tratada apenas por desidentificação e pseudonimização de registros). Os resultados servem de base de comparação para as demais técnicas de sanitização testadas no presente projeto piloto.
- **Análise de privacidade após sanitização por amostragem** (Seção 5): Nesta seção apresentamos as análises experimentais quantitativas da degradação de privacidade decorrente da aplicação de sanitização por amostragem à base do Censo da Educação Básica de 2019.
- **Análise de privacidade após sanitização por privacidade diferencial local** (Seção 6): Nesta seção apresentamos as análises experimentais quantitativas da degradação de privacidade decorrente da aplicação de sanitização por privacidade diferencial local à base do Censo da Educação Básica de 2019.
- **Análise comparativa de privacidade e utilidade após cada método de sanitização empregado** (Seção 7): Nesta seção provemos sumários comparativos do nível de privacidade e de utilidade atingido por cada método de sanitização considerado no presente projeto piloto.
- **Considerações finais** (Seção 8): Nesta seção apresentamos as considerações finais deste documento, incluindo uma seleção de destaques das lições aprendidas com a execução do presente projeto piloto e uma discussão sobre visão de futuro e alternativas identificadas.
- **Anexos**: Apresentamos aqui o seguinte material suplementar.
 - **Formalização matemática de privacidade diferencial local** (Anexo A)

- Formalização de ataque de reidentificação coletiva sobre uma única base de dados sanitizada por desidentificação e pseudonimização (RCU) (Anexo B)
- Formalização de ataque de reidentificação coletiva sobre uma única base de dados sanitizada por amostragem (RCU^{ams}) (Anexo C)
- Formalização de ataque de reidentificação coletiva sobre uma única base de dados sanitizada por privacidade diferencial local ($\widehat{RCU}^{ldp}$) (Anexo D)
- Histogramas das distribuições conjuntas de atributos antes e após mitigação (Anexo E)
- Desafios no uso de sanitização por privacidade diferencial no Censo Decenal de 2020 dos EUA (Anexo F)

2 Conceitos fundamentais

Nesta seção apresentamos a fundamentação teórica que serve de base para este documento. Parte dos tópicos aqui apresentados foram cobertos em produtos anteriores do presente TED 8750, mas os repetimos aqui para tornar o presente produto tão autocontido quanto possível. Em particular, apresentamos conceitos essenciais sobre privacidade, sobre métodos de mitigação de degradação de privacidade, e medidas da utilidade dos dados após o tratamento. Por fim, apresentamos o modelo de bases de dados que será utilizado nas seções seguintes.

2.1 Privacidade

Iniciamos nossa formalização relembrando o significado técnico preciso de alguns termos da literatura sobre proteção à privacidade [25, 57, 15, 17, 18, 45, 19, 41, 27, 31, 55] usados recorrentemente neste documento. Uma introdução unificada a todos estes termos é provida em [24, 7].

A fim de garantir que o conteúdo do presente documento seja tão autocontido quanto possível, repetimos aqui algumas definições já apresentadas em documentos anteriores do presente TED 8750.

Conceitos básicos sobre controle de divulgação estatística A seguir introduzimos os conceitos essenciais da área.

- **Controle de divulgação estatística** é a área que estuda como compartilhar publicamente informações sobre um conjunto de dados, revelando padrões estatísticos a respeito dos mesmos enquanto protege informações sensíveis sobre os indivíduos no conjunto de dados. O controle de divulgação estatística deve balancear a manutenção da utilidade dos dados (com relação a um analista legítimo) com garantias de privacidade para os titulares dos dados (contra um adversário).
- **Curador de dados** é a pessoa ou entidade responsável pela integração de dados coletados de várias fontes, além da organização, publicação e apresentação dos

dados de forma que o valor dos mesmos seja mantido ao longo do tempo e que os dados permaneçam disponíveis para reutilização e preservação. A curadoria de dados inclui “todos os processos necessários para a criação, manutenção e gerenciamento de dados controlados e com princípios, juntamente com a capacidade de agregar valor aos dados” [52].

No contexto do presente projeto, o Inep é o curador dos dados de seus Censos Educacionais.

- **Analista de dados** é a pessoa ou entidade considerada como usuária legítima de uma divulgação de dados.

No contexto do presente projeto, todo o público que tem acesso às divulgações dos Censos Educacionais é considerado analista de dados, incluindo pesquisadores, demógrafos, entidades civis e governamentais.

- **Titular de dados** é a pessoa ou entidade a quem os dados coletados, processados ou divulgados se referem diretamente.

No contexto do presente projeto, seriam titulares de dados estudantes e professores, por exemplo.

- **Utilidade** é a propriedade de uma divulgação servir aos propósitos legítimos do analista de dados, provendo a ele a informação desejada.

No contexto do presente projeto, a utilidade dos Censos Educacionais está atrelada à capacidade do analista de inferir informações estatísticas a respeito de estudantes, escolas, docentes, etc., representados nas pesquisas.

- **Informação sensível (ou segredo)** é aquela considerada como digna de proteção. Exemplos típicos de informação sensível incluem dados pessoais de um indivíduo (e.g., seu número de cartão de crédito, senha bancária ou condição médica), mas outros tipos de valores podem ser considerados sensíveis, como a própria identidade do indivíduo (e.g., caso o anonimato do remetente de uma mensagem seja importante, como em denúncias jornalísticas ou em países sujeitos a forte censura governamental) ou o território específico de circulação no qual pessoas em programas de proteção a testemunhas podem ser acessíveis.

No contexto brasileiro, a LGPD [22], em seu Artigo 5º, inciso II, define como *dado pessoal sensível* todo aquele “dado pessoal sobre origem racial ou étnica, convicção religiosa, opinião política, filiação a sindicato ou a organização de caráter religioso, filosófico ou político, dado referente à saúde ou à vida sexual, dado genético ou biométrico, quando vinculado a uma pessoa natural”.

Neste documento nos focamos nos seguintes tipos de informação sensível ou segredo:

- a *ligação de um registro na base de dados a seu titular*, que é a informação sensível relevante em um ataque de reidentificação; e

- o *valor de um atributo sensível de um indivíduo*, que é a informação sensível relevante em um ataque de inferência de atributo.

- **Adversário** é a entidade contra a qual se deseja proteger a informação sensível sobre indivíduos. O adversário pode ser uma pessoa física ou uma organização. É importante notar que não necessariamente se atribuem intenções deletérias ao adversário: é possível que um analista legítimo de uma divulgação estatística (e.g., um pesquisador acadêmico) atue inadvertidamente como adversário ao inferir informação sensível de indivíduos no decurso de suas ações idôneas.

No contexto do presente projeto, por se tratar de um problema de controle de divulgação estatística, em princípio qualquer analista de dados pode ser um adversário em potencial, seja intencionalmente (e.g., uma agência de empregos que tenta inferir a partir dos dados dos Censos Educacionais se um candidato a uma vaga possui ou não alguma forma de deficiência a fim de negar-lhe emprego), seja não intencionalmente (e.g., um pesquisador que inadvertidamente descobre o paradeiro de um estudante ou docente participante de um programa de proteção a testemunhas).

- **Ataque** é uma ação ou conjunto de ações pelas quais o adversário pode obter informação sensível sobre indivíduos. É importante notar que também ao termo “ataque” não se atribui uma intenção necessariamente deletéria: uma utilização legítima dos dados (e.g., para pesquisa científica) pode resultar inadvertidamente em um ataque se porventura revelar informação sensível.
- **Informação auxiliar ou lateral** é qualquer informação que, em relação a uma divulgação de dados de interesse, possa ser obtida a respeito de um indivíduo através de outros canais que não sejam a divulgação de dados de interesse em si mesma (e.g., via *web*, outros registros públicos, mídia conhecimento prévio). Um exemplo de obtenção de informação auxiliar por parte do adversário ocorre quando ele consegue via outras fontes (e.g., um cartório) o valor de atributos de indivíduo que podem auxiliar em um ataque (e.g., sua data de nascimento).
- **Negação plausível** (*plausible deniability*, no original em inglês) é a capacidade de um titular de dados negar de forma crível para um adversário alguma propriedade sobre sua informação sensível (e.g., negar sua participação em um estudo, ou que um de seus atributos tenha um valor específico), mesmo após um ataque. A possibilidade de negação plausível é essencial para convencer indivíduos a participar honestamente –i.e., sem mentir– de pesquisas que envolvam o fornecimento de informação sensível [26]. Métricas de privacidade são baseadas na quantificação do nível de negação plausível de que os titulares gozam.

Tipos de risco à privacidade De acordo com o tipo de informação considerada sensível em um contexto, os riscos à privacidade podem ser agrupados como a seguir [27, 31, 55].

- **Risco de reidentificação** (*record linkage* ou *deanonymization*, no original em inglês) é aquele de que o adversário determine uma correspondência entre registros presentes na base de dados e os titulares desses registros, i.e., os indivíduos do mundo real a quem os registros se referem.
- **Risco de inferência de atributo sensível** (*attribute linkage*, no original em inglês) é aquele de que o adversário infira o valor assumido por um atributo considerado como sensível para alguns indivíduos, independentemente de se esses indivíduos tenham sido reidentificados com sucesso ou não.
- **Risco de inferência de pertinência** (*table linkage*, no original em inglês) é aquele de que o adversário consiga determinar se um grupo de indivíduos está ou não representado em uma base de dados. Este risco é particularmente importante quando a própria presença na base de dados é considerada informação sensível, por exemplo, quando se trata de uma base de dados contendo apenas pacientes com uma condição médica rara.

No caso dos Censos Educacionais do Inep, focamos nos dois primeiros tipos de risco, reidentificação e inferência de atributo sensível. O Produto 02 do presente TED 8750 provê uma extensa avaliação quantitativa destes riscos nos Censos Educacionais em sua atual forma de divulgação.

Não nos focamos no terceiro tipo de risco, uma vez que a presença ou ausência, em si mesma, de um indivíduo em uma base dos Censos Educacionais não constitui, em princípio, em informação significantemente sensível.

Classificação de atributos Muitas técnicas de proteção à privacidade baseadas em divulgação de microdados cobertas neste documento utilizam a seguinte classificação de atributos individuais [27, 31].

- **Identificadores diretos** são atributos que podem identificar unicamente um indivíduo, como nome, RG, CPF ou número de telefone celular.
- **Quaseidentificadores** são atributos que não são, em si mesmos, identificadores únicos de um indivíduo (como nome, CPF ou RG), mas que estão suficientemente correlacionadas com o titular a ponto de poderem ser combinadas com outros quaseidentificadores para criar um identificador exclusivo. Por exemplo, Sweeney demonstrou em 2000 que o *zip-code* (o equivalente americano ao CEP brasileiro), o gênero e a data de nascimento de um indivíduo são quaseidentificadores poderosos, uma vez que 87% da população dos EUA poderia ser unicamente identificada usando-se apenas estes três atributos combinados [58].
- **Atributos sensíveis** são atributos cujos valores são considerados dignos de proteção. Exemplos típicos incluem a senha bancária de um indivíduo ou sua condição médica, mas podem também conter informação considerada digna de proteção dentro de um contexto, como etnia ou orientação sexual.

- **Atributos não sensíveis** são atributos cujos valores não são considerados dignos de proteção em si mesmos em um dado contexto, como possivelmente a idade ou altura de um indivíduo em algumas situações.

É importante ressaltar que a classificação de atributos nas categorias acima dependem diretamente do cenário de interesse. Uma informação considerada sensível em um contexto pode não o ser em outro, e um atributo pode não ser um quaseidentificador viável em um instante no tempo, mas ser em outro posterior. Por essa razão, alguns métodos de proteção de privacidade mais sofisticados não dependem da categorização de atributos da forma acima.

Degradação de privacidade devida a um ataque, e suas métricas O estudo de privacidade só é preciso quando há medidas quantitativas formais do quanto a privacidade é degradada em cada cenário. A seguir apresentamos os fundamentos de como a degradação de privacidade é formalizada na área de fluxo de informação quantitativo [51, 49, 35, 18, 30, 47, 41, 17, 57, 20, 10, 8, 4, 48, 5, 6, 16, 9]. Uma apresentação unificada destes princípios pode ser encontrada em [7].

- **Conhecimento a priori e sucesso a priori do adversário** Antes mesmo de o ataque ser realizado, presume-se que o adversário tenha algum *conhecimento a priori* sobre o segredo. Tal conhecimento pode advir de várias fontes: informação prévia sobre a distribuição de probabilidade a partir da qual o segredo foi amostrado (e.g., em caso de segredos aleatórios, como uma senha automaticamente gerada por um aplicativo); fontes auxiliares de informação (como jornais, revistas, mídia ou conhecimento comum); ou mesmo de ataques anteriores. O *sucesso a priori do adversário* é, então, uma medida do quanto de informação sensível o adversário já possui antes mesmo de executar um ataque, usando apenas seu conhecimento a priori.

Por exemplo, considere um cenário em que a informação sensível seja o dia da semana em que um indivíduo escolhido como alvo nasceu. Antes mesmo de executar o ataque, o adversário pode ter o conhecimento a priori (advindo, e.g., de jornais, revistas, censos demográficos, etc.) de que a distribuição de datas de nascimento na população em que o indivíduo alvo se insere é uniforme sobre os dias da semana. Usando apenas essa informação, o adversário poderia “adivinhar no escuro”¹ o dia de nascimento do indivíduo-alvo e mesmo assim teria uma chance de 1 em 7 de

¹Em alguns momentos usamos informalmente a expressão “adivinhar no escuro” para descrever a melhor estratégia possível para se estimar o valor de uma variável desconhecida. Apesar do uso desta expressão coloquial, tal abordagem é solidamente baseada no *Princípio da máxima entropia*, que afirma que a distribuição de probabilidade que melhor representa um estado de conhecimento é aquela com a maior entropia possível, dadas as informações já conhecidas [36]. No nosso contexto, isso geralmente significa que, na ausência de mais informação, deve-se assumir que a distribuição de probabilidade sobre um conjunto é uniforme e, portanto, o melhor que o adversário tem a fazer é mesmo “adivinhar no escuro” o valor de uma variável desconhecida.

inferir corretamente o valor do atributo sensível. Nesse caso, sua probabilidade de sucesso a priori na inferência do atributo sensível pode ser quantificada como $1/7 \approx 14\%$.

- **Conhecimento a posteriori e sucesso a posteriori do adversário** Ao longo da execução do ataque, o adversário combina a observação dos resultados obtidos com seu conhecimento a priori, revisando assim sua informação sobre o segredo a fim de obter o que se chama de *conhecimento a posteriori*. O *sucesso a posteriori do adversário* é, então, uma medida (determinística ou probabilística) do quanto de informação sensível o adversário detém após a execução do ataque.

Considere novamente o exemplo acima em que o segredo é o dia da semana em que um indivíduo nasceu. Suponha que o adversário execute um ataque sobre uma base de dados que contém informação sobre o indivíduo-alvo e averigue, assim, que esse indivíduo não nasceu nem em um sábado nem em um domingo. Neste caso, o adversário revisa seu conhecimento a priori (de que qualquer dia da semana é igualmente provável como valor do atributo sensível) para um conhecimento a posteriori (de que qualquer dia entre segunda-feira e sexta-feira são igualmente prováveis como valor do atributo sensível, enquanto sábado e domingo estão descartados). Consequentemente, a probabilidade de sucesso a posteriori do adversário (i.e., a sua chance de inferir corretamente o valor do atributo sensível após a realização do ataque) neste caso é de $1/5 = 20\%$.

- **Degradação de privacidade de um ataque** Um princípio fundamental da formalização de privacidade é que a *degradação de privacidade de um ataque* é uma comparação entre o sucesso a priori do adversário (i.e., informação a respeito do segredo antes mesmo da execução do ataque, contando apenas com seu conhecimento a priori) e seu sucesso a posteriori (i.e., informação a respeito do segredo após a execução do ataque, contando já com seu conhecimento a posteriori). Intuitivamente, quanto maior a degradação de privacidade de um ataque, maior êxito do adversário em obter informação sensível a respeito de seu alvo e maior o dano incorrido à privacidade *por causa direta do ataque*.²

²Como ilustração da razão pela qual a degradação de privacidade é definida como o *aumento na medida de sucesso do adversário devido a um ataque*, em vez de simplesmente como a medida de sucesso a posteriori (i.e., após a execução do ataque), apreciemos os seguintes exemplos. Considere novamente o cenário em que a informação sensível é o dia da semana em que um indivíduo-alvo nasceu. Suponha que o ataque consista em o adversário acessar uma base de dados na qual o indivíduo está representado, juntamente com seu CPF e dia de nascimento, e usar o CPF do indivíduo como informação auxiliar para recuperar a informação sensível. Entretanto, dessa vez, suponha que um adversário *A* já tenha como conhecimento a priori (por exemplo, porque ele teve acesso à certidão do nascimento do indivíduo e cruzou essa informação com um calendário) de que o indivíduo nasceu em uma segunda-feira. Como o CPF é único, esse adversário terá sucesso em reidentificar o indivíduo na base e recuperar o seu dia de nascimento como uma segunda-feira. Note, entretanto, que *o ataque em si não alterou a informação que o adversário A já tinha sobre o segredo*. Intuitivamente, portanto, este ataque pode ser considerado inócua, já que o sucesso a posteriori do adversário permanece o mesmo que seu sucesso a priori. Por outro lado, considere um adversário *B* cujo conhecimento a priori (e.g, vindo de informação auxiliar, ou de um ataque anterior) seja apenas de que é igualmente provável que o indivíduo alvo tenha nascido em

Quando a comparação se faz pela razão entre o sucesso a posteriori e o sucesso a priori do adversário, temos uma *medida multiplicativa de degradação de privacidade* [11, 5]:

$$\text{degradação multiplicativa de privacidade} \stackrel{\text{def}}{=} \frac{\text{sucesso do adversário a posteriori}}{\text{sucesso do adversário a priori}}.$$

Já quando a comparação é feita tomando-se a diferença entre o sucesso a posteriori e o sucesso a priori do adversário, temos uma *medida aditiva de degradação de privacidade* [11, 5]:

$$\text{degradação aditiva de privacidade} \stackrel{\text{def}}{=} \text{sucesso do adversário a posteriori} - \text{sucesso do adversário a priori}.$$

Ainda considerando o mesmo exemplo de data de aniversário acima, a degradação multiplicativa de privacidade devida ao ataque seria de $(1/5)/(1/7) = 7/5 = 1.4$, indicando que a realização do ataque conferiria ao adversário um ganho relativo de 40% em sua chance de sucesso na inferência do atributo sensível. Por outro lado, a degradação aditiva de privacidade devida ao ataque seria dada pela diferença $1/5 - 1/7 = 2/35 \approx 0.06$, indicando que a realização do ataque conferiria ao adversário um ganho absoluto de aproximadamente 6% em sua chance de sucesso na inferência do atributo sensível.

- **Classificação de métricas de privacidade quanto ao grau de sucesso atingido pelo adversário**

- **Métricas determinísticas de sucesso** mensuram o sucesso do adversário de forma absoluta –i.e., retornam um valor qualitativo dependendo de se a informação desejada foi ou não recuperada com absoluta certeza.

Exemplos típicos de métricas determinísticas incluem o número de indivíduos em uma base de dados que podem ser unicamente reidentificados, ou ter o valor de um atributo sensível inferido, com absoluta certeza.

- **Métricas probabilísticas de sucesso** proveem um valor quantitativo representando o grau de certeza com o qual a informação desejada foi recuperada.

Exemplos típicos de métricas probabilísticas incluem a chance de que um indivíduo aleatoriamente selecionado como alvo seja reidentificado em uma

qualquer dia entre segunda-feira e sexta-feira, mas não no final de semana. Claramente, assim como o adversário *A*, o adversário *B* também atinge certeza absoluta, após realizar o ataque, de que o indivíduo nasceu em uma segunda-feira. Entretanto, note que, no caso do adversário *B*, o ataque aumenta seu conhecimento sobre o segredo e pode, intuitivamente, ser considerado de alguma forma eficaz. Portanto, apesar do sucesso a posteriori de ambos os adversários *A* e *B* ser o mesmo (ambos sabem com certeza, a posteriori, o dia de nascimento do indivíduo alvo), a contribuição do ataque em si para o estabelecimento desse conhecimento é distinta em cada caso: para o adversário *A*, o ataque não altera sua medida de sucesso, enquanto que para o adversário *B*, o ataque aumenta significativamente sua medida de sucesso. Por essa razão, considera-se que a degradação de privacidade causada pelo ataque seja maior no caso do adversário *B* do que no caso do adversário *A*.

base de dados, ou a probabilidade de que um indivíduo tenha o valor de seu atributo sensível corretamente inferido, mesmo que sem absoluta certeza.

- **Métricas de caso médio** mensuram a esperança ou média do sucesso do adversário, levando em conta alguma distribuição de probabilidade sobre possíveis configurações do ataque.

Um exemplo típico de métrica de caso médio seria a medida do risco esperado de reidentificação de um indivíduo aleatoriamente selecionado como alvo em uma base de dados. Neste caso, quantifica-se o risco de reidentificação para todos os indivíduos que podem ser escolhidos como alvo de um ataque em uma base de dados e, em seguida, computa-se a média ponderada do risco levando em conta uma distribuição de probabilidade sobre os indivíduos (e.g., a distribuição uniforme).

- **Métricas de pior caso** mensuram o sucesso do adversário sobre a configuração de ataque mais vantajosa para ele possível, independentemente do quão improvável ela seja.

Um exemplo típico de métrica de pior caso seria a medida do risco máximo de reidentificação de um indivíduo em uma base de dados. Neste caso, quantifica-se o risco de reidentificação para todos os indivíduos que podem ser escolhidos como alvo de um ataque em uma base de dados e, em seguida, retorna-se o maior risco dentre todos os encontrados.

É importante destacar que, por levar em conta a esperança do risco, métricas de caso médio podem ocultar o risco a que incorrem poucos indivíduos. Por outro lado, por destacar o pior risco possível, métricas de pior caso podem retornar valores que não são representativos do caso geral. A escolha entre métricas de caso médio e pior caso é uma decisão a ser tomada caso a caso, com cuidado.

2.2 Métodos de mitigação de degradação à privacidade

Um *método de mitigação de degradação de privacidade* é um conjunto de ações que podem ser tomadas pelo curador dos dados para preservar em algum nível a informação sensível dos titulares de dados. Existe um grande número de métodos na literatura, que podem ser agrupados em algumas famílias que guardam entre si similaridades. Apesar de não haver uma nomenclatura única para estas famílias, é comum encontrar métodos sendo classificados (inclusive como fazemos no presente documento) de acordo com as dimensões abaixo.

- **Não perturbativos (*non-perturbative*, no original em inglês) vs. perturbativos (*perturbative*, no original em inglês)** *Métodos não perturbativos* alteram a informação provida apenas por diminuir sua granularidade ou por suprimi-la por partes, mas sem introduzir informação ruidosa. Exemplos incluem os métodos de anonimidade- k [56], diversidade- ℓ [46] e proximidade- t [44] quando não se utilizam

de introdução de dados falsos, e divulgação de histogramas e estatísticas de forma determinística.

Métodos perturbativos podem introduzir informação inverídica de forma controlada na divulgação, seja por criação de dados falsos ou pela inserção de ruído nos dados. Exemplos incluem a privacidade diferencial [25] e suas variantes, que se baseiam na introdução de ruído nos dados.

- **Sintáticos vs. semânticos** *Métodos sintáticos* formulam condições puramente sintáticas –que geralmente podem ser cheçadas apenas analisando-se os dados produzidos– para a divulgação de informação. Exemplos típicos incluem os métodos de de anonimidade- k , diversidade- ℓ e proximidade- t .

Métodos semânticos formulam condições semânticas para a divulgação de informação, incorporando em si mesmos a formalização de privacidade almejada. Um exemplo típico é a privacidade diferencial, em suas mais variadas formas.

- **Globais vs. locais:** *Métodos globais* contam com um *curador de dados* responsável pela coleta de informações individuais e aplicação das técnicas de proteção. Nesse tipo de método assume-se que o curador é uma entidade digna de confiança para tratamento da informação sensível, e o tratamento é aplicado ao conjunto dos dados de forma holística. Exemplos típicos incluem de anonimidade- k , diversidade- ℓ e proximidade- t , assim como as divulgações de dados agregados ou tabulares. Também a privacidade diferencial tem uma variante global.

Métodos locais são aqueles em que a proteção de privacidade é aplicada aos dados de cada titular individualmente. Nesse tipo de método geralmente se assume que ou não há um curador central para os dados ou que, quando há, ele não é digno de confiança e pode agir como adversário. Também é possível que próprio curador, mesmo que confiável, aplique tratamento local a cada dado individualmente em situações especiais (por exemplo, quando se desejam divulgar microdados sanitizados). A própria privacidade diferencial tem uma variante local.

- **Produtores de microdados vs. produtores de dados agregados** *Métodos produtores de microdados*, como o próprio nome diz, produzem como resultado para divulgação informação em nível individual, porém possivelmente tratada de alguma forma. Exemplos típicos incluem os métodos de anonimidade- k , diversidade- ℓ e proximidade- t , além de algumas forma de privacidade diferencial local.

Métodos produtores de dados agregados, também como indicado pelo próprio nome, produzem como resultado informação agregada para divulgação. Exemplos típicos incluem divulgação de estatísticas a respeito dos dados, ou de histogramas para algumas combinações de atributos.

Métodos de mitigação selecionados para o presente projeto piloto No contexto do presente projeto piloto, o Inep optou pela análise dos seguintes dois métodos de produtores de microdados:

- Sanitização por amostragem não-perturbativa, descrita na Seção 5.
- Sanitização por privacidade diferencial local, descrita na Seção 6.

Métodos de divulgação de dados agregados não foram considerados neste projeto piloto.

2.3 Utilidade

Todo método de mitigação de degradação de privacidade vem acompanhado de um maior ou menor custo à utilidade dos dados divulgados –i.e., à qualidade da informação provida aos analistas. É amplamente conhecida na literatura técnica sobre controle de divulgação estatística a dificuldade inerente de conciliar-se a utilidade dos dados divulgados com a privacidade dos indivíduos que participam das pesquisas [25, 29, 12, 40, 3, 28, 9].

Em geral, analistas podem ter objetivos variados e buscar informações diferentes a partir de uma mesma base. Um mecanismo que se foque em atender a um objetivo específico de um analista pode causar danos à utilidade dos dados para outros analistas com objetivos distintos. Um *mecanismo ótimo* para um analista é aquele que respeita suas preferências e tolerâncias com relação ao ruído que é adicionado. Neste contexto, seria desejável obter, sempre que possível, o que se chama de *mecanismo ótimo universal*, i.e., um mecanismo capaz de ser simultaneamente ótimo para todos os (ou uma grande maioria dos) potenciais analistas da base de dados. As condições para a existência de tal mecanismo têm sido amplamente pesquisadas na literatura [29, 32, 12]. Entretanto, as situações em que tal mecanismo é possível são muito restritas.

Neste contexto, existe um grande número de métricas de utilidade na literatura, as quais podem ser classificadas como a seguir.

- **Métricas de utilidade específicas** partem do princípio de que uma divulgação será utilizada para uma tarefa preestabelecida e então medem a qualidade da divulgação para esta tarefa. Por exemplo, quando um conjunto de dados serve de treino para técnicas de aprendizado de máquina, é comum adotarem-se métricas de utilidade relacionadas à qualidade da tarefa de classificação pretendida (e.g., acurácia em relação à decisão sobre se um aluno tem maior ou menor chance de cursar um curso universitário).
- **Métricas de utilidade de propósito geral** tentam diminuir ao máximo a distorção entre os dados originais e os dados tratados. É comum usarem-se métricas de propósito geral que quantificam distância (de acordo, e.g., com a *distância de variação total* ou *divergência de Kullback-Leibler*) entre a distribuição induzida pelos dados reais e a induzida pelos dados sanitizados. A premissa central de tais métricas é que se a distribuição de probabilidade sobre registros após o tratamento for similar à distribuição antes do tratamento, então os dados tratados serão úteis para a maioria dos analistas aplicações.

Métricas específicas dependem de um conhecimento profundo da utilização pretendida dos dados.

Modelo de utilidade selecionado para o presente projeto piloto O modelo de utilidade adotado no presente projeto piloto, uma métrica de propósito geral, é descrito na Seção 7.2.1.

2.4 Modelo de bases de dados, registros e atributos

Aqui formalizamos nosso modelo de “base de dados”, que é uma coleção de “registros” ou “linhas”, cada uma consistindo em uma tupla de valores correspondendo a “atributos” ou “colunas”. Os conceitos aqui introduzidos são ilustrados no Exemplo 1 e servirão de base para as Seções 5 e 6 que apresentam, respectivamente, as análises da aplicação das técnicas de amostragem e de privacidade diferencial local aos estudos de caso do presente documento.

Os elementos do modelo são os seguintes.

- Seja $\mathcal{A} = \{a_1, \dots, a_m\}$ um conjunto (finito) de *atributos* ou *colunas* em algum cenário de interesse. Para todo $1 \leq i \leq m$, denotamos por $\text{dom}(a_i)$ o domínio de todos os valores que o atributo a_i pode assumir.
- Um *registro* (ou *linha*) x é um mapeamento de atributos para valores, i.e., $x = \langle x[a_1], \dots, x[a_m] \rangle$, onde $x[a_i] \in \text{dom}(a_i)$ é o valor assumido pelo atributo a_i no registro x . O domínio de todos os registros possíveis sobre o conjunto de atributos $\mathcal{A}$ é denotado por $\text{registros}(\mathcal{A}) = \text{dom}(a_1) \times \dots \times \text{dom}(a_m)$.
- Uma *base de dados* sobre um conjunto de atributos $\mathcal{A}$ é um multiconjunto (finito) $D = \{\{x_1, x_2, \dots, x_n\}\}$ de registros, cada um pertencendo a $\text{registros}(\mathcal{A})$.³ Denotamos por $\text{mult}_D(x)$ a *multiplicidade* (i.e., o número de ocorrências distintas) do registro x na base de dados D , e por $|D| = \sum_{x \in \text{registros}(\mathcal{A})} \text{mult}_D(x)$ a *cardinalidade* (i.e., o número total de registros, incluindo repetições) de D .
- Dado um subconjunto $\mathcal{A}' \subseteq \mathcal{A}$ de atributos, denotamos por $x[\mathcal{A}']$ o *sub-registro* (ou a *sub-linha*) de x consistindo na projeção de x sobre $\mathcal{A}'$, i.e., a sub-tupla de x contendo apenas os valores correspondentes àqueles atributos em $\mathcal{A}'$. Os sub-registros correspondendo a atributos em $\mathcal{A}' = \{a_{i_1}, \dots, a_{i_k}\}$ têm como domínio o conjunto $\text{registros}(\mathcal{A}') = \text{dom}(a_{i_1}) \times \dots \times \text{dom}(a_{i_k})$.

³Um *multiconjunto* é a generalização de um conjunto, de tal forma que se permite a repetição de elementos. Ao usar multiconjuntos para modelar bases de dados, estamos permitindo que um mesmo registro apareça múltiplas vezes em uma mesma base.

- Denotamos por $D/\sim_{\mathcal{A}'}$ a partição sobre registros da base de dados D induzida pelos atributos $\mathcal{A}' \subseteq \mathcal{A}$.⁴ Intuitivamente, a partição quebra a base de dados D em vários blocos, sendo que cada bloco agrupa todos os registros que compartilhem os mesmos valores para os atributos em $\mathcal{A}'$. Denotamos por $\text{bloco}_{D/\sim_{\mathcal{A}'}}(a)$ o bloco da partição $D/\sim_{\mathcal{A}'}$ que contém os registros $x \in D$ que contém o valor a para os atributos $\mathcal{A}'$, ou seja,

$$\text{bloco}_{D/\sim_{\mathcal{A}'}}(a) \stackrel{\text{def}}{=} \{x \in D \mid x[\mathcal{A}'] = a\}.$$

A seguir apresentamos aquele que servirá como nosso exemplo condutor ao longo da formalização de ataques e suas métricas de sucesso nas seções seguintes.

Exemplo 1 (Exemplo condutor para ataques em uma única base de dados). Considere o cenário de interesse em que o conjunto de atributos seja $\mathcal{A} = \{id, idade, sexo, escola, deficiência\}$, especificado como:

- $\text{dom}(id) = \{1, 2, 3, \dots\}$, consistindo na identificação única de um indivíduo, formada por um número inteiro positivo;
- $\text{dom}(nome) = \{\text{Ana}, \text{Bruna}, \text{Célia}, \dots\}$, consistindo no nome de um indivíduo;
- $\text{dom}(idade) = \{0, 1, 2, 3, 4, 5\}$, consistindo na idade de um indivíduo, em anos completos;
- $\text{dom}(sexo) = \{\text{F}, \text{M}\}$, indicando se um indivíduo é do sexo feminino (F) ou masculino (M);
- $\text{dom}(escola) = \{\text{A}, \text{B}, \text{C}, \text{D}, \text{E}\}$, indicando a escola onde o indivíduo estuda;
- $\text{dom}(deficiência) = \{\text{sim}, \text{não}\}$, indicando se o indivíduo é portador (sim) ou não (não) de alguma deficiência física ou mental.

A Tabela 2.4.1 representa uma base de dados D formada por 10 registros (de modo que sua cardinalidade é $|D| = 10$), cada um deles uma tupla de valores proveniente do domínio $\text{registros}(\mathcal{A}) = \text{dom}(id) \times \text{dom}(nome) \times \text{dom}(idade) \times \text{dom}(sexo) \times \text{dom}(escola) \times \text{dom}(deficiência)$ de todos os registros possíveis. Cada registro em D contém dados a respeito de um indivíduo de uma população de interesse (e.g., em um censo, pesquisa educacional, ou médica).

Considerando o subconjunto $\{sexo, deficiência\} \subseteq \mathcal{A}$ de atributos e tomando o indivíduo x como aquele representado pela tupla $\langle 1, \text{Ana}, 2, \text{F}, \text{A}, \text{não} \rangle$, o sub-registro correspondente a este indivíduo é dado por $x[\{sexo, deficiência\}] = \langle \text{F}, \text{não} \rangle$. A partição $D/\sim_{\{sexo, deficiência\}}$ sobre D induzida por este subconjunto de atributos consiste em quatro blocos, um para cada combinação possível de sexo e deficiência, como a seguir:

⁴Formalmente, uma *partição* P em um conjunto $\mathcal{X}$ é uma coleção $P = \{\mathcal{X}_1, \mathcal{X}_2, \dots, \mathcal{X}_k\}$ de *blocos* tais que: (i) $\mathcal{X}_i \subseteq \mathcal{X}$ para todo $1 \leq i \leq k$; (ii) $\mathcal{X}_i \cap \mathcal{X}_j = \emptyset$ para todo $1 \leq i, j \leq k$ e $i \neq j$; e (iii) $\bigcup_{i=1}^k \mathcal{X}_i = \mathcal{X}$.

<i>id</i>	<i>nome</i>	<i>idade</i>	<i>sexo</i>	<i>escola</i>	<i>deficiência</i>
1	Ana	2	F	A	não
2	Bruna	2	F	A	sim
3	Célia	2	F	C	sim
4	Danilo	2	M	B	sim
5	Enzo	2	M	B	não
6	Flávia	4	F	C	sim
7	Geórgia	4	F	C	sim
8	Helena	4	F	E	não
9	Ivo	4	M	D	não
10	João	5	M	D	não

Tabela 2.4.1: Exemplo 1: Base de dados D utilizada no exemplo condutor.

- um bloco para todos os registros x tais que $x[\{sexo, deficiência\}] = \langle F, sim \rangle$, o que inclui os registros de id 's 2, 3, 6 e 7; e
- um bloco para todos os registros x tais que $x[\{sexo, deficiência\}] = \langle F, não \rangle$, o que inclui os registros de id 's 1 e 8;
- um bloco para todos os registros x tais que $x[\{sexo, deficiência\}] = \langle M, sim \rangle$, o que inclui o indivíduo de id 4; e
- um bloco para todos os registros x tais que $x[\{sexo, deficiência\}] = \langle M, não \rangle$, o que inclui os registros de id 's 5, 9 e 10;

◁

A partir da base de dados D , pode-se derivar uma *distribuição de probabilidade a priori* $\pi^D : \mathbb{D}(\text{registros}(\mathcal{A}))$ sobre registros da seguinte forma. Para cada registro $x \in \text{registros}(\mathcal{A})$, sua probabilidade π_x^D é sua frequência relativa na base D :

$$\pi_x^D \stackrel{\text{def}}{=} \frac{\text{mult}_D(x)}{|D|}. \quad (2.1)$$

A partir de uma distribuição π^D sobre registros da base, pode-se derivar a distribuição de probabilidade marginal $\pi^{\mathcal{A}'|D}$ sobre os valores de qualquer subconjunto $\mathcal{A}' \subseteq \mathcal{A}$ de atributos da forma usual. Mais precisamente, a probabilidade $\pi_a^{\mathcal{A}'|D}$ de cada valor $a \in \text{dom}(\mathcal{A}')$ é dada por:

$$\pi_a^{\mathcal{A}'|D} \stackrel{\text{def}}{=} \sum_{\substack{x \in D, \\ x[\mathcal{A}'] = a}} \pi_x^D = \sum_{\substack{x \in D, \\ x[\mathcal{A}'] = a}} \frac{\text{mult}_D(x)}{|D|} = \sum_{x \in D} \frac{|\{x \in D \mid x[\mathcal{A}'] = a\}|}{|D|}. \quad (2.2)$$

O seguinte exemplo demonstra como se derivar distribuições de probabilidade sobre os valores de qualquer subconjunto dos atributos.

Exemplo 2 (Distribuição de probabilidade marginal sobre um subconjunto de atributos). Considere novamente a base de dados D sobre o conjunto $\mathcal{A}$ de atributos descrita no Exemplo 1, e assuma a distribuição de probabilidade π^D sobre os registros de D definida na Equação 2.1. Se considerarmos o subconjunto de atributos $\{sexo, deficiência\} \subseteq \mathcal{A}$, podemos observar que seu domínio é

$$dom(\{sexo, deficiência\}) = \{\langle F, sim \rangle, \langle F, não \rangle, \langle M, sim \rangle, \langle M, não \rangle\} .$$

Podemos, então, computar a correspondente distribuição marginal $\pi^{\{sexo, deficiência\}|D}$ derivada a partir da frequência de registros em D . Mais precisamente,

$$\pi_{\langle F, sim \rangle}^{\{sexo, deficiência\}|D} = \sum_{\substack{x \in D, \\ x[\{sexo, deficiência\}] = \langle F, sim \rangle}} \pi_x^D = \sum_{\substack{x \in D, \\ x[\{sexo, deficiência\}] = \langle F, sim \rangle}} \frac{mult_D(x)}{|D|} = \frac{4}{10} ,$$

e, de forma análoga,

$$\pi_{\langle F, não \rangle}^{\{sexo, deficiência\}|D} = 2/10, \quad \pi_{\langle M, sim \rangle}^{\{sexo, deficiência\}|D} = 1/10, \quad \text{e} \quad \pi_{\langle M, não \rangle}^{\{sexo, deficiência\}|D} = 3/10 .$$

◁

3 Configuração dos experimentos deste projeto piloto

Neste documento reportamos várias análises experimentais quantitativas sobre o nível de privacidade atingido pelos métodos de sanitização selecionados para o presente projeto piloto. Todos os experimentos foram realizados sobre os dados do Censo da Educação Básica de 2019. Mais precisamente:

- O Experimento 5 analisa a degradação de privacidade em ataques de reidentificação coletiva sobre uma única base sanitizada por desidentificação e pseudonimização (RCU), descrito na Seção 4.1.1, levando em conta a restrição no número e granularidade de atributos determinada pelo Inep para o presente projeto piloto. Os resultados deste experimento demonstram o impacto na degradação de privacidade causado por esta restrição sobre atributos em si mesma (i.e., antes mesmo da aplicação de métodos de sanitização mais refinados), e servem de base de comparação para as demais técnicas de sanitização avaliadas.
- O Experimento 8 analisa a degradação de privacidade em ataques de reidentificação coletiva sobre uma única base sanitizada por amostragem (RCU^{ams}), descrito na Seção 5.3.1.
- O Experimento 12 analisa a degradação de privacidade em ataques de reidentificação coletiva sobre uma única base sanitizada por privacidade diferencial local ($\widehat{RCU}^{ldp}$), descrito na Seção 6.3.1.

Um sumário comparativo do compromisso entre privacidade e utilidade atingido por cada método é provido na Seção 7. No restante da presente seção descrevemos as configurações comuns aos experimentos listados acima.

3.1 Tratamento dos conjuntos de dados fornecidos pelo Inep

A base selecionada pelo Inep para o projeto piloto contém os microdados do Censo do Ensino Básico de 2019. Um conjunto distinto de atributos foi selecionado pelo Inep

para divulgação em cada um dos estudos de caso deste projeto piloto: o referente à sanitização por amostragem e o referente à sanitização por privacidade diferencial local. A Tabela 3.1.1 apresenta os atributos selecionados em cada caso.

A seguir descrevemos os conjuntos de dados referentes à base do Censo da Educação Básica de 2019 fornecidos pelo Inep para o presente projeto piloto. Adicionalmente, descrevemos o tratamento empregado por nós para garantir que as bases utilizadas em cada estudo de caso fossem o mais similares possível e que fossem respeitadas as premissas dos ataques RCU, RCU^{ams} e $\widehat{RCU}^{ldp}$ (descritas nas Seções 4.1.1.1 5.3.1.1 e 6.3.1.1, respectivamente).

- **Conjunto de dados para estudo de caso de sanitização por amostragem.**

O Inep forneceu uma base amostral, já sanitizada de acordo com plano amostral criado e executado pelo próprio instituto, conforme descrito na Seção 5.2. A base fornecida contém 14 154 169 registros. Após tratamento para remoção de registros múltiplos para um mesmo estudante, descrito abaixo, a base resultante possui 13 592, 097 registros, o que equivale a 28% do tamanho da base completa após tratamento (que contém 47 640 822 registros).

O tratamento empregado a este conjunto de dados consistiu no seguinte. Em primeiro lugar, notamos que apenas a base disponibilizada pelo Inep para os experimentos por privacidade diferencial foi fornecida com a coluna referente ao atributo ID_ALUNO, sendo o mesmo atributo ausente na base disponibilizada para os experimentos por amostragem. Dessa forma, tivemos que nos basear no atributo ID_MATRICULA como meio para identificação direta de cada aluno. Entretanto, apenas com o atributo ID_MATRICULA, não é possível identificar alunos com múltiplos registros em uma mesma publicação. Sendo assim, utilizando a base publicada pelo Inep em sua página na Internet para o Censo da Educação Básica de 2019, agrupamos para cada valor do atributo ID_ALUNO, único para cada aluno inclusive em registros distintos, todos os respectivos valores do atributo ID_MATRICULA, único por registro, para verificarmos a existência de estudantes com múltiplos registros na amostra disponibilizada pelo Inep. Em seguida, comparamos os valores de ID_MATRICULA para os 14 154 169 de registros presentes na amostra com o agrupamento que construímos, o que nos permitiu identificar todos os casos de alunos com registros múltiplos na amostra. De modo a garantirmos que cada aluno possui no máximo um registro na amostra, selecionamos aleatoriamente apenas um dos registros disponíveis para aqueles alunos com mais de um registro.

- **Conjunto completo de dados necessário para as análises.** O Inep forneceu uma base completa contendo todos os microdados de interesse para os estudos de caso deste documento, incluindo os atributos destinados à publicação e também atributos necessários apenas para a correta aplicação dos métodos e análises. A base fornecida continha 51 166 723 registros. Após tratamento para remoção de registros múltiplos para um mesmo estudante, descrito abaixo, a base resultante possui 47 640 822 registros.

Atributo	Selecionado para divulgação sob	
	Amostragem	Privacidade diferencial local
Matrícula	NU_ANO_CENSO	✓
	ID_ALUNO	–
	ID_MATRICULA	✓
	TP_SEXO	✓
	TP_ZONA_RESIDENCIAL	✓
	NU_IDADE_0_5	✓
	IN_DIST_IDADE_SERIE	✓
	IN_TEMPO_INTEGRAL	✓
	IN_NECESSIDADE_ESPECIAL	✓
	TP_COR_RACA	–
Turma	TP_ETAPA_ENSINO	✓
	IN_REGULAR	✓
	IN_EJA	✓
	IN_PROFISSIONALIZANTE	✓
	ID_AREA_CURSO_PROFISSIONAL	✓
	TP_MEDIACAO_DIDATICO_PEDAGO	✓
	IN_TURNIO	✓
	TP_TIPO_ATENDIMENTO_TURMA	✓
	IN_ESPECIAL_EXCLUSIVA	–
Entidade	CO_REGIAO	✓
	CO_MESORREGIAO	✓
	CO_MICRORREGIAO	✓
	CO_UF	✓
	CO_MUNICIPIO	✓
	TP_DEPENDENCIA	✓
	TP_LOCALIZACAO	✓
	TP_CATEGORIA_ESCOLA_PRIVADA	✓
	IN_CONVENIADA_PP	✓
	TP_CONVENIO_PODER_PUBLICO	✓
	TP_LOCALIZACAO_DIFERENCIADA	✓
	IN_EDUCACAO_INDIGENA	✓

Tabela 3.1.1: Experimentos 8 e 12: Atributos da base do Censo da Educação Básica de 2019 selecionados pelo Inep para divulgação em cada estudo de caso.

O tratamento empregado a este conjunto de dados consistiu no seguinte. Primeiramente, note que para uma análise apropriada da utilidade de cada mecanismo, é preciso especificar a base original a partir da qual as versões sanitizadas (seja por amostragem, seja por privacidade diferencial local) foram obtidas –e com a qual serão comparadas. Para obter uma base original compatível com as bases sanitizadas e, ao mesmo tempo, com as premissas sobre os ataques, adotamos o seguinte procedimento.

1. Iniciando com a base original vazia, incluímos todos os registros da base completa fornecida que correspondam a algum registro mantido na base amostral após o tratamento para eliminação de duplicatas descrito acima.
 2. Para cada indivíduo de interesse ainda não incluído na base original após o passo anterior, selecionamos aleatoriamente um de seus registros na base completa disponibilizada pelo Inep e o incluímos na base original. Essa seleção se baseou no mapeamento desenvolvido para o conjunto de dados para sanitização por amostragem, i.e., para cada valor do atributo `ID_ALUNO`, único para cada aluno inclusive em registros distintos, temos todos os respectivos valores do atributo `ID_MATRICULA`, único por registro. Desta forma, garantimos que a premissa de que cada indivíduo é representado no máximo uma vez na base original fosse satisfeita.
- **Conjunto de dados para sanitização por privacidade diferencial local.**
O Inep forneceu uma base consistindo em todos os registros da base completa, mas limitada aos valores dos atributos a serem divulgados no estudo de caso de sanitização por privacidade diferencial local. Após tratamento para remoção de registros múltiplos para um mesmo estudante, a base resultante apresenta 47 640 822 registros, o mesmo tamanho da base original tratada.

O tratamento empregado a este conjunto de dados consistiu no seguinte. Sobre a base original obtida no passo anterior, aplicamos o mecanismo de privacidade diferencial local com diferentes parâmetros para obter várias versões sanitizadas da mesma. ¹

3.2 Criação de uma base nacional e uma base restrita ao Distrito Federal

Devido ao alto custo computacional das análises e o reduzido tempo disponível para o presente projeto piloto, alguns experimentos foram executadas em uma versão de cada base de dados contendo apenas registros do Distrito Federal (DF). Tal unidade da federação foi escolhida por ter um tamanho tratável e, ao mesmo tempo, ter uma boa

¹Registramos que 128 registros na base original (dos quais, 3 no Distrito Federal), apresentaram inconsistências no valor do atributos `ID_AREA_CURSO_PROFISSIONAL`. Para tais registros, substituímos o valor inválido pelo valor do atributo `ID_AREA_CURSO_PROFISSIONAL` na turma correspondente.

variabilidade nos dados. Nos casos em que a restrição foi feita, apenas filtramos a base que contém registros de todo o Brasil para selecionar apenas registros correspondentes à região selecionada. Mais especificamente, produzimos as seguintes bases.

- **Base original restrita ao Distrito Federal:** restringindo a base original do Censo da Educação Básica de 2019 a apenas registros do Distrito Federal, obtemos uma base com 654 413 registros após tratamento. Isto equivale a 1.37% do total de registros da base original nacional (que contém 47 640 822 registros após tratamento).
- **Base amostral restrita ao Distrito Federal:** restringindo a base amostral do Censo da Educação Básica de 2019 a apenas registros do Distrito Federal, obtemos uma base com 13 691 registros após tratamento. Isto equivale a 2.09% do total de registros selecionados pelo plano amostral do Inep (que contém 13 592 096 registros após tratamento).
- **Base para sanitização por privacidade diferencial local restrita ao Distrito Federal:** restringindo a base selecionada para sanitização por privacidade diferencial local, referente ao Censo da Educação Básica de 2019, a apenas registros do Distrito Federal, obtemos uma base com 654 413 registros após tratamento. Isto equivale a 1.37% do total de registros da base original nacional (que contém 47 640 822 registros após tratamento).

3.3 Especificação do conhecimento auxiliar do adversário

Dado o significativo custo computacional de tempo e memória das análises executadas, restringimos o número de atributos considerados como candidatos a quaseidentificadores. Para tal, selecionamos atributos cujos valores sejam presumivelmente conhecidos, ou possam ser facilmente descobertos, por um adversário –em geral por serem informação pública ou considerada inofensiva. Exemplos de tais atributos incluem a idade de um aluno, seu sexo, ou informações a respeito da instituição de ensino em que ele está matriculado.² Em nossos experimentos consideramos os seguintes conjuntos de quaseidentificadores, representados na Tabela 3.3.2:

- **Conjunto reduzido de 7 quaseidentificadores:** tal conjunto representa um adversário com conhecimento auxiliar relativamente limitado a respeito dos alvos.

²É importante ressaltar que a escolha de atributos que sejam candidatos a quaseidentificadores ou que devam ser considerados sensíveis pode variar de acordo com o contexto e o tempo. Por exemplo, atributos que hoje sejam considerados inofensivos podem passar a ser sensíveis no futuro (e.g., o posicionamento político de um indivíduo em um país que se torne autoritário). Neste documento não nos preocupamos em fazer afirmações categóricas sobre quais atributos seriam ou não sensíveis no contexto dos Censos Educacionais do Inep, e nossas escolhas devem ser encaradas apenas como ilustração dos riscos à privacidade causados em um cenário em que elas se apliquem.

Mais especificamente, o adversário tem como informação auxiliar apenas o sexo, idade e zona residencial do aluno, além das seguintes informações pontuais sobre sua entidade: município de localização, área de curso profissional, dependência administrativa (federal, estadual, municipal ou privada) e se sua localização é em área diferenciada.

- **Conjunto expandido de 23 quaseidentificadores:** tal conjunto representa um adversário com conhecimento auxiliar relativamente elevado a respeito dos alvos.

Mais especificamente, o adversário tem como informação auxiliar tudo aquilo incluído no conjunto reduzido acima, além de toda informação que pode ser recuperada a partir de fontes públicas (como o próprio Inep ou a própria escola do aluno) uma vez que se saiba a turma do aluno (incluindo todos os dados públicos da turma e da entidade de ensino correspondente).

Atributo	Interpretação	Tipo de QID
TP_SEXO	Gênero do aluno.	Matrícula Q_{ID}^{mat}
TP_ZONA_RESIDENCIAL	Zona residencial do aluno.	
NU_IDADE_0_5	Idade do aluno, truncada em um valor máximo de 4 anos.	
TP_LOCALIZACAO_DIFERENCIADA	Se a escola está em áreas de assentamento, terras indígenas, comunidade remanescente de quilombos, ou nenhuma das anteriores.	Entidade/ Turma $Q_{ID}^{ent/tur}$
TP_DEPENDENCIA	Dependência Administrativa: Federal, Estadual, Municipal ou Privada.	
CO_MUNICIPIO	Código do município da escola.	
ID_AREA_CURSO_PROFISSIONAL	Área/Eixo Técnico do Curso da Educação Profissional Técnica de Nível Médio.	

(a) Conjunto reduzido de 7 quaseidentificadores representando um adversário de conhecimento auxiliar relativamente limitado.

Atributo	Interpretação	Tipo de QID
IN_CONVENIADA_PP	Se a escola é conveniada com o poder público.	Entidade/ Turma $Q_{ID}^{ent/tur}$
CO_REGIAO	Código da região geográfica.	
TP_CONVENIO_PODER_PUBLICO	Dependência do convênio com o poder público: Municipal, Estadual, ou Estadual e Municipal.	
CO_UF	Código da Unidade Federativa da escola.	
TP_CATEGORIA_ESCOLA_PRIVADA	Categoria da escola privada: Particular, Comunitária, Confessional ou Filantrópica.	
IN_EDUCACAO_INDIGENA	Se a escola é de Educação Escolar Indígena.	
TP_LOCALIZACAO	Localização da escola: Urbana ou Rural.	
CO_MESORREGIAO	Código da mesorregião.	
CO_MICRORREGIAO	Código da microrregião.	
TP_TIPO_ATENDIMENTO_TURMA	Tipo de atendimento: Exclusivo Escolarização, Escolarização e Atividade complementar, Atividade complementar ou Atendimento Educacional Especializado (AEE).	
TP_ETAPA_ENSINO	Etapas de ensino da matrícula, harmonizada e ordenada de acordo com o “fluxo anual” das modalidades regular, EJA e educação profissional.	
IN_TURNO	Turno da turma: Diurno ou Noturno.	
IN_PROFISSIONALIZANTE	Modo profissionalizante de ensino correspondente às turmas de cursos de formação inicial e continuada ou de qualificação profissional (Cursos FIC) articulados à EJA ou concomitantes; ou de cursos técnicos de nível médio nas formas articulada (integrada ou concomitante) ou subsequente ao ensino médio e normal/magistério.	
IN_EJA	Modo, maneira ou metodologia de ensino correspondente às turmas destinadas a pessoas que não cursaram o ensino fundamental e/ou médio em idade própria.	
TP_MEDIACAO_DIDATICO_PEDAGO	Tipo de mediação didático-pedagógica: Presencial, Semipresencial ou Educação a Distância (EAD)	
IN_REGULAR	Modo, maneira ou metodologia de ensino correspondente às turmas com etapas de escolarização consecutivas, Creche ao Ensino Médio	

(b) Atributos que aumentam o conjunto reduzido para o conjunto expandido de 23 quaseidentificadores, representando um adversário de conhecimento auxiliar relativamente elevado.

Tabela 3.3.2: Experimentos 8 e 12: Atributos usados como quaseidentificadores, selecionados a partir da Base do Censo da Educação Básica de 2019.

4 Análise de privacidade após sanitização por desidentificação e pseudonimização

A atual forma de divulgação dos dados dos Censos Educacionais por Inep consiste em sanitização pelas seguintes técnicas:

- *desidentificação*, em que se removem possíveis identificadores individuais óbvios dos registros (como nome, CPF, RG); e
- *pseudonimização*, em que tais identificadores individuais óbvios são substituídos por um código único de identificação artificialmente criado.

No Produto 02 do presente TED 8750 realizamos experimentos extensivos sobre os riscos à privacidade a que o Censo da Educação Básica de 2019 está sujeito dada esta forma de divulgação. Entretanto, no presente projeto piloto o Inep restringiu significativamente as informações sobre atributos a serem divulgadas nos microdados dos Censos, de duas formas:

- houve uma restrição no número de atributos divulgados, conforme especificado na Tabela 3.1.1; e
- houve uma restrição na granularidade de atributos divulgados (e.g., o atributo referente à idade deixou de ser um inteiro refletindo a idade exata de um indivíduo e passou a ser truncado para valores entre 0 e 5).

Esta restrição na divulgação de atributos pode, em si mesma, ter um impacto significativo na degradação de privacidade, antes mesmo da aplicação de qualquer método de sanitização mais refinado.

A fim de avaliar este impacto, nesta seção refizemos parte de análise de privacidade sobre o Censo da Educação Básica de 2019, usando o conjunto restrito de atributos selecionado pelo Inep. A nova análise ainda é aplicada sobre a base do Censo em sua atual forma de

divulgação (i.e., tratada apenas por desidentificação e pseudonimização de registros). Os resultados servem de base de comparação para as demais técnicas de sanitização testadas no presente projeto piloto.

4.1 Ataque em uma única base de dados sanitizada apenas por anonimização e pseudonimização

Nesta seção nos focamos na situação em que o adversário deseja reidentificar o maior número de indivíduos possível em base sanitizada, independentemente de quem sejam. Capturamos este cenário como um ataque de reidentificação coletiva em uma única base de dados sanitizada por desidentificação e pseudonimização (RCU), descrito na Seção 4.1.1. Além disso, tecemos considerações sobre o risco de inferência de atributos sensíveis, apresentadas na Seção 4.1.2.

Para propiciar uma leitura mais fluida do presente documento, os detalhes matemáticos da formalização dos ataques RCU são reservados ao Anexo B. As análises experimentais quantitativas da aplicação do modelo às bases dos Censos Educacionais do Inep são apresentadas na Seção 4.2.

4.1.1 Ataque de reidentificação coletiva em uma única base de dados sanitizada apenas por desidentificação e pseudonimização (RCU)

Seguindo a literatura técnica da área [34], assumimos premissas cautelosas a fim de não subestimar as capacidades do adversário. Mais precisamente, assumimos que o adversário tem acesso completo a uma única base sua forma atual, em que se empregam desidentificação e pseudonimização como métodos de proteção de privacidade. O modelo mede, então, a degradação de privacidade de cada ataque em termos do quanto a informação auxiliar a respeito de quaseidentificadores obtida por um adversário pode facilitar a reidentificação ou a inferência de atributos sensíveis de indivíduos na base.

4.1.1.1 Premissas

Assumimos as seguintes premissas em relação ao ataque de reidentificação coletiva em uma única base de dados sanitizada por desidentificação e pseudonimização.

PS0 Existe uma base de dados D de interesse definida sobre um conjunto de atributos $\mathcal{A}$.

PS1 Cada indivíduo de interesse possui no máximo um registro na base de dados D .

PS2 Existe um conjunto $\mathcal{Q}_{ID \in \mathcal{A}}$ de *quaseidentificadores* correspondendo a atributos cujos valores para alguns indivíduos podem ser conhecidos ou aprendidos pelo adversário por fontes auxiliares que não sejam a própria base de dados.




Figura 4.1.1: Esquema de ataque de reidentificação coletiva em uma única base de dados sanitizada por desidentificação e pseudonimização (RCU). No tipo de ataque aqui considerado, a degradação de privacidade é medida em termos do quanto a informação auxiliar a respeito de quaseidentificadores obtida por um adversário pode facilitar a reidentificação ou a inferência de atributos sensíveis de indivíduos.

PS3 A partir da base de dados D pode-se derivar uma *distribuição de probabilidade a priori* $\pi^D : \mathbb{D}(\text{registros}(\mathcal{A}))$ sobre registros conforme Equações (2.1) e (2.2).

PS4 O conhecimento prévio do adversário inclui toda a base de dados D e o fato de que todos os indivíduos de interesse encontram-se na base. O ataque consiste em o adversário obter como informação auxiliar (via outras fontes que não a base D) os valores dos quaseidentificadores em Q_{ID} para alguns indivíduos e usar esses valores para obter informação sensível a respeito destes indivíduos em D . A degradação de privacidade é, portanto, medida como a comparação do sucesso do adversário a posteriori –i.e., após usar a informação auxiliar sobre os valores dos quaseidentificadores– e seu sucesso a priori –i.e., antes de poder usar a informação sobre quaseidentificadores. Esses elementos são esquematizados na Figura 4.1.1.

Estamos, então, prontos para definir o ataque.

4.1.1.2 Descrição do ataque

Em um *ataque de reidentificação coletiva em uma única base de dados sanitizada por desidentificação e pseudonimização (RCU)*, o adversário tem acesso completo a uma única base de dados –conhecendo todos os seus registros– e é capaz de obter como informação auxiliar os valores de um conjunto de quaseidentificadores para todos os indivíduos cujos registros estão na base. O adversário tem como objetivo reidentificar o maior número possível de indivíduos, independentemente de quem sejam.

A degradação de privacidade do ataque é medida como uma comparação entre o sucesso a priori do adversário (i.e., conhecendo apenas a base de dados, mas não ainda os valores dos quaseidentificadores) e seu sucesso a posteriori (i.e., após descobrir os valores dos quaseidentificadores e cruzá-los com a base de dados). Mais precisamente, temos as seguintes condições para um ataque RCU:

- **Quantificação da degradação determinística de privacidade:** A medição do sucesso determinístico de um ataque coletivo RCU leva em conta que o adversário tem como alvo todos os indivíduos da base; portanto, define-se tal sucesso como a fração de indivíduos na base que pode ser reidentificada com absoluta certeza. A degradação determinística de privacidade do ataque é definida, então, como a diferença pela qual sua execução aumenta o sucesso determinístico do adversário.
- **Quantificação da degradação probabilística de privacidade:** Na medição do sucesso probabilístico de um ataque coletivo RCU, não se exige que o adversário realize a reidentificação de todos os indivíduos com absoluta certeza; em vez disso, quantifica-se a probabilidade de um indivíduo aleatoriamente escolhido como alvo ser reidentificado com sucesso. Quanto maior essa probabilidade, mais exitoso é o adversário e maior é o risco esperado de que cada indivíduo presente na base possa ser reidentificado. A degradação probabilística de privacidade do ataque é definida, então, como a razão pela qual sua execução aumenta o sucesso probabilístico do adversário.

A Definição 25 no Anexo B formaliza matematicamente o ataque RCU. A seguir ilustramos como o ataque é executado em nosso exemplo condutor.

Exemplo 3 (Execução de ataque de reidentificação coletiva em uma única base de dados sanitizada por desidentificação e pseudonimização (RCU)). Considere novamente a base de dados D sobre o conjunto de atributos $\mathcal{A}$ do Exemplo 1. Recorde que, de acordo com as hipóteses sobre ataques em uma única base, cada indivíduo de interesse possui no máximo um registro em D e que a distribuição de probabilidade a priori π^D é derivada de acordo com Equação 2.1. Também assuma que o adversário está interessado em reidentificar os registros de todos os indivíduos presentes em D .

Considere que o adversário tem como informação auxiliar os valores dos quaseidentificadores $\mathcal{Q}'_{ID} = \{idade, sexo\}$ para todos os indivíduos na base de dados. Vamos computar tanto a degradação determinística de privacidade quanto a probabilística para este adversário.

- **Degradação determinística de privacidade**

Como a base de dados D possui mais do que um registro, nenhum indivíduo na base pode ser reidentificado com certeza sem informação auxiliar. Dessa forma, o sucesso determinístico a priori do adversário é de 0%, pois esta é a fração de indivíduos reidentificáveis com absoluta certeza na base.

Ao realizar o ataque, entretanto, o adversário pode utilizar *idade* e *sexo* dos indivíduos como informação auxiliar. Note, porém, que em D apenas dois registros possuem uma combinação única de valores para os atributos de *idade* e *sexo* (o registro de *id* 9, um homem de *idade* 4, e o registro de *id* 10, um homem de *idade* 5), significando que apenas dois registros na base podem ser reidentificados com absoluta certeza apenas pelo valor destes quaseidentificadores. Como o tamanho da base é $|D| = 10$, o sucesso determinístico a posteriori do adversário é de $2/10=20\%$, significando que usando apenas *idade* e *sexo* como informação auxiliar, o adversário pode reidentificar 20% dos registros na base.

A correspondente degradação determinística de privacidade é, então de $20\% - 0\% = 0\%$, significando que o uso de *idade* e *sexo* como informação auxiliar produz um aumento absoluto de 20% na quantidade de registros que passam a ser reidentificáveis com absoluta certeza na base de dados.

• Degradação probabilística de privacidade

Note que sem informação auxiliar, o melhor que o adversário pode fazer para reidentificar um indivíduo aleatoriamente selecionado na base é “adivinhar no escuro” qual registro, dentre todos os presentes na base D , corresponde ao indivíduo em questão. Como na base há 10 registros, o sucesso probabilístico a priori do adversário é de 10%.

Entretanto, ao realizar o ataque, o adversário pode utilizar os valores dos quaseidentificadores *idade* e *sexo* de todos os indivíduos como informação auxiliar. Note que, neste caso, o adversário pode particionar a base D em 5 blocos, cada um contendo todos os registros que compartilham o mesmo valor para os atributos *idade* e *sexo*: um bloco contendo os 3 registros cuja combinação de *idade* e *sexo* é $\langle 2, F \rangle$ (registros de *id*'s 1, 2 e 3); um bloco contendo os 2 registros cuja combinação de *idade* e *sexo* é $\langle 2, M \rangle$ (registros de *id*'s 4 e 5); um bloco contendo os 3 registros cuja combinação de *idade* e *sexo* é $\langle 4, F \rangle$ (registros de *id*'s 6, 7 e 8); um bloco contendo o único registro cuja combinação de *idade* e *sexo* é $\langle 4, M \rangle$ (registro de *id* 9); e um bloco contendo o único registro cuja combinação de *idade* e *sexo* é $\langle 5, M \rangle$ (registro de *id* 10). Note que tanto no bloco com valores de quaseidentificadores $\langle 2, F \rangle$ quanto no bloco com valores $\langle 4, F \rangle$ o adversário tem 33.33% de probabilidade de reidentificar um indivíduo corretamente (pois cada bloco tem 3 registros). Já no bloco com valores $\langle 2, M \rangle$, a probabilidade de sucesso é de 50% (pois o bloco tem 2 registros). Por fim, nos blocos com valores $\langle 4, M \rangle$ e $\langle 5, M \rangle$, a probabilidade de sucesso é de 100% (pois cada bloco só tem 1 registro). Ponderando pelo fato de que um indivíduo aleatoriamente selecionado tem 30% de chance de pertencer ao bloco de valores $\langle 2, F \rangle$ (pois 3 dos 10 registros têm esses valores), 20% de chance de pertencer ao bloco de valores $\langle 2, M \rangle$ (2 registros em 10), 30% de chance de pertencer ao bloco de valores $\langle 4, F \rangle$ (3 registros em 10), 10% de chance de pertencer ao bloco de valores $\langle 4, M \rangle$ (1 registro em 10), 10% de chance de pertencer ao bloco de valores $\langle 5, M \rangle$ (1 registro em 10), o sucesso probabilístico a posteriori do adversário pode ser computado como $30\% \cdot 33.33\% + 20\% \cdot 50\% + 30\% \cdot 33.33\% + 10\% \cdot 100\% + 10\% \cdot 100\% = 50\%$,

o que significa que, ao usar *idade* e *sexo* como informação auxiliar, espera-se que um indivíduo aleatoriamente selecionado como alvo na base possa ser reidentificado com probabilidade de 50%.

Portanto, a correspondente degradação probabilística de privacidade é de $50\%/10\% = 5$, o que reflete que o sucesso probabilístico do adversário, ao utilizar *idade* e *sexo* como informação auxiliar, aumenta por um fator de 5.

◁

4.1.2 Considerações sobre riscos de inferência de atributo sensível

Uma vez que o adversário tenha reidentificado o titular de um registro em uma base sanitizada apenas por desidentificação e pseudonimização, ele tem conhecimento com certeza absoluta de que os valores dos atributos sensíveis daquele indivíduo são exatamente os reportados no registro sanitizado.

Por esta razão, a degradação de privacidade em ataques de inferência de atributos sensíveis nestas bases é no mínimo tão elevada quanto a degradação de privacidade em ataques de reidentificação. O seguinte exemplo ilustra esta situação.

Exemplo 4 (Inferência de atributo sensível após reidentificação exitosa em uma única base de dados sanitizada por desidentificação e pseudononimização). Considere novamente a base de dados D sobre o conjunto de atributos $\mathcal{A}$ do Exemplo 1. Assuma que o adversário tenha tido sucesso em reidentificar Bruna como a titular do registro sanitizado de $id=2$. Assuma que o atributo considerado sensível seja *deficiência*. O adversário observa que Bruna tem o valor *sim* para este atributo na base sanitizada, logo ele pode concluir com absoluta certeza que ela é portadora de deficiência. $\triangleleft$

4.2 Resultados de ataques de reidentificação coletiva em uma única base de dados sanitizada por desidentificação e pseudonimização (RCU)

Ataques RCU sobre a base do Censo da Educação Básica de 2019 já foram analisados no Produto 02 do presente TED 8750. A seguir refazemos nossa análise sobre ataques deste tipo em duas versões do Censo da Educação Básica de 2019 com o número e granularidade de atributos reduzidos: uma completa, contendo os registros correspondentes ao Brasil, e uma restrita aos registros do Distrito Federal.

Experimento 5 (Ataques de reidentificação coletiva sobre uma única base sanitizada por desidentificação e pseudonimização RCU, sobre o Censo da Educação Básica de 2019). Para este experimento usamos a base original do Censo da Educação Básica de 2019, que contém 47 640 822 registros após tratamento. Também usamos a base original restrita ao Distrito Federal, que contém 654 413 registros após tratamento.

Como modelo de informação auxiliar do adversário consideramos tanto o conjunto reduzido de 7 quaseidentificadores quanto o conjunto expandido de 23 quaseidentificadores descritos na Tabela 3.3.2.

Medimos, então, a degradação de privacidade (tanto determinística quando probabilística) para cada uma dessas combinações de quaseidentificadores em cada base. A Tabela 4.2.2 sumariza a degradação de privacidade neste ataque.

Separamos a discussão dos resultados pelo tipo de degradação de privacidade.

- **Sucesso determinístico do adversário:** Este tipo de sucesso é medido como a fração dos indivíduos da base que podem ser reidentificados com absoluta certeza.

A Tabela 4.2.2a demonstra que no caso da base completa, o sucesso determinístico a priori do adversário é de 0%, significando que sem informação auxiliar nenhum indivíduo pode ser reidentificado com absoluta certeza na base. Por outro lado, o uso de 7 quaseidentificadores permite ao adversário reidentificar com absoluta certeza até 0.038608% dos indivíduos na base (ou 18 393 registros); enquanto que o uso de 23 quaseidentificadores pode aumentar este valor a 0.269762% da base (ou 128 517 registros).

A Tabela 4.2.2b apresenta os resultados correspondentes no universo reduzido aos registros do Distrito Federal.

- **Sucesso probabilístico do adversário:** Este tipo de sucesso é medido como a probabilidade de que um indivíduo escolhido aleatoriamente seja reidentificado com sucesso na base.

A Tabela 4.2.2a demonstra que o sucesso probabilístico a priori do adversário (que é inversamente proporcional ao número de registros totais) na base completa é da ordem de 0.000002%, significando que sem nenhuma informação auxiliar o adversário tem uma chance ínfima de reidentificar qualquer indivíduo com absoluta certeza.

Por outro lado, a combinação de 7 quaseidentificadores permite ao adversário reidentificar um indivíduo aleatoriamente selecionado como alvo com probabilidade de 0.404132% após a realização do ataque; enquanto uma combinação de 23 quaseidentificadores pode elevar essa chance de sucesso a até 2.243502%.

A Tabela 4.2.2b apresenta os resultados correspondentes no universo reduzido aos registros do Distrito Federal.

Análise do efeito da redução do número e granularidade de atributos divulgados na degradação de privacidade. Os resultados do presente experimento não são diretamente comparáveis àqueles realizados no Produto 02, uma vez que o tratamento das bases não foi estritamente idêntico. Entretanto, podemos obter algumas evidências do efeito da redução do número e granularidade de atributos na divulgação da base do Censo da Educação Básica de 2019 na degradação de privacidade comparando os resultados do presente experimento com aqueles do experimento análogo realizado no Produto 02 do presente TED 8750.

Em particular, naquele experimento observamos que:

- Uma combinação de 3 quaseidentificadores permitia ao adversário reidentificar com absoluta certeza até 14.54% dos indivíduos na base (6 926 976 registros) enquanto que uma combinação de 4 quaseidentificadores pode aumentar este valor a até 33.12% (15 778 640 registros). Já o uso de 10 quaseidentificadores elevava o risco a 60.90% (29 013 261 registros).

- Uma combinação de 3 quaseidentificadores permitia ao adversário reidentificar um indivíduo aleatoriamente selecionado como alvo com probabilidade de até 29.64% após a realização do ataque; enquanto uma combinação de 4 quaseidentificadores podia elevar essa chance de sucesso a até 49.86%. Já o uso de 10 quaseidentificadores elevava o risco a 75.51%.

Estes resultados sugerem que a redução do número e granularidade de atributos divulgados na base pode ter, em si mesma, um efeito de redução da degradação de privacidade, tanto determinística quanto probabilística. Tal efeito deve decorrer de uma menor disponibilidade para o adversário de quaseidentificadores poderosos com alta precisão (como data de nascimento de um indivíduo). De fato, nos novos experimentos, mesmo usando como quaseidentificadores um grande número de atributos divulgados, houve redução na degradação de privacidade. Entretanto, é possível observar que ainda assim um número significativo de indivíduos está exposto a um risco considerável. De fato, de 18 393 a 128 517 registros puderam ser reidentificados com absoluta certeza em nossos novos experimentos.

<

		Sucesso determinístico do adversário		Sucesso probabilístico do adversário	
		Sucesso a priori = 0.000000% (0 registros)		Sucesso a priori = 0.000002%	
#	QIDs	Sucesso a posteriori	Degradação privacidade	Sucesso a posteriori	Degradação privacidade
7	Conjunto reduzido	0.038608% (18 393 registros)	0.038608% (18 393 registros)	0.404132%	192 532
23	Conjunto estendido	0.269762% (128 517 registros)	0.269762% (128 517 registros)	2.243502%	1 068 823

(a) Resultados sobre o Censo da Educação Básica de 2019 completo.

		Sucesso determinístico do adversário		Sucesso probabilístico do adversário	
		Sucesso a priori = 0.000000% (0 registros)		Sucesso a priori = 0.000153%	
#	QIDs	Sucesso a posteriori	Degradação privacidade	Sucesso a posteriori	Degradação privacidade
7	Conjunto reduzido	0.000611% (4 registros)	0.000611% (4 registros)	0.022310%	146
23	Conjunto estendido	0.021546% (141 registros)	0.021546% (141 registros)	0.188566%	1 234

(b) Resultados sobre o Censo da Educação Básica de 2019 restrito a registros do Distrito Federal.

Tabela 4.2.2: Experimento 5: Resultados de ataques de reidentificação coletiva em uma única base de dados sanitizada por desidentificação e pseudonimização (RCU), sobre o Censo da Educação Básica de 2019. Recorde que a degradação determinística de privacidade é dada pela diferença entre o sucesso a posteriori e o a priori do adversário, enquanto a degradação probabilística é dada pela razão dos mesmos dois termos.

5 Análise de privacidade após sanitização por amostragem

Nesta seção apresentamos as análises experimentais quantitativas da degradação de privacidade decorrente da aplicação de sanitização por amostragem à base do Censo da Educação Básica de 2019. Iniciamos por uma discussão do método de sanitização por amostragem empregado neste projeto piloto. Em seguida apresentamos o modelo adotado de ataque a uma única base sanitizada por amostragem, e por fim provemos os resultados experimentais obtidos.

5.1 Fundamentos da sanitização de microdados por amostragem

Uma discussão de métodos de sanitização por amostragem foi provida no Produto 03 do presente TED 8750. Aqui revisamos os pontos fundamentais para este projeto piloto.

A técnica de amostragem não perturbativa visa a mitigar os riscos de reidentificação ou inferência de atributo sensível de indivíduos ao quebrar a premissa de que o adversário já sabe a priori que todos os indivíduos de interesse estão na base. Mais especificamente, espera-se que, mesmo que o adversário consiga isolar na amostra um único registro que combine com a informação auxiliar que ele possui sobre um indivíduo-alvo, não haja certeza de que o registro isolado pertença mesmo ao alvo, pois ele pode nem mesmo estar na amostra.

Vários curadores de dados utilizam a técnica de divulgar microdados de apenas uma amostra aleatoriamente selecionada da população. Como relatado no Produto 01 do presente TED 8750, todas as agências federais dos Estados Unidos que publicam microdados o fazem, necessariamente, por meio da divulgação de amostras da população. Ao todo, 11 agências federais reportavam a publicação de microdados por amostragem em 2005, incluindo o *Bureau of Economic Analysis*, o *United States Census Bureau*, o *National Center for Education Statistics*, o *National Center for Health Statistics*, e o *Bureau of Labor Statistics* [54]. Ainda no cenário internacional, o Escritório Australiano de Estatística, responsável pela realização do Censo na Austrália, também disponibilizou, até

o Censo de 2016, microdados apenas para amostras da população e, ainda assim, sob restrições de acesso. O mesmo ocorre para o Censo Longitudinal Australiano, criado a partir de amostras aleatórias com correspondência entre as edições do Censo [53]. Já a Holanda optou, em 1991, por abolir o Censo em favor de técnicas por amostragem, ou seja, não apenas a divulgação, mas também a coleta de dados é realizada por amostras aleatórias [1].

Já no cenário nacional, o IBGE divulga microdados por amostragem tanto no contexto das Pesquisas Domiciliares por Amostragem Probabilística, quanto dos Censos Demográficos Decenais. No primeiro caso, a seleção da amostra aleatória da população ocorre ainda durante a etapa da coleta dos dados, como realizado pela Holanda, enquanto que no caso dos Censos Demográficos, o IBGE divulga microdados apenas para a parcela de investigação por amostragem [21].

5.2 Modelo de sanitização por amostragem empregado neste projeto piloto

Para a análise de riscos à privacidade e utilidade dos dados, consideramos no presente documento as bases de dados geradas através da técnica de amostragem desenhada pelo próprio Inep. A técnica empregada consiste na estratificação da base de dados de acordo com variáveis de interesse cuja proporção na amostra deve ser preservada. O método de estratificação utiliza novas variáveis inseridas na base de dados derivadas de variáveis já existentes:

- CO_MUNICIPIO2, correspondente ao código do município do indivíduo;
- ETAPA_SUB_POP, derivada de TP_ETAPA_INDICADOR;
- REDE_SUB_POP2, derivada de TP_DEPENDENCIA;
- ESTRATO_SELECAO2, derivada da combinação entre TP_TIPO_ATENDIMENTO_TURMA e TP_ETAPA_INDICADOR.

Para aplicar as técnicas de análise de risco de privacidade e utilidade sobre a amostra, realizamos uma união entre o arquivo que contém os estratos e o arquivo que contém a base de dados original utilizando o campo ID_MATRICULA, como foi recomendado pelo Inep, de tal forma que a amostra inclua todas as subpopulações de interesse.

5.3 Modelo de degradação de privacidade em uma única base de dados sanitizada por amostragem

Nesta seção nos focamos na situação em que o adversário deseja reidentificar o maior número de indivíduos possível na base sanitizada, independentemente de quem sejam.

Capturamos este cenário como um ataque de reidentificação coletiva em uma única base de dados sanitizada por amostragem (RCU^{ams}), descrito na Seção 5.3.1. Além disso, tecemos considerações sobre o risco de inferência de atributos sensíveis, apresentadas na Seção 5.3.2.

Para propiciar uma leitura mais fluida do presente documento, os detalhes matemáticos da formalização dos ataques RCU^{ams} são reservados ao Anexo C. As análises experimentais quantitativas da aplicação do modelo às bases dos Censos Educacionais do Inep são apresentadas na Seção 5.4.

5.3.1 Ataque de reidentificação coletiva em uma única base de dados sanitizada por amostragem (RCU^{ams})

Seguindo a literatura técnica da área [34], assumimos premissas cautelosas a fim de não subestimar as capacidades do adversário. Mais precisamente, assumimos que o adversário tem acesso completo à base sanitizada e que ele conhece o processo de sanitização utilizado. Além disso, assumimos que o adversário tem como informação auxiliar a priori um arquivo de nomes contendo uma identificação única de todos os indivíduos da população de interesse. Tais premissas são necessárias quando estamos preocupados com garantias de privacidade providas a cada indivíduo de forma independente dos demais (como é o caso das garantias previstas na LGPD brasileira).

O modelo mede, então, a degradação de privacidade de cada ataque em termos do quanto a informação auxiliar a respeito de quaseidentificadores obtida por um adversário pode facilitar a obtenção de informação sensível de indivíduos na base sanitizada por amostragem.

5.3.1.1 Premissas

Assumimos as seguintes premissas em relação ao ataque de reidentificação coletiva em uma única base de dados sanitizada por amostragem.

PS₀^{ams} Existe uma base de dados original D de interesse definida sobre um conjunto de atributos $\mathcal{A}$, à qual o adversário não tem acesso direto.

PS₁^{ams} A técnica de mitigação de danos à privacidade produz uma base sanitizada D' obtida a partir da base original D através de um plano amostral público e conhecido pelo adversário, conforme o método descrito na Seção 5.2. Em particular, cada registro de D selecionado pelo plano amostral tem seu atributo de identificação única (e.g., *nome*) removido antes de ser adicionado à base sanitizada D' . A base sanitizada D' é divulgada publicamente e está disponível para consulta pelo adversário.

- PS₂^{ams}** O adversário possui como informação a priori –antes de executar o ataque– uma lista contendo os nomes (ou qualquer outro identificador único, como RG ou CPF) de todos os indivíduos presentes na base original D . Tal lista é representada em um arquivo de nomes $Nomes_D$, o qual possui o mesmo tamanho da base original D , i.e., $|Nomes_D| = |D|$.
- PS₃^{ams}** Existe um conjunto $\mathcal{Q}_{ID} \in \mathcal{A}$ de *quaseidentificadores* correspondendo a atributos cujos valores para os indivíduos da base original D podem ser conhecidos ou aprendidos pelo adversário. Quando o adversário aprende tais valores ele os organiza em um arquivo Aux_D de informação auxiliar, que expande o arquivo de nomes $Nomes_D$ ao associar a cada nome de indivíduo os valores dos seus atributos quaseidentificadores. O arquivo auxiliar possui o mesmo tamanho que a base original D , i.e., $|Aux_D| = |D|$.
- PS₄^{ams}** Cada indivíduo de interesse possui no máximo um registro na base de dados original D . Consequentemente, cada indivíduo possui no máximo um registro também na base sanitizada D' , no arquivo de nomes $Nomes_D$, e no arquivo auxiliar Aux_D .
- PS₅^{ams}** O conhecimento prévio do adversário inclui o plano amostral que gera a base sanitizada D' a partir da base original D , o arquivo de nomes $Nomes_D$, e o fato de que cada indivíduo aparece no máximo uma vez em D . Durante o ataque o adversário obtém como informação auxiliar (via outras fontes que não a base sanitizada D' ou o arquivo de nomes $Nomes_D$) os valores dos quaseidentificadores em $\mathcal{Q}_{ID}$ para todos indivíduos na base original, montando o arquivo auxiliar Aux_D . O ataque consiste, então, em cruzar as informações entre o arquivo auxiliar Aux_D e a base sanitizada D' a fim de obter informação sensível a respeito dos indivíduos presentes na última. A degradação de privacidade é, portanto, medida como a comparação do sucesso do adversário a posteriori –i.e., após cruzar a informação auxiliar sobre os valores dos quaseidentificadores com a base sanitizada– e seu sucesso a priori –i.e., antes de poder usar a informação sobre quaseidentificadores. Esses elementos são esquematizados na Figura 5.3.1.

Estamos, então, prontos para definir o ataque.

5.3.1.2 Descrição do ataque

Em um *ataque de reidentificação coletiva em uma única base de dados sanitizada por amostragem* (RCU^{ams}), o adversário tem acesso completo a uma única base de dados amostral –conhecendo todos os seus registros– obtida a partir de uma base original através de um plano amostral público. O adversário tem como informação auxiliar a priori –i.e., antes do ataque– um arquivo de nomes contendo, para cada indivíduo da base original, sua identificação única (e.g., nome completo ou RG). Um indivíduo presente na base amostral é reidentificado quando o adversário encontra a correspondência correta entre




Figura 5.3.1: Esquema de ataque de reidentificação coletiva em uma única base de dados sanitizada por amostragem (RCU^{ams}). No tipo de ataque aqui considerado a degradação de privacidade é medida em termos do quanto a informação auxiliar a respeito de quaseidentificadores na base sanitizada obtida por um adversário pode facilitar a recuperação de informação sensível.

o registro de tal indivíduo na base amostral e um nome correspondente no arquivo de nomes. Durante o ataque, o adversário é capaz de obter como informação lateral um arquivo auxiliar que expande o arquivo de nomes com os valores de um conjunto de quaseidentificadores para todos os indivíduos no arquivo. O adversário cruza, então, o arquivo auxiliar com a base amostral na tentativa de reidentificar o maior número possível de indivíduos, independentemente de quem sejam.

A degradação de privacidade do ataque é medida como uma comparação entre o sucesso a priori do adversário (i.e., conhecendo apenas a base de dados sanitizada e o arquivo de nomes, mas não ainda o arquivo auxiliar contendo os valores dos quaseidentificadores dos indivíduos) e seu sucesso a posteriori (i.e., após ter acesso ao arquivo auxiliar e cruzá-lo com a base sanitizada). Mais precisamente, temos as seguintes condições para um ataque RCU^{ams}:

- **Quantificação da degradação determinística de privacidade:** A medição do sucesso determinístico de um ataque coletivo RCU^{ams} leva em conta que adversário tem como alvo todos os indivíduos presentes na base sanitizada D' , independente de quem eles sejam. Portanto, define-se tal sucesso como a razão entre o número de indivíduos da base sanitizada que podem ser reidentificados com absoluta certeza e o número de indivíduos total na base amostral, levando em conta o acesso ao arquivo de informação auxiliar. A degradação determinística de privacidade do ataque é definida, então, como a diferença pela qual sua execução aumenta o sucesso determinístico do adversário.

- **Quantificação da degradação probabilística de privacidade:** Na medição do sucesso probabilístico de um ataque coletivo RCU^{ams} , não se exige que o adversário realize a reidentificação de todos os indivíduos com absoluta certeza; em vez disso quantifica-se a probabilidade de um indivíduo aleatoriamente escolhido como alvo na base sanitizada ser reidentificado com sucesso através de cruzamento com o arquivo auxiliar. Quanto maior essa probabilidade, mais exitoso é o adversário, e maior é o risco esperado de cada indivíduo ser reidentificado. A degradação probabilística de privacidade do ataque é definida, então, como a razão pela qual sua execução aumenta o sucesso probabilístico do adversário.

A Definição 26 no Anexo C formaliza matematicamente o ataque RCU^{ams} . A seguir ilustramos como o ataque é executado em nosso exemplo condutor.

Exemplo 6 (Execução de ataque de reidentificação coletiva em uma única base de dados sanitizada por amostragem (RCU^{ams})). Considere novamente a base de dados D sobre o conjunto de atributos $\mathcal{A}$ do Exemplo 1. Recorde que, de acordo com as premissas sobre ataques em uma única base, cada indivíduo de interesse possui no máximo um registro em D .

O cenário do presente exemplo é ilustrado na Tabela 5.3.2. A base original D , representada na Tabela 5.3.2a, contém todos os atributos de todos os indivíduos. A base sanitizada D' , representada na Tabela 5.3.2b, é obtida a partir de D por amostragem (e eliminando a coluna do atributo *nome*, que funciona como um identificador único). Note que D' mantém 50% da população original (5 registros em 10). O adversário possui como informação auxiliar a priori uma lista com os nomes de todos os indivíduos de D , organizada no arquivo $Nomes_D$, representado na Tabela 5.3.2c. Ao realizar o ataque, o adversário pode aprender os valores do conjunto $\mathcal{Q}_{ID} = \{idade, sexo\}$ de quaseidentificadores para todos os indivíduos em D . Esta informação auxiliar é organizada no arquivo auxiliar Aux_D , representado na Tabela 5.3.2d, que estende o arquivo de nomes original com os valores aprendidos.

A seguir ilustramos como computar tanto a degradação determinística de privacidade quanto a probabilística para este adversário.

- **Degradação determinística de privacidade**

Antes de realizar o ataque, o adversário pode escolher qualquer registro na base sanitizada D' como alvo de reidentificação. Neste momento, a única informação disponível para o adversário é a lista $Nomes_D$ com os nomes de todos os indivíduos presentes na base original D . Apenas com essas informações, qualquer registro de D' pode em princípio corresponder a qualquer indivíduo em $Nomes_D$, e o adversário não pode reidentificar com absoluta certeza nenhum registro de D' (a não ser no caso extremo em que D tenha apenas um indivíduo). Assim, o sucesso determinístico a priori do adversário é de 0%, pois antes do ataque nenhum dentre os 5 registros na base sanitizada D' pode ser reidentificado com absoluta certeza.

Ao realizar o ataque, entretanto, o adversário pode aprender os valores do conjunto $\mathcal{Q}_{ID} = \{idade, sexo\}$ de quaseidentificadores para todos os indivíduos em D . Esta informação auxiliar, sumarizada no arquivo auxiliar Aux_D , pode ser utilizada pelo adversário para tentar determinar a correspondência entre registros em D' e indivíduos em $Nomes_D$ da seguinte forma. Primeiro, o adversário seleciona os registros na base sanitizada D' que tenham uma combinação única de valores para os quaseidentificadores de *idade* e *sexo*. No nosso exemplo, isso incluiria apenas os registros de *id* 2 (com valores $\langle 2, F \rangle$), de *id* 8 (com valores $\langle 4, F \rangle$) e de *id* 10 (com valores $\langle 5, M \rangle$), já que os registros de *id*'s 4 e 5 compartilham os mesmos quaseidentificadores (com valores $\langle 2, M \rangle$). Em seguida, para cada registro com QID's únicos em D' (i.e., os indivíduos de *id*'s 2, 8 e 10), adversário checka se eles podem ser unicamente identificados por estes QID's no arquivo auxiliar Aux_D . Mais precisamente, o adversário observa que o registro de *id* 2 em D' não pode ser reidentificado em Aux_D com absoluta certeza, pois há 3 indivíduos naquele arquivo que possuem os mesmos valores de quaseidentificadores: Ana, Bruna e Célia. Também o registro de *id* 8 em D' não pode ser reidentificado com absoluta certeza no arquivo Aux_D , pois há 3 indivíduos naquele arquivo com os mesmos valores de quaseidentificadores: Flávia, Geórgia e Helena. Por fim, o registro de *id* 10 em D' pode ser reidentificado com absoluta certeza no arquivo Aux_D , pois apenas um indivíduo naquele arquivo possui os mesmos valores de quaseidentificadores: João. Dessa forma, o adversário consegue reidentificar com absoluta certeza apenas 1 registro (o de *id* 10, correspondente a João), dentre os 5 registros da base sanitizada D' , e seu sucesso determinístico a posteriori é medido como a razão $1/5 = 20\%$.

A correspondente degradação determinística de privacidade é, então de $20\% - 0\% = 20\%$, significando que o uso de idade e sexo como informação auxiliar produz um aumento absoluto de 20% na quantidade de registros que passam a ser reidentificáveis com absoluta certeza na base de dados sanitizada por amostragem.

• Degradação probabilística de privacidade

Note que, antes de realizar o ataque, o adversário pode escolher qualquer registro aleatório na base sanitizada D' como alvo. Assumimos que esta escolha é feita de forma uniforme, ou seja, que a probabilidade de qualquer registro em D' ser escolhido como alvo é de $1/5 = 20\%$, uma vez que D' tem 5 registros. Neste momento, a única informação disponível para o adversário é a lista $Nomes_D$ com os nomes de todos os indivíduos presentes na base original D . Neste caso, o melhor que o adversário pode fazer para reidentificar um registro aleatoriamente selecionado na base sanitizada D é “adivinhar no escuro” qual indivíduo, dentre todos os presentes no arquivo $Nomes_D$, corresponderia ao registro-alvo. Como no arquivo de nomes há 10 registros, o sucesso probabilístico a priori do adversário é de $1/10 = 10\%$.

Ao realizar o ataque, entretanto, o adversário pode aprender os valores do conjunto $\mathcal{Q}_{ID} = \{idade, sexo\}$ de quaseidentificadores para todos os indivíduos em D . Esta informação auxiliar, sumarizada no arquivo auxiliar Aux_D , pode ser utilizada pelo adversário para tentar determinar a correspondência entre registros em

D' e indivíduos em $Nomes_D$ da seguinte forma. Para cada registro na base sanitizada D' , o adversário seleciona todos os indivíduos no arquivo auxiliar Aux_D que compartilham os mesmos valores de quaseidentificadores do registro-alvo. O que o adversário está fazendo é, de fato, selecionar no arquivo auxiliar Aux_D os indivíduos compatíveis com cada registro em D' . Por exemplo, o adversário começa pelo registro de *id* 2 na base sanitizada D' e determina que ele pode corresponder aos indivíduos Ana, Bruna ou Célia no arquivo auxiliar Aux_D , uma vez que todos eles compartilham os valores $\langle 2, F \rangle$ para os quaseidentificadores *idade* e *sexo*. Apenas com estas informações, o melhor que o adversário pode fazer é “adivinhar no escuro” qual dentre os 3 indivíduos compatíveis corresponderia de fato ao registro de *id* 2. Neste caso, a probabilidade de sucesso do adversário é de $1/3 = 33\%$. De forma semelhante, ao seguir para o registro de *id* 4 em D' , o adversário determina que o indivíduo correspondente no arquivo auxiliar Aux_D pode ser tanto Danilo quanto Enzo, pois ambos compartilham os valores $\langle 2, M \rangle$. A correspondente probabilidade de sucesso de reidentificação para este registro é, portanto, $1/2 = 50\%$. O mesmo processo é repetido para os registros em D' de *id*'s 5, 8 e 10, obtendo uma probabilidade de sucesso de, respectivamente, $1/2 = 50\%$ (dois indivíduos possíveis, Danilo e Enzo), $1/3 = 33.33\%$ (três indivíduos possíveis, Flávia, Geórgia e Helena) e $1/1 = 100\%$ (apenas um indivíduo possível, João). Ainda assumindo que o adversário tem uma probabilidade uniforme de escolher qualquer indivíduo de D' como alvo (ou seja, $1/5 = 20\%$, uma vez que D' tem 5 registros), seu sucesso probabilístico a posteriori pode ser computado como a esperança da probabilidade de sucesso tomada sobre todos os indivíduos de D' : $20\% \cdot 33.33\% + 20\% \cdot 50\% + 20\% \cdot 50\% + 20\% \cdot 33.33\% + 20\% \cdot 100\% = 53.33\%$. Desta forma, ao usar *idade* e *sexo* como informação auxiliar, espera-se que um indivíduo aleatoriamente selecionado como alvo na base possa ser reidentificado com probabilidade de 53.33%.

Portanto, a correspondente degradação probabilística de privacidade é de $53.3\%/10\% = 5.33$ o que reflete que o sucesso probabilístico do adversário, ao utilizar *idade* e *sexo* como informação auxiliar, aumenta por um fator de 5.33 na base sanitizada.

◁

<i>id</i>	<i>nome</i>	<i>idade</i>	<i>sexo</i>	<i>escola</i>	<i>deficiência</i>
1	Ana	2	F	A	não
2	Bruna	2	F	A	sim
3	Célia	2	F	C	sim
4	Danilo	2	M	B	sim
5	Enzo	2	M	B	não
6	Flávia	4	F	C	sim
7	Geórgia	4	F	C	sim
8	Helena	4	F	E	não
9	Ivo	4	M	D	não
10	João	5	M	D	não

(a) Base de dados original D .

<i>id</i>	<i>idade</i>	<i>sexo</i>	<i>escola</i>	<i>deficiência</i>
2	2	F	A	sim
4	2	M	B	sim
5	2	M	B	não
8	4	F	E	não
10	5	M	D	não

(b) Base de dados sanitizada D' , obtida a partir de D por amostragem.

<i>nome</i>
Ana
Bruna
Célia
Danilo
Enzo
Flávia
Geórgia
Helena
Ivo
João

(c) Arquivo $Nomes_D$ representando a informação a priori do adversário: lista de identificação única (*nome*) de todos os indivíduos que fazem parte da base original D .

<i>nome</i>	<i>idade</i>	<i>sexo</i>
Ana	2	F
Bruna	2	F
Célia	2	F
Danilo	2	M
Enzo	2	M
Flávia	4	F
Geórgia	4	F
Helena	4	F
Ivo	4	M
João	5	M

(d) Arquivo auxiliar Aux_D representando a informação auxiliar utilizada pelo adversário durante um ataque: informação a priori acrescida dos valores de quaseidentificadores reais de todos os indivíduos na base original D .Tabela 5.3.2: Exemplo 6: Ataque de reidentificação coletiva em uma única base sanitizada por amostragem (RCU^{ams}) sobre o exemplo condutor.

5.3.2 Considerações sobre riscos de inferência de atributo sensível

Quando a sanitização por amostragem consiste apenas em selecionar um subconjunto de registros da base original para ser representado na base sanitizada, um ataque de reidentificação exitoso implica em um sucesso imediato do adversário em inferir todos os valores de atributos sensíveis do indivíduo reidentificado que se encontrem na base sanitizada. Em outras palavras, uma vez que o adversário tenha reidentificado o titular de um registro, ele tem conhecimento com certeza absoluta de que os valores dos atributos sensíveis daquele indivíduos são exatamente os reportados no registro sanitizado.

Por esta razão, a degradação de privacidade em ataques de inferência de atributos sensíveis no contexto do presente documento é no mínimo tão elevada quanto a degradação de privacidade em ataques de reidentificação.

O seguinte exemplo ilustra esta situação.

Exemplo 7 (Inferência de atributo sensível após reidentificação exitosa em uma única base de dados sanitizada por amostragem). Considere novamente a base de dados D sobre o conjunto de atributos $\mathcal{A}$ do Exemplo 1. Assuma que esta base tenha sido sanitizada por amostragem conforme o Exemplo 6. A base original D e a base sanitizada D' resultante são representadas na Tabela 5.3.2a e na Tabela 5.3.2b, respectivamente.

Assuma que o adversário tenha tido sucesso em reidentificar Bruna como a titular do registro sanitizado de $id=2$. Logo, o adversário sabe que o registro original de Bruna foi sanitizado para o registro em D' com valores $\langle 2, 2, F, A, \text{sim} \rangle$. Assuma que o atributo considerado sensível seja *deficiência*. O adversário observa que Bruna tem o valor *sim* para este atributo na base sanitizada D' , logo ele pode concluir com absoluta certeza que ela é portadora de deficiência. $\triangleleft$

5.4 Resultados de ataques de reidentificação coletiva em uma única base de dados sanitizada por privacidade diferencial local (RCU^{ams})

A seguir provemos nossa análise sobre ataque RCU^{ams} em duas versões da base amostral do Censo da Educação Básica de 2019: uma completa, contendo os registros correspondentes ao Brasil, e uma restrita aos registros do Distrito Federal.

Experimento 8 (Ataques de reidentificação coletiva sobre uma única base sanitizada por amostragem RCU^{ams} , sobre o Censo da Educação Básica de 2019). Para este experimento usamos a base amostral produzida pelo Inep a partir do Censo da Educação Básica de 2019, que contém 13 592 096 registros após tratamento, o que equivale a cerca de 28% da base original (que contém 47 640 822 registros após tratamento). Também usamos a base amostral restrita ao Distrito Federal, que contém 13 691 registros após tratamento.

Como modelo de informação auxiliar do adversário consideramos tanto o conjunto reduzido de 7 quaseidentificadores quanto o conjunto expandido de 23 quaseidentificadores descritos na Tabela 3.3.2.

Medimos, então, a degradação de privacidade (tanto determinística quanto probabilística) para cada uma dessas combinações de quaseidentificadores em cada base. A Tabela 5.4.3 sumariza a degradação de privacidade neste ataque.

Separamos a discussão dos resultados pelo tipo de degradação de privacidade.

- **Sucesso determinístico do adversário:** Este tipo de sucesso é medido como a fração dos indivíduos da base que podem ser reidentificados com absoluta certeza.

A Tabela 5.4.3a demonstra que no caso da base amostral com dados de todo o Brasil, o sucesso determinístico a priori do adversário é de 0%, significando que sem informação auxiliar nenhum indivíduo pode ser reidentificado com absoluta certeza na base amostral. Por outro lado, o uso de 7 quaseidentificadores permite ao adversário reidentificar com absoluta certeza até 0.094268% dos indivíduos na base amostral (ou 12 813 registros); enquanto que o uso de 23 quaseidentificadores pode aumentar este valor a 0.638320% da base (ou 86 761 registros).

A Tabela 5.4.3b apresenta os resultados correspondentes no universo reduzido aos registros do Distrito Federal.

- **Sucesso probabilístico do adversário:** A Tabela 5.4.3a demonstra que o sucesso probabilístico a priori do adversário (que é inversamente proporcional ao número de registros total) na base completa é da ordem de 0.000002%, significando que sem nenhuma informação auxiliar o adversário tem uma chance ínfima de reidentificar qualquer indivíduo com absoluta certeza.

Por outro lado, a combinação de 7 quaseidentificadores permite ao adversário reidentificar um indivíduo aleatoriamente selecionado como alvo com probabilidade de 0.902386% após a realização do ataque; enquanto uma combinação de 23 quaseidentificadores pode elevar essa chance de sucesso a até 4.686075%.

A Tabela 5.4.3b apresenta os resultados correspondentes no universo reduzido aos registros do Distrito Federal.

Análise do efeito da sanitização por amostragem na degradação de privacidade. Podemos analisar o efeito da sanitização por amostragem na degradação de privacidade comparando os resultados do presente experimento com aqueles do Experimento 5, em que apenas desidentificação e pseudonimização são usados como métodos de proteção de privacidade.

Em particular, observamos que a sanitização por amostragem reduziu significativamente a degradação determinística de privacidade:

- Usando 7 quaseidentificadores, houve uma redução de 18 393 para 12 813 indivíduos reidentificados com absoluta certeza.

- Usando 23 quaseidentificadores, houve uma redução de 128 517 para 86 761 indivíduos reidentificados com absoluta certeza.

Por outro lado, a degradação probabilística de privacidade permaneceu comparável tanto na base amostral quanto na original. Este efeito não é surpreendente, uma vez que uma base amostral representativa da população como um todo deve apresentar propriedades estatísticas comparáveis às desta população.

Entretanto, os resultados deste experimento indicam que a sanitização por amostragem reduz o risco de privacidade de indivíduos, mas ainda não a ponto de torná-lo irrisório. De fato, de 12 813 a 86 761 registros puderam ser reidentificados com absoluta certeza na base amostral em nossos experimentos.

◁

		Sucesso determinístico do adversário		Sucesso probabilístico do adversário	
		Sucesso a priori = 0.000000% (0 registros)		Sucesso a priori = 0.000002%	
#	QIDs	Sucesso a posteriori	Degradação privacidade	Sucesso a posteriori	Degradação privacidade
7	Conjunto reduzido	0.094268% (12 813 registros)	0.094268% (12 813 registros)	0.902386%	429 904
23	Conjunto estendido	0.638320% (86 761 registros)	0.638320% (86 761 registros)	4.686075%	2 232 485

(a) Resultados sobre a base amostral completa do Censo da Educação Básica de 2019.

		Sucesso determinístico do adversário		Sucesso probabilístico do adversário	
		Sucesso a priori = 0.000000% (0 registros)		Sucesso a priori = 0.000153%	
#	QIDs	Sucesso a posteriori	Degradação privacidade	Sucesso a posteriori	Degradação privacidade
7	Conjunto reduzido	0.007304% (1 registro)	0.007304% (1 registro)	0.069243%	453
23	Conjunto estendido	0.094953% (13 registros)	0.094953% (13 registros)	0.583066%	3 816

(b) Resultados sobre a base amostral do Censo da Educação Básica de 2019 restrita a registros do Distrito Federal.

Tabela 5.4.3: Experimento 8: Resultados de ataques de reidentificação coletiva em uma única base de dados sanitizada por amostragem (RCU^{ams}), sobre a base amostral do Censo da Educação Básica de 2019. Recorde que a degradação determinística de privacidade é dada pela diferença entre o sucesso a posteriori e o a priori do adversário, enquanto a degradação probabilística é dada pela razão dos mesmos dois termos.

6 Análise de privacidade após sanitização por privacidade diferencial local

Nesta seção apresentamos as análises experimentais quantitativas da degradação de privacidade decorrente da aplicação de sanitização por privacidade diferencial local à base do Censo da Educação Básica de 2019. Iniciamos com uma breve revisão dos princípios de privacidade diferencial local e apresentamos um exemplo de aplicação do método ao nosso exemplo condutor. Em seguida provemos o modelo de ataque a uma única base sanitizada por privacidade diferencial local usado em nossas análises. Por fim discutimos o método de sanitização por privacidade diferencial empregado neste projeto piloto e provemos os resultados experimentais obtidos.

6.1 Fundamentos da sanitização de microdados por privacidade diferencial local

No Produto 03 deste TED 8750 apresentamos uma discussão profunda de métodos de sanitização por privacidade diferencial. No Anexo A do presente documento provemos uma revisão da formulação matemática da privacidade diferencial local, dos mecanismos para atingi-la, e de suas propriedades fundamentais. O restante desta seção, entretanto, é dedicado a um sumário da filosofia essencial do método.

A motivação central por trás da privacidade diferencial local é que uma cuidadosa introdução de ruído em cada registro pode prover aos titulares dos dados um nível razoável de negação plausível sobre os valores reais de seus atributos –assim como sobre se o indivíduo está ou não na base. Como consequência, o titular pode negar de forma verossímil que qualquer de seus atributos tenha um valor específico, mesmo no pior caso em que o indivíduo tenha sido reidentificado e o adversário tenha tido acesso ao registro sanitizado divulgado.

O nível de ruído introduzido é controlado pelo valor de um parâmetro de privacidade ϵ . Quanto menor este valor, mais privados são os dados, porém mais ruído é introduzido e




Figura 6.1.1: Esquema de funcionamento da privacidade diferencial local. Ruído é adicionado individualmente aos dados de cada titular, antes dos mesmos serem organizados em uma base sanitizada. A partir daí, consultas propostas pelo analista são realizadas sobre a base sanitizada, ou então a base sanitizada pode ser ela mesma publicada integralmente.

maior é o risco de que a utilidade dos dados divulgados seja comprometida. É reconhecido na literatura técnica que a escolha do parâmetro ϵ mais adequado a cada aplicação é um desafio não trivial. Várias considerações têm sido feitas ao longo dos anos a respeito do problema (ver, e.g., [43, 33, 42]), mas ele ainda não pode ser considerado bem resolvido no caso geral. Na prática, um processo laborioso e extenso de refinamento, otimização e experimentação é usualmente necessário para que a privacidade diferencial possa atingir seu potencial máximo de utilidade.¹

O esquema de funcionamento geral da privacidade diferencial local é ilustrado na Figura 6.1.1. Essencialmente, ruído é adicionado aos dados de cada titular, e o curador agrupa esses dados já randomizados em uma base que pode ser considerada sanitizada de uma vez por todas.

Adicionar ruído diretamente aos dados dos titulares pode ser conveniente quando estes não confiam no curador. Neste caso, os próprios titulares podem adicionar ruído aos seus dados antes de enviá-los ao curador, tornando-o incerto sobre os dados de qualquer indivíduo em particular.

No caso dos Censos Educacionais do Inep, entretanto, a motivação para uso de privacidade diferencial local é outra, já que o Instituto é considerado um curador confiável. Entretanto, o Inep pode, ele mesmo, introduzir ruído aos dados de cada titular individu-

¹Como discutimos no Anexo F, o próprio Escritório do Censo dos Estados Unidos reporta os elevados recursos de tempo e pessoal técnico investidos para determinação do melhor valor de ϵ em sua tentativa de aplicar privacidade diferencial ao Censo Decenal do país em 2020 [28]. Apesar disso, o USCB continua a preparação para o uso do método, inclusive com a publicação de produtos de demonstração derivados dos microdados do Censo de 2010 [13], por entender que a privacidade diferencial é a melhor abordagem para o problema.

almente, obtendo assim uma base sanitizada. Esta base pode, então, ser disponibilizada publicamente para que os analistas realizem livremente suas próprias consultas sobre a mesma. Como a privacidade diferencial local também goza da propriedade de resistência a pós-processamento (Teorema 22 do Anexo A.3), é garantido que nenhum analista pode reverter as garantias de privacidade embutidas na base sanitizada.

Pelas razões acima, a privacidade diferencial local é um método de sanitização promissor no caso do Inep. Nas seções seguintes discutimos como ele foi implementado no presente projeto piloto e os resultados experimentais obtidos.

6.2 Aplicação de privacidade diferencial local no exemplo condutor

A seguir exemplificamos o método de aplicação de privacidade diferencial local adotada no presente projeto piloto. Mais precisamente, ilustramos o processo sobre o exemplo condutor.

Exemplo 9 (Aplicação de privacidade diferencial- ϵ local no exemplo condutor). Considere novamente a base de dados D sobre o conjunto de atributos $\mathcal{A}$ do Exemplo 1, repetida aqui por conveniência na Tabela 6.2.2a. Vamos demonstrar passo a passo o método de aplicação de privacidade diferencial- ϵ aplicado à base D que leva à obtenção de uma base sanitizada D' , representada na Tabela 6.2.2b.

O primeiro passo da sanitização é a escolha de quais atributos divulgar. Determinamos que o atributo *nome* deve ser omitido da base sanitizada, uma vez que ele identifica unicamente qualquer indivíduo na base. Os demais atributos (*id*, *idade*, *sexo*, *escola* e *deficiência*) são considerados informativos e selecionados para divulgação. Tais atributos são sujeitos, então, a um dos seguintes tratamentos.

- **Manutenção do valor original.** Mantemos o valor do atributo *id* de cada registro inalterado, pois o mesmo é apenas um pseudônimo artificialmente criado para cada indivíduo. Desta forma, o atributo não carrega nenhuma informação a respeito da identidade do mesmo.
- **Aleatorização por privacidade diferencial local.** Os atributos *idade*, *sexo*, *escola*, e *deficiência* são sanitizados por privacidade diferencial local. Neste projeto piloto optamos por aleatorizar o valor de determinados atributos de forma independente dos demais, aplicando um mecanismo de privacidade diferencial local adequado ao tipo de dado de cada atributo. Mais precisamente, se os atributos a serem aleatorizados são a_1 , a_2 e a_3 , primeiro aplicamos um mecanismo de aleatorização ao valor do atributo a_1 , um outro mecanismo ao valor do atributo a_2 e um terceiro mecanismo ao valor do atributo a_3 . Os valores aleatorizados obtidos pela aplicação independente de cada mecanismo são, então, agrupados em uma tupla sanitizada contendo os novos valores a serem divulgados.

<i>id</i>	<i>nome</i>	<i>idade</i>	<i>sexo</i>	<i>escola</i>	<i>deficiência</i>
1	Ana	2	F	A	não
2	Bruna	2	F	A	sim
3	Célia	2	F	C	sim
4	Danilo	2	M	B	sim
5	Enzo	2	M	B	não
6	Flávia	4	F	C	sim
7	Geórgia	4	F	C	sim
8	Helena	4	F	E	não
9	Ivo	4	M	D	não
10	João	5	M	D	não

(a) Base de dados original D .

<i>id</i>	<i>idade</i>	<i>sexo</i>	<i>escola</i>	<i>deficiência</i>
1	5	F	E	não
2	3	F	A	sim
3	3	F	E	não
4	1	M	A	sim
5	2	F	D	não
6	0	M	B	sim
7	5	M	D	não
8	4	F	E	não
9	5	M	D	sim
10	4	M	A	sim

(b) Base de dados sanitizada D' , obtida a partir de D por privacidade diferencial local de acordo com os mecanismos da Tabela 6.2.3.

Tabela 6.2.2: Exemplo 9: Sanitização por privacidade diferencial local aplicada ao exemplo condutor.

Uma etapa essencial na sanitização por privacidade diferencial é a escolha do valor do parâmetro de privacidade ε utilizado para cada atributo. Como já discutimos, a escolha de tal parâmetro não é trivial. Para efeito deste exemplo, entretanto, escolhemos $\varepsilon = \ln 32$ para o atributo *idade*, e $\varepsilon = \ln 2$ para os demais.

A determinação do mecanismo mais apropriado para sanitização de cada atributo depende do tipo de dado envolvido. Neste exemplo aplicamos os seguintes mecanismos: ²

- **Atributos numéricos discretos são tratados pelo mecanismo geométrico truncado.** Atributos numéricos discretos são aqueles que têm como

²Os detalhes matemáticos da definição formal de cada mecanismo são reservados ao Anexo A.2.

domínio, por exemplo, valores inteiros (e.g., $\{0, 1, 2, \dots\}$). O mecanismo geométrico truncado (Definição 18) recebe como entrada o valor original do atributo e retorna um valor aleatorizado no mesmo domínio. Para cada valor de entrada, o mecanismo concentra a probabilidade de saída em torno do valor original do atributo, e deixa essa probabilidade decrescer à medida em que os valores de saída se afastam do valor original.

No exemplo condutor, o atributo numérico discreto *idade* tem como domínio os valores $\{0, 1, 2, 3, 4, 5\}$. Escolhemos o parâmetro de privacidade para este atributo como sendo $\epsilon = \ln 32$. O mecanismo geométrico truncado resultante é obtido a partir da Definição 18 e está representado na Tabela 6.2.3a. Note que quando o valor original de *idade* é 0, a distribuição sobre valores de saída é dada pela primeira linha da matriz do mecanismo. Neste caso, o mecanismo atribui a probabilidade mais alta, $2/3$, ao valor original (a própria idade 0), e produz com probabilidade cada vez menor valores de saída mais distantes do valor original (e.g, o valor 1 é produzido com probabilidade $1/6$, enquanto o valor 5 é produzido com probabilidade $1/48$).

No presente exemplo o único atributo tratado por um mecanismo geométrico truncado é justamente *idade*.

- **Atributos categóricos são tratados pelo mecanismo k -RR.** Atributos categóricos são aqueles que têm como domínio valores que não possuem uma relação de semelhança ou dissemelhança intrínseca. Um exemplo seria o atributo *escola*, cujo domínio são códigos identificadores de entidades de ensino. O mecanismo k -RR (Definição 19) recebe como entrada o valor original do atributo e retorna um valor aleatorizado no mesmo domínio. Para cada valor de entrada, o mecanismo atribui alta probabilidade de saída ao valor original do atributo, e distribui o restante da massa de probabilidade uniformemente sobre os demais valores.

No exemplo condutor, o atributo categórico *escola* tem como domínio os valores $\{A, B, C, D, E\}$. Escolhemos o parâmetro de privacidade para este atributo como sendo $\epsilon = \ln 2$. O mecanismo k -RR resultante é representado na Tabela 6.2.3c. Note que quando o valor original de *escola* é A, a distribuição sobre valores de saída é dada pela primeira linha da matriz do mecanismo. O mecanismo atribui a probabilidade mais alta, $1/3$, ao valor original (o próprio A), e produz cada outra saída com probabilidade uniforme ($1/6$ cada para B, C, D e E).

No presente exemplo os atributos tratados por um mecanismo k -RR são *sexo*, *escola* e *deficiência*. Os mecanismos correspondentes são ilustrados nas Tabelas 6.2.3b, 6.2.3b e 6.2.3b, respectivamente.

Uma vez determinados os mecanismos utilizados em cada atributo, procedemos à sanitização de cada registro da base original D . Exemplificamos o processo com o registro de *id* 1, que tem como valores $\langle 1, \text{Ana}, 2, F, A, \text{não} \rangle$. Os passos aplicados são os seguintes.

- **Passo 1:** Eliminamos o valor do atributo *nome* do registro.
- **Passo 2:** Mantemos o valor do atributo *id* com seu valor original, 1.
- **Passo 3:** Aleatorizamos cada atributo restante de forma independente, como a seguir.
 - **Passo 3(a):** O atributo *idade* do indivíduo de *id* 1 tem valor original 2. Consultando o mecanismo de privacidade diferencial local desenhado para este atributo, representado na Tabela 6.2.3a, notamos que quando o valor original de *idade* é 2, a distribuição de probabilidade sobre valores de saída é dada pela segunda linha do mecanismo. Amostramos, então, um valor de saída de acordo com esta distribuição e obtemos, assim, o valor sanitizado para *idade* como sendo, e.g., 5.
 - **Passo 3(b):** O atributo *sexo* do indivíduo de *id* 1 tem valor original F. Aplicando o mecanismo de privacidade diferencial local desenhado para este atributo, representado na Tabela 6.2.3b obtemos o valor sanitizado como sendo, e.g., F.
 - **Passo 3(c):** O atributo *escola* do indivíduo de *id* 1 tem valor original A. Aplicando o mecanismo de privacidade diferencial local desenhado para este atributo, representado na Tabela 6.2.3c obtemos o valor sanitizado como sendo, e.g., E.
 - **Passo 3(d):** O atributo *deficiência* do indivíduo de *id* 1 tem valor original não. Aplicando o mecanismo de privacidade diferencial local desenhado para este atributo, representado na Tabela 6.2.3d obtemos o valor sanitizado como sendo, e.g., não.
- **Passo 4.** Agrupamos os resultados obtidos nos passos anteriores, mapeando o registro original de *id* 1 para um registro sanitizado com valores $\langle 1, 5, F, E, \text{não} \rangle$.

O processo é repetido para cada registro da base original D . A base sanitizada D' obtida é representada na Tabela 6.2.2b.

◁

<i>idade</i>	0	1	2	3	4	5
0	$2/3$	$1/6$	$1/12$	$1/24$	$1/48$	$1/48$
1	$1/3$	$1/3$	$1/6$	$1/12$	$1/24$	$1/24$
2	$1/6$	$1/6$	$1/3$	$1/6$	$1/12$	$1/12$
3	$1/12$	$1/12$	$1/6$	$1/3$	$1/6$	$1/6$
4	$1/24$	$1/24$	$1/12$	$1/6$	$1/3$	$1/3$
5	$1/48$	$1/48$	$1/24$	$1/12$	$1/6$	$2/3$

(a) Atributo *idade*: mecanismo geométrico truncado local com $\varepsilon = \ln 32$.

<i>sexo</i>	F	M
F	$2/3$	$1/3$
M	$1/3$	$2/3$

(b) Atributo *sexo*: mecanismo k -RR com $\varepsilon = \ln 2$.

<i>escola</i>	A	B	C	D	E
A	$1/3$	$1/6$	$1/6$	$1/6$	$1/6$
B	$1/6$	$1/3$	$1/6$	$1/6$	$1/6$
C	$1/6$	$1/6$	$1/3$	$1/6$	$1/6$
D	$1/6$	$1/6$	$1/6$	$1/3$	$1/6$
E	$1/6$	$1/6$	$1/6$	$1/6$	$1/3$

(c) Atributo *escola*: mecanismo k -RR com $\varepsilon = \ln 2$.

<i>deficiência</i>	não	sim
não	$2/3$	$1/3$
sim	$1/3$	$2/3$

(d) Atributo *deficiência*: mecanismo k -RR com $\varepsilon = \ln 2$.

Tabela 6.2.3: Exemplo 9: Mecanismos de sanitização por privacidade diferencial local para cada atributo do exemplo condutor. Em cada mecanismo as linhas representam os possíveis valores originais do atributo e as colunas representam os possíveis valores sanitizados. O valor na linha i e coluna j representa a probabilidade de o mecanismo de aleatorização mapear o valor real i para o valor sanitizado j .

6.3 Modelo de degradação de privacidade em uma única base de dados sanitizada por privacidade diferencial local

Nesta seção nos focamos na situação em que o adversário deseja reidentificar o maior número de indivíduos possível na base sanitizada, independentemente de quem sejam. Capturamos este cenário como um ataque de reidentificação coletiva em uma única base de dados sanitizada por privacidade diferencial local ($\widehat{RCU}^{ldp}$), descrito na Seção 6.3.1. Além disso, tecemos considerações sobre o risco de inferência de atributos sensíveis, apresentadas na Seção 6.3.2.

É importante notar que, quando a sanitização por privacidade diferencial local é empregada apropriadamente, medições determinísticas do sucesso de ataques tornam-se pouco informativas. De fato, por construção o objetivo central da privacidade diferencial local é impedir que o adversário realize inferências com absoluta certeza. Desta forma, a degradação de privacidade ocorre apenas pela alteração no grau de confiança que o adversário possui sobre o valor da informação sensível. Por esta razão, nos modelos de ataque aqui considerados nos focamos na medida da degradação probabilística de privacidade.

Para propiciar uma leitura mais fluida do presente documento, os detalhes matemáticos da formalização dos ataques $\widehat{RCU}^{ldp}$ são reservados ao Anexo D. As análises experimentais quantitativas da aplicação do modelo às bases dos Censos Educacionais do Inep são apresentadas na Seção 6.5.

Antes de passar aos ataques, vamos introduzir as seguintes convenções e notação.

1. Particionamos o conjunto $\mathcal{A}$ de atributos de interesse em dois blocos:

- (a) um bloco

$$\mathcal{A}_{aux} \stackrel{\text{def}}{=} \{nome\} \cup \mathcal{Q}_{ID}$$

contendo os atributos cujos valores são acessíveis ao adversário através do arquivo auxiliar Aux_D de quaseidentificadores (o atributo *nome* que identifica o indivíduo unicamente e todos os atributos quaseidentificadores em $\mathcal{Q}_{ID}$); e

- (b) um bloco

$$\overline{\mathcal{A}}_{aux} \stackrel{\text{def}}{=} \mathcal{A} - \mathcal{A}_{aux}$$

contendo os atributos de interesse cujos valores não são acessíveis ao adversário através do arquivo auxiliar Aux_D .

2. Denotamos por x_D a variável aleatória associada a um registro qualquer na base original D e por $x_{D'}$ e x_{aux} as variáveis aleatórias associadas aos registros correspondentes a x_D encontrados, respectivamente, na base sanitizada D' e no arquivo

auxiliar Aux_D de quaseidentificadores. Mais precisamente, seguindo o modelo de privacidade diferencial local apresentado na Seção 6.4, dado um registro x_D na base original D :

- (a) x_{aux} é o registro do arquivo auxiliar Aux_D de quaseidentificadores obtido a partir de x_D como informação auxiliar por parte do adversário. O registro x_{aux} consiste nos valores exatos dos atributos de nome e de quaseidentificadores do indivíduo x_D , i.e.,

$$x_{aux} = x_D[\mathcal{A}_{aux}] = x_D[\{\text{nome}\} \cup \mathcal{Q}_{ID}] .$$

- (b) $x_{D'}$ é o registro da base sanitizada D' obtido a partir de x_D através de uma distribuição de probabilidade

$$p(x_{D'}=d' \mid x_D)$$

estabelecida pelo mecanismo de privacidade diferencial local empregado na sanitização.

Em particular, dizemos que x_{aux} *corresponde* a $x_{D'}$, uma vez que eles se originam de um mesmo registro x_D .

3. Particionamos o conjunto $\mathcal{Q}_{ID}$ de atributos quaseidentificadores em dois blocos:

- (a) $\mathcal{Q}_{ID}^{mat}$ é o conjunto de *atributos quaseidentificadores diretos de matrícula* que são associados a um estudante diretamente via seu registro de matrícula; e
- (b) $\mathcal{Q}_{ID}^{ent/tur}$ é o conjunto de *atributos quaseidentificadores indiretos* que são associados a um estudante através da entidade ou turma aos quais ele está associado via, respectivamente; os valores dos atributos CO_ENTIDADE e ID_TURMA em sua matrícula.

4. Denotamos por:

- (a) $\mathcal{A}^{ent/tur}$ o conjunto de todos os atributos referentes às tabelas de entidade e de turma (não necessariamente todos representados no conjunto $\mathcal{A}$ da tabela de alunos); e
- (b) $\mathcal{A}_{COD}^{ent/tur} = \{\text{CO_ENTIDADE}, \text{ID_TURMA}\} \subseteq \mathcal{A}^{ent/tur}$ o conjunto dos atributos que unicamente identificam, respectivamente, entidade e turma.

6.3.1 Ataque de reidentificação coletiva em uma única base de dados sanitizada por privacidade diferencial local ($\widehat{RCU}^{ldp}$)

Seguindo a literatura técnica da área [34], assumimos premissas cautelosas a fim de não subestimar as capacidades do adversário. Mais precisamente, assumimos que o adversário tem acesso completo à base sanitizada e que ele conhece o processo de sanitização

utilizado. Além disso, assumimos que o adversário tem como informação auxiliar a priori um arquivo de nomes contendo uma identificação única de todos os indivíduos da população de interesse. Tais premissas são necessárias quando estamos preocupados com garantias de privacidade providas a cada indivíduo de forma independente dos demais (como é o caso das garantias previstas na LGPD brasileira).

O modelo mede, então, a degradação de privacidade de cada ataque em termos do quanto a informação auxiliar a respeito de quaseidentificadores obtida por um adversário pode facilitar a obtenção de informação sensível de indivíduos na base sanitizada por privacidade diferencial local.

Ressaltamos que a computação exata da degradação de um ataque deste tipo que levasse em conta todo o conhecimento tipicamente atribuído a um adversário de privacidade diferencial seria computacionalmente proibitiva. Mais precisamente, o tempo necessário para simulação de ataques desta natureza estaria muito além do exíguo prazo para execução disponível para o presente projeto piloto. Por esta razão, aqui nos focamos em uma versão aproximada do ataque, em que o adversário faz uso de apenas parte de seu conhecimento. A degradação de privacidade obtida com esta aproximação é, portanto, um limite inferior para o pior caso da degradação de privacidade que o adversário poderia obter caso usasse todo o seu conhecimento e dispusesse de recursos computacionais ilimitados.³

6.3.1.1 Premissas

Assumimos as seguintes premissas em relação ao ataque de reidentificação coletiva em uma única base de dados sanitizada por privacidade diferencial local.

PS₀^{ldp} Existe uma base de dados original D de interesse definida sobre um conjunto de atributos $\mathcal{A}$, à qual o adversário não tem acesso direto.

PS₁^{ldp} A técnica de mitigação de danos à privacidade produz uma base sanitizada D' em que cada registro de D é aleatorizado para produzir um novo registro em D' , conforme o método descrito na Seção 6.4. Desta forma a base sanitizada possui o mesmo tamanho da original, i.e., $|D'| = |D|$.

PS₂^{ldp} O adversário possui como informação a priori –antes de executar o ataque– uma lista contendo os nomes (ou qualquer outro identificador único, como RG ou CPF) de todos os indivíduos presentes na base original D . Tal lista é representada em um arquivo de nomes $Nomes_D$, o qual possui o mesmo tamanho da base original D , i.e., $|Nomes_D| = |D|$.

³É comum na literatura técnica de segurança prover garantias deste tipo, em que há a presunção de que o adversário tem poder computacional limitado. Esta é a praxe, por exemplo, na área de criptografia.

- PS₃^{ldp}** Existe um conjunto $\mathcal{Q}_{ID} \in \mathcal{A}$ de *quaseidentificadores* correspondendo a atributos cujos valores para os indivíduos da base original D podem ser conhecidos ou aprendidos pelo adversário. Quando o adversário aprende tais valores ele os organiza em um arquivo Aux_D de informação auxiliar, que expande o arquivo de nomes $Nomes_D$ ao associar a cada nome de indivíduo os valores dos seus atributos quaseidentificadores. O arquivo auxiliar possui o mesmo tamanho que a base original D , i.e., $|Aux_D| = |D|$.
- PS₄^{ldp}** Cada indivíduo de interesse possui no máximo um registro na base de dados original D . Consequentemente, cada indivíduo possui no máximo um registro também na base sanitizada D' , no arquivo de nomes $Nomes_D$, e no arquivo auxiliar Aux_D .
- PS₅^{ldp}** O conhecimento a priori do adversário inclui a técnica de privacidade diferencial local aplicada para se obter a base sanitizada D' a partir da base original D , o arquivo de nomes $Nomes_D$, e o fato de que cada indivíduo aparece no máximo uma vez em D . Durante o ataque o adversário obtém como informação auxiliar (via outras fontes que não a base sanitizada D' ou o arquivo de nomes $Nomes_D$) os valores dos quaseidentificadores em $\mathcal{Q}_{ID}$ para todos indivíduos na base original, construindo assim o arquivo auxiliar Aux_D . O ataque consiste, então, em cruzar as informações entre o arquivo auxiliar Aux_D e a base sanitizada D' a fim de obter informação sensível a respeito dos indivíduos presentes na última. A degradação de privacidade é medida como a comparação do sucesso do adversário a posteriori –i.e., após cruzar a informação auxiliar sobre os valores dos quaseidentificadores com a base sanitizada– e seu sucesso a priori –i.e., antes de poder usar a informação sobre quaseidentificadores. Esses elementos são esquematizados na Figura 6.3.4.
- PS₆^{ldp}** A fim de realizar um ataque com um custo computacional não proibitivo, o adversário assume um modelo simplificado do mecanismo de privacidade diferencial empregado e de seu próprio conhecimento auxiliar. Mais precisamente, o adversário aplica a heurística do *Princípio da Máxima Verossimilhança (PMV)* para estimar quais indivíduos do arquivo auxiliar Aux_D são os mais prováveis de serem os titulares de um registro sanitizado na base D' . Formalmente, adota a estimativa

$$\arg \max_{a \in \text{dom}(\mathcal{A}_{aux})} p(x_{aux}=a \mid x_{D'}=d') \approx \arg \max_{a \in \text{dom}(\mathcal{A}_{aux})} p(x_{D'}=d' \mid x_{aux}=a) . \quad (6.1)$$

A computação de (6.1) depende do modelo de privacidade diferencial local e do conhecimento do adversário. O adversário usa o fato de que o arquivo auxiliar Aux_D o informa dos valores corretos dos quaseidentificadores $\mathcal{Q}_{ID}$ de todos os indivíduos, i.e., $x_{aux}[\mathcal{Q}_{ID}] = x_D[\mathcal{Q}_{ID}]$ para todo indivíduo de interesse x . Além disso, o adversário usa a simplificação de que os atributos de um registro são aleatorizados de forma independente uns dos outros, transformando (6.1) em ⁴

$$\arg \max_{a \in \text{dom}(\mathcal{A}_{aux})} p(x_{aux}=a \mid x_{D'}=d') \approx$$

⁴O detalhamento preciso do desdobramento desta fórmula para o caso do específico da aplicação de privacidade diferencial local às bases do Inep encontra-se na Definição 27 do Anexo D.




Figura 6.3.4: Esquema de ataque de reidentificação coletiva em uma única base de dados sanitizada por privacidade diferencial local ($\widehat{RCU}^{ldp}$). No tipo de ataque aqui considerado a degradação de privacidade é medida em termos do quanto a informação auxiliar a respeito de quaseidentificadores na base sanitizada obtida por um adversário pode facilitar a recuperação de informação sensível.

$$\arg \max_{a \in \text{dom}(\mathcal{A}_{aux})} \prod_{q \in \mathcal{Q}_{ID}} p(x_{D'}[q]=d'[q] \mid x_D[q]=a[q]) . \quad (6.2)$$

Estamos, então, prontos para definir o ataque.

6.3.1.2 Descrição do ataque

Em um *ataque de reidentificação coletiva em uma única base de dados sanitizada por privacidade diferencial local* ($\widehat{RCU}^{ldp}$), o adversário tem acesso completo a uma única base de dados sanitizada por privacidade diferencial local –conhecendo todos os seus registros– obtida a partir de uma base original através de um processo de sanitização público. O adversário tem como informação auxiliar a priori –i.e., antes do ataque– um arquivo de nomes contendo, para cada indivíduo da base original, sua identificação única (e.g., nome completo, CPF, RG ou qualquer outro identificador individual inequívoco). Um registro selecionado na base sanitizada como alvo de um ataque é considerado reidentificado com sucesso quando o adversário determina corretamente a correspondência entre tal registro e o nome de seu titular no arquivo de nomes. Durante o ataque, o adversário é capaz de obter como informação lateral um arquivo auxiliar que expande o arquivo de nomes com os valores de um conjunto de atributos quaseidentificadores para todos os indivíduos no arquivo. O adversário cruza, então, o arquivo auxiliar com a base sanitizada na tentativa de reidentificar o maior número possível de indivíduos, independentemente de quem sejam. A fim de realizar um ataque com um custo computacional não proibitivo,

o adversário assume um modelo simplificado do mecanismo de privacidade diferencial empregado e de seu próprio conhecimento auxiliar descrito na Premissa $\mathbf{PS}_6^{ldp}$ acima.

A degradação de privacidade do ataque é medida como uma comparação entre o sucesso a priori do adversário (i.e., conhecendo apenas a base de dados sanitizada e o arquivo de nomes, mas não ainda o arquivo auxiliar contendo os valores dos quaseidentificadores dos indivíduos) e seu sucesso a posteriori (i.e., após ter acesso ao arquivo auxiliar e cruzá-lo com a base sanitizada).

É importante ressaltar que em um ataque $\widehat{RCU}^{ldp}$ não é impossível que o sucesso a posteriori do adversário seja menor que seu sucesso a priori, uma vez que ele é computacionalmente limitado e não é capaz de incorporar toda a informação auxiliar disponível. Quando isto ocorre, a interpretação correta é de que a privacidade diferencial local não aumenta o risco de reidentificação para tal adversário computacionalmente limitado, e não que ela efetivamente diminui o risco de reidentificação –uma vez que o adversário pode sempre ignorar a informação a posteriori caso ela não seja útil.

Mais precisamente, temos a seguinte condição para um ataque $\widehat{RCU}^{ldp}$:

- **Quantificação da degradação probabilística de privacidade:** Na medição do sucesso probabilístico de um ataque coletivo $\widehat{RCU}^{ldp}$, quantifica-se a probabilidade de um indivíduo aleatoriamente escolhido como alvo na base sanitizada ser reidentificado com sucesso através de cruzamento com informação auxiliar. Quanto maior essa probabilidade, mais exitoso é o adversário, e maior é o risco esperado de cada indivíduo ser reidentificado. A degradação probabilística de privacidade do ataque é definida, então, como a razão pela qual sua execução aumenta o sucesso probabilístico do adversário.

A Definição 27 no Anexo D formaliza matematicamente o ataque $\widehat{RCU}^{ldp}$. A seguir ilustramos como o ataque é executado em nosso exemplo condutor.

Exemplo 10 (Execução de ataque de reidentificação coletiva em uma única base de dados sanitizada por privacidade diferencial local ($\widehat{RCU}^{ldp}$)). Considere novamente a base de dados D sobre o conjunto de atributos $\mathcal{A}$ do Exemplo 1. Considere ainda que a base D tenha sido sanitizada por privacidade diferencial local conforme o Exemplo 9. O cenário resultante é ilustrado na Tabela 6.3.5. A base original D , representada na Tabela 6.3.5a, contém todos os atributos de todos os indivíduos. A base sanitizada D' , representada na Tabela 6.3.5b, é obtida a partir de D por privacidade diferencial local (e eliminando a coluna do atributo *nome*, que funciona como um identificador único). Recorde que a base sanitizada D' é obtida pela aplicação dos mecanismos descritos na Tabela 6.2.3 sobre a base original D , de forma independente sobre cada atributo, e com um valor de $\varepsilon = \ln 32$ para o atributo *idade* e $\varepsilon = \ln 2$ para os demais atributos. Recorde ainda que, de acordo com as premissas sobre ataques em uma única base, cada indivíduo de interesse possui no máximo um registro em D .

O adversário possui como informação auxiliar a priori uma lista com os nomes de todos os indivíduos de D , organizada no arquivo $Nomes_D$, representado na Tabela 6.3.5c. Ao

realizar o ataque, o adversário pode aprender os valores do conjunto $\mathcal{Q}_{ID} = \{idade, sexo\}$ de quaseidentificadores para todos os indivíduos em D . Esta informação auxiliar é organizada no arquivo auxiliar Aux_D , representado na Tabela 6.3.5d, que estende o arquivo de nomes original com os valores aprendidos.

A seguir ilustramos como computar a degradação probabilística de privacidade para este adversário.

- **Degradação probabilística de privacidade**

Antes de efetuar o ataque RCU^{ldp} , o adversário pode escolher qualquer registro na base sanitizada D' como alvo. Neste momento, a única informação disponível para o adversário é a lista $Nomes_D$ com os nomes de todos os indivíduos potencialmente presentes na base sanitizada. Neste caso, o melhor que o adversário pode fazer para reidentificar o registro selecionado na base sanitizada D' como alvo é “adivinhar no escuro” qual indivíduo, dentre todos os presentes no arquivo de nomes $Nomes_D$, corresponderia ao registro-alvo. Uma vez que a cada indivíduo de interesse corresponde no máximo um registro tanto na base sanitizada quanto no arquivo de nomes, a probabilidade de o adversário adivinhar o indivíduo no arquivo de nomes que realmente corresponde àquele do registro selecionado como alvo na base sanitizada é justamente o inverso do tamanho do arquivo de nomes. Assim, o sucesso probabilístico a priori do adversário é de $1/10=10\%$, uma vez que o arquivo de nomes tem 10 entradas.

Durante a execução do ataque $\widehat{RCU}^{ldp}$, o adversário obtém acesso ao arquivo auxiliar de quaseidentificadores Aux_D que estende o arquivo de nomes $Nomes_D$ com os valores $\{x[\mathcal{Q}_{ID}]\}_{x \in D}$ dos quaseidentificadores de todos os indivíduos do arquivo. O adversário utiliza, então, este arquivo de quaseidentificadores como informação auxiliar na tentativa de reidentificação. Mais especificamente, dado um registro $x_{D'}$, na base sanitizada D' escolhido como alvo, o objetivo do adversário é determinar corretamente qual registro x_{aux} no arquivo auxiliar de quaseidentificadores Aux_D corresponde a $x_{D'}$. A reidentificação do registro é considerada bem sucedida se, e somente se, o adversário estabelece a correspondência correta.

A melhor estratégia para o adversário é selecionar um registro x_{aux} do arquivo auxiliar que tenha máxima probabilidade de estar associado ao registro sanitizado $x_{D'}$ escolhido como alvo. De acordo com a Premissa $\mathbf{PS}_6^{ldp}$, a fim de realizar um ataque com um custo computacional não proibitivo, o adversário assume um modelo simplificado do mecanismo de privacidade diferencial empregado e de seu próprio conhecimento auxiliar. Mais precisamente, dado que o registro escolhido como alvo possui valores $x_D=d'$, o adversário computa qual a probabilidade deste registro sanitizado ter sido gerado a partir de cada registro $x_{aux}=a$ do arquivo auxiliar. Esta probabilidade é estimada levando em conta apenas os valores de quaseidentificadores dos registros envolvidos, uma vez que estes são os únicos atributos sobre os quais o adversário possui informação auxiliar. Mais precisamente, o adversário utiliza a seguinte equação para produzir uma lista $Cand_{(x_{aux}|d')}$ de registros do

arquivo auxiliar Aux_D que ele estima como os candidatos mais prováveis a uma reidentificação de sucesso do registro $x_D=d'$:

$$Cand_{(x_{aux}|d')} \stackrel{\text{def}}{=} \arg \max_{a \in \text{dom}(\mathcal{A}_{aux})} p(x_{D'}[\mathcal{Q}_{ID}]=d'[\mathcal{Q}_{ID}] \mid x_{aux}[\mathcal{Q}_{ID}]=a[\mathcal{Q}_{ID}]) . \quad (6.3)$$

No nosso exemplo, considere que o adversário tenha selecionado como alvo de reidentificação o registro $x_{D'}$ da base sanitizada D' com atributo $id=8$, i.e., aquele com valores sanitizados $d'=\langle 8, 4, F, E, \text{não} \rangle$. O adversário se foca, então, nos quaseidentificadores deste registro sanitizado, i.e., $d'[\{idade, sexo\}]=\langle 4, F \rangle$. A partir daí, o adversário computa a verossimilhança de cada registro do arquivo auxiliar Aux_D ter gerado o registro sanitizado em questão. Por exemplo, o adversário verifica que o registro na base original D de $id=1$ possui quaseidentificadores de $idade, sexo$ com valores $\langle 2, F \rangle$. Usando os mecanismos da Tabela 6.2.3, o adversário computa que a verossimilhança de os QIDs originais $\langle 2, F \rangle$ serem mapeados para os valores sanitizados $\langle 4, F \rangle$ é dada por

$$\begin{aligned} & p(x_{D'}[\{idade, sexo\}]=\langle 4, F \rangle \mid x_{aux}[\{idade, sexo\}]=\langle 2, F \rangle) = \\ & p(x_{D'}[idade]=4 \mid x_{aux}[idade]=2) \cdot p(x_{D'}[sexo]=F \mid x_{aux}[sexo]=F) = \\ & \frac{1}{12} \cdot \frac{2}{3} = \frac{8}{144} = 5.56\% . \end{aligned}$$

De forma similar, o adversário computa a verossimilhança de cada outra combinação de quaseidentificadores do arquivo auxiliar $\mathcal{Q}_{ID}$ ter sido mapeada via sanitização para os quaseidentificadores do registro-alvo d' . O resultado da computação está demonstrado na Tabela 6.3.6. A coluna com rótulo $\langle 4, F \rangle$ corresponde aos valores de quaseidentificadores sanitizados em questão (referentes ao registro de $id=8$). O adversário constata, então, que há 3 registros originais no arquivo auxiliar Aux_D com tais valores para os quaseidentificadores: Flávia, Geórgia e Helena. Assim, o conjunto $Cand_{(x_{aux}|d')}$ de candidatos verossímeis à reidentificação do registro sanitizado de $id=8$ consiste nestes três indivíduos. Neste momento, o adversário deve selecionar um destes candidatos como resultado do seu ataque. Dado seu conhecimento, o melhor que ele pode fazer é “adivinhar no escuro” qual, dentre as três possibilidades, seria a correta. Como o verdadeiro indivíduo que gerou o registro sanitizado em questão –o indivíduo de nome Helena– encontra-se no conjunto de candidatos, o adversário tem uma probabilidade de $1/3=33.33\%$ de reidentificação exitosa do registro sanitizado de $id=8$.

O adversário procede de forma similar para tentar reidentificar cada registro da base sanitizada D' . O resultado de seu raciocínio encontra-se sumarizado na Tabela 6.3.7. Note que quando o conjunto de candidatos $Cand_{(x_{aux}|d')}$ mais verossímeis à reidentificação contém o verdadeiro titular do registro alvo, a probabilidade de reidentificação com sucesso do registro em questão é o inverso do tamanho do conjunto de candidatos. Entretanto, é possível que para alguns registros-alvo o conjunto de candidatos correspondente não contenha o verdadeiro titular; neste

caso qualquer escolha que o adversário faça para o ataque dentro do conjunto de candidatos não leva a uma reidentificação exitosa e, portanto, a probabilidade de sucesso é de 0%.

Ainda assumindo que o adversário tem uma probabilidade uniforme de escolher qualquer indivíduo de D' como alvo (ou seja, $1/10 = 10\%$, uma vez que D' tem 10 registros), seu sucesso probabilístico a posteriori pode ser computado como a esperança da probabilidade de sucesso tomada sobre todos os indivíduos de D' : $10\% \cdot 0\% + 10\% \cdot 16.67\% + 10\% \cdot 16.67\% + 10\% \cdot 50\% + 10\% \cdot 0\% + 10\% \cdot 0\% + 10\% \cdot 0\% + 10\% \cdot 33.33\% + 10\% \cdot 0\% + 10\% \cdot 0\% = 11.67\%$. Desta forma, ao usar *idade* e *sexo* como informação auxiliar, espera-se que um indivíduo aleatoriamente selecionado como alvo na base possa ser reidentificado com probabilidade de 11.67%.

Portanto, a correspondente degradação probabilística de privacidade aproximada é de $11.67\%/10\% = 1.17$ o que reflete que o sucesso probabilístico do adversário, ao utilizar *idade* e *sexo* como informação auxiliar, é alterado por um fator de 1.17 na base sanitizada. Em outras palavras, o ataque aumenta em 17% a probabilidade de reidentificação exitosa do adversário. ⁵

◁

⁵Observamos que um eventual valor de degradação menor que 1 indicaria que a privacidade diferencial local não estaria aumentando o risco de reidentificação em um ataque $\widehat{RCU}^{ldp}$ para o adversário computacionalmente limitado considerado, e não que ela diminuiria seu sucesso —uma vez que o adversário pode sempre ignorar a informação a posteriori caso ela não seja útil. (Entretanto, em ataques a bases de tamanho mais realista tais valores menores que 1 tendem a ser mais incomuns.)

<i>id</i>	<i>nome</i>	<i>idade</i>	<i>sexo</i>	<i>escola</i>	<i>deficiência</i>
1	Ana	2	F	A	não
2	Bruna	2	F	A	sim
3	Célia	2	F	C	sim
4	Danilo	2	M	B	sim
5	Enzo	2	M	B	não
6	Flávia	4	F	C	sim
7	Geórgia	4	F	C	sim
8	Helena	4	F	E	não
9	Ivo	4	M	D	não
10	João	5	M	D	não

(a) Base de dados original D .

<i>id</i>	<i>idade</i>	<i>sexo</i>	<i>escola</i>	<i>deficiência</i>
1	5	F	E	não
2	3	F	A	sim
3	3	F	E	não
4	1	M	A	sim
5	2	F	D	não
6	0	M	B	sim
7	5	M	D	não
8	4	F	E	não
9	5	M	D	sim
10	4	M	A	sim

(b) Base de dados sanitizada D' , obtida a partir de D por privacidade diferencial local de acordo com os mecanismos da Tabela 6.2.3.

<i>nome</i>
Ana
Bruna
Célia
Danilo
Enzo
Flávia
Geórgia
Helena
Ivo
João

<i>nome</i>	<i>idade</i>	<i>sexo</i>
Ana	2	F
Bruna	2	F
Célia	2	F
Danilo	2	M
Enzo	2	M
Flávia	4	F
Geórgia	4	F
Helena	4	F
Ivo	4	M
João	5	M

(c) Arquivo $Nomes_D$ representando a informação a priori do adversário: lista de identificação única (*nome*) de todos os indivíduos que fazem parte da base original D .(d) Arquivo auxiliar Aux_D representando a informação auxiliar utilizada pelo adversário durante um ataque: informação a priori acrescida dos valores de quaseidentificadores reais de todos os indivíduos na base original D .Tabela 6.3.5: Exemplo 10: Ataque de reidentificação coletiva em uma única base sanitizada por privacidade diferencial local ($\widehat{RCU}^{ldp}$) sobre o exemplo condutor.

	$\langle 0, F \rangle$	$\langle 0, M \rangle$	$\langle 1, F \rangle$	$\langle 1, M \rangle$	$\langle 2, F \rangle$	$\langle 2, M \rangle$	$\langle 3, F \rangle$	$\langle 3, M \rangle$	$\langle 4, F \rangle$	$\langle 4, M \rangle$	$\langle 5, F \rangle$	$\langle 5, M \rangle$
$\langle 2, F \rangle$	16/144	8/144	16/144	8/144	32/144	16/144	16/144	8/144	8/144	4/144	8/144	4/144
$\langle 2, M \rangle$	8/144	16/144	8/144	16/144	16/144	32/144	8/144	16/144	4/144	8/144	4/144	8/144
$\langle 4, F \rangle$	4/144	2/144	4/144	2/144	8/144	4/144	16/144	8/144	32/144	16/144	32/144	16/144
$\langle 4, M \rangle$	2/144	4/144	2/144	4/144	4/144	8/144	8/144	16/144	16/144	32/144	16/144	32/144
$\langle 5, M \rangle$	1/144	2/144	1/144	2/144	2/144	4/144	4/144	8/144	8/144	16/144	32/144	64/144

Tabela 6.3.6: Exemplo 10: Computação da verossimilhança aproximada de cada registro original $a[\{idade, sexo\}]$ do arquivo auxiliar ter gerado cada registro sanitizado $d'[\{idade, sexo\}]$ no exemplo condutor, de acordo com a Equação (6.3). As linhas representam possíveis valores de quaseidentificadores $a[\{idade, sexo\}]$ originais presentes no arquivo auxiliar Aux_D , as colunas representam possíveis valores de quaseidentificadores sanitizados $d'[\{idade, sexo\}]$ produzidos de acordo com o mecanismo de privacidade diferencial local da Tabela 6.2.3. O valor na linha i e coluna j representa a probabilidade de o mecanismo de aleatorização mapear o valor real i para o valor sanitizado j . Em cada coluna correspondente a valores sanitizados $d'[\{idade, sexo\}]$, destacamos em negrito os valores de quaseidentificadores originais $a[\{idade, sexo\}]$ com máxima verossimilhança.

id do registro alvo $d' \in D'$	QIDs sanitizados $d'[\mathcal{Q}_{ID}]$	QIDs de máxima verossimilhança em Aux_D	Conjunto $Cand_{(x_{aux} d')}$ de candidatos à reidentificação	Prob. de sucesso na reidentificação
1	$\langle 5, F \rangle$	$\langle 4, F \rangle \langle 5, M \rangle$	Flávia, Geórgia, Helena, João	0%
2	$\langle 3, F \rangle$	$\langle 2, F \rangle \langle 4, F \rangle$	Ana, Bruna , Célia, Fátia, Geórgia, Helena	$1/6 = 16.67\%$
3	$\langle 3, F \rangle$	$\langle 2, F \rangle \langle 4, F \rangle$	Ana, Bruna, Célia , Fátia, Geórgia, Helena	$1/6 = 16.67\%$
4	$\langle 1, M \rangle$	$\langle 2, M \rangle$	Danilo , Enzo	$1/2 = 50\%$
5	$\langle 2, F \rangle$	$\langle 2, F \rangle$	Ana, Bruna, Célia	0%
6	$\langle 0, M \rangle$	$\langle 2, M \rangle$	Danilo, Enzo	0%
7	$\langle 5, M \rangle$	$\langle 5, M \rangle$	João	0%
8	$\langle 4, F \rangle$	$\langle 4, F \rangle$	Flávia, Geórgia, Helena	$1/3 = 33.33\%$
9	$\langle 5, M \rangle$	$\langle 5, M \rangle$	João	0%
10	$\langle 4, M \rangle$	$\langle 4, M \rangle$	Ivo	0%

Tabela 6.3.7: Exemplo 10: Identificação dos valores de quaseidentificadores mais verossímeis para cada registro-alvo e do correspondente conjunto de indivíduos candidatos à reidentificação no exemplo condutor. Quando o conjunto de candidatos selecionado pelo adversário contém o indivíduo que de fato é o titular do registro sanitizado, o nome do indivíduo é destacado em negrito e, neste caso, sua probabilidade de sucesso na reidentificação é o inverso do tamanho do conjunto de candidatos; em caso contrário a probabilidade é zero. A probabilidade de sucesso global é a esperança das probabilidades de sucesso para cada registro alvo, i.e., 11.67%.

6.3.2 Considerações sobre riscos de inferência de atributo sensível

A privacidade diferencial local foi originalmente concebida para prover garantias contra ataques de inferência de atributo sensível de um indivíduo cuja identidade seria potencialmente conhecida. Mais precisamente, cada indivíduo sanitizaria os próprios dados e os disponibilizaria para terceiros (por exemplo, para um curador, ou para o analista de dados). Nesta concepção original de privacidade diferencial local, a identidade do indivíduo em si não seria necessariamente considerada informação sensível, mas apenas os valores de cada um de seus atributos.

Por esta razão, mesmo que o adversário tenha sucesso em reidentificar o titular de um registro sanitizado por privacidade diferencial local, isto não implica em seu sucesso em inferir com absoluta certeza os valores dos atributos sensíveis presentes na base sanitizada. Isto acontece porque a privacidade diferencial local adiciona ruído aos valores de cada atributo, o que permite ao titular um grau de negação plausível a respeito dos mesmos.

Mais especificamente, considere uma base de dados D com um atributo sensível $s \in \mathcal{A}$ assumindo valores num domínio $dom(s)$. Considere que um indivíduo x_D teve seu valor sensível $x_D[s]$ sanitizado por um mecanismo de privacidade diferencial local com parâmetro $\varepsilon > 0$, produzindo um valor sanitizado $x_{D'}[s]$. Seja $p(x_D[s]=\cdot)$ a distribuição de probabilidade sobre $dom(s)$ representando o conhecimento a priori do adversário –i.e., antes de observar o resultado da sanitização– sobre quais valores o indivíduo x_D pode ter para o atributo sensível s . Seja $p(x_D[s]=\cdot \mid x_{D'}[s]=r)$ a distribuição de probabilidade sobre $dom(s)$ representando o conhecimento a posteriori do adversário –i.e., após observar o resultado da sanitização– sobre quais valores o indivíduo x_D pode ter para o atributo sensível s . É possível demonstrar (como feito no Produto 03 do presente TED 8750) que a privacidade diferencial local limita o quanto o adversário pode aprender a respeito do valor do atributo sensível s de x_D da seguinte forma. Para todo par de valores $v_1, v_2 \in dom(s)$ que o atributo s pode assumir, o conhecimento a posteriori do adversário é limitado por

$$e^{-\varepsilon} \frac{p(x_D[s]=v_1)}{p(x_D[s]=v_2)} \leq \frac{p(x_D[s]=v_1 \mid x_{D'}[s]=r)}{p(x_D[s]=v_2 \mid x_{D'}[s]=r)} \leq e^{\varepsilon} \frac{p(x_D[s]=v_1)}{p(x_D[s]=v_2)}. \quad (6.4)$$

Note que quanto maior o valor de ε (isto é, quanto menos privado é o mecanismo), mais relaxados são os limites do quanto o adversário pode inferir. Em particular, quando $\varepsilon=0$, o conhecimento a posteriori do adversário não se altera em relação ao a priori, indicando que o mecanismo o impede de aprender qualquer coisa sobre o atributo sensível.

O exemplo a seguir ilustra o poder desta garantia.

Exemplo 11 (Inferência de atributo sensível após reidentificação exitosa em uma única base de dados sanitizada por privacidade diferencial local). Considere novamente a base de dados D sobre o conjunto de atributos $\mathcal{A}$ do Exemplo 1. Assuma que esta base foi sanitizada por privacidade diferencial local conforme o Exemplo 9, usando para cada atributo um mecanismo com parâmetro $\varepsilon = \ln 2$, com exceção do atributo *idade*, para

o qual foi usado $\varepsilon = \ln 32$. A base original D e a base sanitizada D' resultante são representadas na Tabela 6.3.5a e na Tabela 6.3.5b, respectivamente.

Assuma que o adversário teve sucesso em reidentificar Bruna como a titular do registro sanitizado de $id=2$. Logo, o adversário sabe que o registro original de Bruna foi sanitizado para o registro em D' com valores $\langle 2, 2, F, A, \text{sim} \rangle$.

Assuma que o atributo considerado sensível seja *deficiência*. O adversário observa que Bruna tem o valor **sim** para este atributo na base sanitizada D' . Porém, isso não dá ao adversário certeza absoluta de que Bruna é portadora de deficiência. Mais precisamente, assuma que o conhecimento a priori do adversário seja de que Bruna tem 10% de chance de ser deficiente, i.e., $p(x_D[\text{deficiência}]=\text{sim}) = 0.10$ e $p(x_D[\text{deficiência}]=\text{não}) = 0.90$ para Bruna. Logo, sabendo que $\varepsilon = \ln 2$ para o atributo *deficiência* e usando a Equação 6.4, o conhecimento a posteriori do adversário, após observar que o valor de *deficiência* reportado para Bruna é $x_{D'}[\text{deficiência}]=\text{sim}$, é limitado por

$$\frac{1}{18} \leq \frac{p(x_D[\text{deficiência}]=\text{sim} \mid x_{D'}[\text{deficiência}]=\text{sim})}{p(x_D[\text{deficiência}]=\text{não} \mid x_{D'}[\text{deficiência}]=\text{sim})} \leq \frac{2}{9},$$

o que significa que o nível de confiança relativa do adversário pode ser alterado por, no máximo, um fator entre $1/18$ e $2/9$. Mais especificamente, sabendo que só há 2 valores possíveis para o atributo *deficiência*, podemos computar que no caso de Bruna a probabilidade de ela realmente ser deficiente dado que seu registro sanitizado diz que ela tem deficiência é limitada por

$$5.26\% = \frac{1}{19} \leq p(x_D[\text{deficiência}]=\text{sim} \mid x_{D'}[\text{deficiência}]=\text{sim}) \leq \frac{2}{11} = 18.18\%.$$

Note que antes de o adversário reidentificar Bruna ele acredita que a probabilidade de ela ter deficiência é de 10%. Entretanto, mesmo após reidentificar Bruna com sucesso e observar o valor reportado para seu atributo sensível, a probabilidade que o adversário atribui a ela ter deficiência permanece limitada ao intervalo $[5.26\%, 18.18\%]$. Em outras palavras, a privacidade diferencial local limita o quanto o adversário pode aprender sobre o atributo sensível de Bruna. Isto garante a ela uma razoável plausibilidade ao negar que ela seja de fato deficiente, mesmo que o adversário a tenha reidentificado com sucesso e observado que seu registro sanitizado reporte que ela seja deficiente. $\triangleleft$

6.4 Método de sanitização por privacidade diferencial local empregado neste projeto piloto

No cenário considerado no presente projeto piloto, o próprio Inep, no papel de curador dos dados, introduziria ruído aos dados de cada titular individualmente, obtendo assim uma base sanitizada que poderia, em seguida, ser disponibilizada para que analistas realizassem livremente as próprias consultas sobre a mesma.⁶

É importante ressaltar que o método aqui empregado é um protótipo realizado dentro das restrições impostas pelo exíguo prazo disponível para o presente projeto piloto. Por esta razão, algumas simplificações foram realizadas. Com mais tempo, várias otimizações e refinamentos poderiam ser realizados a fim de aumentar a qualidade dos resultados obtidos.

A base disponibilizada pelo Inep para o presente projeto piloto corresponde a uma versão do Censo do Ensino Básico de 2019 que contém 29 atributos selecionados pelo instituto para divulgação, além de 3 atributos utilizados apenas como variáveis auxiliares na computação de outros atributos.⁷ O processo de sanitização aqui empregado segue os princípios de privacidade diferencial local descritos no Anexo A e ilustrados no Exemplo 9. Mais especificamente, cada registro da base fornecida pelo Inep teve seus atributos submetidos a um dos seguintes tipos de tratamento, conforme sumarizado na Tabela 6.4.8:

- **Manutenção do valor original.** Tratamento aplicado a atributos que possuem o mesmo valor em todos os registros da base (como NU_ANO_CENSO) e a atributos que apenas representam códigos artificialmente criados pelo Inep (como ID_MATRICULA, CO_PESSOA_FISICA e ID_ALUNO).
- **Aleatorização por privacidade diferencial local.** Neste projeto piloto optamos por aleatorizar o valor de determinados atributos de forma independente dos demais, aplicando um mecanismo de privacidade diferencial local adequado ao tipo de dado de cada atributo. Os valores sanitizados obtidos em cada caso são, então, agrupados em uma nova tupla aleatorizada contendo os três valores obtidos.

⁶Como discutido no Produto 03, esta abordagem é vantajosa em situações em que o curador não tem interesse ou os recursos necessários para empregar mecanismos de privacidade diferencial global e responder individualmente a cada consulta posta por analistas (e.g., porque manter o controle de consultas é dispendioso, ou porque o número de consultas permitidas em uma versão global de privacidade diferencial é limitado). Como a privacidade diferencial local também goza da propriedade de resistência a pós-processamento (formalizada no Anexo A.3), é garantido que nenhum analista pode reverter as garantias de privacidade embutidas na base sanitizada.

⁷Observamos, entretanto que os atributos IN_DIST_IDADE_SERIE e IN_TEMPO_INTEGRAL, inicialmente selecionados para divulgação, são omitidos das análises aqui apresentadas por que 3 atributos necessários como variáveis auxiliares em sua computação estão ausentes na base disponibilizada: TP_ETAPA_INDICADOR, NU_DUR_ATIV_COMP_MESMA_REDE, NU_DUR_ATIV_COMP_OUTRAS_REDES e NU_DURACAO_TURMA.

A determinação do mecanismo mais apropriado para sanitização de cada atributo depende do tipo de dado envolvido. No presente projeto piloto utilizamos os seguintes mecanismos:⁸

1. **Mecanismo geométrico truncado aplicado a atributos numéricos discretos.** Atributos numéricos discretos são aqueles que têm como domínio, por exemplo, valores inteiros (e.g., $\{0, 1, 2, \dots\}$). O mecanismo geométrico truncado (Definição 18) recebe como entrada o valor original do atributo e retorna um valor aleatorizado no mesmo domínio. Para cada valor de entrada, o mecanismo concentra a probabilidade de saída em torno do valor original do atributo, e deixa essa probabilidade decrescer à medida em que os valores de saída se afastam do valor original. (A Tabela 6.2.3a do Exemplo 9 ilustra o formato do mecanismo geométrico truncado, aplicado ao atributo *idade* do exemplo condutor.)

O único atributo tratado pelo mecanismo geométrico truncado no presente projeto piloto é NU_IDADE. Mesmo que este atributo não tenha seu valor divulgado na base final, outros atributos (como NU_IDADE_0_5) são função do mesmo e, portanto, ele precisa ser aleatorizado.

2. **Mecanismo k -RR aplicado a atributos categóricos.** Atributos categóricos são aqueles que têm como domínio valores que não possuem uma relação de semelhança ou dissemelhança intrínseca. Um exemplo seria o atributo CO_ENTIDADE, cujo domínio são códigos identificadores de entidades de ensino. O mecanismo k -RR (Definição 19) recebe como entrada o valor original do atributo e retorna um valor aleatorizado no mesmo domínio. Para cada valor de entrada, o mecanismo atribui alta probabilidade de saída ao valor original do atributo, e distribui o restante da massa de probabilidade uniformemente sobre os demais valores. (A Tabela 6.2.3c do Exemplo 9 ilustra o formato do mecanismo k -RR, aplicado ao atributo *escola* do exemplo condutor.)

Os atributos tratados pelo mecanismo k -RR no presente projeto piloto foram TP_SEXO, TP_ZONA_RESIDENCIAL e ID_TURMA.

- **Computação como função de outros atributos.** Alguns atributos têm valores que são uma função de outros atributos. Se um atributo a_2 é uma função de um atributo a_1 e o valor do atributo a_1 for aleatorizado, o valor do atributo a_2 deve ser modificado de acordo com o novo valor do atributo a_1 . Note que há situações em que o atributo a_1 não deve ser disponibilizado na base sanitizada final, mas o atributo a_2 que depende dele deve ser. Nesses casos é necessário aleatorizar o valor de a_1 mesmo que ele não apareça na base final.

Por exemplo, todos os atributos que descrevem uma turma (e.g., TP_ETAPA_ENSINO, IN_TURNO, etc.) são uma função do atributo de identificação da turma, ID_TURMA. Portanto, no nosso processo de sanitização por privacidade diferencial local, primeiro aleatorizamos o valor de ID_TURMA e, uma vez obtido o novo valor saniti-

⁸Os detalhes matemáticos da definição de cada mecanismo são reservados ao Anexo A.2.

zado, recuperamos os valores dos atributos descritivos de turma como uma função do novo identificador. Note que na base sanitizada final são divulgados os valores dos atributos descritivos de turma, enquanto o valor do identificador ID_TURMA é omitido.

Os atributos que não são diretamente aleatorizados, mas têm seus valores atualizados como função de outros atributos aleatorizados são os seguintes.

- Atributos que descrevem uma turma são recuperados diretamente da tabela de turma usando o valor ID_TURMA como chave:

* TP_ETAPA_ENSINO,	* TP_MEDIACAO_DIDATICO_PEDAGO,
* IN_REGULAR,	* IN_TURNO,
* IN_EJA,	* TP_TIPO_ATENDIMENTO_TURMA, e
* IN_PROFISSIONALIZANTE,	* CO_ENTIDADE.
* ID_AREA_CURSO_PROFISSIONAL,	

- Atributos que descrevem uma entidade são recuperados diretamente da tabela de entidade usando o valor CO_ENTIDADE como chave:

* CO_REGIAO,	* TP_CATEGORIA_ESCOLA_PRIVADA,
* CO_MESORREGIAO,	* IN_CONVENIADA_PP,
* CO_MICRORREGIAO,	* TP_CONVENIO_PODER_PUBLICO,
* CO_UF,	* TP_LOCALIZACAO_DIFERENCIADA
* CO_MUNICIPIO,	e
* TP_DEPENDENCIA,	* IN_EDUCACAO_INDIGENA.
* TP_LOCALIZACAO,	

- O atributo NU_IDADE_0_5 é uma função do atributo NU_IDADE, obtida pelo truncamento da mesma. Mais precisamente, idades entre 0 e 4 têm seu valor mantido, enquanto qualquer idade maior ou igual a 5 é convertida para o valor NULL.

A Figura 6.4.9 ilustra o fluxo empregado para tratamento de atributos, que consiste nos seguintes passos:

- **Passo 1:** Adição de ruído aos atributos NU_IDADE, TP_SEXO, TP_ZONA_RESIDENCIAL, ID_TURMA conforme os mecanismos descritos na Tabela 6.4.8.
- **Passo 2:** Computação do valor do atributo NU_IDADE_0_5 como uma função do valor aleatorizado do atributo NU_IDADE.
- **Passo 3:** Computação dos valores descritivos de turma como uma função do valor aleatorizado do atributo ID_TURMA.




Figura 6.4.9: Fluxo de tratamento de atributos na base do Ensino básico de 2019 utilizando privacidade diferencial local. O tratamento de cada atributo é descrito na Tabela 6.4.8.

- **Passo 4:** Computação dos valores descritivos de entidade de ensino como uma função do valor aleatorizado do atributo CO_ENTIDADE.

Ressaltamos os seguintes pontos a respeito do processo de sanitização empregado.

1. Os atributos NU_IDADE, ID_TURMA e CO_ENTIDADE não foram selecionados pelo Inep como parte dos microdados a serem divulgados e foram, portanto, omitidos da base sanitizada final. Entretanto, como variáveis incluídas nos microdados são dependentes destes atributos, eles foram utilizados na adição de ruído para que fosse possível computar os valores de outras variáveis que dependam destas.
2. Os atributos IN_DIST_IDADE_SERIE e IN_TEMPO_INTEGRAL, apesar de selecionados pelo Inep para divulgação, não possuem todas as dependências representadas na base enviada e foram, portanto, omitidos das análises. (Mais precisamente, os atributos auxiliares necessários TP_ETAPA_INDICADOR, NU_DUR_ATIV_COMP_MESMA_REDE, NU_DUR_ATIV_COMP_OUTRAS_REDES e NU_DURACAO_TURMA estão ausentes.)
3. Assumimos que o atributo TP_ETAPA_ENSINO é dependente exclusivamente da turma e não da matrícula, com o intuito de simplificar a análise. Sendo assim, o valor desta variável, para cada registro, foi substituído pelo valor que a turma deste registro possui na tabela de turmas. Como consequência, estudantes que pertenciam a turmas de categoria mista (e.g., “Curso Técnico Misto”, “Ensino Fundamental de

9 anos - Multi”) agora possuem o valor da sua turma, e não o valor individual. Por exemplo, dois estudantes que possuem os valores “*Curso Técnico - Concomitante*” e “*Curso Técnico - Subsequente*” respectivamente, agora serão mapeados ambos para “*Curso Técnico Misto*”.

Atributo	Tipo	Domínio	Tratamento
NU_ANO_CENSO	Númerico discreto	{2019}	Mantido o valor original.
ID_MATRICULA	Categórico	Valores artificiais gerados pelo Inep.	
CO_PESSOA_FISICA	Categórico		
ID_ALUNO	Categórico		
TP_SEXO	Categórico	{1, 2, NULL}	Aleatorizado por mecanismo k -RR.
TP_ZONA_RESIDENCIAL	Categórico	{1, 2, NULL}	Aleatorizado por mecanismo k -RR.
NU_IDADE	Númerico discreto	{0, 1, 2, ..., 120 }	Aleatorizado por mecanismo geométrico truncado. (Atributo auxiliar omitido da base sanitizada final.)
NU_IDADE_0_5	Númerico discreto	{0, 1, 2, 3, 4, NULL}	Recuperado como função do valor aleatorizado de NU_IDADE.
IN_DIST_IDADE_SERIE	Categórico	{0, 1, NULL}	Deveria ser recuperado como função dos valores aleatorizados de NU_IDADE e TP_ETAPA_INDICADOR. Entretanto, foi omitido das análises por dependências ausentes.
IN_TEMPO_INTEGRAL	Categórico	{0, 1, NULL}	Deveria ser recuperado como função dos valores aleatorizados de NU_DURACAO_TURMA, NU_DUR_ATIV_COMP_MESMA_REDE e NU_DUR_ATIV_COMP_OUTRAS_REDES. Entretanto, foi omitido das análises por dependências ausentes.

(a) Tratamento aplicado a atributos de matrícula.

Atributo	Tipo	Domínio	Tratamento
ID_TURMA	Categórico	Códigos de turmas do Ensino Básico de 2019	Aleatorizado por mecanismo k -RR. (Atributo auxiliar omitido da base sanitizada final.)
TP_ETAPA_ENSINO	Categórico	Dezenas de valores	Recuperado diretamente da tabela de turma usando como chave o valor aleatorizado de ID_TURMA.
IN_REGULAR	Categórico	{0, 1, NULL}	
IN_EJA	Categórico	{0, 1, NULL}	
IN_PROFISSIONALIZANTE	Categórico	{0, 1, NULL}	
ID_AREA_CURSO_PROFISSIONAL	Categórico	{1, 2, 3, 4, 5, 6, 7, 8, 9, 10, 11, 12, 13, NULL}	
TP_MEDIACAO_DIDATICO_PEDAGO	Categórico	{1, 2, 3, NULL}	
IN_TURNO	Categórico	{1, 2, NULL}	
TP_TIPO_ATENDIMENTO_TURMA	Categórico	{1, 2, 3, 4, NULL}	

(b) Tratamento aplicado a atributos de turma.

Atributo	Tipo	Domínio	Tratamento
CO_ENTIDADE	Categórico	Códigos de entidades do Ensino Básico de 2019	Recuperado diretamente da tabela de turma usando como chave o valor aleatorizado de ID_TURMA. (Atributo auxiliar omitido da base sanitizada final.)
CO_REGIAO	Categórico	{1, 2, 3, 4, 5, NULL}	Recuperado diretamente da tabela de entidade usando como chave o valor de CO_ENTIDADE associado ao valor ID_TURMA aleatorizado.
CO_MESORREGIAO	Categórico	Dezenas de valores	
CO_MICRORREGIAO	Categórico	Centenas de valores	
CO_UF	Categórico	Dezenas de valores	
CO_MUNICIPIO	Categórico	Milhares de valores	
TP_DEPENDENCIA	Categórico	{1, 2, 3, 4, NULL}	
TP_LOCALIZACAO	Categórico	{1, 2, NULL}	
TP_CATEGORIA_ESCOLA_PRIVADA	Categórico	{1, 2, 3, 4, NULL}	
IN_CONVENIADA_PP	Categórico	{0, 1, 9, NULL}	
TP_CONVENIO_PODER_PUBLICO	Categórico	{1, 2, 3, 9, NULL}	
TP_LOCALIZACAO_DIFERENCIADA	Categórico	{0, 1, 2, 3, NULL}	
IN_EDUCACAO_INDIGENA	Categórico	{0, 1, NULL}	

(c) Tratamento aplicado a atributos de entidade.

Tabela 6.4.8: Tratamento aplicado a cada atributo da base do Censo da Educação Básica de 2019 na sanitização por privacidade diferencial local. Linhas escuras indicam atributos auxiliares omitidos da base sanitizada final, ou atributos cujas dependências são ausentes na base enviada e foram omitidos das análises.

6.5 Resultados de ataques de reidentificação coletiva em uma única base de dados sanitizada por privacidade diferencial local ($\widehat{RCU}^{ldp}$)

Devido ao alto custo computacional das análises deste tipo de ataque e o prazo exíguo para execução do presente projeto piloto, a seguir provemos nossa análise sobre ataque $\widehat{RCU}^{ldp}$ na versão do Censo da Educação Básica de 2019 restrita aos registros do Distrito Federal. Tal unidade da federação foi escolhida por ter um tamanho tratável e, ao mesmo tempo, ter uma boa variabilidade nos dados.

Experimento 12 (Ataques de reidentificação coletiva sobre uma única base sanitizada por privacidade diferencial local $\widehat{RCU}^{ldp}$, sobre o Censo da Educação Básica de 2019). Devido ao alto custo computacional das análises, neste experimento usamos a base original do Censo da Educação Básica de 2019 restrita ao Distrito Federal, que contém 654 413 registros após tratamento. A base foi tratada pelo método descrito na Seção 6.4.

Neste experimento utilizamos vários valores para o parâmetro de privacidade ε . Recordamos que quanto menor o valor do parâmetro ε , maior a proteção de privacidade, porém maior é o risco de compromisso da utilidade dos dados divulgados. Como discutido anteriormente neste documento, a escolha do parâmetro ε mais adequado a cada aplicação é um desafio não trivial e que, na prática, demanda um processo laborioso de refinamento, otimização e experimentação. Para o presente projeto piloto, optamos pelo teste dos seguintes valores do parâmetro:

- **Valores que priorizam privacidade sobre utilidade:** tais valores são tipicamente pequenos. Nesta faixa escolhemos os seguintes valores de ε : $\ln 3$ e $\ln 5$.
- **Valores que priorizam utilidade sobre privacidade:** tais valores são tipicamente grandes. Nesta faixa escolhemos os seguintes valores de ε : $\ln 100$ e $\ln 10^3$ e $\ln 10^5$.

Em cada experimento, o valor de ε adotado foi dividido igualmente entre os atributos aleatorizados. Mais precisamente, se há n atributos a serem aleatorizados, cada um foi aleatorizado com um parâmetro ε/n .⁹

Como modelo de informação auxiliar do adversário, consideramos tanto o conjunto reduzido de 7 quaseidentificadores quanto o conjunto expandido de 23 quaseidentificadores descritos na Tabela 3.3.2.

Recordando que na privacidade diferencial apenas análises de degradação probabilística de privacidade são apropriadas, medimos os valores correspondentes para cada uma dessas combinações de quaseidentificadores em cada base. A Tabela 6.5.10 sumariza a degradação de privacidade neste ataque.

⁹Note que, pelas propriedades composicionais da privacidade diferencial, formalizadas no Teorema 20 do Anexo A.3, se n mecanismos independentes oferecem privacidade diferencial com parâmetro ε/n , então a composição em paralelo destes mecanismos oferece uma privacidade diferencial final com parâmetro $n \cdot \varepsilon/n = \varepsilon$.

Sucesso probabilístico do adversário Este tipo de sucesso é medido como a probabilidade de que um indivíduo escolhido aleatoriamente seja reidentificado com sucesso na base.

A Tabela 6.5.10 demonstra que o sucesso probabilístico a priori do adversário (que é inversamente proporcional ao número de registros total) na base completa é da ordem de 0.000153%, significando que sem nenhuma informação auxiliar o adversário tem uma chance ínfima de reidentificar qualquer indivíduo com absoluta certeza.

Por outro lado, observamos que a aplicação de privacidade diferencial local com todos os valores de ε estudados eliminou a degradação de privacidade para os dois conjuntos de quaseidentificadores considerados.

Análise do efeito da sanitização por privacidade diferencial local na degradação de privacidade. Podemos analisar o efeito da sanitização por privacidade diferencial local na degradação de privacidade comparando os resultados do presente experimento com aqueles do Experimento 5, em que apenas desidentificação e pseudonimização são usados como métodos de proteção de privacidade.

Em particular, observamos que a sanitização por privacidade diferencial local praticamente eliminou a degradação probabilística de privacidade tanto para o conjunto de 7 quanto para o conjunto de 23 quaseidentificadores. O efeito foi observado com todos os valores do parâmetro de privacidade ε analisados.

Entretanto, é importante ressaltar os seguintes pontos:

1. O ataque $\widehat{RCU}^{ldp}$ aqui realizado é uma aproximação do que um adversário com capacidade computacionalmente elevada o suficiente pode atingir.
2. A privacidade diferencial local é reconhecidamente eficaz em garantir privacidade, mas em geral a um custo elevado na utilidade dos dados. Na Seção 7.2.2 analisamos cuidadosamente os efeitos da privacidade diferencial local na utilidade da divulgação.

Parâmetro ε	Conjunto reduzido de 7 QIDs		Conjunto estendido de 23 QIDs	
	Sucesso a priori = 0.000153%		Sucesso a priori = 0.000153%	
	Sucesso a posteriori	Degradação privacidade	Sucesso a posteriori	Degradação privacidade
ln 3	< 0.000001%	Não observada.	< 0.000001%	Não observada.
ln 5	< 0.000001%	Não observada.	< 0.000001%	Não observada.
ln 100	< 0.000001%	Não observada.	< 0.000001%	Não observada.
ln 1 000	< 0.000001%	Não observada.	< 0.000001%	Não observada.
ln 100 000	< 0.000001%	Não observada.	< 0.000001%	Não observada.

Tabela 6.5.10: Experimento 12: Resultados de ataques de reidentificação coletiva em uma única base de dados sanitizada por privacidade diferencial local ($\widehat{RCU}^{ldp}$), sobre a base do Censo da Educação Básica de 2019 restrita a registros do Distrito Federal. Recorde que a degradação probabilística de privacidade é dada pela razão entre o sucesso a posteriori e o a priori do adversário.

7 Análise comparativa de privacidade e utilidade após cada método de sanitização empregado

Como discutimos anteriormente neste documento, todo método de mitigação de degradação de privacidade vem acompanhado de um maior ou menor custo à utilidade dos dados divulgados –i.e., à qualidade da informação provida aos analistas. É amplamente conhecida na literatura técnica sobre controle de divulgação estatística a dificuldade inerente de se conciliar a utilidade dos dados divulgados com a privacidade dos indivíduos que participam das pesquisas [25, 29, 12, 40, 3, 28, 9].

Nesta seção provemos sumários comparativos do nível de privacidade e de utilidade atingido por cada método de sanitização considerado no presente projeto piloto.

7.1 Sumário comparativo da degradação de privacidade dos métodos de mitigação analisados

O seguinte conjunto de tabelas sumariza comparativamente os resultados sobre degradação de privacidade dos métodos de mitigação analisados no presente documento.

- As Tabelas 7.1.1 e 7.1.2 apresentam quadros-resumos do sucesso determinístico de ataques de reidentificação coletiva RCU, RCU^{ams} e $\widehat{RCU}^{ldp}$ sobre, respectivamente, a versão completa e a reduzida a registros do Distrito Federal da base do Censo da Educação Básica de 2019.
- As Tabelas 7.1.3 e 7.1.4 apresentam quadros-resumos do sucesso probabilístico de ataques de reidentificação coletiva RCU, RCU^{ams} e $\widehat{RCU}^{ldp}$ sobre, respectivamente, a versão completa e a reduzida a registros do Distrito Federal da base do Censo da Educação Básica de 2019.

Podemos destacar os seguintes pontos em nossa análise:

- **A restrição do conjunto de atributos divulgados teve um impacto significativo na degradação de privacidade.** No Produto 02 verificamos que 29 013 261 registros (60.92% do total) do Censo da Educação Básica de 2019 puderam ser reidentificados com absoluta certeza usando 10 quaseidentificadores como informação auxiliar.

A restrição do número e da granularidade dos atributos no presente projeto piloto teve o efeito de eliminar vários quaseidentificadores poderosos da base sanitizada (como, por exemplo, a data e município de nascimento de um indivíduo), além de reduzir significativamente a precisão de outros (como a idade do indivíduo). Desta forma, os novos experimentos do presente documento representam um cenário em que o adversário teria maior dificuldade em realizar um ataque de reidentificação exitoso.

Os resultados experimentais sugerem que, mesmo assumindo que o adversário tenha como informação auxiliar uma grande parte dos atributos presentes na nova base, a restrição de atributos divulgados pode reduzir significativamente a degradação de privacidade. Entretanto, ainda assim um número significativo de indivíduos permaneceu exposto a um risco considerável: de 18 393 a 128 517 registros (0.04% a 0.27% do total) puderam ser reidentificados com absoluta certeza, usando de 7 a 23 quaseidentificadores na nova base, respectivamente (Tabela 4.2.2).

- **A sanitização por amostragem reduziu significativamente a degradação de privacidade, mas os riscos remanescente ainda são elevados.** A sanitização por amostragem reduziu significativamente a degradação determinística de privacidade em relação ao tratamento por apenas desidentificação e pseudonimização. Usando 7 quaseidentificadores, houve uma redução de 18 393 para 12 813 indivíduos identificados com absoluta certeza; enquanto que usando 23 quaseidentificadores a redução foi de 128 517 para 86 761 indivíduos identificados com absoluta certeza (Tabela 7.1.1).

Por outro lado, a degradação probabilística de privacidade não se alterou drasticamente, mesmo que o número de indivíduos afetados tenha sido reduzido (Tabela 7.1.3). Este efeito não é surpreendente, uma vez que uma base amostral representativa da população como um todo deve apresentar propriedades estatísticas comparáveis com às desta população. Em particular, se a amostra é representativa, é natural que o risco médio esperado de um indivíduo selecionado para a base amostral deva ser similar ao risco médio esperado de um indivíduo da população em geral.

Os resultados confirmam o conhecimento da literatura técnica de que a sanitização por amostragem pode reduzir riscos à privacidade, mas não os torna irrisórios: o total indivíduos expostos decresce, mas aqueles selecionados para a amostra ainda estão sujeitos a sérias violações.

- **A sanitização por privacidade diferencial local reduziu drasticamente a degradação de privacidade, sendo o método mais efetivo neste quesito.**

Método de sanitização	Sucesso determinístico a priori	Sucesso determinístico a posteriori	Degradação determinística de privacidade
Desidentificação e pseudonimização	0.000000% (0 registros)	0.038608% (18 393 registros)	0.038608% (18 393 registros)
Amostragem	0.000000% (0 registros)	0.094268% (12 813 registros)	0.094268% (12 813 registros)
Privacidade diferencial local	Não se aplica.	Não se aplica.	Não se aplica.

(a) Usando como informação auxiliar o conjunto reduzido de 7 quaseidentificadores.

Método de sanitização	Sucesso determinístico a priori	Sucesso determinístico a posteriori	Degradação determinística de privacidade
Desidentificação e pseudonimização	0.000000% (0 registros)	0.269762% (128 517 registros)	0.269762% (128 517 registros)
Amostragem	0.000000% (0 registros)	0.638320% (86 761 registros)	0.638320% (86 761 registros)
Privacidade diferencial local	Não se aplica.	Não se aplica.	Não se aplica.

(b) Usando como informação auxiliar o conjunto reduzido de 23 quaseidentificadores.

Tabela 7.1.1: Experimentos 5, 8 e 12: Quadro-resumo do sucesso determinístico de ataques de reidentificação coletiva RCU , RCU^{ams} e $\widehat{RCU}^{ldp}$ sobre a base do Censo da Educação Básica de 2019 sanitizada por diferentes métodos. Recorde que a medida da degradação determinística de privacidade não se aplica a bases sanitizadas por privacidade diferencial local.

Os experimentos demonstram que a sanitização por privacidade diferencial local praticamente eliminou a degradação probabilística de privacidade (já que, pela sua própria natureza, a ela não se aplicam análise determinísticas). Os efeitos foram observados tanto para o conjunto reduzido de 7 quaseidentificadores quanto para o conjunto estendido de 23 (Tabela 7.1.4).

Método de sanitização	Sucesso determinístico a priori	Sucesso determinístico a posteriori	Degradação determinística de privacidade
Desidentificação e pseudonimização	0.000000% (0 registros)	0.000611% (4 registros)	0.000611% (4 registros)
Amostragem	0.000000% (0 registros)	0.007304% (1 registro)	0.007304% (1 registro)
Privacidade diferencial local	Não se aplica.	Não se aplica.	Não se aplica.

(a) Usando como informação auxiliar o conjunto reduzido de 7 quaseidentificadores.

Método de sanitização	Sucesso determinístico a priori	Sucesso determinístico a posteriori	Degradação determinística de privacidade
Desidentificação e pseudonimização	0.000000% (0 registros)	0.021546% (141 registros)	0.021546% (141 registros)
Amostragem	0.000000% (0 registros)	0.094953% (13 registros)	0.094953% (13 registros)
Privacidade diferencial local	Não se aplica.	Não se aplica.	Não se aplica.

(b) Usando como informação auxiliar o conjunto reduzido de 23 quaseidentificadores.

Tabela 7.1.2: Experimentos 5, 8 e 12: Quadro-resumo do sucesso determinístico de ataques de reidentificação coletiva RCU , RCU^{ams} e $\widehat{RCU}^{ldp}$ sobre a base do Censo da Educação Básica de 2019 restrita a registros do Distrito Federal e sanitizada por diferentes métodos. Recorde que a medida da degradação determinística de privacidade não se aplica a bases sanitizadas por privacidade diferencial local.

Método de sanitização	Sucesso probabilístico a priori	Sucesso probabilístico a posteriori	Degradação probabilística de privacidade
Desidentificação e pseudonimização	0.000002%	0.404132%	192 532
Amostragem	0.000002%	0.902386%	429 904
Privacidade diferencial local	Computacionalmente proibitivo.	Computacionalmente proibitivo.	Computacionalmente proibitivo.

(a) Usando como informação auxiliar o conjunto reduzido de 7 quaseidentificadores.

Método de sanitização	Sucesso probabilístico a priori	Sucesso probabilístico a posteriori	Degradação probabilística de privacidade
Desidentificação e pseudonimização	0.000002%	2.243502%	1 068 823
Amostragem	0.000002%	4.686075%	2 232 485
Privacidade diferencial local	Computacionalmente proibitivo.	Computacionalmente proibitivo.	Computacionalmente proibitivo.

(b) Usando como informação auxiliar o conjunto reduzido de 23 quaseidentificadores.

Tabela 7.1.3: Experimentos 5, 8 e 12: Quadro-resumo do sucesso probabilístico de ataques de reidentificação coletiva RCU , RCU^{ams} e $\widehat{RCU}^{ldp}$ sobre a base do Censo da Educação Básica de 2019 sanitizada por diferentes métodos.

Método de sanitização		Sucesso probabilístico a priori	Sucesso probabilístico a posteriori	Degradação probabilística de privacidade
Desidentificação e pseudonimização		0.000153%	0.022310%	146
Amostragem		0.000153%	0.069243%	453
Privacidade diferencial local	$\varepsilon = \ln 3$	0.000153%	$< 0.000001\%$	Não há.
	$\varepsilon = \ln 5$	0.000153%	$< 0.000001\%$	Não há.
	$\varepsilon = \ln 100$	0.000153%	$< 0.000001\%$	Não há.
	$\varepsilon = \ln 10^3$	0.000153%	$< 0.000001\%$	Não há.
	$\varepsilon = \ln 10^5$	0.000153%	$< 0.000001\%$	Não há.

(a) Usando como informação auxiliar o conjunto reduzido de 7 quaseidentificadores.

Método de sanitização		Sucesso probabilístico a priori	Sucesso probabilístico a posteriori	Degradação probabilística de privacidade
Desidentificação e pseudonimização		0.000153%	0.188566%	1 234
Amostragem		0.000153%	0.583066%	3 816
Privacidade diferencial local	$\varepsilon = \ln 3$	0.000153%	$< 0.000001\%$	Não há.
	$\varepsilon = \ln 5$	0.000153%	$< 0.000001\%$	Não há.
	$\varepsilon = \ln 100$	0.000153%	$< 0.000001\%$	Não há.
	$\varepsilon = \ln 10^3$	0.000153%	$< 0.000001\%$	Não há.
	$\varepsilon = \ln 10^5$	0.000153%	$< 0.000001\%$	Não há.

(b) Usando como informação auxiliar o conjunto reduzido de 23 quaseidentificadores.

Tabela 7.1.4: Experimentos 5, 8 e 12: Quadro-resumo do sucesso probabilístico de ataques de reidentificação coletiva RCU , RCU^{ams} e $\widehat{RCU}^{ldp}$ sobre a base do Censo da Educação Básica de 2019 restrita a registros do Distrito Federal e sanitizada por diferentes métodos.

7.2 Sumário comparativo da utilidade dos métodos de mitigação analisados

Nesta seção apresentamos uma comparação entre o nível de utilidade atingido por cada método de mitigação considerado.

7.2.1 Modelo de utilidade empregado

Para análise da utilidade de cada método de mitigação, empregamos uma métrica de propósito geral. Como discutimos na Seção 2.3, métricas de propósito geral partem do princípio de que se duas distribuições são semelhantes (e.g., a distribuição sobre dados na base original e a distribuição de dados após a sanitização), é provável que qualquer função computada sobre as mesmas (como valores de média, mediana, variância) tendam a ser também semelhantes. Isto significaria, portanto, que análises estatísticas sobre a base sanitizada tenderiam a ser similares a análises estatísticas realizadas sobre a base original, indicando a manutenção da utilidade da informação. Empregamos tais métricas no projeto piloto porque o Inep indicou a intenção de não privilegiar um uso de dados sobre outro.

É importante notar, entretanto, que métricas de propósito geral podem não capturar noções de utilidade em aplicações específicas, como, por exemplo, quando o analista de dados está interessado em estudar fenômenos de baixa frequência nos dados. Quando é conhecido o intento final do analista de dados, é recomendável realizar análises de utilidade com métricas específicas refletindo tal intento.

Neste projeto piloto, adotamos uma métrica de propósito geral baseada na distância de variação total, definida a seguir.

Definição 13 (Distância de variação total). Dadas duas distribuições de probabilidade P, Q sobre um mesmo domínio finito $\mathcal{X}$, a *distância de variação total* entre elas (também conhecida como *distância estatística*, *diferença estatística* ou *distância de variação*) é definida como

$$d_{TV}(P, Q) \stackrel{\text{def}}{=} \sup_{\mathcal{S} \subseteq \mathcal{X}} |P(\mathcal{S}) - Q(\mathcal{S})| = \frac{1}{2} \sum_{x \in \mathcal{X}} |P(x) - Q(x)|.$$

◁

Intuitivamente, a distância de variação total quantifica o quanto da massa da distribuição P é alocada a valores diferentes daqueles alocados pela massa da distribuição Q .

Por outro lado, a métrica de utilidade que adotamos é, essencialmente, o complemento da distância de variação total: ela quantifica a massa de probabilidade em que as distribuições de entrada atribuem aos mesmos elementos. Mais precisamente, dadas uma base original D , uma base sanitizada D' correspondente, e um conjunto de atributos $\mathcal{A}''$ de

interesse, a métrica de utilidade quantifica a similaridade entre a distribuição conjunta de $\mathcal{A}''$ em D e a distribuição conjunta de $\mathcal{A}''$ em D' . Quanto maior a similaridade, mais útil é a base sanitizada para a distribuição conjunta dos atributos de interesse.

Definição 14 (Utilidade estatística de uma base sanitizada em relação a um conjunto de atributos). Seja uma base original D definida sobre um conjunto de atributos $\mathcal{A}$. Seja D' uma base sanitizada obtida a partir de D através de algum método de sanitização, definida sobre um conjunto de atributos $\mathcal{A}'$. Seja $\mathcal{A}'' \subseteq \mathcal{A} \cap \mathcal{A}'$ um conjunto de atributos de interesse presentes tanto na base original D quanto na base sanitizada D' . A utilidade estatística de D' em relação a D para os atributos $\mathcal{A}''$ é dada por

$$\begin{aligned} util-estatistica_{\mathcal{A}''}(D, D') &\stackrel{\text{def}}{=} 1 - d_{TV}(\pi^{\mathcal{A}''|D}, \pi^{\mathcal{A}''|D'}) \\ &= 1 - \frac{1}{2} \sum_{a \in \text{dom}(\mathcal{A}'')} \left| \pi_a^{\mathcal{A}''|D} - \pi_a^{\mathcal{A}''|D'} \right|, \end{aligned}$$

onde $\pi^{\mathcal{A}''|D}$ e $\pi^{\mathcal{A}''|D'}$ são as distribuições conjuntas sobre os atributos $\mathcal{A}''$ induzidas, respectivamente, pela base original D e pela base sanitizada D' (definidas conforme a Equação 2.2). $\triangleleft$

É possível demonstrar que $util-estatistica_{\mathcal{A}''}(D, D')$ é sempre um valor entre 0 e 1, e quanto maior o valor, mais próxima é a distribuição de $\mathcal{A}''$ em D' e em D . Em particular, quando $util-estatistica_{\mathcal{A}''}(D, D')=1$, temos máxima utilidade (i.e., as distribuições são iguais).

Os exemplos a seguir ilustram o emprego da Definição 14 na análise de utilidade estatística da sanitização por amostragem e por privacidade diferencial local aplicadas ao exemplo condutor.


Exemplo 15 (Utilidade estatística da sanitização por amostragem aplicada ao exemplo condutor). Considere o processo de sanitização por amostragem empregado no Exemplo 6, ilustrado na Tabela 5.3.2. A base original D , representada na Tabela 5.3.2a, contém todos os atributos de todos os indivíduos. A base sanitizada D' , representada na Tabela 5.3.2b, é obtida a partir de D por amostragem (e eliminando a coluna do atributo *nome*, que funciona como um identificador único). Note que D' mantém 50% da população original (5 registros em 10).

A Tabela 7.2.5 apresenta a utilidade estatística computada para várias combinações conjuntas de atributos após emprego da sanitização por amostragem.


Já a Figura 7.2.6 apresenta histogramas de distribuição de probabilidade marginal de cada atributo individual e de algumas combinações de atributos conjuntos antes e após a sanitização. Estes histogramas ilustram o quão similares são as distribuições antes e após a sanitização para vários conjuntos de atributos. A medida de utilidade estatística é justamente uma quantificação da similaridade entre tais distribuições. $\triangleleft$

Atributos	Utilidade estatística
<i>idade</i>	0.8000
<i>sexo</i>	0.8000
<i>escola</i>	0.7000
<i>deficiência</i>	0.9000
$\{idade, sexo\}$	0.7000
$\{idade, escola\}$	0.6000
$\{sexo, escola\}$	0.7000
$\{idade, sexo, escola\}$	0.6000
$\mathcal{A}$	0.5000

Tabela 7.2.5: Exemplo 15: Utilidade estatística para várias combinações conjuntas de atributos após emprego da sanitização por amostragem no exemplo condutor.



(a) Distribuições marginais.



(b) Algumas distribuições conjuntas.

Figura 7.2.6: Exemplo 15: Histogramas comparando as distribuições de probabilidade de atributos antes e após a sanitização por amostragem sobre o exemplo condutor.

Atributos	Utilidade estatística
<i>idade</i>	0.4000
<i>sexo</i>	0.9000
<i>escola</i>	0.6000
<i>deficiência</i>	1.0000
{ <i>idade</i> , <i>sexo</i> }	0.4000
{ <i>idade</i> , <i>escola</i> }	0.2000
{ <i>sexo</i> , <i>escola</i> }	0.4000
{ <i>idade</i> , <i>sexo</i> <i>escola</i> }	0.2000
$\mathcal{A}$	0.2000


Tabela 7.2.7: Exemplo 16: Utilidade estatística para várias combinações conjuntas de atributos após emprego da sanitização por privacidade diferencial local no exemplo condutor.

Exemplo 16 (Utilidade estatística da sanitização por privacidade diferencial local aplicada ao exemplo condutor). Considere o processo de sanitização por privacidade diferencial local empregado no Exemplo 10, ilustrado na Tabela 6.3.5. A base original D , representada na Tabela 6.3.5a, contém todos os atributos de todos os indivíduos. A base sanitizada D' , representada na Tabela 6.3.5b, é obtida a partir de D por privacidade diferencial local (e eliminando a coluna do atributo *nome*, que funciona como um identificador único).

A Tabela 7.2.7 apresenta a utilidade estatística computada para várias combinações conjuntas de atributos após emprego da sanitização por privacidade diferencial local.

Já a Figura 7.2.8 apresenta histogramas de distribuição de probabilidade marginal de cada atributo individual e de algumas combinações de atributos conjuntos antes e após a sanitização. Estes histogramas ilustram o quão similares são as distribuições antes e após a sanitização para vários conjuntos de atributos. A medida de utilidade estatística é justamente uma quantificação da similaridade entre tais distribuições.

◁



(a) Distribuições marginais.



(b) Algumas distribuições conjuntas.

Figura 7.2.8: Exemplo 15: Histogramas comparando as distribuições de probabilidade de atributos antes e após a sanitização por privacidade diferencial local sobre o exemplo condutor.

7.2.2 Resultados da análise experimental de utilidade

A Tabela 7.2.9 apresenta o resultado das análises de utilidade dos métodos de sanitização aplicados aos dados do Censo da Educação Básica de 2019 referentes a todo o Brasil. A Tabela 7.2.10 demonstra os mesmos resultados restritos ao Distrito Federal. O Anexo E apresenta histogramas comparativos da distribuição de probabilidade marginal de cada atributo individual e de algumas combinações de atributos conjuntos antes e após a sanitização por cada método. Estes histogramas ilustram o quão similares são as distribuições antes e após a sanitização para vários conjuntos de atributos.

Podemos destacar os seguintes pontos em nossa análise:

- **Utilidade da distribuição marginal de atributo individual vs. utilidade da distribuição marginal de atributos conjuntos.** Em todos os métodos de sanitização empregados, as distribuições marginais de atributos individuais são melhor mantidas quando comparadas às distribuições de atributos conjuntos.

Isto indica a dificuldade de se manter informação de qualidade sobre correlações de atributos após um processo de sanitização.

- **A sanitização por amostragem provê uma nível de utilidade significativamente superior ao provido pela privacidade diferencial local.** Em todas as combinações de atributos analisadas, a sanitização por amostragem demonstrou prover maior utilidade que a privacidade diferencial local.

Analisando os dados referentes ao Brasil inteiro na Tabela 7.2.9, observamos que para o atributo NU_IDADE_0_5, cujos valores têm alta variabilidade, a privacidade diferencial local foi capaz de prover uma utilidade entre 0.5135 e 0.6165, enquanto a amostragem chegou a um valor 0.9972. Apenas no caso de atributos em que há pouca variabilidade de valores (como TP_TIPO_ATENDIMENTO_TURMA ou IN_EDUCACAO_INDIGENA), a utilidade dos dois métodos de mitigação foi semelhante. Por fim, para a distribuição conjunta de todos os atributos divulgados na base, nem mesmo a amostragem teve uma utilidade elevada, chegando a apenas 0.5822. Mesmo assim, tal valor é superior à utilidade obtida pela privacidade diferencial local, que variou de 0.1524 a 0.3469 para o conjunto de todos os atributos.

- **Conciliar a privacidade diferencial local com alta utilidade da divulgação é um desafio não trivial.** Analisando os dados referentes ao Brasil inteiro na Tabela 7.2.9, observamos que quanto maior o valor do parâmetro de privacidade ϵ , maior a utilidade obtida na divulgação. A literatura técnica na área indica que quanto maior o valor deste parâmetro, menor tende a ser a proteção de privacidade aos titulares dos dados. Entretanto, nos experimentos observados percebemos que mesmo os valores elevados de ϵ testados proveram níveis de privacidade comparáveis aos valores menores utilizados. Este é um indicativo de que há espaço para refinamento de técnicas na tentativa de se encontrar um melhor compromisso entre utilidade e privacidade no caso concreto dos Censos Educacionais.

Os resultados aqui apresentados não indicam que a privacidade diferencial local está definitivamente fora de questão como possível solução para a divulgação de microdados dos Censos Educacionais do Inep. Eles apenas reforçam o conhecimento técnico da literatura de que qualquer solução baseada em privacidade diferencial local exige um trabalho laborioso, incluindo o ajuste fino de parâmetros e técnicas, o que não foi possível completar durante o reduzido tempo disponível para o presente projeto piloto.

Atributo	Sanit. por Amostragem	Sanitização por privacidade diferencial local				
		$\epsilon = \ln 3$	$\epsilon = \ln 5$	$\epsilon = \ln 100$	$\epsilon = \ln 10^3$	$\epsilon = \ln 10^5$
NU_IDADE_0_5	0.9972	0.5135	0.5746	0.6719	0.7219	0.6156
TP_SEXO	0.9978	0.6985	0.6712	0.6685	0.6677	0.9495
TP_COR_RACA	0.9843	—	—	—	—	—
TP_ZONA_RESIDENCIAL	0.9100	0.5513	0.5108	0.5068	0.5056	0.9248
IN_NECESSIDADE_ESPECIAL	0.9868	—	—	—	—	—
TP_ETAPA_ENSINO	0.9205	0.8719	0.8721	0.8722	0.8721	0.8720
IN_ESPECIAL_EXCLUSIVA	0.9634	—	—	—	—	—
IN_REGULAR	0.9356	0.9238	0.9238	0.9239	0.9238	0.9239
IN_EJA	0.9434	0.9238	0.9238	0.9239	0.9238	0.9239
IN_PROFISSIONALIZANTE	0.9592	0.9238	0.9238	0.9239	0.9238	0.9239
ID_AREA_CURSO_PROFISSIONAL	0.9934	0.9909	0.9910	0.9910	0.9909	0.9909
TP_MEDIACAO_DIDATICO_PEDAGO	0.9991	0.9907	0.9907	0.9906	0.9906	0.9906
IN_TURNO	0.9717	0.9735	0.9736	0.9736	0.9735	0.9735
IN_TEMPO_INTEGRAL	0.9662	—	—	—	—	—
TP_TIPO_ATENDIMENTO_TURMA	0.9649	0.9238	0.9238	0.9239	0.9238	0.9239
CO_REGIAO	0.8994	0.9753	0.9752	0.9752	0.9753	0.9753
CO_MESORREGIAO	0.7629	0.9598	0.9596	0.9597	0.9596	0.9598
CO_MICRORREGIAO	0.7074	0.9528	0.9527	0.9527	0.9527	0.9529
CO_UF	0.8564	0.9683	0.9682	0.9683	0.9682	0.9684
CO_MUNICIPIO	0.6482	0.9379	0.9379	0.9381	0.9379	0.9381
TP_DEPENDENCIA	0.9808	0.9314	0.9314	0.9314	0.9315	0.9313
TP_LOCALIZACAO	0.9584	0.9697	0.9698	0.9697	0.9698	0.9697
TP_CATEGORIA_ESCOLA_PRIVADA	0.9909	0.9711	0.9710	0.9711	0.9712	0.9711
IN_CONVENIADA_PP	0.9909	0.9712	0.9711	0.9712	0.9712	0.9712
TP_CONVENIO_PODER_PUBLICO	0.9920	0.9898	0.9898	0.9898	0.9898	0.9898
TP_LOCALIZACAO_DIFERENCIADA	0.9940	0.9932	0.9932	0.9932	0.9931	0.9932
IN_EDUCACAO_INDIGENA	0.9980	0.9972	0.9972	0.9973	0.9972	0.9972

(a) Utilidade da distribuição marginal de cada atributo individual.

Atributos Conjuntos	Sanit. por Amostragem	Sanitização por privacidade diferencial local				
		$\epsilon = \ln 3$	$\epsilon = \ln 5$	$\epsilon = \ln 100$	$\epsilon = \ln 10^3$	$\epsilon = \ln 10^5$
TP_SEXO, TP_ZONA_RESIDENCIAL, NU_IDADE_0_5, TP_LOCALIZACAO_DIFERENCIADA	0.9095	0.2487	0.2572	0.2962	0.3108	0.5453
TP_SEXO, TP_ZONA_RESIDENCIAL, NU_IDADE_0_5, IN_EDUCACAO_INDIGENA	0.9096	0.2502	0.2586	0.2994	0.3181	0.5518
Todos os atributos em conjunto	0.5822	0.1524	0.1522	0.1712	0.1811	0.3469

(b) Utilidade da distribuição conjunta de atributos.

Tabela 7.2.9: Experimentos 8 e 12: Quadro-resumo da utilidade estatística medida para estudos de caso envolvendo a base do Censo da Educação Básica de 2019. Cada linha representa a utilidade estatística para a distribuição conjunta dos atributos em questão.

Atributo	Sanit. por Amostragem	Sanitização por privacidade diferencial local				
		$\epsilon = \ln 3$	$\epsilon = \ln 5$	$\epsilon = \ln 100$	$\epsilon = \ln 10^3$	$\epsilon = \ln 10^5$
NU_IDADE_0_5	0.9967	0.5119	0.5752	0.6709	0.7207	0.6088
TP_SEXO	0.9892	0.6988	0.6707	0.6676	0.6669	0.9497
TP_COR_RACA	0.9590	—	—	—	—	—
TP_ZONA_RESIDENCIAL	0.9914	0.4368	0.3974	0.3948	0.3918	0.8113
IN_NECESSIDADE_ESPECIAL	0.9827	—	—	—	—	—
TP_ETAPA_ENSINO	0.7597	0.8231	0.8232	0.8244	0.8234	0.8234
IN_ESPECIAL_EXCLUSIVA	0.9286	—	—	—	—	—
IN_REGULAR	0.7615	0.8435	0.8437	0.8447	0.8435	0.8440
IN_EJA	0.8728	0.8435	0.8437	0.8447	0.8435	0.8440
IN_PROFISSIONALIZANTE	0.8226	0.8435	0.8437	0.8447	0.8435	0.8440
ID_AREA_CURSO_PROFISSIONAL	0.8950	0.9907	0.9904	0.9905	0.9904	0.9908
TP_MEDIACAO_DIDATICO_PEDAGO	0.9527	0.9942	0.9943	0.9943	0.9943	0.9941
IN_TURNO	0.8840	0.9857	0.9852	0.9860	0.9859	0.9855
IN_TEMPO_INTEGRAL	0.9324	—	—	—	—	—
TP_TIPO_ATENDIMENTO_TURMA	0.9324	0.8435	0.8437	0.8447	0.8435	0.8440
CO_REGIAO	1.0000	1.0000	1.0000	1.0000	1.0000	1.0000
CO_MESORREGIAO	1.0000	1.0000	1.0000	1.0000	1.0000	1.0000
CO_MICRORREGIAO	1.0000	1.0000	1.0000	1.0000	1.0000	1.0000
CO_UF	1.0000	1.0000	1.0000	1.0000	1.0000	1.0000
CO_MUNICIPIO	1.0000	1.0000	1.0000	1.0000	1.0000	1.0000
TP_DEPENDENCIA	0.8148	0.9851	0.9845	0.9854	0.9845	0.9846
TP_LOCALIZACAO	0.9931	0.9983	0.9982	0.9983	0.9981	0.9980
TP_CATEGORIA_ESCOLA_PRIVADA	0.8268	0.9893	0.9888	0.9896	0.9887	0.9890
IN_CONVENIADA_PP	0.8273	0.9882	0.9874	0.9883	0.9874	0.9873
TP_CONVENIO_PODER_PUBLICO	0.9892	0.9989	0.9986	0.9987	0.9987	0.9984
TP_LOCALIZACAO_DIFERENCIADA	1.0000	1.0000	1.0000	1.0000	1.0000	1.0000
IN_EDUCACAO_INDIGENA	0.9991	0.9999	1.0000	0.9999	1.0000	1.0000

(a) Utilidade da distribuição marginal de cada atributo individual.

Atributos Conjuntos	Sanit. por Amostragem	Sanitização por privacidade diferencial local				
		$\epsilon = \ln 3$	$\epsilon = \ln 5$	$\epsilon = \ln 100$	$\epsilon = \ln 10^3$	$\epsilon = \ln 10^5$
TP_SEXO, TP_ZONA_RESIDENCIAL, NU_IDADE_0_5	0.9864	0.1922	0.1878	0.2082	0.2182	0.4936
TP_SEXO, TP_ZONA_RESIDENCIAL, NU_IDADE_0_5, TP_LOCALIZACAO_DIFERENCIADA	0.9864	0.1922	0.1878	0.2082	0.2182	0.4936
TP_SEXO, TP_ZONA_RESIDENCIAL, NU_IDADE_0_5, IN_EDUCACAO_INDIGENA	0.9855	0.1922	0.1878	0.2082	0.2182	0.4936
Todos os atributos em conjunto	0.6615	0.1553	0.1523	0.1689	0.1772	0.3763

(b) Utilidade da distribuição conjunta de atributos.

Tabela 7.2.10: Experimentos 8 e 12: Quadro-resumo da utilidade estatística medida para estudos de caso envolvendo a base do Censo da Educação Básica de 2019 restrita aos registros do Distrito Federal. Cada linha representa a utilidade estatística para a distribuição conjunta dos atributos em questão.

8 Considerações finais

Neste documento apresentamos várias análises experimentais quantitativas sobre a privacidade e a utilidade de dados providas pelos dois métodos de sanitização selecionados pelo Inep para o presente projeto piloto: amostragem e privacidade diferencial local. As análises foram realizadas sobre os dados do Censo da Educação Básica de 2019. Em todas elas consideramos como informação auxiliar para o adversário atributos cujos valores sejam presumivelmente conhecidos, ou possam ser facilmente descobertos (e.g., a idade de um aluno, seu sexo ou dados sobre sua entidade de ensino). Mais precisamente:

- Analisamos a degradação de privacidade nos seguintes ataques.
 - Ataques de reidentificação coletiva sobre uma única base de dados (RCU) sanitizada por desidentificação (em que se removem identificadores individuais óbvios dos registros, como nome e CPF) e pseudonimização (em que tais identificadores individuais óbvios são substituídos por um código único artificialmente criado). Tais técnicas são as atualmente empregadas pelo Inep na divulgação dos dados dos Censos Educacionais. As análises levam em conta a restrição no número e granularidade de atributos divulgados determinada pelo Inep para o presente projeto piloto e servem de base de comparação para as demais técnicas de sanitização avaliadas neste documento.
 - Ataques de reidentificação coletiva sobre uma única base sanitizada por amostragem (RCU^{ams}). O plano amostral utilizado foi desenhado pelo Inep.
 - Ataques de reidentificação coletiva sobre uma única base sanitizada por privacidade diferencial local ($\widehat{RCU}^{ldp}$). Empregamos o método padrão na literatura, em que atributos são sanitizados de forma independente. Dado o prazo deste projeto piloto, foi realizada uma exploração apenas preliminar do espaço vasto de valores possíveis para os parâmetros de privacidade do método.
- Provemos uma análise comparativa da privacidade e utilidade atingidas por cada método de sanitização empregado. Como medida de utilidade, adotamos a métrica de propósito geral de utilidade estatística, que mede a similaridade entre a distribuição de probabilidade sobre atributos antes e após a sanitização.

A seguir destacamos as principais conclusões do presente documento.

(I) **Impacto da restrição do número e granularidade de atributos divulgados na degradação de privacidade e na utilidade dos Censos Educacionais.**

No Produto 02 deste TED 8750, analisamos experimentalmente ataques de reidentificação coletiva sobre uma única base dados (RCU) sobre vários Censos Educacionais divulgados pelo Inep via desidentificação e pseudonimização. Em particular, quantificamos a degradação de privacidade referente ao Censo da Educação Básica de 2019, em que se publicava um número elevado de atributos.

Entretanto, neste projeto piloto o Inep restringiu significativamente o número e a granularidade de atributos a serem divulgados nos microdados dos Censos, conforme a Tabela 3.1.1. Tal restrição teve o efeito de eliminar ou reduzir a precisão de quaseidentificadores poderosos anteriormente disponíveis para o adversário.

A fim de analisar o impacto na degradação de privacidade causado pela restrição de atributos em si mesma (i.e., antes mesmo da aplicação de métodos de sanitização mais refinados), refizemos neste documento a análise a respeito de ataques RCU sobre o Censo da Educação Básica de 2019. A nova análise foi aplicada sobre o Censo em sua atual forma de tratamento pelo Inep (i.e., apenas por desidentificação e pseudonimização), mas considera o novo conjunto restrito de atributos.

Os resultados experimentais sugerem que, mesmo assumindo que o adversário tenha como informação auxiliar uma grande parte dos atributos presentes na nova base, a restrição de atributos divulgados pode reduzir significativamente a degradação de privacidade. Entretanto, o risco remanescente ainda é proibitivamente elevado para os titulares dos dados. Desta forma, a medida não foi suficiente para, isoladamente, prover níveis aceitáveis de privacidade na divulgação do Censo.

Destaque: Para este projeto piloto o Inep restringiu o número e a granularidade de atributos a serem divulgados no Censo da Educação Básica de 2019. Para avaliar o impacto desta restrição na privacidade, refizemos neste documento experimentos do Produto 02 deste TED 8750 sobre ataques de reidentificação coletiva em uma única base de dados (RCU). A nova análise utiliza o conjunto restrito de atributos, mantendo o tratamento apenas por desidentificação e pseudonimização atualmente empregado pelo Inep. No Produto 02 verificamos que 29 013 261 registros (60.92% do total) do Censo da Educação Básica de 2019 puderam ser reidentificados com absoluta certeza usando 10 quaseidentificadores como informação auxiliar. Os novos experimentos mostram que a restrição sobre atributos divulgados pode levar a uma redução da degradação de privacidade no mesmo Censo, tanto determinística quanto probabilística. Entretanto, ainda assim um número significativo de indivíduos permaneceu exposto a um risco considerável: de 18 393 a 128 517 registros (0.04% a 0.27% do total) puderam ser reidentificados com absoluta certeza, usando de 7 a 23 quaseidentificadores (Tabela 4.2.2). Além disso, a restrição sobre atributos reduz a utilidade da divulgação, ao omitir atributos possivelmente de interesse de analistas de dados.

- (II) **Impacto da sanitização por amostragem na degradação de privacidade e na utilidade do projeto piloto.** A motivação para sanitização por amostragem é a expectativa de que o adversário, não tendo certeza da presença de um indivíduo-alvo na base divulgada, teria mais dificuldades em reidentificar registros. Isto supostamente levaria a maior privacidade para os titulares dos dados.

Esta intuição, entretanto, comprova-se apenas parcialmente na prática. Por exemplo, considere que um adversário tenha a informação auxiliar de que no Departamento de Ciência da Computação da UFMG (DCC) só haja um docente de origem holandesa. Caso seja criada uma base amostral sobre o conjunto de professores do DCC, e o docente holandês seja selecionado para a mesma (e a base contiver um atributo que indique seu país de origem), o adversário poderá facilmente reidentificar o alvo na base, pois o único registro que indica nacionalidade holandesa com certeza pertence ao alvo. Apesar da inclusão do docente holandês na base amostral ser um evento de probabilidade potencialmente pequena, isso não necessariamente traria conforto a ele uma vez que sua privacidade tenha sido violada.

Neste documento analisamos o efeito da sanitização por amostragem na degradação de privacidade comparado ao emprego de apenas desidentificação e pseudonimização. Os experimentos demonstram que a sanitização por amostragem reduziu significativamente a degradação determinística de privacidade, enquanto teve pouco efeito na degradação probabilística. O resultado está em conformidade com o conhecimento da literatura técnica: a amostragem diminui o número absoluto de indivíduos expostos a risco, entretanto aqueles presentes na amostra ainda podem estar sujeitos a graves violações. Por outro lado, a amostragem demonstrou uma manutenção razoável da utilidade estatística dos dados divulgados.

Destaque: A sanitização por amostragem reduziu significativamente a degradação determinística de privacidade em relação ao tratamento por apenas desidentificação e pseudonimização. Usando 7 quaseidentificadores, houve uma redução de 18 393 para 12 813 indivíduos reidentificados com absoluta certeza; enquanto o uso de 23 quaseidentificadores causou uma redução de 128 517 para 86 761 indivíduos reidentificados (Tabela 7.1.1). Por outro lado, a degradação probabilística de privacidade não se alterou drasticamente, mesmo que o número de indivíduos afetados tenha sido reduzido (Tabela 7.1.3). Os resultados confirmam o conhecimento da literatura técnica de que a sanitização por amostragem pode reduzir riscos à privacidade, mas não os torna irrisórios: o total de indivíduos expostos decresce, mas aqueles selecionados para a amostra ainda podem estar sujeitos a graves violações. Por outro lado, a amostragem demonstrou uma manutenção razoável na utilidade estatística dos dados, e muito superior à provida por privacidade diferencial local (Tabela 7.2.9). Esta utilidade, entretanto, é maior para atributos isolados e diminui para atributos conjuntos, indicando uma potencial perda da correlação entre atributos na base divulgada.

- (III) **Impacto da sanitização por privacidade diferencial local na degradação de privacidade e na utilidade do projeto piloto.** A motivação central por trás da privacidade diferencial local é que uma cuidadosa introdução de ruído em cada registro produz no adversário um nível de incerteza sobre os valores reais dos atributos divulgados, assim como sobre se um indivíduo alvo estaria ou não na base. Como consequência, o titular pode negar de forma plausível que qualquer de seus atributos tenha um valor específico, mesmo no pior caso em que seu registro tenha sido reidentificado e o adversário tenha tido acesso aos valores sanitizados divulgados. O nível de ruído introduzido é controlado pelo valor do parâmetro de privacidade ϵ : quanto menor este valor, mais privados são os dados, porém corre-se o risco de que ruído adicionado prejudique a utilidade dos mesmos.

Neste documento analisamos a proteção à privacidade da sanitização por privacidade diferencial local comparada à do emprego de apenas desidentificação e pseudonimização. Os experimentos demonstram que a sanitização empregada praticamente eliminou a degradação probabilística de privacidade (lembrando que, pela sua própria natureza, a ela não se aplicam análises determinísticas). Por outro lado, a aplicação do método em sua forma atual apresentou um custo elevado –e potencialmente proibitivo– na utilidade estatística dos dados divulgados. Os resultados confirmam o conhecimento da literatura técnica: a privacidade diferencial local é considerada o estado da arte em controle de divulgação estatística, mas a questão de conciliar-se privacidade com utilidade na técnica é desafiadora. De fato, é conhecido que na maioria dos casos um trabalho longo e laborioso de ajuste de parâmetros e técnicas normalmente é necessário para se atingir o potencial máximo de utilidade da privacidade diferencial local.

Destaque: Os experimentos mostram que a sanitização por privacidade diferencial local praticamente eliminou a degradação probabilística de privacidade (lembrando que a ela não se aplicam análise determinísticas). Os efeitos foram observados tanto no conjunto reduzido de 7 quaseidentificadores quanto no conjunto estendido de 23 (Tabela 7.1.4). Por outro lado, a sanitização por privacidade diferencial local apresentou um custo elevado –e potencialmente proibitivo– na utilidade estatística dos dados divulgados. Nossas análises demonstram que a utilidade estatística dos dados é mantida de forma razoável apenas para atributos isolados, mas as correlações entre um número maior de atributos são degradadas de forma significativa. O efeito foi observado mesmo para valores elevadíssimos do parâmetro ϵ , que na prática não carregariam nenhuma garantia de privacidade razoável (Tabela 7.2.9). Os resultados deste projeto piloto se alinham com o conhecimento técnico da literatura: a privacidade diferencial local tem alta eficácia em garantir privacidade, mas o ajuste fino da utilidade na sanitização pelo método pode demandar um laborioso e minucioso processo de ajuste de parâmetros e refinamento de técnicas, possivelmente necessitando um elevado investimento de tempo e pessoal especializado.

(IV) **Avaliação final do projeto piloto.** No Produto 03 deste TED 8750 provemos evidências da literatura técnica que indicavam que a obtenção de solução para divulgação de microdados de forma privada e útil era implausível no curto espaço de tempo disponível para adequação do Inep à LGPD. Mais precisamente:

- A sanitização por amostragem, apesar de reduzir o risco médio dos indivíduos na base (tanto de reidentificação quanto de inferência de atributo), não garante privacidade em nível individual [24].
- A sanitização por privacidade diferencial local, apesar de altamente eficaz na preservação de privacidade, demanda um laborioso e minucioso processo de ajuste de parâmetros e refinamento de técnicas. Isso normalmente implica em investimento de tempo e pessoal especializado mais elevados, como evidenciado no caso do Escritório do Censo dos Estados Unidos [50, 28, 13].

Este projeto piloto corrobora em extensos estudos quantitativos que estas indicações da literatura se confirmam no caso concreto dos Censos Educacionais do Inep. Nossas análises evidenciam a inviabilidade de se prover no curto prazo uma divulgação de microdados dos Censos que seja concomitantemente privada e útil. Na nossa avaliação, esta é uma contribuição central deste relatório por dois motivos:

- Esta informação é crucial para as futuras tomadas de decisão do Inep sobre a divulgação dos Censos Educacionais, ponderando entre soluções de curto prazo –implementáveis de forma relativamente rápida, mas potencialmente sub-ótimas quanto à utilidade provida– e soluções de longo prazo –mais úteis, porém que demandam maior investimento de tempo e pessoal especializado.
- Esta informação provê ao Inep subsídios para uma efetiva comunicação com as partes interessadas nos Censos Educacionais sobre os desafios técnicos da adequação da divulgação de microdados à LGPD. Isto pode auxiliar tais partes a compreenderem as nuances de futuras decisões do Inep –eventualmente, inclusive, sobre formas de divulgação que restrinjam microdados.

Destaque: As análises experimentais deste projeto piloto evidenciam a inviabilidade da manutenção no curto prazo da divulgação de microdados dos Censos Educacionais de forma privada e útil. Tal constatação está em consonância com a literatura técnica em controle de divulgação estatística e constitui uma contribuição central deste projeto piloto. Primeiramente, ela provê ao Inep informação crucial para tomadas de decisões futuras, balanceando soluções de curto prazo –implementáveis de forma relativamente rápida, mas potencialmente sub-ótimas quanto à utilidade provida– e soluções de longo prazo –mais úteis, porém que demandem maior investimento de tempo e pessoal especializado. Em segundo lugar, ela provê ao Inep subsídios para comunicação efetiva com as partes interessadas sobre os desafios técnicos na divulgação de microdados, facilitando a compreensão sobre eventuais decisões pela limitação dos microdados divulgados.

- (V) **Visão de futuro e alternativas identificadas.** Os resultados deste projeto piloto refletem os objetivos atingidos dadas as fortes restrições do prazo disponível para adequação da divulgação dos Censos Educacionais à LGPD. Os resultados não devem ser interpretados como indicativos de que não há solução possível para divulgação dos dados dos Censos de forma privada e com um nível razoável de utilidade, mas sim que é necessária uma criteriosa ponderação sobre passos futuros.

De fato, as dificuldades relatadas neste Produto 05 não são peculiares ao Inep. Como mencionado no Produto 03 deste TED e no Anexo **F** do presente relatório, a implementação da privacidade diferencial pelo Escritório do Censo dos Estados Unidos enfrentou e enfrenta diversas dificuldades, tanto técnicas [28] quanto de comunicação com o restante da comunidade de estatística [50]. Apesar disso, o Escritório continua a preparação para o uso do método, inclusive com a publicação de produtos de demonstração derivados dos microdados do Censo de 2010 [13], por entender que a privacidade diferencial é a melhor abordagem para o problema.

Em nossa avaliação, as duas alternativas futuras mais razoáveis para o Inep seriam:

- **Alternativa 1:** Abandono da divulgação de microdados –exceto em salas seguras físicas ou virtuais– em favor da divulgação de dados agregados sanitizados por privacidade diferencial. Conforme plano de ação proposto no Produto 03 deste TED 8750, avaliamos esta opção como a mais promissora para os Censos Educacionais do Inep.
- **Alternativa 2:** Desenvolvimento de um método de sanitização de microdados por privacidade diferencial local desenhado e refinado especificamente para Censos Educacionais. Esta opção demandaria tempo e recursos significativamente maiores, incluindo atividades de pesquisa e desenvolvimento.

Destaque: Como observado anteriormente neste projeto, a opção por qualquer método de mitigação deve harmonizar interesses possivelmente conflitantes de vários atores. No caso dos Censos Educacionais do Inep, os atores incluem os titulares de dados (estudantes, professores, etc.), analistas (demógrafos, entidades civis e governamentais, etc.), o governo (que regulamenta tanto questões de privacidade quanto de transparência e acesso à informação), além do próprio Inep (que tem que conciliar de forma realista as demandas dos vários atores com a sua capacidade e recursos para atendê-las). Considerando estes fatores e os desafios técnicos expostos neste projeto piloto, identificamos duas alternativas para a divulgação dos Censos de forma privada e útil: (1) abandono da divulgação de microdados –exceto em salas seguras físicas ou virtuais– em favor da divulgação de dados agregados sanitizados por privacidade diferencial; ou (2) desenvolvimento de um método de sanitização de microdados por privacidade diferencial local desenhado e refinado especificamente para o Inep. Consideramos a primeira alternativa mais promissora, enquanto a segunda demandaria tempo e recursos maiores, incluindo atividades de pesquisa e desenvolvimento.

Referências Bibliográficas

- [1] Volkstelling. In *Wikipedia: de vrije encyclopedie*. Wikimedia, 2020. Disponível em: <https://nl.wikipedia.org/wiki/Volkstelling>.
- [2] John M. Abowd. The U.S. Census Bureau Adopts Differential Privacy. In *Proceedings of the 24th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining, KDD '18*, page 2867. Association for Computing Machinery, 2018.
- [3] Mário S. Alvim, Miguel E. Andrés, Konstantinos Chatzikokolakis, Pierpaolo Degano, and Catuscia Palamidessi. On the information leakage of differentially-private mechanisms. *Journal of Computer Security*, 23(4):427–469, 2015.
- [4] Mário S. Alvim, Miguel E. Andres, and Catuscia Palamidessi. Information Flow in Interactive Systems. *Journal of Computer Security*, 1(20):3–50, 2012.
- [5] Mário S. Alvim, Konstantinos Chatzikokolakis, Annabelle McIver, Carroll Morgan, Catuscia Palamidessi, and Geoffrey Smith. Additive and Multiplicative Notions of Leakage, and Their Capacities. In *Proc. of CSF*, pages 308–322. IEEE, 2014.
- [6] Mário S. Alvim, Konstantinos Chatzikokolakis, Annabelle McIver, Carroll Morgan, Catuscia Palamidessi, and Geoffrey Smith. Axioms for Information Leakage. In *IEEE 29th Computer Security Foundations Symposium, CSF 2016, Lisbon, Portugal, June 27 - July 1, 2016*, pages 77–92, 2016.
- [7] Mário S. Alvim, Konstantinos Chatzikokolakis, Annabelle McIver, Carroll Morgan, Catuscia Palamidessi, and Geoffrey Smith. *The Science of Quantitative Information Flow*. Springer, 2020.
- [8] Mário S. Alvim, Konstantinos Chatzikokolakis, Catuscia Palamidessi, and Geoffrey Smith. Measuring Information Leakage Using Generalized Gain Functions. In *25th IEEE Computer Security Foundations Symposium, CSF 2012, Cambridge, MA, USA, June 25-27, 2012*, pages 265–279, 2012.
- [9] Mário S. Alvim, Natasha Fernandes, Annabelle McIver, and Gabriel H. Nunes. On Privacy and Accuracy in Data Releases (Invited Paper). In *31st International Conference on Concurrency Theory, CONCUR 2020, September 1-4, 2020, Vienna, Aus-*

- tria (Virtual Conference)*, volume 171 of *LIPICs*, pages 1:1–1:18. Schloss Dagstuhl - Leibniz-Zentrum für Informatik, 2020.
- [10] Michele Boreale, Francesca Pampaloni, and Michela Paolini. Asymptotic Information Leakage under One-Try Attacks. In *Foundations of Software Science and Computational Structures - 14th International Conference, FOSSACS 2011, Held as Part of the Joint European Conferences on Theory and Practice of Software, ETAPS 2011, Saarbrücken, Germany, March 26-April 3, 2011. Proceedings*, volume 6604 of *LNCS*, pages 396–410. Springer, 2011.
 - [11] Christelle Braun, Konstantinos Chatzikokolakis, and Catuscia Palamidessi. Quantitative Notions of Leakage for One-try Attacks. In *Proc. of MFPS*, volume 249 of *ENTCS*, pages 75–91. Elsevier, 2009.
 - [12] Hai Brenner and Kobbi Nissim. Impossibility of Differentially Private Universally Optimal Mechanisms. In *2010 IEEE 51st Annual Symposium on Foundations of Computer Science*, pages 71–80, 2010.
 - [13] United States Census Bureau. 2010 Demonstration Data Products, 2019. Disponível em: <https://www.census.gov/programs-surveys/decennial-census/2020-census/planning-management/2020-census-data-products/2010-demonstration-data-products.html>.
 - [14] United States Census Bureau. Legacy Techniques and Current Research in Disclosure Avoidance at the U.S. Census Bureau, 2019. Disponível em <https://www.census.gov/library/working-papers/2019/adrm/legacy-da-techniques.html>.
 - [15] Christian Cachin. *Entropy Measures and Unconditional Security in Cryptography*. PhD thesis, ETH, 1997.
 - [16] Konstantinos Chatzikokolakis, Natasha Fernandes, and Catuscia Palamidessi. Comparing Systems: Max-Case Refinement Orders and Application to Differential privacy. In *32nd IEEE Computer Security Foundations Symposium, CSF 2019, Hoboken, NJ, USA, June 25-28, 2019*, pages 442–457. IEEE, 2019.
 - [17] Konstantinos Chatzikokolakis, Catuscia Palamidessi, and Prakash Panangaden. Anonymity Protocols as Noisy channels. *Inf. and Comp.*, 206(2–4):378–401, 2008.
 - [18] David Clark, Sebastian Hunt, and Pasquale Malacaria. Quantitative Analysis of the Leakage of Confidential Data. In *Proc. of QAPL*, volume 59 (3) of *ENTCS*, pages 238–251. Elsevier, 2001.
 - [19] David Clark, Sebastian Hunt, and Pasquale Malacaria. Quantitative Information Flow, Relations and Polymorphic Types. *J. of Logic and Computation*, 18(2):181–199, 2005.
 - [20] Michael R. Clarkson, Andrew C. Myers, and Fred B. Schneider. Belief in information flow. *Journal of Computer Security*, 17(5):655–701, 2009.

- [21] Instituto Brasileiro de Geografia e Estatística. Confidencialidade no IBGE - procedimentos adotados na preservação do sigilo das informações individuais nas divulgações de resultados das operações estatísticas, 2018. Disponível em: <http://biblioteca.ibge.gov.br/index.php/biblioteca-catalogo?view=detalhes&id=2101636>.
- [22] Governo do Brasil. Lei 13.709, de 14 de agosto de 2018, Lei Geral de Proteção de Dados Pessoais (LGPD). Disponível em: http://www.planalto.gov.br/ccivil_03/_ato2015-2018/2018/Lei/L13709.htm.
- [23] Cynthia Dwork. Differential Privacy. In *Proceedings of the 33rd International Conference on Automata, Languages and Programming - Volume Part II*, ICALP'06, pages 1–12. Springer-Verlag, 2006.
- [24] Cynthia Dwork. A firm foundation for private data analysis. *Communications of the ACM*, 54(1):86–95, 2011.
- [25] Cynthia Dwork, Frank McSherry, Kobbi Nissim, and Adam Smith. Calibrating noise to sensitivity in private data analysis. In *Theory of cryptography conference*, pages 265–284. Springer, 2006.
- [26] Cynthia Dwork, Aaron Roth, et al. The Algorithmic Foundations of Differential Privacy. *Foundations and Trends® in Theoretical Computer Science*, 9(3–4):211–407, 2014.
- [27] Benjamin C. M. Fung, Ke Wang, Ada Wai-Chee Fu, and Philip S. Yu. *Introduction to Privacy-Preserving Data Publishing: Concepts and Techniques*. Chapman & Hall/CRC, 1st edition, 2010.
- [28] Simson Garfinkel, John M Abowd, and Sarah Powazek. Issues Encountered Deploying Differential Privacy. In *Proceedings of the 2018 Workshop on Privacy in the Electronic Society*, WPES'18, pages 133–137. Association for Computing Machinery, 2018.
- [29] Arpita Ghosh, Tim Roughgarden, and Mukund Sundararajan. Universally Utility-maximizing Privacy Mechanisms. *SIAM Journal on Computing*, 2012.
- [30] Pablo Giambiagi, Gerardo Schneider, and Frank D. Valencia. On the Expressiveness of Infinite behavior and Name Scoping in Process Calculi. In *Foundations of Software Science and Computation Structures, 7th International Conference, FOSSACS 2004, Held as Part of the Joint European Conferences on Theory and Practice of Software, ETAPS 2004, Barcelona, Spain, March 29 - April 2, 2004, Proceedings*, volume 2987 of *LNCS*, pages 226–240. Springer, 2004.
- [31] Aris Gkoulalas-Divanis and Grigorios Loukides. *Medical Data Privacy Handbook*. Springer, 1st edition, 2015.

- [32] Mangesh Gupte and Mukund Sundararajan. Universally Optimal Privacy Mechanisms for Minimax Agents. In *Proceedings of the Twenty-Ninth ACM SIGMOD-SIGACT-SIGART Symposium on Principles of Database Systems*, PODS '10, page 135–146. Association for Computing Machinery, 2010.
- [33] Justin Hsu, Marco Gaboardi, Andreas Haeberlen, Sanjeev Khanna, Arjun Narayan, Benjamin C. Pierce, and Aaron Roth. Differential Privacy: An Economic Method for Choosing Epsilon. In *IEEE 27th Computer Security Foundations Symposium*, pages 398–410. IEEE Computer Society, 2014.
- [34] Anco Hundepool, Josep Domingo-Ferrer, Luisa Franconi, Sarah Giessing, Eric Schulte Nordholt, Keith Spicer, and Peter-Paul de Wolf. *Statistical Disclosure Control*. Wiley, 2012.
- [35] James W. Gray III. Toward a Mathematical Foundation for Information Flow Security. In *Proceedings of the 1991 IEEE Symposium on Security and Privacy, Oakland, California, USA, May 20-22, 1991*, pages 21–35, 1991.
- [36] Edwin T. Jaynes. *Probability theory: The logic of science*. Cambridge University Press, Cambridge, 2003.
- [37] Lefki Kacem and Catuscia Palamidessi. Geometric Noise for Locally Private Counting Queries. In *Proceedings of the 13th Workshop on Programming Languages and Analysis for Security*, pages 13–16. ACM, 2018.
- [38] Peter Kairouz, Sewoong Oh, and Pramod Viswanath. Extremal Mechanisms for Local Differential Privacy. *The Journal of Machine Learning Research*, 17(1):492–542, 2016.
- [39] Shiva Prasad Kasiviswanathan, Homin K. Lee, Kobbi Nissim, Sofya Raskhodnikova, and Adam D. Smith. What Can We Learn Privately? In *49th Annual IEEE Symposium on Foundations of Computer Science, FOCS 2008, October 25-28, 2008, Philadelphia, PA, USA*, pages 531–540. IEEE Computer Society, 2008.
- [40] Daniel Kifer and Ashwin Machanavajjhala. No Free Lunch in Data Privacy. In *Proceedings of the 2011 ACM SIGMOD International Conference on Management of Data*, SIGMOD '11, page 193–204. Association for Computing Machinery, 2011.
- [41] Boris Köpf and David A. Basin. An information-theoretic model for adaptive side-channel attacks. In *Proc. of CCS*, pages 286–296. ACM, 2007.
- [42] Sara Krehbiel. Choosing Epsilon for Privacy as a Service. *Proceedings on Privacy Enhancing Technologies*, 2019:192–205, 1 2019.
- [43] Jaewoo Lee and Chris Clifton. How Much Is Enough? Choosing ϵ for Differential Privacy. In *Information Security, 14th International Conference, ISC 2011*, volume 7001 of *Lecture Notes in Computer Science*, pages 325–340. Springer, 2011.

- [44] Ninghui Li, Tiancheng Li, and Suresh Venkatasubramanian. t-Closeness: Privacy Beyond k-Anonymity and l-Diversity. volume 2, pages 106 – 115, 05 2007.
- [45] Gavin Lowe. Quantifying Information Flow. In *Proc. of CSFW 2002*, pages 18–31. IEEE, 2002.
- [46] Ashwin Machanavajjhala, Johannes Gehrke, Daniel Kifer, and Muthuramakrishnan Venkatasubramanian. l-diversity: Privacy beyond k-anonymity. In *22nd International Conference on Data Engineering (ICDE'06)*, pages 24–24. IEEE, 2006.
- [47] Pasquale Malacaria. Assessing security threats of looping constructs. In *Proceedings of the 34th ACM SIGPLAN-SIGACT Symposium on Principles of Programming Languages, POPL 2007, Nice, France, January 17-19, 2007*, pages 225–235. ACM, 2007.
- [48] Annabelle McIver, Carroll Morgan, Geoffrey Smith, Barbara Espinoza, and Larissa Meinicke. Abstract Channels and Their Robust Information-Leakage Ordering. In *Principles of Security and Trust - Third International Conference, POST 2014, Held as Part of the European Joint Conferences on Theory and Practice of Software, ETAPS 2014, Grenoble, France, April 5-13, 2014, Proceedings*, volume 8414 of *LNCS*, pages 83–102. Springer, 2014.
- [49] John McLean. Security Models and Information Flow. In *Proceedings of the 1990 IEEE Symposium on Security and Privacy, Oakland, California, USA, May 7-9, 1990*, pages 180–189. IEEE Computer Society, 1990.
- [50] Jeffrey Mervis. Can a set of equations keep U.S. census data private? *Science Magazine*, 2019. Disponível em: <https://www.sciencemag.org/news/2019/01/can-set-equations-keep-us-census-data-private>.
- [51] Jonathan K. Millen. Covert Channel Capacity. In *Proceedings of the 1987 IEEE Symposium on Security and Privacy, Oakland, California, USA, April 27-29, 1987*, pages 60–66. IEEE Computer Society, 1987.
- [52] Renée Miller. Big Data Curation. In *Proceedings of the 20th International Conference on Management of Data, COMAD '14*, page 4, Mumbai, Maharashtra, India, 2014. Computer Society of India.
- [53] Australian Bureau of Statistics. Census Microdata. Disponível em: <https://www.abs.gov.au/ausstats/abs@.nsf/Lookup/by%20Subject/2011.0.55.001~2016~Main%20Features~Census%20Microdata~13>.
- [54] Government of the United States of America. Statistical Policy Working Paper 22 - Report on Statistical Disclosure Limitation Methodology, 2005. Disponível em: <https://nces.ed.gov/FCSM/pdf/spwp22.pdf>.
- [55] Fabian Prasser and Contributors. ARX - Data Anonymization Tool, 2020. Disponível em: <https://arx.deidentifier.org/>.

- [56] Pierangela Samarati and Latanya Sweeney. Protecting Privacy when Disclosing Information: k-Anonymity and Its Enforcement through Generalization and Suppression. Technical report, SRI International, 1998.
- [57] Geoffrey Smith. On the Foundations of Quantitative Information Flow. In *Proc. of FOSSACS*, volume 5504 of *LNCS*, pages 288–302. Springer, 2009.
- [58] Latanya Sweeney. Simple Demographics Often Identify People Uniquely, 2000. Disponível em: https://kilthub.cmu.edu/articles/Simple_Demographics_Often_Identify_People_Uniquely/6625769/1.
- [59] Stanley L. Warner. Randomized Response: A Survey Technique for Eliminating Evasive Answer Bias. *Journal of the American Statistical Association*, 60(309):63–69, 1965. PMID: 12261830.

Anexos

A Formalização matemática de privacidade diferencial local

No Produto 03 do presente TED 8750 apresentamos uma discussão profunda de métodos de sanitização por privacidade diferencial. Aqui provemos uma revisão da formulação matemática da privacidade diferencial local, os mecanismos para atingi-la, e suas propriedades fundamentais.

A.1 Definição formal de privacidade diferencial- ε local

Um dos pilares da privacidade é o conceito de *negação plausível*, que garante que um indivíduo possa negar de forma crível a um adversário que ele tenha participado em um estudo, ou que um de seus atributos tenha um valor específico. A possibilidade de negação plausível é essencial para convencer indivíduos a participar honestamente –i.e., sem mentir– de pesquisas que envolvam o fornecimento de informação sensível [26].

Em 1965, o pesquisador S. L. Warner propôs a técnica de *resposta aleatorizada* (*randomized response*, no original em inglês), para lidar com o problema [59]. O emprego da técnica é ilustrado no Exemplo 23 do Anexo A.4. A privacidade diferencial local foi formalizada em 2008 por Kasiviswanathan, Lee, Nissim, Raskhodnikova e Smith [39], tendo como espírito filosofia semelhante à da técnica de resposta aleatorizada.

Recorde que denotamos por $\text{registros}(\mathcal{A})$ o domínio de todos os valores que registros de uma base de dados podem assumir em um cenário de interesse. Na privacidade diferencial local consideramos que um mecanismo aleatório é aplicado a cada registro $x \in \text{registros}(\mathcal{A})$, produzindo uma versão sanitizada deste registro. Esta ideia é formalizada abaixo.

Definição 17 (Privacidade diferencial- ε (local)). Seja ε um valor real positivo, e $\mathcal{M}$ um *mecanismo local de aleatorização* (ou um *algoritmo randomizado local*) que recebe como entrada um registro $x \in \text{registros}(\mathcal{A})$ de um indivíduo e produz como saída um valor pertencente a um conjunto $\text{img}(\mathcal{M})$. Considere que haja uma *relação de indistinguibilidade* sobre $\text{registros}(\mathcal{A}) \times \text{registros}(\mathcal{A})$ definindo todos os pares de valores $x, x' \in \text{registros}(\mathcal{A})$ que devem ser considerados indistinguíveis do ponto de vista do adversário. Dizemos que $\mathcal{M}$

satisfaz *privacidade diferencial- ε (local)* se, e somente se, para todo par x, x' registros que devam ser indistinguíveis e para todo $S \subseteq \text{img}(\mathcal{M})$,

$$\Pr[\mathcal{M}(x) \in S] \leq e^\varepsilon \cdot \Pr[\mathcal{M}(x') \in S], \quad (\text{A.1})$$

onde a probabilidade é tomada sobre a aleatoriedade do mecanismo. $\triangleleft$

O Exemplo 24 do Anexo A.5 ilustra as garantias da privacidade diferencial local e seu custo em termos da utilidade dos dados.

A.2 Mecanismos para se atingir privacidade diferencial- ε local

A pesquisadora Cynthia Dwork, uma das inventoras da privacidade diferencial, demonstrou que qualquer tipo de mecanismo de consulta que forneça algum tipo de privacidade não trivial deve necessariamente empregar aleatoriedade de alguma forma [26]. Em particular, é impossível implementar a privacidade diferencial sem utilização de ruído.

Existem vários mecanismos para se aplicar privacidade diferencial local. No geral, a definição de um mecanismos depende do tipo de dados aos quais ele será aplicado –e.g., numéricos contínuos, numéricos discretos, categóricos, etc. A seguir apresentamos os mecanismos de adição de ruído para atingir privacidade diferencial local utilizados no presente documento.

Mecanismo geométrico truncado O mecanismo geométrico truncado é adequado quando o valor a ser sanitizado é um valor inteiro em um subconjunto $\{0, 1, \dots, n\}$ dos números naturais [37].

Definição 18 (Mecanismo geométrico truncado local). Seja $\mathcal{S} = \{0, 1, \dots, n\}$ um subconjunto finito dos números naturais, e $\varepsilon > 0$ um parâmetro de privacidade. Um *mecanismo geométrico truncado* $\mathcal{M}_{GT}$ é um mapeamento probabilístico que, a cada entrada $i \in \mathcal{S}$, associa uma saída $j \in \mathcal{S}$ com a seguinte probabilidade

$$\mathcal{M}_{GT}(i, j) = \begin{cases} 1/(1+\alpha) \cdot \alpha^i, & \text{se } j=0, \\ (1-\alpha)/(1+\alpha) \cdot \alpha^{|i-j|}, & \text{se } 0 < j < n, \\ 1/(1+\alpha) \cdot \alpha^{|i-n|}, & \text{se } j=n, \end{cases}$$

onde $\alpha = e^{-\varepsilon/n}$. ¹ $\triangleleft$

¹Note que aqui estamos considerando que a sensibilidade da consulta é $\Delta f = n$.

Mecanismo de resposta aleatorizada k -RR O mecanismo de resposta aleatorizada k -RR é normalmente utilizado quando o valor a ser sanitizado é categórico (e.g., a enfermidade mais comum em uma população, ou o estado da federação com a maior proporção de alunos no sistema público de ensino) [38].

Definição 19 (Mecanismo de resposta aleatorizada k -RR). Seja $\mathcal{S}$ um conjunto categórico finito e $\varepsilon > 0$ um parâmetro de privacidade. Um *mecanismo de resposta aleatorizada*, também conhecido como k -RR, é um mapeamento probabilístico $\mathcal{M}_{RR}$ que, a cada entrada $i \in \mathcal{S}$, associa uma saída $j \in \mathcal{S}$ com a seguinte probabilidade

$$\mathcal{M}_{RR}(i, j) = \begin{cases} e^\varepsilon / (|\mathcal{S}| - 1 + e^\varepsilon), & \text{se } i=j, \\ 1 / (|\mathcal{S}| - 1 + e^\varepsilon), & \text{se } i \neq j. \end{cases}$$

◁

A.3 Propriedades da privacidade diferencial- ε

A privacidade diferencial satisfaz importantes propriedades de composicionalidade. Mais especificamente, imagine que dois mecanismos $\mathcal{M}_1$ e $\mathcal{M}_2$ satisfaçam privacidade diferencial para valores ε_1 e ε_2 , respectivamente. Se o conjunto das possíveis respostas que $\mathcal{M}_1$ e $\mathcal{M}_2$ podem dar são C_1 e C_2 , respectivamente, então a combinação destes dois mecanismos, i.e., um mecanismo $\mathcal{M}_{1,2}$, retorna um par ordenado $(i, j) \in C_1 \times C_2$ como resposta para a consulta combinada. Ao se combinarem mecanismos desta forma, temos a propriedade de que os diferentes ε_i se somam, ou seja, $\mathcal{M}_{1,2}$ neste caso satisfaz privacidade diferencial- $(\varepsilon_1 + \varepsilon_2)$. Este resultado é formalizado no seguinte teorema.

Teorema 20 (Composicionalidade sequencial de privacidade diferencial [24]). *Seja $\mathcal{M}_1, \dots, \mathcal{M}_n$ um conjunto de n mecanismos, cada $\mathcal{M}_i$ satisfazendo privacidade diferencial para um valor ε_i , e aplicados de forma independente. Então, qualquer função $g(\mathcal{M}_1, \dots, \mathcal{M}_n)$ destes mecanismos satisfaz privacidade diferencial para o valor $\sum_{i=1}^n \varepsilon_i$.*

Uma outra propriedade importante da privacidade diferencial é a seguinte.

Teorema 21 (Composicionalidade paralela de privacidade diferencial [24]). *Seja $\mathcal{M}_1, \dots, \mathcal{M}_n$ um conjunto de n mecanismos, cada $\mathcal{M}_i$ satisfazendo privacidade diferencial para um valor ε_i . Se cada mecanismo é aplicado a um subconjunto disjuncto da base de dados de entrada, então qualquer função $g(\mathcal{M}_1, \dots, \mathcal{M}_n)$ destes mecanismos satisfaz privacidade diferencial para o valor $\max_i \varepsilon_i$.*

Por fim, a privacidade diferencial é resistente a pós-processamento. Isso significa que um adversário que realize computações arbitrárias apenas sobre a saída de um mecanismo que respeita privacidade diferencial- ε não consegue reverter a garantia de privacidade do mecanismo. Esta propriedade é formalizada a seguir.

Teorema 22 (Privacidade diferencial resiste a pós-processamento [23]). *Seja $\mathcal{M}$ um mecanismo satisfazendo privacidade diferencial para um valor ε , e seja F uma função (determinística ou probabilística) definida sobre a imagem de $\mathcal{M}$. Então $F(\mathcal{M})$ também satisfaz privacidade diferencial para o mesmo valor ε .*

A.4 Exemplo de negação plausível em resposta aleatorizada

Aqui ilustramos o emprego da técnica de de *resposta aleatorizada* (*randomized response*, no original em inglês), proposta por S. L. Warner [59]. A técnica utiliza adição de ruído para dar a participantes a possibilidade de negação plausível. A privacidade diferencial local é baseada no mesmo princípio.

Exemplo 23 (Resposta aleatorizada aplicada a uma pesquisa sobre uso de drogas ilícitas). Suponha que pesquisadores desejem estimar a proporção de indivíduos em uma população que fazem uso de drogas ilícitas. Naturalmente há receio por parte das pessoas em participar da pesquisa, uma vez que o provimento de respostas honestas pode produzir consequências sociais e judiciais negativas.

Para contornar o problema, pode-se aplicar o mecanismo de resposta aleatorizada ao estudo da seguinte forma. Ao ser indagado com a pergunta “*Você faz uso de alguma droga ilícita?*”, cada participante da pesquisa é instruído a prover uma resposta “**sim**” ou “**não**” de acordo com o seguinte procedimento.

1. Jogue uma moeda para cima.
2. Se o resultado obtido no lançamento for **cara**, responda honestamente à pergunta.
3. Se o resultado for **coroa**, jogue uma segunda moeda para cima; se o resultado obtido neste segundo lançamento for **cara**, responda “**sim**”, caso contrário, responda “**não**”.

A Tabela A.1 ilustra a aplicação da metodologia sobre uma população de 10 pessoas. Note que o procedimento garante a possibilidade de negação plausível para cada respondente: mesmo que ele tenha respondido “**sim**” à pergunta (como no caso de Ana, Danilo e Hugo), ele pode alegar de forma crível que a resposta seja falsa e se deva tão somente ao resultado aleatório do lançamento das moedas.

Entretanto, mesmo após a adição de ruído às respostas de cada participante, o procedimento ainda permite a estimação da proporção de indivíduos na população que faz uso de drogas. Note que o desenho do experimento leva à expectativa, caso o número de respondentes seja grande o suficiente, de que:

- metade dos indivíduos forneça a resposta honesta para a pergunta (aqueles que obtiverem **cara** no primeiro lançamento da moeda);

Respondente	Faz uso da droga ilícita	Resultado da 1ª moeda	Resultado da 2ª moeda	Resposta fornecida
Ana	sim	cara	-	“sim”
Bruno	não	cara	-	“não”
Clara	não	coroa	coroa	“não”
Danilo	não	coroa	cara	“sim”
Eva	não	cara	-	“não”
Felipe	sim	coroa	coroa	“não”
Gabriela	não	cara	-	“não”
Hugo	não	coroa	cara	“sim”
Iara	não	cara	-	“não”
João	não	cara	-	“não”

Tabela A.1: Exemplo 23: Resultado de uma pesquisa sobre uso de drogas ilícitas usando a técnica de reposta aleatorizada. A proporção real de usuários de drogas na população é de $f = 20\%$, enquanto a proporção de respondentes que afirmam usar drogas na pesquisa é de $s = 30\%$. O tratamento estatístico das respostas da pesquisa estimaria, então, que a proporção de usuários de drogas é $\hat{f} = 2s - 1/2 = 10\%$.

- um quarto dos indivíduos forneça a resposta “sim” independentemente de se ela é ou não acurada (aqueles que obtiverem coroa no primeiro lançamento e cara no segundo); e
- um quarto dos indivíduos forneça a resposta “não” independentemente de se ela é ou não acurada (aqueles que obtiverem coroa em ambos os lançamentos).

Assim, espera-se que forneçam a resposta “sim” à pergunta cerca de $3/4$ dos participantes que fazem uso da droga e cerca de $1/4$ dos participantes que não usam a droga. Portanto, sendo f a fração de pessoas na população que fazem o uso da droga, e s a fração de pessoas que responderam “sim” à pergunta, obtemos a relação

$$s \approx \frac{3}{4}f + \frac{1}{4}(1 - f) ,$$

e a partir dela obtemos uma estimativa $\hat{f}$ da real proporção f como

$$\hat{f} = 2s - \frac{1}{2} . \quad (\text{A.2})$$

Voltando à Tabela A.1, temos que $f = 20\%$ da população amostrada realmente faz uso da droga, enquanto $s = 30\%$ dos respondentes proveram a resposta “sim” à pergunta. Logo, de acordo com a Equação A.2, o resultado desta pesquisa levaria à estimação de que a proporção de usuários de droga na população é de $\hat{f} = 2 \cdot 30\% - 1/2 = 10\%$.

Note que o emprego do mecanismo resposta aleatorizada aumentou a privacidade dos respondentes a um custo na utilidade dos dados: a estimativa dos usuários de drogas se




Figura A.2: Exemplo 23: Procedimento adotado por cada respondente a uma pesquisa a fim de garantir resposta aleatorizada. O valor $b \in [0, 1]$ representa a probabilidade da primeira moeda retornar o valor **coroa**.

desviou do número real por 10%. Entretanto, o exemplo aqui utilizado consiste em uma base muito pequena. No geral, quanto maior a base, maior tende a ser a utilidade dos dados. $\triangleleft$

A.5 Exemplo do compromisso entre privacidade vs. utilidade em privacidade diferencial- ϵ local

O seguinte exemplo ilustra as garantias da privacidade diferencial local e seu custo em termos da utilidade dos dados.

Exemplo 24 (O compromisso entre privacidade vs. utilidade em privacidade diferencial local). Considere novamente o cenário do Exemplo 23, em que pesquisadores desejam estimar a proporção de indivíduos em uma população que fazem uso de drogas ilícitas. A pesquisa usa a metodologia de resposta aleatorizada, em que, ao ser indagado com a pergunta “*Você faz uso de alguma droga ilícita?*”, cada participante é instruído a prover uma resposta “**sim**” ou “**não**” seguindo o procedimento ilustrado na Figura A.2. Mais precisamente, cada respondente joga uma moeda para cima: se o resultado for cara, responde honestamente à pergunta; se for coroa, joga outra moeda e responde “**sim**” ou “**não**” dependendo de se o resultado desta segunda moeda foi cara ou coroa, respectivamente.

Considere que a primeira moeda lançada por cada participante tenha um viés $b \in [0, 1]$ em favor do resultado **coroa**, (i.e., b é a probabilidade da moeda retornar **coroa**, e $1 - b$ é a probabilidade da moeda retornar **cara**), mas que a segunda moeda seja justa (i.e., a probabilidade de **cara** e **coroa** é de 0.5 para cada). A Tabela A.3 provê as probabilidades condicionais de um indivíduo responder afirmativa ou negativamente à pergunta da pesquisa dependendo de se ele é ou não consumidor de drogas.

Seria natural desejar que o mecanismo de resposta aleatorizada provesse máxima privacidade aos respondentes, ao mesmo tempo em que permitisse ao analista de dados obter

$p(\text{resposta} \mid \text{drogas})$	$\text{resposta} = \text{"sim"}$	$\text{resposta} = \text{"não"}$
$\text{drogas} = \text{sim}$	$(1 - b) + 0.5b = 1 - 0.5b$	$0.5b$
$\text{drogas} = \text{não}$	$0.5b$	$(1 - b) + 0.5b = 1 - 0.5b$

Tabela A.3: Exemplo 23: Probabilidade condicional de cada resposta dado se o indivíduo é mesmo usuário de drogas ou não, em função do viés b da primeira moeda.

a proporção correta de usuários de drogas na população. Entretanto, tal cenário ideal não é atingível, como explicamos abaixo.

Chamemos de drogas e resposta as variáveis aleatórias, ambas com domínio $\{\text{sim}, \text{não}\}$, que indicam, respectivamente, se um indivíduo é usuário de drogas e se ele respondeu à pergunta da pesquisa afirmativamente. Intuitivamente, neste mecanismo:

- (i) A privacidade para cada respondente está ligada à sua capacidade de poder recorrer à negação plausível, mesmo que sua resposta para a pergunta seja afirmativa. Em outras palavras, o nível de credibilidade da negação do titular é dado pela probabilidade de ele realmente não usar drogas mesmo que ele tenha respondido “sim” à pergunta, que é dada por $p(\text{drogas} = \text{não} \mid \text{resposta} = \text{"sim"})$.
- (ii) A utilidade para o analista de dados é tão maior quanto mais próximas forem a proporção de respostas afirmativas obtidas na pesquisa, dada por $p(\text{resposta} = \text{"sim"})$, e a proporção de indivíduos que realmente usam drogas na população, dada por $p(\text{drogas} = \text{sim})$.

Note que o viés b da primeira moeda funciona como um parâmetro que controla o compromisso entre privacidade e utilidade. Quanto maior o valor de b , mais privado é o mecanismo (pois mais provável é que a resposta de cada indivíduo seja aleatória, o que aumenta a plausibilidade de sua negação), porém menos útil é o resultado da pesquisa para o analista de dados (pois a proporção de respostas afirmativas na pesquisa se afasta da proporção real de usuário de drogas na população de interesse, que, de acordo com a Tabela A.1, é de $p(\text{drogas} = \text{sim}) = 0.20$). A Figura A.4a ilustra a relação do valor de b com a utilidade e a privacidade do mecanismo resultante.²

²Para o leitor interessado, aqui apresentamos os cálculos que levaram aos gráficos da Figura A.4. Primeiro note que a probabilidade de se obter uma resposta afirmativa nesta população é dada por

$$\begin{aligned}
 p(\text{resposta} = \text{"sim"}) &= p(\text{drogas} = \text{sim}) \cdot p(\text{resposta} = \text{"sim"} \mid \text{drogas} = \text{sim}) + \\
 &\quad p(\text{drogas} = \text{não}) \cdot p(\text{resposta} = \text{"sim"} \mid \text{drogas} = \text{não}) \quad (\text{marginalização}) \\
 &= p(\text{drogas} = \text{sim}) \cdot (1 - 0.5b) + (1 - p(\text{drogas} = \text{sim})) \cdot 0.5b \quad (\text{Tabela A.3}) \\
 &= (1 - b) \cdot p(\text{drogas} = \text{sim}) + 0.5b, \quad (\text{A.3})
 \end{aligned}$$

enquanto a probabilidade de um indivíduo não usar drogas mesmo tendo respondido afirmativamente à

Por fim, note que, através da análise da Tabela A.3, percebemos que para cada valor do viés b da primeira moeda o mecanismo resultante atinge um valor de ε diferente para a privacidade diferencial, dado por ³

$$\varepsilon(b) = \ln \frac{1 - 0.5b}{0.5b}.$$

Esta relação é ilustrada na Figura A.4b: quanto maior o valor de b , mais a resposta de cada indivíduo é puramente aleatória, e mais privado é o mecanismo resultante (i.e., menor é o valor de ε).

Por fim, a Figura A.4c apresenta a relação entre o valor do parâmetro ε , utilidade e privacidade. $\triangleleft$

pergunta da pesquisa é dada por


$$\begin{aligned} p(\text{drogas} = \text{n\~ao} \mid \text{resposta} = \text{"sim"}) &= && \text{(pelo Teorema de Bayes)} \\ \frac{p(\text{drogas} = \text{n\~ao}) \cdot p(\text{resposta} = \text{"sim"} \mid \text{drogas} = \text{n\~ao})}{p(\text{resposta} = \text{"sim"})} &= && \text{(Tabela A.3 e Eq. A.3)} \\ \frac{0.5b \cdot (1 - p(\text{drogas} = \text{sim}))}{(1 - b) \cdot p(\text{drogas} = \text{sim}) + 0.5b} &= && \text{(A.4)} \end{aligned}$$

Levando em conta que de acordo com a Tabela A.1, 20% da população realmente usa drogas, temos que $p(\text{drogas} = \text{sim}) = 0.20$. Substituindo este valor nas Equações A.3 e A.4 obtemos, respectivamente, que a equação relaciona a proporção de respostas afirmativas ao viés b da primeira moeda é $p(\text{resposta} = \text{"sim"}) = 0.2 + 0.3b$, enquanto a equação que relaciona a negação plausível ao viés b é $p(\text{drogas} = \text{n\~ao} \mid \text{resposta} = \text{"sim"}) = 0.40b/(0.2+0.3b)$.


³Isto porque o mecanismo de resposta aleatorizada utilizado neste exemplo está inteiramente representado na Tabela A.3. Chamando este mecanismo de $\mathcal{M}$, a privacidade diferencial- ε local (Definição 17) exige que para todo valor possível do registro real do titular (**sim** ou **n\~ao**) e para toda resposta possível (**"sim"** ou **"n\~ao"**) do mecanismo $\mathcal{M}$, tenhamos $Pr[\mathcal{M}(x) \in S] \leq e^\varepsilon \cdot Pr[\mathcal{M}(x') \in S]$. Pode-se verificar, então, que $\mathcal{M}$ satisfaz privacidade diferencial- ε para um valor ε qualquer se, e somente se,

$$e^{-\varepsilon} \leq \frac{Pr[\text{resposta} = \text{"sim"} \mid \text{drogas} = \text{sim}]}{Pr[\text{resposta} = \text{"sim"} \mid \text{drogas} = \text{n\~ao}]} \leq e^\varepsilon \quad \text{e} \quad e^{-\varepsilon} \leq \frac{Pr[\text{resposta} = \text{"n\~ao"} \mid \text{drogas} = \text{sim}]}{Pr[\text{resposta} = \text{"n\~ao"} \mid \text{drogas} = \text{n\~ao}]} \leq e^\varepsilon,$$


o que implica que o menor valor de ε possível é justamente $\varepsilon(b) = \ln(1-0.5b)/0.5b$.



(a) Relação do viés b da primeira moeda com os níveis de utilidade e de negação plausível do mecanismo resultante. Quanto maior o valor de b , mais a negação de um titular de que ele usa drogas é plausível (i.e., maior o valor de $p(\text{drogas} = \text{não} \mid \text{resposta} = \text{"sim"})$), porém mais distante se torna a proporção esperada de respostas afirmativas na pesquisa (i.e., $p(\text{resposta} = \text{"sim"})$) em relação à proporção real de usuários de droga na população (i.e., $p(\text{drogas} = \text{sim})$).



(b) Relação entre o viés b da segunda moeda e o nível ε de privacidade diferencial atingido ($\varepsilon = \ln(1-0.5b)/0.5b$). Quanto maior o viés da moeda, mais a resposta de cada indivíduo é puramente aleatória, e mais mais privado é o mecanismo resultante (i.e., menor é o valor de ε).



(c) Relação do parâmetro ε da privacidade diferencial com os níveis de utilidade e de negação plausível do mecanismo resultante. Quanto maior o valor de ε , menos privado é o mecanismo (i.e., menor é a credibilidade $p(\text{drogas} = \text{não} \mid \text{resposta} = \text{"sim"})$ da negação plausível), mas maior é sua utilidade (i.e., mais $p(\text{resposta} = \text{"sim"})$ se aproxima de $p(\text{drogas} = \text{sim})$).

Figura A.4: Exemplo 24: Compromisso entre utilidade e privacidade num mecanismo de privacidade diferencial local baseado em resposta aleatorizada. Recorde que quanto menor o valor do parâmetro ε , mais privado é o mecanismo resultante.

B Formalização de ataque de reidentificação coletiva sobre uma única base de dados sanitizada por desidentificação e pseudonimização (RCU)

Nesta seção formalizamos matematicamente o ataque de reidentificação coletiva sobre uma única base de dados sanitizada por desidentificação e pseudonimização (RCU) provida no Produto 02 do presente TED 8750 e revisada neste documento na Seção 4.1.1.

Definição 25 (Ataque de reidentificação coletiva em uma única base de dados sanitizada por desidentificação e pseudonimização (RCU)). Em um *ataque de reidentificação coletiva em uma única base de dados sanitizada por desidentificação e pseudonimização (RCU)*, o adversário tem acesso completo a uma única base de dados –conhecendo todos os seus registros– e é capaz de obter como informação auxiliar os valores de um conjunto de quaseidentificadores para todos os indivíduos cujos registros estão na base. O adversário tem como objetivo reidentificar o maior número possível de indivíduos, independentemente de quem sejam. A especificação deste ataque é como a seguir.

- **Conhecimento do adversário em um ataque RCU.** Em um ataque RCU, assume-se que o adversário:
 - (i) tem completo acesso a uma base de dados D (não vazia) sobre um conjunto de atributos $\mathcal{A}$;
 - (ii) tem como alvo da tentativa de reidentificação todo indivíduo x presente na base de dados D , independente de quem x seja; e
 - (iii) dado um conjunto $\mathcal{Q}_{ID} \subseteq \mathcal{A}$ de quaseidentificadores, é capaz de obter como informação auxiliar os sub-registros $\{x[\mathcal{Q}_{ID}]\}_{x \in D}$ correspondentes aos valores dos quaseidentificadores de todos os indivíduos presentes na base.

- **Quantificação da degradação determinística de privacidade em um ataque RCU.** A medição do sucesso determinístico de um ataque coletivo RCU leva em conta que adversário tem como alvo todos os indivíduos da base; portanto, define-se tal sucesso como a fração de indivíduos na base que pode ser reidentificada com absoluta certeza.
 - **Quantificação do sucesso determinístico a priori do adversário em um ataque RCU.** Antes de efetuar o ataque RCU, o adversário não pode utilizar os valores dos quaseidentificadores dos indivíduos como informação auxiliar em sua tentativa de reidentificá-los. Logo, o adversário atinge absoluta certeza sobre qual registro na base de dados corresponde a um indivíduo qualquer se, e somente se, a base contém apenas um registro. Dessa forma, a fração de indivíduos na base que pode ser reidentificada com absoluta certeza antes da realização do ataque ou é 1, caso a base contenha apenas um registro, ou é 0, caso a base possua dois ou mais registros. Assim, o sucesso determinístico a priori do adversário em um ataque RCU sobre uma base D é definido como

$$suc\text{-}prior_{det}^{RCU}(D) \stackrel{\text{def}}{=} \begin{cases} 1, & \text{se } |D|=1, \\ 0, & \text{se } |D|\geq 2. \end{cases} \quad (\text{B.1})$$

- **Quantificação do sucesso determinístico a posteriori do adversário em um ataque RCU.** Durante a execução do ataque RCU, o adversário dispõe como informação auxiliar do conhecimento dos valores $\{x[\mathcal{Q}_{ID}]\}_{x \in D}$ dos quaseidentificadores de todos os indivíduos na base para tentar reidentificá-los. O adversário age, então, em turnos. Em cada turno ele fixa um indivíduo distinto na base como alvo e seleciona o subconjunto de todos os registros da base cujos valores de quaseidentificadores são idênticos aos valores dos quaseidentificadores do indivíduo ora fixado. É fácil perceber que o adversário atinge absoluta certeza na reidentificação do indivíduo-alvo de cada turno se, e somente se, o subconjunto de registros selecionados no turno contém exatamente um elemento (ou seja, o próprio indivíduo-alvo). O sucesso determinístico global tomado sobre o conjunto de todos os turnos é definido, então, como a razão entre o número de indivíduos que podem ser reidentificados com absoluta certeza em seu turno e o número total de indivíduos na base.

Para formalizar esta métrica, observamos o seguinte. Conhecendo os valores $\{x[\mathcal{Q}_{ID}]\}_{x \in D}$ dos quaseidentificadores de todos os indivíduos em D , o adversário pode derivar a partição $D/\sim_{\mathcal{Q}_{ID}}$ induzida na base de dados por esses quaseidentificadores. Assim, cada bloco da partição contém o conjunto de todos os indivíduos que compartilham entre si os mesmos valores para todos os quaseidentificadores. Claramente, são reidentificáveis com absoluta certeza apenas os indivíduos que estão sozinhos em seu bloco na partição. Logo, a quantidade de indivíduos unicamente reidentificáveis na base a partir de seus quaseidentificadores é justamente o número $\left| \{ \alpha \in D/\sim_{\mathcal{Q}_{ID}} \mid |\alpha|=1 \} \right|$ de blocos

$\alpha \in D / \sim_{\mathcal{Q}_{ID}}$ da partição que contêm exatamente um indivíduo. Naturalmente, a fração de indivíduos reidentificáveis após a execução do ataque é obtida dividindo-se esse número pelo número total $|D|$ de indivíduos na base. Assim, o sucesso determinístico a posteriori do adversário em um ataque RCU sobre uma base D , dado seu conhecimento sobre os valores $\{x[\mathcal{Q}_{ID}]\}_{x \in D}$ dos quaseidentificadores de todos os indivíduos na base, é definido como

$$suc-post_{det}^{RCU}(D, \{x[\mathcal{Q}_{ID}]\}_{x \in D}) \stackrel{\text{def}}{=} \frac{|\{\alpha \in D / \sim_{\mathcal{Q}_{ID}} \mid |\alpha|=1\}|}{|D|} . \quad (\text{B.2})$$

- **Quantificação da degradação determinística de privacidade em um ataque RCU.** A degradação determinística de privacidade em um ataque RCU é definida como a diferença pela qual a realização do ataque aumenta o sucesso determinístico do adversário. Formalmente,

$$degrad-priv_{det}^{RCU}(D, \{x[\mathcal{Q}_{ID}]\}_{x \in D}) \stackrel{\text{def}}{=} suc-post_{det}^{RCU}(D, \{x[\mathcal{Q}_{ID}]\}_{x \in D}) - suc-prior_{det}^{RCU}(D) . \quad (\text{B.3})$$

- **Quantificação da degradação probabilística de privacidade em um ataque RCU.** Na medição do sucesso probabilístico de um ataque coletivo RCU, não se exige que o adversário realize a reidentificação de todos os indivíduos com absoluta certeza; em vez disso quantifica-se a probabilidade de um indivíduo aleatoriamente escolhido como alvo ser reidentificado com sucesso. Quanto maior essa probabilidade, mais exitoso é o adversário, e maior é o risco esperado de cada indivíduo presente na base ser reidentificado.

- **Quantificação do sucesso probabilístico a priori do adversário em um ataque RCU.** Antes de efetuar o ataque RCU, o adversário não pode utilizar na tentativa de reidentificação os valores dos quaseidentificadores de nenhum indivíduo. Portanto, dado um indivíduo aleatoriamente selecionado como alvo pelo adversário, o melhor que o último pode fazer é “adivinhar no escuro” qual registro, dentre todos os presentes na base de dados, corresponderia a esse indivíduo-alvo. Uma vez que a cada indivíduo de interesse corresponde no máximo um registro na base, a probabilidade de o adversário adivinhar o registro que realmente corresponde àquele do indivíduo selecionado é justamente o inverso do tamanho da base. Assim, o sucesso probabilístico a priori do adversário em um ataque RCU sobre uma base D é definido como

$$suc-prior_{prob}^{RCU}(D) \stackrel{\text{def}}{=} \frac{1}{|D|} . \quad (\text{B.4})$$

- **Quantificação do sucesso probabilístico a posteriori do adversário em um ataque RCU.** Durante a execução do ataque RCU, o adversário dispõe do conhecimento dos valores $\{x[\mathcal{Q}_{ID}]\}_{x \in D}$ dos quaseidentificadores de todos os

indivíduos na base como informação auxiliar na tentativa de reidentificação. Dado um indivíduo aleatoriamente fixado como alvo, o adversário seleciona o subconjunto de todos os registros da base cujos valores de quaseidentificadores são idênticos aos valores dos quaseidentificadores do indivíduo fixado. A partir daí, o melhor que o adversário pode fazer é “adivinhar no escuro” qual registro do subconjunto de registros selecionados corresponde ao indivíduo-alvo. Uma vez que a cada indivíduo de interesse corresponde no máximo um registro na base, a probabilidade de o adversário adivinhar o registro que realmente corresponde àquele do indivíduo-alvo dentro do subconjunto selecionado é justamente o inverso do tamanho desse subconjunto. O sucesso probabilístico global após o ataque é definido, então, como a esperança da probabilidade de sucesso tomada sobre a distribuição de probabilidade de que cada indivíduo da base tenha sido selecionado como alvo. Assim, o sucesso probabilístico a posteriori do adversário em um ataque RCU sobre uma base D , dado seu conhecimento sobre os valores $\{x[\mathcal{Q}_{ID}]\}_{x \in D}$ dos quaseidentificadores de todos os indivíduos na base, é definido como

$$\begin{aligned} \text{suc-post}_{prob}^{RCU}(D, \{x[\mathcal{Q}_{ID}]\}_{x \in D}) &\stackrel{\text{def}}{=} \sum_{x \in D} \pi_x^D \cdot \frac{1}{|\{x' \in D \mid x'[\mathcal{Q}_{ID}] = x[\mathcal{Q}_{ID}]\}|} \\ &= \frac{|D / \sim_{\mathcal{Q}_{ID}}|}{|D|}. \end{aligned} \quad (\text{B.5})$$

- **Quantificação da degradação probabilística de privacidade em um ataque RCU.** A degradação probabilística de privacidade em um ataque RCU é definida como a razão pela qual a realização do ataque aumenta o sucesso probabilístico do adversário. Formalmente,

$$\text{degrad-priv}_{prob}^{RCU}(D, \{x[\mathcal{Q}_{ID}]\}_{x \in D}) \stackrel{\text{def}}{=} \frac{\text{suc-post}_{prob}^{RCU}(D, \{x[\mathcal{Q}_{ID}]\}_{x \in D})}{\text{suc-prior}_{prob}^{RCU}(D)}. \quad (\text{B.6})$$

◁

C Formalização de ataque de reidentificação coletiva sobre uma única base de dados sanitizada por amostragem (RCU^{ams})

Nesta seção formalizamos matematicamente o ataque de reidentificação coletiva sobre uma única base de dados sanitizada por amostragem (RCU^{ams}) introduzido na Seção 5.3.1.

Definição 26 (Ataque de reidentificação coletiva em uma única base de dados sanitizada por amostragem (RCU^{ams})). Em um *ataque de reidentificação coletiva em uma única base de dados sanitizada por amostragem* (RCU^{ams}), o adversário tem acesso completo a uma única base de dados amostral –conhecendo todos os seus registros– obtida a partir de uma base original através de um plano amostral público. O adversário tem como informação auxiliar a priori –i.e., antes do ataque– um arquivo de nomes contendo, para cada indivíduo da base original, sua identificação única (e.g., nome completo ou RG). Um indivíduo presente na base amostral é reidentificado quando o adversário encontra a correspondência correta entre o registro de tal indivíduo na base amostral e um nome correspondente no arquivo de nomes. Durante o ataque, o adversário é capaz de obter como informação lateral um arquivo auxiliar que expande o arquivo de nomes com os valores de um conjunto de quaseidentificadores para todos os indivíduos no arquivo. O adversário cruza, então, o arquivo auxiliar com a base amostral na tentativa de reidentificar o maior número possível de indivíduos, independentemente de quem sejam. A especificação deste ataque é como a seguir.

- **Conhecimento do adversário em um ataque RCU^{ams} .** Em um ataque RCU^{ams} , assume-se que o adversário:
 - (i) sabe que existe uma base de dados original D definida sobre um conjunto de atributos $\mathcal{A}$, à qual ele não possui acesso direto;
 - (ii) tem completo acesso a uma base de dados sanitizada D' obtida a partir da base original D através de um plano amostral público e conhecido pelo adversário,

conforme o método descrito na Seção 5.2 (em particular, cada registro de D selecionado pelo plano amostral tem seu atributo de identificação única (e.g., *nome*) removido antes de ser adicionado à base sanitizada D');

- (iii) possui como informação auxiliar a priori um arquivo de nomes $Nomes_D$ contendo os nomes (ou qualquer outro identificador único, como RG ou CPF) de todos os indivíduos presentes na base original D ;
- (iv) tem como alvo da tentativa de reidentificação todo registro x presente na base sanitizada D' , independente de qual seja o registro x seja, e seu objetivo é encontrar a correspondência correta entre registros de D' e os indivíduos do arquivo de nomes $Nomes_D$;
- (v) durante a execução do ataque é capaz de obter um arquivo auxiliar Aux_D que expande o arquivo de nomes $Nomes_D$ com os sub-registros $\{x[\mathcal{Q}_{ID}]\}_{x \in D}$ correspondentes aos valores do conjunto $\mathcal{Q}_{ID} \subseteq \mathcal{A}$ de quaseidentificadores para todos os indivíduos presentes na base sanitizada D ; e
- (vi) sabe que cada indivíduo de interesse possui no máximo um registro na base de dados original D –e, consequentemente, também tanto na base sanitizada D' quanto no arquivo de nomes $Nomes_D$ e no arquivo auxiliar Aux_D .

- **Quantificação da degradação determinística de privacidade em um ataque RCU^{ams}.** A medição do sucesso determinístico de um ataque coletivo RCU^{ams} leva em conta que adversário tem como alvo todos os registros presentes na base sanitizada D' , independente de quem eles sejam. Portanto, define-se tal sucesso como a razão entre o número de registros da base sanitizada que podem ser reidentificados com absoluta certeza e o número de indivíduos total da população de interesse presente na base amostral, levando em conta o acesso ao arquivo de informação auxiliar.

– **Quantificação do sucesso determinístico a priori do adversário em um ataque RCU^{ams}.**

Antes de realizar o ataque RCU^{ams}, o adversário pode escolher qualquer registro na base sanitizada D' como alvo de reidentificação. Neste momento, a única informação disponível para o adversário é a lista $Nomes_D$ com os nomes de todos os indivíduos presentes na base original D . Apenas com essas informações, qualquer registro de D' pode em princípio corresponder a qualquer indivíduo em $Nomes_D$, e o adversário não pode reidentificar com absoluta certeza nenhum registro de D' , a não ser no caso extremos em que D tenha apenas um indivíduo. Dessa forma, a fração de indivíduos na base original que pode ser reidentificada com absoluta certeza antes da realização do ataque ou é 1, caso a base original contenha apenas um registro, ou é 0, caso tal base possua dois ou mais registros. Assim, o sucesso determinístico a priori do adversário em um ataque RCU^{ams} sobre uma base sanitizada D' , dado seu

acesso ao arquivo de nomes $Nomes_D$, é definido como

$$suc\text{-}prior_{det}^{RCU^{ams}}(D', Nomes_D) \stackrel{\text{def}}{=} \begin{cases} 1, & \text{se } |Nomes_D|=|D'|=1, \\ 0, & \text{se } |Nomes_D|=|D'| \geq 2. \end{cases} \quad (C.1)$$

- **Quantificação do sucesso determinístico a posteriori do adversário em um ataque RCU^{ams} .** Durante a execução do ataque RCU^{ams} , o adversário obtém como informação lateral o arquivo auxiliar Aux_D contendo os nomes e os valores $\{x[\mathcal{Q}_{ID}]\}_{x \in D}$ de um conjunto $\mathcal{Q}_{ID}$ de quaseidentificadores para todos os indivíduos na base original D . O adversário cruza, então, o arquivo auxiliar de quaseidentificadores com a base sanitizada na tentativa de reidentificação, agindo em turnos. Em cada turno ele fixa um registro distinto na base sanitizada como alvo. A partir daí o adversário seleciona o subconjunto de todos os registros da base sanitizada D' cujos valores de quaseidentificadores são idênticos aos valores dos quaseidentificadores do registro ora fixado. Em seguida, o adversário seleciona o subconjunto de todos os registros do arquivo auxiliar Aux_D cujos valores de quaseidentificadores são idênticos aos valores dos quaseidentificadores do registro ora fixado. É fácil perceber que o adversário atinge absoluta certeza na reidentificação do registro-alvo de cada turno se, e somente se, ambos os subconjuntos de registros selecionados nos dois passos acima (i.e., tanto na base sanitizada quanto no arquivo auxiliar de quaseidentificadores) possuem apenas um elemento –ou seja, o próprio indivíduo-alvo. O sucesso determinístico global tomado sobre o conjunto de todos os turnos é definido, então, como a razão entre o número de registros da base sanitizada que podem ser reidentificados com absoluta certeza em seu turno e o número total de indivíduos na base original.

Para formalizar esta métrica, observamos o seguinte. Conhecendo os valores $\{x[\mathcal{Q}_{ID}]\}_{x \in D'}$ dos quaseidentificadores de todos os indivíduos na base sanitizada D' , o adversário pode derivar a partição $D'/\sim_{\mathcal{Q}_{ID}}$ induzida nesta base por esses quaseidentificadores. Assim, cada bloco da partição contém o conjunto de todos os indivíduos que compartilham entre si os mesmos valores para todos os quaseidentificadores na base sanitizada. De forma similar, o adversário pode também derivar a partição $Aux_D/\sim_{\mathcal{Q}_{ID}}$ induzida no arquivo auxiliar Aux_D induzida por esses mesmos quaseidentificadores. Claramente, são reidentificáveis com absoluta certeza apenas os indivíduos que estão sozinhos em seu respectivo bloco em cada uma das duas partições. Logo, a quantidade de indivíduos unicamente reidentificáveis na base amostral a partir de seus quaseidentificadores é $\left| \{x \in D' \mid |\text{bloco}_{D'/\sim_{\mathcal{Q}_{ID}}}(x[\mathcal{Q}_{ID}])| = |\text{bloco}_{Aux_D/\sim_{\mathcal{Q}_{ID}}}(x[\mathcal{Q}_{ID}])| = 1\} \right|$. Naturalmente, a fração de registros reidentificáveis após a execução do ataque é obtida dividindo-se esse número pelo número total $|D'|$ de registros na base sanitizada. Assim, o sucesso determinístico a posteriori do adversário em um ataque RCU^{ams} sobre uma base D , dado seu acesso ao arquivo auxiliar Aux_D com os valores $\{x[\mathcal{Q}_{ID}]\}_{x \in D}$ dos quaseidentificadores de todos os indivíduos

na base sanitizada, é definido como ¹

$$suc-post_{det}^{RCU^{ams}}(D', Aux_D) \stackrel{\text{def}}{=} \frac{\left| \{x \in D' \mid |bloco_{D'/\sim_{Q_{ID}}}(x[Q_{ID}])| = |bloco_{Aux_D/\sim_{Q_{ID}}}(x[Q_{ID}])| = 1\} \right|}{|D'|} . \quad (C.2)$$

- **Quantificação da degradação determinística de privacidade em um ataque RCU^{ams}.** A degradação determinística de privacidade em um ataque RCU^{ams} é definida como a diferença pela qual a realização do ataque aumenta o sucesso determinístico do adversário. Formalmente,

$$\begin{aligned} degrad-priv_{det}^{RCU^{ams}}(D', Nomes_D, Aux_D) &\stackrel{\text{def}}{=} \\ suc-post_{det}^{RCU^{ams}}(D', Aux_D) - suc-prior_{det}^{RCU^{ams}}(D', Nomes_D) . \end{aligned} \quad (C.3)$$

- **Quantificação da degradação probabilística de privacidade em um ataque RCU^{ams}.** Na medição do sucesso probabilístico de um ataque coletivo RCU^{ams}, não se exige que o adversário realize a reidentificação de todos os indivíduos com absoluta certeza; em vez disso quantifica-se a probabilidade de um indivíduo aleatoriamente escolhido como alvo na base sanitizada ser reidentificado com sucesso através de cruzamento com o arquivo auxiliar de quaseidentificadores. Quanto maior essa probabilidade, mais exitoso é o adversário, e maior é o risco esperado de cada indivíduo ser reidentificado.

- **Quantificação do sucesso probabilístico a priori do adversário em um ataque RCU^{ams}.** Antes de efetuar o ataque RCU^{ams}, o adversário pode escolher qualquer registro na base sanitizada D' como alvo. Neste momento, a única informação disponível para o adversário é a lista $Nomes_D$ com os nomes de todos os indivíduos presentes na base original D . Neste caso, o melhor que o adversário pode fazer para reidentificar um registro aleatoriamente selecionado na base sanitizada sanitizada D' é “adivinhar no escuro” qual indivíduo, dentre todos os presentes no arquivo $Nomes_D$, corresponderia ao registro-alvo. Uma vez que a cada indivíduo de interesse corresponde no máximo um registro tanto na base sanitizada quanto no arquivo de nomes, a probabilidade de o adversário adivinhar o registro no arquivo auxiliar de quaseidentificadores que realmente corresponde àquele do indivíduo selecionado na base sanitizada é justamente o inverso do tamanho do arquivo de nomes. Assim, o sucesso probabilístico a priori do adversário em um ataque RCU^{ams} sobre uma base sanitizada D' , dado conhecimento do arquivo de nomes $Nomes_D$, é definido como

$$suc-prior_{prob}^{RCU^{ams}}(D', Nomes_D) \stackrel{\text{def}}{=} \frac{1}{|Nomes_D|} . \quad (C.4)$$

¹Esta medida é similar à medida τ definida na pág. 41 em [34], com a diferença em que lá usa-se como denominador o número total $|Nomes_D| = |D|$ de indivíduos na base original, em vez do número $|D'|$ de registros na base amostral.

- **Quantificação do sucesso probabilístico a posteriori do adversário em um ataque RCU^{ams} .** Durante a execução do ataque RCU^{ams} , o adversário obtém acesso ao arquivo auxiliar Aux_D que estende o arquivo de nomes $Nomes_D$ com os valores $\{x[\mathcal{Q}_{ID}]\}_{x \in D}$ dos quaseidentificadores de todos os indivíduos na base original D . O adversário utiliza, então, este arquivo como informação auxiliar na tentativa de reidentificação da seguinte forma. Dado um indivíduo aleatoriamente fixado como alvo na base sanitizada, o adversário seleciona o subconjunto de todos os registros no arquivo auxiliar cujos valores de quaseidentificadores são idênticos aos valores dos quaseidentificadores do indivíduo fixado. A partir daí, o melhor que o adversário pode fazer é “adivinhar no escuro” qual registro do subconjunto de registros selecionados no arquivo auxiliar corresponde ao indivíduo-alvo. Uma vez que a cada indivíduo de interesse corresponde no máximo um registro no arquivo auxiliar de quaseidentificadores, a probabilidade de o adversário adivinhar o registro que realmente corresponde àquele do indivíduo-alvo dentro do subconjunto selecionado é justamente o inverso do tamanho desse subconjunto. O sucesso probabilístico global após o ataque é definido, então, como a esperança da probabilidade de sucesso tomada sobre a distribuição de probabilidade de que cada indivíduo da base sanitizada tenha sido selecionado como alvo –a qual assumimos ser uniforme, i.e., $\pi_x^{D'} = 1/|D'|$. Assim, o sucesso probabilístico a posteriori do adversário em um ataque RCU^{ams} sobre uma base sanitizada D' , dado seu acesso ao arquivo auxiliar Aux_D com os valores $\{x[\mathcal{Q}_{ID}]\}_{x \in D'}$ dos quaseidentificadores de todos os indivíduos na base sanitizada, é definido como

$$\begin{aligned} \text{suc-post}_{prob}^{\text{RCU}^{ams}}(D', Aux_D) &\stackrel{\text{def}}{=} \\ \sum_{x \in D'} \pi_x^{D'} \cdot \frac{1}{|\{x' \in Aux_D \mid x'[\mathcal{Q}_{ID}] = x[\mathcal{Q}_{ID}]\}|} &= \\ \frac{1}{|D'|} \sum_{x \in D} \frac{1}{|\{x' \in Aux_D \mid x'[\mathcal{Q}_{ID}] = x[\mathcal{Q}_{ID}]\}|} &. \end{aligned} \quad (\text{C.5})$$

- **Quantificação da degradação probabilística de privacidade em um ataque RCU^{ams} .** A degradação probabilística de privacidade em um ataque RCU^{ams} é definida como a razão pela qual a realização do ataque aumenta o sucesso probabilístico do adversário. Formalmente,

$$\begin{aligned} \text{degrad-priv}_{prob}^{\text{RCU}^{ams}}(D', Nomes_D, Aux_D) &\stackrel{\text{def}}{=} \\ \frac{\text{suc-post}_{prob}^{\text{RCU}^{ams}}(D', Aux_D)}{\text{suc-prior}_{prob}^{\text{RCU}^{ams}}(D', Nomes_D)} &. \end{aligned} \quad (\text{C.6})$$

◁

D Formalização de ataque de reidentificação coletiva sobre uma única base de dados sanitizada por privacidade diferencial local ($\widehat{RCU}^{ldp}$)

Nesta seção formalizamos matematicamente o ataque de reidentificação coletiva sobre uma única base de dados sanitizada por privacidade diferencial local ($\widehat{RCU}^{ldp}$) introduzido na Seção 6.3.1.

Definição 27 (Ataque de reidentificação coletiva em uma única base de dados sanitizada por privacidade diferencial local ($\widehat{RCU}^{ldp}$)). Em um *ataque de reidentificação coletiva em uma única base de dados sanitizada por privacidade diferencial local* ($\widehat{RCU}^{ldp}$), o adversário tem acesso completo a uma única base de dados sanitizada por privacidade diferencial local –conhecendo todos os seus registros– obtida a partir de uma base original através de um processo de sanitização público. O adversário tem como informação auxiliar a priori –i.e., antes do ataque– um arquivo de nomes contendo, para cada indivíduo da base original, sua identificação única (e.g., nome completo, CPF, RG ou qualquer outro identificador individual inequívoco). Um registro selecionado na base sanitizada como alvo de um ataque é considerado reidentificado com sucesso quando o adversário determina corretamente a correspondência entre tal registro e o nome de seu titular no arquivo de nomes. Durante o ataque, o adversário é capaz de obter como informação auxiliar um arquivo auxiliar de quaseidentificadores que expande o arquivo de nomes com os valores de um conjunto de atributos quaseidentificadores para todos os indivíduos no arquivo. O adversário cruza, então, o arquivo auxiliar de quaseidentificadores com a base sanitizada na tentativa de reidentificar o maior número possível de indivíduos, independentemente de quem sejam. Entretanto, a fim de realizar um ataque viável com um volume não proibitivo de recursos computacionais e de tempo, o adversário emprega heurísticas podem levar a um sucesso probabilístico a posteriori, e uma consequente degradação de privacidade, possivelmente sub-ótimos.

A especificação deste ataque é como a seguir.

- **Conhecimento do adversário em um ataque $\widehat{RCU}^{ldp}$.** Em um ataque $\widehat{RCU}^{ldp}$, assume-se que o adversário:

- (i) sabe que existe uma base de dados original D definida sobre um conjunto de atributos $\mathcal{A}$, à qual ele não possui acesso direto;
- (ii) tem completo acesso a uma base de dados sanitizada $D' \subseteq D$ gerada a partir da base original D através da aplicação de privacidade diferencial local em que cada registro de D é aleatorizado para produzir um novo registro em D' , conforme o método descrito na Seção 6.4, e conhece o mecanismo utilizado para produção da base sanitizada D' ;
- (iii) possui como informação auxiliar a priori um arquivo de nomes $Nomes_D$ contendo os nomes (ou qualquer outro identificador individual único) de todos os indivíduos presentes na base original D ;
- (iv) tem como alvo da tentativa de reidentificação todo registro presente na base sanitizada D' , independente de qual seja o registro, e seu objetivo é encontrar a correspondência correta entre registros de D' e os indivíduos do arquivo de nomes $Nomes_D$;
- (v) durante a execução do ataque é capaz de obter um arquivo auxiliar de quaseidentificadores Aux_D que expande o arquivo de nomes $Nomes_D$ com os sub-registros $\{x[\mathcal{Q}_{ID}]\}_{x \in D}$ correspondentes aos valores do conjunto $\mathcal{Q}_{ID} \subseteq \mathcal{A}$ de quaseidentificadores para todos os indivíduos presentes no arquivo de nomes;
- (vi) sabe que cada indivíduo de interesse possui no máximo um registro na base de dados original D –e, conseqüentemente, também na base sanitizada D' , no arquivo de nomes $Nomes_D$ e no arquivo de quaseidentificadores Aux_D ; e
- (vii) a fim de realizar um ataque com um custo computacional não proibitivo, assume o modelo simplificado do mecanismo de privacidade diferencial empregado e de seu próprio conhecimento auxiliar descrito na premissa $\mathbf{PS}_6^{ldp}$ da Seção 6.3.1.1. Mais precisamente, o adversário aplica a heurística do *Princípio da Máxima Verossimilhança (PMV)* para estimar quais indivíduos do arquivo auxiliar Aux_D são os mais prováveis de serem os titulares de um registro sanitizado na base D' . Formalmente, adota a estimativa

$$\arg \max_{a \in \text{dom}(\mathcal{A}_{aux})} p(x_{aux}=a \mid x_{D'}=d') \approx \arg \max_{a \in \text{dom}(\mathcal{A}_{aux})} p(x_{D'}=d' \mid x_{aux}=a) . \quad (\text{D.1})$$

A computação de (D.1) depende do modelo de privacidade diferencial local e do conhecimento do adversário. O adversário usa o fato de que o arquivo auxiliar Aux_D o informa dos valores corretos dos quaseidentificadores $\mathcal{Q}_{ID}$ de todos os indivíduos, i.e., $x_{aux}[\mathcal{Q}_{ID}] = x_D[\mathcal{Q}_{ID}]$ para todo indivíduo de interesse x . Além disso, o adversário assume o modelo simplificado em que quaseidentificadores diretos $\mathcal{Q}_{ID}^{mat}$ são sanitizados de forma independente dos quaseidentificadores indiretos $\mathcal{Q}_{ID}^{ent/tur}$. Desta forma, utilizando seu conhecimento sobre

o mecanismo de privacidade diferencial local provido na Seção 6.4, aproxima o valor de (D.1) usando a fórmula

$$p(x_{D'}=d' \mid x_{aux}=a) \approx (x_{D'}[\mathcal{Q}_{ID}^{mat}]=d'[\mathcal{Q}_{ID}^{mat}] \mid x_D[\mathcal{Q}_{ID}^{mat}]=a[\mathcal{Q}_{ID}^{mat}]) \cdot p(x_{D'}[\mathcal{Q}_{ID}^{ent/tur}]=d'[\mathcal{Q}_{ID}^{ent/tur}] \mid x_D[\mathcal{Q}_{ID}^{ent/tur}]=a[\mathcal{Q}_{ID}^{ent/tur}]) , \quad (D.2)$$

onde o primeiro fator da multiplicação em (D.2) corresponde à sanitização dos valores de quaseidentificadores diretos de matrícula em $\mathcal{Q}_{ID}^{mat}$, dada por

$$p(x_{D'}[\mathcal{Q}_{ID}^{mat}]=d'[\mathcal{Q}_{ID}^{mat}] \mid x_D[\mathcal{Q}_{ID}^{mat}]=a[\mathcal{Q}_{ID}^{mat}]) = \prod_{q \in \mathcal{Q}_{ID}^{mat}} p(x_{D'}[q]=d'[q] \mid x_D[q]=a[q]) , \quad (D.3)$$

e o segundo fator da multiplicação em (D.2) corresponde à sanitização valores de quaseidentificadores indiretos de turma e escola em $\mathcal{Q}_{ID}^{ent/tur}$, dada por

$$\frac{p(x_{D'}[\mathcal{Q}_{ID}^{ent/tur}]=d'[\mathcal{Q}_{ID}^{ent/tur}] \mid x_D[\mathcal{Q}_{ID}^{ent/tur}]=a[\mathcal{Q}_{ID}^{ent/tur}])}{1} \cdot \sum_{\substack{\langle e,t \rangle \in \text{dom}(\mathcal{A}^{ent/tur}), \\ \langle e,t \rangle[\mathcal{Q}_{ID}^{ent/tur}]=a[\mathcal{Q}_{ID}^{ent/tur}], \\ \langle e',t' \rangle \in \text{dom}(\mathcal{A}^{ent/tur}), \\ \langle e',t' \rangle[\mathcal{Q}_{ID}^{ent/tur}]=d'[\mathcal{Q}_{ID}^{ent/tur}]}} \left(\frac{p(x_D[\mathcal{A}_{COD}^{ent/tur}]=\langle e,t \rangle[\mathcal{A}_{COD}^{ent/tur}])}{p(X_{D'}[\mathcal{A}_{COD}^{ent/tur}]=\langle e',t' \rangle[\mathcal{A}_{COD}^{ent/tur}] \mid p(X_D[\mathcal{A}_{COD}^{ent/tur}]=\langle e,t \rangle[\mathcal{A}_{COD}^{ent/tur}]))} \right) \quad (D.4)$$

- **Quantificação da degradação probabilística de privacidade em um ataque $\widehat{RCU}^{ldp}$.** Na medição do sucesso probabilístico de um ataque $\widehat{RCU}^{ldp}$, quantifica-se a probabilidade de um indivíduo aleatoriamente escolhido como alvo na base sanitizada ser reidentificado com sucesso através de cruzamento com o arquivo auxiliar de quaseidentificadores. Quanto maior essa probabilidade, mais exitoso é o adversário, e maior é o risco esperado de cada indivíduo ser reidentificado.

- **Quantificação do sucesso probabilístico a priori do adversário em um ataque $\widehat{RCU}^{ldp}$.** Antes de efetuar o ataque $\widehat{RCU}^{ldp}$, o adversário pode escolher qualquer registro na base sanitizada D' como alvo. Neste momento, a única informação disponível para o adversário é a lista $Nomes_D$ com os nomes de todos os indivíduos potencialmente presentes na base sanitizada. Neste caso, o melhor que o adversário pode fazer para reidentificar o registro selecionado na base sanitizada D' como alvo é “adivinhar no escuro” qual indivíduo, dentre todos os presentes no arquivo de nomes $Nomes_D$, corresponderia ao registro-alvo. Uma vez que a cada indivíduo de interesse corresponde no

máximo um registro tanto na base sanitizada quanto no arquivo de nomes, a probabilidade de o adversário adivinhar o indivíduo no arquivo de nomes que realmente corresponde àquele do registro selecionado como alvo na base sanitizada é justamente o inverso do tamanho do arquivo de nomes. Assim, o sucesso probabilístico a priori do adversário em um ataque $\widehat{RCU}^{ldp}$ sobre uma base sanitizada D' , dado conhecimento do arquivo de nomes $Nomes_D$, é definido como

$$suc-prior_{prob}^{\widehat{RCU}^{ldp}}(D', Nomes_D) \stackrel{\text{def}}{=} \frac{1}{|Nomes_D|} . \quad (\text{D.5})$$

- **Quantificação do sucesso probabilístico a posteriori do adversário em um ataque $\widehat{RCU}^{ldp}$.** Durante a execução do ataque $\widehat{RCU}^{ldp}$, o adversário obtém acesso ao arquivo auxiliar de quaseidentificadores Aux_D que estende o arquivo de nomes $Nomes_D$ com os valores $\{x[\mathcal{Q}_{ID}]\}_{x \in D}$ dos quaseidentificadores de todos os indivíduos do arquivo. O adversário utiliza, então, este arquivo de quaseidentificadores como informação auxiliar na tentativa de reidentificação. Mais especificamente, dado um registro $x_{D'}$, na base sanitizada D' escolhido como alvo, o objetivo do adversário é determinar corretamente qual registro x_{aux} no arquivo auxiliar de quaseidentificadores Aux_D corresponde a $x_{D'}$. A reidentificação do registro é considerada bem sucedida se, e somente se, o adversário estabelece a correspondência correta.

A probabilidade de um registro a qualquer no arquivo auxiliar Aux_D corresponder a um registro $x_{D'} = d'$ é denotada por

$$p(x_{aux}=a \mid x_{D'}=d') . \quad (\text{D.6})$$

Naturalmente, a melhor estratégia para o adversário durante a tentativa de reidentificação de um registro sanitizado $x_{D'} = d'$ consiste em escolher um registro do arquivo auxiliar de quase identificadores que tenha a maior probabilidade de corresponder ao registro-alvo. Formalmente, o adversário seleciona como identidade provável do registro sanitizado $d' \in D'$ um registro do arquivo auxiliar Aux_D pertencente ao conjunto

$$\arg \max_{a \in Aux_D} p(x_{aux}=a \mid x_{D'}=d') . \quad (\text{D.7})$$

A fim de realizar um ataque com um custo computacional não proibitivo, o adversário assume um modelo simplificado do mecanismo de privacidade diferencial empregado e de seu conhecimento próprio conhecimento auxiliar, conforme seu especificado no item (vii) acima. Mais precisamente, ele aproxima (D.7) usando as Equações de (D.1) a (D.4), produzindo uma lista $Cand_{(x_{aux}|d')}$ de registros do arquivo auxiliar Aux_D consistindo em sua estimativa dos candidatos mais prováveis à uma reidentificação de sucesso do registro d' :

$$Cand_{(x_{aux}|d')} \stackrel{\text{def}}{=} \arg \max_{a \in dom(\mathcal{A}_{aux})} p(x_{D'}[\mathcal{Q}_{ID}]=d'[\mathcal{Q}_{ID}] \mid x_{aux}[\mathcal{Q}_{ID}]=a[\mathcal{Q}_{ID}]) . \quad (\text{D.8})$$

Como todo registro $a \in \text{Cand}_{(x_{aux}|d')}$ possui máxima probabilidade estimada de ser o titular que gerou o registro sanitizado $d' \in D'$, e assumimos uma probabilidade uniforme sobre os indivíduos de interesse, a melhor estratégia que o adversário tem para selecionar qual candidato em $\text{Cand}_{(x_{aux}|d')}$ corresponde ao registro $x_{D'}=d'$ é “adivinhar no escuro”, escolhendo um elemento de $\text{Cand}_{(x_{aux}|d')}$ aleatoriamente como sua tentativa de reidentificação. Desta forma, podemos calcular a probabilidade de sucesso a posteriori do adversário em reidentificar corretamente um registro $x_{D'}=d'$ selecionado como alvo na base sanitizada D' da seguinte forma. Caso o titular x_D que corresponde ao registro sanitizado $x_{D'}=d'$ não esteja no conjunto de candidatos $\text{Cand}_{(x_{aux}|d')}$ selecionados, qualquer escolha do adversário não leva a uma reidentificação exitosa e, portanto, a probabilidade de sucesso é zero. Por outro lado, caso o titular x_D que corresponde ao registro sanitizado $x_{D'}=d'$ esteja no conjunto de candidatos $\text{Cand}_{(x_{aux}|d')}$ selecionados, o adversário tem uma probabilidade de $1/|\text{Cand}_{(x_{aux}|d')}|$ de selecioná-lo e, assim, realizar uma reidentificação exitosa. O sucesso a posteriori do adversário em reidentificar um registro $d' \in D'$ escolhido como alvo é formalizado, então, como

$$\text{suc-post}_{\text{prob}}^{\widehat{RCU}^{ldp}}(D', \text{Aux}_D, d') \stackrel{\text{def}}{=} \begin{cases} 1/|\text{Cand}_{(x_{aux}|d')}|, & \text{se } x_{aux} \in \text{Cand}_{(x_{aux}|d')}, \\ 0, & \text{caso contrário.} \end{cases} \quad (\text{D.9})$$

O sucesso probabilístico global após o ataque é definido, então, como a esperança da probabilidade de sucesso tomada sobre a distribuição de probabilidade de que cada registro da base sanitizada tenha sido selecionado como alvo –a qual assumimos ser uniforme, i.e., $\pi_x^{D'} = 1/|D'|$. Assim, o sucesso probabilístico a posteriori do adversário em um ataque $\widehat{RCU}^{ldp}$ sobre uma base sanitizada D' , dado seu acesso ao arquivo auxiliar de quaseidentificadores Aux_D com os valores $\{x[\mathcal{Q}_{ID}]\}_{x \in D'}$ dos quaseidentificadores de todos os indivíduos na base sanitizada, é definido como

$$\begin{aligned} \text{suc-post}_{\text{prob}}^{\widehat{RCU}^{ldp}}(D', \text{Nomes}_D, \text{Aux}_D) &\stackrel{\text{def}}{=} \\ \sum_{d' \in D'} \pi_{d'}^{D'} \cdot \text{suc-post}_{\text{prob}}^{\widehat{RCU}^{ldp}}(D', \text{Aux}_D, d') &= \\ \frac{1}{|D'|} \sum_{d' \in D'} \text{suc-post}_{\text{prob}}^{\widehat{RCU}^{ldp}}(D', \text{Aux}_D, d') &. \end{aligned} \quad (\text{D.10})$$

- **Quantificação da degradação probabilística de privacidade em um ataque $\widehat{RCU}^{ldp}$.** A degradação probabilística de privacidade em um ataque $\widehat{RCU}^{ldp}$ é definida como a razão pela qual a realização do ataque aumenta o

sucesso probabilístico do adversário. Formalmente,

$$\text{degrad-priv}_{\text{prob}}^{\widehat{RCU}^{ldp}}(D', \text{Nomes}_D, \text{Aux}_D) \stackrel{\text{def}}{=} \frac{\text{suc-post}_{\text{prob}}^{\widehat{RCU}^{ldp}}(D', \text{Aux}_D)}{\text{suc-prior}_{\text{prob}}^{\widehat{RCU}^{ldp}}(D', \text{Nomes}_D)} . \quad (\text{D.11})$$

É importante ressaltar que neste ataque não é impossível que a degradação de privacidade apresente valores menores que 1, uma vez que o adversário é computacionalmente limitado e não é capaz de incorporar toda a informação auxiliar disponível. Quando um valor de degradação menor do que 1 ocorre, a interpretação correta é de que a privacidade diferencial local não aumenta o risco de reidentificação para tal adversário computacionalmente limitado, e não que ela efetivamente diminui o risco de reidentificação —uma vez que o adversário pode sempre ignorar a informação a posteriori caso ela não seja útil.


◁

E Histogramas das distribuições conjuntas de atributos antes e após mitigação


Nesta seção provemos informações suplementares sobre a análise comparativa da utilidade de diferentes métodos de mitigação, provida na Seção 7.2.2.

Apresentamos histogramas de distribuição de probabilidade marginal de cada atributo individual e de algumas combinações de atributos conjuntos antes e após a sanitização por cada método sobre a base amostral do Censo da Educação Básica de 2019. Estes histogramas ilustram o quão similares são as distribuições antes e após a sanitização para vários conjuntos de atributos. Mais especificamente:

- A Figura E.1 provê histogramas relativos à sanitização por amostragem descrita no Experimento 8.
- As Figuras E.2, E.3, E.4, E.5 e E.6 proveem os histogramas relativos à sanitização por privacidade diferencial local descrita no Experimento 12, em que o parâmetro de privacidade ϵ assume valores $\ln 3$, $\ln 5$, $\ln 100$, $\ln 10^3$ e $\ln 10^5$, respectivamente.




(a) Distribuições marginais.




(b) Distribuições conjuntas. Por questão de legibilidade, omitidos os rótulos indicando os valores de cada combinação de atributos.

Figura E.1: Experimento 8: Histogramas comparando as distribuições de probabilidade de atributos antes e após a sanitização por amostragem sobre a base amostral do Censo da Educação Básica de 2019.




(a) Distribuições marginais.




(b) Distribuições conjuntas. Por questão de legibilidade, omitidos os rótulos indicando os valores de cada combinação de atributos.

Figura E.2: Experimento 12: Histogramas comparando as distribuições de probabilidade de atributos antes e após a sanitização por privacidade diferencial local sobre a base do Censo da Educação Básica de 2019 restrito ao Distrito Federal, com $\epsilon = \ln 3$.




(a) Distribuições marginais.




(b) Distribuições conjuntas. Por questão de legibilidade, omitidos os rótulos indicando os valores de cada combinação de atributos.

Figura E.3: Experimento 12: Histogramas das distribuições de atributos antes e após a sanitização por privacidade diferencial local sobre a base amostral do Censo da Educação Básica de 2019 restrito ao Distrito Federal, usando $\epsilon = \ln 5$.




(a) Distribuições marginais.




(b) Distribuições conjuntas. Por questão de legibilidade, omitidos os rótulos indicando os valores de cada combinação de atributos.

Figura E.4: Experimento 12: Histogramas comparando as distribuições de probabilidade de atributos antes e após a sanitização por privacidade diferencial local sobre a base do Censo da Educação Básica de 2019 restrito ao Distrito Federal, com $\epsilon = \ln 10^2$.




(a) Distribuições marginais.




(b) Distribuições conjuntas. Por questão de legibilidade, omitidos os rótulos indicando os valores de cada combinação de atributos.

Figura E.5: Experimento 12: Histogramas comparando as distribuições de probabilidade de atributos antes e após a sanitização por privacidade diferencial local sobre a base do Censo da Educação Básica de 2019 restrito ao Distrito Federal, com $\epsilon = \ln 10^3$.



(a) Distribuições marginais.



(b) Distribuições conjuntas. Por questão de legibilidade, omitidos os rótulos indicando os valores de cada combinação de atributos.

Figura E.6: Experimento 12: Histogramas comparando as distribuições de probabilidade de atributos antes e após a sanitização por privacidade diferencial local sobre a base do Censo da Educação Básica de 2019 restrito ao Distrito Federal, com $\epsilon = \ln 10^5$.

F Desafios no uso de sanitização por privacidade diferencial no Censo Decenal de 2020 dos EUA

O USCB é uma das maiores agências de estatística do país, e é responsável por gerenciar o Censo Decenal previsto na Constituição dos EUA. A divulgação pública do censo tem vários propósitos, como por exemplo, dividir os assentos da Câmara dos Deputados. Juntamente com a divulgação do censo, a agência também tem a obrigação de proteger a privacidade dos cidadãos.

Como discutido no Produto 01 do presente projeto, o USCB está atualmente executando o Censo de 2020, no qual ocorrerá a maior alteração já realizada pela agência no que diz respeito às suas práticas de controle de divulgação estatística. As mudanças são devidas ao reconhecimento de que métodos sintáticos utilizados até o Censo Decenal de 2010 são inerentemente inseguros e sujeitam os registros individuais à possibilidade de reidentificação [14].

Dessa forma, o USCB anunciou em 2018 sua decisão de substituir métodos sintáticos por soluções baseadas em privacidade diferencial a partir do Censo de 2020 [2]. Neste mesmo anúncio o Escritório ressaltou que não existia *software* disponível no mercado que aplicasse privacidade diferencial em um censo nacional. Por esse motivo, foi necessário que a própria equipe do USCB desenvolvesse a solução, a um elevado custo tanto financeiro quanto de pessoal. Devido às alterações nos métodos utilizados pelo USCB para o controle da divulgação de dados estatísticos, mudanças também são esperadas no que diz respeito aos produtos que serão disponibilizados pelo Escritório a partir dos dados coletados pelo Censo de 2020. Conforme discutido no Produto 03 deste TED 8750, a solução encontrada tem alto grau de sofisticação e complexidade.

F.1 Desafios encontrados na implementação da privacidade diferencial

Como já mencionado no Produto 01 do presente TED, a implementação da privacidade diferencial pelo USCB enfrentou e enfrenta diversas dificuldades, tanto técnicas [28] quanto de comunicação com o restante da comunidade de estatística [50]. Apesar disso, o Escritório do Censo continua a preparação para o uso da privacidade diferencial, inclusive com a publicação de produtos de demonstração derivados dos microdados do Censo de 2010 [13]. A seguir resumizamos as principais dificuldades reportadas pela própria agência durante o desenho, implementação e comunicação à sociedade da nova solução adotada.

(I) Desafios científicos:

- **Mecanismos hierárquicos.** É preciso controlar cuidadosamente o erro introduzido à medida em que estatísticas são relatadas de geolocalidades menores para maiores. Mais precisamente, o erro deve diminuir conforme a população aumenta. Foi necessário o desenvolvimento de um conjunto de novos mecanismos hierárquicos projetados para otimizar a precisão de várias consultas simultaneamente.
- **Invariantes.** Invariantes descrevem estatísticas que não podem ser alteradas pela aplicação da privacidade diferencial. Algumas estatísticas devem ser, então, reportadas de forma exata (e.g., número de pessoas que vivem em cada quarteirão), enquanto outras estatísticas podem ser sanitizadas via ruído (e.g., o número de hispânicos que vivem em cada quarteirão). Não existe uma teoria bem desenvolvida sobre como a privacidade diferencial opera na presença de tais invariantes.
- **Emprego em amostragens estratificadas.** Desde 2005 o USCB vem utilizando a Pesquisa da Comunidade Americana (*American Community Survey*) que realiza uma amostragem probabilística estratificada para medir continuamente a população dos EUA. Não há um mecanismo aceito para aplicar a privacidade diferencial aos resultados de amostras probabilísticas estratificadas.
- **Métricas de qualidade.** A troca entre precisão estatística e perda de privacidade está no cerne da privacidade diferencial. Existem diversas métricas para avaliar a qualidade de um conjunto de dados. Os usos pretendidos das estatísticas devem ser previamente conhecidos para que possam ser incorporados ao mecanismo de privacidade de modo a aumentar a utilidade para um mesmo orçamento de perda de privacidade.
- **Apresentar e resolver questões de equidade.** Publicar muitas tabelas a partir da mesma base de dados confidencial permite aumentar a precisão de algumas tabelas em detrimento da precisão de outras, sob um mesmo

limite de perda de privacidade. A privacidade diferencial carece de uma teoria bem desenvolvida para medir o impacto relativo do ruído adicional sobre a utilidade de diferentes produtos de dados, ajustando as compensações de equidade e apresentando o impacto de tais decisões.

- **Estabelecer o valor do parâmetro ϵ .** A configuração da perda de privacidade, determinada pelo valor do parâmetro ϵ , é uma questão política, e não meramente técnica. A literatura sobre privacidade diferencial neste assunto ainda é muito escassa.

O Comitê de Política Executiva de Administração de Dados do Escritório do Censo, composto apenas por executivos seniores de carreira, é o órgão responsável pela avaliação e escolha do valor final do parâmetro ϵ e de outros parâmetros ajustáveis do sistema de controle de privacidade do Escritório.

Essa escolha está sendo realizada em etapas, conforme a área técnica finaliza as especificações de cada produto a ser divulgado pelo Escritório. Até o momento, apenas os dados necessários para definir a distribuição de assentos legislativos a nível federal já estão especificados, com publicação prevista para 30 de abril de 2021.

- **Desenvolvimento do mecanismo.** Mecanismos mais eficientes e provas com limites mais rígidos são necessários para reduzir os níveis de ruído para um mesmo nível de perda de privacidade e para fazer uso eficiente do orçamento de perda de privacidade para liberações iterativas de estatísticas editadas e corrigidas.

(II) Desafios operacionais:

- **Obtenção de pessoal qualificado e ferramentas.** O Escritório do Censo não contava com especialistas em teoria e prática de privacidade diferencial. Ainda há falta de ferramentas para realizar cálculos de privacidade diferencial e para verificar a correção de implementações específicas.
- **Reformulação de consultas de alta sensibilidade.** Consultas de contagem possuem sensibilidade 1. Entretanto, outros tipos de consulta podem apresentar sensibilidade significativamente mais elevada, o que torna necessária a adição de uma grande quantidade de ruído.
- **Zeros estruturais e de amostragem.** Existem algumas regras de edição do censo que buscam manter certas consistências, como “*Não pode haver mães de seis anos com crianças de 30 anos*”, ou “*Não pode haver um cidadão que mora na cidade de São Francisco e no estado de Nova Iorque*”. A adição de ruído da privacidade diferencial não pode alterar os zeros estruturais.
- **Obtenção de ambiente de computação adequado.** Os algoritmos desenvolvidos para o Censo de 2020 exigem pós-processamento significativo após a aplicação do ruído. Estima-se que pelo menos três ordens de magnitude de recursos computacionais a mais do que os necessários para o Censo de 2010

serão utilizados no Censo de 2020. O Escritório está migrando de computação local para um ambiente baseado em processamento em nuvem.

- **Contabilização de todos os usos de dados confidenciais.** Um requisito fundamental da privacidade diferencial é que todos os cálculos envolvendo dados privados devem ter ruído acrescentado antes de poderem ser tornados públicos. O Escritório do Censo teve que identificar previamente cada uso dos dados confidenciais na execução e processamento do Censo de 2020. Requisitos novos e imprevistos surgiram durante o projeto do sistema após a equipe considerar que o projeto estava fechado.
- **Falta de especificações finais.** Muitos dos produtos de dados do Escritório do Censo foram tradicionalmente desenvolvidos perto do final da década, em consulta com os usuários de dados. Esse processo colaborativo ajuda a garantir a utilidade dos dados do Censo, mas está em desacordo com boas práticas de desenho e desenvolvimento de um sistema de privacidade diferencial. Todos os cálculos devem ser conhecidos antecipadamente ou uma parte do orçamento para perda de privacidade deve ser reservada para uso futuro.

(III) Desafio para os analistas de dados:

- **Acesso a microdados.** Muitos usuários de dados do Escritório do Censo estão acostumados a usar microdados brutos ou que passaram por edições limitadas de confidencialidade. Os dados em nível de registro são extremamente difíceis de proteger de uma maneira que ofereça proteção real à privacidade. Atualmente, o Escritório do Censo aconselha que tais usuários considerem as modalidades de acesso restrito, as quais dependem de aprovação prévia.
- **Aumento da transparência.** Os usuários estarão cientes de que o ruído foi adicionado e poderão calcular a margem de erro que o ruído introduz. Entretanto, alguns analistas de dados ainda estão confusos sobre essa margem de erro, um termo que tradicionalmente associam a pesquisas por amostragem. Dessa forma, com o objetivo de sanar dúvidas e preparar a comunidade para receber os novos produtos do Censo de 2020, o Escritório do Censo tem atuado ativamente na produção de materiais educativos, incluindo a liberação de código-fonte e disponibilização de microdados de exemplo com resultados esperados para comparação.
- **Incompreensão sobre aleatoriedade e ruído.** Uma das bases da privacidade diferencial é a adição de ruído aleatório aos dados tabulados antes da publicação. Por definição, os mecanismos de adição de ruído usados pelo Escritório do Censo resultam em maior precisão à medida em que o tamanho da população aumenta. Explicar isso aos analistas de dados, líderes comunitários e ao público em geral será fundamental para a aceitação dessa nova metodologia de garantia de privacidade. A falta de materiais simplificados para promover uma compreensão geral da privacidade diferencial aumenta a probabilidade de mal-entendidos.

Lista de Siglas

DCC Departamento de Ciência da Computação da UFMG.

DEED Diretoria de Estatísticas Educacionais do Inep.

DF Distrito Federal.

GDPR *General Data Protection Regulation*.

INEP Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira.

LAI Lei de Acesso à Informação.

LDP privacidade diferencial local, em suas iniciais do inglês *local differential privacy*.

LGPD Lei Geral de Proteção de Dados Pessoais.

LGPDP Lei Geral de Proteção de Dados Pessoais.

MEC Ministério da Educação.

RCU Ataque de reidentificação coletiva em uma única base de dados (sanitizada por desidentificação e pseudonimização).

RCU^{ams} Ataque de reidentificação coletiva em uma única base de dados sanitizada por amostragem.

RCU^{ldp} Ataque de reidentificação coletiva em uma única base de dados sanitizada por privacidade diferencial local.

RGPD Regulamento Geral de Proteção de Dados.

TED Termo de Execução Descentralizada.

UFMG Universidade Federal de Minas Gerais.

Glossário

adversário Entidade contra quem se deseja proteger a informação sensível sobre indivíduos. O adversário pode ser uma pessoa física ou uma organização. Não necessariamente se atribuem intenções deletérias ao adversário: é possível que um consumidor legítimo de uma divulgação estatística (e.g., um pesquisador acadêmico) atue inadvertidamente como adversário ao inferir informação sensível de indivíduos no decurso de ações idôneas.

analista de dados Pessoa ou entidade considerada como usuária legítima de uma divulgação de dados.

analista racional Analista que, sabendo que o mecanismo de divulgação adapta sua resposta adicionando ruído para garantir privacidade, utiliza o resultado da consulta em conjunto com seus conhecimentos e convicções prévias para inferir a partir da resposta ruidosa qual é a resposta que minimize sua perda de acordo com uma função de utilidade/perda subjetiva.

anonimidade- k (*k-anonymity*) Método sintático de tratamento que garante que os dados de cada indivíduo pertencente a uma divulgação de dados não possam ser distinguidos dos dados de pelo menos outros $k-1$ indivíduos também pertencentes à mesma divulgação.

anonimização Utilização de meios técnicos razoáveis e disponíveis no momento do tratamento, por meio dos quais um dado perde a possibilidade de associação, direta ou indireta, a um indivíduo. Técnicas de anonimização incluem, mas não se limitam a, *desidentificação*, *k-anonymity*, *l-diversity* e *privacidade diferencial*, dentre outras. Diferentes técnicas têm diferentes graus de sucesso, e algumas são comprovadamente menos eficazes que outras.

ataque Ação ou conjunto de ações pelas quais o adversário pode obter informação sensível sobre titulares de dados. Ao termo “ataque” não se atribui uma intenção necessariamente deletéria: uma utilização legítima dos dados (e.g., para pesquisa científica) pode resultar inadvertidamente em um ataque se porventura revelar informação sensível.

ataque composicional Ataque que se utiliza do cruzamento de informações divulgadas por mais de uma fonte, ou por divulgações diferentes de uma mesma fonte (e.g., cruzamento de dados de um censo médico com registros públicos de eleitores).

ataque de inferência de atributo Ataque em que o objetivo do adversário é inferir o valor assumido por um atributo considerado como sensível para um conjunto de indivíduos, independentemente de se estes indivíduos tenham sido reidentificados com sucesso ou não.

ataque de reconstrução da base de dados Método para reconstruir parcialmente um conjunto de dados privado a partir de informações agregadas públicas.

ataque de reidentificação Ataque em que o objetivo do adversário é determinar uma correspondência entre registros presentes na base de dados e os titulares desses registros, i.e., os indivíduos do mundo real a quem os registros se refere.

ataque longitudinal Ataque que se utiliza de informações divulgadas ao longo do tempo (e.g., várias liberações de informação referentes a uma mesma pesquisa, ou pesquisas em anos consecutivos que se referem aos mesmos titulares).

atributo não sensível Atributo cujo valor não é considerado digno de proteção em si mesmo em um dado contexto.

banco de dados O mesmo que *base de dados*.

base de dados Conjunto estruturado de dados pessoais, estabelecido em um ou em vários locais, em suporte eletrônico ou físico.

Censo da Educação Básica Principal pesquisa estatística educacional do país, abrangendo a Educação Básica e Profissional.

Censo da Educação Superior Mais completa pesquisa estatística sobre as Instituições de Educação Superior do país.

composicionalidade Propriedade de um método de tratamento de poder ser aplicado independentemente a divulgações distintas e ainda preservar garantias de privacidade globais.

conhecimento a posteriori do adversário Conhecimento a respeito da informação sensível que o adversário adquire ao revisar seu conhecimento a priori de acordo com o resultado da execução de um ataque.

conhecimento a priori do adversário Conhecimento a respeito da informação sensível que o adversário possui antes mesmo de executar um ataque.

consulta Uma recuperação de dados ou informações a partir de uma base de dados, normalmente efetuada em linguagem específica.

controle de divulgação estatística Área que estuda como compartilhar publicamente informações sobre um conjunto de dados, revelando padrões estatísticos a respeito dos mesmos ao mesmo tempo em que se protegem informações sensíveis sobre os indivíduos no conjunto de dados. O controle de divulgação estatística deve balancear a manutenção da utilidade dos dados (com relação a um analista legítimo) com garantias de privacidade para os titulares dos dados (contra um adversário).

curador de dados Pessoa ou entidade responsável pela integração de dados coletados de várias fontes, além da organização, publicação e apresentação dos dados de forma que o valor dos dados seja mantido ao longo do tempo e os dados permaneçam disponíveis para reutilização e preservação. A curadoria de dados inclui todos os processos necessários para a criação, manutenção e gerenciamento de dados controlados e com princípios, juntamente com a capacidade de agregar valor aos dados.

dado agregado Dado sumarizado correspondendo a uma agregação das informações dos microdados para unidades mais amplas, ou mesmo a uma função computada sobre essas informações (e.g., frequência, média ou outros tipos de análises).

dado anonimizado Dado relativo a titular que não possa ser identificado, considerando a utilização de meios técnicos razoáveis e disponíveis na ocasião de seu tratamento.

dado pessoal Informação relacionada a pessoa natural identificada ou identificável.

dado pessoal sensível Dado pessoal sobre o qual a preocupação quanto à privacidade (e.g., sobre origem racial ou étnica, convicção religiosa, opinião política, filiação a sindicato ou a organização de caráter religioso, filosófico ou político, dado referente à saúde ou à vida sexual, dado genético ou biométrico), quando vinculado a uma pessoa natural.

dados sintéticos Dados especialmente criados para substituir dados reais em divulgações de microdados ou para geração de dados tabulares. São gerados de forma a preservar algumas propriedades estatísticas dos dados originais, tais como distribuições marginais, médias e quartis.

degradação de privacidade Comparação entre o *sucesso a posteriori* do adversário –i.e., depois de executar o ataque– e o *sucesso a priori* do adversário –i.e., antes de executar o ataque– em seu intuito de inferir informação sensível. Intuitivamente, quanto maior a degradação de privacidade de um ataque, maior o incremento no sucesso esperado do adversário em obter informação sensível.

desanonimização O mesmo que *reidentificação*.

desidentificação Técnica de tratamento de dados pela qual são removidos possíveis identificadores individuais óbvios dos registros (e.g., nome, CPF, RG, ou endereços em níveis mais detalhados que as cidades), na expectativa de dificultar-se uma eventual reidentificação do titular.

differential privacy O mesmo que *privacidade diferencial*.

diversidade- ℓ (*ℓ -diversity*) Método sintático de tratamento que aperfeiçoa a técnica de anonimidade- k ao garantir um nível mínimo de diversidade nos atributos sensíveis de cada conjunto de indivíduos agrupados.

Exame Nacional de Desempenho dos Estudantes (ENADE) Avaliação do rendimento dos concluintes dos Cursos de Graduação tanto em relação aos conteúdos programáticos previstos nas diretrizes curriculares dos cursos, quanto no que diz respeito às habilidades desenvolvidas e à atualização do aluno em relação ao Brasil e ao mundo.

Exame Nacional do Ensino Médio (ENEM) Avaliação do desempenho escolar ao final da Educação Básica.

General Data Protection Regulation (GDPR) Regulamento do direito europeu de 2018 que trata da privacidade e proteção de dados pessoais, aplicável a todos os indivíduos na União Europeia e do Espaço Econômico Europeu.

histograma Forma de divulgação de informação sobre uma base de dados contendo apenas projeções marginais da distribuição de registros por valores.

identificador direto Atributo que pode unicamente identificar um indivíduo, como nome, RG, CPF, ou número de telefone celular.

inferência de atributo Prática de combinar dados anonimizados com informações publicamente disponíveis ou dados auxiliares, a fim de descobrir o valor de algum atributo sensível de um indivíduo.

informação auxiliar Em relação a uma divulgação de dados de interesse, informação auxiliar é qualquer informação que se possa obter a respeito de um indivíduo através de outros canais que não sejam a divulgação de dados de interesse em si mesma (e.g, via *web*, outros registros públicos, jornais ou revistas, conhecimento prévio).

informação lateral O mesmo que *informação auxiliar*.

informação sensível Informação considerada como digna de proteção. Exemplos típicos incluem a situação médica, a renda, ou vida pessoal de um indivíduo.

Inscrypt *Laboratory of Information Security, Cryptography, Privacy, and Transparency*, laboratório de pesquisa do DCC/UFMG focado em segurança da informação, criptografia, privacidade e transparência.

Lei de Acesso à Informação (LAI) Lei brasileira 12.527/2011, que trata dos procedimentos a serem observados pelo Estado para garantir o acesso a informações previsto na Constituição Federal do Brasil de 1988.

Lei Geral de Proteção de Dados Pessoais (LGPD ou LGPDP) Lei brasileira 13.709/2018, que dispõe sobre o tratamento de dados pessoais, inclusive nos meios digitais, por pessoa natural ou por pessoa jurídica de direito público ou privado, com o objetivo de proteger os direitos fundamentais de liberdade e de privacidade e o livre desenvolvimento da personalidade da pessoa natural.

mecanismo ótimo Mecanismo que respeita as preferências e tolerâncias de um analista em específico com relação ao ruído adicionado.

mecanismo de Laplace Mecanismo que implementa a privacidade diferencial sobre um domínio de dados numérico contínuo, aplicando ruído de acordo com uma distribuição de probabilidade de Laplace.

mecanismo exponencial Mecanismo que implementa a privacidade diferencial sobre um domínio de dados categórico, aplicando ruído de acordo com uma distribuição de probabilidade proporcional a uma noção de distância sobre as categorias.

mecanismo geométrico Mecanismo que implementa a privacidade diferencial sobre um domínio de dados numérico discreto, aplicando ruído de acordo com uma distribuição de probabilidade geométrica.

mecanismo k -RR Mecanismo que implementa a privacidade diferencial sobre um domínio de dados categórico, aplicando ruído de acordo com o princípio de resposta aleatorizada.

mecanismo ótimo universal Mecanismo capaz de ser simultaneamente ótimo para todos os (ou uma grande maioria dos) potenciais analistas da base de dados.

método composicional Método de mitigação de degradação de privacidade que apresenta a propriedade de *composicionalidade*.

método global Método de tratamento que conta com um curador de dados responsável pela coleta de informações individuais e aplicação das técnicas de proteção. Nesse tipo de método assume-se que o curador é uma entidade digna de confiança para tratamento da informação sensível, e o tratamento é aplicado ao conjunto dos dados de forma holística.

método local Método de tratamento em que a proteção de privacidade é aplicada aos dados de cada titular individualmente.

método não perturbativo Método de tratamento que altera a informação provida apenas por diminuir sua granularidade ou por suprimi-la por partes, mas sem introduzir informação ruidosa.

método perturbativo Método de tratamento que pode introduzir informação inverídica de forma controlada na divulgação, seja por criação de dados falsos ou pela inserção de ruído nos dados.

método semântico Qualquer método de tratamento de dados que formule condições semânticas para a divulgação de informação, incorporando em si mesmo a formalização de privacidade almejada (e.g., privacidade diferencial).

método sintático Qualquer método de tratamento de dados que formule condições puramente sintáticas para a divulgação de informação (e.g., desidentificação, *k-anonymity* e *l-diversity*).

métrica de privacidade de caso médio Medida de privacidade que quantifica a esperança ou média do sucesso do adversário, levando em conta alguma distribuição de probabilidade sobre possíveis configurações do ataque.

métrica de privacidade de pior caso Medida de privacidade que quantifica o sucesso do adversário sobre a configuração de ataque mais vantajosa para ele possível, independentemente do quão improvável ela seja.

métrica determinística de sucesso do adversário Função que mensura o sucesso do adversário e forma absoluta, retornando um valor qualitativo dependendo de se a informação desejada foi ou não recuperada com absoluta certeza.

métrica de utilidade específica Métrica de utilidade que parte do princípio de que uma divulgação será utilizada para uma tarefa preestabelecida e então medem a qualidade da divulgação para esta tarefa.

métrica de utilidade geral Métrica de utilidade que tenta diminuir ao máximo a distorção entre os dados originais e os dados tratados, sob a premissa de se a distribuição de probabilidade sobre registros após o tratamento for similar à distribuição antes do tratamento, então os dados tratados serão úteis para a maioria dos analistas aplicações.

métrica probabilística de sucesso do adversário Função que mensura o sucesso do adversário de forma probabilística, retornando um valor quantitativo representando o grau de certeza com o qual a informação desejada foi recuperada.

microdado A menor fração de um dado e pode estar relacionado a uma pesquisa ou avaliação; o dado em sua menor forma de agregação. Microdados geralmente carregam informação sobre entidades em nível individual (e.g., pessoas, escolas, institutos).

mitigação, técnica ou método de O mesmo que *tratamento de dados*.

negação plausível (*plausible deniability*) Capacidade de um titular de dados negar de forma crível para um adversário alguma propriedade sobre sua informação sensível (e.g., negar sua participação em um estudo, ou que um de seus atributos tenha um valor específico), mesmo após um ataque.

privacidade-*d* (*d-privacy*) Variante da privacidade diferencial que explora a noção de indistinguibilidade entre segredos para aumentar a utilidade de divulgações.

privacidade diferencial Método semântico de tratamento de dados que garante formalmente que apenas uma quantidade negligível de informação sobre um dado indivíduo pode ser obtida a partir dos dados publicados, independentemente da participação ou não do indivíduo na pesquisa.

privacidade diferencial global Variante da privacidade diferencial em que o ruído é adicionado ao resultado de cada consulta realizada.

privacidade diferencial local Variante da privacidade diferencial em que o ruído é adicionado diretamente aos dados coletados.

proximidade- t (t -closeness) Método sintático de tratamento que aperfeiçoa a técnica de diversidade- ℓ ao garantir que aprender apenas os valores de uma coleção predefinida de quaseidentificadores não altera o conhecimento probabilístico do adversário a respeito dos atributos sensíveis de cada indivíduo.

pseudonimização Técnica de tratamento de dados pela qual atribui-se um código individual artificialmente criado a cada registro de uma base de dados, acompanhada da transferência de identificadores diretos (como nome, CPF e RG) para outra base de dados. Dessa forma, o controlador é capaz de mapear identificadores diretos em uma base de dados a registros específicos na outra base através do uso dos códigos individuais, ao mesmo tempo em que se dificultam tentativas de reidentificação do titular por parte de agentes externos.

quaseidentificador Informações que não são, em si mesmas, identificadores únicos, mas que estão suficientemente correlacionadas com uma entidade a ponto de poderem ser combinadas com outros quaseidentificadores para criar um identificador exclusivo.

query O mesmo que *consulta*.

registro Informação em uma base de dados correspondente a um indivíduo específico.

Regulamento Geral de Proteção de Dados (RGPD) O mesmo que *General Data Protection Regulation*.

reidentificação Prática de combinar dados anonimizados com informações publicamente disponíveis ou dados auxiliares, a fim de descobrir o indivíduo ao qual os dados pertencem.

sala segura Lugar físico seguro que possui servidores que contém os dados reais de pesquisas sociais e pesquisas estatísticas de alguma natureza (por exemplo, dados médicos ou dados de censos populacionais) e terminais que os usuários podem utilizar para acessar esses dados de forma controlada.

sensibilidade ℓ_1 Dada uma consulta, trata-se da maior influência que a adição, remoção ou alteração de um único registro em uma base de dados pode ocasionar na resposta retornada por esta consulta.

Sistema de Avaliação da Educação Básica (SAEB) Conjunto de testes e questionários aplicados na rede pública e em uma amostra da rede privada que auxilia no diagnóstico da Educação Básica e de possíveis fatores que interfiram no desempenho do estudante.

sucesso a posteriori do adversário Medida (determinística ou probabilística) do quanto de informação sensível o adversário possui após a execução do ataque, usando a informação a posteriori adquirida.

sucesso a priori do adversário Medida (determinística ou probabilística) do quanto de informação sensível o adversário já possui antes mesmo de executar um ataque, usando apenas seu conhecimento a priori.

sumário estatístico Forma de divulgação de informação sobre uma base de dados contendo apenas resposta a um conjunto de consultas estatísticas predeterminadas.

Teorema de Reconstrução da Base de Dados (*Dataset Reconstruction Theorem*) Resultado formal que mostra que, dado acesso a uma quantidade suficientemente grande de informações, alguém pode reconstruir bancos de dados subjacentes e, em teoria, reidentificar indivíduos.

titular Pessoa natural a quem se referem os dados pessoais que são objeto de tratamento.

titular de dados Pessoa ou entidade a quem os dados coletados, processados ou divulgados se referem diretamente.

tratamento (de dados) Toda operação realizada com dados pessoais, como as que se referem a coleta, produção, recepção, classificação, utilização, acesso, reprodução, transmissão, distribuição, processamento, arquivamento, armazenamento, eliminação, avaliação ou controle da informação, modificação, comunicação, transferência, difusão ou extração.

United States Census Bureau (USCB) Agência federal dos EUA responsável por divulgar dados sobre população e economia.

utilidade Propriedade de uma divulgação servir aos propósitos legítimos do analista de dados, provendo a ele a informação desejada.

TED 8750 - PRICE

PRIVACIDADE NOS CENSOS EDUCACIONAIS

Termo de Execução Descentralizada entre o Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira - Inep e a Universidade Federal de Minas Gerais - UFMG

PRODUTO 06

Relatório técnico de implantação



Mário S. ALVIM
Ramon G. GONZE
Jeroen van de GRAAF

Igor W. LEMES
Lucas LOPES
Gabriel H. NUNES

23 de dezembro de 2020

Resumo

No presente documento resumizamos as principais atividades de transferência de conhecimento da equipe técnica executora para a equipe do Inep. Adicionalmente, detalhamos os recursos computacionais usados para execução dos ataques no Produto 02, intitulado *Relatório sobre os riscos à privacidade decorrentes da atual forma de divulgação dos microdados dos Censos Educacionais do Inep*. Desta forma, torna-se possível estimar quais recursos o Inep precisaria caso deseje reproduzir e explorar os resultados daquele Produto em mais profundidade.

Sumário

1	Introdução	1
1.1	Objetivo deste documento	1
1.2	Contextualização	1
1.3	Organização deste documento	4
2	Atividades de transferência de conhecimento	5
3	Recursos utilizados na execução do Produto 02	6
3.1	<i>Hardware</i>	6
3.2	<i>Software</i>	6
3.3	Performance	7
3.3.1	Ataques em uma única base de dados	7
3.3.2	Ataques em base de dados longitudinal	8

Lista de Tabelas

3.3.1	Atributos usados como candidatos a quaseidentificadores nos experimentos de ataques em uma única base de dados.	9
3.3.2	Atributos sensíveis usados nos experimentos de ataques em uma única base de dados.	10
3.3.3	Atributos usados como candidatos a quaseidentificadores nos experimentos de ataques longitudinais.	11
3.3.4	Atributos sensíveis usados nos experimentos de ataques longitudinais. . .	12
3.3.5	Resumo dos ataques e o tempo de execução na plataforma. Qids significa quaseidentificadores, As significa atributos sensíveis	12

1 Introdução

Este documento consiste no Produto 06, intitulado *Relatório de implantação*, do plano de trabalho do Termo de Execução Descentralizada (TED) 8750, firmado entre o Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira (Inep) e a Universidade Federal de Minas Gerais (UFMG), e em execução pelo Laboratório Inscript (*Laboratory of Information Security, Cryptography, Privacy, and Transparency*) do Departamento de Ciência da Computação (DCC) da Universidade.

1.1 Objetivo deste documento

De acordo com o plano de trabalho do TED 8750, o Produto 06 que este documento implementa consiste em um:

Documento técnico apresentando o relatório das atividades de transferência de tecnologia e de validação analítica do ambiente de execução do Inep.

Mais especificamente, distinguem-se dois componentes previstos para o presente produto:

1. apresentação da relação com os procedimentos de transferência aplicados; e
2. apresentação de relatório analítico sobre o ambiente de execução preparado pelo Inep.

1.2 Contextualização

Seguindo o plano de trabalho do presente TED 8750, foram concluídos os seguintes produtos:

1. Produto 01: *Relatório sobre o panorama internacional e o contexto do Inep a respeito dos métodos de tratamento de controle de privacidade na divulgação estatística*);

2. Produto 02: *Relatório sobre os riscos à privacidade decorrentes da atual forma de divulgação dos microdados dos Censos Educacionais do Inep*); e
3. Produto 03: *Relatório técnico sobre métodos de tratamento aplicáveis aos microdados de divulgação dos Censos Educacionais do Inep*).

Em particular, no Produto 03 a equipe executora produziu uma avaliação da atual situação do Inep em relação à privacidade na divulgação dos Censos Educacionais. Tal avaliação inclui as seguintes considerações:

A opção por qualquer método de mitigação deve passar pela harmonização de interesses possivelmente conflitantes de vários atores. No caso dos Censos Educacionais do Inep, os atores incluem os **titulares de dados** (estudantes, professores, escolas, etc.), **analistas** (demógrafos, entidades civis e governamentais, etc.), o **governo** (que regulamenta tanto questões de privacidade quanto de transparência e acesso à informação), além do próprio **Inep** (que tem que conciliar de forma realista as demandas dos vários atores com a sua capacidade e recursos para atendê-las).

Além disso, o Inep dispõe de um **prazo exíguo** para implementação de uma solução que atenda às demandas da LGPD. Dada esta restrição de tempo, o Inep deve considerar adotar uma **solução emergencial de curto prazo** que garanta a privacidade dos titulares –mesmo que seja possivelmente subótima em relação à utilidade provida aos analistas (ou vice-versa)–, enquanto elabora-se uma **alternativa de longo prazo** que forneça um melhor **custo-benefício na relação de privacidade e utilidade**.

Baseado nas considerações acima, a recomendação da equipe técnica presente no Produto 03 consistiu no plano de ação sumarizado a seguir. Primeiramente, o Inep eliminaria imediatamente a divulgação de microdados em qualquer forma, a fim de garantir a privacidade em nível individual exigida pela LGPD. O Inep ofereceria, então, apenas informações agregadas (sumários estatísticos ou histogramas) em seus canais públicos de comunicação, protegidos com privacidade diferencial, possibilitando a analistas o acesso a microdados apenas com autorização prévia e em salas seguras (possivelmente virtuais). Reconhecidamente, a solução proposta acima estaria contingenciada pela significativa restrição de tempo para execução do presente TED 8750. Além disso, ela teria o efeito colateral de aumentar a demanda por acesso a salas seguras. Para contornar este problema, no Produto 03 foi sugerido ao Inep considerar futuramente a seguinte medida. Uma vez assegurado nível de privacidade individual dos dados demandado pela LGPD, proceder-se-ia a um estudo aprofundado de como aumentar a utilidade das divulgações enquanto se mantém a privacidade conquistada. O aumento gradual da utilidade dos dados visaria a satisfazer a um número cada vez maior de analistas, o que poderia contribuir para arrefecer a demanda suplementar por acesso a salas seguras eventualmente causada pelas etapas anteriores do plano de ação.

Como previsto no plano de trabalho, as recomendações acima foram profundamente discutidas entre a equipe executora do presente TED 8750 e os representantes do Inep, a fim de suportar uma tomada de decisão bem informada.

Após esta etapa de discussão e deliberação, o Inep optou por manter o foco do presente TED 8750 na avaliação da viabilidade de divulgação de microdados, descartando no presente momento soluções baseadas na divulgação de dados agregados. A decisão foi baseada na premissa de que, apesar de haver indícios fortes na literatura de que a divulgação de microdados no tempo exíguo disponível para o presente TED 8750 pode não atingir um nível de compromisso entre privacidade e utilidade aceitável, é importante averiguar empiricamente este fato. Tal averiguação quantitativa proveria suporte científico para qualquer eventual tomada de decisão futura do Inep, justificando-a perante outras partes interessadas (i.e., titulares de dados, analistas e governo).

Neste sentido, as abordagens escolhidas para avaliação no presente TED 8750 foram:

1. divulgação de microdados por amostragem, ou seja, publicar apenas um subconjunto dos registros; e
2. aplicação de privacidade diferencial local a microdados, perturbando-os de forma controlada com ruído aleatório.

Como mencionado, é previsto que dentro do tempo disponível para o TED 8750 as técnicas de sanitização de microdados selecionadas possam não atinjam níveis satisfatórios de privacidade e utilidade. Neste sentido, o presente Produto 06 não se foca na transferência de tecnologia de como aplicar tais técnicas aos dados dos Censos Educacionais do Inep, uma vez que elas não necessariamente serão postas em produção –mesmo que seus resultados experimentais sejam essenciais para tomada de decisão futura.

Por outro lado, o Inep se mostrou interessado em reproduzir as ataques apresentados em Produto 02 a fim de pesquisar e aprofundar suas análises internas sobre os riscos de privacidade na divulgação de microdados. Este documento lista detalhadamente quais recursos computacionais foram usados para chegar aos resultados do Produto 02. Optamos por essa abordagem pelos seguintes argumentos. Primeiro, não sabemos com qual frequência o Inep pretende fazer essas simulações (e.g., anualmente, mensalmente, ou com outra periodicidade), nem para quantos conjuntos de dados (e.g., quantos Censos, e de quantos anos), nem qual seria a urgência na obtenção dos resultados (e.g., eles deveriam estar disponíveis em um dia, ou um intervalo de algumas semanas seria aceitável). Segundo, não sabemos quais recursos computacionais o Inep já possui à sua disposição. Por exemplo, se a demanda for baixa, é concebível que a área de TI do Inep consiga suprir essa demanda usando o parque computacional já disponível. E com base desse relatório, junto com as demandas reais, que é possível estimar com exatidão os recursos computacionais necessários.

1.3 Organização deste documento

O restante deste documento está organizado da seguinte forma.

- **Atividades de transferência de conhecimento** (Seção 2): Nesta seção resumiremos as principais atividades de transferência de conhecimento da equipe técnica executora para a equipe do Inep.
- **Recursos utilizados na execução do Produto 02** (Seção 3): Nesta seção descrevemos o ambiente de execução utilizado para as análises providas no Produto 02, intitulado *Relatório sobre os riscos à privacidade decorrentes da atual forma de divulgação dos microdados dos Censos Educacionais do Inep*, assim como os requisitos mínimos para a reprodução dos mesmos e os respectivos tempos de execução.

2 Atividades de transferência de conhecimento

Sumarizamos a seguir as principais atividades de transferência de conhecimento da equipe técnica executora para a equipe do Inep.

1. Documentação técnica provida ao Inep:
 - (a) Documentação do Produto 01, intitulado *Relatório sobre o panorama internacional e o contexto do Inep a respeito dos métodos de tratamento de controle de privacidade na divulgação estatística*);
 - (b) Documentação do Produto 02, intitulado *Relatório sobre os riscos à privacidade decorrentes da atual forma de divulgação dos microdados dos Censos Educacionais do Inep*); e
 - (c) Documentação do Produto 03, intitulado *Relatório técnico sobre métodos de tratamento aplicáveis aos microdados de divulgação dos Censos Educacionais do Inep*).
2. Apresentações técnicas para a equipe do Inep:
 - (a) Apresentação do contexto do presente TED 8750 em 20/05/2020.
 - (b) Apresentação técnica dos resultados do Produto 01 em 22/07/2020.
 - (c) Apresentação técnica dos resultados do Produto 02 em 06/09/2020.
3. Reuniões para discussão técnica:
 - (a) Entre a entrega do Produto 03 em 25/09/2020 e a decisão do Inep no final de novembro de 2020, foram realizadas pelo menos 3 reuniões para discussão técnica entre a equipe executora da UFMG e a equipe do Inep.
4. Minicurso tutorial sobre como utilizar a ferramenta ARX ¹ ministrado em 07/10/2020.

¹<https://arx.deidentifier.org>

3 Recursos utilizados na execução do Produto 02

O Produto 02 do presente TED, intitulado *Relatório sobre os riscos à privacidade decorrentes da atual forma de divulgação dos microdados dos Censos Educacionais do Inep*, teve como peça central a realização de milhares de ataques individuais e coletivos, tanto de reidentificação quanto de inferência de atributo sensível, aos registros presentes nas bases do Censo da Educação Básica e do Censo da Educação Superior divulgadas pelo Inep em diferentes anos.

Descrevemos a seguir o ambiente de execução utilizado nesses ataques, assim como os requisitos mínimos para a reprodução dos mesmos e os respectivos tempos de execução.

3.1 *Hardware*

Todos os experimentos para o Produto 02 do presente TED foram realizados no servidor do laboratório INSCRIPT.

As configurações de *hardware* do servidor utilizado à época são detalhadas a seguir:

- *Motherboard*: Supermicro X9DRi-LN4+/X9DR3-LN4+;
- *Central Processor Unit*: 1x Intel Xeon Processor E5-2620 v2 (socket: FCLGA2011);
- *Random Access Memory*: 6x 16GB DDR3-1866 RDIMM (total: 96GB).

3.2 *Software*

Todos os experimentos para o Produto 02 do presente TED foram realizados sob as mesmas configurações de *software*.

As configurações de *software* do servidor utilizado à época são detalhadas a seguir:

- *Operational System*: Debian 10.4;

- *Programming Language*: Python 3.7.

As seguintes bibliotecas da linguagem de programação Python foram utilizadas e instaladas a partir do Python pip *package-management system*:

- numpy 1.18.4;
- pandas 1.0.5;
- notebook 6.0.3.

3.3 Performance

O código implementado para a realização dos ataques coletivos, tanto de reidentificação quanto de inferência de atributo sensível, levou em consideração todos os recursos de *hardware* disponíveis, i.e., as 12 *threads* da *Central Processor Unit* e os 96GB de *Random Access Memory*. Além disso, os ataques de reidentificação foram realizados simultaneamente aos de inferência de atributo sensível, para todos os atributos sensíveis selecionados, dado um conjunto de atributos quaseidentificadores.

3.3.1 Ataques em uma única base de dados

Apresentamos os modelos para os ataques coletivos em uma única base de dados no Produto 02 do presente TED, mais especificamente no Capítulo 3.3 *Ataque de reidentificação coletiva em uma única base de dados (RCU)* e no Capítulo 3.5 *Ataque de inferência de atributo coletiva em uma única base de dados (ACU)*. Já os respectivos resultados para os experimentos realizados foram apresentados nos Capítulos 4.3 e 4.5 do Produto 02.

Para a base de dados do Censo da Educação Superior de 2018, foram selecionados 11 atributos quaseidentificadores, apresentados na Tabela 3.3.1a, e 2 atributos sensíveis, apresentados na Tabela 3.3.2a. Além disso, como discutido no Produto 02, Capítulo 4.1 *Configuração dos experimentos em uma única base*, foi mantido apenas um registro aleatoriamente escolhido para cada aluno. Dessa forma, uma vez realizado o tratamento, a base de dados passou a apresentar 10 811 601 registros, de um total de 12 043 994.

Dadas as configurações de *hardware* e *software* apresentadas nas Seções 3.1 e 3.2 do presente documento, respectivamente, e a base de dados tratada para o Censo da Educação Superior de 2018, os experimentos realizados sobre os 2047 diferentes conjuntos de atributos quaseidentificadores levaram um total de, aproximadamente, 17 horas para serem executados por completo.

Já para a base de dados do Censo da Educação Básica de 2019, foram selecionados 10 atributos quaseidentificadores, apresentados na Tabela 3.3.1b, e 2 atributos sensíveis, apresentados na Tabela 3.3.2b. Além disso, como discutido no Produto 02, Capítulo

4.1 *Configuração dos experimentos em uma única base*, foi mantido apenas um registro aleatoriamente escolhido para cada aluno. Dessa forma, uma vez realizado o tratamento, a base de dados passou a apresentar 47 640 822 registros, de um total de 51 166 723.

Dadas as configurações de *hardware* e *software* apresentadas nas Seções 3.1 e 3.2 do presente documento, respectivamente, e a base de dados tratada para o Censo da Educação Básica de 2019, os experimentos realizados sobre os 1 023 diferentes conjuntos de atributos quaseidentificadores levaram um total de, aproximadamente, 8 horas para serem executados por completo.

3.3.2 Ataques em base de dados longitudinal

Apresentamos os modelos para os ataques coletivos em base de dados longitudinal no Produto 02 do presente TED, mais especificamente no Capítulo 5.3 *Ataque de reidentificação coletiva longitudinal (RCL)* e no Capítulo 5.5 *Ataque de inferência de atributo coletiva longitudinal (ACL)*. Já os respectivos resultados para os experimentos realizados foram apresentados nos Capítulos 6.3 e 6.5 do Produto 02.

Para o Censo da Educação Superior, utilizamos a base de dados de 2014 como base focal e as bases de dados de 2015, 2016 e 2017 como bases auxiliares. Dessa forma, selecionamos o código da Instituição de Ensino Superior (CO_IES) e o código do curso (CO_CURSO) como atributos quaseidentificadores, conforme Tabela 3.3.3a, e dois atributos sensíveis, conforme Tabela 3.3.4a. Além disso, como discutido no Produto 02, Capítulo 6.1 *Configuração dos experimentos longitudinais*, foi mantido apenas um registro aleatoriamente escolhido para cada aluno. Dessa forma, uma vez realizado o tratamento, a base de dados focal passou a apresentar 9 773 350 registros, de um total de 10 793 936.

Dadas as configurações de hardware e software apresentadas nas Seções 3.1 e 3.2, respectivamente, e a base de dados tratada para o Censo da Educação Superior de 2014, os experimentos realizados sobre as agregações longitudinais das bases de dados de 2015, 2016 e 2017 levaram um total de, aproximadamente, 2 horas para serem executados por completo.

Para o Censo da Educação Básica, também utilizamos a base de dados de 2014 como base focal e as bases de dados de 2015, 2016 e 2017 como bases auxiliares. Dessa forma, selecionamos o código do município (FK_COD_MUNICIPIO_END), o código da entidade (PK_COD_ENTIDADE) e o código da etapa de ensino (FK_COD_ETAPA_ENSINO) como atributos quaseidentificadores, conforme Tabela 3.3.3b, e dois atributos sensíveis, conforme Tabela 3.3.4b. Além disso, como discutido no Produto 02, Capítulo 6.1 *Configuração dos experimentos longitudinais*, foi mantido apenas um registro aleatoriamente escolhido para cada aluno. Dessa forma, uma vez realizado o tratamento, a base de dados focal passou a apresentar 49 491 319 registros, de um total de 56 064 675.

Dadas as configurações de hardware e software apresentadas nas Seções 3.1 e 3.2, respectivamente, e a base de dados tratada para o Censo da Educação Básica de 2014, os experimentos realizados sobre as agregações longitudinais das bases de dados de 2015,

Variável	Interpretação
NU_DIA_NASCIMENTO	Dia de nascimento do aluno.
NU_MES_NASCIMENTO	Mês de nascimento do aluno.
NU_ANO_NASCIMENTO	Ano de nascimento do aluno.
TP_SEXO	Gênero do aluno.
TP_COR_RACA	Etnia do aluno.
TP_NACIONALIDADE	Nacionalidade do aluno.
CO_PAIS_ORIGEM	Código do país de origem do aluno.
CO_MUNICIPIO_NASCIMENTO	Código do município de nascimento do aluno.
CO_IES	Código da Instituição de Ensino Superior (IES).
CO_CURSO	Código do curso da IES ao qual o aluno está matriculado.
TP_ESCOLA_CONCLUSAO_ENS_MEDIO	Dependência administrativa da escola na qual o aluno concluiu o Ensino Médio.

(a) Variáveis do Censo da Educação Superior de 2018 selecionadas como candidatas a quaseidentificadores em ataques de reidentificação coletiva (RCU) e em ataques de inferência de atributo coletiva (ACU).

Variável	Interpretação
NU_MES	Mês de nascimento do aluno.
NU_ANO	Ano de nascimento do aluno.
TP_SEXO	Gênero do aluno.
TP_COR_RACA	Etnia do aluno.
TP_NACIONALIDADE	Nacionalidade do aluno.
CO_PAIS_ORIGEM	Código do país de origem do aluno.
CO_MUNICIPIO_NASC	Código do município de nascimento do aluno.
CO_MUNICIPIO_END	Código do município de residência do aluno.
CO_ENTIDADE	Código da escola.
TP_DEPENDENCIA	Dependência administrativa da escola.

(b) Variáveis do Censo da Educação Básica de 2019 selecionadas como candidatas a quaseidentificadores em ataques de reidentificação coletiva (RCU) e em ataques de inferência de atributo coletiva (ACU). Apesar de presente no dicionário de variáveis disponibilizado com os dados do Censo da Educação Superior de 2019, a variável referente ao atributo dia de nascimento do aluno (NU_DIA_NASCIMENTO) não foi encontrada no arquivo correspondente publicado pelo Inep e, portanto, não pôde ser considerada aqui como candidata a quaseidentificador.

Tabela 3.3.1: Atributos usados como candidatos a quaseidentificadores nos experimentos de ataques em uma única base de dados.

Variável	Valores	Interpretação
IN_DEFICIENCIA	0 (Não) 1 (Sim) 9 (Sem resposta)	Aluno com deficiência, transtorno global do desenvolvimento ou altas habilidades/superdotação.
IN_FINANCIAMENTO_ESTUDANTIL	-1 (Indisponível) 0 (Não) 1 (Sim)	Uso de financiamento estudantil por parte do aluno.

(a) Atributos sensíveis utilizados nos ataques de inferência de atributo coletiva em uma única base (ACU) no Censo da Educação Superior de 2018.

Variável	Valores	Interpretação
IN_NECESSIDADE_ESPECIAL	0 (Não) 1 (Sim)	Aluno com deficiência, transtorno do espectro autista ou altas habilidades/superdotação.
IN_TRANSPORTE_PUBLICO	-1 (Indisponível) 0 (Não) 1 (Sim)	Uso de transporte escolar público por parte do aluno.

(b) Atributos sensíveis utilizados nos ataques de inferência de atributo coletiva em uma única base (ACU) no Censo da Educação Básica de 2019.

Tabela 3.3.2: Atributos sensíveis usados nos experimentos de ataques em uma única base de dados.

Variável	Interpretação
CO_IES	Código da Instituição de Ensino Superior (IES).
CO_CURSO	Código do curso da IES ao qual o aluno está matriculado.

(a) Variáveis do Censo da Educação Superior de 2014 selecionadas como candidatas a quaseidentificadores em ataques de reidentificação coletiva (RCL) e em ataques de inferência de atributo coletiva (ACL).

Variável	Interpretação
FK_COD_MUNICIPIO_END	Código do município de residência do aluno.
PK_COD_ENTIDADE	Código da escola.
FK_COD_ETAPA_ENSINO	Código da etapa de ensino do aluno.

(b) Variáveis do Censo da Educação Básica de 2014 selecionadas como candidatas a quaseidentificadores em ataques de reidentificação coletiva (RCL) e em ataques de inferência de atributo coletiva (ACL).

Tabela 3.3.3: Atributos usados como candidatos a quaseidentificadores nos experimentos de ataques longitudinais.

2016 e 2017 levaram um total de, aproximadamente, 2 horas para serem executados por completo.

Na Tabela 3.3.5 esses dados estão resumidos.

Variável	Valores	Interpretação
IN_ALUNO_DEF_TGD_SUPER	0 (Não) 1 (Sim) 2 (Sem informação)	Aluno com deficiência, transtorno global do desenvolvimento ou altas habilidades/superdotação.
IN_FINANC_ESTUDANTIL	-1 (Indisponível) 0 (Não) 1 (Sim)	Uso de financiamento estudantil por parte do aluno.

(a) Atributos sensíveis utilizados nos ataques de inferência de atributo coletiva longitudinal (ACL) com o Censo da Educação Superior de 2014 como base focal.

Variável	Valores	Interpretação
ID_POSSUI_NEC_ESPECIAL	0 (Não) 1 (Sim)	Aluno com deficiência, transtorno global do desenvolvimento ou altas habilidades/superdotação.
ID_N_T_E_P	0 (Não) 1 (Sim)	Uso de transporte escolar público por parte do aluno.

(b) Atributos sensíveis utilizados nos ataques de inferência de atributo coletiva longitudinal (ACL) com o Censo da Educação Básica de 2014 como base focal.

Tabela 3.3.4: Atributos sensíveis usados nos experimentos de ataques longitudinais.

Tipo ataque	Censo	Ano(s)	Qids	As	Registros	Tempo
base única (RCU+ACU)	Ed. Superior	2018	11	2	10,8 mi	17 horas
base única (RCU+ACU)	Ed. Básica	2019	10	2	47,6 mi	8 horas
longitudinal (RCL+ACL)	Ed. Superior	2014-2017	2	2	9,7 mi	2 horas
longitudinal (RCL+ACL)	Ed. Básica	2014-2017	3	2	49,4 mi	2 horas

Tabela 3.3.5: Resumo dos ataques e o tempo de execução na plataforma. Qids significa quaseidentificadores, As significa atributos sensíveis

TED 8750 - PRICE

PRIVACIDADE NOS CENSOS EDUCACIONAIS

Termo de Execução Descentralizada entre o Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira - Inep e a Universidade Federal de Minas Gerais - UFMG

PRODUTO 07

Relatório de operação assistida



Mário S. ALVIM
Ramon G. GONZE
Jeroen van de GRAAF

Igor W. LEMES
Lucas LOPES
Gabriel H. NUNES

09 de abril de 2021

Resumo

O presente documento consiste em um *Relatório de operação assistida*, previsto como Produto 07 no plano de trabalho do Termo de Execução Descentralizada (TED) 8750. Este TED foi firmado entre o Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira (Inep) e a Universidade Federal de Minas Gerais (UFMG), e encontra-se em execução pelo Laboratório Inscript (*Laboratory of Information Security, Cryptography, Privacy, and Transparency*) do Departamento de Ciência da Computação (DCC) da Universidade.

A constatação da inviabilidade de manutenção no curto prazo da divulgação de microdados dos Censos Educacionais de forma privada e útil, ocorrida como resultado do Produto 04 (*Solução tecnológica e sua documentação*) e do Produto 05 (*Relatório técnico final do projeto piloto*), impactou os objetivos dos produtos subsequentes do plano de trabalho. Em particular, o objetivo central do Produto 07 deixou de ser a documentação do processo de operação assistida, o qual apresentaria a aplicação, por parte da equipe do Inep, da solução a um conjunto de microdados diferente do piloto no ambiente real do Inep. Por outro lado, seguem sendo requeridas e desenvolvidas as ações de transferência de tecnologia, incluindo o desenvolvimento de conhecimento técnico, a especificação de um ambiente computacional adequado para a execução dos experimentos e outras atividades de tratamento de dados para o controle de divulgação estatística, além da documentação e o suporte à equipe para a compreensão dos processos envolvidos.

Neste sentido, a transferência passou a focar-se no conhecimento gerado pelo projeto piloto, que é crucial para as futuras tomadas de decisão do Inep sobre a divulgação dos Censos Educacionais, ponderando-se entre soluções de curto prazo e soluções de longo prazo. Adicionalmente, este conhecimento provê ao Inep subsídios para uma efetiva comunicação com as partes interessadas nos Censos Educacionais sobre os desafios técnicos da adequação da divulgação de microdados à LGPD. Isto pode auxiliar tais partes a compreenderem as nuances de futuras decisões do Inep –eventualmente, inclusive, sobre formas de divulgação que restrinjam microdados.

Neste documento apresentamos as formas de transferência de conhecimento da equipe executora para a equipe do Inep empregadas neste TED 8750. Tais formas incluem, além das entregas dos produtos previstos no plano de trabalho, também reuniões técnicas e deliberativas e treinamentos da equipe do Inep.

Sumário

1	Introdução	1
1.1	Objetivo deste documento	1
1.2	Contextualização	2
1.3	Organização deste documento	4
2	Histórico de execução do projeto até o momento	5
3	Atividades complementares para transferência de conhecimento e tecnologia	10
4	Considerações finais	13
	Referências Bibliográficas	14
	Lista de Siglas	15

Lista de Tabelas

2.0.1	Estado de execução dos produtos previstos no plano de trabalho.	9
3.0.1	Reuniões e discussões técnicas entre equipe executora da UFMG e o Inep.	11
3.0.2	Treinamento da equipe do Inep.	12

1 Introdução

Este documento consiste no Produto 07, intitulado *Relatório de operação assistida*, do plano de trabalho do Termo de Execução Descentralizada (TED) 8750, firmado entre o Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira (Inep) e a Universidade Federal de Minas Gerais (UFMG), e em execução pelo Laboratório Inscrypt (*Laboratory of Information Security, Cryptography, Privacy, and Transparency*) do Departamento de Ciência da Computação (DCC) da Universidade.

1.1 Objetivo deste documento

De acordo com o plano de trabalho original do TED 8750, o Produto 07 que este documento implementa consiste em:

Documentação do processo de operação assistida, o qual apresentará a aplicação, por parte da equipe do Inep, da solução a um conjunto de microdados diferente do piloto no ambiente real do Inep, afim de contribuir na internalização do conhecimento e eliminação de possíveis falhas.

Mais especificamente, em conjunto com o Produto 04, visa-se a atender aos Objetivos Específicos 06 e 07 do plano de trabalho:

Desenvolver capacidade técnica no Instituto para o tratamento de dados pessoais conforme as disposições da legislação vigente e as melhores práticas internacionais do setor.

Aplicar o conjunto de métodos de controle de divulgação por meio do processo computacional desenvolvido em outro conjunto de microdados dos Censos Educacionais, com suporte e assistência técnica, de forma a possibilitar a internalização da tecnologia desenvolvida e garantir aderência às disposições da legislação vigente.

Entretanto, como contextualizado na próxima seção, o plano de trabalho original foi alterado por apostilamento em resposta a informações relevantes obtidas durante a execução

do presente TED 8750. Mais especificamente, o foco deste Produto 07 deixou de ser o treinamento e acompanhamento da equipe do Inep para emprego interno ao Instituto do processo computacional produzido no projeto piloto. Em vez disso, o presente produto se foca em ações requeridas e desenvolvidas para transferência de tecnologia, incluindo o desenvolvimento de conhecimento técnico, a especificação de um ambiente computacional adequado para a execução dos experimentos e outras atividades de tratamento de dados para o controle de divulgação estatística, a documentação e o suporte à equipe para a compreensão dos processos envolvidos.

1.2 Contextualização

No Produto 02 (*Relatório sobre os riscos à privacidade decorrentes da atual forma de divulgação dos microdados dos Censos Educacionais do Inep*) deste TED 8750 provemos extensivas análises quantitativas experimentais sobre a atual forma de divulgação dos dados dos Censos Educacionais pelo Inep, consistindo apenas em *desidentificação* –em que se removem possíveis identificadores individuais óbvios dos registros, como nome, CPF e RG– e em *pseudonimização* –em que tais identificadores individuais óbvios são substituídos por um código único de identificação artificialmente criado. Tais análises demonstraram de forma inequívoca que esta abordagem submete os titulares dos dados a sérios e generalizados riscos de violação de privacidade, em especial aos de reidentificação e de inferência de atributos sensíveis. Em nossa visão esta situação poderia constituir em uma violação da Lei Geral de Proteção de Dados Pessoais (LGPD) [1].

Nos Produtos 04 (*Solução tecnológica e sua documentação*) e 05 (*Relatório técnico final do projeto piloto*) apresentamos várias análises experimentais quantitativas sobre a privacidade e a utilidade de dados providas pelos dois métodos de sanitização selecionados pelo Inep para o projeto piloto deste TED: amostragem e privacidade diferencial local. As análises foram realizadas sobre os dados do Censo da Educação Básica de 2019. Tais análises evidenciaram a inviabilidade da manutenção no curto prazo da divulgação de microdados dos Censos Educacionais de forma privada e útil. Tal constatação está em consonância com a literatura técnica em controle de divulgação estatística.

Entretanto, em nossos relatórios ressaltamos que não se deve concluir que não há solução possível para divulgação dos dados dos Censos de forma privada e com razoável utilidade, mas sim que é necessária uma criteriosa ponderação sobre passos futuros. Neste sentido, identificamos no Produto 05 alternativas para tratamento dos dados pelo Inep no futuro:

- **Alternativa 1:** Abandono da divulgação de microdados –exceto em salas seguras– em favor da divulgação de dados agregados sanitizados por privacidade diferencial. Conforme plano de ação proposto no Produto 03 deste TED 8750, avaliamos esta opção como a mais promissora para os Censos Educacionais do Inep.
- **Alternativa 2:** Desenvolvimento de um método de sanitização de microdados por privacidade diferencial local desenhado e refinado especificamente para Censos

Educacionais. Esta opção demandaria tempo e recursos significativamente maiores, incluindo atividades de pesquisa e desenvolvimento.

A eventual implementação de alguma das alternativas acima, entretanto, está fora do escopo deste TED 8750. A constatação da inviabilidade de manutenção de microdados no curto prazo impactou, portanto, os objetivos de produtos seguintes no plano de trabalho.

Mais especificamente, o objetivo central do Produto 07 deixou de ser a documentação do processo de operação assistida, o qual apresentaria a aplicação, por parte da equipe do Inep, da solução a um conjunto de microdados diferente do piloto no ambiente real do Inep.¹ Por outro lado, seguem sendo requeridas e desenvolvidas as ações de transferência de tecnologia, incluindo o desenvolvimento de conhecimento técnico, a especificação de um ambiente computacional adequado para a execução dos experimentos e outras atividades de tratamento de dados para o controle de divulgação estatística, além da documentação e o suporte à equipe para a compreensão dos processos envolvidos. Portanto, a transferência passou a focar-se no conhecimento gerado pelo projeto piloto, que, em nossa visão, é crucial por dois motivos principais:

- Este conhecimento é crucial para as futuras tomadas de decisão do Inep sobre a divulgação dos Censos Educacionais, ponderando-se entre soluções de curto prazo –implementáveis de forma relativamente rápida, mas potencialmente sub-ótimas quanto à utilidade provida– e soluções de longo prazo –mais úteis, porém que demandam maior investimento de tempo e pessoal especializado.
- Este conhecimento provê ao Inep subsídios para uma efetiva comunicação com as partes interessadas nos Censos Educacionais sobre os desafios técnicos da adequação da divulgação de microdados à LGPD. Isto pode auxiliar tais partes a compreenderem as nuances de futuras decisões do Inep –eventualmente, inclusive, sobre formas de divulgação que restrinjam microdados.

De fato, já observamos que a opção por qualquer método de mitigação deve passar pela harmonização de interesses possivelmente conflitantes de vários atores. No caso dos Censos Educacionais do Inep, os atores incluem os titulares de dados (estudantes, professores, escolas, etc.), analistas (demógrafos, entidades civis e governamentais, etc.), o governo (que regulamenta tanto questões de privacidade quanto de transparência e acesso à informação), além do próprio Inep (que tem que conciliar de forma realista as demandas dos vários atores com a sua capacidade operacional e recursos para atendê-las).

Neste sentido, o presente documento apresenta as formas de transferência de conhecimento da equipe executora para a equipe do Inep empregadas neste TED 8750.

¹Apesar de o foco ter sido alterado, todo o código fonte necessário para uma eventual aplicação dos métodos do projeto piloto por parte do Inep, incluindo manuais e documentação, foram fornecidos ao Inep no Produto 04.

1.3 Organização deste documento

O restante deste documento está organizado da seguinte forma.

- **Histórico de execução do projeto até o momento** (Seção 2): Nesta seção resumizamos o histórico de execução do projeto até o momento, destacando os principais conhecimentos produzidos e transmitidos ao Inep.
- **Atividades complementares para transferência de conhecimento e tecnologia** (Seção 3): Nesta seção resumizamos as atividades de transferência de conhecimento e tecnologia que são complementares à entrega dos produtos em si, incluindo reuniões, treinamentos e *workshops*.
- **Considerações finais** (Seção 4): Nesta seção apresentamos as considerações finais deste documento.

2 Histórico de execução do projeto até o momento

Nesta seção resumizamos o histórico de execução do projeto até o momento, destacando os principais conhecimentos produzidos e transmitidos ao Inep.

A Tabela 2.0.1 apresenta o estado de execução dos produtos previstos no plano de trabalho, incluindo aqueles entregues. Descrevemos estes produtos a seguir.

- **Produto 01:** *Relatório sobre o panorama internacional e o contexto do Inep a respeito dos métodos de tratamento de controle de privacidade na divulgação estatística.*

Neste produto apresentamos, através de vários estudos de caso, um panorama internacional e um nacional de como institutos produtores de estatísticas oficiais equilibram requisitos de transparência e de proteção à privacidade em seus métodos de divulgação de informação.

Em todos os casos internacionais estudados, os órgãos produtores de estatísticas oficiais adotam medidas mais rígidas do que as do Inep na mitigação de danos à privacidade causados por publicação de microdados. Tais medidas incluem, e.g., a não publicação de microdados individuais de estudantes sob nenhuma forma, a publicação de microdados apenas por amostras da população, ou a permissão de acesso a todo o conjunto de microdados apenas sob autorização prévia, de acordo com os objetivos do pesquisador ou indivíduo interessado, e em salas seguras.

- **Produto 02:** *Relatório sobre os riscos à privacidade decorrentes da atual forma de divulgação dos microdados dos Censos Educacionais do Inep.*

Neste produto provemos extensivas análises quantitativas experimentais sobre a atual forma de divulgação dos dados dos Censos Educacionais pelo Inep, consistindo apenas em *desidentificação* –em que se removem possíveis identificadores individuais óbvios dos registros, como nome, CPF e RG– e em *pseudonimização* –em que tais identificadores individuais óbvios são substituídos por um código único de identificação artificialmente criado. Tais análises demonstraram de forma inequívoca que esta abordagem submete os titulares dos dados a sérios e generalizados

riscos de violação de privacidade, em especial aos de reidentificação e de inferência de atributos sensíveis. Em nossa visão esta situação poderia constituir em uma violação da Lei Geral de Proteção de Dados Pessoais (LGPD) [1].

- **Produto 03:** *Relatório técnico sobre métodos de tratamento aplicáveis aos microdados de divulgação dos Censos Educacionais do Inep.*

Neste produto provemos um parecer técnico sobre a adequação de variadas técnicas de mitigação de danos à privacidade aos Censos Educacionais do Inep. Em particular, consideramos que a LGPD prevê garantias de privacidade individualmente a cada titular de dados –em especial, contra reidentificação– que devem ser atendidas pelos Censos Educacionais. Também consideramos que qualquer método adotado devesse manter a maior utilidade possível para os analistas e consumidores dos dados dos Censos.

À época observamos que o Inep dispunha de um prazo exíguo para implementação de uma solução coerente com a nova legislação. Sugerimos, então, a adoção de uma solução emergencial que garantisse no curto prazo a privacidade dos titulares –mesmo que fosse possivelmente sub-ótima em relação à utilidade provida aos analistas (ou vice-versa)–, enquanto elaborar-se-ia uma alternativa de longo prazo que fornecesse um melhor custo-benefício na relação entre privacidade e utilidade.

O plano emergencial proposto na ocasião consistia, essencialmente, em eliminar imediatamente a divulgação de microdados sob qualquer forma que não fosse via salas seguras (físicas ou virtuais) e oferecer apenas informações agregadas (sumários estatísticos ou histogramas) em canais públicos de comunicação, protegidos por privacidade diferencial. Uma vez assegurado o nível de privacidade individual dos dados demandado pela LGPD (obtido nos passos anteriores), proceder-se-ia a um estudo aprofundado de como aumentar a utilidade das divulgações enquanto manter-se-ia a privacidade conquistada. Tal aumento gradual da utilidade dos dados visaria a satisfazer a um número cada vez maior de analistas, o que poderia contribuir para arrefecer a demanda suplementar por acesso a salas seguras eventualmente causada pela implementação da solução emergencial.

Como previsto no plano de trabalho, as recomendações do Produto 03 foram profundamente discutidas entre a equipe executora do presente TED 8750 e os representantes do Inep, a fim de suportar uma tomada de decisão bem informada.

Após discussão e deliberação, o Inep optou por manter o foco deste TED 8750 na avaliação da viabilidade de divulgação de microdados, descartando no presente momento soluções baseadas na divulgação de dados agregados. A decisão fundamentou-se na premissa de que, apesar de haver indícios fortes na literatura de que a divulgação de microdados no tempo exíguo disponível para este TED 8750 pudesse não atingir um nível aceitável no compromisso entre privacidade e utilidade, era importante averiguar tal fato empiricamente. Tal constatação proveria suporte técnico para eventuais tomadas de decisão do Inep, justificando-as perante outras partes interessadas (i.e., titulares de dados, analistas e entidades

governamentais).

Neste sentido, as abordagens escolhidas para avaliação no projeto piloto foram a *sanitização por amostragem não-perturbativa* e a *sanitização por privacidade diferencial- ϵ local*. Além disso, fixou-se como dados de estudo a base do Censo da Educação Básica de 2019.

- **Produto 04:** *Solução tecnológica e sua documentação.*

Este produto contém a solução tecnológica para o tratamento da base de dados da pesquisa escolhida para o projeto piloto após o Produto 03. O presente documento inclui a documentação e componentes da solução tecnológica desenvolvida, bem como os requisitos e configurações necessárias para a aplicação a outras bases de dados no ambiente computacional do Inep. Além disso, instruímos o Inep a como ter acesso às bases sanitizadas criadas no projeto piloto.

- **Produto 05:** *Relatório técnico final do projeto piloto.*

Neste produto apresentamos várias análises experimentais quantitativas sobre a privacidade e a utilidade de dados providas pelos dois métodos de sanitização selecionados pelo Inep para o projeto piloto deste TED: amostragem e privacidade diferencial local. As análises foram realizadas sobre os dados do Censo da Educação Básica de 2019. Além disso, provemos uma análise comparativa da privacidade e utilidade atingidas por cada método de sanitização empregado. Adotamos a métrica de propósito geral de utilidade estatística, que mede a similaridade entre a distribuição de probabilidade sobre atributos antes e após a sanitização.

Os resultados encontrados evidenciaram a inviabilidade da manutenção no curto prazo da divulgação de microdados dos Censos Educacionais de forma privada e útil. Tal constatação está em consonância com a literatura técnica em controle de divulgação estatística e constitui uma contribuição central do projeto piloto. Observamos, por fim que os resultados obtidos foram naturalmente impactados pelo exíguo prazo disponível para adequação da divulgação de microdados dos Censos Educacionais à LGPD.

- **Produto 06:** *Relatório técnico de implantação.*

À luz dos resultados obtidos no projeto piloto dos Produtos 04 e 05, o objetivo central do Produto 06 deixou de ser a transferência de tecnologia de como aplicar tais técnicas aos dados dos Censos Educacionais do Inep, uma vez que elas não necessariamente seriam postas em produção –mesmo que seus resultados experimentais fossem essenciais para tomada de decisão futura.

Dessa forma, neste produto detalhamos os recursos computacionais usados para execução dos ataques no Produto 02 (*Relatório sobre os riscos à privacidade decorrentes da atual forma de divulgação dos microdados dos Censos Educacionais do Inep*) e das análises quantitativas experimentais do Produto 04 (*Solução tecnológica e sua documentação*) e do Produto 05 (*Relatório técnico final do projeto piloto*). O

objetivo do produto é tornar possível ao Inep estimar quais recursos precisaria caso deseje reproduzir e explorar os resultados destes Produtos em maior profundidade.

Produto	Título	Descrição	Entregue
Produto 01	<i>Relatório sobre o panorama internacional e o contexto do Inep a respeito dos métodos de tratamento de controle de privacidade na divulgação estatística</i>	Relatório com o panorama internacional sobre o tratamento de dados com vistas a garantir a transparência das pesquisas e privacidade dos dados pessoais na divulgação estatística de outros institutos produtores de estatísticas oficiais, incluindo a contextualização da situação do Inep.	15 de junho de 2020 (revisado em 03 de julho de 2020)
Produto 02	<i>Relatório sobre os riscos à privacidade decorrentes da atual forma de divulgação dos microdados dos Censos Educacionais do Inep</i>	Documento técnico apresentando os riscos de divulgação inapropriada no conjunto de microdados dos Censos da Educação Básica e da Educação Superior e a definição do escopo do projeto piloto.	14 de agosto de 2020 (revisado em 06 de setembro de 2020)
Produto 03	<i>Relatório técnico sobre métodos de tratamento aplicáveis aos microdados de divulgação dos Censos Educacionais do Inep</i>	Documento técnico com a apresentação e a discussão comparativa dos métodos de tratamento aplicáveis aos microdados de divulgação pública do Censo da Educação Básica e do Censo da Educação Superior, realizados pelo Inep.	25 de setembro de 2020
Produto 04	<i>Solução tecnológica e sua documentação</i>	Documento técnico com a apresentação da solução tecnológica para o tratamento da base de dados da pesquisa escolhida para o projeto piloto, incluindo manual, documentação e componentes da solução tecnológica desenvolvida, bem como os requisitos e configurações necessárias para a aplicação a outras bases de dados no ambiente computacional no Inep.	12 de fevereiro de 2021 (revisado em 26 de fevereiro de 2021)
Produto 05	<i>Relatório técnico final do projeto piloto</i>	Relatório técnico apresentando os resultados do projeto piloto, mudanças e replanejamento do plano de execução inicial, comparação entre os métodos testados, lições aprendidas, nível de atendimento ao escopo e aos objetivos definidos para a aplicação.	05 de fevereiro de 2021 (revisado em 26 de fevereiro de 2021)
Produto 06	<i>Relatório técnico de implantação</i>	Documento técnico apresentando o relatório das atividades de transferência de tecnologia e de validação analítica do ambiente de execução do Inep.	23 de dezembro de 2020 (revisado em 26 de fevereiro de 2021)
Produto 07	<i>Relatório de operação assistida</i>	Documentação do processo de operação assistida, o qual apresentará a aplicação, por parte da equipe do Inep, da solução a um conjunto de microdados diferente do piloto no ambiente real do Instituto, a fim de contribuir na internalização do conhecimento e eliminação de possíveis falhas.	09 de abril de 2021
Produto 08	<i>Relatório de encerramento do projeto</i>	Relatório com o resumo final do projeto, incluindo: principais problemas e soluções; principais mudanças e replanejamento; relatório de execução das diferentes etapas e produtos, lições aprendidas; nível de atendimento aos objetivos do projeto; execução financeira; e Termo de Aceite assinado pelo demandante.	A entregar.

Tabela 2.0.1: Estado de execução dos produtos previstos no plano de trabalho.

3 Atividades complementares para transferência de conhecimento e tecnologia

Em complementação à entrega dos produtos em si, as atividades de transferência de conhecimento e tecnologia empregadas no projeto consistiram principalmente em reuniões técnicas e deliberativas, além de treinamentos da equipe do Inep. A Tabela 3.0.1 sumariza as reuniões e discussões técnicas, enquanto a Tabela 3.0.2 sumariza o treinamento da equipe do Inep.

Adicionalmente, mantivemos a disponibilidade para suporte ao Inep em demandas de implantação que surgissem durante as fases finais do projeto.

Além das atividades listadas acima, prevemos como atividade de transferência de conhecimento o auxílio ao Inep na organização de um *workshop* sobre os resultados obtidos no presente projeto e alternativas futuras. Tal *workshop* está previsto para abril de 2021 e deve contar com a participação de integrantes de variadas diretorias do Inep, além de possivelmente integrantes de outros órgãos produtores de estatísticas oficiais nacionais.

Data	Tópico da reunião	Sumário
20 de maio de 2020	Apresentação inicial do escopo do TED 8750	Apresentação às partes interessadas do Inep sobre o TED 8750. Discussão de seus objetivos gerais e específicos, etapas, resultados esperados e cronograma de atividades.
22 de julho de 2020	Apresentação e discussão dos resultados obtidos no Produto 01	Apresentação às partes interessadas do Inep sobre os panoramas internacional e nacional de como órgãos estatísticos divulgam seus dados. Contextualização e discussão da situação dos Censos Educacionais do Inep.
05 de outubro de 2020	Apresentação e discussão dos resultados obtidos no Produto 02	Apresentação às partes interessadas do Inep sobre os atuais riscos de reidentificação e inferência de atributos decorrentes da atual forma de divulgação dos Censos Educacionais por parte do Inep. Discussão sobre as possíveis consequências das descobertas e da adequação dos métodos atuais à LGPD.
09 de novembro de 2020	Apresentação do Produto 03 e discussão sobre o escopo do projeto piloto.	Apresentação às partes interessadas do Inep das diferentes técnicas de mitigação a danos de privacidade aplicáveis aos Censos Educacionais do Inep. Discussão de prós e contras de cada método.
17 de novembro de 2020	Reunião para definição do escopo do projeto piloto.	Discussão aprofundada sobre o escopo do projeto piloto. Definição da base a ser utilizada como sendo a do Censo do Ensino Básico de 2019. Definição dos métodos de tratamento de microdados a serem analisados como sendo sanitização por amostragem e sanitização por privacidade diferencial local.
03 de março de 2021	Apresentação e discussão dos resultados obtidos nos Produtos 04 e 05	Apresentação às partes interessadas do Inep sobre os resultados obtidos no projeto piloto, que evidenciam a inviabilidade da manutenção no curto prazo da divulgação de microdados dos Censos Educacionais de forma privada e útil. Discussão de como tais resultados estão em consonância com o conhecimento técnico na área de divulgação estatística. Apresentação de alternativas futuras baseadas em divulgação de dados agregados sanitizados por privacidade diferencial ou em divulgação de microdados sanitizados por privacidade diferencial local.

Tabela 3.0.1: Reuniões e discussões técnicas entre equipe executora da UFMG e o Inep.

Data	Tópico do treinamento	Sumário
07 de outubro de 2020	Análise de risco à privacidade usando a ferramenta ARX [2].	Treinamento <i>online</i> dividido em 5 etapas: (1) Visão Geral do ARX: Introdução, apresentação da ferramenta, suas capacidades e limitações. (2) Configuração: Configuração de projeto, banco de dados e atributos. (3) Análise de risco: Análise de risco, identificação de quaseidentificadores, modelos de ataque, etc. (4) Outras aplicabilidades do ARX: Anonimização e utilidade de dados. (5) Discussão sobre dúvidas.
Fevereiro a Abril de 2021	Disponibilidade para suporte.	Suporte em eventuais demandas do Inep que surgissem durante as fases finais do projeto.

Tabela 3.0.2: Treinamento da equipe do Inep.

4 Considerações finais

Neste documento apresentamos as formas de transferência de conhecimento e tecnologia empregadas neste TED 8750. Tais formas incluíram, além das entregas dos produtos previstos no plano de trabalho, também reuniões técnicas e deliberativas e treinamentos da equipe do Inep. Adicionalmente, mantivemos a disponibilidade para suporte ao Inep em demandas de implantação que surgissem durante as fases finais do projeto.

No Produto 08 (*Relatório de encerramento do projeto*) daremos continuidade ao processo de transferência de conhecimento, provendo uma visão geral do projeto, dificuldades encontradas, e resultados obtidos.

Referências Bibliográficas

- [1] Governo do Brasil. Lei 13.709, de 14 de agosto de 2018, Lei Geral de Proteção de Dados Pessoais (LGPD). Disponível em: http://www.planalto.gov.br/ccivil_03/_ato2015-2018/2018/Lei/L13709.htm.
- [2] Fabian Prasser and Contributors. ARX - Data Anonymization Tool, 2020. Disponível em: <https://arx.deidentifier.org/>.

Lista de Siglas

DCC Departamento de Ciência da Computação da UFMG.

DEED Diretoria de Estatísticas Educacionais do Inep.

GDPR *General Data Protection Regulation*.

INEP Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira.

LDP privacidade diferencial local, em suas iniciais do inglês *local differential privacy*.

LGPD Lei Geral de Proteção de Dados Pessoais.

LGPDP Lei Geral de Proteção de Dados Pessoais.

MEC Ministério da Educação.

RGPD Regulamento Geral de Proteção de Dados.

TED Termo de Execução Descentralizada.

UFMG Universidade Federal de Minas Gerais.

TED 8750 - PRICE

PRIVACIDADE NOS CENSOS EDUCACIONAIS

Termo de Execução Descentralizada entre o Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira - Inep e a Universidade Federal de Minas Gerais - UFMG

PRODUTO 08

Relatório de encerramento do projeto



Mário S. ALVIM
Ramon G. GONZE
Jeroen van de GRAAF

Igor W. LEMES
Lucas LOPES
Gabriel H. NUNES

09 de abril de 2021

Resumo

O presente documento consiste em um *Relatório de encerramento do projeto*, previsto como Produto 08 no plano de trabalho do Termo de Execução Descentralizada (TED) 8750. Este TED foi firmado entre o Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira (Inep) e a Universidade Federal de Minas Gerais (UFMG), e encontra-se em execução pelo Laboratório Inscript (*Laboratory of Information Security, Cryptography, Privacy, and Transparency*) do Departamento de Ciência da Computação (DCC) da Universidade.

Avanços tecnológicos exigem que a sociedade reveja continuamente sua percepção sobre riscos de violação de privacidade, e em vários países, incluindo o Brasil, observa-se um fortalecimento da legislação sobre o assunto. O Inep, produtor e divulgador de várias pesquisas educacionais de relevância nacional, tem o desafio de adequar-se a estas novas exigências, encontrando soluções que conciliem privacidade e transparência na divulgação de informação. Este TED 8750 abordou tal desafio, em torno de três objetivos principais: (1) Identificação dos riscos à privacidade inerentes ao atual processo de divulgação dos Censos da Educação pelo Inep; (2) Análise de novas técnicas de divulgação aplicáveis, que melhor conciliem privacidade e transparência; e (3) Implementação de um projeto-piloto que avaliasse a adequação de duas destas técnicas aos Censos Educacionais do Inep.

Consideramos que os objetivos deste TED 8750 foram cumpridos com êxito. Foi provida ao Inep informação crucial para tomadas de decisões futuras, balanceando soluções de curto prazo –implementáveis de forma relativamente rápida, mas potencialmente sub-ótimas quanto à utilidade provida– e soluções de longo prazo –mais úteis, porém que demandam maior investimento de tempo e pessoal especializado. Esta informação ainda subsidia uma comunicação efetiva com as partes interessadas sobre os desafios técnicos na divulgação de microdados, facilitando a compreensão sobre eventuais decisões futuras.

No presente documento provemos um relatório com o resumo final do projeto, incluindo: principais problemas e soluções; principais mudanças e replanejamento; relatório de execução das diferentes etapas e produtos; lições aprendidas; e nível de atendimento aos objetivos do projeto.

Sumário

1	Introdução	1
1.1	Objetivo deste documento	1
1.2	Contextualização	1
1.3	Organização deste documento	4
2	Relatório de execução e mudanças de planejamento	5
2.1	Histórico de execução dos Produtos 01 a 06	5
2.2	Readequação dos objetivos do Produto 07	12
2.3	Atividades complementares para transferência de conhecimento e tecnologia	13
3	Principais dificuldades encontradas e suas soluções	18
3.1	Dificuldades administrativas	18
3.2	Dificuldades metodológicas	19
3.2.1	Dificuldades referentes ao Produto 01: <i>Relatório sobre o panorama internacional e o contexto do Inep a respeito dos métodos de tratamento de controle de privacidade na divulgação estatística</i>	19
3.2.2	Dificuldades referentes ao Produto 02: <i>Relatório sobre os riscos à privacidade decorrentes da atual forma de divulgação dos microdados dos Censos Educacionais do Inep</i>	20
3.2.3	Dificuldades referentes ao Produto 04: <i>Solução tecnológica e sua documentação</i> e ao Produto 05: <i>Relatório técnico final do projeto piloto</i>	20
3.2.4	Dificuldades referentes ao Produto 07: <i>Relatório de operação assistida</i>	22
3.3	Dificuldades de implementação	23

3.3.1	Dificuldades referentes ao Produto 02: <i>Relatório sobre os riscos à privacidade decorrentes da atual forma de divulgação dos microdados dos Censos Educacionais do Inep</i>	23
3.3.2	Dificuldades referentes ao Produto 03: <i>Relatório técnico sobre métodos de tratamento aplicáveis aos microdados de divulgação dos Censos Educacionais do Inep</i>	24
3.3.3	Dificuldades referentes ao Produto 04: <i>Solução tecnológica e sua documentação</i> e ao Produto 05: <i>Relatório técnico final do projeto piloto</i>	25
4	Análise de resultados obtidos	28
5	Considerações finais	32
	Referências Bibliográficas	33
	Lista de Siglas	34
	Glossário	35

Lista de Tabelas

2.0.1	Histórico de execução dos produtos previstos no plano de trabalho.	15
2.3.2	Reuniões e discussões técnicas entre equipe executora da UFMG e o Inep.	16
2.3.3	Treinamento da equipe do Inep.	17
4.0.1	Análise dos objetivos específicos previstos no plano de trabalho.	31

1 Introdução

Este documento consiste no Produto 08, intitulado *Relatório de encerramento do projeto*, do plano de trabalho do Termo de Execução Descentralizada (TED) 8750, firmado entre o Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira (Inep) e a Universidade Federal de Minas Gerais (UFMG), e em execução pelo Laboratório Inscrypt (*Laboratory of Information Security, Cryptography, Privacy, and Transparency*) do Departamento de Ciência da Computação (DCC) da Universidade.

1.1 Objetivo deste documento

De acordo com o plano de trabalho do TED 8750, o Produto 08 que este documento implementa consiste em um:

Relatório com o resumo final do projeto, incluindo: principais problemas e soluções; principais mudanças e replanejamento; relatório de execução da diferentes etapas e produtos, lições aprendidas; nível de atendimento aos objetivos do projeto; execução financeira; e Termo de Aceite assinado pelo demandante.

1.2 Contextualização

Conforme plano de trabalho original, a contextualização do presente TED 8750 é descrita como:

Atualmente, em decorrência dos avanços na capacidade computacional e do aumento da disponibilidade de dados, diversas instituições de pesquisas estatísticas em todo o mundo têm enfrentado desafios relacionados à manutenção da confidencialidade dos participantes das pesquisas que desenvolvem. De um lado, surgem demandas relacionadas ao uso dos microdados como subsídio para o desenvolvimento de políticas públicas, por outro lado, há expectativas de uso para outras finalidades diversas da coletada. Nesse contexto, pela

necessidade de conformidade com resolução internacional sobre a produção de estatísticas oficiais, legislações nacionais e melhores práticas do setor, as instituições de pesquisa são compelidas a demonstrar que os dados por elas divulgados não permitem a identificação ou reidentificação das pessoas que fazem parte do público-alvo das pesquisas, requerendo por vezes a atualização dos procedimentos técnicos e dos produtos de divulgação estatística. Ao mesmo tempo, esforçam-se para desenvolver novos produtos informacionais para atender demandas cada vez mais recorrentes da sociedade e dos governos por novas informações e prazos mais curtos de atualização. O Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira (Inep) se insere neste cenário na medida em que os Censos Educacionais e outras pesquisas que desenvolve geram estatísticas oficiais do sistema educacional brasileiro. A preservação da privacidade dos indivíduos da população pesquisada é um pressuposto expresso em Resolução Internacional da Assembleia Geral das Nações Unidas, Resolução no 68/261, de 29 de janeiro de 2014; em manuais e documentos técnicos dos sistemas estatísticos nacionais, e em normas legais nacionais, como a Lei de Acesso à Informação - LAI (Lei 12.527/2011) e a Lei Geral de Proteção de Dados Pessoais - LGPD (Lei 13.709/2018). Esta última, em consequência de sua promulgação e entrada em vigência –prevista à época de assinatura do presente TED 8750 como sendo a partir de agosto de 2020–, impõe ao Inep, e a todos os controladores que realizam tratamento de dados pessoais, a necessidade de conformidade às suas diretrizes, nem sempre simples de serem demonstradas, oportunidade que se apresenta para a revisão dos processos relacionados ao tratamento de dados pessoais em suas pesquisas. Portanto, considerando a necessidade de manutenção da relação de confiança entre o Inep, o público-alvo de suas pesquisas, especialmente os estudantes e suas famílias, e toda a cadeia de usuários das informações produzidas, observa-se a necessidade de implantação de métodos de controle de privacidade na divulgação dos resultados do Censos Educacionais.

O presente projeto é uma cooperação do Inep com a Universidade Federal de Minas Gerais (UFMG) e suas unidades com capacidades e competências necessárias à disseminação dos princípios orientadores do projeto para a execução das ações propostas, em especial o Departamento de Ciência da Computação (DCC).

Neste sentido, o mesmo plano de trabalho prevê como objetivo principal deste TED 8750:

Objetivo principal: O objetivo geral do projeto é contribuir de forma significativa para a melhoria da política de disseminação de microdados do Inep, especificamente no que se refere aos microdados dos Censos Educacionais, adequando-a à legislação vigente, em especial à Lei Geral de Proteção de Dados Pessoais – LGPD (Lei 13.709/2018).

Dentro do objetivo geral do projeto, precisam-se os seguintes objetivos específicos:

1. **Objetivo específico 1:** Levantar o panorama internacional dos procedimentos de garantia da privacidade em bases de dados de pesquisas estatísticas, em especial nos produtos de disseminação dos microdados. O contexto desta pesquisa bibliográfica deve abranger os normativos técnicos e as políticas de tratamento de dados pessoais de outros institutos relevantes de pesquisas estatísticas, no cenário internacional, relacionando-os ao contexto do Inep. O objetivo desta pesquisa é estabelecer a percepção da situação atual do Inep frente a institutos similares em outros países, além de reconhecer os desafios inerentes e as melhores práticas aplicáveis. Neste sentido, a pesquisa será fundamental para a definição das melhorias desejadas na atual política de disseminação de microdados do Inep, uma vez que trará evidências sobre o tratamento técnico realizado por outros institutos e o embasamento necessário à tomada de decisão.
2. **Objetivo específico 2:** Alinhar qualquer proposta apresentada no âmbito do projeto aos pressupostos legais e normativos vigentes ou com vigência iminente, especialmente aqueles que se referem aos critérios apresentados pela Comissão Econômica das Nações Unidas para a Europa - UNECE, pelo IBGE, pela Lei de Acesso à Informação - LAI (Lei 12.527/2011) e pela Lei Geral de Proteção de Dados Pessoais - LGPD (Lei 13.709/2018).
3. **Objetivo específico 3:** Avaliar o risco potencial de identificação das pessoas a quem os dados estatísticos se referem nos microdados do Censo Escolar e do Censo da Educação Superior.
4. **Objetivo específico 4:** Apresentar alternativas, a partir do panorama encontrado, de métodos de controle de divulgação com base nas abordagens pesquisadas. Estas alternativas devem fornecer aos gestores do Inep uma percepção clara dos benefícios, custos e riscos da adoção de cada abordagem. Este estudo técnico deve apresentar as técnicas propostas para o tratamento dos dados de forma que as equipes do Inep sejam capazes de compreender e reproduzi-las, inclusive independentemente do apoio de ferramentas estranhas ao ambiente do Inep e sem o auxílio de equipes externas, após o repasse de conhecimento.
5. **Objetivo específico 5:** Desenvolver e implantar um processo computacional baseado em até dois métodos de controle de divulgação escolhidos pelo Inep dentre aqueles elencados pelo DCC/UFGM no item anterior, como forma de aprimorar sua atual política de disseminação de microdados educacionais. Este processo deverá respeitar o ambiente tecnológico de infraestrutura e de sistemas existente no Inep e considerar, dentre as bases de dados dos Censos Educacionais, a que melhor se adequa aos objetivos de complexidade necessários para a realização de uma aplicação piloto dos métodos escolhidos. O objetivo do teste de conceito é apresentar os resultados da aplicação prática, quando será possível observar os resultados e identificar a sua aderência às necessidades iniciais.
6. **Objetivo específico 6:** Desenvolver capacidade técnica no Instituto para o tratamento de dados pessoais conforme as disposições da legislação vigente e as melhores

práticas internacionais do setor.

7. **Objetivo específico 7:** Aplicar o conjunto de métodos de controle de divulgação por meio do processo computacional desenvolvido em outro conjunto de microdados dos Censos Educacionais, com suporte e assistência técnica, de forma a possibilitar a internalização da tecnologia desenvolvida e garantir aderência às disposições da legislação vigente.

Para atingir tais objetivos, o plano de trabalho previa um conjunto de 4 fases: (1) Identificação do panorama internacional; (2) Definição do escopo do projeto piloto; (3) Desenvolvimento de soluções de tecnologia da informação; e (4) Implantação. Cada fase foi devidamente especificada em um conjunto de ações. Um conjunto de 08 produtos foi especificado para ser entregue pela equipe executora, em um cronograma distribuído dentro da vigência deste TED 8750, de 29 de abril de 2020 a 28 de abril de 2021. Os Produtos de 01 a 07 foram devidamente entregues.

Neste presente documento, correspondente ao Produto 08 do plano de trabalho, provemos um relatório com o resumo final do projeto, incluindo: principais problemas e soluções; principais mudanças e replanejamento; relatório de execução das diferentes etapas e produtos; lições aprendidas; e nível de atendimento aos objetivos do projeto. O relatório de execução financeira e o Termo de Aceite assinado pelo demandante serão tratados em momento oportuno, após a finalização do projeto.

1.3 Organização deste documento

O restante deste documento está organizado da seguinte forma.

- **Relatório de execução e mudanças de planejamento** (Seção 2): Nesta seção provemos um histórico da execução do projeto, discutindo os principais resultados obtidos e as mudanças de planejamento que se fizeram necessárias.
- **Principais dificuldades encontradas e suas soluções** (Seção 3): Nesta seção relatamos as principais dificuldades encontradas durante a execução deste TED 8750 –tanto administrativas quanto técnicas– e discutimos as soluções adotadas em cada caso.
- **Análise de resultados obtidos** (Seção 4): Nesta seção avaliamos o nível de atendimento aos objetivos propostos no plano de trabalho deste TED 8750 e discutimos as principais lições aprendidas durante sua execução.
- **Considerações finais** (Seção 5): Nesta seção apresentamos as considerações finais deste documento.

2 Relatório de execução e mudanças de planejamento

Nesta seção provemos um histórico da execução do projeto, discutindo os principais resultados obtidos e as mudanças de planejamento que se fizeram necessárias. A Tabela 2.0.1 sumariza o estado de execução dos oito produtos previstos no plano de trabalho.

2.1 Histórico de execução dos Produtos 01 a 06

O plano de trabalho deste TED 8750 previa seis produtos até a conclusão do projeto piloto. A seguir apresentamos um histórico da execução destes produtos.

Produto 01: *Relatório sobre o panorama internacional e o contexto do Inep a respeito dos métodos de tratamento de controle de privacidade na divulgação estatística*

Neste produto apresentamos, através de vários estudos de caso, um panorama internacional e um nacional de como institutos produtores de estatísticas oficiais equilibram requisitos de transparência e de proteção à privacidade em seus métodos de divulgação de informação.

Cada estudo de caso consistiu em: (i) um sumário da regulamentação geral mais relevante sobre privacidade no país ou região onde o caso se insere; (ii) um sumário da regulamentação específica identificada como pertinente ao instituto em questão; (iii) a identificação dos tipos de dados divulgados pelo instituto, distinguindo-se entre microdados e dados agregados; e (iv) uma descrição das medidas empregadas para mitigação de possíveis violações de privacidade decorrentes da divulgação.

Iniciamos a cobertura do panorama internacional com um sumário das principais diretivas e regulamentações gerais sobre privacidade estabelecidas pela Organização das Nações Unidas (ONU) e outros organismos internacionais relevantes. Em seguida, apresentamos os seguintes estudos de caso: No contexto dos Estados Unidos:

- (1) o caso das práticas de limitação de divulgação das agências federais norte-americanas;
- (2) o caso da divulgação de dados estatísticos pelo Centro Nacional de Estatísticas da Educação (*National Center for Education Statistics* - NCES); e
- (3) o caso da divulgação de dados estatísticos pelo Escritório do Censo (*Census Bureau* - USCB).

No contexto da União Europeia:

- (4) o caso da divulgação de dados educacionais por escolas e pelo Ministério da Educação da Holanda.

No contexto da Austrália:

- (5) o caso da divulgação de dados estatísticos pelo Escritório Australiano de Estatística (*Australian Bureau of Statistics* - ABS).

Iniciamos a cobertura do panorama nacional com um sumário das principais diretivas e regulamentações gerais brasileiras sobre transparência e privacidade, com foco na Lei 12.527/2011, conhecida como *Lei de Acesso à Informação* (LAI), e na Lei 13.709/2018, conhecida como *Lei Geral de Proteção de Dados Pessoais* (LGPD ou LGPD). Em seguida, apresentamos os seguintes estudos de caso nacionais:

- (1) o caso da divulgação de dados pelo Instituto Brasileiro de Geografia e Estatística (IBGE); e
- (2) o caso da divulgação de dados pelo Portal da Transparência do Governo Federal.

Como cerne do documento, provemos uma avaliação comparativa da atual forma de divulgação dos Censos Educacionais pelo Inep frente a práticas correntes nos panoramas internacional e nacional, com foco em potenciais riscos à privacidade. Primeiramente, apresentamos uma contextualização da atual situação do Instituto, incluindo sumários da principal regulamentação específica a ele aplicável, da sua atual forma de divulgação dos Censos Educacionais, e das metodologias de mitigação de danos à privacidade por ele empregadas atualmente. Em seguida, provemos uma análise comparativa da situação do Inep com aquela dos outros estudos de caso internacionais e nacionais descritos no Produto 01. A partir desta análise, destacamos as seguintes conclusões:

- (i) Frente a todos os casos internacionais estudados, o Inep publica em seus Censos Educacionais a maior quantidade de microdados individuais e em maior nível de detalhes.

- (ii) Em todos os casos internacionais estudados, os órgãos produtores de estatísticas oficiais adotam medidas mais rígidas do que as do Inep na mitigação de danos à privacidade causados por publicação de microdados. Tais medidas incluem, e.g., a não publicação de microdados individuais de estudantes sob nenhuma forma, a publicação de microdados apenas por amostras da população, ou a permissão de acesso a todo o conjunto de microdados apenas sob autorização prévia, de acordo com os objetivos do pesquisador ou indivíduo interessado, e em salas seguras.
- (iii) As atuais técnicas de proteção de privacidade utilizadas pelo Inep nos microdados divulgados, consistindo apenas em *desidentificação* –em que se removem possíveis identificadores individuais óbvios dos registros, como nome, CPF e RG– e em *pseudonimização* –em que tais identificadores individuais óbvios são substituídos por um código único de identificação artificialmente criado–, estão potencialmente sujeitas a vários riscos de privacidade já identificados na literatura.

Produto 02: *Relatório sobre os riscos à privacidade decorrentes da atual forma de divulgação dos microdados dos Censos Educacionais do Inep*

Neste produto apresentamos uma extensa análise quantitativa experimental dos riscos à privacidade de titulares de dados decorrentes da atual forma de divulgação dos microdados dos Censos Educacionais da Educação Básica e da Educação Superior por parte do Inep, que se baseia apenas na desidentificação e pseudonimização de registros. Entretanto, é conhecido na literatura técnica sobre privacidade que, mesmo quando se removem ou se criptografam identificadores explícitos (como nomes, endereços e números de telefone) dos titulares dos microdados em uma divulgação, outros dados distintos, chamados de *quaseidentificadores*, podem se combinar de maneira inadequada e ser, assim, vinculados a informações publicamente disponíveis para reidentificar os indivíduos.¹ Neste contexto, este relatório analisou a degradação de privacidade de indivíduos presentes nas bases dos Censos Educacionais quando quaseidentificadores podem ser usados na inferência de informação sensível a seu respeito.

O documento proveu uma formalização matemática precisa de modelos de *adversário* –i.e., a entidade contra quem se deseja proteger a informação sensível sobre indivíduos– e de *ataques* –i.e., uma ação ou conjunto de ações pelas quais o adversário pode obter informação sensível sobre titulares de dados. Em particular, provemos uma classificação metódica de ataques organizada nas seguintes dimensões:

- (i) *o tipo de informação procurada pelo adversário*, distinguindo entre *ataques de reidentificação*, em que o objetivo do adversário é determinar uma correspondência entre registros presentes na base de dados e os titulares desses registros, vs. *ataques de inferência de atributo*, em que o objetivo do adversário é inferir o valor

¹Como exemplo de quaseidentificadores poderosos, Sweeney demonstrou em 2000 que 87% da população dos EUA poderia ser unicamente identificada usando-se apenas o *zip-code* (o equivalente americano ao CEP brasileiro), o gênero e data de nascimento do indivíduo [2].

de um atributo considerado como sensível para um conjunto de indivíduos, independentemente de que estes indivíduos tenham sido reidentificados com sucesso ou não;

- (ii) *o foco do adversário*, distinguindo entre *ataques focados em indivíduo* ou *individuais*, em que o adversário visa obter informação sensível a respeito de um indivíduo específico pré-determinado como alvo, vs. *ataques coletivos*, em que o adversário objetiva obter informação sensível sobre o maior número possível de indivíduos, independentemente de quem eles sejam; e
- (iii) *as bases de dados acessíveis ao adversário*, distinguindo entre *ataques em uma única base de dados*, em que o adversário tem acesso a uma única base de dados, referente a um ponto específico do tempo, vs. *ataques longitudinais*, em que o adversário tem acesso a várias versões da base de dados, cada uma referente a um ponto distinto do tempo.

Consideramos dois tipos de métricas da degradação de privacidade causada por um ataque:

- (i) *determinísticas*, em que a degradação é medida em termos absolutos –i.e., um valor qualitativo dependendo de se a informação desejada foi recuperada com absoluta certeza ou não; e
- (ii) *probabilísticas*, em que a degradação é medida em termos estocásticos –i.e., um valor quantitativo representando o grau de certeza com o qual a informação desejada foi recuperada.

Dadas as dimensões acima, obtêm-se 8 combinações distintas de tipos de ataques e 2 medidas de degradação de privacidade, levando a um total de 16 cenários distintos. Para cada um deles apresentamos análises no Produto 02. Em particular, para cada tipo de ataque considerado –reidentificação vs. inferência de atributo, em uma única base vs. longitudinal–, apresentamos resultados de ataques individuais e coletivos. Por focarem-se em um aluno específico pré-determinado como alvo, ataques individuais serviram para ilustrar concretamente os riscos a que um alvo selecionado pode estar sujeito. Entretanto, resultados quantitativos de ataques individuais são altamente dependentes das características específicas do alvo escolhido, e podem não ser representativos do risco esperado da coletividade de todos os indivíduos de interesse. Já as análises de ataques coletivos nos permitiram quantificar o risco médio a que todos os indivíduos estão sujeitos. Portanto, apesar de mais abstratos, resultados quantitativos de ataques coletivos proveram uma visão mais acurada dos riscos médios esperados nas bases consideradas.

As análises demonstraram que, usando apenas quaseidentificadores que sejam facilmente descobríveis sobre um indivíduo escolhido como alvo (e.g., sua data de nascimento e curso em que está matriculado), ataques em uma única base de dados podem levar, em alguns casos, à reidentificação de mais de 79% dos indivíduos, e à inferência de um atributo

sensível (e.g., se o indivíduo é ou não portador de necessidades especiais) de mais de 98% dos indivíduos. Usando informação auxiliar ainda mais trivial (e.g., apenas a instituição de ensino e curso vinculados a um aluno), um ataque longitudinal que combine várias bases liberadas ano a ano sobre um mesmo Censo podem levar o risco de reidentificação a mais de 15% dos indivíduos presentes nas bases, e à inferência de atributos sensíveis a mais de 58% dos indivíduos.

Os resultados obtidos demonstraram de forma inequívoca que a atual forma de divulgação dos Censos Educacionais pelo Inep submete os titulares dos dados a consideráveis riscos de violação de privacidade, incluindo reidentificação e inferência de atributos sensíveis. Em nossa visão, tal situação poderia constituir em violação da Lei Geral de Proteção de Dados Pessoais (LGPD).

Produto 03: *Relatório técnico sobre métodos de tratamento aplicáveis aos microdados de divulgação dos Censos Educacionais do Inep*

Neste produto provemos um parecer técnico sobre a adequação de variadas técnicas de mitigação de danos à privacidade aos Censos Educacionais do Inep. Em particular, consideramos que a LGPD prevê garantias de privacidade individualmente a cada titular de dados –em especial, contra reidentificação– que devem ser atendidas pelos Censos Educacionais. Também consideramos que qualquer método adotado devesse manter a maior utilidade possível para os analistas e consumidores dos dados dos Censos.

À época observamos que o Inep dispunha de um prazo exíguo para implementação de uma solução coerente com a nova legislação. Sugerimos, então, a adoção de uma solução emergencial que garantisse no curto prazo a privacidade dos titulares –mesmo que fosse possivelmente sub-ótima em relação à utilidade provida aos analistas (ou vice-versa)–, enquanto elaborar-se-ia uma alternativa de longo prazo que fornecesse um melhor custo-benefício na relação entre privacidade e utilidade.

O plano emergencial proposto na ocasião consistia, essencialmente, em eliminar imediatamente a divulgação de microdados sob qualquer forma que não fosse via salas seguras (físicas ou virtuais) e oferecer apenas informações agregadas (sumários estatísticos ou histogramas) em canais públicos de comunicação, protegidos por privacidade diferencial. Uma vez assegurado o nível de privacidade individual dos dados demandado pela LGPD (obtido nos passos anteriores), proceder-se-ia a um estudo aprofundado de como aumentar a utilidade das divulgações enquanto manter-se-ia a privacidade conquistada. Tal aumento gradual da utilidade dos dados visaria a satisfazer a um número cada vez maior de analistas, o que poderia contribuir para arrefecer a demanda suplementar por acesso a salas seguras eventualmente causada pela implementação da solução emergencial.

Como previsto no plano de trabalho, as recomendações do Produto 03 foram profundamente discutidas entre a equipe executora do presente TED 8750 e os representantes do Inep, a fim de fundamentar uma tomada de decisão bem informada.

Após esta etapa de discussão e deliberação, o Inep optou por manter o foco do presente TED 8750 na avaliação da viabilidade de divulgação de microdados, descartando

no presente momento soluções baseadas na divulgação de dados agregados. A decisão foi baseada na premissa de que, apesar de haver indícios fortes na literatura de que a divulgação de microdados no tempo exíguo disponível para o presente TED 8750 pudesse não atingir um nível de compromisso entre privacidade e utilidade aceitável, era importante averiguar empiricamente este fato. Tal averiguação quantitativa proveria suporte científico para qualquer eventual tomada de decisão futura do Inep, justificando-a perante outras partes interessadas (i.e., titulares de dados, analistas e governo).

Neste sentido, as abordagens escolhidas pelo Inep para avaliação no projeto piloto foram:

- (i) sanitização de microdados por amostragem não-perturbativa; e
- (ii) sanitização de microdados por privacidade diferencial- ε local.

Além disso, fixou-se como dados de estudo a base do Censo da Educação Básica de 2019.

Produto 04: *Solução tecnológica e sua documentação*

Neste produto fornecemos a solução tecnológica para o tratamento da base de dados da pesquisa escolhida para o projeto piloto descrito no Produto 05 (*Relatório técnico final do projeto piloto*). O produto incluiu a documentação e componentes da solução tecnológica desenvolvida, bem como os requisitos e configurações necessárias para a aplicação a outras bases de dados no ambiente computacional do Inep. Além disso, instruímos o Inep a como ter acesso às bases sanitizadas criadas no projeto piloto.

Produto 05: *Relatório técnico final do projeto piloto*

Neste produto apresentamos várias análises experimentais quantitativas sobre a privacidade e a utilidade de dados providas pelos dois métodos de sanitização selecionados, após o Produto 03, pelo Inep para o projeto piloto deste TED: (i) amostragem; e (ii) privacidade diferencial local. As análises foram realizadas sobre os dados do Censo da Educação Básica de 2019. Em todas elas consideramos como informação auxiliar para o adversário atributos cujos valores sejam presumivelmente conhecidos, ou possam ser facilmente descobertos, em geral por serem informação pública ou considerada inofensiva (e.g., a idade de um aluno, seu sexo ou dados sobre sua entidade de ensino).

Mais precisamente, quantificamos a degradação de privacidade sob as seguintes condições:

- (i) Ataques de reidentificação coletiva sobre uma única base de dados sanitizada pelas técnicas de desidentificação e pseudonimização. Tais técnicas são as atualmente empregadas pelo Inep na divulgação dos dados dos Censos Educacionais. As análises levam em conta a restrição no número e granularidade de atributos divulgados determinada pelo Inep para o presente projeto piloto e servem de base de comparação para as demais técnicas de sanitização avaliadas neste documento.

- (ii) Ataques de reidentificação coletiva sobre uma única base sanitizada por amostragem. O plano amostral utilizado foi desenhado pelo Inep.
- (iii) Ataques de reidentificação coletiva sobre uma única base sanitizada por privacidade diferencial local.

As análises foram realizadas em bases sanitizadas pela equipe executora. Para tal, desenhamos e implementamos um algoritmo de sanitização por privacidade diferencial local baseado no método tradicional da literatura, em que atributos são sanitizados de forma independente. Dado o prazo deste projeto piloto, foi realizada uma exploração apenas preliminar do vasto espaço de valores possíveis para os parâmetros de privacidade do método.

Além disso, provemos uma análise comparativa da privacidade e utilidade atingidas por cada método de sanitização empregado. Adotamos a métrica de propósito geral de utilidade estatística, que mede a similaridade entre a distribuição de probabilidade sobre atributos antes e após a sanitização.

Destacamos os seguintes pontos da nossa análise.

- (i) A sanitização por amostragem reduziu significativamente a degradação determinística de privacidade, mas teve pouco efeito na degradação probabilística. O resultado está em conformidade com o conhecimento da literatura técnica: a amostragem diminui o número absoluto de indivíduos expostos a risco, entretanto aqueles presentes na amostra ainda podem estar sujeitos a graves violações. Por outro lado, a amostragem demonstrou uma manutenção razoável da utilidade estatística.
- (ii) A sanitização por privacidade diferencial local praticamente eliminou a degradação probabilística de privacidade (a ela não se aplicam análises determinísticas). Por outro lado, o método em sua forma atual apresentou um custo elevado –e potencialmente proibitivo– na utilidade estatística dos dados divulgados. Os resultados confirmam o conhecimento da literatura técnica: na maioria dos casos um trabalho longo e laborioso de ajuste de parâmetros e técnicas é necessário para se atingir o potencial máximo de utilidade da privacidade diferencial local.

Os resultados encontrados evidenciaram a inviabilidade da manutenção no curto prazo da divulgação de microdados dos Censos Educacionais de forma privada e útil. Tal constatação está em consonância com a literatura técnica e constitui uma contribuição central deste projeto piloto. Primeiramente, ela provê ao Inep informação crucial para tomadas de decisões futuras, balanceando soluções de curto prazo –implementáveis de forma relativamente rápida, mas potencialmente sub-ótimas quanto à utilidade provida– e soluções de longo prazo –mais úteis, porém que demandem maior investimento de tempo e pessoal especializado. Em segundo lugar, ela subsidia uma comunicação efetiva com as partes interessadas sobre os desafios técnicos na divulgação de microdados, facilitando a compreensão sobre eventuais decisões futuras.

Observamos ainda que os resultados obtidos foram naturalmente impactados pelo exíguo prazo disponível para adequação da divulgação de microdados dos Censos Educacionais à LGPD. Portanto, não se deve concluir que não haja solução possível para divulgação dos dados dos Censos de forma privada e com razoável utilidade, mas sim que é necessária uma criteriosa ponderação sobre passos futuros. Na Seção 4 discutimos alternativas possíveis para o futuro.

Produto 06: *Relatório técnico de implantação*

Neste produto resumizamos as principais atividades de transferência de conhecimento da equipe técnica executora para a equipe do Inep. Adicionalmente, detalhamos os recursos computacionais usados para execução dos ataques no Produto 02 (*Relatório sobre os riscos à privacidade decorrentes da atual forma de divulgação dos microdados dos Censos Educacionais do Inep*) e das análises quantitativas experimentais do Produto 04 (*Solução tecnológica e sua documentação*) e do Produto 05 (*Relatório técnico final do projeto piloto*). Desta forma, possibilitou-se estimar quais recursos o Inep precisaria caso deseje reproduzir e explorar os resultados destes Produtos em maior profundidade.

2.2 Readequação dos objetivos do Produto 07

Conforme exposto na seção anterior, as análises experimentais do Produto 02 (*Relatório sobre os riscos à privacidade decorrentes da atual forma de divulgação dos microdados dos Censos Educacionais do Inep*) demonstraram de forma inequívoca que a atual forma de divulgação de microdados dos Censos –baseada apenas desidentificação e pseudonimização– submete os titulares de dados a sérios e generalizados riscos de violação de privacidade, em especial aos de reidentificação e de inferência de atributos sensíveis.

Complementarmente, os resultados do projeto piloto do Produto 04 (*Solução tecnológica e sua documentação*) e Produto 05 (*Relatório técnico final do projeto piloto*) evidenciaram a inviabilidade da manutenção no curto prazo da divulgação de microdados dos Censos Educacionais de forma privada e útil. Esta constatação indica que é necessária uma criteriosa ponderação sobre passos futuros. Na Seção 4 do presente documento discutimos alternativas para solução do problema, como a adoção de divulgação de dados agregados sanitizados por privacidade diferencial global ou o desenvolvimento de um método de sanitização de microdados por privacidade diferencial local desenhado e refinado especificamente para Censos Educacionais. A eventual implementação de alguma destas alternativas, entretanto, está além do escopo deste TED 8750.

Naturalmente, a constatação da inviabilidade de manutenção da divulgação de microdados no curto prazo impactou os objetivos dos produtos subsequentes do TED. A seguir detalhamos as readequações necessárias.

Produto 07: *Relatório de operação assistida*

Dentre os objetivos específicos do Produto 07 previstos no plano de trabalho original, foi suprimido aquele referente à documentação do processo de operação assistida. Tal documentação apresentaria a aplicação, por parte da equipe do Inep, da solução a um conjunto de microdados diferente do piloto no ambiente real do Instituto.² Por outro lado, seguiram sendo requeridas e desenvolvidas as ações de transferência de tecnologia, incluindo o desenvolvimento de conhecimento técnico, a especificação de um ambiente computacional adequado para a execução dos experimentos e outras atividades de tratamento de dados para o controle de divulgação estatística, além da documentação e o suporte à equipe para a compreensão dos processos envolvidos.

Portanto, a transferência passou a focar-se no conhecimento gerado pelo projeto piloto, que é crucial para as futuras tomadas de decisão do Inep sobre a divulgação dos Censos Educacionais, ponderando-se entre soluções de curto prazo e soluções de longo prazo. Adicionalmente, este conhecimento provê ao Inep subsídios para uma efetiva comunicação com as partes interessadas nos Censos Educacionais sobre os desafios técnicos da adequação da divulgação de microdados à LGPD. Isto pode auxiliar tais partes a compreenderem as nuances de futuras decisões do Inep –eventualmente, inclusive, sobre formas de divulgação que restrinjam microdados.

Em particular, provemos um treinamento da equipe do Inep para manuseio da Ferramenta ARX [1], que permite ao Instituto realizar análises futuras de riscos à privacidade em suas bases de microdados. Adicionalmente, mantivemos a disponibilidade para suporte ao Inep em demandas de implantação que surgissem durante as fases finais do projeto.

Desta forma, neste produto apresentamos as formas de transferência de conhecimento da equipe executora para a equipe do Inep empregadas neste TED 8750. Tais formas incluíram, além das entregas dos produtos previstos no plano de trabalho, também reuniões técnicas e deliberativas e treinamentos da equipe do Inep.

2.3 Atividades complementares para transferência de conhecimento e tecnologia

Em complementação à entrega dos produtos em si, as atividades de transferência de conhecimento e tecnologia deste TED 8750 consistiram principalmente em reuniões técnicas e deliberativas, além de treinamentos da equipe do Inep. A Tabela 2.3.2 sumariza as reuniões e discussões técnicas realizadas, enquanto a Tabela 2.3.3 sumariza o treinamento da equipe do Inep.

Além das atividades listadas acima, prevemos como atividade de transferência de conhecimento o auxílio ao Inep na organização de um *workshop* sobre os resultados obtidos

²Ressaltamos que, apesar de o foco do Produto 07 ter sido alterado, todo o código fonte necessário para uma eventual aplicação dos métodos do projeto piloto por parte do Inep, incluindo manuais e documentação, foram fornecidos ao Instituto.

no presente projeto e alternativas futuras. Tal *workshop* está previsto para abril de 2021 e deve contar com a participação de integrantes de variadas diretorias do Inep, além de possivelmente integrantes de outros órgãos produtores de estatísticas oficiais nacionais.

Produto	Título	Descrição	Entregue
Produto 01	<i>Relatório sobre o panorama internacional e o contexto do Inep a respeito dos métodos de tratamento de controle de privacidade na divulgação estatística</i>	Relatório com o panorama internacional sobre o tratamento de dados com vistas a garantir a transparência das pesquisas e privacidade dos dados pessoais na divulgação estatística de outros institutos produtores de estatísticas oficiais, incluindo a contextualização da situação do Inep.	15 de junho de 2020 (revisado em 03 de julho de 2020)
Produto 02	<i>Relatório sobre os riscos à privacidade decorrentes da atual forma de divulgação dos microdados dos Censos Educacionais do Inep</i>	Documento técnico apresentando os riscos de divulgação inapropriada no conjunto de microdados dos Censos da Educação Básica e da Educação Superior e a definição do escopo do projeto piloto.	14 de agosto de 2020 (revisado em 06 de setembro de 2020)
Produto 03	<i>Relatório técnico sobre métodos de tratamento aplicáveis aos microdados de divulgação dos Censos Educacionais do Inep</i>	Documento técnico com a apresentação e a discussão comparativa dos métodos de tratamento aplicáveis aos microdados de divulgação pública do Censo da Educação Básica e do Censo da Educação Superior, realizados pelo Inep.	25 de setembro de 2020
Produto 04	<i>Solução tecnológica e sua documentação</i>	Documento técnico com a apresentação da solução tecnológica para o tratamento da base de dados da pesquisa escolhida para o projeto piloto, incluindo manual, documentação e componentes da solução tecnológica desenvolvida, bem como os requisitos e configurações necessárias para a aplicação a outras bases de dados no ambiente computacional no Inep.	12 de fevereiro de 2021 (revisado em 26 de fevereiro de 2021)
Produto 05	<i>Relatório técnico final do projeto piloto</i>	Relatório técnico apresentando os resultados do projeto piloto, mudanças e replanejamento do plano de execução inicial, comparação entre os métodos testados, lições aprendidas, nível de atendimento ao escopo e aos objetivos definidos para a aplicação.	05 de fevereiro de 2021 (revisado em 26 de fevereiro de 2021)
Produto 06	<i>Relatório técnico de implantação</i>	Documento técnico apresentando o relatório das atividades de transferência de tecnologia e de validação analítica do ambiente de execução do Inep.	23 de dezembro de 2020 (revisado em 26 de fevereiro de 2021)
Produto 07	<i>Relatório de operação assistida</i>	<u>Original:</u> Documentação do processo de operação assistida, o qual apresentará a aplicação, por parte da equipe do Inep, da solução a um conjunto de microdados diferente do piloto no ambiente real do Instituto, a fim de contribuir na internalização do conhecimento e eliminação de possíveis falhas. <u>Atualizado por apostilamento:</u> Relatório de ações requeridas e desenvolvidas para transferência de tecnologia, incluindo o desenvolvimento de conhecimento técnico, a especificação de um ambiente computacional adequado para a execução dos experimentos e outras atividades de tratamento de dados para o controle de divulgação estatística, a documentação e o suporte à equipe para a compreensão dos processos envolvidos.	09 de abril de 2021
Produto 08	<i>Relatório de encerramento do projeto</i>	Relatório com o resumo final do projeto, incluindo: principais problemas e soluções; principais mudanças e replanejamento; relatório de execução das diferentes etapas e produtos, lições aprendidas; nível de atendimento aos objetivos do projeto; execução financeira; e Termo de Aceite assinado pelo demandante.	09 de abril de 2021.

Tabela 2.0.1: Histórico de execução dos produtos previstos no plano de trabalho.

Data	Tópico da reunião	Sumário
20 de maio de 2020	Apresentação inicial do escopo do TED 8750	Apresentação às partes interessadas do Inep sobre o TED 8750. Discussão de seus objetivos gerais e específicos, etapas, resultados esperados e cronograma de atividades.
22 de julho de 2020	Apresentação e discussão dos resultados obtidos no Produto 01	Apresentação às partes interessadas do Inep sobre os panoramas internacional e nacional de como órgãos estatísticos divulgam seus dados. Contextualização e discussão da situação dos Censos Educacionais do Inep.
05 de outubro de 2020	Apresentação e discussão dos resultados obtidos no Produto 02	Apresentação às partes interessadas do Inep sobre os atuais riscos de reidentificação e inferência de atributos decorrentes da atual forma de divulgação dos Censos Educacionais por parte do Inep. Discussão sobre as possíveis consequências das descobertas e da adequação dos métodos atuais à LGPD.
09 de novembro de 2020	Apresentação do Produto 03 e discussão sobre o escopo do projeto piloto.	Apresentação às partes interessadas do Inep das diferentes técnicas de mitigação a danos de privacidade aplicáveis aos Censos Educacionais do Inep. Discussão de prós e contras de cada método.
17 de novembro de 2020	Reunião para definição do escopo do projeto piloto.	Discussão aprofundada sobre o escopo do projeto piloto. Definição da base a ser utilizada como sendo a do Censo da Educação Básica de 2019. Definição dos métodos de tratamento de microdados a serem analisados como sendo sanitização por amostragem e sanitização por privacidade diferencial local.
05 de março de 2021	Apresentação e discussão dos resultados obtidos nos Produtos 04 e 05	Apresentação às partes interessadas do Inep sobre os resultados obtidos no projeto piloto, que evidenciam a inviabilidade da manutenção no curto prazo da divulgação de microdados dos Censos Educacionais de forma privada e útil. Discussão de como tais resultados estão em consonância com o conhecimento técnico na área de divulgação estatística. Apresentação de alternativas futuras baseadas em divulgação de dados agregados sanitizados por privacidade diferencial ou em divulgação de microdados sanitizados por privacidade diferencial local.

Tabela 2.3.2: Reuniões e discussões técnicas entre equipe executora da UFMG e o Inep.

Data	Tópico do treinamento	Sumário
07 de outubro de 2020	Análise de risco à privacidade usando a ferramenta ARX [1].	Treinamento <i>online</i> dividido em 5 etapas: (1) Visão Geral do ARX: Introdução, apresentação da ferramenta, suas capacidades e limitações. (2) Configuração: Configuração de projeto, banco de dados e atributos. (3) Análise de risco: Análise de risco, identificação de quaseidentificadores, modelos de ataque, etc. (4) Outras aplicabilidades do ARX: Anonimização e utilidade de dados. (5) Discussão sobre dúvidas.

Tabela 2.3.3: Treinamento da equipe do Inep.

3 Principais dificuldades encontradas e suas soluções

Nesta seção relatamos as principais dificuldades encontradas durante a execução deste TED 8750 –tanto administrativas, quanto metodológicas ou de implementação– e discutimos as soluções adotadas em cada caso.

3.1 Dificuldades administrativas

Destacamos as seguintes dificuldades administrativas encontradas.

- (i) **Dificuldade:** O processo de negociação deste TED 8750 iniciou-se no segundo semestre de 2018, mas o termo de cooperação só foi formalizado em abril de 2020. Isto acarretou em um encurtamento significativo no tempo disponível para execução deste projeto antes da entrada em vigor da LGPD.

Solução: Os objetivos e prazos do presente TED tiveram que ser readequados para o novo prazo disponível. Um aditivo ao TED foi necessário para garantir ao projeto o tempo mínimo de execução. O processo de refinamento de parâmetros do mecanismo de privacidade diferencial local empregado no projeto piloto teve que ser simplificado, o que significa que parâmetros ótimos não puderam ser encontrados no exíguo tempo disponível.

- (ii) **Dificuldade:** Quando da elaboração do plano de trabalho, em novembro de 2019, a expectativa era de que o TED tivesse vigência de 02 de janeiro de 2020 a 15 de dezembro de 2020. Como o TED só foi assinado em 29 de abril, a vigência prevista até 15 de dezembro de 2020 seria insuficiente para execução do plano de trabalho e precisaria ser reajustada.

Solução: O aditivo ao TED 8750 estendeu a vigência do mesmo a um período compatível com a do plano original, de aproximadamente 1 (um) ano corrido. Desta forma, o TED passou a se encerrar em 28 de abril de 2021.

- (iii) **Dificuldade:** Nos 5 meses decorridos entre a finalização da proposta de plano de custos, em novembro de 2019, e data de assinatura do TED 8750, em abril de 2020, ocorreram mudanças no cenário do país e do mundo que impactaram de forma significativa os custos do projeto.

Mais especificamente, houve uma importante alteração na conjuntura cambial do país, com uma desvalorização do real frente ao dólar em 5 meses que se aproximava de 30%. Esta alteração impactou a parte do orçamento correspondente aos custos de material permanente cujo valor é dependente diretamente da taxa cambial da moeda americana.

Solução: O aditivo ao TED 8750 readequou os valores previstos de acordo com as necessidades apontadas.

- (iv) **Dificuldade:** As medidas de enfrentamento à atual pandemia de COVID-19 impediram o acesso físico da equipe executora ao campus da UFMG. Isso impediu o acesso ao laboratório de pesquisa Inscript, executor do TED 8750, durante toda a execução do projeto.

Solução: A equipe executora foi movida de seu ambiente no campus universitário para o regime de *home-office*. Esta alteração implicou na adaptação do material permanente e de consumo fornecido aos membros da equipe de trabalho para que pudessem executar remotamente suas funções no projeto.

- (v) **Dificuldade:** O plano de trabalho original teve que ter algumas ações referentes à Etapa 4 (*Implantação*) revisadas, devido a novas informações levantadas durante o curso do presente projeto.

Solução: Foi criado um Termo de Apostilamento ao TED 8750, em que as ações da referida etapa foram atualizadas.

3.2 Dificuldades metodológicas

Destacamos as seguintes dificuldades metodológicas encontradas.

3.2.1 Dificuldades referentes ao Produto 01: *Relatório sobre o panorama internacional e o contexto do Inep a respeito dos métodos de tratamento de controle de privacidade na divulgação estatística*

- (i) **Dificuldade:** Para contextualizar apropriadamente a situação jurídica do Inep quanto à aderência à LGPD é preciso interpretar o texto legal propriamente.

Solução: A interpretação jurídica da LGPD é considerada fora do escopo de atuação da equipe executora do presente TED 8750. Quaisquer dúvidas legais por parte do Inep devem ser esclarecidas junto a órgãos jurídicos competentes e via eventuais consultas à *Agência Nacional de Proteção de Dados - ANPD*.

3.2.2 Dificuldades referentes ao Produto 02: *Relatório sobre os riscos à privacidade decorrentes da atual forma de divulgação dos microdados dos Censos Educacionais do Inep*

- (i) **Dificuldade:** As premissas adotadas sobre ataques em uma única base e em bases longitudinais demandavam que cada estudante tivesse exatamente um registro em cada base. Entretanto, as bases do Inep permitiam múltiplos registros por estudante.

Solução: Realizamos um tratamento sobre as bases de dados de modo a garantir que cada aluno apresentasse apenas um registro. Para isto, nos baseamos no atributo ID_ALUNO, único para cada estudante em uma mesma base de dados e também entre bases de anos diferentes até a publicação dos Censos referentes a 2017. Dado um ID_ALUNO com mais de um registro em uma base de dados, selecionamos aleatoriamente apenas um dos registros para compor a base utilizada para gerar os resultados apresentados no Produto 02. Este tratamento não altera significativamente o tamanho das bases de dados, mantendo, por exemplo, 89% dos registros na base do Censo da Educação Superior de 2018 (10 811 601 registros de um total de 12 043 994) e 93% dos registros do Censo da Educação Básica de 2019 (47 640 822 registros de um total de 51 166 723).

3.2.3 Dificuldades referentes ao Produto 04: *Solução tecnológica e sua documentação* e ao Produto 05: *Relatório técnico final do projeto piloto*

- (i) **Dificuldade:** As premissas adotadas sobre ataques em uma única base e em bases longitudinais demandavam que cada estudante tivesse exatamente um registro em cada base. Entretanto, as bases do Inep permitiam múltiplos registros por estudante. Além disso, o Instituto disponibilizou uma amostra que continha registros não existentes nas bases de dados tratadas durante a execução do Produto 02.

Solução: Assim como feito para o Produto 02, era necessário garantir que cada aluno apresentasse apenas um registro nas bases de dados. Entretanto, os registros presentes deveriam também ser compatíveis com aqueles disponibilizados na amostra enviada pelo Inep. Dessa forma, tivemos que alterar o tratamento realizado para o Produto 02 de modo a garantir que os resultados para os experimentos com uso de de-identificação e pseudonimização, amostragem, e privacidade diferencial local fossem comparáveis. Ou seja, era necessário que todos os experimentos fossem feitos sobre bases de dados com os mesmos registros –mas não necessariamente com as mesmas colunas.

Para tanto, inicialmente notamos que apenas a base disponibilizada pelo Inep para os experimentos por privacidade diferencial local foi fornecida com a coluna referente ao atributo ID_ALUNO, sendo o mesmo atributo ausente na base disponibilizada para os experimentos por amostragem. Dessa forma, tivemos que nos basear no atributo

ID_MATRICULA como meio para identificação direta de cada aluno. Entretanto, apenas com o atributo ID_MATRICULA, não é possível identificar alunos com múltiplos registros em uma mesma publicação.

Sendo assim, utilizando a base publicada pelo Inep em sua página na Internet para o Censo da Educação Básica de 2019, agrupamos para cada valor do atributo ID_ALUNO, único para cada aluno inclusive em registros distintos, todos os respectivos valores do atributo ID_MATRICULA, único por registro, para verificarmos a existência de estudantes com múltiplos registros na amostra disponibilizada pelo Inep.

Em seguida, comparamos os valores de ID_MATRICULA para os registros presentes na amostra com o agrupamento que construímos, o que nos permitiu identificar todos os casos de alunos com registros múltiplos na amostra. De modo a garantirmos que cada aluno possui no máximo um registro na amostra, selecionamos aleatoriamente apenas um dos registros disponíveis para aqueles alunos com mais de um registro.

Finalmente, para obtermos uma base com todos os alunos compatível com a base sanitizada por amostragem e tratada conforme especificado acima, realizamos o seguinte procedimento.

- (i) Iniciando com a base original vazia, incluímos todos os registros da base completa fornecida que correspondam a algum registro mantido na base amostral após o tratamento para eliminação de duplicatas descrito acima.
 - (ii) Para cada indivíduo de interesse ainda não incluído na base original após o passo anterior, selecionamos aleatoriamente um de seus registros na base completa disponibilizada pelo Inep e o incluímos na base original. Essa seleção se baseou no mapeamento desenvolvido para o conjunto de dados para sanitização por amostragem, i.e., para cada valor do atributo ID_ALUNO, único para cada aluno inclusive em registros distintos, temos todos os respectivos valores do atributo ID_MATRICULA, único por registro. Desta forma, garantimos que a premissa de que cada indivíduo seja representado no máximo uma vez na base original fosse satisfeita.
- (ii) **Dificuldade:** O desenho do processo de sanitização por privacidade diferencial local normalmente demanda um elevado investimento de tempo, superior àquele disponível para a execução do presente TED 8750.

Solução: Optamos por uma abordagem clássica na literatura, em que ruído é aplicado a cada atributo de forma independente. Além disso, o processo de busca no espaço de parâmetros para otimização do compromisso entre privacidade e utilidade foi simplificado.

- (iii) **Dificuldade:** A escolha de uma medida de utilidade razoável também é um desafio. De fato, é importante que a métrica escolhida capture diferenças semânticas entre as bases de dados, para que ela seja compreensível e intuitiva para profissionais e

analistas; adicionalmente, é desejável que seja capturado o quão bem as propriedades estatísticas dos dados são preservadas, dado um pós processamento dos dados (i.e., amostragem ou adição de ruído com privacidade diferencial local). Implementações prontas de métricas de utilidade em bibliotecas comuns da linguagem de programação *Python* são escassas e, em geral, servem a propósitos específicos.

Solução: A medida de utilidade dos dados foi implementada cuidadosamente aproveitando as estruturas de dados e operações oferecidas por bibliotecas comuns de *Python*, mas adaptando-as ao contexto do presente projeto.

3.2.4 Dificuldades referentes ao Produto 07: *Relatório de operação assistida*

- (i) **Dificuldade:** Conforme exposto na Seção 2.2, as análises experimentais do Produto 02 (*Relatório sobre os riscos à privacidade decorrentes da atual forma de divulgação dos microdados dos Censos Educacionais do Inep*), assim como os resultados do projeto piloto do Produto 04 (*Solução tecnológica e sua documentação*) e do Produto 05 (*Relatório técnico final do projeto piloto*), evidenciaram a inviabilidade da manutenção no curto prazo da divulgação de microdados dos Censos Educacionais de forma privada e útil.

Solução: Tal constatação está em consonância com a literatura técnica em controle de divulgação estatística, uma vez que os resultados obtidos foram naturalmente impactados pelo exíguo prazo disponível para adequação da divulgação de microdados dos Censos Educacionais à LGPD.

Entretanto, reiteramos que não se deve concluir que não há solução possível para divulgação dos dados dos Censos de forma privada e com razoável utilidade. Esta constatação indica que é necessária uma criteriosa ponderação sobre passos futuros. Na Seção 4 do presente documento discutimos alternativas para solução do problema, como a adoção de divulgação de dados agregados sanitizados por privacidade diferencial global ou o desenvolvimento de um método de sanitização de microdados por privacidade diferencial local desenhado e refinado especificamente para Censos Educacionais. A eventual implementação de alguma destas alternativas, entretanto, está além do escopo deste TED 8750.

Como consequência, conforme discutido na Seção 2.2, o escopo do Produto 07 foi alterado para excluir o objetivo específico referente à documentação do processo de operação assistida. Tal documentação apresentaria a aplicação, por parte da equipe do Inep, da solução a um conjunto de microdados diferente daquele utilizado no projeto piloto e no ambiente real do Instituto.¹

Foram mantidos, entretanto, os objetivos específicos de transferência de tecnologia e de capacitação da equipe do Inep para tomadas de decisões bem informadas

¹Ressaltamos que, apesar de o foco do Produto 07 ter sido alterado, todo o código fonte necessário para uma eventual aplicação dos métodos do projeto piloto por parte do Inep, incluindo manuais e documentação, foram fornecidos ao Instituto.

sobre alternativas futuras e para proporcionar uma efetiva comunicação com as partes interessadas (escolas, governo, alunos, etc.) sobre os prós e contras de cada alternativa. Em particular, provemos um treinamento da equipe do Inep para manuseio da Ferramenta ARX [1], que permite ao Instituto realizar análises futuras de riscos à privacidade em suas bases de microdados.

3.3 Dificuldades de implementação

Destacamos as seguintes dificuldades de implementação encontradas.

3.3.1 Dificuldades referentes ao Produto 02: *Relatório sobre os riscos à privacidade decorrentes da atual forma de divulgação dos microdados dos Censos Educacionais do Inep*

- (i) **Dificuldade:** Foram realizados experimentos de reidentificação e inferência de atributo sensível, individual e coletivo, em base única e longitudinal. Para isto, utilizamos o pacote `pandas`,² suportado pela a linguagem de programação *Python*. Um desafio decorrente dos resultados obtidos foi o gerenciamento de memória. A presença de células vazias nas bases de dados resultava no uso de variáveis do tipo `float` para as colunas afetadas, resultando no uso de memória na ordem de dez vezes o tamanho do arquivo publicado em formato `csv`.

Solução: Utilizamos versões alteradas dos arquivos, nas quais as células vazias foram substituídas pelo valor -1. Dessa forma, as colunas afetadas puderam ser carregadas com variáveis do tipo `int` e o uso de memória foi controlado.

Como efeito colateral, outro problema resolvido pela substituição das células vazias pelo valor -1 foi um comportamento documentado, mas pouco enfatizado, da função `groupby` do pacote `pandas`: por padrão, a função ignora registros que contenham células vazias, o que gerou resultados inconsistentes inicialmente.

- (ii) **Dificuldade:** O uso da função `groupby`,^{3 4} nativa do pacote `pandas`, apesar da praticidade, resultava em tempo elevado de execução e uso excessivo de memória no algoritmo de ataques.

Solução: Foi necessário alterar o algoritmo dos ataques de modo a otimizar o tempo gasto para execução e o uso de memória. Abandonamos o uso da função `groupby` e implementamos um algoritmo próprio que ordena a base de dados de acordo com os atributos quase-identificadores escolhidos e realiza apenas uma passagem por todos

²<https://pandas.pydata.org/>

³Documentação oficial da função `groupby` do pacote `pandas`:
<https://pandas.pydata.org/pandas-docs/stable/reference/api/pandas.DataFrame.groupby.html>

⁴Guia de uso oficial da função `groupby` do pacote `pandas`:
https://pandas.pydata.org/pandas-docs/stable/user_guide/groupby.html

os registros calculando todas as métricas de reidentificação e inferência de atributo sensível simultaneamente.

- (iii) **Dificuldade:** No Produto 02 do presente TED foram realizados experimentos de reidentificação coletiva em uma única base de dados (RCU) utilizando a ferramenta ARX. Estes experimentos serviram como uma validação independente dos experimentos originais realizados com uma implementação própria da equipe executora. As maiores bases de dados do Inep – como a do Censo da Educação Básica de 2019 – podem chegar à ordem de 50 milhões de registros com 100 atributos por registro. Esta quantidade de dados é superior àquela suportada pelo ARX.

Solução: Realizar uma modificação do software original do ARX (que tem código aberto) para que fosse possível realizar os ataques RCU nas bases do Ensino Básico. A modificação do software original foi enviada aos responsáveis por manter o repositório contendo o código-fonte do software, e após uma análise inicial, estão considerando incorporar a solução ao código original. A modificação se encontra no *branch* `morecells` do repositório oficial.⁵ Atualmente a modificação encontra-se funcional quando utilizada via API do software, entretanto, a modificação apresenta algumas incompatibilidades e *bugs* ao utilizá-la com a interface gráfica. Para que a modificação seja incorporada ao software, é necessária a correção de *bugs* para que esta fique funcional quando utilizada via interface gráfica.

3.3.2 Dificuldades referentes ao Produto 03: *Relatório técnico sobre métodos de tratamento aplicáveis aos microdados de divulgação dos Censos Educacionais do Inep*

- (i) **Dificuldade:** A `diffprivlib`⁶ é uma biblioteca na linguagem *Python* mantida pela empresa IBM e que tem um propósito geral de experimentação, investigação e desenvolvimento de aplicações utilizando privacidade diferencial. Ela contém a implementação de alguns mecanismos que satisfazem a privacidade diferencial, e por este motivo foi utilizada como parte da solução tecnológica desenvolvida para os Produto 04 e 05 do presente TED. Inicialmente a biblioteca não possuía a implementação do mecanismo *k*-RR de forma otimizada para domínios contendo tanto strings quanto valores inteiros.

Solução: Provemos nossa própria implementação deste mecanismo e o adicionamos à biblioteca.

⁵Repositório oficial da ferramenta ARX: <https://github.com/arx-deidentifier/arx>

⁶Repositório oficial da biblioteca `diffprivlib`:
<https://github.com/IBM/differential-privacy-library>

3.3.3 Dificuldades referentes ao Produto 04: *Solução tecnológica e sua documentação* e ao Produto 05: *Relatório técnico final do projeto piloto*

- (i) **Dificuldade:** Foram realizados experimentos de reidentificação e inferência de atributo sensível, apenas coletivo e em base única. Para tanto, utilizamos o pacote *pandas* para a linguagem *Python*.

Um desafio decorrente foi o gerenciamento de memória. A presença de células vazias nos bancos de dados resultava no uso de variáveis do tipo `float` para as colunas afetadas, resultando no uso de memória na ordem de dez vezes o tamanho do arquivo publicado em formato `csv`.

Solução: Utilizamos versões alteradas dos arquivos, nas quais as células vazias foram substituídas pelo valor `-1`. Dessa forma, as colunas afetadas puderam ser carregadas com variáveis do tipo `int` e o uso de memória foi controlado.

- (ii) **Dificuldade:** Como as bases de dados utilizadas possuem milhões de registros e dezenas de colunas, uma das maiores limitações para realização das análises discutidas no presente TED 8750 é a limitação de recursos computacionais. Essa quantidade de dados requer elevada capacidade de armazenamento em memória primária para realização das operações dos ataques e análise de utilidade.

Solução: Além de contar com um servidor de processamento com 96GB de memória RAM, para alguns experimentos foram utilizadas técnicas de particionamento dos dados em tamanhos menores e realização das operações sobre as partições criadas.

- (iii) **Dificuldade:** Os experimentos de cálculo de risco, tanto em bases de dados sanitizadas por amostragem quanto em bases sanitizadas por privacidade diferencial- ϵ local, se baseiam em conjuntos de colunas da base de dados, podendo esses conjuntos variar sobre qualquer combinação das colunas ou de subconjuntos das colunas da base. Desta forma, a quantidade de possíveis experimentos cresce exponencialmente de acordo com a quantidade de colunas sendo analisadas.

Solução: Para realizar um número suficiente de experimentos em tempo hábil foi necessário utilizar técnicas de paralelização de código, o que torna o gerenciamento de memória primária e o controle da saída mais complexos.

- (iv) **Dificuldade:** Para realizar os ataques de forma eficiente, os modelos descritos no Produto 05 do presente TED 8750 não devem ser implementados cegamente de acordo com as definições matemáticas, pois uma implementação ingênua implica em tempo de execução muito grande.

Solução: Técnicas de engenharia de *software* foram utilizadas para unir cálculos intermediários que se repetem entre as análises, reaproveitar estruturas de dados que não se alteram entre experimentos e dividir os dados em partições menores para otimizar a utilização de memória primária. Em particular, um bom domínio e

conhecimento da linguagem *Python* favorece a implementação de programas eficientes, que utilizam bibliotecas adequadas para exploração e análise de dados. Essas bibliotecas disponibilizam estruturas de dados e operações altamente otimizadas sobre elas, que tornam o programa muito mais eficiente.

- (v) **Dificuldade:** A biblioteca `price-library`⁷ faz parte da solução tecnológica desenvolvida pela equipe executora para os Produtos 04 e 05 do presente TED 8750. Durante o seu desenvolvimento, foram realizados experimentos de adição de ruído e cálculo do risco de reidentificação coletiva em uma única base de dados sanitizada por privacidade diferencial local ($\widehat{RCU}^{ldp}$) em um recorte da base da Educação Básica de 2019 contendo 1 milhão de registros. O tempo de execução destes experimentos foi de aproximadamente 26 horas, e, fazendo uma projeção do tempo de execução necessário para executar o mesmo experimento utilizando a base completa da Educação Básica de 2019, concluímos que seria inviável realizar uma análise relevante da utilização da privacidade diferencial local no Censo da Educação Básica de 2019 dentro do prazo acertado com o Inep.

Solução: Após uma análise minuciosa do código-fonte, foram encontrados alguns pontos onde era possível realizar otimizações. Dentre as primeiras otimizações realizadas, tivemos a paralelização do código, que diminuiu drasticamente o tempo de execução. Posteriormente, seguimos com a refatoração do código do mecanismo k -RR adicionado à biblioteca da IBM `diffprivlib`, que por sua vez causou uma considerável diminuição no tempo de execução. As duas otimizações diminuíram o tempo de execução dos experimentos de 1 dia e 2 horas para aproximadamente 1 minuto e 30 segundos.

- (vi) **Dificuldade:** Nos Produtos 02 e 03 do presente TED foram apresentadas definições teóricas de análises de risco à privacidade, análise de utilidade dos dados e de métodos de mitigação de risco à privacidade. A implementação de um *software* que realiza computações de modelagens teóricas precisa ser feita com bastante cuidado para que sua corretude esteja em conformidade com as definições teóricas. A biblioteca `price-library` já citada anteriormente, por se tratar de um *software* que realiza diversas computações derivadas de extensas definições teóricas, demandou um extenso trabalho de conferência de corretude.

Solução: Foram criados diversos testes para verificar a corretude da biblioteca, e a criação de alguns desses testes se mostrou laboriosa pelo fato de ter sido necessário criar exemplos fictícios e calcular manualmente valores como o sucesso probabilístico do adversário a fim de comparar com a saída retornada pelos módulos da biblioteca.

- (vii) **Dificuldade:** Mesmo após implementar otimizações na biblioteca `price-library` descritas acima, o tempo de execução para calcular o risco de reidentificação coletiva em uma única base de dados sanitizada por privacidade diferencial local ($\widehat{RCU}^{ldp}$)

⁷Código-fonte e documentação da biblioteca `price-library`, com acesso permitido somente para os usuários repassados pelo Inep à equipe executora: <https://gitlab.com/ted8750/price-library>

ainda permaneceu bastante elevado para bases de dados como a base completa da Educação Básica de 2019.

Solução: Executamos experimentos de teste para estimar o tempo de execução deste cálculo na base completa. A partir destes testes, e dado o tempo disponível para a execução do Produto, concluímos que o cálculo seria viável para um recorte da base contendo menos registros, e então foi selecionado um subconjunto da base contendo somente os estudantes do Distrito Federal. O objetivo do experimento não foi prejudicado pois os riscos obtidos para o subconjunto dos alunos do Distrito Federal são um limite inferior para o risco presente na base completa da Educação Básica de 2019, conforme detalhado no Produto 05 do presente TED 8750.

4 Análise de resultados obtidos

Nesta seção avaliamos o nível de atendimento aos objetivos propostos no plano de trabalho deste TED 8750 e discutimos as principais lições aprendidas durante sua execução.

De acordo com o plano de trabalho deste TED 8750:

O objetivo geral do projeto é contribuir de forma significativa para a melhoria da política de disseminação de microdados do Inep, especificamente no que se refere aos microdados dos Censos Educacionais, adequando-a à legislação vigente, em especial a Lei Geral de Proteção de Dados Pessoais – LGPD (Lei 13.709/2018).

Em nossa avaliação, tal objetivo foi satisfatoriamente atingindo no presente TED 8750. Mais especificamente, podemos organizar os resultados obtidos nas três etapas a seguir.

- **Identificação dos riscos à privacidade inerentes ao atual processo de divulgação dos Censos pelo Inep.** A pertinência e urgência do presente projeto ficaram indubitavelmente evidenciadas pelos resultados obtidos já nos dois primeiros produtos. A contextualização da situação do Inep frente ao panorama internacional, provida no Produto 01 (*Relatório sobre o panorama internacional e o contexto do Inep a respeito dos métodos de tratamento de controle de privacidade na divulgação estatística*), evidenciou que o Instituto adota atualmente práticas de proteção à privacidade significativamente menos estritas que seus pares internacionais. Além disso, as análises quantitativas do Produto 02 (*Relatório sobre os riscos à privacidade decorrentes da atual forma de divulgação dos microdados dos Censos Educacionais do Inep*) demonstraram de forma inequívoca que a atual forma de divulgação dos Censos Educacionais pelo Inep –baseada apenas em desidentificação e pseudonimização– submete os titulares dos dados a consideráveis riscos de violação de privacidade, incluindo reidentificação e inferência de atributos sensíveis. Em nossa visão tal situação poderia constituir em uma violação da Lei Geral de Proteção de Dados Pessoais (LGPD). Não encontramos na literatura nenhum outro trabalho que tenha efetuado uma análise quantitativa tão profunda a respeito dos riscos à privacidade relativos aos Censos Educacionais do Inep quanto a realizada no presente projeto.

- **Análise de novas técnicas de divulgação aplicáveis, que melhor conciliem privacidade e transparência.** O Produto 03 (*Relatório técnico sobre métodos de tratamento aplicáveis aos microdados de divulgação dos Censos Educacionais do Inep*) apresentou técnicas do estado-da-arte para mitigação de danos à privacidade aplicáveis aos Censos, incluindo aquelas baseadas em microdados, dados agregados, salas seguras, aplicações web e dados sintéticos. Apresentamos as premissas de cada técnica, seus custos e benefícios em relação ao balanceamento entre a privacidade e utilidade, além de uma sugestão de plano de ação. Ocorreram várias interações entre a equipe executora e o Inep, visando a uma tomada de decisão bem fundamentada. Dada uma expectativa arraigada pela disponibilidade de microdados dos Censos, o Inep optou pela implementação no projeto piloto de duas técnicas de divulgação deste tipo de dado: (i) por amostragem; e (ii) por privacidade diferencial local.
- **Implementação de um projeto-piloto que avaliasse a adequação de duas destas técnicas aos Censos Educacionais do Inep.** Quanto ao cerne deste TED 8750, os resultados do projeto piloto, consistindo no Produto 04 (*Solução tecnológica e sua documentação*) e no Produto 05 (*Relatório técnico de implantação*), evidenciaram a inviabilidade da manutenção no curto prazo da divulgação de microdados dos Censos Educacionais de forma privada e útil. Tal constatação está em consonância com a literatura técnica, e foi naturalmente impactada pelo exíguo prazo disponível para adequação da divulgação de microdados dos Censos Educacionais à LGPD.

Na nossa avaliação, esta constatação é uma contribuição central do presente TED 8750, por dois motivos:

- Esta informação é crucial para as futuras tomadas de decisão do Inep sobre a divulgação dos Censos Educacionais, ponderando-se entre soluções de curto prazo –implementáveis de forma relativamente rápida, mas potencialmente sub-ótimas quanto à utilidade provida– e soluções de longo prazo –mais úteis, porém que demandam maior investimento de tempo e pessoal especializado.
- Esta informação provê ao Inep subsídios para uma efetiva comunicação com as partes interessadas nos Censos Educacionais sobre os desafios técnicos da adequação da divulgação de microdados à LGPD. Isto pode auxiliar tais partes a compreenderem as nuances de futuras decisões do Inep –eventualmente, inclusive, sobre formas de divulgação que restrinjam microdados.

De fato, já observamos que a opção por qualquer método de mitigação deve passar pela harmonização de interesses possivelmente conflitantes de vários atores. No caso dos Censos Educacionais do Inep, os atores incluem os titulares de dados (estudantes, professores, escolas, etc.), analistas (demógrafos, entidades civis e governamentais, etc.), o governo (que regulamenta tanto questões de privacidade quanto de transparência e acesso à informação), além do próprio Inep (que tem que conciliar de forma realista as demandas dos vários atores com a sua capacidade e recursos para atendê-las).

Entretanto, ressaltamos que não se deve concluir que não há solução possível para divulgação dos dados dos Censos de forma privada e com razoável utilidade, mas sim que é necessária uma criteriosa ponderação sobre passos futuros. Neste sentido, identificamos alternativas para tratamento dos dados pelo Inep no futuro:

- **Alternativa 1:** Abandono da divulgação de microdados –exceto em salas seguras– em favor da divulgação de dados agregados sanitizados por privacidade diferencial. Conforme plano de ação proposto no Produto 03 deste TED 8750, avaliamos esta opção como a mais promissora para os Censos Educacionais do Inep.
- **Alternativa 2:** Desenvolvimento de um método de sanitização de microdados por privacidade diferencial local desenhado e refinado especificamente para os Censos Educacionais. Esta opção demandaria tempo e recursos significativamente maiores, incluindo atividades de pesquisa e desenvolvimento.

A eventual implementação de alguma destas alternativas acima, entretanto, está fora do escopo do presente TED 8750.

Por fim, a Tabela 4.0.1 apresenta uma avaliação dos resultados pertinentes a cada objetivo específico previsto no plano de trabalho.

Objetivo específico	Análise de atendimento
Objetivo 01: Levantar o panorama internacional dos procedimentos de garantia da privacidade em bases de dados de pesquisas estatísticas, em especial nos produtos de disseminação dos microdados. O contexto desta pesquisa bibliográfica deve abranger os normativos técnicos e as políticas de tratamento de dados pessoais de outros institutos relevantes de pesquisas estatísticas, no cenário internacional, relacionando-os ao contexto do Inep. O objetivo desta pesquisa é estabelecer a percepção da situação atual do Inep frente a institutos similares em outros países, além de reconhecer os desafios inerentes e as melhores práticas aplicáveis. Neste sentido, a pesquisa será fundamental para a definição das melhorias desejadas na atual política de disseminação de microdados do Inep, uma vez que trará evidências sobre o tratamento técnico realizado por outros institutos e o embasamento necessário à tomada de decisão.	Atendido com sucesso no Produto 01 (<i>Relatório sobre o panorama internacional e o contexto do Inep a respeito dos métodos de tratamento de controle de privacidade na divulgação estatística</i>).
Objetivo 02: Alinhar qualquer proposta apresentada no âmbito do projeto aos pressupostos legais e normativos vigentes ou com vigência iminente, especialmente aqueles que se referem aos critérios apresentados pela Comissão Econômica das Nações Unidas para a Europa - UNECE, pelo IBGE, pela Lei de Acesso à Informação - LAI (Lei 12.527/2011) e pela Lei Geral de Proteção de Dados Pessoais - LGPD (Lei 13.709/2018).	Realizado pelo Inep internamente. A interpretação jurídica de normas é considerada fora do escopo de atuação da equipe executora do presente TED 8750. Quaisquer dúvidas legais por parte do Inep devem ser esclarecidas junto a órgãos jurídicos competentes e via eventuais consultas à Agência Nacional de Proteção de Dados - ANPD.
Objetivo 03: Avaliar o risco potencial de identificação das pessoas a quem os dados estatísticos se referem nos microdados do Censo Escolar da Educação Básica e do Censo da Educação Superior.	Atendido com sucesso no Produto 02 (<i>Relatório sobre os riscos à privacidade decorrentes da atual forma de divulgação dos microdados dos Censos Educacionais do Inep</i>).
Objetivo 04: Apresentar alternativas, a partir do panorama encontrado, de métodos de controle de divulgação com base nas abordagens pesquisadas. Estas alternativas devem fornecer aos gestores do Inep uma percepção clara dos benefícios, custos e riscos da adoção de cada abordagem. Este estudo técnico deve apresentar as técnicas propostas para o tratamento dos dados de forma que as equipes do Inep sejam capazes de compreender e reproduzi-las, inclusive independentemente do apoio de ferramentas estranhas ao ambiente do Inep e sem o auxílio de equipes externas, após o repasse de conhecimento.	Atendido com sucesso no Produto 03 (<i>Relatório técnico sobre métodos de tratamento aplicáveis aos microdados de divulgação dos Censos Educacionais do Inep</i>).
Objetivo 05: Desenvolver e implantar um processo computacional baseado em até dois métodos de controle de divulgação escolhidos pelo Inep dentre aqueles elencados pelo DCC/UFGM no item anterior, como forma de aprimorar sua atual política de disseminação de microdados educacionais. Este processo deverá respeitar o ambiente tecnológico de infraestrutura e de sistemas existente no Inep e considerar, dentre as bases de dados dos Censos Educacionais, a que melhor se adequa aos objetivos de complexidade necessários para a realização de uma aplicação piloto dos métodos escolhidos. O objetivo do teste de conceito é apresentar os resultados da aplicação prática, quando será possível observar os resultados e identificar a sua aderência às necessidades iniciais.	Atendido com sucesso no Produto 04 (<i>Solução tecnológica e sua documentação</i>), no Produto 05 (<i>Relatório técnico final do projeto piloto</i>) e no Produto 06 (<i>Relatório técnico de implantação</i>).
Objetivo 06: Desenvolver capacidade técnica no Instituto para o tratamento de dados pessoais conforme as disposições da legislação vigente e as melhores práticas internacionais do setor.	Objetivos readequados conforme descrito na Seção 2.2. Após readequação, objetivos foram atendidos no Produto 07 (<i>Relatório de operação assistida</i>).
Objetivo 07: Aplicar o conjunto de métodos de controle de divulgação por meio do processo computacional desenvolvido em outro conjunto de microdados dos Censos Educacionais, com suporte e assistência técnica, de forma a possibilitar a internalização da tecnologia desenvolvida e garantir aderência às disposições da legislação vigente.	

Tabela 4.0.1: Análise dos objetivos específicos previstos no plano de trabalho.

5 Considerações finais

Avanços tecnológicos exigem que a sociedade reveja continuamente sua percepção sobre riscos de violação de privacidade, e em vários países, incluindo o Brasil, observa-se um fortalecimento da legislação sobre o assunto. O Inep, produtor e divulgador de vários Censos Educacionais de relevância nacional, tem o desafio de adequar-se a estas novas exigências, encontrando soluções que conciliem privacidade e transparência na divulgação de informação.

Acreditamos que objetivos deste TED 8750 foram cumpridos com êxito. Foi provida ao Inep informação crucial para tomadas de decisões futuras, balanceando soluções de curto prazo –implementáveis de forma relativamente rápida, mas potencialmente sub-ótimas quanto à utilidade provida– e soluções de longo prazo –mais úteis, porém que demandem maior investimento de tempo e pessoal especializado. Esta informação ainda subsidia uma comunicação efetiva com as partes interessadas sobre os desafios técnicos na divulgação de microdados, facilitando a compreensão sobre eventuais decisões futuras.

Nós da equipe executora do DCC/UFMG relatamos uma grande satisfação na execução deste TED 8750. Além de extremamente relevante do ponto de vista social, educacional e sociológico, o objeto deste projeto apresentou desafios técnicos, metodológicos e científicos que criaram inestimáveis oportunidades de aprendizado para nossa equipe. Adicionalmente, experimentamos uma significativa sinergia com a equipe do Inep, o que se refletiu em interações sempre produtivas, propositivas e construtivas. Acreditamos que tal sinergia tenha sido um fator significativo no êxito deste projeto.

Por fim, em nossa visão este TED 8750 evidencia o pioneirismo por parte Inep, no plano nacional, quanto ao enfrentamento do desafio de conciliação entre privacidade e transparência na divulgação de estatísticas oficiais. Foge ao nosso conhecimento a existência de qualquer outra agência brasileira produtora de dados semelhantes que tenha realizado um estudo tão aprofundado e abrangente sobre o assunto. Como consequência, o Inep se encontra em uma sólida posição para servir como liderança e exemplo nacional no enfrentamento da questão, abrindo caminho para uma nova, mais moderna e criteriosa abordagem. Felizmente, a literatura técnica apresenta avanços constantes no tema, com novas soluções sendo produzidas em um ritmo acelerado. Certamente o Inep se beneficiará destes avanços, ao mesmo tempo em que atua como liderança no Brasil no enfrentamento destes desafios tão relevantes para nossos concidadãos.

Referências Bibliográficas

- [1] Fabian Prasser and Contributors. ARX - Data Anonymization Tool, 2020. Disponível em: <https://arx.deidentifier.org/>.
- [2] Latanya Sweeney. Simple Demographics Often Identify People Uniquely, 2000. Disponível em: https://kilthub.cmu.edu/articles/Simple_Demographics_Often_Identify_People_Uniquely/6625769/1.

Lista de Siglas

ABS *Australian Bureau of Statistics.*

DCC Departamento de Ciência da Computação da UFMG.

DEED Diretoria de Estatísticas Educacionais do Inep.

EUA Estados Unidos da América.

GDPR *General Data Protection Regulation.*

IBGE Instituto Brasileiro de Geografia e Estatística.

INEP Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira.

INSCRIPT *Laboratory of Information Security, Cryptography, Privacy, and Transparency* (Laboratório de Segurança da Informação, Criptografia, Privacidade e Transparência).

LAI Lei de Acesso à Informação.

LDP privacidade diferencial local, em suas iniciais do inglês *local differential privacy*.

LGPD Lei Geral de Proteção de Dados Pessoais.

LGPDP Lei Geral de Proteção de Dados Pessoais.

NCES *National Center for Education Statistics.*

ONU Organização das Nações Unidas.

RGPD Regulamento Geral de Proteção de Dados.

TED Termo de Execução Descentralizada.

UFMG Universidade Federal de Minas Gerais.

USCB *United States Census Bureau.*

Glossário

adversário Entidade contra quem se deseja proteger a informação sensível sobre indivíduos. O adversário pode ser uma pessoa física ou uma organização. Não necessariamente se atribuem intenções deletérias ao adversário: é possível que um consumidor legítimo de uma divulgação estatística (e.g., um pesquisador acadêmico) atue inadvertidamente como adversário ao inferir informação sensível de indivíduos no decurso de ações idôneas.

analista de dados Pessoa ou entidade considerada como usuária legítima de uma divulgação de dados.

anonimização Utilização de meios técnicos razoáveis e disponíveis no momento do tratamento, por meio dos quais um dado perde a possibilidade de associação, direta ou indireta, a um indivíduo. Técnicas de anonimização incluem, mas não se limitam a, *desidentificação*, *k-anonymity*, *l-diversity* e *privacidade diferencial*, dentre outras. Diferentes técnicas têm diferentes graus de sucesso, e algumas são comprovadamente menos eficazes que outras.

ataque Ação ou conjunto de ações pelas quais o adversário pode obter informação sensível sobre titulares de dados. Ao termo “ataque” não se atribui uma intenção necessariamente deletéria: uma utilização legítima dos dados (e.g., para pesquisa científica) pode resultar inadvertidamente em um ataque se porventura revelar informação sensível.

ataque de inferência de atributo Ataque em que o objetivo do adversário é inferir o valor assumido por um atributo considerado como sensível para um conjunto de indivíduos, independentemente de se estes indivíduos tenham sido reidentificados com sucesso ou não.

ataque de reidentificação Ataque em que o objetivo do adversário é determinar uma correspondência entre registros presentes na base de dados e os titulares desses registros, i.e., os indivíduos do mundo real a quem os registros se refere.

ataque longitudinal Ataque que se utiliza de informações divulgadas ao longo do tempo (e.g., várias liberações de informação referentes a uma mesma pesquisa, ou pesquisas em anos consecutivos que se referem aos mesmos titulares).

atributo não sensível Atributo cujo valor não é considerado digno de proteção em si mesmo em um dado contexto.

Australian Bureau of Statistics (ABS) Escritório australiano com mandato de coleta de dados estatísticos, incluindo a realização do censo do país.

banco de dados O mesmo que *base de dados*.

base de dados Conjunto estruturado de dados pessoais, estabelecido em um ou em vários locais, em suporte eletrônico ou físico.

Censo da Educação Básica Principal pesquisa estatística educacional do país, abrangendo a Educação Básica e Profissional.

Censo da Educação Superior Mais completa pesquisa estatística sobre as Instituições de Educação Superior do país.

conhecimento a posteriori do adversário Conhecimento a respeito da informação sensível que o adversário adquire ao revisar seu conhecimento a priori de acordo com o resultado da execução de um ataque.

conhecimento a priori do adversário Conhecimento a respeito da informação sensível que o adversário possui antes mesmo de executar um ataque.

consulta Uma recuperação de dados ou informações a partir de uma base de dados, normalmente efetuada em linguagem específica.

controle de divulgação estatística Área que estuda como compartilhar publicamente informações sobre um conjunto de dados, revelando padrões estatísticos a respeito dos mesmos ao mesmo tempo em que se protegem informações sensíveis sobre os indivíduos no conjunto de dados. O controle de divulgação estatística deve balancear a manutenção da utilidade dos dados (com relação a um analista legítimo) com garantias de privacidade para os titulares dos dados (contra um adversário).

curador de dados Pessoa ou entidade responsável pela integração de dados coletados de várias fontes, além da organização, publicação e apresentação dos dados de forma que o valor dos dados seja mantido ao longo do tempo e os dados permaneçam disponíveis para reutilização e preservação. A curadoria de dados inclui todos os processos necessários para a criação, manutenção e gerenciamento de dados controlados e com princípios, juntamente com a capacidade de agregar valor aos dados.

dado agregado Dado sumarizado correspondendo a uma agregação das informações dos microdados para unidades mais amplas, ou mesmo a uma função computada sobre essas informações (e.g., frequência, média ou outros tipos de análises).

dado anonimizado Dado relativo a titular que não possa ser identificado, considerando a utilização de meios técnicos razoáveis e disponíveis na ocasião de seu tratamento.

dado pessoal Informação relacionada a pessoa natural identificada ou identificável.

dado pessoal sensível Dado pessoal sobre o qual a preocupação quanto à privacidade (e.g., sobre origem racial ou étnica, convicção religiosa, opinião política, filiação a sindicato ou a organização de caráter religioso, filosófico ou político, dado referente à saúde ou à vida sexual, dado genético ou biométrico), quando vinculado a uma pessoa natural.

dados sintéticos Dados especialmente criados para substituir dados reais em divulgações de microdados ou para geração de dados tabulares. São gerados de forma a preservar algumas propriedades estatísticas dos dados originais, tais como distribuições marginais, médias e quartis.

degradação de privacidade Comparação entre o *sucesso a posteriori* do adversário –i.e., depois de executar o ataque– e o *sucesso a priori* do adversário –i.e., antes de executar o ataque–em seu intuito de inferir informação sensível. Intuitivamente, quanto maior a degradação de privacidade de um ataque, maior o incremento no sucesso esperado do adversário em obter informação sensível.

desanonimização O mesmo que *reidentificação*.

desidentificação Técnica de tratamento de dados pela qual são removidos possíveis identificadores individuais óbvios dos registros (e.g., nome, CPF, RG, ou endereços em níveis mais detalhados que as cidades), na expectativa de dificultar-se uma eventual reidentificação do titular.

differential privacy O mesmo que *privacidade diferencial*.

histograma Forma de divulgação de informação sobre uma base de dados contendo apenas projeções marginais da distribuição de registros por valores.

identificador direto Atributo que pode unicamente identificar um indivíduo, como nome, RG, CPF, ou número de telefone celular.

inferência de atributo Prática de combinar dados anonimizados com informações publicamente disponíveis ou dados auxiliares, a fim de descobrir o valor de algum atributo sensível de um indivíduo.

informação auxiliar Em relação a uma divulgação de dados de interesse, informação auxiliar é qualquer informação que se possa obter a respeito de um indivíduo através de outros canais que não sejam a divulgação de dados de interesse em si mesma (e.g, via *web*, outros registros públicos, jornais ou revistas, conhecimento prévio).

informação lateral O mesmo que *informação auxiliar*.

informação sensível Informação considerada como digna de proteção. Exemplos típicos incluem a situação médica, a renda, ou vida pessoal de um indivíduo.

Inscript *Laboratory of Information Security, Cryptography, Privacy, and Transparency*, laboratório de pesquisa do DCC/UFMG focado em segurança da informação, criptografia, privacidade e transparência.

Lei de Acesso à Informação (LAI) Lei brasileira 12.527/2011, que trata dos procedimentos a serem observados pelo Estado para garantir o acesso a informações previsto na Constituição Federal do Brasil de 1988.

Lei Geral de Proteção de Dados Pessoais (LGPD ou LGPDP) Lei brasileira 13.709/2018, que dispõe sobre o tratamento de dados pessoais, inclusive nos meios digitais, por pessoa natural ou por pessoa jurídica de direito público ou privado, com o objetivo de proteger os direitos fundamentais de liberdade e de privacidade e o livre desenvolvimento da personalidade da pessoa natural.

método global Método de tratamento que conta com um curador de dados responsável pela coleta de informações individuais e aplicação das técnicas de proteção. Nesse tipo de método assume-se que o curador é uma entidade digna de confiança para tratamento da informação sensível, e o tratamento é aplicado ao conjunto dos dados de forma holística.

método local Método de tratamento em que a proteção de privacidade é aplicada aos dados de cada titular individualmente.

método não perturbativo Método de tratamento que altera a informação provida apenas por diminuir sua granularidade ou por suprimi-la por partes, mas sem introduzir informação ruidosa.

método perturbativo Método de tratamento que pode introduzir informação inverídica de forma controlada na divulgação, seja por criação de dados falsos ou pela inserção de ruído nos dados.

métrica determinística de sucesso do adversário Função que mensura o sucesso do adversário e forma absoluta, retornando um valor qualitativo dependendo de se a informação desejada foi ou não recuperada com absoluta certeza.

métrica de utilidade específica Métrica de utilidade que parte do princípio de que uma divulgação será utilizada para uma tarefa preestabelecida e então medem a qualidade da divulgação para esta tarefa.

métrica de utilidade geral Métrica de utilidade que tenta diminuir ao máximo a distorção entre os dados originais e os dados tratados, sob a premissa de se a distribuição de probabilidade sobre registros após o tratamento for similar à distribuição antes do tratamento, então os dados tratados serão úteis para a maioria dos analistas aplicações.

métrica probabilística de sucesso do adversário Função que mensura o sucesso do adversário de forma probabilística, retornando um valor quantitativo representando o grau de certeza com o qual a informação desejada foi recuperada.

microdado A menor fração de um dado e pode estar relacionado a uma pesquisa ou avaliação; o dado em sua menor forma de agregação. Microdados geralmente carregam informação sobre entidades em nível individual (e.g., pessoas, escolas, institutos).

mitigação, técnica ou método de O mesmo que *tratamento de dados*.

National Center for Education Statistics (NCES) Agência federal dos EUA responsável por divulgar dados sobre educação e informações sobre finanças de distritos escolares.

negação plausível (*plausible deniability*) Capacidade de um titular de dados negar de forma crível para um adversário alguma propriedade sobre sua informação sensível (e.g., negar sua participação em um estudo, ou que um de seus atributos tenha um valor específico), mesmo após um ataque.

privacidade diferencial Método semântico de tratamento de dados que garante formalmente que apenas uma quantidade negligível de informação sobre um dado indivíduo pode ser obtida a partir dos dados publicados, independentemente da participação ou não do indivíduo na pesquisa.

privacidade diferencial global Variante da privacidade diferencial em que o ruído é adicionado ao resultado de cada consulta realizada.

privacidade diferencial local Variante da privacidade diferencial em que o ruído é adicionado diretamente aos dados coletados.

pseudonimização Técnica de tratamento de dados pela qual atribui-se um código individual artificialmente criado a cada registro de uma base de dados, acompanhada da transferência de identificadores diretos (como nome, CPF e RG) para outra base de dados. Dessa forma, o controlador é capaz de mapear identificadores diretos em uma base de dados a registros específicos na outra base através do uso dos códigos individuais, ao mesmo tempo em que se dificultam tentativas de reidentificação do titular por parte de agentes externos.

quaseidentificador Informações que não são, em si mesmas, identificadores únicos, mas que estão suficientemente correlacionadas com uma entidade a ponto de poderem ser combinadas com outros quaseidentificadores para criar um identificador exclusivo.

registro Informação em uma base de dados correspondente a um indivíduo específico.

reidentificação Prática de combinar dados anonimizados com informações publicamente disponíveis ou dados auxiliares, a fim de descobrir o indivíduo ao qual os dados pertencem.

sala segura Lugar físico seguro que possui servidores que contém os dados reais de pesquisas sociais e pesquisas estatísticas de alguma natureza (por exemplo, dados médicos ou dados de censos populacionais) e terminais que os usuários podem utilizar para acessar esses dados de forma controlada.

sucesso a posteriori do adversário Medida (determinística ou probabilística) do quanto de informação sensível o adversário possui após a execução do ataque, usando a informação a posteriori adquirida.

sucesso a priori do adversário Medida (determinística ou probabilística) do quanto de informação sensível o adversário já possui antes mesmo de executar um ataque, usando apenas seu conhecimento a priori.

sumário estatístico Forma de divulgação de informação sobre uma base de dados contendo apenas resposta a um conjunto de consultas estatísticas predeterminadas.

titular Pessoa natural a quem se referem os dados pessoais que são objeto de tratamento.

titular de dados Pessoa ou entidade a quem os dados coletados, processados ou divulgados se referem diretamente.

tratamento (de dados) Toda operação realizada com dados pessoais, como as que se referem a coleta, produção, recepção, classificação, utilização, acesso, reprodução, transmissão, distribuição, processamento, arquivamento, armazenamento, eliminação, avaliação ou controle da informação, modificação, comunicação, transferência, difusão ou extração.

United States Census Bureau (USCB) Agência federal dos EUA responsável por divulgar dados sobre população e economia.

utilidade Propriedade de uma divulgação servir aos propósitos legítimos do analista de dados, provendo a ele a informação desejada.